

经济学博士的数学工具箱

一份面向经济学博士生的工具性数学指南

周睿 编著

2026 年

如何阅读本书

这本书写给正在念经济学博士、却时常被数学“卡一下”的人——包括我自己。经济学的核心课程（微观、宏观、计量）会不断借用数学工具：计量里大量的线性代数，微观里的最优化与比较静态，宏观里的动态规划，决策论与博弈论里的概率、测度与贝叶斯更新。这些工具往往散落在不同的数学课本里，各讲各的、各有各的记号，且大多是为数学家而非经济学家写的——它们把“严格”放在第一位，却很少告诉你**这个工具是用来干什么的**。本书想做的，正是把这些工具集中到一处，并且始终站在使用者的角度来讲。

每个知识点都按“三件套”来写

本书不追求数学课本那种环环相扣的逻辑链条；相反，它以**工具**为单位来组织，每一个工具都尽量回答三个问题：

- **它解决什么问题（用处）**——先说清楚经济学家为什么需要它，它在你将来会遇到的哪类问题里登场。
- **它从哪里来（推导）**——给出关键的推导与直觉，让你看清这个结论不是从天而降，而是可以自己重建的。证明以“讲明白”为标准，少数极重的纯数学构造只陈述并给直觉、不逐行搭建。
- **它以后用在哪（去处）**——指出它在微观、宏观、计量乃至后续章节里的具体落点，把孤立的工具接回经济学的主干。

正因如此，各章之间**不强求严丝合缝的先后衔接**：你可以按需跳读，遇到不熟的前置概念时再回头翻查。每章开头会点明它依赖哪些前面的工具。

彩框颜色约定

• 绿色：定义

——我们赖以构建的对象与概念。

• 蓝色：定理 / 命题

——核心结论，通常附证明。

• 粉色：假设

——一个论证所维持的前提。

• 淡紫：要点框

——对工具性的提炼，或一句话点透的关键直觉。

- 全书还穿插着**例**（worked examples）与**注**（remarks）。

记号约定

向量用粗体小写, 如 $\mathbf{x}, \boldsymbol{\beta}$; 矩阵用粗体大写, 如 $\mathbf{A}, \mathbf{H}$; 转置记为 $\mathbf{A}^\top$, 逆记为 $\mathbf{A}^{-1}$ 。实数集记 $\mathbb{R}$, n 维欧氏空间记 $\mathbb{R}^n$ 。梯度记 ∇f , Hessian 记 $\nabla^2 f$; 映射 $\mathbf{F}$ 关于变量组 $\mathbf{x}$ 的 Jacobian 记 $\mathbf{D}_{\mathbf{x}} \mathbf{F}$ 。概率测度记 $\mathbb{P}$, 期望记 $\mathbb{E}(\cdot)$, 方差、协方差记 $\text{Var}(\cdot)$ 、 $\text{Cov}(\cdot, \cdot)$; σ -代数等用花体 $\mathcal{F}, \mathcal{B}$ 。依概率、依分布收敛分别记 $\xrightarrow{p}$ 、 $\xrightarrow{d}$ 。各章若另有局部记号, 会在该章开头声明。

目录

第一部分 线性代数：计量经济学的引擎	13
第一章 向量空间、线性无关、基与维数	14
1.1 为什么从向量空间讲起	14
1.2 向量空间	14
1.3 线性组合与张成	15
1.4 线性无关	16
1.5 基与坐标	18
1.6 维数与替换定理	20
1.7 子空间	21
1.8 小结：本章工具通向何处	22
第二章 矩阵、秩、行列式与线性方程组的解结构	24
2.1 从正规方程说起	24
2.2 矩阵作为线性映射	24
2.3 四个基本子空间	25
2.4 秩：行秩等于列秩	26
2.5 秩-零化度定理	27
2.6 $\mathbf{Ax} = \mathbf{b}$ 解的存在性与结构	28
2.7 满秩、列满秩、行满秩	30
2.8 行列式：可逆性的数值判据与体积	31
2.9 去处：OLS 何时被唯一确定	33
第三章 内积、正交、投影与最小二乘	36
3.1 从拟合一条直线说起	36
3.2 内积、范数与正交	37
3.3 正交补与投影定理	38
3.4 投影矩阵	39
3.5 Gram-Schmidt 正交化	41
3.6 最小二乘即正交投影	43
3.7 几处去处：FWL、 R^2 与方差分解	44

第四章 特征值、特征向量与对角化	47
4.1 方向不变的轴：特征值与特征向量	47
4.2 特征多项式：怎样把特征值找出来	48
4.3 代数重数与几何重数	50
4.4 可对角化：凑齐 n 个线性无关的特征向量	51
4.5 相似变换：换坐标系看同一台变换	53
4.6 迹等于特征值之和，行列式等于特征值之积	54
4.7 矩阵幂：对角化最直接的红利	55
4.8 去处：稳定性、Markov 链与通往谱定理	56
第五章 对称矩阵、谱定理、二次型与正定性	59
5.1 对称矩阵：为什么经济学里到处是它	59
5.2 谱定理：实、正交、可对角化	60
5.3 二次型与正交换元	61
5.4 正定、半正定、负定、不定	62
5.5 几何：等值线的形状由特征值决定	64
5.6 Rayleigh 商：特征值是二次型的极值	66
5.7 去处：协方差、二阶条件、白化与 Cholesky	67
第六章 奇异值分解与降维	69
6.1 为什么需要一把“万能分解”	69
6.2 奇异值分解：陈述与几何	70
6.3 奇异值从哪来：与 $\mathbf{A}^T \mathbf{A}$ 、 $\mathbf{A} \mathbf{A}^T$ 的关系	71
6.4 低秩近似：Eckart-Young 定理	73
6.5 Moore-Penrose 广义逆与最小范数最小二乘解	75
6.6 条件数与多重共线性诊断	76
6.7 去处：PCA、共线性、弱工具与压缩	78
第七章 矩阵微积分：向量与矩阵求导	79
7.1 布局约定：先把记号钉死	79
7.2 标量对向量：四条核心恒等式	80
7.3 链式法则与梯度的几何	82
7.4 应用一：OLS 的一阶条件	83
7.5 标量对矩阵与迹技巧	84
7.6 应用二：正态线性模型的 MLE 与信息矩阵	86
7.7 小结：一张可随身携带的规则表	87
第二部分 分析与拓扑：存在性与收敛的语言	88
第八章 度量空间、开集闭集与序列收敛	89
8.1 为什么经济学也需要拓扑语言	89
8.2 度量、范数与邻域	90

8.3	开集、闭集与点的分类	92
8.4	序列收敛、Cauchy 列与完备性	95
8.5	$\mathbb{R}^n$ 的拓扑与 Bolzano–Weierstrass	97
8.6	这套语言通向何处	99
第九章	紧致性、连续性与 Weierstrass 极值定理	100
9.1	先问“解存不存在”	100
9.2	紧致性	101
9.3	连续性	103
9.4	Weierstrass 极值定理	104
9.5	一致连续（简述）	107
9.6	这把工具通向何处	107
第十章	半连续、对应与最大值定理 (Berge)	109
10.1	为什么“连续”要拆成两半	109
10.2	上半连续与下半连续函数	110
10.3	对应：当映射的取值是一个集合	111
10.4	参数化最优化与最大值定理	114
10.5	为什么最优解只能保证“上半连续”	115
10.6	它通向何处	117
第十一章	不动点定理与均衡存在性	118
11.1	为什么“均衡”就是“不动点”	118
11.2	Brouwer 不动点定理	119
11.3	从函数到对应：Kakutani 不动点定理	121
11.4	应用一：纳什均衡的存在	122
11.5	应用二：一般均衡的存在	124
11.6	它通向何处：存在 vs. 唯一与构造	125
第十二章	压缩映射与 Banach 不动点定理	127
12.1	为什么需要“压缩”这个更强的条件	127
12.2	压缩映射	128
12.3	Banach 不动点定理	129
12.4	Blackwell 充分条件	132
12.5	应用：Bellman 算子是压缩	133
12.6	它通向何处	134
第三部分	多元微积分与比较静态	135
第十三章	偏导、梯度、Jacobian 与 Hessian	136
13.1	偏导数与方向导数	136
13.2	梯度：把偏导数装进一个向量	137

13.3 全微分与可微性：导数即最佳线性逼近	139
13.4 Jacobian：向量值映射的导数	141
13.5 Hessian 与混合偏导的对称性	142
13.6 链式法则的矩阵形式	144
13.7 三件套通向何处	145
第十四章 Taylor 展开与二阶近似	147
14.1 为什么要做近似	147
14.2 一元 Taylor 定理	148
14.3 多元 Taylor 展开	150
14.4 局部二次近似与临界点分类	152
14.5 去处：从牛顿法到渐近展开	154
第十五章 隐函数定理与比较静态	156
15.1 从“解不出来”说起	156
15.2 单变量情形	157
15.3 应用一：税负转嫁	158
15.4 多变量情形	159
15.5 应用二：从一阶条件做比较静态	159
15.6 失效的时候，以及它通向何处	161
第十六章 凹凸函数与拟凹、拟凸	162
16.1 凸集：一切的地基	162
16.2 凹函数与凸函数	163
16.3 光滑情形：一阶判据与二阶判据	165
16.4 核心承诺：凹函数的局部最大就是全局最大	167
16.5 拟凹与拟凸：经济学真正需要的弱化	168
16.6 Jensen 不等式：凹凸性遇上期望	170
16.7 它通向何处	171
第十七章 齐次函数与欧拉定理	172
17.1 从“同比例放大”说起	172
17.2 齐次函数	173
17.3 欧拉定理	174
17.4 偏导数的齐次度下降一阶	175
17.5 应用一：欧拉的“产品耗尽”与分配	176
17.6 应用二：需求的零次齐次与无货币幻觉	177
17.7 位似函数：齐次性的“有用推广”	177
17.8 小结：一条缩放律，三处落点	179

第四部分 最优化	181
第十八章 无约束最优化：一阶与二阶条件	182
18.1 极大、极小：先把话说清楚	182
18.2 一阶必要条件：梯度为零	183
18.3 二阶条件：Hessian 的正负定性	184
18.4 鞍点：驻点未必是极值	187
18.5 凹性：让局部极大升格为全局极大	188
18.6 它通向何处	190
第十九章 等式约束与 Lagrange 乘子	191
19.1 从无约束到有约束：问题长什么样	191
19.2 相切：一阶条件的几何来源	192
19.3 Lagrange 函数：把约束揉进目标	193
19.4 乘子的经济含义：影子价格	194
19.5 多约束情形	196
19.6 二阶条件：bordered Hessian	197
19.7 这把工具通向何处	199
第二十章 不等式约束与 KKT 条件	200
20.1 不等式约束带来的新问题	200
20.2 KKT 条件：四件套	201
20.3 约束规范：为什么需要它	204
20.4 凸问题下 KKT 是充分条件	205
20.5 实例：带预算与非负约束的消费选择	207
20.6 它通向何处	208
第二十一章 凸优化与对偶	210
21.1 什么是凸优化问题	210
21.2 Lagrangian 与对偶函数	211
21.3 弱对偶：永远成立的那道界	213
21.4 强对偶与 Slater 条件	214
21.5 鞍点与极小极大	216
21.6 它通向何处	219
第二十二章 值函数与包络定理	221
22.1 值函数：把“最优值”看成参数的函数	221
22.2 包络定理（无约束）	222
22.3 约束情形：包络定理与 Lagrange 乘子	225
22.4 去处一：Shephard 引理、Roy 恒等式、Hotelling 引理	226
22.5 去处二：动态规划的 Benveniste–Scheinkman 公式	228
22.6 小结：选择之导与值之导，配成一对	229

第二十三章 单调比较静态与超模性 (Topkis)	231
23.1 从符号到序: 动机	231
23.2 格、递增差与超模性	232
23.3 Topkis 单调性定理	235
23.4 单交叉条件 (Milgrom-Shannon)	237
23.5 与隐函数定理的对照	239
23.6 去处	240
 第五部分 概率与测度	 242
第二十四章 概率空间、σ-代数与测度	243
24.1 为什么朴素概率不够用	243
24.2 样本空间与事件	244
24.3 σ -代数: 可以放概率的事件族	245
24.4 为什么不能给所有子集赋概率: 不可测集	246
24.5 测度与概率空间	247
24.6 生成的 σ -代数与 Borel 集	249
24.7 测度的连续性	251
24.8 几乎处处与几乎必然	252
24.9 它通向何处	253
 第二十五章 可测函数、随机变量与分布	 255
25.1 动机: 为什么要把随机性写成函数	255
25.2 可测函数	256
25.3 随机变量	257
25.4 分布: 把概率搬到实数轴上	258
25.5 分布函数 (CDF)	259
25.6 离散型、连续型与混合型	260
25.7 可测性在运算下的封闭性	263
25.8 它通向何处	264
 第二十六章 Lebesgue 积分与期望	 265
26.1 为什么 Riemann 积分不够用	265
26.2 Lebesgue 积分的三步构造	267
26.3 期望就是一个 Lebesgue 积分	270
26.4 极限与积分交换: 三大主力定理	271
26.5 换元: 把期望算到分布上去	272
26.6 三个常用不等式	273
26.7 它通向何处	274

第二十七章 多维分布、独立性与变量变换	276
27.1 联合分布与边缘分布	277
27.2 独立性	277
27.3 协方差与相关	279
27.4 多维变量变换公式	280
27.5 卷积：独立和的分布	282
27.6 多元正态分布	284
27.7 它们通向何处	286
第二十八章 条件期望（作为投影）	287
28.1 从“给定信息的最好猜测”说起	287
28.2 初等条件期望：给定事件、给定离散变量	288
28.3 一般条件期望：Kolmogorov 的定义	289
28.4 核心视角：条件期望是 L^2 投影	290
28.5 性质：塔性质、提出已知量、条件 Jensen	292
28.6 回归函数： $\mathbb{E}(Y X)$ 与它的去处	295
第二十九章 贝叶斯更新与信息	297
29.1 贝叶斯定理：把看法翻过来	297
29.2 共轭先验：让更新变成代数	299
29.3 信息的语言： σ -代数	302
29.4 信号与信念更新：博弈论的视角	303
29.5 后验信念是鞅：你说服不了自己往哪边走	304
29.6 它通向何处	306
第六部分 渐近统计	307
第三十章 收敛模式	308
30.1 为什么“收敛”必须分清几种意思	308
30.2 四种收敛模式	309
30.3 蕴含关系：谁强谁弱	310
30.4 反向不成立：四个经典反例	313
30.5 速度的语言： o_p 与 O_p	315
30.6 它通向何处	317
第三十一章 大数定律	319
31.1 它在守护什么：从样本到总体的桥	319
31.2 两件趁手的不等式	320
31.3 弱大数定律：三步证完	321
31.4 去掉方差假设：Khinchin 与截断的骨架	323
31.5 强大数定律：沿路径的收敛	323
31.6 大数定律就是“一致性”	324

31.7 它通向何处	326
第三十二章 中心极限定理	328
32.1 问题：估计量围绕真值如何波动	328
32.2 Lindeberg-Lévy 中心极限定理	329
32.3 为什么极限恰是正态：特征函数法	330
32.4 放松同分布：Lyapunov 与 Lindeberg	332
32.5 多元中心极限定理	333
32.6 去处：渐近推断的总枢纽	334
第三十三章 连续映射定理、Slutsky 与 Delta 法	336
33.1 为什么需要“组合”工具	336
33.2 连续映射定理	337
33.3 Slutsky 定理	338
33.4 Delta 法	340
33.5 多元 Delta 法	342
33.6 去处：渐近推断的通用引擎	344
第三十四章 极值估计的统一框架 (MLE/GMM/M-估计)	346
34.1 一个模子装下所有估计量	346
34.2 一致性：样本的峰收敛到总体的峰	348
34.3 渐近正态：对一阶条件做 Taylor 展开	350
34.4 极大似然：信息矩阵等式与 Cramér-Rao	353
34.5 GMM：矩条件与最优权重	355
34.6 M-估计与 QMLE：当模型可能错	356
34.7 收束：三位一体的检验与全书的汇流	357
第七部分 动态最优化	359
第三十五章 差分方程与稳定性	360
35.1 从递推到“长期会怎样”	360
35.2 一阶线性差分方程	361
35.3 高阶线性差分方程	363
35.4 一阶系统： $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$	364
35.5 鞍点路径与跳跃变量	366
35.6 这套工具通向何处	369
第三十六章 变分法与 Euler 方程	370
36.1 从“选一个数”到“选一条路径”	370
36.2 Euler-Lagrange 方程	371
36.3 横截条件：端点自由时补上的边界	375
36.4 应用：最优消费路径	375

36.5 它通向何处	377
第三十七章 最优控制与 Pontryagin 最大值原理	379
37.1 问题的结构：状态、控制与运动方程	379
37.2 Hamilton 量与影子价格	380
37.3 Pontryagin 最大值原理	381
37.4 折现与 current-value Hamilton 量	383
37.5 应用一：Ramsey 增长与 Keynes–Ramsey 规则	384
37.6 应用二：Hotelling 与可耗竭资源开采	386
37.7 应用三：q 理论投资	386
37.8 与动态规划的等价： λ 是值函数的梯度	388
第三十八章 动态规划与 Bellman 方程	389
38.1 序贯决策与序贯问题	389
38.2 最优性原理与 Bellman 方程	390
38.3 Bellman 算子与值函数的存在唯一	392
38.4 值迭代	393
38.5 最优策略函数	395
38.6 策略迭代	396
38.7 包络定理与 Euler 方程	397
38.8 它通向何处	399
第三十九章 随机动态规划与递归方法	401
39.1 从确定到随机：状态里多出一个冲击	401
39.2 随机 Bellman 方程	402
39.3 期望算子保压缩：随机值迭代照样收敛	404
39.4 随机 Euler 方程	406
39.5 应用一：随机增长与预防性储蓄	407
39.6 应用二：递归竞争均衡	409
39.7 应用三：资产定价与随机贴现因子	410
39.8 它通向何处	411
第八部分 随机过程	413
第四十章 Markov 链：平稳分布与遍历性	414
40.1 Markov 性：只记得现在	414
40.2 转移矩阵：把一条链装进一个矩阵	415
40.3 n 步转移与 Chapman–Kolmogorov：矩阵幂	416
40.4 状态分类：常返、暂留与周期	418
40.5 平稳分布：被转移矩阵原样保持的分布	419
40.6 遍历定理：收敛、且时间平均 = 空间平均	420
40.7 细致平衡：可逆链与一个验证平稳的捷径	422

40.8 去处：它把哪些门连了起来	423
第四十一章 鞅	425
41.1 信息流: filtration	425
41.2 鞅、上鞅、下鞅	426
41.3 典型例子	429
41.4 可选停时定理	430
41.5 鞅收敛定理	433
41.6 它通向何处	434
第四十二章 布朗运动与 Itô 引理	436
42.1 从随机游走到布朗运动	436
42.2 处处连续，处处不可微	438
42.3 二次变分: $(dW)^2 = dt$	439
42.4 Itô 积分：为何不能照搬普通积分	440
42.5 Itô 引理：随机演算的链式法则	441
42.6 几何布朗运动：资产价格的标准模型	443
42.7 去处：从 Black-Scholes 到随机控制	444

第一部分

线性代数：计量经济学的引擎

第一章 向量空间、线性无关、基与维数

用到的前置工具：几乎没有——只需 $\mathbb{R}^n$ 中向量的加法与数乘。这是全书第一章，是后面整套线性代数的地基。

经济学是一门把现实世界翻译成“线性”关系再求解的学问。计量经济学的整套机器建立在线性回归之上；消费者面对的是线性的预算约束；一般均衡、投入产出、最优化的一阶条件，到头来都化成一组线性方程。线性这件事之所以好用，是因为它有一套异常干净的几何与代数：可以把变量打包成向量、把关系打包成矩阵，然后用一套统一的语言去问“有没有解”“解唯一吗”“参数能不能被数据认出来”。

这套语言的舞台，就是**向量空间**。它把“可以相加、可以按比例放缩”这件事抽象出来，于是直线、平面、 $\mathbb{R}^n$ 、乃至全体随机变量构成的集合，都成了同一类对象，可以用同一套定理处理。而本章真正的主角是一个数字——**维数**。它度量一个空间里“独立方向”有多少、“自由度”有多大；后面会看到，计量里设计矩阵能不能识别出参数、共线性为什么是个问题、回归的自由度从哪来，答案都藏在维数与线性无关里。本章先把向量空间、张成、线性无关、基、维数、子空间、坐标这七个概念依次立起来，并且始终盯着一个问题：它们将来在微观、计量里到底拿来干什么。

1.1 为什么从向量空间讲起

考虑最熟悉的线性回归 $y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i$ 。把 n 个观测竖着摞起来，写成矩阵形式 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，其中 $\mathbf{X}$ 是 $n \times k$ 的设计矩阵。OLS 在做的事，几何上是：把 $\mathbf{y}$ 投影到 $\mathbf{X}$ 的各列所能“张成”的那个空间里。这个空间是不是足够“大”、 $\mathbf{X}$ 的列是不是“彼此独立”，直接决定了 $\boldsymbol{\beta}$ 能不能被唯一地估出来。“张成”与“独立”这两个词不是比喻，它们是本章要精确定义的数学概念；而“ $\mathbf{X}$ 列空间的维数”，就是回归里真正能被数据区分开的参数个数。

换句话说，许多在计量、微观课上以为是“技术细节”的东西——满秩、可识别、共线性、自由度——其实都是同一个几何事实的不同侧面。把向量空间这层地基打牢，后面这些概念就不再是需要死记的术语，而是可以一眼看穿的同一件事。这就是把它放在全书第一章的理由。

1.2 向量空间

我们先给出抽象定义，但读者完全可以在脑子里只装着一个例子： $\mathbb{R}^n$ ，即 n 元实数列 $\mathbf{x} = (x_1, \dots, x_n)$ 的全体，逐分量相加、逐分量乘以一个实数。本书绝大多数时候，

向量空间就是 $\mathbb{R}^n$ 。

定义 1.1: 向量空间

设 V 是一个非空集合，其上定义了加法 $u + v$ 与数乘 αu （标量 α 取自域 $\mathbb{R}$ ，本书只用实数）。若加法满足交换律、结合律，存在零向量 0 ($v + 0 = v$) 与负元 ($v + (-v) = 0$)，数乘满足

$$\alpha(\beta v) = (\alpha\beta)v, \quad 1v = v, \quad \alpha(u + v) = \alpha u + \alpha v, \quad (\alpha + \beta)v = \alpha v + \beta v,$$

则称 V 为 $\mathbb{R}$ 上的向量空间， V 的元素称为向量。

这一长串公理可以一句话概括：在 V 里相加、按比例放缩，怎么算都“算得通”，而且结果仍落在 V 内。最后这半句——“结果仍落在 V 内”——叫做对线性运算的封闭性，是后面判定子空间时唯一要反复检查的东西。

注（为什么要抽象，而不只讲 $\mathbb{R}^n$ ）。

对经济学使用者来说，把定义抽象成公理的好处是一份证明、到处通用。一旦某个集合被验证是向量空间，本章关于张成、线性无关、维数的所有结论就自动成立，不必重证。这样的集合远不止 $\mathbb{R}^n$ ：所有 $m \times n$ 实矩阵构成一个向量空间；定义在某区间上的全体连续函数也是（计量里的非参数估计就活在这种“函数空间”里）；甚至“零均值、有限方差的随机变量”全体也构成向量空间，且其上“协方差”恰好是一个内积——条件期望就是在这个空间里做投影（见后文“条件期望”一章）。本章先在 $\mathbb{R}^n$ 里把直觉建立起来，这些直觉将原封不动地迁移到那些更抽象的空间。

1.3 线性组合与张成

有了加法和数乘，能从一组向量造出来的所有新向量，就是它们的线性组合。这是整个线性代数里最基础的动作。

定义 1.2: 线性组合与张成

设 $v_1, \dots, v_k \in V$ 。形如

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_k v_k, \quad \alpha_1, \dots, \alpha_k \in \mathbb{R}$$

的向量称为 $v_1, \dots, v_k$ 的一个线性组合。这组向量的全体线性组合构成的集合

$$\text{span}\{v_1, \dots, v_k\} = \left\{ \sum_{j=1}^k \alpha_j v_j : \alpha_1, \dots, \alpha_k \in \mathbb{R} \right\}$$

称为它们的张成 (span)。

张成回答的是“用手头这几个向量，按线性方式最多能够到多大一片空间”。几何上（图 1.1）：在 $\mathbb{R}^2$ 或 $\mathbb{R}^3$ 里，一个非零向量的张成是一条过原点的直线（沿它来回伸缩）；两个不共线向量的张成是一个过原点的平面（在两个方向上自由配比）。注意张成

必然过原点——取所有系数为 0 就得到 $\mathbf{0}$ 。




图 1.1: 张成的几何。(a) 一个非零向量张成一条过原点的直线；(b) 两个不共线向量张成一个过原点的平面。张成永远包含原点。

定义 1.3: 生成集

若 $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = V$ ，即 V 中每个向量都能写成 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 的某个线性组合，则称 $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 是 V 的一个生成集（也说它们张成 V ）。

例（标准坐标向量张成 $\mathbb{R}^n$ ）。

在 $\mathbb{R}^n$ 里取 $\mathbf{e}_i$ 为第 i 个分量是 1、其余为 0 的向量。验证 $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 张成 $\mathbb{R}^n$ 。

解。

任取 $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ 。直接写出

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_n \mathbf{e}_n,$$

这是 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 的线性组合，系数恰是 $\mathbf{x}$ 的各分量。故每个 $\mathbf{x}$ 都落在张成里， $\{\mathbf{e}_i\}$ 是 $\mathbb{R}^n$ 的生成集。这组向量稍后将充当 $\mathbb{R}^n$ 的“标准基”。

1.4 线性无关

生成集解决了“够不够用”，但它可能冗余——一组向量里也许有的能被其它的表示出来，删掉它张成不变。把这种冗余精确刻画出来，就是线性相关与无关。这是本章的技术核心。

定义 1.4: 线性无关 / 线性相关

称 $v_1, \dots, v_k$ 线性无关, 若方程

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_k v_k = \mathbf{0}$$

只有平凡解 $\alpha_1 = \dots = \alpha_k = 0$ 。若存在不全为零的系数使上式成立, 则称它们线性相关。

定义读起来抽象, 但它说的是一件朴素的事: 相关意味着某个向量是多余的——可以被其余向量线性表示。

命题 1.5: 相关 $\iff$ 某一个能被其余表示

$v_1, \dots, v_k$ ($k \geq 2$) 线性相关, 当且仅当其中至少有一个向量是其余向量的线性组合。

证明. ($\implies$) 相关则存在不全为零的 α_j 使 $\sum_j \alpha_j v_j = \mathbf{0}$ 。取某个 $\alpha_m \neq 0$, 移项并除以 α_m :

$$v_m = -\frac{1}{\alpha_m} \sum_{j \neq m} \alpha_j v_j,$$

即 v_m 是其余向量的线性组合。(⇐) 若某 $v_m = \sum_{j \neq m} \beta_j v_j$, 移项得 $v_m - \sum_{j \neq m} \beta_j v_j = \mathbf{0}$, 其中 v_m 的系数为 $1 \neq 0$, 是不全为零的系数, 故相关。□

线性无关的判定: 化成一个齐次方程组

要判定 $v_1, \dots, v_k \in \mathbb{R}^n$ 是否无关, 把它们当作矩阵 $\mathbf{A} = [v_1 \ \dots \ v_k]$ 的各列, 则

$$\alpha_1 v_1 + \dots + \alpha_k v_k = \mathbf{A}\alpha, \quad \alpha = (\alpha_1, \dots, \alpha_k)^\top.$$

于是无关 $\iff$ 齐次方程组 $\mathbf{A}\alpha = \mathbf{0}$ 只有零解。这把一个看似抽象的几何问题, 彻底转化成一个可以用消元法机械求解的方程组问题——这正是“线性无关”最常被实际验证的方式 (细节见后文“矩阵、秩与方程组”一章)。

线性相关的几何含义同样直观 (图 1.2): 在 $\mathbb{R}^2$ 里两个向量相关就是共线, 再添第二个向量并不能把张成从直线扩成平面; 在 $\mathbb{R}^3$ 里三个向量相关就是共面, 张成至多是一个平面而非整个空间。相关, 就意味着多出来的向量没有开辟新的方向。

例 (判定一组 $\mathbb{R}^3$ 向量是否无关) .

判定 $v_1 = (1, 0, 1)$ 、 $v_2 = (0, 1, 1)$ 、 $v_3 = (1, 1, 2)$ 是否线性无关。

解.




图 1.2: 线性相关的几何。(a) 两个共线向量相关, 第二个向量没有开辟新方向, 张成仍是一条直线; (b) 三个共面向量相关, 张成仍只是一个平面, 够不到整个 $\mathbb{R}^3$ 。

设 $\alpha_1 v_1 + \alpha_2 v_2 + \alpha_3 v_3 = \mathbf{0}$, 逐分量写出方程组:

$$\begin{cases} \alpha_1 + \alpha_3 = 0, \\ \alpha_2 + \alpha_3 = 0, \\ \alpha_1 + \alpha_2 + 2\alpha_3 = 0. \end{cases}$$

前两式给 $\alpha_1 = -\alpha_3$ 、 $\alpha_2 = -\alpha_3$, 代入第三式: $-\alpha_3 - \alpha_3 + 2\alpha_3 = 0$, 恒成立。于是取 $\alpha_3 = 1$ 得非零解 $(\alpha_1, \alpha_2, \alpha_3) = (-1, -1, 1)$ 。存在非零解, 故线性相关。事实上一眼可验 $v_3 = v_1 + v_2$ ——第三个向量是前两个的和, 正是命题里“某个能被其余表示”的情形。

注 (一个常用的小事实)。

含有零向量的向量组必然线性相关 (给零向量配系数 1、其余配 0 即得非平凡解); 两个向量相关当且仅当其一为另一的标量倍 (即共线)。这两条平凡观察在快速排查共线性时很顺手。

1.5 基与坐标

把“够用”(生成)与“不冗余”(无关)这两个要求合在一起, 就得到线性代数里最重要的概念之一: **基**。基是“恰到好处”的一组向量——多一个则冗余, 少一个则不够。

定义 1.6: 基

向量空间 V 的一组向量 $\{b_1, \dots, b_n\}$ 称为 V 的一个**基**, 若它们 (i) 线性无关, 且 (ii) 张成 V 。

基的关键性质是: 它给空间里每个向量配上一组**唯一**的“读数”。

定理 1.7: 坐标表示的存在唯一性

设 $\{b_1, \dots, b_n\}$ 是 V 的一个基。则 V 中每个向量 x 都唯一地写成

$$x = c_1 b_1 + c_2 b_2 + \dots + c_n b_n.$$

系数 $(c_1, \dots, c_n)$ 称为 x 在该基下的坐标, 记 $[x]_B$ 。

证明. 存在性来自基张成 V : 每个 x 都是某个线性组合。唯一性来自线性无关: 若同时有

$$x = \sum_j c_j b_j = \sum_j c'_j b_j,$$

两式相减得 $\sum_j (c_j - c'_j) b_j = 0$ 。因 $\{b_j\}$ 无关, 只能 $c_j - c'_j = 0$ 对所有 j 成立, 即 $c_j = c'_j$ 。坐标唯一。□

这条定理点明了“无关”与“生成”各自的职责: 生成保证坐标存在, 无关保证坐标唯一。缺了无关, 同一个向量会有多种写法, “坐标”就失去意义。几何上(图 1.3), 在 $\mathbb{R}^2$ 里取一组(未必正交的)基 b_1, b_2 , 任一向量 x 都能由一个“平行四边形法则”唯一地分解到这两个方向上, 两条边长就是它的坐标。




图 1.3: 向量在基下的坐标。给定基 $\{b_1, b_2\}$, 向量 x 沿两个基方向唯一地分解出平行四边形, 两个分量的系数 (c_1, c_2) 就是 x 在该基下的坐标。

注 (标准基与一般基) .

$\mathbb{R}^n$ 里最自然的基是上节的标准坐标向量 $\{e_1, \dots, e_n\}$, 此时向量的坐标就是它的各个分量——我们平时写 $x = (x_1, \dots, x_n)$ 其实是默认选了标准基。但基的选择并不唯一: 同一个 $\mathbb{R}^n$ 可以有无穷多组基。换一组基, 相当于换一副“坐标眼镜”看同一个向量; 后续“特征值与对角化”一章会反复利用这点——选对了基(特征向量基), 一个复杂的线性变换会变成简单的逐坐标伸缩。

1.6 维数与替换定理

一个空间可以有无数组不同的基，但它们有一个铁打不变的共同点：含的向量个数相同。这个公共的个数就是空间的维数——它度量“独立方向”有几个，是“自由度”概念的数学源头。要让“维数”这个定义站得住脚，必须先证明“任意两组基等势”，而这件事的引擎是**替换定理**（Steinitz 替换引理）。

引理 1.8: 替换定理

设 $\{w_1, \dots, w_m\}$ 张成 V ，而 $\{u_1, \dots, u_p\}$ 是 V 中一组线性无关的向量。则必有 $p \leq m$ 。

核心直觉。一句话：无关的向量组，不可能比生成组还长。生成组 $\{w_j\}$ 用 m 个向量就够覆盖整个 V ；若无关组 $\{u_i\}$ 的个数 p 超过 m ，那这 p 个向量挤在一个“只需 m 个方向就铺满”的空间里，必然有人是多余的、能被别人线性表示，这与无关矛盾。替换定理用一个“逐个换入”的构造把这句直觉做实。

替换定理的关键步骤。思路是把无关组的向量一个一个换进生成组，每换入一个，就从生成组里淘汰一个旧向量，同时保持“仍是生成组”。

第一步，因 $\{w_1, \dots, w_m\}$ 张成 V ，无关向量 u_1 可写成它们的线性组合

$$u_1 = \beta_1 w_1 + \dots + \beta_m w_m.$$

$u_1 \neq 0$ （无关组不含零向量），故某个 $\beta_j \neq 0$ ，不妨设 $\beta_1 \neq 0$ 。于是能反解出 w_1 ：

$$w_1 = \frac{1}{\beta_1} \left(u_1 - \sum_{j \geq 2} \beta_j w_j \right).$$

这说明 $w_1 \in \text{span}\{u_1, w_2, \dots, w_m\}$ 。把 w_1 换成 u_1 后，新的一组 $\{u_1, w_2, \dots, w_m\}$ 仍然张成 V （因为凡是用得到 w_1 的地方，都能用 u_1 与其余 w 替代）。

归纳地，假设已经成功换入 $u_1, \dots, u_k$ 、淘汰掉 k 个旧向量，且新组仍张成 V 。把下一个 u_{k+1} 用这个新生成组表示。关键一步：表达式里诸 w 的系数不可能全为零——否则 u_{k+1} 就成了 $u_1, \dots, u_k$ 的线性组合，与 $\{u_i\}$ 无关矛盾。既然某个 w 的系数非零，就照样反解、用 u_{k+1} 把那个 w 换出来，新组依旧张成 V 。

每换入一个 u ，就消耗掉一个 w 。若 $p > m$ ，到第 m 步时所有 w 已被换光，可此时还剩 $u_{m+1}, \dots, u_p$ 没换入——按上一段，下一个 u_{m+1} 会被迫表示成 $\{u_1, \dots, u_m\}$ 的线性组合，与无关矛盾。故必有 $p \leq m$ 。□

替换定理 $\implies$ 维数良定义

设 $\{b_1, \dots, b_n\}$ 与 $\{b'_1, \dots, b'_{n'}\}$ 都是 V 的基。第一组张成 V 、第二组无关，替换定理给 $n' \leq n$ ；调换两组角色（第二组张成、第一组无关）又给 $n \leq n'$ 。于是 $n = n'$ 。任意两组基含的向量个数相同——这个公共数与基的选取无关，把它定义为 V 的维数才有意义。

定义 1.9: 维数

向量空间 V 的**维数** $\dim V$ 定义为它任一组基所含的向量个数（由上，这个数与基的选取无关）。约定 $\dim\{\mathbf{0}\} = 0$ 。

推论 1.10: $\mathbb{R}^n$ 的维数是 n

标准基 $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 含 n 个向量且是 $\mathbb{R}^n$ 的基，故 $\dim \mathbb{R}^n = n$ 。等价地： $\mathbb{R}^n$ 里任意 $n+1$ 个向量必线性相关，任意少于 n 个向量都张不成 $\mathbb{R}^n$ 。

注（维数就是“自由度”）。

维数衡量一个空间里能独立选取的方向数，也就是“自由度”。这正是统计里“自由度”一词的来历： n 个观测张成 $\mathbb{R}^n$ ，回归用掉 k 个线性无关的解释变量方向去拟合，残差就只能活在一个 $(n-k)$ 维的子空间里——剩下的 $n-k$ 个自由度，正是方差估计 $s^2 = \text{RSS}/(n-k)$ 分母的来源（详见后文“投影与最小二乘”一章）。维数不是抽象装饰，它直接进了你每天看的回归输出。

1.7 子空间

实际问题里，我们关心的往往不是整个 $\mathbb{R}^n$ ，而是它内部某个“自带向量空间结构”的部分——比如设计矩阵的列所能张成的那一片。这就是子空间。

定义 1.11: 子空间

向量空间 V 的子集 $W \subseteq V$ 称为 V 的**子空间**，若 W 在 V 的加法与数乘下自身也构成向量空间。

直接按定义逐条核对公理很麻烦，但绝大多数公理 W 从 V 那里“继承”即可，真正要查的只有封闭性与含零。

命题 1.12: 子空间判定准则

$W \subseteq V$ 是子空间，当且仅当 (i) $\mathbf{0} \in W$; (ii) 对加法封闭: $\mathbf{u}, \mathbf{v} \in W \Rightarrow \mathbf{u} + \mathbf{v} \in W$; (iii) 对数乘封闭: $\mathbf{v} \in W, \alpha \in \mathbb{R} \Rightarrow \alpha \mathbf{v} \in W$ 。

证明. 必要性显然。充分性：交换律、结合律、分配律等运算性质 W 中的向量作为 V 中的向量自动满足；(i) 提供零向量；由 (iii) 取 $\alpha = -1$ 得负元 $-\mathbf{v} \in W$ 。故 W 满足全部公理，是向量空间。□

条件 (i) 可由 (iii) 推出（取 $\alpha = 0$ ），但单列出来是为了强调一个最常见的判别口诀：不含原点的集合一定不是子空间。

子空间的典型样貌（图 1.4）：在 $\mathbb{R}^2$ 、 $\mathbb{R}^3$ 里，子空间只能是过原点的直线、过原点的平面、 $\{\mathbf{0}\}$ 、或整个空间。一条不过原点的直线就不是子空间——它连零向量都不

含，对数乘也不封闭（把线上一点放大两倍就离开了这条线）。任何一组向量的张成 $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 都自动是子空间（封闭性由线性组合的形式直接给出），它是“由这几个向量生成的最小子空间”。




图 1.4: 子空间必须过原点。(a) 过原点的直线 $W = \text{span}\{\mathbf{x}\}$ 含零、对线性运算封闭，是子空间；(b) 不过原点的直线 L 既不含 $\mathbf{0}$ ，对数乘也不封闭——线上点 $\mathbf{p}$ 放大两倍后 $2\mathbf{p}$ 已离开 L 。

例（计量里的列空间）。

设计矩阵 $\mathbf{X} = [\mathbf{x}_1 \cdots \mathbf{x}_k]$ 的各列张成 $\mathbb{R}^n$ 中的子空间 $\text{span}\{\mathbf{x}_1, \dots, \mathbf{x}_k\}$ ，称为 $\mathbf{X}$ 的列空间。说明 OLS 与这个子空间的关系，以及“列线性相关”意味着什么。

解。

OLS 把因变量 $\mathbf{y}$ 投影到列空间上：拟合值 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是列空间里离 $\mathbf{y}$ 最近的点。若各列线性无关，列空间维数为 k ，每个 $\hat{\mathbf{y}}$ 对应唯一的系数 $\hat{\boldsymbol{\beta}}$ ——参数可识别。若各列线性相关（即存在完全共线性，比如放进了“男”与“女”两个虚拟变量又保留了截距），列空间维数小于 k ，同一个 $\hat{\mathbf{y}}$ 可由无穷多组 $\hat{\boldsymbol{\beta}}$ 给出——参数不可识别， $(\mathbf{X}^\top \mathbf{X})^{-1}$ 不存在。“共线性”这个计量里的常见病，本质就是本章的“列线性相关”；而“满秩 $\iff$ 可识别”，正是“列无关 $\iff$ 坐标唯一”这条定理的计量版本。

1.8 小结：本章工具通向何处

七个概念，一条主线

向量空间提供舞台；张成回答“够不够”、线性无关回答“冗不冗余”，二者合一即基；基给每个向量唯一的坐标；任意两组基等势（替换定理）让维数良定义，它就是“独立方向数 / 自由度”；子空间是大空间内部自带结构的一片，它的维数度量它有多“大”。贯穿始终的判定手法只有一个：把问题化成齐次方程组 $\mathbf{A}\boldsymbol{\alpha} = \mathbf{0}$ 看有没有非零解。

本章是纯粹的地基，它的去处遍布全书：

- **秩与方程组**（下一章）。“一个矩阵有多少线性无关的列”就是它的秩，它把本章的“维数”落到具体矩阵上，并直接决定线性方程组 $\mathbf{Ax} = \mathbf{b}$ 解的存在与个数——计量里的“满秩假设”即由此而来。
- **投影与最小二乘**（后续章节）。OLS 是把 $\mathbf{y}$ 投影到设计矩阵列空间这个子空间上；本章的列空间、维数、自由度在那里全部兑现为回归的几何。
- **特征值与对角化**（后续章节）。换一组基（特征向量基）看同一个线性变换，复杂的矩阵会化简为逐坐标的伸缩——这正是“基的选择不唯一、坐标随基而变”这件事的威力所在。
- **更抽象的空间**。零均值有限方差的随机变量构成向量空间，协方差是其上的内积，条件期望是正交投影（见“条件期望”一章）；非参数估计活在无穷维函数空间里。本章在 $\mathbb{R}^n$ 建立的全部直觉，会原样搬到这些空间。

一旦看清“线性”在数学上不过是“可加、可放缩”外加“独立方向数”这点结构，经济学里层出不穷的线性模型就都成了同一出戏的不同布景。这是本书反复要传达的：抓住少数几个数学构造，许多扇门就一起打开了。

第二章 矩阵、秩、行列式与线性方程组的解结构

用到的前置工具：向量空间、线性无关、基与维数（第一章）；矩阵乘法与转置（基础线性代数）。

经济学里，凡是要“从数据里把参数解出来”的地方，背后都站着同一个方程： $\mathbf{Ax} = \mathbf{b}$ 。最小二乘的正规方程是它，工具变量的矩估计方程是它，联立方程组模型的约简型也是它。于是三个问题反复出现——这个方程有没有解？解唯一不唯一？若有多个解，它们长什么样？这三问看似零碎，其实由一个统一的几何图景一并回答：把矩阵 $\mathbf{A}$ 看成一个线性映射，它的四个基本子空间（列空间、零空间、行空间、左零空间）就把全部答案写在脸上。本章先建立这个图景，再用一个数——秩——把它量化，并顺带补上行列式这把同源的尺子（它判可逆、量体积，又是后面特征值与正定判据的入口），最后把结论翻译回计量经济学最关心的那句话：OLS 的系数何时被唯一确定？

2.1 从正规方程说起

线性回归要做的事，是给定一张数据矩阵 $\mathbf{X}$ （ n 行观测、 k 列解释变量）和一个被解释向量 $\mathbf{y} \in \mathbb{R}^n$ ，找一组系数 $\boldsymbol{\beta} \in \mathbb{R}^k$ 使 $\mathbf{X}\boldsymbol{\beta}$ 尽量接近 $\mathbf{y}$ 。最小二乘的一阶条件给出正规方程

$$\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}.$$

这是一个标准的 $\mathbf{Ax} = \mathbf{b}$ （这里 $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$ 、 $\mathbf{x} = \boldsymbol{\beta}$ 、 $\mathbf{b} = \mathbf{X}^\top \mathbf{y}$ ）。计量经济学的开篇结论——“OLS 估计量 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 存在且唯一”——其实就是在断言这个线性方程组恰好有唯一解。它什么时候成立？当它不成立（比如两个解释变量完全共线）时，又是哪里出了问题、参数变成了什么？

要干净地回答这些，必须跳出“逐个方程消元”的层面，换一个更高的视角：把矩阵当成一种作用——一个把向量送到向量的映射。一旦这样看， $\mathbf{Ax} = \mathbf{b}$ 就不再是一堆等式，而是一个几何问题： $\mathbf{b}$ 是不是落在 $\mathbf{A}$ 能够“够得到”的那些向量之中？

2.2 矩阵作为线性映射

一个 $m \times n$ 矩阵 $\mathbf{A}$ 通过 $\mathbf{x} \mapsto \mathbf{Ax}$ 把 $\mathbb{R}^n$ 里的向量送到 $\mathbb{R}^m$ 里。这个对应是线性的： $\mathbf{A}(\alpha \mathbf{x} + \beta \mathbf{y}) = \alpha \mathbf{Ax} + \beta \mathbf{Ay}$ 。反过来， $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的任何线性映射都可由某个唯一

的 $m \times n$ 矩阵实现，所以“矩阵”与“有限维线性映射”是一回事的两种说法。

关键的一步观察是：矩阵乘向量，本质是对列做加权求和。把 $\mathbf{A}$ 按列写成 $\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_n]$ ，其中 $\mathbf{a}_j \in \mathbb{R}^m$ 是第 j 列，则

$$\mathbf{A}\mathbf{x} = [\mathbf{a}_1 \ \cdots \ \mathbf{a}_n] \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n.$$

也就是说， $\mathbf{A}\mathbf{x}$ 就是 $\mathbf{A}$ 各列的一个线性组合，组合系数正是 $\mathbf{x}$ 的各分量。这句话朴素得近乎平凡，却是本章一切结论的源头：方程 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 有解，当且仅当 $\mathbf{b}$ 能写成 $\mathbf{A}$ 各列的线性组合。

把方程看成“ $\mathbf{b}$ 是不是列的组合”

$\mathbf{A}\mathbf{x} = \mathbf{b}$ 有解 $\iff \mathbf{b}$ 属于 $\mathbf{A}$ 各列张成的集合。求解 $\mathbf{x}$ ，就是去找“用哪些系数把各列拼出 $\mathbf{b}$ ”。这一改写把“解方程”变成了“判断归属”，而后者是纯几何的——这正是引入子空间的理由。

2.3 四个基本子空间

由 $\mathbf{A}$ （连同它的转置 $\mathbf{A}^\top$ ）自然生出四个子空间，它们装下了关于映射 $\mathbf{A}$ 与方程 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 想知道的一切。先给定义。

定义 2.1: 列空间与零空间

设 $\mathbf{A}$ 为 $m \times n$ 矩阵。

- **列空间** (column space) $C(\mathbf{A}) = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in \mathbb{R}^n\} \subseteq \mathbb{R}^m$: $\mathbf{A}$ 各列张成的子空间，也是映射 $\mathbf{A}$ 的值域（能够被够到的所有向量）。
- **零空间** (null space, 核) $N(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A}\mathbf{x} = \mathbf{0}\} \subseteq \mathbb{R}^n$: 被 $\mathbf{A}$ 压成零向量的所有 $\mathbf{x}$ 。

对转置 $\mathbf{A}^\top$ 重复同一构造，得到另两个：**行空间** $C(\mathbf{A}^\top) \subseteq \mathbb{R}^n$ ($\mathbf{A}$ 各行张成的子空间) 与**左零空间** $N(\mathbf{A}^\top) \subseteq \mathbb{R}^m$ (满足 $\mathbf{A}^\top \mathbf{y} = \mathbf{0}$ ，即 $\mathbf{y}^\top \mathbf{A} = \mathbf{0}^\top$ 的所有 $\mathbf{y}$)。

这四个子空间分住在两个房间里：列空间与左零空间在到达域 $\mathbb{R}^m$ ，行空间与零空间在定义域 $\mathbb{R}^n$ 。它们的关系——尤其是“谁与谁正交”——构成了线性代数最优美的一张图（图 2.1）。本章先把维数关系讲透；正交关系留待“内积、正交、投影”一章用内积语言精确证明，这里只点出结论与直觉。

注（“左”零空间的由来）。

$N(\mathbf{A}^\top)$ 里的向量 $\mathbf{y}$ 满足 $\mathbf{A}^\top \mathbf{y} = \mathbf{0}$ ，转置一下就是 $\mathbf{y}^\top \mathbf{A} = \mathbf{0}^\top$ —— $\mathbf{y}$ 从左边乘 $\mathbf{A}$ 得到零行向量，故名“左”零空间。它收集的是“ $\mathbf{A}$ 各列的所有线性约束”： $\mathbf{y}$ 与 $\mathbf{A}$ 的




图 2.1: 四个基本子空间。映射 $\mathbf{A}$ 把行空间一一映满列空间（二者同维 r ），把整个零空间压到 $\mathbf{0}$ 。行空间 $\perp$ 零空间（在 $\mathbb{R}^n$ 内），列空间 $\perp$ 左零空间（在 $\mathbb{R}^m$ 内）。

每一列都正交，因此 $\mathbf{y} \perp C(\mathbf{A})$ 。这正是图 2.1 右侧那对正交关系。

2.4 秩：行秩等于列秩

四个子空间的维数不是各自独立的，它们被一个数串起来——这个数就是秩。

定义 2.2: 秩

矩阵 $\mathbf{A}$ 的列秩是其列向量张成空间的维数 $\dim C(\mathbf{A})$ ，即线性无关列的最大个数；行秩是 $\dim C(\mathbf{A}^T)$ ，即线性无关行的最大个数。下面的定理表明二者相等，于是统称为 $\mathbf{A}$ 的秩，记作 $\text{rank}(\mathbf{A})$ 或 r 。

行秩等于列秩，乍看并无道理：行是 $\mathbb{R}^n$ 里的向量、列是 $\mathbb{R}^m$ 里的向量，两组向量住在不同空间，凭什么“无关者的个数”恰好一样多？这其实是线性代数里最值得惊叹的事实之一。

定理 2.3: 行秩 = 列秩

对任意 $m \times n$ 实矩阵 $\mathbf{A}$ ，行秩与列秩相等。

证明. 记列秩为 r 。取列空间 $C(\mathbf{A})$ 的一组基 $\mathbf{c}_1, \dots, \mathbf{c}_r \in \mathbb{R}^m$ ，把它们拼成 $m \times r$ 矩阵 $\mathbf{C} = [\mathbf{c}_1 \cdots \mathbf{c}_r]$ 。 $\mathbf{A}$ 的每一列都是这组基的线性组合，故每列 $\mathbf{a}_j$ 都可写成 $\mathbf{a}_j = \mathbf{C}\mathbf{r}_j$ ，其中 $\mathbf{r}_j \in \mathbb{R}^r$ 是组合系数。把这些系数列拼成 $r \times n$ 矩阵 $\mathbf{R} = [\mathbf{r}_1 \cdots \mathbf{r}_n]$ ，于是

$$\mathbf{A} = \mathbf{C}\mathbf{R}, \quad \mathbf{C} \in \mathbb{R}^{m \times r}, \mathbf{R} \in \mathbb{R}^{r \times n}.$$

这是一个秩分解：把 $\mathbf{A}$ 写成一个“窄”矩阵乘一个“扁”矩阵，中间维数为 r 。

现在看行。由 $\mathbf{A} = \mathbf{C}\mathbf{R}$ ， $\mathbf{A}$ 的第 i 行等于 $\mathbf{C}$ 第 i 行（一个 $\mathbb{R}^r$ 中的行向量）右乘 $\mathbf{R}$ ，也就是 $\mathbf{R}$ 各行的线性组合。因此 $\mathbf{A}$ 的每一行都落在 $\mathbf{R}$ 的 r 个行所张成的空间里，

从而 $\mathbf{A}$ 的行空间维数

$$\text{行秩}(\mathbf{A}) = \dim C(\mathbf{A}^\top) \leq r = \text{列秩}(\mathbf{A}).$$

把上述论证施于 $\mathbf{A}^\top$ (它的列秩是 $\mathbf{A}$ 的行秩, 行秩是 $\mathbf{A}$ 的列秩), 同样得到“列秩 $\leq$ 行秩”, 即 $\text{列秩}(\mathbf{A}) \leq \text{行秩}(\mathbf{A})$ 。两个不等式合起来即得行秩 = 列秩。 $\square$

秩是“真实自由度”的度量

一个 $m \times n$ 矩阵看似有 mn 个数, 但作为一个映射, 它真正能“撑起”的维数只有 $r = \text{rank}(\mathbf{A})$: 值域 $C(\mathbf{A})$ 是 r 维的, 被独立编码进去的输入方向也是 r 维的 (行空间)。秩分解 $\mathbf{A} = \mathbf{C}\mathbf{R}$ 把这点摆明——信息全压在那个 r 维的“腰”上。在计量里, $\mathbf{X}$ 的秩就是“线性无关的解释变量个数”, 它直接决定能识别多少个参数。

由秩分解 $\mathbf{A} = \mathbf{C}\mathbf{R}$ 顺带可见: $C(\mathbf{A}) = C(\mathbf{C})$ ($\mathbf{A}$ 的列都是 $\mathbf{C}$ 各列的组合, 反之 $\mathbf{C}$ 各列是基、本就在 $C(\mathbf{A})$ 中), 故 $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{C}) = r$, 自洽。

2.5 秩-零化度定理

秩量化了“被映射保留”的维数, 那么“被压垮”的维数有多少? 答案由秩-零化度定理给出, 它是本章承上启下的枢纽。

定义 2.4: 零化度

零空间的维数 $\dim N(\mathbf{A})$ 称为 $\mathbf{A}$ 的零化度 (nullity), 记作 $\text{null}(\mathbf{A})$ 。它是齐次方程 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 的解空间维数, 也就是“自由变量”的个数。

定理 2.5: 秩-零化度定理

对任意 $m \times n$ 矩阵 $\mathbf{A}$, 定义域维数 n 在映射下一分为二:

$$\text{rank}(\mathbf{A}) + \text{null}(\mathbf{A}) = n, \quad \text{即} \quad \dim C(\mathbf{A}^\top) + \dim N(\mathbf{A}) = n.$$

证明. 设 $\text{null}(\mathbf{A}) = k$, 取零空间 $N(\mathbf{A})$ 的一组基 $\mathbf{u}_1, \dots, \mathbf{u}_k \in \mathbb{R}^n$ 。把它扩充成整个 $\mathbb{R}^n$ 的一组基, 补进 $\mathbf{w}_1, \dots, \mathbf{w}_{n-k}$ (线性无关扩充总能做到, 见第一章)。断言: 像 $\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_{n-k}$ 构成列空间 $C(\mathbf{A})$ 的一组基; 若成立, 则 $\text{rank}(\mathbf{A}) = n - k$, 于是 $\text{rank} + \text{null} = (n - k) + k = n$ 。

张成。任取 $\mathbf{b} \in C(\mathbf{A})$, 即 $\mathbf{b} = \mathbf{A}\mathbf{x}$ 。把 $\mathbf{x}$ 按基展开 $\mathbf{x} = \sum_i \alpha_i \mathbf{u}_i + \sum_j \beta_j \mathbf{w}_j$, 作用 $\mathbf{A}$, 因 $\mathbf{A}\mathbf{u}_i = \mathbf{0}$, 得 $\mathbf{b} = \sum_j \beta_j \mathbf{A}\mathbf{w}_j$ 。故诸 $\mathbf{A}\mathbf{w}_j$ 张成 $C(\mathbf{A})$ 。

线性无关。设 $\sum_j \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}$, 即 $\mathbf{A}(\sum_j \beta_j \mathbf{w}_j) = \mathbf{0}$, 于是 $\sum_j \beta_j \mathbf{w}_j \in N(\mathbf{A})$, 可写成 $\sum_i \gamma_i \mathbf{u}_i$ 。移项得 $\sum_j \beta_j \mathbf{w}_j - \sum_i \gamma_i \mathbf{u}_i = \mathbf{0}$ 。但 $\{\mathbf{u}_i\} \cup \{\mathbf{w}_j\}$ 是 $\mathbb{R}^n$ 的基、线性无关, 故所有系数为零, 特别地 $\beta_j = 0$ 。于是诸 $\mathbf{A}\mathbf{w}_j$ 线性无关。

两条合起来, $\{\mathbf{A}w_j\}$ 是 $C(\mathbf{A})$ 的基, $\dim C(\mathbf{A}) = n - k$, 定理得证。 $\square$

定理的直觉一目了然: n 维的输入空间, 被 $\mathbf{A}$ 沿着 $\text{null}(\mathbf{A})$ 个方向“彻底压扁”(这些方向全送到 $\mathbf{0}$), 剩下的 $\text{rank}(\mathbf{A})$ 个独立方向才被搬到值域里去。压扁的加上保留的, 正好是全部 n 个维度。结合图 2.1: 左房间 $\mathbb{R}^n$ 被劈成“零空间 ($n - r$ 维) $\oplus$ 行空间 (r 维)”, 前者整团塌向原点, 后者被一一映满到右边的列空间。

一张维数账单

对 $m \times n$ 矩阵 $\mathbf{A}$, 秩为 r , 四个子空间的维数被两条账目锁死:

$$\underbrace{\dim C(\mathbf{A}^\top)}_r + \underbrace{\dim N(\mathbf{A})}_{n-r} = n \quad (\mathbb{R}^n \text{ 内}),$$

$$\underbrace{\dim C(\mathbf{A})}_r + \underbrace{\dim N(\mathbf{A}^\top)}_{m-r} = m \quad (\mathbb{R}^m \text{ 内}).$$

第二条是把第一条用到 $\mathbf{A}^\top$ ($n \times m$ 、同秩 r) 的结果。记住这张账单, 下一节关于“有解 / 唯一”的全部判据都是它的直接推论。

2.6 $\mathbf{Ax} = \mathbf{b}$ 解的存在性与结构

万事俱备。把前面的几何翻译成关于解的三句话: 何时解、何时唯一、多个解时的形状。

存在性: $\mathbf{b}$ 必须落在列空间里

由 §2.2, $\mathbf{Ax} = \mathbf{b}$ 有解当且仅当 $\mathbf{b}$ 是 $\mathbf{A}$ 各列的线性组合, 即 $\mathbf{b} \in C(\mathbf{A})$ 。

命题 2.6: 有解的判据

$\mathbf{Ax} = \mathbf{b}$ 有解 $\iff \mathbf{b} \in C(\mathbf{A}) \iff \text{rank}(\mathbf{A}) = \text{rank}[\mathbf{A} \ \mathbf{b}]$, 其中 $[\mathbf{A} \ \mathbf{b}]$ 是把 $\mathbf{b}$ 添为新列的增广矩阵。

证明. 前一个等价已述。后一个: 把 $\mathbf{b}$ 添为新列, 若 $\mathbf{b} \in C(\mathbf{A})$ 则它是已有列的组合、不增加无关列个数, 秩不变; 若 $\mathbf{b} \notin C(\mathbf{A})$ 则它带来一个新的无关方向, 秩加一。故“秩不变”与“ $\mathbf{b} \in C(\mathbf{A})$ ”等价。 $\square$

唯一性: 零空间必须平凡

假设已有解。解唯一与否, 完全由零空间说了算。设 $\mathbf{x}_1, \mathbf{x}_2$ 都满足 $\mathbf{Ax} = \mathbf{b}$, 相减得 $\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}$, 即 $\mathbf{x}_1 - \mathbf{x}_2 \in N(\mathbf{A})$ 。反之, 给定一个解 $\mathbf{x}_p$, 对任意 $\mathbf{h} \in N(\mathbf{A})$ 都有 $\mathbf{A}(\mathbf{x}_p + \mathbf{h}) = \mathbf{Ax}_p + \mathbf{0} = \mathbf{b}$, 故 $\mathbf{x}_p + \mathbf{h}$ 也是解。这就把解集刻画得清清楚楚。

定理 2.7: 解集的仿射结构

若 $\mathbf{Ax} = \mathbf{b}$ 有一个特解 $\mathbf{x}_p$ (任取其一), 则它的全部解恰为

$$\{\mathbf{x} : \mathbf{Ax} = \mathbf{b}\} = \mathbf{x}_p + N(\mathbf{A}) = \{\mathbf{x}_p + \mathbf{h} : \mathbf{h} \in N(\mathbf{A})\}.$$

即“一个特解 + 齐次解的全体”。解集是一个**仿射集**: 把子空间 $N(\mathbf{A})$ 整体平移 $\mathbf{x}_p$ 得到, 它过 $\mathbf{x}_p$ 、且“平行于”零空间。

证明. ($\supseteq$) 上一段已证 $\mathbf{x}_p + \mathbf{h}$ 对每个 $\mathbf{h} \in N(\mathbf{A})$ 都是解. ($\subseteq$) 若 $\mathbf{x}$ 是任一解, 令 $\mathbf{h} = \mathbf{x} - \mathbf{x}_p$, 则 $\mathbf{Ah} = \mathbf{b} - \mathbf{b} = \mathbf{0}$, 故 $\mathbf{h} \in N(\mathbf{A})$ 、 $\mathbf{x} = \mathbf{x}_p + \mathbf{h}$ 属于右边. 两个包含合起来即等号. $\square$

这正是图 2.2 的内容: 齐次方程的解 $N(\mathbf{A})$ 是一个过原点的子空间 (图中那条过 $\mathbf{0}$ 的直线), 而非齐次方程的解集是把它整体平移到特解 $\mathbf{x}_p$ 处的一条平行线 (或平面). 解的“形状”由零空间决定, 解的“位置”由特解决定——二者职责分明。




图 2.2: 解集 = 特解 + 零空间。零空间 $N(\mathbf{A})$ 是过原点的子空间 (橙线); 非齐次方程的解集 (蓝线) 是它平移 $\mathbf{x}_p$ 后的仿射集, 与零空间平行。沿 $\mathbf{v}$ 方向移动不改变 $\mathbf{Ax}$ 的值, 故仍在解集上。

三问的统一答案

对 $\mathbf{Ax} = \mathbf{b}$:

- 是否有解由 $\mathbf{b}$ 与列空间 $C(\mathbf{A})$ 的关系决定: $\mathbf{b} \in C(\mathbf{A})$ 才有解。
- 解是否唯一由零空间 $N(\mathbf{A})$ 决定: $N(\mathbf{A}) = \{\mathbf{0}\}$ (零化度为 0) 时, 有解必唯一; 否则一旦有解便有无穷多。
- 多解时的形状永远是“一个特解 + 零空间”的仿射集, 其维数 $= \text{null}(\mathbf{A}) = n - r$ 。

存在性看右房间 (列空间), 唯一性看左房间 (零空间) ——这就是图 2.1 两侧的

分工。

例（读出解集的形状）。

设

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

判断 $\mathbf{Ax} = \mathbf{b}$ 是否有解，若有，写出全部解。

解。

第二行是第一行的 2 倍，故 $\text{rank}(\mathbf{A}) = 1$ 。增广矩阵 $[\mathbf{A} \ \mathbf{b}]$ 的第二行 $(2, 4, 6 \mid 2)$ 也是第一行 $(1, 2, 3 \mid 1)$ 的 2 倍，秩仍为 1，与 $\text{rank}(\mathbf{A})$ 相等，故有解。

方程退化为单条 $x_1 + 2x_2 + 3x_3 = 1$ 。取一个特解：令 $x_2 = x_3 = 0$ 得 $\mathbf{x}_p = (1, 0, 0)^T$ 。零空间由 $x_1 + 2x_2 + 3x_3 = 0$ 给出，是 $\mathbb{R}^3$ 中过原点的二维平面，维数 $\text{null} = n - r = 3 - 1 = 2$ ，与秩-零化度定理 $1 + 2 = 3$ 吻合。取它的一组基，例如

$$\mathbf{h}_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{h}_2 = \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix} \quad (\text{皆满足 } \mathbf{A}\mathbf{h}_i = \mathbf{0}).$$

于是全部解为一个二维仿射平面

$$\mathbf{x} = \underbrace{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}}_{\mathbf{x}_p} + s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix}, \quad s, t \in \mathbb{R}.$$

2.7 满秩、列满秩、行满秩

把上一节的判据按“秩取到极大值”的几种情形归类，就得到几个反复出现的术语。设 $\mathbf{A}$ 为 $m \times n$ 、秩为 r ；总有 $r \leq \min(m, n)$ （无关列不会超过列数 n 、无关行不超过行数 m ）。

定义 2.8: 各种满秩

- **列满秩**： $r = n$ （秩等于列数）。此时各列线性无关， $N(\mathbf{A}) = \{\mathbf{0}\}$ 。
- **行满秩**： $r = m$ （秩等于行数）。此时各行线性无关， $C(\mathbf{A}) = \mathbb{R}^m$ 。
- **满秩**： $r = \min(m, n)$ ，即列满秩或行满秩。方阵（ $m = n$ ）满秩时同时是列满秩与行满秩，等价于可逆。

把它们对接到“有解 / 唯一”，就是下面这张可以直接查的表（证明都是 §2.6 三问答案的直接套用）。

	零空间 $N(\mathbf{A})$	列空间 $C(\mathbf{A})$
列满秩 ($r = n$)	$= \{\mathbf{0}\}$	真子空间 (除非 $r = m$)
含义	有解必唯一	未必对每个 $\mathbf{b}$ 有解
行满秩 ($r = m$)	一般非平凡 (除非 $r = n$)	$= \mathbb{R}^m$
含义	有解时一般无穷多	对任意 $\mathbf{b}$ 都有解

表 2.1: 满秩类型与解的对应。列满秩管“唯一性”，行满秩管“存在性”；方阵满秩二者兼得，故对每个 $\mathbf{b}$ 恰有唯一解——这正是可逆。

推论 2.9: 方阵的等价刻画

对 $n \times n$ 方阵 $\mathbf{A}$ ，下列陈述彼此等价：(i) $\mathbf{A}$ 可逆；(ii) $\text{rank}(\mathbf{A}) = n$ ；(iii) $N(\mathbf{A}) = \{\mathbf{0}\}$ （齐次方程只有零解）；(iv) 对每个 $\mathbf{b}$ ， $\mathbf{A}\mathbf{x} = \mathbf{b}$ 有唯一解；(v) $\det \mathbf{A} \neq 0$ 。

(v) 用到行列式——下一节就把它需要的部分补齐：判断一个方阵可不可逆，既可以问“秩满不满”，也可以问“行列式是否为零”，二者说的是同一件事。

2.8 行列式：可逆性的数值判据与体积

上一节用“秩满不满”来判一个方阵是否可逆。本节给出同一件事的另一把尺子——**行列式**：它把一个 $n \times n$ 方阵压成一个数 $\det \mathbf{A}$ ，这个数是否为零恰好判定可逆（上面推论中的第 (v) 条），而它的绝对值还有一个极干净的几何含义。行列式更是后面三处的钥匙：特征多项式 $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ （第四章）、二次型正定的顺序主子式判据（第五章），以及概率论里多重积分变量变换的 Jacobian 行列式。本书不为它单设一章，这里把要用到的部分一次备齐。

定义 2.10: 行列式

n 阶方阵 $\mathbf{A}$ 的**行列式** $\det \mathbf{A}$ （也记作 $|\mathbf{A}|$ ）是把方阵映为一个标量、且满足下面三条性质的唯一函数：(i) 关于每一列分别是线性的（**多重线性**）；(ii) 若某两列相同则取值为 0（**交错性**）；(iii) $\det \mathbf{I} = 1$ （**归一**）。

这三条性质唯一地确定了行列式，并等价地给出可计算的**按行（列）的代数余子式展开**（Laplace 展开）。实用中最常用的是低阶情形：

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc,$$

$$\det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \sum_{j=1}^3 (-1)^{1+j} a_{1j} M_{1j},$$

其中 M_{1j} 是划去第 1 行、第 j 列后剩下的 2×2 子行列式，称为**余子式**；带上符号的 $(-1)^{1+j} M_{1j}$ 则称为**代数余子式**。

定理 2.11: 行列式的关键性质

设 $\mathbf{A}, \mathbf{B}$ 为 n 阶方阵。

- $\det(\mathbf{A}^T) = \det \mathbf{A}$ ，故凡对“列”成立的性质对“行”同样成立。
- 交换两列（行）使行列式变号；某列（行）整体乘以 k 使行列式乘 k ；把某列（行）的倍数加到另一列（行）上，行列式不变。
- 三角矩阵（含对角矩阵）的行列式等于其对角元之积。
- 乘性： $\det(\mathbf{AB}) = \det \mathbf{A} \cdot \det \mathbf{B}$ 。
- $\mathbf{A}$ 可逆 $\iff \det \mathbf{A} \neq 0$ ；可逆时 $\det(\mathbf{A}^{-1}) = 1/\det \mathbf{A}$ 。

要点. 前三条都是定义中三条性质的直接推论：交换两列后，用交错性与多重线性即得变号；把某列的倍数加到另一列上，多出来的那一项含有两列相同、由交错性为零，故行列式不变；将矩阵用列变换化成三角形并记录这些变换对行列式的影响，即得三角阵公式。乘性可以这样看：固定 $\mathbf{B}$ ，函数 $\mathbf{A} \mapsto \det(\mathbf{AB})$ 关于 $\mathbf{A}$ 的各列同样是多重线性且交错的，故它必是 $\det \mathbf{A}$ 的常数倍；取 $\mathbf{A} = \mathbf{I}$ 定出该常数恰为 $\det \mathbf{B}$ 。最后一条：若 $\mathbf{A}$ 可逆，则 $\det \mathbf{A} \cdot \det(\mathbf{A}^{-1}) = \det(\mathbf{AA}^{-1}) = \det \mathbf{I} = 1$ ，故 $\det \mathbf{A} \neq 0$ ；反之若 $\det \mathbf{A} = 0$ ，由下面的几何解读，列向量必线性相关， $\mathbf{A}$ 不可逆。□

几何解读：行列式就是体积缩放因子。 把 $\mathbf{A}$ 看成线性映射，它的列 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 正是单位坐标向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 的像。于是 $\mathbf{A}$ 把单位立方体映成由这些列向量张成的平行多面体，而

$$|\det \mathbf{A}| = \text{该平行多面体的体积（二维即面积）},$$

行列式的符号则记录定向是否被翻转。由此立刻看出： $\det \mathbf{A} = 0$ 当且仅当这些列向量线性相关、平行多面体塌缩到更低的维度——也就是映射把空间“压扁”，自然不可逆（图 2.3）。乘性 $\det(\mathbf{AB}) = \det \mathbf{A} \det \mathbf{B}$ 在这个图景下几乎不言自明：先后施加两个线性映射，体积的缩放因子相乘。




图 2.3: 2×2 行列式的几何：矩阵 $\mathbf{A}$ 把单位正方形（虚线）映成由它的两列 $\mathbf{a}_1, \mathbf{a}_2$ 张成的平行四边形，面积恰为 $|\det \mathbf{A}|$ ；行列式的符号表示定向是否翻转。当 $\det \mathbf{A} = 0$ 时 $\mathbf{a}_1, \mathbf{a}_2$ 共线、平行四边形塌成线段，映射把平面压扁，故不可逆。

行列式还顺带给出一个理论上很顺手的求解公式。

命题 2.12: Cramer 法则

若 $\mathbf{A}$ 为 n 阶可逆方阵，则 $\mathbf{Ax} = \mathbf{b}$ 的唯一解的第 i 个分量为

$$x_i = \frac{\det \mathbf{A}_i}{\det \mathbf{A}},$$

其中 $\mathbf{A}_i$ 是把 $\mathbf{A}$ 的第 i 列替换为 $\mathbf{b}$ 后所得的矩阵。

Cramer 法则在理论推导里很方便（例如在比较静态中写出某个内生变量的显式表达式），但当 n 较大时其计算量远高于高斯消元，数值计算中几乎不用。

注（行列式的去处）。

行列式真正高频的用处在后面：特征值由特征方程 $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ 给出（第四章）；对称矩阵正定的一个判据是其所有顺序主子式（左上角各阶子行列式）皆为正（第五章 Sylvester 判据）；在概率论中，多维随机变量做变量变换时，新密度要乘上变换的 Jacobian 行列式的绝对值——那里行列式扮演的正是本节这个“体积缩放因子”的角色。

2.9 去处：OLS 何时被唯一确定

回到开篇的正规方程。现在可以把“OLS 估计量存在且唯一”这句话彻底讲透，并看清它失效时究竟发生了什么。

定理 2.13: 正规方程有唯一解 $\iff \mathbf{X}$ 列满秩

设 $\mathbf{X}$ 为 $n \times k$ 数据矩阵。正规方程 $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$ 对每个 $\mathbf{y}$ 都有唯一解 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ ，当且仅当 $\mathbf{X}$ 列满秩（ $\text{rank}(\mathbf{X}) = k$ ，即各解释变量线性无关、无完全多重共线）。

证明. 唯一性由 §2.7 表归结为 $k \times k$ 方阵 $\mathbf{X}^T \mathbf{X}$ 可逆，即 $N(\mathbf{X}^T \mathbf{X}) = \{\mathbf{0}\}$ 。关键是一条恒等：

$$\mathbf{X}^T \mathbf{X} \mathbf{v} = \mathbf{0} \implies \mathbf{v}^T \mathbf{X}^T \mathbf{X} \mathbf{v} = 0 \implies \|\mathbf{Xv}\|^2 = (\mathbf{Xv})^T (\mathbf{Xv}) = 0 \implies \mathbf{Xv} = \mathbf{0}.$$

反向 $\mathbf{Xv} = \mathbf{0} \implies \mathbf{X}^T \mathbf{X} \mathbf{v} = \mathbf{0}$ 显然。故 $N(\mathbf{X}^T \mathbf{X}) = N(\mathbf{X})$ ——两者零空间相同。于是 $\mathbf{X}^T \mathbf{X}$ 可逆 $\iff N(\mathbf{X}) = \{\mathbf{0}\} \iff \mathbf{X}$ 列满秩。（存在性是免费的：正规方程的右端 $\mathbf{X}^T \mathbf{y}$ 总落在 $C(\mathbf{X}^T \mathbf{X}) = C(\mathbf{X}^T)$ 中，故无论是否列满秩，正规方程总有解；列满秩只是把“有解”升级为“唯一解”。） $\square$

多重共线性 = 零空间非平凡 = 不可识别

若 $\mathbf{X}$ 不列满秩, 存在 $\mathbf{v} \neq \mathbf{0}$ 使 $\mathbf{X}\mathbf{v} = \mathbf{0}$: 某些解释变量的一个非平凡组合恒等于零 (完全多重共线)。此时对任一解 $\hat{\boldsymbol{\beta}}$, 整条 $\hat{\boldsymbol{\beta}} + t\mathbf{v}$ ($t \in \mathbb{R}$) 都同样最小化残差平方和——数据无法在这条线上区分谁对谁错。用经济学的话说, 对应的参数不可识别: 列方向 $\mathbf{v}$ 上的系数被数据留作未定。解集恰是 §2.6 那个“特解 + 零空间”的仿射集 (图 2.2), 只不过这里它住在参数空间里。识别, 归根结底就是要求零空间平凡。

例 (两个完全共线的回归元) .

模型 $y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$, 但数据中恒有 $x_{i2} = 2x_{i1}$ (例如“身高 (厘米)”与“身高 (英寸)”的换算)。说明为何 β_1, β_2 不可单独识别。

解.

此时 $\mathbf{X}$ 第二列 = $2 \times$ 第一列, $\text{rank}(\mathbf{X}) = 1 < 2 = k$, 非列满秩。取 $\mathbf{v} = (2, -1)^\top$, 则 $\mathbf{X}\mathbf{v}$ 的第 i 个分量为 $2x_{i1} - x_{i2} = 2x_{i1} - 2x_{i1} = 0$, 即 $\mathbf{X}\mathbf{v} = \mathbf{0}$, $\mathbf{v} \in N(\mathbf{X})$ 。给定任意一组拟合系数 (β_1, β_2) , 换成 $(\beta_1 + 2t, \beta_2 - t)$ 后拟合值

$$(\beta_1 + 2t)x_{i1} + (\beta_2 - t)x_{i2} = \beta_1 x_{i1} + \beta_2 x_{i2} + t(2x_{i1} - x_{i2}) = \beta_1 x_{i1} + \beta_2 x_{i2}$$

对所有 i 都不变, 残差平方和也不变。于是沿 $\mathbf{v}$ 方向有一整条等价的“最优”系数线, 数据无从挑选。能被识别的只有不随 $\mathbf{v}$ 变动的量, 比如这里的“总效应”组合 $\beta_1 + 2\beta_2$ (读者可验证它在替换下不变)。补救之道——删掉冗余列、加约束、或换识别假设——本质都是把零空间打回平凡。

最后点出这把工具的几处去处, 它们都把今天的“秩 / 零空间”当作基本词汇:

- **OLS 的几何** (后文“内积、正交、投影与最小二乘”一章)。本章把列空间当成“可达集”, 下一步会赋予它内积, 于是“ $\mathbf{b} \notin C(\mathbf{X})$ 时怎么办”有了标准答案: 把 $\mathbf{y}$ 投影到 $C(\mathbf{X})$ 上, 投影点就是拟合值 $\mathbf{X}\hat{\boldsymbol{\beta}}$, 残差落在左零空间 $N(\mathbf{X}^\top)$ 里——正交关系 (图 2.1) 正是最小二乘的几何内核。
- **识别** (计量与结构估计)。“参数可识别”的一般定义, 是某个映射的零空间平凡; 线性情形它就退化为本章的列满秩。工具变量、联立方程的秩条件与阶条件, 本质都是在数另一个矩阵的秩。
- **降维与近似** (后文“奇异值分解”一章)。当 $\mathbf{X}$ 接近不满秩 (强但不完全的多重共线) 时, $\mathbf{X}^\top \mathbf{X}$ 虽可逆却“病态”, $(\mathbf{X}^\top \mathbf{X})^{-1}$ 把噪声放得很大。秩分解 $\mathbf{A} = \mathbf{C}\mathbf{R}$ 的连续版本——奇异值分解——会把“有效秩”量化为奇异值的衰减, 给出主成分回归、岭回归等稳健化手段的统一语言。

一个数 (秩)、两个房间 ($\mathbb{R}^n$ 与 $\mathbb{R}^m$)、四个子空间, 就回答了“有解 / 唯一 / 形状”的全部追问, 并直通计量经济学的识别问题。这是线性代数作为“计量引擎”的第

一块基石；接下来的几章会在它之上，逐步装上内积、特征值与分解，把这台引擎彻底点火。

第三章 内积、正交、投影与最小二乘

用到的前置工具：向量空间、线性无关、基与维数（第一章）；矩阵、秩与列空间，矩阵求逆（第二章）。

计量经济学的入门动作只有一个：给一堆数据点配一条“最贴合”的直线。这件看似朴素的事，背后藏着整个线性代数里最有用的一段几何——**正交投影**。本章想说服你：最小二乘（OLS）不是一套需要硬背的代数公式，而是一个一句话就能说清的几何图像——把被解释变量这个向量，垂直地投影到回归元张成的那个子空间上。一旦接受了这个图像，正规方程、投影矩阵 $\mathbf{P} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ 的种种性质、拟合值与残差的正交、 R^2 的含义、乃至 Frisch-Waugh-Lovell 定理，都会从同一张图里自然长出来，几乎不需要再单独记忆。

为了讲清这张图，我们先把它赖以成立的几何语言备齐：度量“长度”与“夹角”的**内积**，由内积派生的**范数与正交**，以及“垂直分解”得以唯一进行的**投影定理**。这些工具本身远不止服务于 OLS——条件期望是 L^2 空间里的投影（见后文概率部分『条件期望作为投影』一章），最优线性预测、GLS、工具变量法也都讲着同一套正交的语言。

3.1 从拟合一条直线说起

设有 n 个观测，被解释变量堆成列向量 $\mathbf{y} \in \mathbb{R}^n$ ， k 个回归元（含常数项）堆成 $n \times k$ 矩阵 $\mathbf{X} = [\mathbf{x}_1 \cdots \mathbf{x}_k]$ 。OLS 要找一组系数 $\boldsymbol{\beta} \in \mathbb{R}^k$ ，使拟合 $\mathbf{X}\boldsymbol{\beta}$ 与 $\mathbf{y}$ 的“总偏差”最小：

$$\min_{\boldsymbol{\beta} \in \mathbb{R}^k} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 = \min_{\boldsymbol{\beta} \in \mathbb{R}^k} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2.$$

这里有一个视角的转换，是理解全章的关键。我们不把 $\mathbf{X}$ 的每一行（一个观测的若干特征）当主角，而是把 $\mathbf{X}$ 的每一列（一个变量在全部 n 个观测上的取值）当主角。于是 $\mathbf{X}\boldsymbol{\beta} = \beta_1 \mathbf{x}_1 + \cdots + \beta_k \mathbf{x}_k$ 是诸列向量的一个线性组合，当 $\boldsymbol{\beta}$ 取遍 $\mathbb{R}^k$ 时， $\mathbf{X}\boldsymbol{\beta}$ 扫出的正是 $\mathbf{X}$ 各列张成的子空间——它的**列空间** $\text{col}(\mathbf{X}) \subseteq \mathbb{R}^n$ 。

这样一来，OLS 问题就被翻译成了一句纯几何的话：

OLS 的几何重述

在 n 维空间 $\mathbb{R}^n$ 里，给定一个点 $\mathbf{y}$ 和一个子空间 $\text{col}(\mathbf{X})$ ，求该子空间中离 $\mathbf{y}$ 最近的点。这个最近点就是拟合值 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ ，而由它指回 $\mathbf{y}$ 的那截“够不到”的部分就是残差 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ 。

到一个子空间“最近的点”是什么？欧氏几何的直觉早已给出答案：从点向子空间作垂线，垂足就是最近点。把这个“垂线”的直觉变成可计算、可证明、可推广到任意维数的定理，正是本章前半段的任务。我们需要先有“垂直”——也就是内积与正交。

3.2 内积、范数与正交

定义 3.1: 内积

$\mathbb{R}^n$ 上两个向量 $\mathbf{u}, \mathbf{v}$ 的（标准）内积定义为

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^\top \mathbf{v} = \sum_{i=1}^n u_i v_i.$$

它满足：对称性 $\langle \mathbf{u}, \mathbf{v} \rangle = \langle \mathbf{v}, \mathbf{u} \rangle$ ；对每个分量线性 $\langle a\mathbf{u} + b\mathbf{w}, \mathbf{v} \rangle = a\langle \mathbf{u}, \mathbf{v} \rangle + b\langle \mathbf{w}, \mathbf{v} \rangle$ ；以及正定性 $\langle \mathbf{v}, \mathbf{v} \rangle \geq 0$ ，等号当且仅当 $\mathbf{v} = \mathbf{0}$ 。

内积一举给了我们“长度”与“夹角”两样东西。长度即范数

$$\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle} = \sqrt{\sum_i v_i^2},$$

它就是欧氏距离；两点的距离 $\|\mathbf{u} - \mathbf{v}\|$ 度量的正是 OLS 要最小化的那个“偏差”。夹角则由

$$\cos \theta = \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

定义。这里右边落在 $[-1, 1]$ 内并非凑巧，而是 **Cauchy-Schwarz 不等式**

$$|\langle \mathbf{u}, \mathbf{v} \rangle| \leq \|\mathbf{u}\| \|\mathbf{v}\|$$

的保证——它是内积三条性质（对称、线性、正定）的直接推论：对任意实数 t ，正定性给出 $0 \leq \|\mathbf{u} - t\mathbf{v}\|^2 = \|\mathbf{u}\|^2 - 2t\langle \mathbf{u}, \mathbf{v} \rangle + t^2\|\mathbf{v}\|^2$ ，这是关于 t 的开口向上的二次式，恒非负要求判别式 ≤ 0 ，即 $\langle \mathbf{u}, \mathbf{v} \rangle^2 \leq \|\mathbf{u}\|^2 \|\mathbf{v}\|^2$ ，开方即得。当夹角为直角时 $\cos \theta = 0$ ，内积为零——这就是“垂直”的代数定义。

定义 3.2: 正交

两个向量 $\mathbf{u}, \mathbf{v}$ 正交（记 $\mathbf{u} \perp \mathbf{v}$ ），若 $\langle \mathbf{u}, \mathbf{v} \rangle = 0$ 。称向量 $\mathbf{v}$ 与子空间 $\mathcal{L}$ 正交（记 $\mathbf{v} \perp \mathcal{L}$ ），若 $\mathbf{v}$ 与 $\mathcal{L}$ 中每个向量都正交。一组两两正交且都非零的向量称为**正交组**；若再把每个都标准化到单位长度，则称**标准正交组**。

正交之所以是好东西，最直接的理由是下面这条——它把读者熟悉的勾股定理搬进了任意维空间，而 R^2 与方差分解最终都落在它上面。

事实 3.3: 勾股定理

若 $\mathbf{u} \perp \mathbf{v}$, 则 $\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$.

验证只需展开: $\|\mathbf{u} + \mathbf{v}\|^2 = \langle \mathbf{u} + \mathbf{v}, \mathbf{u} + \mathbf{v} \rangle = \|\mathbf{u}\|^2 + 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2$, 正交项 $\langle \mathbf{u}, \mathbf{v} \rangle = 0$ 一抹去即得。

注 (为什么一上来就抽象成“内积”而不只说点积)。

本章只用标准内积 $\mathbf{u}^T \mathbf{v}$, 但刻意把性质 (对称、线性、正定) 单列出来, 是因为经济学里“垂直”常以别的面目出现: GLS 用的是加权内积 $\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^T \Omega^{-1} \mathbf{v}$; 概率论里随机变量的内积是 $\langle X, Y \rangle = \mathbb{E}(XY)$, 于是“不相关”就是一种正交, 条件期望就是一种投影。凡满足这三条性质的运算都配得上“内积”之名, 本章关于投影的所有结论会原样搬过去——这正是抽象的回报。

3.3 正交补与投影定理

把“垂直于一个子空间”的所有向量收集起来, 就得到该子空间的正交补。它是“残差该待的地方”。

定义 3.4: 正交补

子空间 $\mathcal{L} \subseteq \mathbb{R}^n$ 的正交补定义为

$$\mathcal{L}^{\perp} = \{ \mathbf{v} \in \mathbb{R}^n : \langle \mathbf{v}, \mathbf{m} \rangle = 0 \text{ 对一切 } \mathbf{m} \in \mathcal{L} \}.$$

它本身也是一个子空间, 且 $\mathcal{L} \cap \mathcal{L}^{\perp} = \{\mathbf{0}\}$ 、 $\dim \mathcal{L} + \dim \mathcal{L}^{\perp} = n$ 。

有了正交补, “向子空间作垂线”这件事就有了精确而强力的表述: $\mathbb{R}^n$ 里任何一个向量都能唯一地拆成“落在 $\mathcal{L}$ 里”与“垂直于 $\mathcal{L}$ ”两块。这正是全章的轴心定理。

定理 3.5: 正交投影定理

设 $\mathcal{L} \subseteq \mathbb{R}^n$ 是一个 (有限维) 子空间, $\mathbf{y} \in \mathbb{R}^n$ 。则存在唯一的分解

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}, \quad \hat{\mathbf{y}} \in \mathcal{L}, \quad \mathbf{e} \in \mathcal{L}^{\perp}.$$

其中 $\hat{\mathbf{y}}$ 称为 $\mathbf{y}$ 在 $\mathcal{L}$ 上的正交投影。它有两条等价的刻画:

- (i) 正交性。 $\hat{\mathbf{y}}$ 是 $\mathcal{L}$ 中使残差 $\mathbf{y} - \hat{\mathbf{y}}$ 垂直于整个 $\mathcal{L}$ 的那个向量。
- (ii) 最近性。 $\hat{\mathbf{y}}$ 是 $\mathcal{L}$ 中离 $\mathbf{y}$ 最近的点: 对一切 $\mathbf{m} \in \mathcal{L}$, $\|\mathbf{y} - \hat{\mathbf{y}}\| \leq \|\mathbf{y} - \mathbf{m}\|$, 等号仅当 $\mathbf{m} = \hat{\mathbf{y}}$ 。

证明. 存在性 (构造性)。取 $\mathcal{L}$ 的一组基, 对它作下一节的 Gram-Schmidt 正交化得到

标准正交基 $\{q_1, \dots, q_r\}$, 令

$$\hat{y} = \sum_{j=1}^r \langle y, q_j \rangle q_j.$$

则 $\hat{y} \in \mathcal{L}$, 且对每个基向量 q_i ,

$$\langle y - \hat{y}, q_i \rangle = \langle y, q_i \rangle - \sum_j \langle y, q_j \rangle \langle q_j, q_i \rangle = \langle y, q_i \rangle - \langle y, q_i \rangle = 0,$$

末步用了标准正交性 $\langle q_j, q_i \rangle = \mathbf{1}\{i = j\}$ 。残差与每个基向量正交, 故与它们的全部线性组合正交, 即 $e = y - \hat{y} \in \mathcal{L}^\perp$ 。

(i) $\Rightarrow$ (ii) 最近性。设 $\hat{y}$ 满足正交性, 任取 $m \in \mathcal{L}$ 。把 $y - m$ 拆成两段:

$$y - m = \underbrace{(y - \hat{y})}_{\in \mathcal{L}^\perp} + \underbrace{(\hat{y} - m)}_{\in \mathcal{L}}.$$

两段正交, 套勾股定理:

$$\|y - m\|^2 = \|y - \hat{y}\|^2 + \|\hat{y} - m\|^2 \geq \|y - \hat{y}\|^2,$$

等号当且仅当 $\|\hat{y} - m\| = 0$ 即 $m = \hat{y}$ 。

唯一性。若另有 $y = \hat{y}' + e'$ 满足同样的分解, 则 $\hat{y} - \hat{y}' = e' - e$ 。左边在 $\mathcal{L}$ 中, 右边在 $\mathcal{L}^\perp$ 中, 故此向量同属 $\mathcal{L} \cap \mathcal{L}^\perp = \{0\}$, 于是 $\hat{y} = \hat{y}'$ 、 $e = e'$ 。□

投影定理是 OLS 的全部内核

“残差垂直于子空间”（正交性）与“拟合值离数据最近”（最近性）是同一件事的两种说法——这正是定理 (i) $\Leftrightarrow$ (ii) 的内容。OLS 最小化 $\|y - X\beta\|^2$, 要的是最近性; 而我们马上会看到, 正交性给出可解的正规方程。最小化问题与一组线性方程之所以等价, 根子就在这条定理。

图 3.1 把这张图画在最容易看清的二维情形: 子空间是一条过原点的直线, 投影 $\hat{y}$ 是垂足, 残差 e 垂直于直线; 直线上任何别的点 w 到 y 的距离都更长——这正是“最近性”的肉眼版本。

注 (“唯一”靠的是 $\mathcal{L} \cap \mathcal{L}^\perp = \{0\}$)。

唯一性证明里那一步——一个向量既在 $\mathcal{L}$ 又在 $\mathcal{L}^\perp$ 就只能是零——看似平凡, 却是整套理论稳固的基石。它在 OLS 里的回声是: 投影 $\hat{y}$ 永远唯一确定 (无论 X 是否列满秩), 而系数 $\hat{\beta}$ 唯一与否, 则取决于 X 的列是否线性无关——这正是“多重共线性”在几何上的位置 (详见下文)。

3.4 投影矩阵

投影定理保证了 $\hat{y}$ 存在且唯一, 但还没告诉我们怎么算它。既然 $y \mapsto \hat{y}$ 是个线性映射 (投影显然对加法与数乘封闭), 它必由一个矩阵实现。当子空间是 $\text{col}(X)$ 时, 这




图 3.1: 正交投影定理 (二维情形): $\hat{\mathbf{y}}$ 是 $\mathbf{y}$ 在子空间 $\mathcal{L}$ 上的垂足, 残差 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ 垂直于 $\mathcal{L}$; $\mathcal{L}$ 中任何别的点 $\mathbf{w}$ 都离 $\mathbf{y}$ 更远。

个矩阵有一个漂亮的闭式。

定理 3.6: 投影到列空间的矩阵

设 $\mathbf{X}$ 为 $n \times k$ 且列满秩 ($\text{rank } \mathbf{X} = k$, 即 $\mathbf{X}^\top \mathbf{X}$ 可逆)。则向 $\text{col}(\mathbf{X})$ 的正交投影由矩阵

$$\mathbf{P} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

实现, 即对任何 $\mathbf{y}$ 都有 $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$ 。

证明. 要证 $\mathbf{P}\mathbf{y}$ 正是投影, 按投影定理的正交刻画, 只需验证两件事: $\mathbf{P}\mathbf{y} \in \text{col}(\mathbf{X})$, 且残差 $\mathbf{y} - \mathbf{P}\mathbf{y}$ 与 $\text{col}(\mathbf{X})$ 正交。

第一件显然: $\mathbf{P}\mathbf{y} = \mathbf{X}[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}]$ 是 $\mathbf{X}$ 各列的线性组合, 故在列空间里。

第二件, “与列空间正交” 等价于 “与 $\mathbf{X}$ 每一列正交”, 即 $\mathbf{X}^\top (\mathbf{y} - \mathbf{P}\mathbf{y}) = \mathbf{0}$ 。直接算:

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{P}\mathbf{y}) = \mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{y} = \mathbf{0}.$$

两条都成立, 故 $\mathbf{P}\mathbf{y}$ 即所求投影。□

这个 $\mathbf{P}$ 在计量里就是大名鼎鼎的“帽子矩阵” (hat matrix), 因为它给 $\mathbf{y}$ 戴上帽子变成 $\hat{\mathbf{y}}$ 。

投影矩阵有两条招牌性质, 几乎所有 OLS 的代数恒等式都从它们派生。

命题 3.7: 投影矩阵的对称与幂等

上述 $\mathbf{P} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 满足

(a) 对称: $\mathbf{P}^\top = \mathbf{P}$; (b) 幂等: $\mathbf{P}^2 = \mathbf{P}$ 。

反之, 任何对称且幂等的矩阵都是向某个子空间 (即它自己的列空间) 的正交投影。

证明. (a) 对称. 注意 $\mathbf{X}^\top \mathbf{X}$ 对称, 故其逆也对称, $\left((\mathbf{X}^\top \mathbf{X})^{-1}\right)^\top = (\mathbf{X}^\top \mathbf{X})^{-1}$. 于是

$$\mathbf{P}^\top = \left(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top\right)^\top = \mathbf{X} \left((\mathbf{X}^\top \mathbf{X})^{-1}\right)^\top \mathbf{X}^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{P}.$$

(b) 幂等. 中间的 $\mathbf{X}^\top \mathbf{X}$ 与它的逆相消:

$$\mathbf{P}^2 = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}}_{=\mathbf{I}} \mathbf{X}^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{P}.$$

□

这两条性质都不是巧合, 而是“投影”这件事的几何本质在代数上的投影 (恕用此双关):

对称 = 正交, 幂等 = 投影

幂等 $\mathbf{P}^2 = \mathbf{P}$ 说的是: 已经落在子空间里的东西, 再投一次纹丝不动——投影是“一锤子买卖”。对称 $\mathbf{P}^\top = \mathbf{P}$ 说的是这个投影是正交的 (沿垂直方向投, 而非斜着投); 去掉对称只保留幂等, 得到的是“斜投影”, 在 GLS、IV 里会遇到。把这两个几何事实记牢, 胜过记任何代数公式。

与 $\mathbf{P}$ 配对的是消灭矩阵 $\mathbf{M} = \mathbf{I} - \mathbf{P}$, 它把 $\mathbf{y}$ 送到残差: $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{P})\mathbf{y} = \mathbf{M}\mathbf{y}$ 。

推论 3.8: 消灭矩阵 $\mathbf{M} = \mathbf{I} - \mathbf{P}$

$\mathbf{M}$ 也对称、幂等, 它是向正交补 $\text{col}(\mathbf{X})^\perp$ 的投影; 且 $\mathbf{M}$ 与 $\mathbf{P}$ 互相“湮灭”:

$$\mathbf{M}^\top = \mathbf{M}, \quad \mathbf{M}^2 = \mathbf{M}, \quad \mathbf{PM} = \mathbf{MP} = \mathbf{0}.$$

特别地 $\mathbf{MX} = \mathbf{0}$: 消灭矩阵作用在自己的回归元上得零。

证明. 对称由 $\mathbf{P}$ 对称立得。幂等: $\mathbf{M}^2 = (\mathbf{I} - \mathbf{P})^2 = \mathbf{I} - 2\mathbf{P} + \mathbf{P}^2 = \mathbf{I} - 2\mathbf{P} + \mathbf{P} = \mathbf{I} - \mathbf{P} = \mathbf{M}$ 。
湮灭: $\mathbf{PM} = \mathbf{P}(\mathbf{I} - \mathbf{P}) = \mathbf{P} - \mathbf{P}^2 = \mathbf{0}$, 同理 $\mathbf{MP} = \mathbf{0}$ 。最后 $\mathbf{MX} = \mathbf{X} - \mathbf{PX} = \mathbf{X} - \mathbf{X} = \mathbf{0}$, 因为 $\mathbf{X}$ 的列本就在列空间里、投影不动它们。 □

注 (投影矩阵的几个“一眼能看穿”的量)。

对称幂等矩阵的特征值非 0 即 1 (若 $\mathbf{P}\mathbf{v} = \lambda\mathbf{v}$, 则 $\lambda\mathbf{v} = \mathbf{P}\mathbf{v} = \mathbf{P}^2\mathbf{v} = \lambda^2\mathbf{v}$, 故 $\lambda = \lambda^2$)。特征值为 1 的方向正是子空间内部、为 0 的是正交补。于是 $\text{rank } \mathbf{P} = \text{tr } \mathbf{P} = k$ (迹等于特征值之和, 即 1 的个数), $\text{rank } \mathbf{M} = \text{tr } \mathbf{M} = n - k$ ——后者正是 OLS 的“自由度”, 它在估计 σ^2 时分母里的 $n - k$ 由此而来 (见后文计量部分)。

3.5 Gram-Schmidt 正交化

投影定理的存在性证明欠了一笔账: 它用到了一组标准正交基。任意一组线性无关向量未必正交, 但总能“扳正”成正交的——这就是 Gram-Schmidt 过程。它本身就是

投影的反复运用：每加入一个新向量，就减去它在“已经处理好的那块子空间”上的投影，只留下垂直的新方向。

定理 3.9: Gram-Schmidt 正交化

设 $\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^n$ 线性无关。依次令

$$\mathbf{q}_1 = \mathbf{a}_1, \quad \mathbf{q}_j = \mathbf{a}_j - \sum_{i=1}^{j-1} \frac{\langle \mathbf{a}_j, \mathbf{q}_i \rangle}{\langle \mathbf{q}_i, \mathbf{q}_i \rangle} \mathbf{q}_i \quad (j = 2, \dots, k).$$

则 $\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$ 两两正交，且对每个 j 都有 $\text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_j\} = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_j\}$ 。把各 $\mathbf{q}_j$ 单位化即得标准正交基。

证明. 对 j 归纳。 $j=1$ 平凡。设 $\mathbf{q}_1, \dots, \mathbf{q}_{j-1}$ 已两两正交。式中减去的那一项 $\sum_{i=1}^{j-1} \frac{\langle \mathbf{a}_j, \mathbf{q}_i \rangle}{\langle \mathbf{q}_i, \mathbf{q}_i \rangle} \mathbf{q}_i$ 恰是 $\mathbf{a}_j$ 在子空间 $\text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_{j-1}\}$ 上的正交投影（这正是投影定理存在性里用正交基写投影的公式）。因此 $\mathbf{q}_j$ 是对应的残差，按投影定理它垂直于该子空间，即与 $\mathbf{q}_1, \dots, \mathbf{q}_{j-1}$ 全部正交。张成相等则由“每个 $\mathbf{q}_j$ 是 $\mathbf{a}_1, \dots, \mathbf{a}_j$ 的线性组合，反之亦然”逐层推得。□

最干净的画面是两个向量的情形（图 3.2）：保留 $\mathbf{a}_1$ 不动，把 $\mathbf{a}_2$ 沿 $\mathbf{a}_1$ 方向的影子减掉，剩下的 $\mathbf{q}_2$ 就垂直于 $\mathbf{a}_1$ 。




图 3.2: Gram-Schmidt 的一步：从 $\mathbf{a}_2$ 中减去它在 $\mathbf{a}_1$ 上的投影，得到与 $\mathbf{a}_1$ 正交的 $\mathbf{q}_2$ 。每一步都是“原向量 - 投影 = 残差”。

注 (Gram-Schmidt 通向 QR 分解)。

把上式反解， $\mathbf{a}_j$ 可写成 $\mathbf{q}_1, \dots, \mathbf{q}_j$ 的线性组合，系数排成一个上三角矩阵。归一化后这给出 $\mathbf{X} = \mathbf{QR}$ ，其中 $\mathbf{Q}$ 列标准正交、 $\mathbf{R}$ 上三角——这就是数值线性代数里解最小二乘的 **QR 分解**。用它，正规方程退化成 $\mathbf{R}\hat{\beta} = \mathbf{Q}^T \mathbf{y}$ ，免去了直接对（数值上容易病态的） $\mathbf{X}^T \mathbf{X}$ 求逆。统计软件算 OLS 走的多是这条路，而非课本里的闭式。

3.6 最小二乘即正交投影

万事俱备。现在把投影定理用到子空间 $\mathcal{L} = \text{col}(\mathbf{X})$ 上，OLS 的全套结论一次落地。最小化 $\|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2$ 求的是 $\text{col}(\mathbf{X})$ 中离 $\mathbf{y}$ 最近的点，由投影定理它就是正交投影 $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$ ，残差 $\mathbf{e} = \mathbf{M}\mathbf{y}$ 垂直于整个列空间。“残差垂直于每个回归元”这句话写成方程，就是著名的正规方程。

定理 3.10: 正规方程

OLS 系数 $\hat{\boldsymbol{\beta}}$ 是

$$\mathbf{X}^T(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \iff \mathbf{X}^T\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^T\mathbf{y}$$

的解。若 $\mathbf{X}$ 列满秩，则解唯一： $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$ ，相应拟合值 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{P}\mathbf{y}$ 。

证明。 由投影定理的正交刻画，最优拟合 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 的残差必垂直于列空间，即与 $\mathbf{X}$ 每列正交： $\mathbf{X}^T(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$ 。展开即 $\mathbf{X}^T\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^T\mathbf{y}$ 。列满秩时 $\mathbf{X}^T\mathbf{X}$ 可逆，左乘其逆得唯一解。也可由微积分直接核验：令 $S(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$ ，则 $\nabla S = -2\mathbf{X}^T(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ ，置零即正规方程——一阶条件与正交条件是同一个方程，再次印证最近性与正交性的等价。 $\square$

图 3.3 是本章最该记住的一张图：把图 3.1 的“直线”换成 n 维空间里的一张“平面”（代表列空间）， $\mathbf{y}$ 从空间外垂直落到平面上得 $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$ ，竖直的残差 $\mathbf{e} = (\mathbf{I} - \mathbf{P})\mathbf{y}$ 垂直于整个平面。所有 OLS 公式都是这张图的文字注解。




图 3.3: OLS 的几何全貌：被解释变量 $\mathbf{y}$ 向回归元列空间 $\text{col}(\mathbf{X})$ 作正交投影，得拟合值 $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$ ；残差 $\mathbf{e} = (\mathbf{I} - \mathbf{P})\mathbf{y}$ 垂直于整个列空间。

正交性 $\mathbf{X}^T\mathbf{e} = \mathbf{0}$ 不是抽象装饰，它逐条对应着回归里熟悉的事实。

$\mathbf{X}^T\mathbf{e} = \mathbf{0}$ 一句话里的全部含义

残差与每个回归元正交。其中：若 $\mathbf{X}$ 含常数列 $\mathbf{1}$ ，则 $\mathbf{1}^T\mathbf{e} = \sum_i e_i = 0$ ——残差和为零（回归“平均意义上”无偏地穿过数据）；与任一回归元 $\mathbf{x}_j$ 正交即 $\mathbf{x}_j^T\mathbf{e} = 0$ ——残差与每个解释变量样本不相关。这两条不是 OLS 的额外假定，而是“垂直投影”四个字的直接推论。

例（最简单的投影：回归到常数项）。

只用一个常数列 $\mathbf{X} = \mathbf{1} = (1, \dots, 1)^\top$ 去拟合 $\mathbf{y}$ 。求投影矩阵 $\mathbf{P}$ 、拟合值 $\hat{\mathbf{y}}$ 与残差 $\mathbf{e}$ ，并说明几何含义。

解。

此时 $\mathbf{X}^\top \mathbf{X} = \mathbf{1}^\top \mathbf{1} = n$ ，故

$$\mathbf{P} = \mathbf{1}(\mathbf{1}^\top \mathbf{1})^{-1} \mathbf{1}^\top = \frac{1}{n} \mathbf{1} \mathbf{1}^\top,$$

它是每个元素都为 $1/n$ 的 $n \times n$ 矩阵。作用在 $\mathbf{y}$ 上：

$$\hat{\mathbf{y}} = \mathbf{P}\mathbf{y} = \frac{1}{n} \mathbf{1}(\mathbf{1}^\top \mathbf{y}) = \bar{y} \mathbf{1}, \quad \bar{y} = \frac{1}{n} \sum_i y_i.$$

拟合值是每个分量都等于样本均值 $\bar{y}$ 的向量——向常数子空间（一维对角线 $\text{span}\{\mathbf{1}\}$ ）的投影就是取平均。残差 $\mathbf{e} = \mathbf{y} - \bar{y}\mathbf{1}$ 是去均值（中心化）后的偏差向量，自动满足 $\mathbf{1}^\top \mathbf{e} = \sum_i (y_i - \bar{y}) = 0$ 。这个不起眼的例子是下一节方差分解的出发点：“总平方和”正是 $\mathbf{y}$ 减去它在 $\text{span}\{\mathbf{1}\}$ 上投影后的长度平方。

注（列不满秩时：投影还在，系数散了）。

若 $\mathbf{X}$ 的列线性相关（完全多重共线性）， $\mathbf{X}^\top \mathbf{X}$ 不可逆，闭式 $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 失效。但请注意：投影 $\hat{\mathbf{y}}$ 依旧存在且唯一——投影定理只要求“子空间”，从不要求基线性无关。失去唯一性的只是坐标 $\hat{\boldsymbol{\beta}}$ ：同一个 $\hat{\mathbf{y}}$ 能由相关的列以无穷多种系数组合凑出。这把“共线性”的病灶定位得一清二楚：不是拟合出了问题，而是“把拟合拆给各变量”这件事没了唯一答案。

3.7 几处去处：FWL、 R^2 与方差分解

投影这把工具一旦在手，许多看似独立的计量结论都成了它的推论。这里点出三处最重要的去处。

Frisch-Waugh-Lovell：分步投影。 把回归元分成两块 $\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2]$ ，对应系数 $\hat{\boldsymbol{\beta}} = (\hat{\boldsymbol{\beta}}_1, \hat{\boldsymbol{\beta}}_2)$ 。FWL 定理说：要得到 $\hat{\boldsymbol{\beta}}_2$ ，不必做完整回归，可以先把 $\mathbf{X}_1$ 的影响从 $\mathbf{y}$ 和 $\mathbf{X}_2$ 中都“洗掉”，再用洗净的部分对回归。记 $\mathbf{M}_1 = \mathbf{I} - \mathbf{X}_1(\mathbf{X}_1^\top \mathbf{X}_1)^{-1} \mathbf{X}_1^\top$ 为向 $\text{col}(\mathbf{X}_1)^\perp$ 的投影，则

$$\hat{\boldsymbol{\beta}}_2 = ((\mathbf{M}_1 \mathbf{X}_2)^\top (\mathbf{M}_1 \mathbf{X}_2))^{-1} (\mathbf{M}_1 \mathbf{X}_2)^\top (\mathbf{M}_1 \mathbf{y}).$$

几何上这无非是“分两次投影等于一次投影”：先投到 $\text{col}(\mathbf{X}_1)$ 的正交补里（用 $\mathbf{M}_1$ 把 $\mathbf{X}_1$ 那部分扣净），再在剩下的方向上投影。

FWL 的用处与寓意

用处：它解释了“控制变量”到底在做什么——回归系数 $\hat{\beta}_2$ 度量的是剔除 $\mathbf{X}_1$ 之后 $\mathbf{X}_2$ 与 $\mathbf{y}$ 的关系。固定效应模型里“组内变换”（减去组均值）、以及偏回归图（partial regression plot），都是 FWL 的直接应用。寓意：高维回归可以被拆成一连串低维投影——这是后续诸多估计量（部分线性模型、双重机器学习里的“正交化”）共同的骨架。

R^2 是投影长度之比。对含常数项的回归，先把 $\mathbf{y}$ 与 $\hat{\mathbf{y}}$ 都减去均值 $\bar{y}\mathbf{1}$ （即投到 $\text{span}\{\mathbf{1}\}$ 的正交补里）。中心化后 $\mathbf{y} - \bar{y}\mathbf{1}$ 仍可分解为“已解释”与“残差”两段，且二者正交（残差垂直于含 $\mathbf{1}$ 的整个列空间，自然也垂直于已解释部分），勾股定理给出

$$\underbrace{\|\mathbf{y} - \bar{y}\mathbf{1}\|^2}_{\text{SST}} = \underbrace{\|\hat{\mathbf{y}} - \bar{y}\mathbf{1}\|^2}_{\text{SSE}} + \underbrace{\|\mathbf{e}\|^2}_{\text{SSR}}.$$

（缩写约定：本书统一用 SST 记总平方和、SSE 记已解释平方和、SSR 记残差平方和；英文教材另有把 SSR 当“回归/已解释”、SSE 当“误差/残差”的相反约定，后文方差分析等处一律沿用此处的命名。）于是

$$R^2 = \frac{\text{SSE}}{\text{SST}} = \frac{\|\hat{\mathbf{y}} - \bar{y}\mathbf{1}\|^2}{\|\mathbf{y} - \bar{y}\mathbf{1}\|^2} = \cos^2 \theta,$$

其中 θ 是中心化的 $\mathbf{y}$ 与其拟合之间的夹角（图 3.4）。 R^2 不过是“总向量被投影到模型里的那一段，占了多大比例”——一个纯粹的长度（角度）问题。它天然落在 $[0, 1]$ 里，正因为投影分量永远不长于原向量。




图 3.4: R^2 的几何：中心化后总向量、已解释向量、残差构成直角三角形（勾股 $\text{SST} = \text{SSE} + \text{SSR}$ ）； $R^2 = \cos^2 \theta$ 是已解释长度平方占总长度平方的比例。

方差分解。 上式两边同除 n （或 $n-1$ ），就是“样本方差 = 被模型解释的方差 + 残差方差”。这一勾股式的分解远不止用于线性回归：方差分析（ANOVA）、随机变量的“总方差 = 条件期望的方差 + 条件方差”（全方差公式）、乃至贝叶斯里信息的增减，骨子里都是同一条正交分解。把“方差”理解成“长度平方”、把“不相关”理解成“正交”，这些公式就从一个共同的几何母本里流出来。

一图三课

本章的核心图（图 3.3）会在全书反复回响。微观里，最优线性预测、需求系统的估计都靠它；宏观/时序里，新息（innovation）与 Wold 分解是把当期变量向过去信息张成的空间作投影；计量的整座大厦——GLS（换一种内积的投影）、IV 与两阶段最小二乘（先投到工具变量空间再回归）、条件期望作为 L^2 投影（见后文『条件期望作为投影』一章）——都是同一张“垂直落下”的图在不同空间里的重演。学会了正交投影，等于一次性拿到了这许多扇门的钥匙。

第四章 特征值、特征向量与对角化

用到的前置工具：矩阵作为线性映射、矩阵乘法（第二章）；线性无关、基与维数（第一章）；行列式与矩阵可逆（基础线性代数，本书直接借用，见第二章末）。

一个矩阵 $\mathbf{A}$ 作用在向量上，一般会同时做两件事——把向量转个方向、再拉长或缩短。方向一变，连续作用 $\mathbf{A}^2, \mathbf{A}^3, \dots$ 就纠缠得难以追踪：这正是动态系统、Markov 链、反复迭代的最优化算法里反复出现的难题。本章要找的，是这台变换里“方向不变”的那几根轴——沿着它们， $\mathbf{A}$ 退化成一个纯粹的数乘。把坐标系换到这几根轴上，矩阵就被“拉直”成对角形，所有关于它的幂、它的长期行为、它的稳定性，都一目了然。这就是**对角化**：为一个线性变换找到让它变简单的坐标系。它是计量里方差矩阵分析、宏观里差分方程与 VAR 稳定性、概率里 Markov 链收敛的公用引擎，也是下一章谱定理与主成分分析的正门。

4.1 方向不变的轴：特征值与特征向量

先把“方向不变”这件事精确化。绝大多数向量被 $\mathbf{A}$ 作用后都会偏转，但总有一些特殊方向，作用前后仍落在同一条过原点的直线上——只是被拉伸了一个倍数。这样的方向就是特征向量，那个倍数就是特征值。

定义 4.1: 特征值与特征向量

设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 。若存在标量 λ 与非零向量 $\mathbf{v}$ （允许 $\lambda \in \mathbb{C}, \mathbf{v} \in \mathbb{C}^n$ ），使得

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

则称 λ 为 $\mathbf{A}$ 的一个**特征值** (eigenvalue)， $\mathbf{v}$ 为属于 λ 的**特征向量** (eigenvector)。

注（为什么要排除 $\mathbf{v} = \mathbf{0}$ ）。

若允许 $\mathbf{v} = \mathbf{0}$ ，则 $\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$ 对任何 λ 都成立，“特征值”便毫无意义。所以定义里硬性要求 $\mathbf{v} \neq \mathbf{0}$ 。与之相反， $\lambda = 0$ 是允许的： $\mathbf{A}\mathbf{v} = \mathbf{0}$ 且 $\mathbf{v} \neq \mathbf{0}$ 说明 $\mathbf{A}$ 有非平凡零空间，即 $\mathbf{A}$ 奇异。换句话说，“0 是 $\mathbf{A}$ 的特征值”与“ $\mathbf{A}$ 不可逆”是同一件事——这一点稍后还会用到。

特征向量的几何意义是本章的母图： $\mathbf{A}$ 把单位圆压成一个椭圆时，椭圆的主轴方向就是“方向不变”的轴，每条主轴被拉伸的倍数就是对应的特征值（图 4.1）。沿这些轴，

弯曲与旋转都消失了，只剩纯缩放。




图 4.1: 特征向量是“变换下方向不变的轴”。这里 $\mathbf{A} = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}$ 把单位圆压成椭圆：沿特征方向 $\mathbf{v}_1$ (45°) 向量被拉长 $\lambda_1 = 2$ 倍、方向不变，沿 $\mathbf{v}_2$ (-45°) 保持原长 $\lambda_2 = 1$ 、方向也不变；而一般向量 $\mathbf{x}$ 既被拉伸、方向又偏转 ($\mathbf{Ax}$ 与 $\mathbf{x}$ 不共线)。

把特征向量读成“矩阵的自然坐标轴”

特征向量给出 $\mathbf{A}$ 最“顺手”的一组坐标方向：在这些方向上，矩阵乘法 $\mathbf{Av}$ 退化为标量乘法 $\lambda\mathbf{v}$ 。一旦把任意向量按特征向量展开，作用 $\mathbf{A}$ 就只是把各个分量分别乘上各自的 λ_i ——没有方向纠缠。本章后面的对角化、矩阵幂、稳定性分析，全都是在兑现这一句话的红利。

4.2 特征多项式：怎样把特征值找出来

定义说清了“是什么”，却没说“怎么求”。把 $\mathbf{Av} = \lambda\mathbf{v}$ 移项，关键的代数变形只有一步：

$$\mathbf{Av} = \lambda\mathbf{v} \iff (\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}.$$

这是一个齐次线性方程组。我们要的是非零解 $\mathbf{v}$ ——而一个齐次方程组有非零解，当且仅当它的系数矩阵奇异（第二章）。于是 λ 是特征值，当且仅当 $\mathbf{A} - \lambda\mathbf{I}$ 不可逆，即其行列式为零。

定义 4.2: 特征多项式

矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的**特征多项式** (characteristic polynomial) 是

$$p(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}).$$

它是 λ 的 n 次多项式; 方程 $p(\lambda) = 0$ 称为**特征方程**, 其根恰为 $\mathbf{A}$ 的全部特征值。

求特征值就是解特征方程; 求特征向量就是解齐次方程组

两步走, 机械而可靠:

(1) 解 $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$, 得到全部特征值 $\lambda_1, \dots$;

(2) 对每个 λ_i , 求 $(\mathbf{A} - \lambda_i \mathbf{I})\mathbf{v} = \mathbf{0}$ 的非零解, 即得该特征值的特征向量 (它们张成一个子空间, 称为**特征子空间** $\ker(\mathbf{A} - \lambda_i \mathbf{I})$)。

注 (特征值可能是复数) .

特征方程是实系数多项式方程, 但根未必是实数。最干净的例子是旋转 90° 的矩阵 $\mathbf{A} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$: 它把每一个实方向都转走了, 几何上根本没有“不变的实轴”, 对应地 $p(\lambda) = \lambda^2 + 1 = 0$ 给出 $\lambda = \pm i$ 。在 $\mathbb{C}$ 上特征向量依然存在。代数基本定理保证 n 阶矩阵在复数域内总有 n 个特征值 (按重数计)。下一章会看到, 实对称矩阵把这种麻烦一扫而空——它的特征值必为实数。

例 (一个 2×2 的完整计算) .

求 $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 的特征值与特征向量。

解.

特征值。 特征多项式为

$$p(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}) = \det \begin{bmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{bmatrix} = (2-\lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda-1)(\lambda-3).$$

故 $\lambda_1 = 1$ 、 $\lambda_2 = 3$ 。

特征向量。 对 $\lambda_1 = 1$, 解 $(\mathbf{A} - \mathbf{I})\mathbf{v} = \mathbf{0}$:

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \mathbf{v} = \mathbf{0} \implies v_1 + v_2 = 0 \implies \mathbf{v}_1 \propto \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

对 $\lambda_2 = 3$, 解 $(\mathbf{A} - 3\mathbf{I})\mathbf{v} = \mathbf{0}$:

$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{v} = \mathbf{0} \implies v_1 = v_2 \implies \mathbf{v}_2 \propto \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

验算 $\mathbf{A}(1,1)^\top = (3,3)^\top = 3(1,1)^\top$, 无误。特征向量只定到一个非零倍数: 若 $\mathbf{v}$ 是特征向量则 $c\mathbf{v}$ ($c \neq 0$) 也是, 因为 $\mathbf{A}(c\mathbf{v}) = c\mathbf{A}\mathbf{v} = \lambda(c\mathbf{v})$ 。注意这里两特征向量恰好正交——这并非巧合, 而是 $\mathbf{A}$ 对称的结果 (下一章谱定理)。

4.3 代数重数与几何重数

特征值在特征方程里可能是重根, 它对应的特征方向也可能不止一个。要刻画 “一个特征值带来多少独立方向”, 需要分清两个 “重数”。

定义 4.3: 代数重数与几何重数

设 λ_0 是 $\mathbf{A}$ 的特征值。

λ_0 的代数重数 (algebraic multiplicity) $m_a(\lambda_0)$ 是它作为特征多项式 $p(\lambda)$ 的根的重数。

λ_0 的几何重数 (geometric multiplicity) $m_g(\lambda_0)$ 是它的特征子空间的维数 $\dim \ker(\mathbf{A} - \lambda_0\mathbf{I})$, 即属于 λ_0 的线性无关特征向量的个数。

二者的关系是一条不等式, 方向恰好是 “几何 $\leq$ 代数”:

命题 4.4: 重数不等式

对任一特征值 λ_0 , 总有

$$1 \leq m_g(\lambda_0) \leq m_a(\lambda_0).$$

下界 $m_g \geq 1$ 是定义自带的: 特征值至少有一个特征向量。上界 $m_g \leq m_a$ 是实质内容, 直觉是 “一个 λ_0 撑不起比它的代数重数更多的独立方向”; 严格证明可在该特征子空间取一组基、扩成全空间的基后看 $\mathbf{A}$ 在这组基下的分块上三角形 (其证依赖相似不改变特征多项式, 见下一节)。当 $m_g < m_a$ 时, 我们说这个特征值是亏损的 (defective), 它 “欠” 了几个特征向量。

例 (一个亏损的例子: 剪切矩阵)。

考虑剪切矩阵 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 。它的特征结构是什么?

解.

特征多项式 $p(\lambda) = \det \begin{bmatrix} 1-\lambda & 1 \\ 0 & 1-\lambda \end{bmatrix} = (1-\lambda)^2$, 故 $\lambda = 1$ 是唯一特征值、代数重

数 $m_a = 2$ 。求特征向量：

$$(\mathbf{A} - \mathbf{I})\mathbf{v} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \mathbf{v} = \mathbf{0} \implies v_2 = 0 \implies \mathbf{v} \propto \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

特征子空间只有一维，几何重数 $m_g = 1 < 2 = m_a$ 。于是 $\mathbf{A}$ 亏损——它只有一根方向不变的轴 (x_1 轴)，别的方向都被“剪”歪了 (图 4.2)。这正是下一节“可对角化”会卡壳的那类矩阵。




图 4.2: 亏损矩阵: 剪切 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 把单位正方形“推”成平行四边形, 上边整体右滑。特征值 $\lambda = 1$ 代数重数为 2, 却只有一根不变的轴—— x_1 轴上的向量原地不动 ($\mathbf{A}(1, 0)^T = (1, 0)^T$), 其余方向都被剪歪。几何重数 $1 < 2$, 故 $\mathbf{A}$ 不可对角化。

4.4 可对角化: 凑齐 n 个线性无关的特征向量

对角化的整个故事, 可以浓缩成一句话: 能不能用特征向量拼出一组基。如果能, 矩阵就被拉直成对角形; 如果不能 (像上面的剪切矩阵), 就拉不直。先把“拉直”说清楚。

定义 4.5: 可对角化

方阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 称为可对角化的 (diagonalizable), 若存在可逆矩阵 $\mathbf{P}$ 与对角矩阵 $\mathbf{D}$, 使得

$$\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1},$$

等价地 $\mathbf{P}^{-1} \mathbf{A} \mathbf{P} = \mathbf{D}$ 。此时称 $\mathbf{A}$ 与对角阵 $\mathbf{D}$ 相似。

这个 $\mathbf{P}, \mathbf{D}$ 不是凭空来的, 它们就是特征向量与特征值。把 $\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1}$ 右乘 $\mathbf{P}$ 写成 $\mathbf{A} \mathbf{P} = \mathbf{P} \mathbf{D}$, 再逐列看: 设 $\mathbf{P}$ 的第 j 列是 $\mathbf{p}_j$ 、 $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$, 则左边第 j 列是 $\mathbf{A} \mathbf{p}_j$, 右边第 j 列是 $\lambda_j \mathbf{p}_j$ 。两边相等正是 $\mathbf{A} \mathbf{p}_j = \lambda_j \mathbf{p}_j$ ——即 $\mathbf{P}$ 的每一列都是特征向量、 $\mathbf{D}$ 的对角元是对应特征值。而 $\mathbf{P}$ 要可逆, 等价于它的 n 列线性无关。于是:

定理 4.6: 可对角化判据

$\mathbf{A} \in \mathbb{R}^{n \times n}$ 可对角化, 当且仅当它有 n 个线性无关的特征向量。此时取 $\mathbf{P} = [\mathbf{v}_1 \cdots \mathbf{v}_n]$ (各列为特征向量)、 $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$ (对应特征值), 便有

$$\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1}.$$

注 (列的顺序与配对) .

$\mathbf{P}$ 各列的顺序可以随意, 但 $\mathbf{D}$ 对角元的顺序必须与之一一对应: 第 j 列特征向量配第 j 个对角元特征值。换一个排列, $\mathbf{P}$ 与 $\mathbf{D}$ 同步换, 等式照样成立。还要注意 $\mathbf{P}$ 不唯一——每个特征向量都可任意缩放、重特征值的特征子空间内可任选基——但对角阵 $\mathbf{D}$ 的对角元 (连重数) 是 $\mathbf{A}$ 定死的。

什么时候凑得齐 n 个线性无关的特征向量? 一个最常用的充分条件, 来自下面这条干净的引理: 不同特征值的特征向量天然就线性无关。

引理 4.7: 相异特征值的特征向量线性无关

设 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 分别是 $\mathbf{A}$ 属于两两不同的特征值 $\lambda_1, \dots, \lambda_k$ 的特征向量。则 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 线性无关。

证明. 对 k 作归纳。 $k=1$ 时单个非零向量自然无关。设结论对 $k-1$ 成立, 要证对 k 成立。设有线性关系

$$c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + \cdots + c_k \mathbf{v}_k = \mathbf{0}. \quad (*)$$

对 $(*)$ 两边作用 $\mathbf{A}$, 利用 $\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$:

$$c_1 \lambda_1 \mathbf{v}_1 + c_2 \lambda_2 \mathbf{v}_2 + \cdots + c_k \lambda_k \mathbf{v}_k = \mathbf{0}. \quad (**)$$

再把 $(*)$ 乘以 λ_k , 与 $(**)$ 相减, 消去 $\mathbf{v}_k$ 那一项:

$$c_1 (\lambda_1 - \lambda_k) \mathbf{v}_1 + \cdots + c_{k-1} (\lambda_{k-1} - \lambda_k) \mathbf{v}_{k-1} = \mathbf{0}.$$

这是关于 $\mathbf{v}_1, \dots, \mathbf{v}_{k-1}$ 的线性关系。由归纳假设它们线性无关, 故每个系数为零: $c_i (\lambda_i - \lambda_k) = 0$ ($i = 1, \dots, k-1$)。因为 $\lambda_i \neq \lambda_k$, 得 $c_1 = \cdots = c_{k-1} = 0$ 。代回 $(*)$ 只剩 $c_k \mathbf{v}_k = \mathbf{0}$, 而 $\mathbf{v}_k \neq \mathbf{0}$, 故 $c_k = 0$ 。所有系数为零, 线性无关得证。 $\square$

推论 4.8: 相异特征值 $\Rightarrow$ 可对角化

若 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 有 n 个互不相同的特征值, 则它的 n 个特征向量线性无关, 故 $\mathbf{A}$ 可对角化。

可对角化的两个等价标准

对 $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，下面两件事等价于“可对角化”：

- (i) 存在 n 个线性无关的特征向量；
- (ii) 每个特征值的几何重数都等于其代数重数（即没有亏损），且全部代数重数之和为 n 。

相异特征值是 (i) 的一个方便充分条件，但不必要——单位阵 $\mathbf{I}$ 只有一个特征值 1（代数重数 n ），却有满满 n 维特征子空间，照样可对角化。真正会卡壳的只有亏损：几何重数顶不上代数重数时（如剪切矩阵），怎么也凑不齐 n 个无关特征向量。

注（拉不直时怎么办）。

亏损矩阵无法对角化，但总能化成“几乎对角”的 **Jordan 标准形**——对角线上是特征值、紧邻的上对角线上点缀几个 1，每个亏损方向贡献一个 Jordan 块。本书不展开 Jordan 理论，只需记住：经济学里真正要紧的那一大类矩阵（实对称矩阵，下一章）永不亏损，必可正交对角化；至于一般动态系统，即便偶遇亏损，谱半径主导的稳定性结论依然成立（本章末再述）。

4.5 相似变换：换坐标系看同一台变换

对角化 $\mathbf{A} = \mathbf{PDP}^{-1}$ 是“相似”这个更一般概念的特例。理解相似，就理解了对角化为何“保留了 $\mathbf{A}$ 的本质而只换了外衣”。

定义 4.9: 相似

两个方阵 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ **相似** (similar)，若存在可逆矩阵 $\mathbf{P}$ 使

$$\mathbf{B} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}.$$

相似的含义是**换基**：同一个线性变换，在不同的坐标系（基）下写出来的矩阵互相相似， $\mathbf{P}$ 是两组基之间的换基矩阵。可对角化，就是说存在一组基（特征向量基），在这组基下这台变换的矩阵是纯对角的。下面这条性质解释了为什么相似变换“不动”特征结构。

命题 4.10: 相似保特征多项式（从而保特征值、迹、行列式）

若 $\mathbf{B} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ ，则 $\mathbf{A}$ 与 $\mathbf{B}$ 有相同的特征多项式，因而有相同的特征值（连同代数重数）、相同的迹与相同的行列式。

证明. 直接计算特征多项式，反复用 $\det(\mathbf{XY}) = \det \mathbf{X} \det \mathbf{Y}$ 与 $\det(\mathbf{P}^{-1}) = 1/\det \mathbf{P}$ ：

$$\begin{aligned} \det(\mathbf{B} - \lambda \mathbf{I}) &= \det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P} - \lambda \mathbf{P}^{-1}\mathbf{P}) = \det(\mathbf{P}^{-1}(\mathbf{A} - \lambda \mathbf{I})\mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A} - \lambda \mathbf{I}) \det(\mathbf{P}) = \det(\mathbf{A} - \lambda \mathbf{I}). \end{aligned}$$

特征多项式相同，其根（特征值）随之相同。迹是特征多项式中 λ^{n-1} 的系数（差一个符号）、行列式是常数项（差一个符号），故也相同。□

相似变换是“换个坐标系，本质不变”

特征值、迹、行列式、秩、可对角化与否——这些都是**相似不变量**：它们刻画的是线性变换本身，与你用哪组基来写矩阵无关。对角化的全部意义，就是在所有相似的“外衣”里挑出最朴素的那一件（对角阵），让这些不变量直接显形在对角线上。

4.6 迹等于特征值之和，行列式等于特征值之积

特征值不仅藏着方向信息，还把矩阵两个最常用的标量——迹与行列式——一口气算了出来。这两条恒等式在计量与最优化里出现得极其频繁。

定理 4.11: 迹与行列式的特征值公式

设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的特征值为 $\lambda_1, \dots, \lambda_n$ （在 $\mathbb{C}$ 上按代数重数计）。则

$$\operatorname{tr} \mathbf{A} = \sum_{i=1}^n \lambda_i, \quad \det \mathbf{A} = \prod_{i=1}^n \lambda_i.$$

证明. 把特征多项式 $p(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I})$ 按它的根分解：因首项系数为 $(-1)^n$,

$$p(\lambda) = (-1)^n (\lambda - \lambda_1)(\lambda - \lambda_2) \cdots (\lambda - \lambda_n).$$

两边比较系数即可。

行列式。 令 $\lambda = 0$: 左边 $p(0) = \det \mathbf{A}$, 右边 $(-1)^n (-\lambda_1) \cdots (-\lambda_n) = (-1)^n (-1)^n \prod_i \lambda_i = \prod_i \lambda_i$. 故 $\det \mathbf{A} = \prod_i \lambda_i$ 。

迹。 比较 λ^{n-1} 的系数。右边展开, λ^{n-1} 的系数是 $(-1)^n \cdot (-(\lambda_1 + \cdots + \lambda_n)) = (-1)^{n-1} \sum_i \lambda_i$. 左边 $\det(\mathbf{A} - \lambda \mathbf{I})$ 中 λ^{n-1} 的系数——只有主对角线连乘项 $\prod_i (a_{ii} - \lambda)$ 才贡献 λ^{n-1} ——是 $(-1)^{n-1} \sum_i a_{ii} = (-1)^{n-1} \operatorname{tr} \mathbf{A}$. 两者相等, 得 $\operatorname{tr} \mathbf{A} = \sum_i \lambda_i$. □

注（对可对角化矩阵有一行更短的证法）。

若 $\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1}$, 则由迹的循环性 $\operatorname{tr}(\mathbf{X} \mathbf{Y}) = \operatorname{tr}(\mathbf{Y} \mathbf{X})$ 得 $\operatorname{tr} \mathbf{A} = \operatorname{tr}(\mathbf{P} \mathbf{D} \mathbf{P}^{-1}) = \operatorname{tr}(\mathbf{D} \mathbf{P}^{-1} \mathbf{P}) = \operatorname{tr} \mathbf{D} = \sum_i \lambda_i$; 又 $\det \mathbf{A} = \det \mathbf{P} \det \mathbf{D} \det(\mathbf{P}^{-1}) = \det \mathbf{D} = \prod_i \lambda_i$. 上面的证法不依赖可对角化, 对一切方阵都成立。

这两条公式的用处遍布全书。其一, 它们给了“不解特征方程也能做核验”的快捷手段——算出几个特征值后, 看它们的和、积对不对得上一眼可得的迹与行列式, 立刻知道有没有算错。其二, 许多结论可直接用迹/行列式翻译成特征值语言: 例如“ $\mathbf{A}$ 可逆 $\iff \det \mathbf{A} \neq 0 \iff$ 所有 $\lambda_i \neq 0$ ”, 又把第 4.1 节那句“0 是特征值 $\iff$ 奇异”补成了

完整闭环。计量里用 $\text{tr } \mathbf{A} = \sum_i \lambda_i$ 算投影矩阵的秩（前一章 OLS 自由度 $\text{tr } \mathbf{P} = \text{rank } \mathbf{P}$ 正是此理），统计里用 $\det \Sigma = \prod_i \lambda_i$ 度量协方差矩阵的“广义方差”，都靠这两行。

例（用迹与行列式倒查特征值）。

已知 $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ （即第 4.2 节那个矩阵）。不重新解特征方程，验证它的特征值之和、之积。

解。

$\text{tr } \mathbf{A} = 2 + 2 = 4$, $\det \mathbf{A} = 2 \cdot 2 - 1 \cdot 1 = 3$ 。我们求得特征值是 $\lambda_1 = 1, \lambda_2 = 3$ ：和为 $1 + 3 = 4 = \text{tr } \mathbf{A}$ ，积为 $1 \cdot 3 = 3 = \det \mathbf{A}$ ，两边吻合。反过来，若只知道迹与行列式，特征值便是方程 $\lambda^2 - (\text{tr } \mathbf{A})\lambda + \det \mathbf{A} = \lambda^2 - 4\lambda + 3 = 0$ 的根——这对 2×2 矩阵是最快的求特征值途径。

4.7 矩阵幂：对角化最直接的红利

到这里，对角化最实用的一个回报就要兑现了。动态系统反复迭代同一个矩阵 ($\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 意味着 $\mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0$)，Markov 链 t 步转移是 $\mathbf{A}^t$ ，反复代换的差分方程也归结为求 $\mathbf{A}^k$ 。直接做矩阵连乘既繁琐又看不出规律，但对角化把它打回了“标量的幂”。

关键观察：对角阵的幂是逐元素的幂。若 $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$ ，则

$$\mathbf{D}^k = \text{diag}(\lambda_1^k, \dots, \lambda_n^k),$$

因为对角阵相乘就是对角元逐个相乘。再借相似把它搬到 $\mathbf{A}$ 上： $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$ 时，连乘里中间的 $\mathbf{P}^{-1}\mathbf{P}$ 成对抵消，

$$\mathbf{A}^k = (\mathbf{P}\mathbf{D}\mathbf{P}^{-1})(\mathbf{P}\mathbf{D}\mathbf{P}^{-1}) \dots (\mathbf{P}\mathbf{D}\mathbf{P}^{-1}) = \mathbf{P}\mathbf{D}(\mathbf{P}^{-1}\mathbf{P})\mathbf{D} \dots \mathbf{D}\mathbf{P}^{-1} = \mathbf{P}\mathbf{D}^k\mathbf{P}^{-1}.$$

定理 4.12: 可对角化矩阵的幂

若 $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$ 可对角化，则对任意正整数 k ，

$$\mathbf{A}^k = \mathbf{P}\mathbf{D}^k\mathbf{P}^{-1} = \mathbf{P} \text{diag}(\lambda_1^k, \dots, \lambda_n^k) \mathbf{P}^{-1}.$$

若 $\mathbf{A}$ 还可逆（所有 $\lambda_i \neq 0$ ），公式对负整数 k 亦成立（取 $\mathbf{D}^{-1} = \text{diag}(\lambda_i^{-1})$ ）。

把矩阵的幂化成标量的幂

$\mathbf{A}^k = \mathbf{P}\mathbf{D}^k\mathbf{P}^{-1}$ 是本章使用频率最高的一条结论。它说：要追踪一个线性动态系统迭代很多次以后的样子，只需看每个特征值各自的 λ_i^k 怎样增长或衰减——增长最快的那个 λ_i （模最大者）最终主宰一切。差分方程、VAR、Markov 链的“长期行为”，答案全写在特征值的模里。

例 (手算一个 $\mathbf{A}^k$) .

用矩阵 $\mathbf{A} = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}$ (即图 4.1 那个矩阵, 特征值 $\lambda_1 = 2, \mathbf{v}_1 = (1, 1)^\top$ 与 $\lambda_2 = 1, \mathbf{v}_2 = (1, -1)^\top$), 写出 $\mathbf{A}^k$ 的闭式。

解.

取

$$\mathbf{P} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{P}^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

($\mathbf{P}^{-1}$ 用 2×2 求逆公式, $\det \mathbf{P} = -2$)。于是

$$\mathbf{A}^k = \mathbf{P} \mathbf{D}^k \mathbf{P}^{-1} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2^k & 0 \\ 0 & 1 \end{bmatrix} \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 2^k + 1 & 2^k - 1 \\ 2^k - 1 & 2^k + 1 \end{bmatrix}.$$

验证 $k = 1$ 还原成 $\mathbf{A}$ 、 $k = 0$ 给出 $\mathbf{I}$, 无误。注意当 k 增大, 2^k 项压倒一切: $\mathbf{A}^k$ 的行为最终由最大特征值 $\lambda_1 = 2$ 及其特征方向 $\mathbf{v}_1 = (1, 1)^\top$ 主导——这正是下一节“谁主导长期”的小型预演。

4.8 去处: 稳定性、Markov 链与通往谱定理

本章这套“特征值 + 对角化”的语言, 是后面好几门课的公用底座。这里把三处最重要的落点点明, 作为路标。

差分方程与 VAR 的稳定性: 谱半径

线性动态系统 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ (差分方程、向量自回归 VAR、迭代算法都是这个形式) 的长期命运, 完全由 $\mathbf{A}$ 特征值的模决定。把初值按特征向量展开 $\mathbf{x}_0 = \sum_i c_i \mathbf{v}_i$, 再用上一节的矩阵幂公式,

$$\mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0 = \sum_i c_i \lambda_i^t \mathbf{v}_i.$$

每个模式 $\mathbf{v}_i$ 以速率 λ_i^t 演化: $|\lambda_i| < 1$ 的模式衰减、 $|\lambda_i| > 1$ 的模式爆炸。于是整条轨道是收敛还是发散, 取决于最大的那个模。

定义 4.13: 谱半径

矩阵 $\mathbf{A}$ 的谱半径 (spectral radius) 是其特征值模的最大值

$$\rho(\mathbf{A}) = \max_i |\lambda_i|.$$

稳定性判据： $\rho(\mathbf{A}) < 1$

对线性系统 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ ：

$\rho(\mathbf{A}) < 1 \iff$ 对任意初值 $\mathbf{x}_t \rightarrow \mathbf{0}$ (系统渐近稳定)；

$\rho(\mathbf{A}) > 1 \iff$ 存在初值使 $\mathbf{x}_t$ 发散。

增长最快的模式 $\lambda_i^t \mathbf{v}_i$ (模最大的特征值方向) 最终主宰轨道，故“长期增长率”就是 $\rho(\mathbf{A})$ 、“长期方向”就是它对应的特征向量 (图 4.3)。VAR 平稳、差分方程稳定、不动点迭代收敛——这些条件在矩阵语言里是同一句话：谱半径小于一。




图 4.3: 线性系统 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 的轨道。两块矩阵的特征向量相同 (主方向 $\mathbf{v}_1$ 沿 45°)，区别只在谱半径。左： $\rho(\mathbf{A}) < 1$ ，任意初值都被吸进原点，路径渐渐贴上主方向 $\mathbf{v}_1$ (衰减最慢的模式)。右： $\rho(\mathbf{A}) > 1$ ，轨道沿 $\mathbf{v}_1$ 越甩越远。长期行为完全由谱半径与主特征向量决定。

Markov 链的平稳分布：特征值 1

一条有限状态 Markov 链由转移矩阵 $\mathbf{T}$ 刻画 (行随机：每行非负、行和为 1)， t 步后的状态分布是行向量 $\pi_0^T \mathbf{T}^t$ 。这里特征值扮演双重角色。一方面，行随机矩阵必有特征值 1：因各行和为 1，全 1 向量满足 $\mathbf{T}\mathbf{1} = \mathbf{1}$ ，故 1 是右特征向量 $\mathbf{1}$ 对应的特征值；与之配对的左特征向量 π (满足 $\pi^T \mathbf{T} = \pi^T$) 归一化为概率后，就是**平稳分布**——链跑到长期不再变化的那个分布。另一方面，其余特征值的模都 ≤ 1 ，它们控制“收敛到平稳分布有多快”：模第二大的特征值 $|\lambda_2|$ 决定混合速度，谱间隙 $1 - |\lambda_2|$ 越大、收敛越快。

平稳分布 = 特征值 1 的特征向量；收敛速度 = 第二特征值

“链最终稳定在哪里”与“稳定得多快”，分别由 $\mathbf{T}$ 的第一、第二特征值回答：平稳分布是 $\lambda_1 = 1$ 对应的左特征向量，混合速率由 $|\lambda_2|$ 主宰。这把动态随机过程的两个核心问题，化成了一道特征值问题。Markov 链一章 (在随机过程部分) 会把遍历性、唯一平稳分布等结论严格建立在这条观察上。

通往谱定理与主成分分析

最后，本章是下一章的正门。这里讲的对角化对一般方阵成立，代价是 $\mathbf{P}$ 不一定好——它的列（特征向量）未必正交， $\mathbf{A}$ 甚至可能亏损、根本对角化不了。下一章把镜头对准经济学里最常见的一族——**实对称矩阵**（协方差矩阵、Hessian、Gram 矩阵 $\mathbf{X}^T \mathbf{X}$ ）。它们的特征结构格外干净：特征值必为实数、永不亏损，而且特征向量可取成两两正交。于是对角化升级为**正交对角化** $\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T$ ($\mathbf{Q}$ 正交)，即**谱定理**。它进一步通向二次型的正定性判别、主成分分析（去找协方差矩阵最大特征值的方向，即方差最大的主轴）与最优化的二阶条件。本章把“特征值是什么、怎么算、怎么用幂”讲透，是读懂那一切的前提。

一句话收束：对角化是为线性变换挑坐标系的艺术——挑到特征向量这组基，矩阵的幂、它的长期行为、它的稳定性就都从对角线上直接读出。这正是本书反复强调的工具性：认清“特征值主宰长期行为”这一条，差分方程、Markov 链、PCA 这几扇看似无关的门，便一并有了钥匙。

第五章 对称矩阵、谱定理、二次型与正定性

用到的前置工具：特征值与特征向量、对角化（第四章）；内积、正交与正交矩阵（第三章）；矩阵的秩与可逆性（第二章）。

经济学里有两类对象，几乎是“生来对称”的：一是计量里的方差-协方差矩阵，二是最优化里目标函数的 Hessian。前者刻画一组随机变量怎样一起波动，后者刻画一个最优值面在驻点附近的弯曲方式。它们都是对称矩阵，而且我们对它们最想问的那个问题，措辞惊人地一致——这个二次型是“恒为正”、“恒为负”，还是有正有负？方差不可能为负，于是协方差矩阵必须半正定；山顶处目标函数往各个方向都向下弯，于是极大值的 Hessian 必须负定。本章要把“正定”这件事彻底讲透：它精确地意味着什么、怎样判断、以及为什么对称矩阵恰好是回答这个问题最顺手的对象。

关键是谱定理：实对称矩阵总能被一组正交的特征向量对角化。它把一个看似纠缠的二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 拆成若干条互相垂直的“主轴”，每条主轴上的弯曲程度就是一个特征值。一旦看清这一点，“正定”不过是“所有特征值都为正”的同义词，而本章后面所有的判据、所有的几何图像，都从这一句话里流出来。

5.1 对称矩阵：为什么经济学里到处是它

定义 5.1: 对称矩阵

方阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 称为对称的，若 $\mathbf{A}^T = \mathbf{A}$ ，即对一切 i, j 有 $a_{ij} = a_{ji}$ 。

对称性看上去只是一个记号上的巧合，但它在经济学里几乎是“默认设置”，原因有三处，每一处都对应一类核心应用。

对称矩阵的三个经济学来源

(i) 方差-协方差矩阵。设随机向量 $\mathbf{X} = (X_1, \dots, X_n)^T$ ，其协方差矩阵 $\Sigma = [\text{Cov}(X_i, X_j)]$ 天然对称，因为 $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$ 。

(ii) Hessian。二阶连续可微函数 f 的 Hessian $\nabla^2 f = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]$ 对称，这正是混合偏导可交换（Young 定理，第十三章）： $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$ 。

(iii) Gram 矩阵。任给矩阵 $\mathbf{X}$ （例如计量里的设计矩阵）， $\mathbf{X}^T \mathbf{X}$ 必对称，因为

$(\mathbf{X}^T \mathbf{X})^T = \mathbf{X}^T \mathbf{X}$ 。OLS 的正规方程里那个 $\mathbf{X}^T \mathbf{X}$ 就是这一类。

这三处来源解释了本章为何被单列出来：经济学家真正需要研究“弯曲”与“共同波动”时，研究的对象几乎必然落在对称矩阵这一族里。而对称矩阵恰好拥有一切方阵里最干净的谱结构，下一节就是它。

5.2 谱定理：实、正交、可对角化

一般方阵的特征值可能是复数，特征向量也不一定互相垂直，对角化甚至可能根本做不到（第四章）。对称矩阵把这些麻烦一扫而空。

定理 5.2: 谱定理（实对称矩阵）

设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 对称。则有三件事。

- (1) $\mathbf{A}$ 的特征值全为实数。
- (2) 属于不同特征值的特征向量互相正交。
- (3) 存在一个正交矩阵 $\mathbf{Q}$ （即 $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ ）与对角矩阵 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ ，使得

$$\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^T,$$

其中 $\mathbf{Q}$ 的各列 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 是 $\mathbf{A}$ 的一组标准正交特征向量， $\mathbf{A} \mathbf{q}_i = \lambda_i \mathbf{q}_i$ 。

(3) 就是常说的“正交可对角化”或谱分解。它的几何含义是：对称矩阵所做的线性变换，无非是“选一组正交的坐标轴 ($\mathbf{q}_i$)，沿各轴分别按因子 λ_i 伸缩”。把任一向量 $\mathbf{x}$ 按这组正交基展开 $\mathbf{x} = \sum_i (\mathbf{q}_i^T \mathbf{x}) \mathbf{q}_i$ ，作用 $\mathbf{A}$ 后每个分量被各自的 λ_i 缩放——没有旋转、没有剪切，纯粹的沿轴伸缩。这一图像是本章后面一切结论的母本。

(1) 与 (2) 的证明很短，把“对称”这个性质用足即可；(3) 里“总能凑齐一整组正交特征向量”是更深的部分，我们陈述并给直觉。

特征值为实数，且不同特征值的特征向量正交。先证 (1)。设 $\mathbf{A} \mathbf{v} = \lambda \mathbf{v}$ ， $\mathbf{v} \neq \mathbf{0}$ ，暂且允许 $\lambda \in \mathbb{C}$ 、 $\mathbf{v} \in \mathbb{C}^n$ 。记 $\bar{\mathbf{v}}$ 为逐元素的复共轭。把 $\mathbf{A} \mathbf{v} = \lambda \mathbf{v}$ 两边逐元素取共轭，并利用 $\mathbf{A}$ 是实矩阵 ($\bar{\mathbf{A}} = \mathbf{A}$)，得 $\mathbf{A} \bar{\mathbf{v}} = \bar{\lambda} \bar{\mathbf{v}}$ ——即 $\bar{\mathbf{v}}$ 是属于 $\bar{\lambda}$ 的特征向量，这一步下面要用到。现考虑标量 $\bar{\mathbf{v}}^T \mathbf{A} \mathbf{v}$ 。一方面

$$\bar{\mathbf{v}}^T \mathbf{A} \mathbf{v} = \bar{\mathbf{v}}^T (\lambda \mathbf{v}) = \lambda \bar{\mathbf{v}}^T \mathbf{v}.$$

另一方面，因 $\mathbf{A}$ 是实对称矩阵 ($\bar{\mathbf{A}} = \mathbf{A}$, $\mathbf{A}^T = \mathbf{A}$)，这个标量等于它自己的共轭转置：

$$\overline{\bar{\mathbf{v}}^T \mathbf{A} \mathbf{v}}^T = \mathbf{v}^T \bar{\mathbf{A}} \bar{\mathbf{v}} = \mathbf{v}^T \mathbf{A} \bar{\mathbf{v}} = \mathbf{v}^T (\bar{\lambda} \bar{\mathbf{v}}) = \bar{\lambda} \mathbf{v}^T \bar{\mathbf{v}} = \bar{\lambda} \bar{\mathbf{v}}^T \mathbf{v}.$$

故 $\lambda \bar{\mathbf{v}}^T \mathbf{v} = \bar{\lambda} \bar{\mathbf{v}}^T \mathbf{v}$ 。而 $\bar{\mathbf{v}}^T \mathbf{v} = \sum_i |v_i|^2 > 0$ ，两边消去即得 $\lambda = \bar{\lambda}$ ，即 $\lambda \in \mathbb{R}$ 。

再证 (2)。设 $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ 、 $\mathbf{A}\mathbf{w} = \mu\mathbf{w}$ ，且 $\lambda \neq \mu$ （现在 $\lambda, \mu, \mathbf{v}, \mathbf{w}$ 都已知是实的）。用 $\mathbf{A}^\top = \mathbf{A}$ 算同一个标量 $\mathbf{w}^\top \mathbf{A}\mathbf{v}$ 的两种方式：

$$\mathbf{w}^\top \mathbf{A}\mathbf{v} = \mathbf{w}^\top (\lambda\mathbf{v}) = \lambda \mathbf{w}^\top \mathbf{v}, \quad \mathbf{w}^\top \mathbf{A}\mathbf{v} = (\mathbf{A}\mathbf{w})^\top \mathbf{v} = \mu \mathbf{w}^\top \mathbf{v}.$$

相减得 $(\lambda - \mu) \mathbf{w}^\top \mathbf{v} = 0$ 。因 $\lambda \neq \mu$ ，必有 $\mathbf{w}^\top \mathbf{v} = 0$ ，即两特征向量正交。□

注（为什么“凑齐一整组”是更深的一步）。

(1)(2) 只说了“不同特征值”的情形。真正需要技术的是重特征值：当某个 λ 的代数重数大于 1 时，要保证它的特征子空间维数恰好等于重数（即无“亏损”），从而能在这个子空间内部再取一组正交基。对称矩阵确实满足这一点，标准证法是对维数作归纳：取一个特征向量 $\mathbf{q}_1$ （紧致性保证它存在，见第九章），把它正交补 $\mathbf{q}_1^\perp$ 看成 $(n-1)$ 维空间， $\mathbf{A}$ 限制在其上仍对称，归纳即可。直觉上，对称变换“各向独立地伸缩”，不会把一个方向的伸缩“渗”到与它垂直的方向去，于是总能把整个空间切成互相垂直的伸缩轴。

谱定理是本章的总开关

有了 $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top$ ，“对称矩阵”的几乎所有问题都能换到对角的 $\mathbf{\Lambda}$ 上去问，而对角矩阵的一切都一目了然。下面三件事将反复用到它：(i) 二次型 $\mathbf{x}^\top \mathbf{A}\mathbf{x}$ 经正交变换元变成纯平方和 $\sum_i \lambda_i y_i^2$ ；(ii) “正定”等价于“所有 $\lambda_i > 0$ ”；(iii) $\mathbf{A}$ 的行列式 $= \prod_i \lambda_i$ 、迹 $= \sum_i \lambda_i$ 。

5.3 二次型与正交换元

定义 5.3: 二次型

对称矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 诱导的二次型是函数

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j, \quad \mathbf{x} \in \mathbb{R}^n.$$

注（只有对称部分起作用）。

即便 $\mathbf{A}$ 不对称， $\mathbf{x}^\top \mathbf{A}\mathbf{x}$ 也只感知它的对称部分：因为 $\mathbf{x}^\top \mathbf{A}\mathbf{x}$ 是标量，等于自身转置 $\mathbf{x}^\top \mathbf{A}^\top \mathbf{x}$ ，故 $\mathbf{x}^\top \mathbf{A}\mathbf{x} = \mathbf{x}^\top \left[\frac{1}{2}(\mathbf{A} + \mathbf{A}^\top) \right] \mathbf{x}$ 。所以研究二次型时不妨总设 $\mathbf{A}$ 对称——这也是为何 Hessian、协方差这些以二次型身份登场的矩阵，都可以、并且总是当作对称矩阵处理。

把谱分解代入二次型，是本章最有用的一步代数。令正交变量 $\mathbf{y} = \mathbf{Q}^\top \mathbf{x}$ （这是一

次旋转换元，因为 $\mathbf{Q}$ 正交，保长保角），则 $\mathbf{x} = \mathbf{Q}\mathbf{y}$ ，于是

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T \mathbf{x} = (\mathbf{Q}^T \mathbf{x})^T \mathbf{\Lambda} (\mathbf{Q}^T \mathbf{x}) = \mathbf{y}^T \mathbf{\Lambda} \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2.$$

正交换元把二次型“对角化”成纯平方和

在沿特征向量取的新坐标 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$ 下，二次型变成无交叉项的纯平方和

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2.$$

每个特征值 λ_i 就是“沿第 i 条主轴方向，二次型弯曲的快慢与正负”。二次型恒正、恒负、还是有正有负，到这里完全由 λ_i 的符号决定——这就是下一节正定性判据的全部来源。

5.4 正定、半正定、负定、不定

定义 5.4: 正定性的四种类型

设 $\mathbf{A}$ 为 n 阶实对称矩阵。称 $\mathbf{A}$ 为：

正定 (positive definite, 记 $\mathbf{A} \succ 0$)，若对一切 $\mathbf{x} \neq \mathbf{0}$ 有 $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$ ；

半正定 (positive semidefinite, 记 $\mathbf{A} \succeq 0$)，若对一切 $\mathbf{x}$ 有 $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$ ；

负定 ($\mathbf{A} \prec 0$)、半负定 ($\mathbf{A} \preceq 0$)，定义对称地把不等号反向；

不定 (indefinite)，若 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 在某些 $\mathbf{x}$ 取正、在另一些取负。

由上一节的纯平方和表示 $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_i \lambda_i y_i^2$ (其中 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$ ，且 $\mathbf{x} \neq \mathbf{0} \iff \mathbf{y} \neq \mathbf{0}$ ，因为 $\mathbf{Q}$ 可逆)，符号判据立刻读出。

定理 5.5: 特征值符号判据

对实对称矩阵 $\mathbf{A}$ ，

$$\mathbf{A} \succ 0 \iff \text{所有 } \lambda_i > 0, \quad \mathbf{A} \succeq 0 \iff \text{所有 } \lambda_i \geq 0,$$

$$\mathbf{A} \prec 0 \iff \text{所有 } \lambda_i < 0, \quad \mathbf{A} \text{ 不定} \iff \text{既有 } \lambda_i > 0 \text{ 又有 } \lambda_j < 0.$$

证明。只证正定一行，其余完全平行。由 $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_i \lambda_i y_i^2$ 且 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$ 与 $\mathbf{x}$ 一一对应。
 $(\Leftarrow)$ 若所有 $\lambda_i > 0$ ，则对 $\mathbf{x} \neq \mathbf{0}$ 有 $\mathbf{y} \neq \mathbf{0}$ ，故 $\sum_i \lambda_i y_i^2 \geq (\min_i \lambda_i) \sum_i y_i^2 > 0$ 。
 $(\Rightarrow)$ 反设某 $\lambda_k \leq 0$ 。取 $\mathbf{y} = \mathbf{e}_k$ (第 k 个标准基向量)，对应的 $\mathbf{x} = \mathbf{Q} \mathbf{e}_k = \mathbf{q}_k \neq \mathbf{0}$ ，此时 $\mathbf{x}^T \mathbf{A} \mathbf{x} = \lambda_k \leq 0$ ，与正定矛盾。 $\square$

这条判据极其好用：要判断正定性，只需看特征值的符号，根本不必逐个去验证 $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ 。它也立刻给出两条常用的副产品。

推论 5.6: 行列式、迹与正定性

若 $\mathbf{A} \succ 0$ ，则 $\mathbf{A}$ 可逆且 $\mathbf{A}^{-1} \succ 0$ ；其行列式 $\det \mathbf{A} = \prod_i \lambda_i > 0$ ，迹 $\operatorname{tr} \mathbf{A} = \sum_i \lambda_i > 0$ 。更一般地， $\mathbf{A} \succeq 0$ 时 $\det \mathbf{A} = \prod_i \lambda_i \geq 0$ 。

反向不真： $\det \mathbf{A} > 0$ 不蕴含正定—— $\operatorname{diag}(-1, -1)$ 行列式为 1 却负定。光看行列式符号会被偶数个负特征值“骗过”，这正是下面 Sylvester 判据要逐阶把关的原因。

Sylvester 顺序主子式判据

特征值判据虽干净，却要先解特征方程。实践中常有一条不必求特征值、只需算几个行列式的捷径。

定义 5.7: 顺序主子式

n 阶矩阵 $\mathbf{A}$ 的第 k 个顺序主子式 (leading principal minor) D_k 是其左上角 $k \times k$ 子块的行列式：

$$D_1 = a_{11}, \quad D_2 = \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad \dots, \quad D_n = \det \mathbf{A}.$$

定理 5.8: Sylvester 判据

设 $\mathbf{A}$ 为 n 阶实对称矩阵。则

$$\mathbf{A} \succ 0 \iff D_1 > 0, D_2 > 0, \dots, D_n > 0 \quad (\text{所有顺序主子式皆正});$$

$$\mathbf{A} \prec 0 \iff (-1)^k D_k > 0 \text{ 对一切 } k \quad (\text{符号交错: } D_1 < 0, D_2 > 0, D_3 < 0, \dots).$$

注 (判据的直觉与一个易错点)。

正定性“遗传给子块”：若 $\mathbf{A} \succ 0$ ，把 $\mathbf{x}$ 限制在前 k 个坐标 (其余置零) 仍有 $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$ ，故左上 $k \times k$ 子块也正定，从而 $D_k > 0$ 。反方向 (所有 $D_k > 0$ 推出正定) 可由对 k 的归纳、配方法逐步消元得到，每一步的“主元”正比于 $D_k/D_{k-1} > 0$ 。负定情形把 $\mathbf{A}$ 换成 $-\mathbf{A}$ 即知 $D_k(-\mathbf{A}) = (-1)^k D_k(\mathbf{A})$ ，于是符号交错。

易错点：Sylvester 判据只对严格正/负定干净成立。半正定不能仅靠“顺序主子式 ≥ 0 ”来判——反例 $\mathbf{A} = \operatorname{diag}(0, -1)$ 有 $D_1 = 0, D_2 = 0$ 都非负，但它显然不是半正定 (取 $\mathbf{x} = \mathbf{e}_2$ 得 $-1 < 0$)。要判半正定，必须验所有主子式 (不止左上角那一列嵌套子块) 非负，或者干脆回到特征值。

例 (二阶矩阵的速记)。

对 $\mathbf{A} = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$, 用 Sylvester 判据写出正定 / 负定 / 不定的条件。

解.

顺序主子式为 $D_1 = a$, $D_2 = \det \mathbf{A} = ac - b^2$ 。于是

$$\mathbf{A} \succ 0 \iff a > 0 \text{ 且 } ac - b^2 > 0; \quad \mathbf{A} \prec 0 \iff a < 0 \text{ 且 } ac - b^2 > 0.$$

当 $ac - b^2 < 0$ 时 $D_2 = \lambda_1 \lambda_2 < 0$, 两特征值一正一负, $\mathbf{A}$ 不定 (等值线是双曲线)。这正是无约束最优化里二元函数的二阶检验: $f_{xx} > 0$ 且 $f_{xx}f_{yy} - f_{xy}^2 > 0$ 判极小, $f_{xx} < 0$ 且同一行列式 > 0 判极大, 行列式 < 0 则是鞍点——它就是这条速记的逐字翻译。

合同与惯性定律

还有第三种刻画, 它丢掉特征值的具体大小, 只保留符号的“个数”。

定义 5.9: 合同

两个对称矩阵 $\mathbf{A}, \mathbf{B}$ 合同 (congruent), 若存在可逆矩阵 $\mathbf{P}$ 使 $\mathbf{B} = \mathbf{P}^T \mathbf{A} \mathbf{P}$ 。

合同正是“对二次型作可逆线性换元 $\mathbf{x} = \mathbf{P}\mathbf{y}$ ”在矩阵上的体现: $\mathbf{x}^T \mathbf{A} \mathbf{x} = \mathbf{y}^T (\mathbf{P}^T \mathbf{A} \mathbf{P}) \mathbf{y}$ 。前面的正交换元 $\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T$ 是合同的一个特例 ($\mathbf{P} = \mathbf{Q}$, 且恰好正交)。如果允许更一般的可逆 $\mathbf{P}$, 还能把各个 λ_i 进一步缩放到 ± 1 或 0 。

定理 5.10: Sylvester 惯性定律

任一实对称矩阵 $\mathbf{A}$ 都合同于一个形如

$$\text{diag}(\underbrace{1, \dots, 1}_{n_+}, \underbrace{-1, \dots, -1}_{n_-}, \underbrace{0, \dots, 0}_{n_0})$$


的对角阵。其中正项数 n_+ 、负项数 n_- 、零项数 n_0 由 $\mathbf{A}$ 唯一确定 (不依赖所作的换元), n_+ 与 n_- 分别等于 $\mathbf{A}$ 的正、负特征值个数, 三元组 (n_+, n_-, n_0) 称为 $\mathbf{A}$ 的惯性指数。

惯性定律说的是: 可逆换元能改变各主轴的“长度” (把 λ_i 缩成 ± 1), 却动不了“正负零”这三类的数目。正定 $\iff n_+ = n$; 半正定 $\iff n_- = 0$; 不定 $\iff n_+ > 0$ 且 $n_- > 0$ 。它解释了为什么“符号”而非“大小”才是二次型的本质不变量。


5.5 几何: 等值线的形状由特征值决定

把上面所有判据落到二维图像上, 一切变得直观。看二次型的等值线 $\{\mathbf{x} : \mathbf{x}^T \mathbf{A} \mathbf{x} = c\}$ ($c > 0$)。在正交坐标 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$ 下它是 $\lambda_1 y_1^2 + \lambda_2 y_2^2 = c$:

- $\mathbf{A} \succ 0$ ($\lambda_1, \lambda_2 > 0$): 等值线是椭圆, 主轴沿特征向量 $\mathbf{q}_1, \mathbf{q}_2$, 第 i 条半轴长为 $\sqrt{c/\lambda_i}$ 。特征值越大、该方向弯得越急、椭圆在该方向越“扁”; 半轴长正比于 $1/\sqrt{\lambda_i}$ 。曲面本身是一只碗, 原点是唯一极小 (图 5.1 左、图 5.2 左)。
- $\mathbf{A}$ 不定 ($\lambda_1 > 0 > \lambda_2$): 等值线是双曲线, 曲面是一张鞍, 原点是驻点但非极值——沿一条主轴向上、沿另一条向下 (图 5.1 右、图 5.2 右)。
- $\mathbf{A}$ 半正定退化 (某 $\lambda_i = 0$): 该方向上二次型是平的, 等值线退化为一对平行线 (一条“谷底直线”)。




(a) 正定: 同心椭圆



(b) 不定: 双曲 (鞍形)

图 5.1: 二次型 $Q(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} = c$ 的等值线。(a) 正定 $\mathbf{A}$ ($\lambda_1, \lambda_2 > 0$) 给同心椭圆, 主轴沿特征向量 $\mathbf{q}_1, \mathbf{q}_2$, 半轴长 $\propto 1/\sqrt{\lambda_i}$ (此处 $\lambda_1 < \lambda_2$, 故沿 $\mathbf{q}_1$ 更长)。(b) 不定 $\mathbf{A}$ ($\lambda_1 > 0 > \lambda_2$) 给双曲线: $Q > 0$ (蓝) 与 $Q < 0$ (红) 两族被零水平线 (渐近线, 虚线) 隔开, 对应鞍形曲面。

正定: 碗形 (唯一极小)



不定: 鞍形 (驻点非极值)




图 5.2: 同样两块矩阵对应的曲面 $z = \mathbf{x}^T \mathbf{A} \mathbf{x}$ 。正定给一只碗 (原点处各方向都向上弯, 唯一极小), 不定给一张鞍 (一方向向上、另一方向向下, 驻点非极值)。这正是最优化二阶条件的几何来源。

把符号读成形状

特征值的符号决定二次型曲面是碗（全正，正定）、倒碗（全负，负定）、还是鞍（有正有负，不定）；特征值的大小决定碗有多陡、椭圆有多扁。最优化里“这个驻点是极大、极小还是鞍点”，问的就是 Hessian 这块矩阵给出的是碗、倒碗还是鞍——把代数判据翻译成这幅图像，二阶条件就不再需要死记。

5.6 Rayleigh 商：特征值是二次型的极值

谱定理还顺带回答了一个最优化味道十足的问题：在单位球面上，二次型能取到的最大、最小值是多少？答案漂亮——就是最大、最小特征值。

定义 5.11: Rayleigh 商

对实对称矩阵 $\mathbf{A}$ 与 $\mathbf{x} \neq \mathbf{0}$ ，Rayleigh 商定义为

$$R(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}.$$

它是“单位化后的二次型”： $R(\mathbf{x})$ 只依赖 $\mathbf{x}$ 的方向、不依赖长度（ $R(t\mathbf{x}) = R(\mathbf{x})$ ）。所以研究它只需把 $\mathbf{x}$ 限制在单位球面 $\|\mathbf{x}\| = 1$ 上，此时 $R(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ 。

定理 5.12: Rayleigh–Ritz

设 $\mathbf{A}$ 实对称，特征值排为 $\lambda_{\min} = \lambda_1 \leq \dots \leq \lambda_n = \lambda_{\max}$ 。则对一切 $\mathbf{x} \neq \mathbf{0}$,

$$\lambda_{\min} \leq R(\mathbf{x}) \leq \lambda_{\max},$$

且两端分别在 $\mathbf{x}$ 取最小、最大特征值对应的特征向量时取到：

$$\lambda_{\max} = \max_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \max_{\|\mathbf{x}\|=1} \mathbf{x}^T \mathbf{A} \mathbf{x}, \quad \lambda_{\min} = \min_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}).$$

证明. 在正交坐标 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$ 下， $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_i \lambda_i y_i^2$ ，而 $\mathbf{Q}$ 正交保长，故 $\mathbf{x}^T \mathbf{x} = \mathbf{y}^T \mathbf{y} = \sum_i y_i^2$ 。于是

$$R(\mathbf{x}) = \frac{\sum_i \lambda_i y_i^2}{\sum_i y_i^2},$$

这是特征值 λ_i 以权重 $w_i = y_i^2 / \sum_j y_j^2 \geq 0$ ($\sum_i w_i = 1$) 作的加权平均。加权平均必落在最小项与最大项之间： $\lambda_{\min} \leq \sum_i w_i \lambda_i \leq \lambda_{\max}$ 。把全部权重压到 $\lambda_{\max}$ 对应的坐标（即 $\mathbf{y} = \mathbf{e}_n$ ， $\mathbf{x} = \mathbf{q}_n$ ）取得上界；压到 $\lambda_{\min}$ 取得下界。□

Rayleigh 商：把“谱”变成一个最优化问题

最大特征值 = 单位球面上二次型的最大值，并在对应特征向量处取到——这把“求特征值”重述成“求约束最优化的极值”，是数值线性代数（幂法、Lanczos）与统计降维的共同出发点。

下图把这件事画出来：让 $\mathbf{x}$ 沿单位圆转一圈（用角度 θ 参数化），看 R 怎样在 $\lambda_{\min}$ 与 $\lambda_{\max}$ 之间起伏，并恰在特征向量方向触顶、触底。




图 5.3: Rayleigh 商 $R(\mathbf{x}_\theta)$ 随单位向量 $\mathbf{x}_\theta = (\cos \theta, \sin \theta)^\top$ 转动的变化 ($n = 2$, $\mathbf{A} = \text{diag}(\lambda_{\min}, \lambda_{\max})$)。它在 $\lambda_{\min}$ 与 $\lambda_{\max}$ 之间起伏，恰在特征向量方向 $\mathbf{q}_1$ （最小）、 $\mathbf{q}_n$ （最大）处触底、触顶。

5.7 去处：协方差、二阶条件、白化与 Cholesky

本章这套“对称矩阵 + 正定性”的语言，是后续好几门核心课的公用底座。这里把几处最重要的落点点明，作为通往各 Part 的路标。

方差矩阵必半正定

任一随机向量 $\mathbf{X}$ 的协方差矩阵 $\Sigma = \mathbb{E}((\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top)$ 总是半正定的。理由就是一句二次型的计算：对任意常向量 $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \mathbf{a}^\top \mathbb{E}((\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top) \mathbf{a} = \mathbb{E}([\mathbf{a}^\top (\mathbf{X} - \mu)]^2) = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

半正定性就是“方差不会为负”

$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0$ 把一个代数性质 ($\Sigma \succeq 0$) 与一个统计常识（任何线性组合的方差非负）划上等号。它的推论遍布计量： Σ 的特征值非负、 $\det \Sigma \geq 0$ ； Σ 奇异（某 $\lambda_i = 0$ ）恰对应“存在一个零方差的线性组合”，即变量间有完全共线性。主成分分析（第六章）正是去找 Σ 最大特征值方向——方差最大的那条

主轴，骨子里就是本章的 Rayleigh 商。

最优化的二阶条件

这是与隐函数定理（第十五章）直接咬合的去处。无约束最优化中（第十八章），内点驻点 $\mathbf{x}^*$ ($\nabla f(\mathbf{x}^*) = \mathbf{0}$) 的二阶判别，全在 Hessian $\mathbf{H} = \nabla^2 f(\mathbf{x}^*)$ 的正定性上：

Hessian $\mathbf{H}$	二次型曲面	该驻点性质
负定 $\mathbf{H} \prec 0$	倒碗	严格局部极大
正定 $\mathbf{H} \succ 0$	碗	严格局部极小
不定	鞍	鞍点（非极值）
半定（退化）	退化	二阶检验失效，需更高阶信息

道理就是 Taylor 二阶展开（第十四章）： $f(\mathbf{x}^* + \mathbf{h}) \approx f(\mathbf{x}^*) + \frac{1}{2}\mathbf{h}^\top \mathbf{H} \mathbf{h}$ ，驻点附近函数的增减完全由二次型 $\mathbf{h}^\top \mathbf{H} \mathbf{h}$ 主宰，于是“往哪个方向都下降”（极大）就等价于 $\mathbf{H}$ 负定。还记得隐函数定理（第十五章）里那句“二阶条件一身二任”吗——极大值要求 $\mathbf{H}$ 负定，而负定矩阵必可逆，这恰好又是对最优化一阶条件做比较静态时所需的非退化条件。两章在“正定性”这个词上接上了头。

白化、GLS 与 Cholesky 前奏

正定矩阵还能开平方根，这给了我们“拉直”相关数据的工具。设 $\Sigma \succ 0$ ，由谱分解 $\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top$ 可定义对称正定平方根

$$\Sigma^{1/2} = \mathbf{Q} \Lambda^{1/2} \mathbf{Q}^\top, \quad \Lambda^{1/2} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}),$$

它满足 $\Sigma^{1/2} \Sigma^{1/2} = \Sigma$ （因 $\lambda_i > 0$ ， $\sqrt{\lambda_i}$ 有定义——这一步用足了正定性）。于是变换 $\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \boldsymbol{\mu})$ 把任意相关、异方差的 $\mathbf{X}$ 标准化成 $\text{Var}(\mathbf{Z}) = \mathbf{I}$ 的“白噪声”，这叫白化（whitening）。

正定性是“开平方”与“白化”的通行证

$\mathbf{A} \succ 0 \iff$ 它有对称正定平方根 $\mathbf{A}^{1/2}$ ，也 $\iff$ 它有 Cholesky 分解 $\mathbf{A} = \mathbf{L} \mathbf{L}^\top$ （ $\mathbf{L}$ 下三角、对角元为正）。这两件事在计量里都化作“白化”这一个动作：广义最小二乘（GLS）把 $\Sigma^{-1/2}$ 乘到模型两边，将相关、异方差的误差拉成同方差不相关的 OLS 标准情形；模拟相关随机向量则反过来用 $\mathbf{L}$ 把独立标准正态“染上”指定的协方差。正定性正是这一切的前提——平方根、Cholesky 都只对正定矩阵存在。

至此，本章的逻辑链条已经合拢：对称矩阵（来自方差与 Hessian） $\rightarrow$ 谱定理（拆成正交主轴） $\rightarrow$ 正定性（主轴方向的符号） $\rightarrow$ 三处去处（方差非负、二阶条件、白化）。读到后面无论是 PCA、GLS，还是最优化的二阶条件，遇到“这个矩阵正定吗”这个问句时，回到本章这幅“碗、倒碗、鞍”的图像，答案与做法往往就在眼前。

第六章 奇异值分解与降维

用到的前置工具：内积、正交与投影（第三章）；特征值、特征向量与对角化（第四章）；对称矩阵、谱定理与正定性（第五章）。

到上一章为止，我们能漂亮地分解的都是方阵，而且谱定理那套最干净的结论只对对称方阵成立。可经济学里真正天天打交道的矩阵——数据矩阵 $\mathbf{X}$ （ n 个观测、 k 个变量）——通常既不是方阵（ $n \gg k$ ），更谈不上对称。奇异值分解（singular value decomposition, SVD）正是把谱定理推广到任意 $m \times n$ 矩阵的那把钥匙：任何矩阵都能写成“旋转—沿主轴拉伸—再旋转”三步。它一举回答了一长串看似各自独立的问题——主成分分析（PCA）如何降维、当 $\mathbf{X}^T \mathbf{X}$ 不可逆时最小二乘还能不能解、一个矩阵离低秩矩阵有多远、多重共线性到底“病”在哪里。本章把这把万能分解讲透，并把它接回计量与数据分析的几个核心落点。

6.1 为什么需要一把“万能分解”

特征值分解（第四章）和谱定理（第五章）很强大，但它们有一道硬门槛：只能作用在方阵上，而最干净的正交对角化 $\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T$ 更是只对实对称矩阵成立。经济学家手里最重要的那个矩阵——把每一行当作一个观测、每一列当作一个变量的数据矩阵 $\mathbf{X} \in \mathbb{R}^{n \times k}$ ——几乎从不是方阵（样本量 n 远大于变量数 k ），自然也无所谓对称。我们却偏偏想对它做这些事：

- **降维**： k 个变量高度相关，能否用少数几个“综合指标”几乎无损地概括全部信息？这是主成分分析。
- **求解病态或不可逆的最小二乘**：当 $\mathbf{X}^T \mathbf{X}$ 因共线性而（近乎）奇异、正规方程 $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$ 无唯一解时，还能不能给出一个有意义的解？
- **低秩近似与压缩**：用一个秩很低的矩阵去逼近 $\mathbf{X}$ ，丢掉的“信息”最少能控制在多少？
- **诊断病态**：怎样用一个数刻画“这个矩阵离奇异有多近”，从而预警共线性、弱工具变量这类麻烦？

这四件事的共同要害，是想把一个一般矩阵拆成“彼此正交的几条独立方向 + 每条方向上的一个强度”。谱定理对对称阵正是这么做的；SVD 把它推广到一切矩阵，从而成为上面所有问题的统一答案。

一句话定位

谱定理回答“对称方阵怎么拆”，奇异值分解回答“任意矩阵怎么拆”。后者是前者的推广：把 $\mathbf{A}$ 作用到一对正交基上，输出仍是一组正交方向，只是长度被“奇异值”缩放了。降维、广义逆、低秩近似、病态诊断，骨子里都是在读这把分解。

6.2 奇异值分解：陈述与几何

定理 6.1: 奇异值分解

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 为任意实矩阵，秩为 r 。则存在正交矩阵 $\mathbf{U} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{V} \in \mathbb{R}^{n \times n}$ （即 $\mathbf{U}^T \mathbf{U} = \mathbf{I}_m$ ， $\mathbf{V}^T \mathbf{V} = \mathbf{I}_n$ ）与“对角”矩阵 $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ ，使得

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T,$$

其中 $\mathbf{\Sigma}$ 除主对角线外全为零，对角元

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0 = \sigma_{r+1} = \cdots$$

称为 $\mathbf{A}$ 的奇异值。 $\mathbf{U}$ 的各列 $\mathbf{u}_1, \dots, \mathbf{u}_m$ 称为左奇异向量， $\mathbf{V}$ 的各列 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 称为右奇异向量。

把分解逐列读出来，更见其用意。 $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$ 等价于对每个 $j \leq r$,

$$\mathbf{A} \mathbf{v}_j = \sigma_j \mathbf{u}_j, \quad \mathbf{A}^T \mathbf{u}_j = \sigma_j \mathbf{v}_j,$$

而对 $j > r$ 则 $\mathbf{A} \mathbf{v}_j = \mathbf{0}$ 。换言之：存在一组输入端的正交基 $\{\mathbf{v}_j\}$ 和一组输出端的正交基 $\{\mathbf{u}_j\}$ ，使得 $\mathbf{A}$ 把第 j 个输入方向原封不动地送到第 j 个输出方向上，只是把长度乘了 σ_j 。这正是“ $\mathbf{A}$ 在合适的坐标里就是一组纯缩放”——和对角化的精神完全一致，区别只在于进出两端用了两套不同的正交基。

把 $\mathbf{A}$ 读成“旋转—拉伸—旋转”

$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$ 作用在向量 $\mathbf{x}$ 上是三步： $\mathbf{V}^T$ 先把 $\mathbf{x}$ 旋转到以右奇异向量为坐标轴的系里； $\mathbf{\Sigma}$ 沿这些坐标轴各自拉伸 σ_j 倍； $\mathbf{U}$ 再把结果旋转到以左奇异向量为坐标轴的系里。正交矩阵只转不形变，全部的“形变”都集中在中间那步对角拉伸上——奇异值 σ_j 就是各主方向上的拉伸强度。

这个三步图像最干净的看法，是看 $\mathbf{A}$ 把单位球面送到哪里。单位球面经正交变换 $\mathbf{V}^T$ 仍是单位球面；经 $\mathbf{\Sigma}$ 沿各坐标轴拉伸 σ_j 倍后变成一个半轴长为 σ_j 的椭球；再经正交变换 $\mathbf{U}$ 旋转到位。于是：

几何本质

任意矩阵 $\mathbf{A}$ 把单位球面映成一个椭球。椭球的半轴长就是奇异值 σ_j ，半轴的方向就是左奇异向量 $\mathbf{u}_j$ ；把这些半轴拉回原像，对应的就是右奇异向量 $\mathbf{v}_j$ 。最大奇异值 $\sigma_1 = \max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$ 度量了 $\mathbf{A}$ 能产生的最大拉伸，最小（非零）奇异值则是最小拉伸。

图 6.1 把二维情形画了出来：一个 2×2 矩阵把单位圆经“ $\mathbf{V}^T$ 旋转 $\rightarrow \Sigma$ 沿坐标轴拉伸 $\rightarrow \mathbf{U}$ 旋转”三步送成一个椭圆。




图 6.1: 二维 SVD 的几何三步。单位圆经 $\mathbf{V}^T$ 旋转（圆不变，右奇异向量 $\mathbf{v}_1, \mathbf{v}_2$ 转到坐标轴），经 Σ 沿坐标轴拉伸 σ_1, σ_2 倍成轴对齐椭圆，再经 $\mathbf{U}$ 旋转得到一般椭圆——其长短半轴正是 $\sigma_1 \mathbf{u}_1, \sigma_2 \mathbf{u}_2$ 。这里取长短半轴之比 $\sigma_1 : \sigma_2 = 3 : 1$ 。

6.3 奇异值从哪来：与 $\mathbf{A}^T \mathbf{A}$ 、 $\mathbf{A} \mathbf{A}^T$ 的关系

奇异值不是凭空规定的，它直接来自一个对称半正定矩阵的谱。这一节用谱定理把 SVD 构造出来——这既是它的“来历”，也是实际计算它的方法。

关键观察是：对任意 $\mathbf{A}$ ，矩阵 $\mathbf{A}^T \mathbf{A}$ 是 $n \times n$ 对称半正定矩阵（对任意 $\mathbf{x}$ 有 $\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0$ ）。由谱定理，它可正交对角化：存在标准正交基 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 与非负特征值 $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ ，使得

$$\mathbf{A}^T \mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{v}_j.$$

这些 $\mathbf{v}_j$ 就取作右奇异向量。定义

$$\sigma_j = \sqrt{\lambda_j} \quad (\text{奇异值} = \mathbf{A}^\top \mathbf{A} \text{ 特征值的算术平方根}),$$

对 $\sigma_j > 0$ 的那些 j (即 $j \leq r = \text{rank } \mathbf{A}$), 令

$$\mathbf{u}_j = \frac{1}{\sigma_j} \mathbf{A} \mathbf{v}_j.$$

核心等式

$$\sigma_j(\mathbf{A}) = \sqrt{\lambda_j(\mathbf{A}^\top \mathbf{A})} = \sqrt{\lambda_j(\mathbf{A} \mathbf{A}^\top)}.$$

$\mathbf{A}^\top \mathbf{A}$ 与 $\mathbf{A} \mathbf{A}^\top$ 有相同的非零特征值 (即 σ_j^2), 右奇异向量 $\mathbf{v}_j$ 是前者的特征向量、左奇异向量 $\mathbf{u}_j$ 是后者的特征向量。这把“一般矩阵的奇异值”彻底化归为“对称半正定矩阵的特征值”——后者我们在谱定理一章已经完全掌握。

要验证这套构造确实给出 SVD, 只需检查 $\{\mathbf{u}_j\}$ 标准正交、且 $\mathbf{A} = \sum_j \sigma_j \mathbf{u}_j \mathbf{v}_j^\top$ 。

证明. 先看 $\{\mathbf{u}_j\}_{j \leq r}$ 标准正交。对 $i, j \leq r$,

$$\mathbf{u}_i^\top \mathbf{u}_j = \frac{1}{\sigma_i \sigma_j} (\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j) = \frac{1}{\sigma_i \sigma_j} \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_j = \frac{\lambda_j}{\sigma_i \sigma_j} \mathbf{v}_i^\top \mathbf{v}_j.$$

由 $\{\mathbf{v}_j\}$ 标准正交, $\mathbf{v}_i^\top \mathbf{v}_j = \delta_{ij}$; 当 $i = j$ 时上式为 $\lambda_j / \sigma_j^2 = 1$, 当 $i \neq j$ 时为 0。故 $\{\mathbf{u}_j\}_{j \leq r}$ 标准正交, 可补成 $\mathbb{R}^m$ 的标准正交基。

再看分解式。 $\{\mathbf{v}_j\}$ 是 $\mathbb{R}^n$ 的标准正交基, 故任意 $\mathbf{x}$ 有 $\mathbf{x} = \sum_j (\mathbf{v}_j^\top \mathbf{x}) \mathbf{v}_j$ 。两边左乘 $\mathbf{A}$, 并用 $\mathbf{A} \mathbf{v}_j = \sigma_j \mathbf{u}_j$ ($j \leq r$)、 $\mathbf{A} \mathbf{v}_j = \mathbf{0}$ ($j > r$, 因为 $\|\mathbf{A} \mathbf{v}_j\|^2 = \lambda_j = 0$):

$$\mathbf{A} \mathbf{x} = \sum_{j \leq r} \sigma_j (\mathbf{v}_j^\top \mathbf{x}) \mathbf{u}_j = \left(\sum_{j \leq r} \sigma_j \mathbf{u}_j \mathbf{v}_j^\top \right) \mathbf{x}.$$

对一切 $\mathbf{x}$ 成立, 故 $\mathbf{A} = \sum_{j \leq r} \sigma_j \mathbf{u}_j \mathbf{v}_j^\top$, 写成矩阵形式即 $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ 。□

注 (为什么不直接对 $\mathbf{A}$ 做特征分解)。

当 $\mathbf{A}$ 不是方阵时根本谈不上特征值; 即便是方阵, 非对称矩阵的特征向量也未必正交、甚至可能不可对角化。SVD 的高明之处正在于: 它不去碰 $\mathbf{A}$ 本身的谱, 而是退到永远对称半正定的 $\mathbf{A}^\top \mathbf{A}$ 上借谱定理的力。代价是进出两端要用两套正交基 ($\mathbf{V}$ 与 $\mathbf{U}$), 换来的是对一切矩阵都成立。

上面那个 $\mathbf{A} = \sum_{j \leq r} \sigma_j \mathbf{u}_j \mathbf{v}_j^\top$ 的写法极其有用, 它把 $\mathbf{A}$ 表成 r 个秩一矩阵之和, 按奇异值从大到小排列:

秩一展开 (外积形式)

$$\mathbf{A} = \sum_{j=1}^r \sigma_j \mathbf{u}_j \mathbf{v}_j^{\top}.$$

每一项 $\sigma_j \mathbf{u}_j \mathbf{v}_j^{\top}$ 是一个秩一矩阵, “重要性” 由 σ_j 排序。这一形式是低秩近似 (下一节) 和数据压缩的直接出发点: 想压缩 $\mathbf{A}$, 就只留前几个最大的项。

例 (手算一个 2×2 的 SVD) .

求 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 的奇异值。

解.

按构造法, 先算 $\mathbf{A}^{\top} \mathbf{A}$:

$$\mathbf{A}^{\top} \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

其特征值由 $\det(\mathbf{A}^{\top} \mathbf{A} - \lambda \mathbf{I}) = (1 - \lambda)(2 - \lambda) - 1 = \lambda^2 - 3\lambda + 1 = 0$ 解出

$$\lambda = \frac{3 \pm \sqrt{5}}{2} \implies \lambda_1 = \frac{3 + \sqrt{5}}{2} \approx 2.618, \quad \lambda_2 = \frac{3 - \sqrt{5}}{2} \approx 0.382.$$

于是奇异值为

$$\sigma_1 = \sqrt{\lambda_1} \approx 1.618, \quad \sigma_2 = \sqrt{\lambda_2} \approx 0.618.$$

可作两处校验: 其一, $\sigma_1 \sigma_2 = \sqrt{\lambda_1 \lambda_2} = \sqrt{\det(\mathbf{A}^{\top} \mathbf{A})} = \sqrt{1} = 1$, 正是 $|\det \mathbf{A}| = 1$ (奇异值之积等于行列式绝对值); 其二, $\sigma_1^2 + \sigma_2^2 = \lambda_1 + \lambda_2 = \text{tr}(\mathbf{A}^{\top} \mathbf{A}) = 3$, 正是 $\mathbf{A}$ 各元素平方和——这就是下文要用到的“奇异值平方和 = Frobenius 范数平方”。

6.4 低秩近似: Eckart-Young 定理

秩一展开 $\mathbf{A} = \sum_{j \leq r} \sigma_j \mathbf{u}_j \mathbf{v}_j^{\top}$ 自然引出一个问题: 若只留前 k 项, 得到的秩 k 矩阵

$$\mathbf{A}_k = \sum_{j=1}^k \sigma_j \mathbf{u}_j \mathbf{v}_j^{\top}$$

是 $\mathbf{A}$ 多好的近似? Eckart-Young 定理说: 它是最好的。先约定两个矩阵“大小”的度量: 谱范数 $\|\mathbf{A}\|_2 = \sigma_1$ (最大奇异值, 即最大拉伸), Frobenius 范数 $\|\mathbf{A}\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\sum_j \sigma_j^2}$ 。

定理 6.2: Eckart-Young (最佳低秩近似)

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 的奇异值为 $\sigma_1 \geq \dots \geq \sigma_r > 0$, $\mathbf{A}_k = \sum_{j \leq k} \sigma_j \mathbf{u}_j \mathbf{v}_j^\top$ 为其前 k 项截断 ($k < r$)。则在一切秩不超过 k 的矩阵 $\mathbf{B}$ 中, $\mathbf{A}_k$ 使近似误差最小, 且

$$\min_{\text{rank } \mathbf{B} \leq k} \|\mathbf{A} - \mathbf{B}\|_2 = \|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1},$$

$$\min_{\text{rank } \mathbf{B} \leq k} \|\mathbf{A} - \mathbf{B}\|_F = \|\mathbf{A} - \mathbf{A}_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

证明的完整版需要一点变分论证, 这里只给最透亮的直觉: 误差 $\mathbf{A} - \mathbf{A}_k = \sum_{j > k} \sigma_j \mathbf{u}_j \mathbf{v}_j^\top$ 恰好是被丢掉的那些项, 它本身就是一个 SVD (剩余奇异值为 $\sigma_{k+1}, \dots, \sigma_r$), 故其谱范数是 σ_{k+1} 、Frobenius 范数是剩余奇异值的平方和开根。定理真正的内容是“没有任何别的秩 k 矩阵能做得更好”, 这一最优性来自奇异值的极值刻画。

它的用处: 降维与压缩的“无损率”有了标尺

把 $\|\mathbf{A}\|_F^2 = \sum_j \sigma_j^2$ 想成 $\mathbf{A}$ 的总“能量”。取前 k 个奇异值, 保留的能量比例就是

$$\frac{\sigma_1^2 + \dots + \sigma_k^2}{\sigma_1^2 + \dots + \sigma_r^2}.$$

当奇异值衰减很快 (数据高度相关) 时, 少数几个 k 就能吃下绝大部分能量——这正是降维与压缩之所以可能的数学原因, 也是怎么挑 k 的依据。

图 6.2 画出一个典型的奇异值谱及其累计能量: 前 3 个奇异值已捕获 97% 的能量, 意味着用秩 3 的 $\mathbf{A}_3$ 近似 $\mathbf{A}$, 丢掉的能量不到 3%。




图 6.2: 一个快速衰减的奇异值谱 (柱, 左轴) 及其累计能量比 (折线, 右轴)。前 3 个奇异值已吃下 97% 的能量, 故秩 3 截断 $\mathbf{A}_3$ 几乎无损。奇异值衰减越快, 降维空间越大。

6.5 Moore-Penrose 广义逆与最小范数最小二乘解

最小二乘（第三章）的正规方程是 $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$ 。当 $\mathbf{X}$ 列满秩时 $\mathbf{X}^T \mathbf{X}$ 可逆，解唯一： $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。但只要存在共线性（某列是其它列的线性组合）， $\mathbf{X}$ 就不再列满秩、 $\mathbf{X}^T \mathbf{X}$ 奇异，逆不存在——此时最小二乘解不唯一（有一整条解的仿射空间）。SVD 给出一个对一切矩阵都成立、且能在不唯一时挑出“最自然”那一个解的工具：Moore-Penrose 广义逆。

定义 6.3: Moore-Penrose 广义逆（伪逆）

设 $\mathbf{A} = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^T$ 的秩为 r 。其伪逆 $\mathbf{A}^+ \in \mathbb{R}^{n \times m}$ 定义为

$$\mathbf{A}^+ = \mathbf{V} \boldsymbol{\Sigma}^+ \mathbf{U}^T,$$

其中 $\boldsymbol{\Sigma}^+$ 由 $\boldsymbol{\Sigma}$ 转置后把每个非零奇异值取倒数、零仍为零得到：对角元为 $1/\sigma_1, \dots, 1/\sigma_r$ ，其余为零。

伪逆把可逆矩阵的逆推广到了任意矩阵：当 $\mathbf{A}$ 方且可逆时， σ_j 全非零， $\boldsymbol{\Sigma}^+ = \boldsymbol{\Sigma}^{-1}$ ，于是 $\mathbf{A}^+ = \mathbf{V} \boldsymbol{\Sigma}^{-1} \mathbf{U}^T = (\mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^T)^{-1} = \mathbf{A}^{-1}$ ，与普通逆重合。它真正的价值在于不可逆的情形：

定理 6.4: 伪逆给出最小范数最小二乘解

对任意 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 与 $\mathbf{b} \in \mathbb{R}^m$ ，向量

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$$

是最小二乘问题 $\min_{\mathbf{x}} \|\mathbf{A} \mathbf{x} - \mathbf{b}\|^2$ 的解；并且在所有最小二乘解中， $\hat{\mathbf{x}}$ 是范数最小的那一个。当 $\mathbf{A}$ 列满秩时它就是唯一的普通最小二乘解 $(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$ 。

证明。用 SVD 把目标函数在两套正交基里“拉直”。记 $\mathbf{c} = \mathbf{U}^T \mathbf{b}$ （坐标旋转，不改范数）， $\mathbf{z} = \mathbf{V}^T \mathbf{x}$ 。因正交变换保持范数，

$$\|\mathbf{A} \mathbf{x} - \mathbf{b}\|^2 = \|\mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^T \mathbf{x} - \mathbf{b}\|^2 = \|\boldsymbol{\Sigma} \mathbf{z} - \mathbf{c}\|^2 = \sum_{j=1}^r (\sigma_j z_j - c_j)^2 + \sum_{j>r} c_j^2.$$

最后一组 $\sum_{j>r} c_j^2$ 与 $\mathbf{z}$ 无关，是无法消去的残差（ $\mathbf{b}$ 落在 $\mathbf{A}$ 列空间之外的部分）。前 r 项每一项都能独立取零，当且仅当

$$z_j = \frac{c_j}{\sigma_j} \quad (j \leq r).$$

这唯一地定下了 $\mathbf{z}$ 的前 r 个分量；而 $z_{r+1}, \dots, z_n$ 不出现在目标里，可任取——这正是解不唯一的来源。要在这些解里取范数最小者，由 $\|\mathbf{x}\| = \|\mathbf{z}\|$ ，只需令多余分量 $z_j = 0$

($j > r$)。于是

$$z_j = \frac{c_j}{\sigma_j} \quad (j \leq r), \quad z_j = 0 \quad (j > r) \iff \mathbf{z} = \mathbf{\Sigma}^+ \mathbf{c},$$

回代 $\mathbf{x} = \mathbf{V}\mathbf{z} = \mathbf{V}\mathbf{\Sigma}^+ \mathbf{U}^T \mathbf{b} = \mathbf{A}^+ \mathbf{b}$ 。证毕。 $\square$

伪逆的双重含义

$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$ 同时做了两件事：在列空间方向上，它给出最小二乘拟合（让残差正交于列空间，与第三章的投影一致）；在零空间方向上，它把多余的自由度统统设为零，从而在所有等价拟合里选出范数最小的解。后一条在共线性下尤其要紧：普通最小二乘此时给不出唯一答案，伪逆用“最小范数”这一额外准则把答案钉死。

零奇异值“取倒数变零”这一步是全部关窍：可逆方向照常取倒数还原，不可逆方向 ($\sigma_j = 0$) 则直接抹掉、不去强行除以零。

例（共线设计下的最小范数解）。

设 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ （两列相同，秩 1）， $\mathbf{b} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$ 。求最小范数最小二乘解。

解。

$\mathbf{A}$ 秩为 1，奇异值只有一个： $\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$ ，特征值 $\lambda_1 = 4, \lambda_2 = 0$ ，故 $\sigma_1 = 2$ 。对应右、左奇异向量 $\mathbf{v}_1 = \mathbf{u}_1 = \frac{1}{\sqrt{2}}(1, 1)^T$ 。于是

$$\mathbf{A}^+ = \frac{1}{\sigma_1} \mathbf{v}_1 \mathbf{u}_1^T = \frac{1}{2} \cdot \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} = \frac{1}{4} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1/2 \\ 1/2 \end{bmatrix}.$$

所有最小二乘解满足 $x_1 + x_2 = 1$ （拟合值 $\mathbf{A}\mathbf{x} = (x_1 + x_2)(1, 1)^T$ 要尽量逼近 $\mathbf{b}$ ，最优为 $x_1 + x_2 = 1$ ，残差 $\|(1, -1)^T\| = \sqrt{2}$ ）。在这条直线上，离原点最近的点正是 $(1/2, 1/2)$ ——伪逆自动选中了它，而非诸如 $(1, 0)$ 或 $(0, 1)$ 这种范数更大的解。

6.6 条件数与多重共线性诊断

伪逆的证明里那个关键步骤 $z_j = c_j/\sigma_j$ 暴露了一个隐患：如果某个 σ_j 很小（接近零但不为零），那么 $\mathbf{b}$ 在该方向上的微小扰动 Δc_j 会被放大 $1/\sigma_j$ 倍，导致解 $\hat{\mathbf{x}}$ 剧烈变动。这就是病态（ill-conditioning）。刻画这种敏感程度的标准量是条件数。

定义 6.5: 条件数

满秩矩阵 $\mathbf{A}$ 的（谱）条件数定义为最大奇异值与最小奇异值之比

$$\kappa(\mathbf{A}) = \frac{\sigma_{\max}}{\sigma_{\min}} \geq 1.$$

κ 越大，矩阵越接近奇异，求解 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 对数据扰动越敏感。 $\kappa = 1$ 对应正交矩阵（所有奇异值相等，最稳）。

条件数的意义可以一句话说清：它是“输出相对误差”对“输入相对误差”的最大放大倍数。沿最大奇异值方向 $\mathbf{A}$ 拉伸 $\sigma_{\max}$ 倍，沿最小奇异值方向只拉伸 $\sigma_{\min}$ 倍；解一个方程相当于反着做，于是最小奇异值方向上的扰动被放大 $1/\sigma_{\min}$ 、再相对于 $\sigma_{\max}$ 这把尺子衡量，放大因子就是 κ 。

为什么计量经济学家盯着条件数

在最小二乘里，相关的矩阵是设计矩阵 $\mathbf{X}$ （或正规化后的 $\mathbf{X}^T\mathbf{X}$ ，其条件数是 $\mathbf{X}$ 的平方）。多重共线性的本质就是 $\mathbf{X}$ 的列近乎线性相关，于是 $\mathbf{X}$ 把某个方向几乎压扁——对应一个接近零的奇异值， $\kappa(\mathbf{X})$ 暴涨。后果是 $\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$ 在该方向上方差极大、符号飘忽、对样本的微小变动极不稳定。条件数（或其平方 $\kappa(\mathbf{X}^T\mathbf{X})$ ）因此是共线性最直接的诊断量——比逐对相关系数更可靠，因为它能抓住三个及以上变量联合的近线性相关。

图 6.3 把这件事画了出来：当两个回归元近正交时， $\hat{\beta}$ 的方差椭圆近乎圆形（ $\kappa \approx 1$ ，各方向同样稳）；当两个回归元夹角很小、近乎共线时，方差椭圆沿某个方向被极度拉长（ κ 很大），意味着估计量在该方向上几乎不可辨识。




图 6.3: 条件数与共线性（系数空间示意，回归元 x_j 仅标方向）。红色椭圆示意最小二乘估计量 $\hat{\beta}$ 的方差形态（正比于 $(\mathbf{X}^T\mathbf{X})^{-1}$ ）。(a) 回归元近正交时椭圆近圆，各方向都稳；(b) 回归元近共线时椭圆沿某方向被极度拉长，对应一个接近零的奇异值、 κ 暴涨，该方向上的系数几乎不可辨识。

6.7 去处：PCA、共线性、弱工具与压缩

本章这把分解的下游应用极广，这里点出几个经济学博士最常撞见的落点。

主成分分析 (PCA)。 给定中心化的数据矩阵 $\mathbf{X} \in \mathbb{R}^{n \times k}$ （每列已减去均值），样本协方差矩阵正比于 $\mathbf{X}^T \mathbf{X}$ 。PCA 要找的“主成分”是数据方差最大的那些正交方向——而这恰好是 $\mathbf{X}^T \mathbf{X}$ 的特征向量，也就是 $\mathbf{X}$ 的右奇异向量 $\mathbf{v}_j$ ；第 j 个主成分解释的方差正比于 σ_j^2 。于是：

PCA 就是对数据矩阵做 SVD

主成分方向 = $\mathbf{X}$ 的右奇异向量 $\mathbf{v}_j = \mathbf{X}^T \mathbf{X}$ 的特征向量；该主成分上的得分 = $\mathbf{X} \mathbf{v}_j = \sigma_j \mathbf{u}_j$ ；它解释的方差比例 = $\sigma_j^2 / \sum_l \sigma_l^2$ 。取前几个最大奇异值对应的主成分，就是用 Eckart-Young 意义下最优的低维子空间概括数据——降维与可视化、构造少数“综合指标”（如把多个宏观序列压成一个景气指数）皆源于此。

多重共线性诊断。 如上节所述，条件数 $\kappa(\mathbf{X})$ （或方差膨胀的来源——接近零的奇异值）是共线性最干净的度量。出现极大 κ 时，常见对策正是用 PCA 把高度相关的回归元压成少数正交主成分再回归（主成分回归），或转向带正则的岭回归——后者可证等价于把伪逆里每个滤波因子 $1/\sigma_j$ 替换为 $\sigma_j/(\sigma_j^2 + \lambda)$ （当 $\lambda \rightarrow 0$ 时回到 $1/\sigma_j$ ，即第 6.5 节里 $z_j = c_j/\sigma_j$ 那个倒数），从而压低小奇异值方向的方差放大。

弱工具变量。 在工具变量估计里，第一阶段是把内生回归元对工具投影。若工具与内生变量的相关性很弱，第一阶段设计矩阵就接近降秩——又是一个“最小奇异值接近零”的病态问题。弱工具之所以让 IV/2SLS 估计量方差爆炸、并产生有限样本偏误，根本上和共线性是同一回事：相关矩阵的条件数过大。识别强度的诸多检验（如基于第一阶段的统计量）背后量的就是这种奇异性。

数据压缩与去噪。 秩一展开 $\mathbf{A} = \sum_j \sigma_j \mathbf{u}_j \mathbf{v}_j^T$ 让压缩变得显然：存一个 $m \times n$ 矩阵要 mn 个数，而存前 k 项只需 $k(m+n+1)$ 个数；当 $k \ll \min(m, n)$ 时省下大量存储。更进一步，若数据 = 低秩信号 + 小噪声，丢掉小奇异值往往同时去掉了噪声——这正是图像压缩、推荐系统的低秩补全、以及计量里因子模型（用少数共同因子解释大量序列）的共同数学内核。

一把分解，多门核心课

SVD 把谱定理从对称方阵推广到一切矩阵，于是同一套“奇异值 + 左右奇异向量”反复出现在彼此看似无关的问题里：在数据分析里它是 PCA 与降维，在计量里它是共线性与弱工具的诊断、是岭回归的几何，在数值上它是求解病态线性系统、是计算伪逆与秩的最稳手段。认清了奇异值就是“各正交主方向上的拉伸强度”、接近零的奇异值就是“病态的源头”，上面这些门就一并打开了。

第七章 矩阵微积分：向量与矩阵求导

用到的前置工具：偏导数、梯度与 Jacobian、Hessian（第十三章）；矩阵乘法、转置、迹、行列式与求逆（第二章）；二次型与正定性（第五章）。

到本书这一处为止，“对一个变量求导”你早已驾轻就熟。可经济学里要求导的对象，几乎从来不是一个标量：OLS 要让残差平方和 $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$ 对整个系数向量 $\boldsymbol{\beta}$ 取极小；极大似然要让对数似然 $\ell(\boldsymbol{\theta})$ 对参数向量 $\boldsymbol{\theta}$ 取极大；GMM 要让一个二次型对参数求一阶条件。把这些一阶条件一项一项地拆成对 $\beta_1, \beta_2, \dots$ 的偏导再拼回去，既冗长又容易出错。本章要做的，是把“对向量、对矩阵求导”变成一套和标量求导一样机械、可背、可查的规则——给定常用的几条恒等式，几乎所有估计量的推导都能在半页纸内一气呵成。

我们先把记号约定钉死（向量求导最大的混乱来源就是布局约定不统一），再逐条把核心恒等式用逐元素展开推一遍，让你不必死记、随时能自己重建。最后用 OLS 与正态 MLE 两个范例演示这套规则如何直接吐出估计量，并指明它通向计量经济学渐近理论的去处。

7.1 布局约定：先把记号钉死

标量对标量求导只有一个 $\frac{dy}{dx}$ ，没有歧义。可一旦分子分母里出现向量，“导数排成行还是排成列”就有了两种相反的摆法，文献里都在用，混用必出错。先讲清楚，后面才不会乱。

定义 7.1: 标量对向量的导数（梯度）

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $\mathbf{x} = (x_1, \dots, x_n)^\top$ 。把各个偏导排成一个列向量，称为 f 的梯度：

$$\nabla f = \frac{\partial f}{\partial \mathbf{x}} = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix} \in \mathbb{R}^n.$$

把梯度取成列向量（与自变量 $\mathbf{x}$ 同形），是本书自始至终采用的**分母布局**（denominator layout）约定。这样做有两个好处：其一，一阶条件 $\nabla f = \mathbf{0}$ 是 n 个方程组成的列向量，和 $\mathbf{x}$ 摆放一致，更新公式 $\mathbf{x} \leftarrow \mathbf{x} - \nabla f$ 类的式子形状自治；其二，与 Hessian、Jacobian 等高阶对象拼接时维数能直接对上。

定义 7.2: 向量对向量的导数 (Jacobian)

设映射 $\mathbf{g}: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $\mathbf{g}(\mathbf{x}) = (g_1(\mathbf{x}), \dots, g_m(\mathbf{x}))^\top$ 。把所有一阶偏导排成 $m \times n$ 矩阵, 称为 $\mathbf{g}$ 的 **Jacobian**:

$$\mathbf{D}_{\mathbf{x}} \mathbf{g} = \begin{bmatrix} \partial g_1 / \partial x_1 & \cdots & \partial g_1 / \partial x_n \\ \vdots & & \vdots \\ \partial g_m / \partial x_1 & \cdots & \partial g_m / \partial x_n \end{bmatrix} \in \mathbb{R}^{m \times n}, \quad [\mathbf{D}_{\mathbf{x}} \mathbf{g}]_{ij} = \frac{\partial g_i}{\partial x_j}.$$

Jacobian 的第 i 行是分量函数 g_i 的梯度的转置。这里采用的是**分子布局**（行随分子 g_i 走、列随分母 x_j 走）——这是 Jacobian 的通用写法, 与上面梯度的分母布局并不矛盾: 梯度若视为 $m = 1$ 的特例, 按 Jacobian 写法本应是一个行向量 $(\nabla f)^\top$, 而我们约定标量函数的“梯度”专指其列向量形式。

两条记号铁律, 本章 (及全书) 始终遵守

- (1) **梯度是列向量** (标量对向量, 分母布局): $\nabla f = \frac{\partial f}{\partial \mathbf{x}} \in \mathbb{R}^n$, 与 $\mathbf{x}$ 同形。
- (2) **Jacobian 是 $m \times n$ 矩阵** (向量对向量, 分子布局): $[\mathbf{D}_{\mathbf{x}} \mathbf{g}]_{ij} = \partial g_i / \partial x_j$, 行随分子、列随分母。

判断维数的口诀: 写完一个求导表达式, 先数“它该有几行几列”, 对不上就说明哪里转置错了。下面所有恒等式都已按这套约定校准, 可放心套用。

注 (为什么布局之争值得一提)。

同一个恒等式 $\partial(\mathbf{a}^\top \mathbf{x}) / \partial \mathbf{x}$, 分母布局给 $\mathbf{a}$ (列向量), 分子布局给 $\mathbf{a}^\top$ (行向量) ——差一个转置。两套都自洽, 混用才出错。许多教材的“矛盾”其实只是布局不同。本书统一用上面那套 (梯度列、Jacobian $m \times n$), 读外部文献时只需先认出对方用的是哪套, 再决定要不要补转置。

7.2 标量对向量: 四条核心恒等式

经济学里反复出现的标量函数, 无非线性型 $\mathbf{a}^\top \mathbf{x}$ 与二次型 $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ 两类。把这两类的梯度推清楚, OLS、GLS、岭回归的一阶条件就都到手了。推导的统一手法是**逐元素展开**、对单个 x_k 求偏导、再拼回向量——这是本章最值得掌握的“重建”能力。

线性型的梯度**定理 7.3: 线性型求导**

设 $\mathbf{a} \in \mathbb{R}^n$ 为常向量, $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} = \sum_{i=1}^n a_i x_i$ 。则

$$\frac{\partial(\mathbf{a}^\top \mathbf{x})}{\partial \mathbf{x}} = \mathbf{a}.$$

证明. 对第 k 个分量求偏导: $\frac{\partial}{\partial x_k} \sum_{i=1}^n a_i x_i = a_k$, 因为只有 $i = k$ 的那一项含 x_k 。把 $\{a_k\}_{k=1}^n$ 按梯度的列向量约定拼回, 正是 $\mathbf{a}$ 。同理 $\partial(\mathbf{x}^\top \mathbf{a})/\partial \mathbf{x} = \mathbf{a}$ ($\mathbf{x}^\top \mathbf{a}$ 与 $\mathbf{a}^\top \mathbf{x}$ 是同一个标量)。 $\square$

这是最简单也最常用的一条: 它是线性求导法则在向量上的直接推广, 对应标量世界里的 $(ax)' = a$ 。

二次型的梯度

定理 7.4: 二次型求导

设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 为常矩阵, $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ 。则

$$\frac{\partial(\mathbf{x}^\top \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}.$$

特别地, 当 $\mathbf{A}$ 对称 ($\mathbf{A} = \mathbf{A}^\top$) 时,

$$\frac{\partial(\mathbf{x}^\top \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x}.$$

证明. 把二次型写成双重求和: $f = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j$ 。对 x_k 求偏导, 凡含 x_k 的项都要贡献: 当 $i = k$ (且 $j \neq k$) 时项为 $A_{kj} x_k x_j$, 导数 $A_{kj} x_j$; 当 $j = k$ (且 $i \neq k$) 时项为 $A_{ik} x_i x_k$, 导数 $A_{ik} x_i$; 当 $i = j = k$ 时项为 $A_{kk} x_k^2$, 导数 $2A_{kk} x_k$ 。合并 (注意对角项恰好把上面两类各算了一遍、二者相加正好是 $2A_{kk} x_k$) 得

$$\frac{\partial f}{\partial x_k} = \sum_{j=1}^n A_{kj} x_j + \sum_{i=1}^n A_{ik} x_i = [\mathbf{A} \mathbf{x}]_k + [\mathbf{A}^\top \mathbf{x}]_k.$$

第一个和是 $\mathbf{A}$ 第 k 行点乘 $\mathbf{x}$, 即 $(\mathbf{A} \mathbf{x})_k$; 第二个和是 $\mathbf{A}$ 第 k 列点乘 $\mathbf{x}$, 即 $(\mathbf{A}^\top \mathbf{x})_k$ 。拼回列向量即 $(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$ 。 $\mathbf{A}$ 对称时两项相等, 合为 $2\mathbf{A} \mathbf{x}$ 。 $\square$

注 (对称化: 为什么实际中几乎总是 $2\mathbf{A} \mathbf{x}$)。

任何二次型 $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ 都等于它的对称化版本 $\mathbf{x}^\top \mathbf{A}_s \mathbf{x}$, 其中 $\mathbf{A}_s = \frac{1}{2}(\mathbf{A} + \mathbf{A}^\top)$ ——因为反对称部分对二次型零贡献 ($\mathbf{x}^\top \mathbf{B} \mathbf{x} = 0$ 当 $\mathbf{B}^\top = -\mathbf{B}$)。于是不妨一开始就把 $\mathbf{A}$ 取成对称的, 公式就是干净的 $2\mathbf{A} \mathbf{x}$ 。经济学里的二次型 (残差平方和的 $\mathbf{X}^\top \mathbf{X}$ 、协方差矩阵、Hessian) 本来就对称, 所以你日常见到的几乎永远是 $2\mathbf{A} \mathbf{x}$ 这一形。

把它接到 Jacobian 上：线性映射的导数

定理 7.5: 线性映射求导

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 为常矩阵, $\mathbf{g}(\mathbf{x}) = \mathbf{Ax} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 。则其 Jacobian

$$\mathbf{D}_{\mathbf{x}}(\mathbf{Ax}) = \mathbf{A}.$$

证明. 第 i 个分量 $g_i = \sum_{j=1}^n A_{ij}x_j$, 故 $\partial g_i / \partial x_k = A_{ik}$ 。按 Jacobian 约定 $[\mathbf{D}_{\mathbf{x}} \mathbf{g}]_{ik} = \partial g_i / \partial x_k = A_{ik}$, 正是 $\mathbf{A}$ 本身。□

这三条放在一起, 构成了向量求导的“乘法表”(表 7.1)。把它们和标量世界对照, 记忆几乎是免费的:

标量世界	向量世界	结果形状
$(ax)' = a$	$\partial(\mathbf{a}^\top \mathbf{x}) / \partial \mathbf{x} = \mathbf{a}$	列向量 $\in \mathbb{R}^n$
$(ax^2)' = 2ax$	$\partial(\mathbf{x}^\top \mathbf{Ax}) / \partial \mathbf{x} = (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}$	列向量 $\in \mathbb{R}^n$
$(ax)' = a$	$\mathbf{D}_{\mathbf{x}}(\mathbf{Ax}) = \mathbf{A}$	矩阵 $\in \mathbb{R}^{m \times n}$

表 7.1: 向量求导的三条核心恒等式, 与一元微积分一一对应。

7.3 链式法则与梯度的几何

恒等式之间靠链式法则串起来。它在向量情形就是 Jacobian 的矩阵乘法, 维数自动对齐——这正是采用统一布局的红利。

定理 7.6: 链式法则 (向量形式)

设 $\mathbf{x} \xrightarrow{\mathbf{g}} \mathbf{u} \in \mathbb{R}^m \xrightarrow{\mathbf{h}} \mathbf{z} \in \mathbb{R}^p$, 复合映射 $\mathbf{z} = \mathbf{h}(\mathbf{g}(\mathbf{x}))$ 。则

$$\mathbf{D}_{\mathbf{x}} \mathbf{z} = [\mathbf{D}_{\mathbf{u}} \mathbf{h}] [\mathbf{D}_{\mathbf{x}} \mathbf{g}] \quad (p \times m \text{ 乘 } m \times n = p \times n).$$

若最外层是标量 $\phi : \mathbb{R}^m \rightarrow \mathbb{R}$, $\phi(\mathbf{u})$ 且 $\mathbf{u} = \mathbf{g}(\mathbf{x})$, 则按梯度 (列向量) 约定

$$\nabla_{\mathbf{x}} \phi = [\mathbf{D}_{\mathbf{x}} \mathbf{g}]^\top \nabla_{\mathbf{u}} \phi.$$

证明. 分量上就是普通链式法则 $\partial z_i / \partial x_j = \sum_k (\partial z_i / \partial u_k) (\partial u_k / \partial x_j)$, 右端恰是矩阵乘积 $[\mathbf{D}_{\mathbf{u}} \mathbf{h} \cdot \mathbf{D}_{\mathbf{x}} \mathbf{g}]_{ij}$ 。标量情形: $\partial \phi / \partial x_j = \sum_k (\partial \phi / \partial u_k) (\partial u_k / \partial x_j)$ 。右端是 $\mathbf{g}$ 的 Jacobian 第 j 列与 $\nabla_{\mathbf{u}} \phi$ 的内积, 即 $[(\mathbf{D}_{\mathbf{x}} \mathbf{g})^\top \nabla_{\mathbf{u}} \phi]_j$; 之所以要转置, 正是为了把分子布局的 Jacobian 转回与列向量梯度相容的形状——再次印证那条“数行数列”的口诀。□

例 (用链式法则推二次型梯度)。

设 $f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2 = (\mathbf{Ax} - \mathbf{b})^\top (\mathbf{Ax} - \mathbf{b})$, 求 $\nabla_{\mathbf{x}} f$ 。

解.

令 $\mathbf{u} = \mathbf{Ax} - \mathbf{b}$, 则 $f = \mathbf{u}^\top \mathbf{u} = \phi(\mathbf{u})$, $\nabla_{\mathbf{u}} \phi = 2\mathbf{u}$ (二次型 $\mathbf{A} = \mathbf{I}$ 的情形)。又 $\mathbf{D}_{\mathbf{x}} \mathbf{u} = \mathbf{A}$ 。代入链式法则:

$$\nabla_{\mathbf{x}} f = [\mathbf{D}_{\mathbf{x}} \mathbf{u}]^\top \nabla_{\mathbf{u}} \phi = \mathbf{A}^\top (2\mathbf{u}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).$$

这正是下一节 OLS 一阶条件的雏形 (取 $\mathbf{A} = \mathbf{X}$ 、 $\mathbf{b} = \mathbf{y}$)。

梯度的几何。 梯度不只是“偏导拼成的列”，它有清晰的几何意义——指向最速上升方向，这也是它在最优化里居核心地位的原因。在一点 $\mathbf{x}_0$ 处，函数沿单位方向 $\mathbf{v}$ ($\|\mathbf{v}\| = 1$) 的方向导数是 $\nabla f(\mathbf{x}_0)^\top \mathbf{v}$ 。由 Cauchy-Schwarz 不等式，

$$\nabla f(\mathbf{x}_0)^\top \mathbf{v} \leq \|\nabla f(\mathbf{x}_0)\| \|\mathbf{v}\| = \|\nabla f(\mathbf{x}_0)\|,$$

等号当且仅当 $\mathbf{v}$ 与 $\nabla f(\mathbf{x}_0)$ 同向。梯度方向是函数增长最快的方向，其长度是这个最大增长率；负梯度方向则是下降最快的方向（梯度下降法的依据）。同时，梯度垂直于过该点的等高线 $\{\mathbf{x} : f(\mathbf{x}) = f(\mathbf{x}_0)\}$ ：沿等高线移动 f 不变，方向导数为零，故等高线的切向与梯度正交（图 7.1）。




图 7.1: 梯度 ∇f 垂直于等高线、指向函数增长最快的方向；其长度等于最大方向导数。等高线由内向外 f 递增，故梯度指向外侧。

7.4 应用一：OLS 的一阶条件

现在收割。最小二乘要解

$$\min_{\beta \in \mathbb{R}^k} S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2 = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta),$$

其中 $\mathbf{y} \in \mathbb{R}^n$ 、 $\mathbf{X} \in \mathbb{R}^{n \times k}$ 列满秩。先把目标函数展开成“线性型 + 二次型”的标准形：

$$S(\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\mathbf{y}^\top \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}^\top (\mathbf{X}^\top \mathbf{X})\boldsymbol{\beta}.$$

(中间项用了 $\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{X}\boldsymbol{\beta}$ ，二者是同一个标量、互为转置。) 三项逐一对 $\boldsymbol{\beta}$ 求梯度，正好各用上一条恒等式：常数项 $\mathbf{y}^\top \mathbf{y}$ 梯度为 $\mathbf{0}$ ；线性项 $-2\mathbf{y}^\top \mathbf{X}\boldsymbol{\beta} = -2(\mathbf{X}^\top \mathbf{y})^\top \boldsymbol{\beta}$ 梯度为 $-2\mathbf{X}^\top \mathbf{y}$ （线性型法则）；二次型项的核 $\mathbf{X}^\top \mathbf{X}$ 对称，梯度为 $2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}$ （二次型法则）。合并得

$$\nabla_{\boldsymbol{\beta}} S = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

令其为零，立得正规方程与 OLS 估计量：

$$\mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y} \implies \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

两条路殊途同归

“投影”一章是从几何（残差垂直于列空间）得到正规方程的；这里是纯靠求向量梯度、令一阶条件为零得到同一个方程。一阶条件 $\nabla_{\boldsymbol{\beta}} S = \mathbf{0}$ 与正交条件 $\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$ 是同一行字——这正是“最近”与“正交”等价的代数面孔。本章提供的是后续一切估计量都通用的机械手法：写出目标、套恒等式求梯度、令零、解出。

二阶条件也现成：Hessian $\nabla_{\boldsymbol{\beta}}^2 S = 2\mathbf{X}^\top \mathbf{X}$ 。列满秩时 $\mathbf{X}^\top \mathbf{X}$ 正定（第五章），故 S 严格凸，一阶条件的解是唯一的全局极小。

7.5 标量对矩阵与迹技巧

到这里求导对象都是向量。但 MLE 要对协方差矩阵求导、面板与系统方程要对系数矩阵求导，于是需要“标量对矩阵”的导数。约定与梯度平行：把对每个矩阵元素的偏导排回同形的矩阵。

定义 7.7：标量对矩阵的导数

设 $f: \mathbb{R}^{n \times m} \rightarrow \mathbb{R}$ 是矩阵 $\mathbf{X} = (X_{ij})$ 的标量函数。其导数定义为与 $\mathbf{X}$ 同形的矩阵，第 (i, j) 元为对 X_{ij} 的偏导：

$$\left[\frac{\partial f}{\partial \mathbf{X}} \right]_{ij} = \frac{\partial f}{\partial X_{ij}}.$$

处理矩阵的标量函数，最顺手的桥梁是迹：任何“矩阵进、标量出”的线性组合都能写成迹，而迹有一身好用的代数性质（线性、轮换不变 $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 、 $\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$ ）。下面两条是“迹技巧”的核心。

定理 7.8: 迹对矩阵求导

设 $\mathbf{A}$ 为与 $\mathbf{X}$ 维数相容的常矩阵。则

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{A}\mathbf{X}) = \mathbf{A}^\top, \quad \frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^\top \mathbf{A}) = \mathbf{A}, \quad \frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{X}.$$

证明. 第一条: $\text{tr}(\mathbf{A}\mathbf{X}) = \sum_i (\mathbf{A}\mathbf{X})_{ii} = \sum_i \sum_k A_{ik} X_{ki} = \sum_{i,k} A_{ik} X_{ki}$. 对 X_{pq} 求偏导, 只有 $(k, i) = (p, q)$ 那一项存活, 得 A_{qp} . 故 $[\partial \text{tr}(\mathbf{A}\mathbf{X}) / \partial \mathbf{X}]_{pq} = A_{qp} = (\mathbf{A}^\top)_{pq}$, 即 $\mathbf{A}^\top$. 第二条同理 (或由 $\text{tr}(\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$ 配第一条, 得 $(\mathbf{A}^\top)^\top = \mathbf{A}$). 第三条把 $\text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}) = \sum_{i,j,k} X_{ki} A_{kj} X_{ji}$ 逐元素展开、对 X_{pq} 求偏导 (含 X_{pq} 的项出现两处, 分别凑出 $\mathbf{A}$ 与 $\mathbf{A}^\top$), 与向量二次型完全平行, 得 $(\mathbf{A} + \mathbf{A}^\top) \mathbf{X}$; $\mathbf{A}$ 对称时为 $2\mathbf{A}\mathbf{X}$. $\square$

注 (一切“矩阵进标量出”都先化成迹) .

诀窍是: 标量等于自己的迹 ($c = \text{tr} c$), 于是任何这类表达式都能套上 tr , 再用轮换性 $\text{tr}(\mathbf{A}\mathbf{B}) = \text{tr}(\mathbf{B}\mathbf{A})$ 把要求导的 $\mathbf{X}$ 挪到方便的位置, 最后套上面三条. 例如 $\mathbf{a}^\top \mathbf{X} \mathbf{b} = \text{tr}(\mathbf{a}^\top \mathbf{X} \mathbf{b}) = \text{tr}(\mathbf{X} \mathbf{b} \mathbf{a}^\top)$, 于是 $\partial(\mathbf{a}^\top \mathbf{X} \mathbf{b}) / \partial \mathbf{X} = (\mathbf{b} \mathbf{a}^\top)^\top = \mathbf{a} \mathbf{b}^\top$. 这一手在 MLE 推导里几乎逢矩阵必用。

行列式与逆的导数

正态似然里会出现 $\ln |\det \mathbf{X}|$ (来自高斯密度的归一化常数), GLS 与信息矩阵会用到 $\mathbf{X}^{-1}$ 怎么随 $\mathbf{X}$ 变。两条结论:

定理 7.9: 对数行列式与逆的导数

设 $\mathbf{X}$ 可逆。则

$$\frac{\partial}{\partial \mathbf{X}} \ln |\det \mathbf{X}| = (\mathbf{X}^{-1})^\top, \quad d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} (d\mathbf{X}) \mathbf{X}^{-1}.$$

$\mathbf{X}$ 对称正定时第一条即 $\mathbf{X}^{-1}$ 。

证明. 对数行列式。用余子式 (Laplace) 展开 $\det \mathbf{X} = \sum_j X_{ij} C_{ij}$ (沿第 i 行, C_{ij} 为代数余子式, 与 X_{ij} 无关), 故 $\partial \det \mathbf{X} / \partial X_{ij} = C_{ij}$. 而逆矩阵的元素公式 $(\mathbf{X}^{-1})_{ji} = C_{ij} / \det \mathbf{X}$ (伴随矩阵除以行列式) 给出 $C_{ij} = \det \mathbf{X} \cdot (\mathbf{X}^{-1})_{ji}$. 于是

$$\frac{\partial \ln |\det \mathbf{X}|}{\partial X_{ij}} = \frac{1}{\det \mathbf{X}} \frac{\partial \det \mathbf{X}}{\partial X_{ij}} = \frac{C_{ij}}{\det \mathbf{X}} = (\mathbf{X}^{-1})_{ji} = [(\mathbf{X}^{-1})^\top]_{ij},$$

拼回矩阵即 $(\mathbf{X}^{-1})^\top$ 。

逆的微分。对恒等式 $\mathbf{X} \mathbf{X}^{-1} = \mathbf{I}$ 两边取全微分 (乘积法则): $(d\mathbf{X}) \mathbf{X}^{-1} + \mathbf{X} d(\mathbf{X}^{-1}) = \mathbf{0}$. 左乘 $\mathbf{X}^{-1}$ 解出 $d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} (d\mathbf{X}) \mathbf{X}^{-1}$. 这是标量公式 $d(1/x) = -x^{-2} dx$ 的矩阵版——注意矩阵不交换, 两个 $\mathbf{X}^{-1}$ 必须分别夹在 $d\mathbf{X}$ 两侧. $\square$

7.6 应用二：正态线性模型的 MLE 与信息矩阵

把上面所有工具合到一处，推一遍古典正态线性模型的极大似然——它既复用了向量求导（对 β ）又复用了矩阵/标量求导（对 σ^2 ），是检验本章规则的标准考场。模型 $\mathbf{y} = \mathbf{X}\beta + \varepsilon$, $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ 。对数似然为

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta).$$

对 β 求导。只有最后一项含 β ，且它就是 $-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|^2$ ，梯度已在 OLS 一节算过：

$$\nabla_{\beta} \ell = -\frac{1}{2\sigma^2} \cdot [-2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta)] = \frac{1}{\sigma^2} \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta).$$

令其为零， σ^2 这个正标量约掉，得到的正是正规方程——正态误差下的 MLE 与 OLS 给出同一个 $\hat{\beta}$ ：

$$\hat{\beta}_{\text{MLE}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

对 σ^2 求导。记 $\tau = \sigma^2$ ，含 τ 的两项对 τ 求偏导：

$$\frac{\partial \ell}{\partial \tau} = -\frac{n}{2\tau} + \frac{1}{2\tau^2} \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

令其为零并代入 $\hat{\beta}$ ：

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \left\| \mathbf{y} - \mathbf{X}\hat{\beta} \right\|^2 = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2.$$

注意分母是 n 而非 $n-k$ ：MLE 的方差估计有限样本下有偏（低估），这正是计量里用 $s^2 = \text{RSS}/(n-k)$ 做无偏修正的由来（见“投影”一章里 $\text{tr } \mathbf{M} = n-k$ 的自由度论证）。

信息矩阵。渐近推断要的是 Fisher 信息矩阵——对数似然的负 Hessian 的期望，它的逆给出 MLE 的渐近方差。把参数堆成 $\theta = (\beta^\top, \sigma^2)^\top$ ，逐块求二阶导。对 β 块：

$$\nabla_{\beta\beta}^2 \ell = \frac{\partial}{\partial \beta^\top} \left[\frac{1}{\sigma^2} \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) \right] = -\frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X}.$$

对 σ^2 块（用上面的 $\partial \ell / \partial \tau$ 再对 τ 求一次导）： $\partial^2 \ell / \partial \tau^2 = \frac{n}{2\tau^2} - \frac{1}{\tau^3} \|\mathbf{y} - \mathbf{X}\beta\|^2$ ，取期望（用 $\mathbb{E}(\|\mathbf{y} - \mathbf{X}\beta\|^2) = n\sigma^2$ ）得 $-\frac{n}{2\sigma^4}$ 。交叉块 $\partial^2 \ell / \partial \beta \partial \tau = -\frac{1}{\tau^2} \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta)$ 的期望为 $\mathbf{0}$ （因 $\mathbb{E}(\mathbf{y} - \mathbf{X}\beta) = \mathbf{0}$ ）。于是信息矩阵 $\mathcal{I} = -\mathbb{E}(\nabla^2 \ell)$ 是块对角的：

$$\mathcal{I}(\beta, \sigma^2) = \begin{bmatrix} \frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X} & \mathbf{0} \\ \mathbf{0}^\top & \frac{n}{2\sigma^4} \end{bmatrix}.$$

块对角意味着 $\hat{\beta}$ 与 $\hat{\sigma}^2$ 渐近独立；左上块的逆 $\sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 正是 $\hat{\beta}$ 那条经典的渐近协方差矩阵。整段推导自始至终只调用了本章的几条恒等式，没有额外的特设步骤。

本章这套规则的真正去处

所有极值估计量——MLE、GMM、M-估计——都由一个样本一阶条件 $\frac{1}{n} \sum_i \nabla_{\theta} m(z_i, \hat{\theta}) = \mathbf{0}$ 隐含定义。要导出 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V})$ ，关键一步是对这个一阶条件做 Taylor 展开，而展开里出现的 Jacobian、Hessian、信息矩阵，全都是本章“对向量/矩阵求导”的产物。Delta 法要算变换 $g(\hat{\theta})$ 的雅可比 $D_{\theta} g$ ；三明治协方差矩阵 $\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-\top}$ 里的 $\mathbf{A}$ 是矩 Jacobian。换言之，本章是后面整个渐近统计部分（中心极限定理之后）反复调用的“求导引擎”。

7.7 小结：一张可随身携带的规则表

本章把“对向量、对矩阵求导”压缩成几条可背、可查、可自证的规则。最后汇总成一张表，遇到推导时按图索骥即可（皆采用本书约定：梯度为列向量、Jacobian 为 $m \times n$ 、标量对矩阵导数与矩阵同形）。

表达式	导数	备注
$\mathbf{a}^{\top} \mathbf{x}$	$\partial / \partial \mathbf{x} = \mathbf{a}$	线性型
$\mathbf{x}^{\top} \mathbf{A} \mathbf{x}$	$\partial / \partial \mathbf{x} = (\mathbf{A} + \mathbf{A}^{\top}) \mathbf{x}$	对称时 $2\mathbf{A} \mathbf{x}$
$\mathbf{A} \mathbf{x}$	$D_{\mathbf{x}} = \mathbf{A}$	线性映射，Jacobian
$\ \mathbf{y} - \mathbf{X} \beta\ ^2$	$\partial / \partial \beta = -2\mathbf{X}^{\top}(\mathbf{y} - \mathbf{X} \beta)$	OLS 一阶条件
$\text{tr}(\mathbf{A} \mathbf{X})$	$\partial / \partial \mathbf{X} = \mathbf{A}^{\top}$	迹技巧
$\text{tr}(\mathbf{X}^{\top} \mathbf{A} \mathbf{X})$	$\partial / \partial \mathbf{X} = (\mathbf{A} + \mathbf{A}^{\top}) \mathbf{X}$	对称时 $2\mathbf{A} \mathbf{X}$
$\ln \det \mathbf{X} $	$\partial / \partial \mathbf{X} = (\mathbf{X}^{-1})^{\top}$	对称正定时 $\mathbf{X}^{-1}$
$\mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$	微分形式
复合 $\mathbf{h} \circ \mathbf{g}$	$D_{\mathbf{x}} = (D_{\mathbf{u}} \mathbf{h})(D_{\mathbf{x}} \mathbf{g})$	链式法则 = 矩阵乘

表 7.2: 向量与矩阵求导核心恒等式速查表。每一条都能用“逐元素展开”在草稿纸上重建。

这套规则本身不深，但它是经济计量学日常推导的通用语：OLS、GLS、MLE、GMM 的一阶条件，信息矩阵与渐近方差，Delta 法的雅可比——它们的起点都是“对一个向量或矩阵求导”。把表 7.2 里的几条恒等式连同“数行数列”的维数自检练熟，后面渐近统计部分的大量推导都能照此机械地展开。

第二部分

分析与拓扑：存在性与收敛的语言

第八章 度量空间、开集闭集与序列收敛

用到的前置工具：向量空间与范数（线性代数部分，向量空间见第一章）；实数的基本性质（确界、绝对值）。本章是 Part II 的开篇，几乎是自足的。

经济学里到处是“逼近”与“极限”的论证：估计量 $\hat{\theta}$ 随样本量增大收敛到真值，值迭代 $V_{n+1} = TV_n$ 一步步逼近值函数，均衡作为某条曲线与另一条曲线的交点而存在。这些说法在一维实数轴上人人会用——“ x_n 离 x^* 越来越近”无非是 $|x_n - x^*| \rightarrow 0$ 。可一旦对象变成 $\mathbb{R}^n$ 里的价格向量、甚至变成一整个“函数”（值函数本身就是无穷维空间里的一个点），“近”和“极限”该怎么讲就不再显然。本章要做的，就是把“接近”“收敛”“闭合”这套直觉从实数轴搬到任意空间里、并讲精确。它是后面所有存在性证明、连续性讨论、动态系统与估计量收敛理论共用的语言地基——这一章先把字母表立起来，后面的章节才有词可写。

8.1 为什么经济学也需要拓扑语言

先说清楚动机，免得把这章当成纯数学的礼节性铺垫。经济学家真正要用到这套语言的地方，集中在三类问题上。

第一类是**存在性**。“竞争均衡存在吗？”“这个最优化问题有没有解？”——回答它们的标准武器是紧致性与不动点定理（后面几章），而紧致、连续这些概念本身，必须先有“开集”“收敛子列”才能定义。没有本章的词汇，连“Weierstrass 定理：连续函数在紧集上取到最大值”这句话都说不出口。

第二类是**收敛**。计量经济学整门课都在讨论估计量的大样本性质： $\hat{\theta}_n \xrightarrow{P} \theta_0$ （依概率收敛）、 $\hat{\theta}_n \xrightarrow{a.s.} \theta_0$ （几乎必然收敛）。这些收敛模式各自的定义，骨子里都是“某个距离趋于零”——依概率收敛说的是“落在 θ_0 的 ε -邻域之外的概率趋于零”，而“邻域”正是本章的开球。要把这些概念摆对，得先有度量。

第三类是**迭代与动态**。动态规划靠反复作用 Bellman 算子来求值函数，靠的是“相邻迭代越挤越近”最终收敛——这是 Cauchy 列与完备性的语言（压缩映射一章会正面向用到）。差分方程的稳定性、马尔可夫链收敛到平稳分布，同样是“序列在某空间里收敛”的故事。

本章在全书里的位置

本章提供的是**词汇而非定理**：开集 / 闭集、邻域、收敛、Cauchy、完备、有界序列有收敛子列。它们本身很少直接给出经济学结论，但后面每一个“存在”“收

敛”“连续”的论证都建在它们之上。读法上不必背，重点是每个概念对应回它在一维时的朴素直觉：度量是“距离”，开集是“每个点都还有活动余地的集合”，闭集是“取极限跑不出去的集合”，完备是“该收敛的都收敛，没有窟窿”。

8.2 度量、范数与邻域

一切从“两点之间有多远”开始。我们不假定空间是 $\mathbb{R}^n$ 、也不假定有坐标，只要求有一个测距的函数，且这个函数满足任何“距离”都该满足的几条朴素性质。

定义 8.1: 度量空间

设 X 是一个非空集合。函数 $d: X \times X \rightarrow \mathbb{R}$ 称为 X 上的一个**度量** (metric, 距离函数)，若对一切 $x, y, z \in X$ 满足：

(M1) 非负且可分： $d(x, y) \geq 0$ ，且 $d(x, y) = 0$ 当且仅当 $x = y$ ；

(M2) 对称： $d(x, y) = d(y, x)$ ；

(M3) 三角不等式： $d(x, z) \leq d(x, y) + d(y, z)$ 。

此时称二元组 (X, d) 为**度量空间**。

这三条恰是“距离”一词的最小公约数：距离不为负、A 到 B 等于 B 到 A、绕路不会更近。三角不等式 (M3) 是其中唯一“有内容”的一条，后面几乎每个证明都要靠它——它正是“ x 与 z 都离 y 近，则 x 与 z 彼此也近”这个几何直觉的代数化身。

例（最常用的几个度量）。

验证以下都是度量空间，并体会“同一集合可配不同度量”。

解。

(1) 实数轴： $X = \mathbb{R}$ ， $d(x, y) = |x - y|$ 。三条性质都是绝对值的基本性质，(M3) 即 $|x - z| \leq |x - y| + |y - z|$ 。

(2) 欧氏空间： $X = \mathbb{R}^n$ ， $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$ ，即由欧氏范数诱导的度量。这是本书默认的 $\mathbb{R}^n$ 度量。

(3) 同一 $\mathbb{R}^n$ 上的另两个度量：曼哈顿度量 $d_1(\mathbf{x}, \mathbf{y}) = \sum_i |x_i - y_i|$ 与切比雪夫度量 $d_\infty(\mathbf{x}, \mathbf{y}) = \max_i |x_i - y_i|$ 。它们与欧氏度量给出不同的“球”的形状（菱形、正方形），但在 $\mathbb{R}^n$ 上它们彼此“等价”，即诱导出相同的开集、相同的收敛——后面会回到这点。

(4) 离散度量：任意集合 X ，令 $d(x, y) = 0$ （若 $x = y$ ）、 $= 1$ （若 $x \neq y$ ）。它满足三条公理，提醒我们度量可以与“连续”的直觉毫无关系。

在向量空间上，度量通常由**范数**诱导。范数是“长度”的抽象，由它定义距离 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$ 既自然又自动满足三条度量公理。

定义 8.2: 范数

设 V 是 $\mathbb{R}$ 上的向量空间。函数 $\|\cdot\| : V \rightarrow \mathbb{R}$ 称为**范数**，若对一切 $\mathbf{x}, \mathbf{y} \in V$ 与标量 $\alpha \in \mathbb{R}$ ：

- (N1) $\|\mathbf{x}\| \geq 0$ ，且 $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$ ；
 (N2) $\|\alpha\mathbf{x}\| = |\alpha| \|\mathbf{x}\|$ （正齐次）；
 (N3) $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$ （三角不等式）。

注（范数 $\implies$ 度量，反之不然）。

由范数令 $d(\mathbf{x}, \mathbf{y}) := \|\mathbf{x} - \mathbf{y}\|$ ，则 (N1) 给出度量的 (M1)，(N2) 取 $\alpha = -1$ 给出对称 (M2)，(N3) 给出三角 (M3)——范数诱导的度量自动是度量，且还平移不变 ($d(\mathbf{x} + \mathbf{z}, \mathbf{y} + \mathbf{z}) = d(\mathbf{x}, \mathbf{y})$)。但度量空间未必来自范数：上面的离散度量就不是任何范数诱导的（它不满足 $d(\alpha\mathbf{x}, \alpha\mathbf{y}) = |\alpha| d(\mathbf{x}, \mathbf{y})$ ）。范数的额外结构（与线性运算相容）在线性代数与最优化里很关键；度量则是更朴素、适用面更广的底层概念。

有了距离，“一个点附近”就能精确表达。这是全章最频繁使用的对象。

定义 8.3: 开球与邻域

设 (X, d) 为度量空间， $x_0 \in X$ ， $r > 0$ 。集合

$$B(x_0, r) := \{x \in X : d(x, x_0) < r\}$$

称为以 x_0 为心、 r 为半径的**开球**（open ball）。 x_0 的一个**邻域**指任何包含某个 $B(x_0, r)$ 的集合。

在 $\mathbb{R}$ 里开球就是开区间 $(x_0 - r, x_0 + r)$ ；在 $\mathbb{R}^2$ 里（欧氏度量）就是不含边界的圆盘；换成曼哈顿或切比雪夫度量，“球”分别是菱形和正方形（图 8.1）。“邻域”则不必是球，只要容得下一个以该点为心的球即可——这点松弛在后面定义内点时正好够用。




图 8.1: 同一 $\mathbb{R}^2$ 、同一“单位球” $\{x : d(x, 0) < 1\}$ ，换一个度量就换一副形状：欧氏度量下是圆、曼哈顿度量下是菱形、切比雪夫度量下是正方形。三者“球”形虽异，在 $\mathbb{R}^2$ 上却给出相同的开集与相同的收敛（彼此等价）。

8.3 开集、闭集与点的分类

下面这组概念是整套拓扑语言的语法核心。直觉上，开集是“每个成员都还有富余空间”的集合，闭集是“取极限跑不出去”的集合；而二者通过取补集精确地互为对偶。

8.3.1 内点与开集

定义 8.4: 内点与开集

设 $A \subseteq X$ 。点 $x \in A$ 称为 A 的**内点** (interior point)，若存在 $r > 0$ 使得 $B(x, r) \subseteq A$ ——即 x 周围有一整个小球都还在 A 里。 A 的全体内点记作 $\text{int } A$ 。若 A 的每个点都是内点 (即 $\text{int } A = A$)，则称 A 为**开集** (open set)。

“开”说的就是“没有边”：站在开集里的任何一点，无论它多靠近“边缘”，总还有一点活动余地不出界。开区间 (a, b) 是开集——再贴近 a 的点 x ，离 a 仍有正距离，可取 $r = \min\{x - a, b - x\}$ ；而 $[a, b]$ 不是开集，因为端点 a 的任何小球都会探出区间左侧。

事实 8.5: 开集的基本性质

在任何度量空间 (X, d) 中：

- (i) 每个开球 $B(x_0, r)$ 都是开集；
- (ii) 空集 $\emptyset$ 与全空间 X 都是开集；
- (iii) 任意多个开集之并仍是开集；
- (iv) 有限个开集之交仍是开集。

(i) 与 (iv) 值得动手验一遍：(i) 是“开球”名副其实的依据，也示范了三角不等式怎么用；(iv) 则点出“有限”这个限定不可省。

证明. 验 (i)：取 $y \in B(x_0, r)$ ，记 $s := r - d(y, x_0) > 0$ 。对任何 $z \in B(y, s)$ ，由三角不等式

$$d(z, x_0) \leq d(z, y) + d(y, x_0) < s + d(y, x_0) = r,$$

故 $z \in B(x_0, r)$ ，即 $B(y, s) \subseteq B(x_0, r)$ 。这说明 y 是内点。 y 在球内任取，故 $B(x_0, r)$ 全由内点组成，是开集。几何上 s 就是“ y 到球面还剩的余量” (图 8.2)。

(iv)：设 $A_1, \dots, A_k$ 开， $x \in \bigcap_j A_j$ 。每个 A_j 给出半径 $r_j > 0$ 使 $B(x, r_j) \subseteq A_j$ ；取 $r = \min_j r_j > 0$ ，则 $B(x, r)$ 同时落在所有 A_j 里，故落在交里。“有限”在此不可省：取 $r = \min$ 用到了正数个数有限才保证 $\min > 0$ ；无穷个开集 $(-\frac{1}{n}, \frac{1}{n})$ 的交是单点集 $\{0\}$ ，并不开。(ii)(iii) 留给读者，皆是定义的直接推演。□




图 8.2: 开球是开集的证明图解。任取球内一点 y , 令 $s = r - d(y, x_0)$ 为“ y 到球面还剩的余量”; 由三角不等式, 整个 $B(y, s)$ 都落在 $B(x_0, r)$ 内 (小球恰好内切于大球面), 故 y 是内点。

8.3.2 闭集、聚点与闭包

闭集最干净的定义是“开集的补集”, 但更能体现其内涵的等价说法是“包含自身的全部极限点”。两条我们都要。

定义 8.6: 闭集

集合 $A \subseteq X$ 称为**闭集** (closed set), 若它的补集 $X \setminus A$ 是开集。

注 (开与闭不是反义词)。

“闭”被定义为“补集开”, 这是个常被误解的地方: 开与闭不互斥、也不穷尽。一个集合可以既开又闭 (在 $\mathbb{R}$ 中只有 $\emptyset$ 和 $\mathbb{R}$, 但在一般空间里可以更多——这正是“连通”概念的来由), 也可以既不开也不闭 (如半开区间 $[0, 1)$: 含端点 0 故不开, 缺端点 1 故不闭, 见图 8.3)。所以看到“不是开集”千万别顺势断定“是闭集”。

要把“闭 = 取极限跑不出去”讲清楚, 先要“极限点”这个词。

定义 8.7: 聚点、孤立点与闭包

设 $A \subseteq X$, $x \in X$ 。

- x 称为 A 的**聚点** (accumulation/limit point), 若 x 的每个邻域都含有 A 中异于 x 的点——直觉上 A 的点能要多近有多近地挤向 x 。
- $x \in A$ 若不是 A 的聚点, 则称**孤立点**。
- A 的**闭包** (closure) $\overline{A}$ 是 A 连同其全部聚点构成的集合。

注意聚点不必属于 A 本身——它恰恰是“ A 在边上够不着、却被逼近”的那种点。例如 $A = \{1/n : n \in \mathbb{N}\}$ 的唯一聚点是 $0 \notin A$ 。下面这条等价刻画是“闭”字的真正含义，也是日后判定闭集时最常用的判据。

定理 8.8: 闭集的序列刻画

设 $A \subseteq X$ 。以下三者等价：

- (a) A 是闭集（即 $X \setminus A$ 开）；
- (b) A 包含它自身的全部聚点（即 $\bar{A} = A$ ）；
- (c) A 中任何收敛序列的极限仍在 A 内：若 $x_n \in A$ 且 $x_n \rightarrow x$ ，则 $x \in A$ 。

证明. (a) $\implies$ (c): 设 A 闭、 $x_n \in A$ 、 $x_n \rightarrow x$ ，反设 $x \notin A$ ，即 $x \in X \setminus A$ 。因 $X \setminus A$ 开，存在 $r > 0$ 使 $B(x, r) \subseteq X \setminus A$ ，该球与 A 无交。但 $x_n \rightarrow x$ 意味着 n 充分大后 $x_n \in B(x, r)$ ，与 $x_n \in A$ 矛盾。故 $x \in A$ 。

(c) $\implies$ (b): 设 x 是 A 的聚点。对每个 n ，邻域 $B(x, 1/n)$ 含 A 中异于 x 的点 x_n ；则 $d(x_n, x) < 1/n \rightarrow 0$ ，即 $x_n \rightarrow x$ ，由 (c) 得 $x \in A$ 。故 A 含其全部聚点。

(b) $\implies$ (a): 设 $\bar{A} = A$ ，要证 $X \setminus A$ 开。取 $y \in X \setminus A$ 。 y 不在 A 、也不是 A 的聚点（否则 $y \in \bar{A} = A$ ），故 y 有某邻域 $B(y, r)$ 不含 A 中异于 y 的点；又 $y \notin A$ ，所以 $B(y, r)$ 干脆与 A 无交，即 $B(y, r) \subseteq X \setminus A$ 。于是 $X \setminus A$ 的每点都是内点，是开集。□

判定“闭”的实战口径

日常证明里几乎总用 (c)：要证某集合闭，就取它内部一个收敛序列，验它的极限还在集合里。这条“序列判据”之所以好用，是因为经济学里的集合常以“满足若干不等式”的形式给出（如约束集 $\{x : g(x) \leq 0\}$ ），而“弱不等式在取极限下保持”——若 $g(x_n) \leq 0$ 且 g 连续、 $x_n \rightarrow x$ ，则 $g(x) \leq 0$ ——正好兑现 (c)。这就是“闭约束集”几乎总成立、而紧约束集（闭 + 有界）成为存在性定理标准前提的根由。

推论 8.9: 开闭对偶

对集族取补，“并”与“交”互换，于是

事实 8.10: 开集的基本性质

逐

条翻译成： $\emptyset, X$ 闭；任意多个闭集之交是闭集；有限个闭集之并是闭集。（注意“任意/有限”随对偶而对调。）




图 8.3: 开、闭不是反义词。端点取舍决定一切：两端都不取是开集 (a, b) ，两端都取是闭集 $[c, d]$ ，只取一端的 $[0, 1)$ 则既不开也不闭（含 0 故不开、缺聚点 1 故不闭）。

8.3.3 边界点

定义 8.11: 边界

点 $x \in X$ 称为 A 的边界点 (boundary point)，若 x 的每个邻域既含 A 中的点又含 $X \setminus A$ 中的点。 A 的全体边界点记作 ∂A 。

边界点是“一脚在内、一脚在外”的临界点。它干净地统一了前面几个概念：开集就是“一个边界点都不含”的集合，闭集就是“把自己的边界点全含进来”的集合，而 $\overline{A} = \text{int } A \cup \partial A$ 。在 $\mathbb{R}^n$ 里，闭球 $\{x : d(x, x_0) \leq r\}$ 的边界正是球面 $\{x : d(x, x_0) = r\}$ ，它既属于闭球（故闭球闭）、又不属于开球（故开球开）——开球与闭球的差别，整个就装在这层边界里。

8.4 序列收敛、Cauchy 列与完备性

度量最直接的用途是定义收敛——也就是把一维的 $|x_n - x| \rightarrow 0$ 原样搬到任意度量空间。

定义 8.12: 序列收敛

度量空间 (X, d) 中的序列 (x_n) 收敛到 $x \in X$ ，记 $x_n \rightarrow x$ ，若 $d(x_n, x) \rightarrow 0$ ；展开即：对任意 $\varepsilon > 0$ ，存在 N ，使 $n \geq N$ 时 $d(x_n, x) < \varepsilon$ 。等价地说， x 的任何邻域最终都“关住”了序列的全部尾项（图 8.4）。此 x 称为序列的极限。

注（极限唯一、与度量绑定）。

度量空间中极限唯一：若 $x_n \rightarrow x$ 又 $x_n \rightarrow y$ ，则由三角不等式 $d(x, y) \leq d(x, x_n) + d(x_n, y) \rightarrow 0$ ，故 $d(x, y) = 0$ ，即 $x = y$ 。要紧的是，“收敛”是相对于所选度量而言的：换一个度量，同一序列可能收敛到别处、甚至不再收敛（离散度量下只有最终恒为常数的序列才收敛）。所幸在 $\mathbb{R}^n$ 上，欧氏、曼哈顿、切比雪夫三种度量等价，给出完全一样的收敛——下一节细说。




图 8.4: $\mathbb{R}^2$ 中序列 $x_n \rightarrow x^*$ 。早期的项 $x_1, \dots, x_4$ 可以四处游荡、离 x^* 还远；但收敛意味着：无论把 ε -球 $B(x^*, \varepsilon)$ 取得多小，总存在一个下标 N ，使 N 之后的全部尾项 $x_5, x_6, x_7, \dots$ 都被关进这个球里。

8.4.1 子列与 Cauchy 列

定义 8.13: 子列

给定序列 (x_n) 与严格递增的下标 $n_1 < n_2 < n_3 < \dots$ ，新序列 $(x_{n_k})_{k \geq 1}$ 称为 (x_n) 的一个子列 (subsequence)。

子列是“沿原序列挑出无穷多项、保持次序”。一个有用的事实：若 $x_n \rightarrow x$ ，则它的每个子列也收敛到同一个 x （尾项的性质对子列照样成立）。反过来，一个不收敛的序列也可能有收敛的子列——这正是后面 Bolzano–Weierstrass 的舞台。

下面这个概念是完备性的关键。它刻画“序列项彼此越挤越近”，而不预设极限存在——这点差别正是它的全部价值。

定义 8.14: Cauchy 列

序列 (x_n) 称为 **Cauchy 列**（柯西列），若对任意 $\varepsilon > 0$ ，存在 N ，使得对一切 $m, n \geq N$ 都有 $d(x_m, x_n) < \varepsilon$ ——即足够靠后的任意两项都任意接近。

收敛与 Cauchy 的关系，是本节的全部张力所在。

命题 8.15: 收敛 $\implies$ Cauchy

任何收敛序列都是 Cauchy 列。

证明. 设 $x_n \rightarrow x$ 。给定 $\varepsilon > 0$ ，取 N 使 $n \geq N$ 时 $d(x_n, x) < \varepsilon/2$ 。则对 $m, n \geq N$ ，三角不等式给出

$$d(x_m, x_n) \leq d(x_m, x) + d(x, x_n) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

故 (x_n) 是 Cauchy 列。 □

注意推导只用到“两项都离极限近”，根本没用到极限是谁。反方向——Cauchy 列是否一定收敛——却不总成立，而它成立与否，恰恰是空间“有没有窟窿”的试金石。

8.4.2 完备性

定义 8.16: 完备空间

度量空间 (X, d) 称为**完备** (complete), 若其中每个 Cauchy 列都在 X 内收敛。

完备性 = “该收敛的都收敛、空间没有窟窿”

Cauchy 列是“项已经挤成一团、只差一个极限来收口”的序列。完备性断言：这个极限真的存在、且就在空间内。反例最能说明问题：在有理数空间 $\mathbb{Q}$ (带 $d(x, y) = |x - y|$) 里，取逼近 $\sqrt{2}$ 的有理数列 $1, 1.4, 1.41, 1.414, \dots$ ——它是 Cauchy 列 (项越挤越近)，可它“想”收敛到的 $\sqrt{2}$ 是个无理数，不在 $\mathbb{Q}$ 里。 $\mathbb{Q}$ 在 $\sqrt{2}$ 处有个“窟窿”，故不完备。把窟窿全填上，得到的正是 $\mathbb{R}$ ——实数系的完备性是它区别于有理数系的根本特征，也是“实分析”得以展开的地基。

事实 8.17: $\mathbb{R}^n$ 完备

配欧氏度量的 $\mathbb{R}^n$ 是完备度量空间：其中每个 Cauchy 列都在 $\mathbb{R}^n$ 内收敛。更一般地， $\mathbb{R}$ 上的有限维赋范空间都完备，常用的函数空间 (如紧集上连续函数配上确界范数的 $C(K)$) 也完备。

完备性是动态规划的隐形地基：压缩映射定理 (后文) 能断言 Bellman 算子的迭代收敛到唯一不动点，前提正是值函数所在的空间完备——否则迭代出的 Cauchy 列可能“收敛”到一个根本不在空间里的对象。

8.5 $\mathbb{R}^n$ 的拓扑与 Bolzano–Weierstrass

把上面的一般框架落到经济学最常用的 $\mathbb{R}^n$ 上，会冒出两件特别好用、却并非在任何度量空间都成立的事实。

8.5.1 $\mathbb{R}^n$ 上度量的等价与逐分量收敛命题 8.18: $\mathbb{R}^n$ 上收敛即逐分量收敛

设 $\mathbf{x}_n = (x_n^{(1)}, \dots, x_n^{(p)}) \in \mathbb{R}^p$ 。则 (在欧氏度量下) $\mathbf{x}_n \rightarrow \mathbf{x}$ 当且仅当每个分量都收敛: $x_n^{(i)} \rightarrow x^{(i)}$, $i = 1, \dots, p$ 。

证明. 对每个分量, $|x_n^{(i)} - x^{(i)}| \leq \|\mathbf{x}_n - \mathbf{x}\|$, 故向量收敛蕴含各分量收敛。反过来,

$$\|\mathbf{x}_n - \mathbf{x}\| = \sqrt{\sum_{i=1}^p (x_n^{(i)} - x^{(i)})^2} \leq \sqrt{p} \max_i |x_n^{(i)} - x^{(i)}|,$$

右端在各分量都收敛时趋于零，故向量收敛。这条等价让我们能把 $\mathbb{R}^n$ 里的收敛问题拆成 n 个一维问题逐个处理。□

同样的两边夹估计还表明欧氏度量 d_2 与切比雪夫度量 d_∞ 互相控制 ($d_\infty \leq d_2 \leq \sqrt{p}d_\infty$)，由此它们等价：诱导相同的开集、相同的收敛。这就是为什么在 $\mathbb{R}^n$ 上我们可以随意挑一个用着方便的范数而不影响任何拓扑结论。

8.5.2 Bolzano–Weierstrass 定理

这是 $\mathbb{R}^n$ 拓扑里最常被引用的一条，几乎所有“选一个收敛子列”的论证都从它出发。

定理 8.19: Bolzano–Weierstrass

$\mathbb{R}^n$ 中每个有界序列都有收敛的子列。

它说的是：序列本身可以颠来倒去永不收敛，但只要它被关在一个有界范围里，就一定能从中挑出无穷多项、让这些项收敛到某个点。直觉用“反复二分”最清楚（见下证的一维骨架），结论则是后续紧致性理论的引擎。

证明. 先看一维 $\mathbb{R}$ ，再升到 $\mathbb{R}^n$ 。设 $(x_n) \subseteq \mathbb{R}$ 有界，即落在某闭区间 $I_0 = [a, b]$ 内。把 I_0 对半分，两半中至少有一半含序列的无穷多项，取这一半为 I_1 ；再对半分 I_1 ，取含无穷多项的一半为 I_2 ；如此得到一系列闭区间

$$I_0 \supseteq I_1 \supseteq I_2 \supseteq \cdots, \quad \text{长度 } |I_k| = \frac{b-a}{2^k} \rightarrow 0,$$

每个 I_k 都含序列的无穷多项。从 I_k 中挑一项 x_{n_k} 、且让下标严格递增（每步都有无穷多项可挑，做得到），就得到一个子列 (x_{n_k}) 。由区间套定理（ $\mathbb{R}$ 完备的体现），存在唯一的 $x \in \bigcap_k I_k$ ；因 x_{n_k} 与 x 同在长度 $\rightarrow 0$ 的 I_k 内， $|x_{n_k} - x| \leq |I_k| \rightarrow 0$ ，故 $x_{n_k} \rightarrow x$ 。

升到 $\mathbb{R}^n$ ：有界向量序列的第一分量有界，由一维情形取出使第一分量收敛的子列；在该子列里第二分量仍有界，再取子列使第二分量也收敛——前一分量的收敛被子列继承、不会破坏。逐分量做 n 次，得到一个使所有分量都收敛的子列；由上一命题，它在 $\mathbb{R}^n$ 中收敛。□

注（“有界”与“ $\mathbb{R}^n$ ”都不能省）。

两个前提缺一不可。其一，去掉有界： $x_n = n$ 跑向无穷，任何子列都发散。其二，离开 $\mathbb{R}^n$ （有限维）：在无穷维空间里“有界”不再保证有收敛子列。例如序列空间 ℓ^2 里的标准基 $e_1, e_2, \dots$ （第 k 个分量为 1、其余为 0）两两距离都是 $\sqrt{2}$ ，有界却无任何 Cauchy 子列、更无收敛子列。这条差异正是“有限维”在经济学存在性定理里如此关键的原因——也提示：一旦模型搬到函数空间（无穷维），紧致性要靠别的（更强的）条件来补。

Bolzano–Weierstrass 通向“紧致”

下一章会看到：在 $\mathbb{R}^n$ 中，“闭且有界”、“每个序列都有收敛到集内的子列”（列紧）、以及“每个开覆盖都有有限子覆盖”（拓扑紧）三者等价，这就是著名的 Heine–Borel 定理。Bolzano–Weierstrass 正是“有界 $\implies$ 有收敛子列”这半边，配上本章“闭 $\implies$ 极限不出界”，就拼出“闭 + 有界 $\implies$ 列紧”。而列紧性是 Weierstrass 极值定理（连续函数在紧集上取到最值）的引擎，后者又是几乎所有“最优解存在”论证的落脚点。

8.6 这套语言通向何处

本章只立了字母表，但它支撑起的句子遍布全书。几处主要去处：

- **紧致性与极值定理**（下一章）。“闭 + 有界”经 Heine–Borel 升级为紧致，紧集上连续函数必取到最大值——这是“最优化问题有解”“竞争均衡存在”等一切存在性结论的源头。本章的开集、收敛子列是它的原料。
- **连续性与最大值定理**（Berge）。连续可由“开集的原像是开集”或“ $x_n \rightarrow x \implies f(x_n) \rightarrow f(x)$ ”来定义，两者都直接调用本章词汇；参数化最优化的解如何随参数变（上半连续性），也建在这套收敛语言上。
- **压缩映射与 Bellman 算子**（后文）。值迭代收敛的证明，核心是“迭代序列是 Cauchy 列”加上“值函数空间完备”——完备性正是本章的概念。
- **估计量的收敛理论**（渐近统计部分）。依概率收敛 $\hat{\theta} \xrightarrow{P} \theta_0$ 、几乎必然收敛 $\xrightarrow{a.s.}$ 、连续映射定理，乃至“一致律”中处理上确界的论证，底层都是度量空间里“距离趋于零”与“有界序列取收敛子列”的反复运用。

把这章的几个词——开 / 闭、邻域、收敛、Cauchy、完备、有界序列有收敛子列——记牢并对回它们在一维时的朴素样子，后面那些“存在”“收敛”“连续”的论证就不再是黑箱，而是同一套语法的反复造句。

第九章 紧致性、连续性与 Weierstrass 极值定理

用到的前置工具：度量空间、开集与闭集、序列收敛与完备性（第八章）；上确界与下确界、实数的完备性（实数公理，线性代数与分析部分常用）。

经济学里几乎每一个模型，第一步都是写下一个最优化问题：消费者最大化效用、厂商最小化成本、计量学家在参数空间上最大化对数似然。可在动笔求一阶条件之前，有一个更基本、却常被跳过的问题：这个最优解到底存不存在？如果连“最大值”都不存在，那么“最优选择”、“均衡”、“估计量”就都是空中楼阁，后面所有比较静态、所有渐近分析都失去了立足点。本章给出回答这个问题的标准工具——**Weierstrass 极值定理**：连续函数在紧致集上一定取到最大值与最小值。为把它讲清楚，我们要先认识两个角色——刻画定义域“不漏气”的**紧致性**，和刻画目标函数“不跳变”的**连续性**——再看它们如何合力保证最优解存在。最后简单提一句一致连续，它是后续讲积分与逼近时会再登场的近亲。

9.1 先问“解存不存在”

考虑最朴素的最大化问题

$$\max_{x \in S} f(x),$$

S 是可行集（预算集、参数空间……）， f 是目标函数（效用、利润、似然）。我们太习惯“求出最优解”这件事，以至于默认它一定有解。但它未必有。

举两个一眼可见的失败。其一，把可行集取成开区间 $S = (0, 1)$ 、目标 $f(x) = x$ ： f 在 S 上的取值可以任意接近 1，却永远到不了 1——没有哪个 $x \in (0, 1)$ 使 $f(x)$ 最大，“最优解”不存在。毛病出在定义域“漏了气”：它缺了本该是上确界所在的那个端点。其二，把可行集取成整条实轴 $S = \mathbb{R}$ 、目标 $f(x) = x$ ：取值无上界，更谈不上最大。毛病出在定义域“跑到了无穷远”。这两种病——缺边界与跑无穷——正是“紧致”这个概念要一举堵死的。

还有第三种失败，毛病不在定义域而在函数自身：哪怕 $S = [0, 1]$ 这么规整，若 f 在某点突然跳一下（不连续），它也可能在那一点附近无限接近一个值却取不到。把这三种失败合起来看，结论很清爽：只要定义域紧致、函数连续，三种病就全被排除，最大值与最小值必定存在。这就是 Weierstrass 极值定理，本章的主角。

为什么经济学家必须在乎“存在性”

“最优解存在”不是数学洁癖，而是整座建筑的地基。需求函数 $x^*(p, w) = \arg \max_{x \in B(p, w)} u(x)$ 要先有解，才谈得上它怎么随价格变（比较静态）；一般均衡要先有解，才谈得上它的性质；极大似然估计量 $\hat{\theta} = \arg \max_{\theta} \ell_n(\theta)$ 要先良定义，才谈得上它一致、渐近正态。本章的定理，就是这一切“先有解”的统一出处。

9.2 紧致性

紧致性有两副面孔：一副是抽象的“开覆盖”定义，它在任意拓扑空间里都成立、是定理证明里最锋利的工具；另一副是直观的“有界闭集”刻画，它只在 $\mathbb{R}^n$ 里成立、却是我们日常判断一个集合紧不紧致的实用判据。两者之间架着 Heine–Borel 定理这座桥。

9.2.1 开覆盖定义

定义 9.1: 开覆盖与紧致集

设 K 是度量空间 (X, d) 的子集。 X 中一族开集 $\{U_\alpha\}_{\alpha \in A}$ 称为 K 的一个开覆盖，若

$$K \subseteq \bigcup_{\alpha \in A} U_\alpha.$$

若从中总能挑出有限个 $U_{\alpha_1}, \dots, U_{\alpha_n}$ 仍覆盖 K （即 $K \subseteq U_{\alpha_1} \cup \dots \cup U_{\alpha_n}$ ），就称这是一个有限子覆盖。若 K 的每一个开覆盖都存在有限子覆盖，则称 K 是紧致集 (compact)。

这个定义初看抽象得让人摸不着头脑：为什么“任意开覆盖都能缩成有限个”会是个有用的性质？关键在那个“任意”与“有限”的对比。它说的是：无论别人用多么稀碎、多么刁钻的一族开集来盖住 K ，你总能只留下有限件就把活干完（图 9.1）。这种“无穷的覆盖可以被有限地驾驭”的能力，正是后面把“逐点的局部信息”拼成“整体结论”时所依赖的——证明 Weierstrass 定理、证明连续函数在紧集上一致连续，用的都是它。




图 9.1: 开覆盖与有限子覆盖。一堆开区间盖住闭区间 $K = [a, b]$ ；紧致性断言，无论原来这族开集有多少个，总能只留下有限个（这里四个）仍盖住 K 。

注（为什么用“开”集、为什么要“任意”覆盖）。

两处都不可放松。若允许用闭集覆盖，则任何集合都能被它自身（一个闭集）“覆盖”，定义就废了——开集的“软边界”才让覆盖这件事有内容。而“任意”也省不得：开区间 $(0, 1)$ 存在有限子覆盖的开覆盖（例如用单个 $(-1, 2)$ 盖住），但它不是对每个开覆盖都行——取 $U_n = (1/n, 1)$, $n = 1, 2, \dots$ ，这族开集盖住了 $(0, 1)$ ，可任意有限个的并都是某个 $(1/N, 1)$ ，漏掉了 $(0, 1/N]$ 。正是这个“漏”，暴露出 $(0, 1)$ 不紧致——也正是上一节“取不到最大值”那个毛病的拓扑版本。

9.2.2 Heine–Borel: 在 $\mathbb{R}^n$ 里紧致就是有界闭

开覆盖定义虽利，却难直接验证——你总不能真去检查“每一个”开覆盖。所幸在欧氏空间里，紧致性等价于一个一眼可查的几何条件。

定理 9.2: Heine–Borel 定理

设 $K \subseteq \mathbb{R}^n$ 。则

$$K \text{ 紧致} \iff K \text{ 既有界又闭.}$$

注（这是 $\mathbb{R}^n$ 的特权，不是普遍真理）。

“紧致 = 有界闭”只在有限维欧氏空间（更一般地，在有限维赋范空间）里成立。在无穷维空间里它会崩塌：闭单位球在任何无穷维赋范空间里都是有界闭的，却不紧致。这件事对计量与决策论并非纯属遐想——当参数空间是函数空间（非参数估计、连续型机制设计）时，“有界闭”就不再保证存在性，得另请高明（如 Arzelà–Ascoli 给出函数族紧致的判据）。本书后续凡说“紧致”，默认在 $\mathbb{R}^n$ 中，可与“有界闭”互换。

完整证明偏重纯拓扑，这里只给两个方向的直觉，足够使用与记忆。

直觉，非严格。紧致 $\implies$ 有界闭。先说有界：用一族同心开球 $B(0, m)$ ($m = 1, 2, \dots$) 覆盖 K ，它们是一个开覆盖；有限子覆盖意味着 K 被某个最大的 $B(0, M)$ 装下，故有界。再说闭：若 K 不闭，则存在一个在 K 外的极限点 p ，可用“挖掉 p 的小邻域”的那些开集覆盖 K ；但因 p 是极限点，任何有限个这样的开集都会在 p 附近留下 K 的点没盖住——与紧致矛盾。故 K 必闭。

有界闭 $\implies$ 紧致。这一半是实数完备性的化身。先看一维闭区间 $[a, b]$ ：用二分法。若某个开覆盖没有有限子覆盖，就把 $[a, b]$ 平分，两半中至少一半仍不能被有限子覆盖；对它再平分，如此下去得到一串长度趋于零、层层套住的闭区间，每个都不能被有限子覆盖。由闭区间套定理（实数完备性），它们交于唯一一点 $x^* \in [a, b]$ 。但 x^* 总被覆盖里某个开集 U 含住，而 U 是开的、必含 x^* 的一个小邻域——当区间套缩得足够小时，整段区间都落进这一个 U 里，它单独一个就构成有限子覆盖，矛盾。故 $[a, b]$ 紧致。高维的有界闭集落在某个闭方体 $[a, b]^n$ 内，方体由一维情形（取乘积）紧致，而紧致集的闭子集仍紧致，于是 K 紧致。□

$\mathbb{R}^n$ 中判紧致的实用流程

要断定 $K \subseteq \mathbb{R}^n$ 紧致，只需查两件事：(1) 有界——存在 R 使 $\|x\| \leq R$ 对一切 $x \in K$ 成立；(2) 闭—— K 的每个收敛序列的极限仍在 K 内（等价地， K 含其全部极限点）。预算集 $\{x \geq 0 : p \cdot x \leq w\}$ （价格为正时）、概率单纯形 $\{x \geq 0 : \sum_i x_i = 1\}$ 、有界闭的参数空间 Θ ，都是这样验出来的紧致集——它们正是消费者问题、混合策略、极值估计存在性的舞台。

9.2.3 序列紧致：紧致性的“可用”形态

证明 Weierstrass 定理时，我们其实不直接搬开覆盖，而用紧致性的一个等价说法，它更贴合“序列”这门第八章已练熟的语言。

定理 9.3: 序列紧致 ($\mathbb{R}^n$ 中等价于紧致)

$K \subseteq \mathbb{R}^n$ 紧致，当且仅当 K 是序列紧致的： K 中任意序列 $\{x_k\}$ 都有一个收敛子列 $\{x_{k_j}\}$ ，且其极限仍落在 K 内。

注（为什么序列紧致就是“有界闭”的序列版）。

拆开看：“ K 中任意序列有收敛子列”正是 **Bolzano–Weierstrass 定理**（ $\mathbb{R}^n$ 中任何有界序列必有收敛子列）所保证的——前提是序列有界，而这由 K 有界供给；“极限仍在 K 内”则正是 K 闭的定义。所以“有界”管“抽得出收敛子列”，“闭”管“极限不逃出 K ”。两件事合起来，就是序列紧致。这也再次印证了 Heine–Borel：有界闭 $\iff$ 序列紧致 $\iff$ 紧致。

9.3 连续性

定义域备好了，再看目标函数。“连续”要捕捉的，是“输入微调、输出也只微调”这件直觉上“函数不跳变”的事。它同样有两副等价的面孔——古典的 ε - δ 语言，和更便于和紧致性配合的序列语言。

定义 9.4: 连续 (ε - δ 与序列两种刻画)

设 $f: S \rightarrow \mathbb{R}$, $S \subseteq \mathbb{R}^n$, $x_0 \in S$ 。以下两条等价，满足任一条即称 f 在 x_0 连续；若 f 在 S 的每一点都连续，称 f 在 S 上连续。

(1) ε - δ 刻画. 对任意 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使得对一切 $x \in S$ ，

$$\|x - x_0\| < \delta \implies |f(x) - f(x_0)| < \varepsilon.$$

(2) 序列刻画. 对 S 中任意收敛到 x_0 的序列 $\{x_k\}$ ，都有 $f(x_k) \rightarrow f(x_0)$ 。

注（两种刻画为何等价、各擅何处）。

ε - δ 量化了“要输出误差小于 ε ，输入只需贴近到 δ 之内”，适合做精细的估计；序列刻画则把连续等同于“可以与取极限交换次序”—— $\lim_k f(x_k) = f(\lim_k x_k)$ ，做收敛论证时格外顺手。证明二者等价的关键一步是：若序列刻画成立而 ε - δ 不成立，便能造出一个收敛到 x_0 、函数值却始终离 $f(x_0)$ 至少 ε 的序列，与序列刻画矛盾（这里悄悄用到了选取——对每个 $\delta = 1/k$ 挑一个“坏点” x_k ）。下一节我们用的是序列刻画，因为它能和序列紧致严丝合缝地咬在一起。

9.4 Weierstrass 极值定理

万事俱备。把“定义域紧致”与“函数连续”合在一处，最大值与最小值的存在性就水到渠成。

定理 9.5: Weierstrass 极值定理

设 $K \subseteq \mathbb{R}^n$ 非空紧致， $f: K \rightarrow \mathbb{R}$ 连续。则 f 在 K 上有界，并且达到它的最大值与最小值：存在 $x^*, x_* \in K$ 使得

$$f(x_*) \leq f(x) \leq f(x^*) \quad \text{对一切 } x \in K.$$

等价地， $\max_{x \in K} f(x)$ 与 $\min_{x \in K} f(x)$ 都存在（而非仅有 $\sup$ 、 $\inf$ ）。

证明分两步，逻辑很干净：先证“有界”（于是上确界是个有限数），再证这个上确界“真被取到”。两步都靠序列紧致把“逼近”升级成“达到”。最小值的论证与最大值对称，证一个即可。

证明. 第一步： f 有上界。反证。若 f 在 K 上无上界，则对每个 $k \in \mathbb{N}$ 都能找到 $x_k \in K$ 使 $f(x_k) > k$ 。由 K 序列紧致， $\{x_k\}$ 有收敛子列 $x_{k_j} \rightarrow \bar{x} \in K$ 。 f 连续，故由序列刻画 $f(x_{k_j}) \rightarrow f(\bar{x})$ ，是个有限数。但按构造 $f(x_{k_j}) > k_j \rightarrow \infty$ ，发散——矛盾。故 f 有上界（同理有下界）， f 在 K 上有界。

第二步：上确界被取到。既然 f 在 K 上有上界，记

$$M = \sup_{x \in K} f(x) \in \mathbb{R}.$$

由上确界的定义，存在一列 $x_k \in K$ 使 $f(x_k) \rightarrow M$ （这样的“逼近最大值”的序列总能取到——这是 $\sup$ 的特征）。再用序列紧致： $\{x_k\}$ 有收敛子列 $x_{k_j} \rightarrow x^* \in K$ 。一方面，作为收敛子列，它对应的函数值仍 $f(x_{k_j}) \rightarrow M$ ；另一方面， f 连续给出 $f(x_{k_j}) \rightarrow f(x^*)$ 。极限唯一，于是

$$f(x^*) = M = \sup_{x \in K} f(x).$$

这说明上确界 M 在点 $x^* \in K$ 处真正被取到，它就是最大值。对 $-f$ 重复整套论证（ $-f$ 也连续），即得最小值在某 $x_* \in K$ 取到。□

定理的“三步骨架”值得记住

整个证明就是同一招用了两遍：(i) 造一个逼近目标（无穷大／上确界）的序列；(ii) 用紧致性抽出收敛子列，把“逼近”钉在 K 内的一个真实极限点上；(iii) 用连续性让函数值跟着收敛过去，于是“逼近的极限”变成“在某点真正达到”。紧致性负责“极限点不逃逸”，连续性负责“函数值不跳变”，二者缺一，达到性就垮。下面两图正是这两根支柱各自抽掉后会怎样。

9.4.1 两个条件都不能省

紧致性不可省：开区间上的反例。 回到引子里的例子。取 $S = (0, 1)$ （有界但不闭，故不紧致）， $f(x) = x$ 连续。 f 的取值充满 $(0, 1)$ ，上确界 $\sup f = 1$ ，可没有任何 $x \in (0, 1)$ 让 $f(x) = 1$ （图 9.2）。证明里第二步会失败：逼近 $\sup$ 的序列 $x_k \rightarrow 1$ 的“极限点”1 恰恰漏在 S 之外——这正是 S 不闭（不紧致）的代价。把定义域换成闭区间 $[0, 1]$ ，端点补回，最大值立刻在 $x^* = 1$ 取到。




图 9.2: 紧致性不可省。 $f(x) = x$ 在开区间 $(0, 1)$ 上连续，取值可任意接近 $\sup f = 1$ （空心端点处），却没有任何一点使 f 达到 1——最大值不存在。

连续性不可省。 反过来，把定义域换成漂亮的紧致集 $[0, 1]$ ，但让 f 不连续：例如

$$f(x) = \begin{cases} x, & 0 \leq x < 1, \\ 0, & x = 1. \end{cases}$$

f 在 $x = 1$ 处跳了一下（图 9.3）。它的上确界仍是 $\sup f = 1$ ，逼近 $\sup$ 的序列 $x_k \rightarrow 1$ 极限点 1 这回留在定义域内（ K 紧致），但证明第二步还是失败：连续性断了， $f(x_k) \rightarrow 1$ 与 $f(1) = 0$ 对不上，“函数值跟着收敛”这一环掉链子，于是 $f(1) \neq \sup f$ ，最大值仍不存在。这说明紧致性与连续性各司其职、互不替代。

例（预算集上的效用最大化为何有解）。




图 9.3: 连续性不可省。定义域 $[0, 1]$ 紧致, 但 f 在 $x = 1$ 处跳变: 取值可任意接近 $\sup f = 1$, 而 $f(1) = 0$ 。逼近 $\sup$ 的序列极限点 1 这回留在域内, 是连续性断了让“函数值跟着收敛”失效——最大值仍不存在。与图 9.2 对照: 那里漏的是端点, 这里断的是连续。

价格 $p \in \mathbb{R}_{++}^n$ (各分量为正)、收入 $w > 0$, 预算集

$$B(p, w) = \{x \in \mathbb{R}^n : x \geq 0, p \cdot x \leq w\}.$$

设效用 $u: \mathbb{R}_+^n \rightarrow \mathbb{R}$ 连续。说明 $\max_{x \in B(p, w)} u(x)$ 存在。

解.

只需验证 $B(p, w)$ 非空紧致, 再调用 Weierstrass 定理。非空: $x = 0$ 满足约束。有界: 对任一 $x \in B(p, w)$ 与任一坐标 i , 由 $x \geq 0$ 与 $p \cdot x \leq w$ 得 $p_i x_i \leq p \cdot x \leq w$, 故 $0 \leq x_i \leq w/p_i$ (这里用到 $p_i > 0$)。于是 $B(p, w)$ 被装进盒子 $\prod_i [0, w/p_i]$, 有界。闭: $B(p, w)$ 是有限个闭集

$$\{x_i \geq 0\} \ (i = 1, \dots, n) \quad \text{与} \quad \{p \cdot x \leq w\}$$

的交 (每个都是连续函数的非严格不等式水平集, 故闭), 有限交仍闭。综上 $B(p, w)$ 非空、有界、闭, 即非空紧致; u 连续, 故由 Weierstrass 定理最大值存在——马歇尔需求非空、效用最大化问题良定义。注意这里处处用到 $p_i > 0$: 若某个价格为零, 预算集在该方向无界, 紧致性垮掉, “最优消费”可能不存在 (想要多少要多少)。

注 (只要“达到”, 连可微都不需要)。

Weierstrass 定理对 f 只要求连续, 不要求可微、更不要求凹。这一点常被忽视, 却很重要: 它把“最优解存在”与“用一阶条件刻画最优解”彻底分了家。存在性这一关, 靠的纯是紧致 + 连续这套拓扑—分析的论证, 跟微分毫无关系。等存在性落定, 我们才在内点、可微、可能加凹性的额外假设下, 用一阶条件去找那个早已确知存在的解。

9.5 一致连续（简述）

连续是“逐点”的性质：在 x_0 处那个 δ 可以随 x_0 变，越靠近函数“陡”的地方，要达到同样的输出精度 ε ，所需的 δ 往往越小。一致连续则要求一个“通用”的 δ 对全定义域一齐管用。

定义 9.6: 一致连续

$f: S \rightarrow \mathbb{R}$ 在 S 上一致连续，若对任意 $\varepsilon > 0$ ，存在同一个 $\delta > 0$ ，使得对一切 $x, y \in S$,

$$\|x - y\| < \delta \implies |f(x) - f(y)| < \varepsilon.$$

与逐点连续的差别全在量词次序：逐点连续是“ $\forall x_0 \forall \varepsilon \exists \delta$ ”（ δ 可依赖 x_0 ），一致连续是“ $\forall \varepsilon \exists \delta \forall x, y$ ”（ δ 对所有点统一）。 $f(x) = 1/x$ 在 $(0, 1)$ 上逐点连续却非一致连续——越靠近 0 越陡，没有一个 δ 能通吃。但只要把定义域换成紧致集，这种“陡到失控”就不会发生。

定理 9.7: Heine–Cantor 定理

若 $K \subseteq \mathbb{R}^n$ 紧致， $f: K \rightarrow \mathbb{R}$ 连续，则 f 在 K 上一致连续。

证明仍是“紧致 + 连续”那套老配方：反设非一致连续，则可造出两列点 x_k, y_k 距离趋于零而函数值之差始终 $\geq \varepsilon_0$ ；用序列紧致抽收敛子列把它们逼到同一个极限点，再用连续性导出函数值之差应趋于零——矛盾。

一致连续以后用在哪

它是把“逐点”升级为“整体”的桥梁，在后续两处反复出现：其一，证明连续函数在闭区间上可积（Riemann 积分存在）时，要用一致连续保证分割足够细时各小段的振幅一齐变小（见后文积分与期望部分）；其二，在渐近统计里证明一致大数定律、进而证明极值估计量一致时，需要目标函数关于参数“一致”地连续——紧致参数空间正是这条性质的来源。这又是一例：紧致性默默地把“逐点成立”兜底成“整体成立”。

9.6 这把工具通向何处

本章给出的是经济学里所有存在性论证的源头。它的去处密布在三门核心课中：

- **最大值定理**（Berge，见后文紧接的一章）。当目标函数还依赖参数、可行集本身也随参数移动（如预算集随价格变）时，我们不仅要最优值存在，还想知道它和最优选择如何连续地随参数变化。Berge 最大值定理正是 Weierstrass 的参数化升级版，它对约束集（一个对应/集值映射）施加紧致性与（半）连续性，结论是值函数连续、最优解对应上半连续——需求函数的连续性、动态规划里值函数的连续性，都从这里来。

- **均衡的存在性**（不动点定理，见后文）。Brouwer 与 Kakutani 不动点定理的前提里都端坐着“非空、紧致、凸”——紧致性是其中绕不开的一环。一般均衡的存在、纳什均衡的存在，归根结底都建立在“在紧致集上做事”之上。
- **极值估计量的良定义**（见后文渐近统计部分）。极大似然、GMM、M-估计量都形如 $\hat{\theta} = \arg \max_{\theta \in \Theta} Q_n(\theta)$ 。要让这个 $\arg \max$ 存在（估计量良定义）、并进而一致 ($\hat{\theta} \xrightarrow{P} \theta_0$)，标准做法正是假定参数空间 Θ 紧致、目标 Q_n （及其极限）连续，然后套用本章的 Weierstrass 与一致连续——计量教科书里“ Θ compact”这条看似形式化的假设，兑现的就是本章的存在性。

把这几处连起来看，本章其实只讲了一句话：紧致 + 连续 $\implies$ 最优解存在。可正是这句话，撑起了从消费者选择到一般均衡、再到计量估计的整条“先有解、再谈性质”的链条。先确认解存在，是一切最优化分析当之无愧的第一步。

第十章 半连续、对应与最大值定理 (Berge)

用到的前置工具：度量空间、开集闭集与序列收敛（第八章）；紧致性、连续函数与 Weierstrass 极值定理（第九章）。

经济学里几乎每一个有意思的量，最后都长成“某个最优化问题的解”：消费者在预算约束下选最优消费束，厂商在技术约束下选最优投入，博弈中的玩家对别人的策略选最优反应，动态规划里的决策者逐期选最优行动。而这些最优化问题无一例外地带着参数——价格、收入、对手的策略、状态变量。于是真正要问的不是“给定这一组参数，最优解是什么”，而是“参数动一动，最优值和最优解会怎么变”。第十五章的隐函数定理回答了其中可微、内点、约束不起作用的那一类；但经济学里大量约束是会卡住的（预算约束取等、产量非负），最优解可能落在边界、可能不唯一、甚至可能随参数跳变。要在这种一般情形下哪怕只是断言“最优值随参数连续变化”，隐函数定理就不够用了——我们需要一套能处理“参数化的、带约束的、解可能是一个集合”的最优化的语言。

这套语言由两块拼成。其一是**半连续**：把“连续”拆成“上”与“下”两半，因为最优值与最优解往往只占其中一半。其二是**对应**（correspondence，集值映射）：当最优解不唯一、或约束集本身随参数变动时，自然的对象不是函数而是“把每个参数映到一个集合”的映射。本章先把这两块工具讲清楚，再用它们陈述并理解全书最常被引用的结论之一——**Berge 最大值定理**：只要目标函数连续、约束对应连续且取紧值，那么最优值函数连续、最优解对应上半连续。最后我们说明它的去处：动态规划值函数的连续性、马歇尔需求的良好性态、博弈最优反应对应的上半连续（这正是下一章 Kakutani 不动点定理的入场券）。

10.1 为什么“连续”要拆成两半

先看一个最朴素的现象，它解释了为什么半连续这个概念非引入不可。考虑参数化的最优值

$$v(\theta) = \max_{x \in C(\theta)} f(x, \theta),$$

当参数 θ 越过某个临界点时，最优选择可能从一处突然跳到另一处（两个候选峰的高度此消彼长），但最优值却可以一路平滑地接上——在跳变那一刻，两个峰恰好一样高。这意味着：值函数 v 可能连续，而最优解却在同一点不连续。“连续”这把笼统的尺子，

量不出这种“一半连续、一半跳”的精细差别。

更基本地,最优化天然只青睐“连续”的一半。回忆 Weierstrass 定理(第九章):连续函数在紧集上取得最大值。但若把条件放松——只要求函数“不会向上跳”(上半连续),紧集上的最大值依然存在;而“不会向下跳”(下半连续)对取最大值毫无帮助,对取最小值才有用。可见在最优化里,“上”与“下”这两半地位完全不对称,必须分开命名、分别使用。这就是半连续的来由:它把连续性按方向拆开,好让我们精确地说出“恰好需要哪一半”。

10.2 上半连续与下半连续函数

我们在度量空间 X 上的实值函数 $f: X \rightarrow \mathbb{R}$ 上定义两个“半”。直观上:上半连续函数在每一点的值“不低于”它附近的极限行为(向上看是闭的),下半连续则反过来。

定义 10.1: 上半连续与下半连续 (函数)

设 X 是度量空间, $f: X \rightarrow \mathbb{R}$, $x_0 \in X$ 。

- 称 f 在 x_0 上半连续 (upper semicontinuous, u.s.c.), 若对任意 $\varepsilon > 0$ 存在 $\delta > 0$, 使得 $d(x, x_0) < \delta$ 时

$$f(x) < f(x_0) + \varepsilon.$$

等价地, 对任意 $x_n \rightarrow x_0$ 有 $\limsup_n f(x_n) \leq f(x_0)$ 。

- 称 f 在 x_0 下半连续 (lower semicontinuous, l.s.c.), 若对任意 $\varepsilon > 0$ 存在 $\delta > 0$, 使得 $d(x, x_0) < \delta$ 时

$$f(x) > f(x_0) - \varepsilon.$$

等价地, 对任意 $x_n \rightarrow x_0$ 有 $\liminf_n f(x_n) \geq f(x_0)$ 。

若 f 在每一点都上(下)半连续, 就称 f 在 X 上上(下)半连续。

两个定义合起来恰好是连续: f 在 x_0 连续 $\iff$ 它在 x_0 既上半连续又下半连续。把这件事记牢, 半连续就不再抽象——它就是连续的“左右两半”。

怎么记住哪半是哪半

盯住“跳”发生时函数在断点取哪个值。**上半连续**: 在向下跳的断点处, f 取较高的那个值(图 10.1 左, 实心点在上支)——即上方水平集 $\{x: f(x) \geq a\}$ 对一切 a 都闭。**下半连续**: 在断点处取较低的值(图 10.1 右, 实心点在下支)——即下方水平集 $\{x: f(x) \leq a\}$ 对一切 a 都闭。一句话: u.s.c. 的图像“不会向上跳出去”, l.s.c. 的图像“不会向下跳出去”。后面会看到, 最优值的连续性, 正是靠“目标向上不跳”(u.s.c.) 与“约束不塌缩”(l.s.c.) 这两半分别保住的。




图 10.1: 同一条带跳函数的两种“补点”方式。左：在断点取较高值，向上不跳出去，故上半连续。右：取较低值，向下不跌出去，故下半连续。两者皆于 x_0 不连续，但各占连续性的一半。

注 (Weierstrass 只需要一半)。

第九章的极值定理可被半连续精确地“减肥”：紧集上的上半连续函数必取得最大值（对称地，下半连续函数必取得最小值）。证明思路与连续情形一致——取一个使 f 趋于其上确界的序列，紧致性保证有收敛子列 $x_{n_k} \rightarrow x^*$ ，而上半连续给出 $f(x^*) \geq \limsup_k f(x_{n_k}) = \sup f$ ，故上确界在 x^* 处达到。取最大只用到上半连续这一半，下半连续在这里一点忙都帮不上。这条“半个 Weierstrass”正是 Berge 定理里保住最优值的那块砖。

10.3 对应：当映射的取值是一个集合

第二块工具应对的是另一种一般性：参数映到的不是一个点，而是一个集合。约束集 $C(\theta)$ （如预算集随价格变）天然集合；最优解 $x^*(\theta)$ 在不唯一时也是集合；博弈里的最优反应通常是一整个集合。把这类对象统一抽象出来，就是对应。

定义 10.2: 对应（集值映射）

设 Θ, X 为集合。一个对应（correspondence） $C : \Theta \rightrightarrows X$ 是一条规则，给每个 $\theta \in \Theta$ 指派一个子集 $C(\theta) \subseteq X$ 。其图像（graph）定义为

$$\text{Gr}(C) = \{ (\theta, x) \in \Theta \times X : x \in C(\theta) \}.$$

若每个 $C(\theta)$ 都非空（紧、闭、凸），就说该对应非空值（紧值、闭值、凸值）。

记号 $\rightrightarrows$ （双箭头）专门用来区别对应与普通函数 $\rightarrow$ 。普通函数是对应的特例——每个 $C(\theta)$ 恰好是单点集。

对应的“连续性”该怎么定义？由于值是集合，“ $C(\theta)$ 随 θ 连续地变”这件事，同样分裂成不对称的两半——而且分裂方式与函数那里精神一致：一半管“集合不会突然变大/有点冒出来无法被逼近”，一半管“集合不会突然塌缩/有点凭空消失”。

定义 10.3: 上半连续与下半连续 (对应)

设 Θ, X 为度量空间, $C: \Theta \rightrightarrows X$ 在 θ_0 取非空值。

- 称 C 在 θ_0 上半连续 (u.s.c.), 若对任意包含 $C(\theta_0)$ 的开集 V , 存在 θ_0 的邻域 U , 使得 $\theta \in U$ 时 $C(\theta) \subseteq V$ 。
- 称 C 在 θ_0 下半连续 (l.s.c.), 若对任意与 $C(\theta_0)$ 相交的开集 V , 存在 θ_0 的邻域 U , 使得 $\theta \in U$ 时 $C(\theta) \cap V \neq \emptyset$ 。
- 称 C 连续, 若它在 θ_0 既上半连续又下半连续。

这两条定义初看绕, 但顺着“开集”读直觉立刻浮现。上半连续说: 无论你给 $C(\theta_0)$ 套一个多紧的开外套 V , 只要 θ 离 θ_0 够近, $C(\theta)$ 整个都还待在外套里——即 $C(\theta)$ 不会随 θ 的微动突然向外膨胀出去。下半连续则说: $C(\theta_0)$ 里任何一小块 (与之相交的开集 V) 所代表的点, 在邻近的 θ 处仍有 $C(\theta)$ 的点落在那里——即 $C(\theta_0)$ 里的点不会随 θ 的微动突然消失。

对应的两半, 对照函数的两半

上半连续 (不爆炸) 盯的是“ $C(\theta)$ 会不会在 $\theta \rightarrow \theta_0$ 时冒出 $C(\theta_0)$ 之外的多余部分”——等价地, 对紧值对应, $\text{u.s.c.} \iff$ 图像闭: $\theta_n \rightarrow \theta_0, x_n \in C(\theta_n), x_n \rightarrow x \Rightarrow x \in C(\theta_0)$ 。下半连续 (不塌缩) 盯的是“ $C(\theta_0)$ 里的点会不会在 θ 邻近时无法被逼近”: 对 $C(\theta_0)$ 中任一点 x 与任一 $\theta_n \rightarrow \theta_0$, 都能找到 $x_n \in C(\theta_n)$ 使 $x_n \rightarrow x$ 。一句口诀: u.s.c. 防膨胀 (图像闭), l.s.c. 防塌缩 (可逼近)。图 10.2 把两种“单边”失败画出来。




图 10.2: 对应的两种单边失败。左: $C(\theta) = \{\text{底线}\}$, 仅在 θ_0 处向上长成一整段——图像闭 (u.s.c.), 但那段无法被邻近的 $C(\theta)$ 逼近, 故非 l.s.c.。右: $C(\theta)$ 为一条带子, 却在 θ_0 处突然塌成一点——每个剩下的点都可被逼近 (l.s.c.), 但顶部极限点未纳入 $C(\theta_0)$, 图像不闭, 故非 u.s.c.。

注 (闭图像与上半连续的微妙)。

“图像闭”与“上半连续”在一般情形下并不完全等价：图像闭只是 u.s.c. 的必要条件，要它充分还需一个“不跑到无穷远”的条件。但在 Berge 定理用得着的场景里—— X 紧致，或对应取值落在某个紧集内——两者等价。本书后续凡谈 u.s.c. 对应，默认都在紧值（或局部紧）的框架下，届时“上半连续”与“闭图像”可放心互换。验一个对应是不是 u.s.c.，最省事的办法往往就是验它的图像是不是闭集。

例（预算集是关于价格连续的对应）。

固定收入 $w > 0$ ，价格 $p = (p_1, p_2) \gg 0$ ，预算集

$$B(p, w) = \{x \in \mathbb{R}_+^2 : p \cdot x \leq w\}$$

是一个把价格映到消费集合的对应 $B(\cdot, w) : \mathbb{R}_{++}^2 \rightrightarrows \mathbb{R}_+^2$ 。说明它在 $p \gg 0$ 处连续（图 10.3）。

解。

$B(p, w)$ 是以两轴截距 w/p_1 、 w/p_2 为顶点的实心三角形，非空、紧（有界闭）、凸。上半连续（不膨胀）：价格略升一点，三角形只会缩小或微动，不会突然冒出原来够不着的远处消费束——形式上，截距 w/p_i 是 p_i 的连续函数，故任给包住 $B(p, w)$ 的开集 V ， p 邻近时 $B(p', w) \subseteq V$ 。下半连续（不塌缩）：价格略变，原预算集里的任何消费束 x （满足 $p \cdot x \leq w$ ）都能被邻近价格下可负担的束逼近——只要把 x 沿原点方向稍微缩一点（ λx ， λ 略小于 1）就严格落入新预算集，再令 $\lambda \rightarrow 1$ 。两半都成立，故 $B(\cdot, w)$ 连续。这正是后面断言马歇尔需求“性态良好”的前提。




图 10.3: 预算集对应 $p \mapsto B(p, w)$ 。 p_1 上升时横截距 w/p_1 连续减小，三角形连续收缩——既不膨胀（u.s.c.）也不塌缩（l.s.c.），故连续。

10.4 参数化最优化与最大值定理

工具备齐，回到主问题。设参数空间 Θ 、选择空间 X 均为度量空间，给定

$$\text{目标函数 } f: X \times \Theta \rightarrow \mathbb{R}, \quad \text{约束对应 } C: \Theta \rightrightarrows X.$$

对每个参数 θ ，决策者求解 $\max_{x \in C(\theta)} f(x, \theta)$ ，由此定义两个对象：**值函数与最优解对应**

$$v(\theta) = \max_{x \in C(\theta)} f(x, \theta), \quad x^*(\theta) = \arg \max_{x \in C(\theta)} f(x, \theta) = \{x \in C(\theta) : f(x, \theta) = v(\theta)\}.$$

注意 v 是普通函数（最大值是个数），而 x^* 天然是个对应——最优解可能不唯一。我们要问： f 与 C 的连续性，能给 v 与 x^* 带来什么？答案就是 Berge 定理。

定理 10.4: Berge 最大值定理

设 Θ, X 为度量空间。若

- 目标函数 $f: X \times \Theta \rightarrow \mathbb{R}$ 连续（关于 (x, θ) 联合连续）；
- 约束对应 $C: \Theta \rightrightarrows X$ 在 θ_0 连续（既上半连续又下半连续）、且非空紧值，

则：

- 值函数 $v(\theta) = \max_{x \in C(\theta)} f(x, \theta)$ 在 θ_0 连续；
- 最优解对应 $x^*(\theta) = \arg \max_{x \in C(\theta)} f(x, \theta)$ 在 θ_0 非空、紧值、上半连续。

定理的结论里藏着一处不对称，值得先点破：值函数得到完整的连续，最优解却只得到“上”半。这不是证明做不到更好，而是事情本身如此——下一节会用一张图说明最优解为什么必然可能跳。下面给出证明骨架，分三块：紧值保证 v 良定义（最大值真的取得到）、 C 的下半连续 + f 上半连续保证 v 上半连续、 C 的上半连续 + f 下半连续保证 v 下半连续；两半合起来即 v 连续，而 x^* 的上半连续由图像闭推出。

证明. 第零步： v 与 x^* 良定义。 固定 θ 。因 $f(\cdot, \theta)$ 连续、 $C(\theta)$ 非空紧，由 Weierstrass 定理（第九章）最大值取得到，故 $v(\theta)$ 是有限数、 $x^*(\theta)$ 非空。又 $x^*(\theta)$ 是连续函数 $f(\cdot, \theta)$ 在紧集 $C(\theta)$ 上的最大值点集，它是闭集（最大值点的逆像）且含于紧集 $C(\theta)$ ，故紧。

第一步： v 下半连续（用 C 的下半连续）。 取 $\theta_n \rightarrow \theta_0$ 。设 $\hat{x} \in x^*(\theta_0)$ 是 θ_0 处的一个最优解， $v(\theta_0) = f(\hat{x}, \theta_0)$ 。由 C 在 θ_0 下半连续（不塌缩），存在 $x_n \in C(\theta_n)$ 使 $x_n \rightarrow \hat{x}$ 。这些 x_n 未必最优，但终归可行，故 $v(\theta_n) \geq f(x_n, \theta_n)$ 。令 $n \rightarrow \infty$ ，由 f 连续得 $f(x_n, \theta_n) \rightarrow f(\hat{x}, \theta_0) = v(\theta_0)$ ，于是

$$\liminf_n v(\theta_n) \geq \lim_n f(x_n, \theta_n) = v(\theta_0).$$

这正是 v 在 θ_0 下半连续。说到底, 约束不塌缩意味着旧的好选择在新参数下仍“近似可用”, 所以最优值不会向下掉。

第二步: v 上半连续 (用 C 的上半连续)。仍取 $\theta_n \rightarrow \theta_0$, 并取 $x_n \in x^*(\theta_n)$, 即 $v(\theta_n) = f(x_n, \theta_n)$ 。我们要证 $\limsup_n v(\theta_n) \leq v(\theta_0)$ 。 C 在 θ_0 上半连续且紧值, 可推知这些最优解 $\{x_n\}$ 终究被困在 θ_0 附近一个紧集里, 故有收敛子列 $x_{n_k} \rightarrow \bar{x}$; 再由 C 的图像闭 (u.s.c. + 紧值) 得 $\bar{x} \in C(\theta_0)$, 即 $\bar{x}$ 对 θ_0 可行。于是

$$\limsup_n v(\theta_n) = \lim_k f(x_{n_k}, \theta_{n_k}) = f(\bar{x}, \theta_0) \leq \max_{x \in C(\theta_0)} f(x, \theta_0) = v(\theta_0),$$

其中等号用 f 连续、不等号因 $\bar{x}$ 只是可行 (未必最优)。这正是 v 上半连续。背后的道理是, 约束不膨胀意味着新参数下的最优选择跑不到 θ_0 够不着的地方, 所以最优值不会向上冒。

第一、二步合起来即 v 在 θ_0 连续。

第三步: x^* 上半连续。在紧值框架下, 证 x^* 上半连续等价于证它图像闭。取 $\theta_n \rightarrow \theta_0$, $x_n \in x^*(\theta_n)$, $x_n \rightarrow x$; 要证 $x \in x^*(\theta_0)$ 。一方面 $x_n \in C(\theta_n)$, 由 C 图像闭得 $x \in C(\theta_0)$ (可行)。另一方面 $f(x_n, \theta_n) = v(\theta_n)$, 令 $n \rightarrow \infty$, 左边由 f 连续趋于 $f(x, \theta_0)$ 、右边由刚证得的 v 连续趋于 $v(\theta_0)$, 故 $f(x, \theta_0) = v(\theta_0)$, 即 x 是 θ_0 处的最优解。于是 x^* 图像闭, 从而上半连续。□

Berge 定理交付什么, 以及它对约束两半的“分工”要求

一句话: 目标连续 + 约束连续紧值 $\Rightarrow$ 最优值连续、最优解上半连续。证明里清清楚楚地暴露出约束的两半各管一头——

- 约束的下半连续 (不塌缩) 保住 v 不向下掉: 旧的好选择得在新约束下仍近似可用。
- 约束的上半连续 (不膨胀) 保住 v 不向上冒: 新约束下的最优解跑不出旧约束的“闭包”。

缺哪一半, v 就只剩对应的那半连续。这种“目标的连续 + 约束的连续, 按方向各保 v 的一半”的结构, 是半连续这套语言最漂亮的回报: 它让你能精确诊断“连续性是在哪一侧、因为哪个条件失效而坏掉”。

10.5 为什么最优解只能保证“上半连续”

定理把完整的连续给了 v , 却只把上半连续给了 x^* 。这道“缺口”不是技术遗憾, 而是经济现实: 最优选择本就可能随参数跳变。最干净的例子是两个候选峰高度此消彼长。

例 (最优解的跳变)。

设选择空间 $X = \{a, b\}$ 只有两个点 (或想成两处局部峰), 参数 $\theta \in \mathbb{R}$, 目标

$$f(a, \theta) = 1 - \theta, \quad f(b, \theta) = 1 + \theta, \quad C(\theta) = \{a, b\} \text{ (常对应)}.$$

求 v 与 x^* , 并观察 θ 越过 0 时的行为。

解.

逐点比较两个值: 当 $\theta < 0$ 时 $f(a, \theta) > f(b, \theta)$, 最优是 a ; 当 $\theta > 0$ 时反过来, 最优是 b ; 当 $\theta = 0$ 时两者都等于 1, 皆最优。于是

$$v(\theta) = \max\{1 - \theta, 1 + \theta\} = 1 + |\theta|, \quad x^*(\theta) = \begin{cases} a, & \theta < 0, \\ \{a, b\}, & \theta = 0, \\ b, & \theta > 0. \end{cases}$$

值函数 $v(\theta) = 1 + |\theta|$ 连续 (在 0 处有个折点, 但不跳); 最优解 x^* 在 $\theta = 0$ 处从 a “跳”到 b 。它是上半连续的: 在跳点 $\theta = 0$, x^* 把两个端点 a, b 都纳入 (图像闭), 所以 $\theta_n \rightarrow 0$ 时的最优解的极限仍在 $x^*(0)$ 里——没有膨胀出多余的点。但它不是下半连续: $x^*(0) = \{a, b\}$ 里的 b 无法被 $\theta < 0$ 一侧的最优解 (恒为 a) 逼近, 集合在跨过 0 时一侧“塌掉”了。

图 10.4 把这个机理画成连续光滑的版本: 两条候选值曲线的上包络给出连续 (带折点) 的 v , 而最优解在交点处从一支跳到另一支, 跳点把两支端点都收进来——这正是“上半连续、非下半连续”的标准相貌。




图 10.4: Berge 定理的“缺口”。上: 值函数 $v(\theta)$ 是两条候选值曲线的上包络, 连续 (θ_0 处有折点而不跳)。下: 最优解 $x^*(\theta)$ 在 θ_0 处从一支跳到另一支; 跳点把两支端点都纳入 $x^*(\theta_0)$ (两端实心、竖直虚段), 故上半连续——但不下半连续。

注 (什么时候 x^* 升级为连续函数) .

若再添一个条件—— $f(\cdot, \theta)$ 在凸集 $C(\theta)$ 上严格拟凹 (且 C 凸值) ——则最优解唯一, x^* 退化为单值; 单值的上半连续对应就是连续函数。于是“目标严格拟凹 + 约束连续凸紧值”给出 x^* 连续 (一条曲线、不跳)。这正是消费者理论里马歇尔需求为何通常是价格-收入的连续函数: 严格拟凹的效用挑出唯一最优束。一旦丢掉严格性 (如线性效用、完全替代品), 最优解就可能不唯一、随价格跳变——退回到“只上半连续”的一般相貌。

10.6 它通向何处

Berge 定理是那种“陈述一次、终身受用”的结论: 经济学里凡是“带约束、参数化”的最优化, 它的最优值与最优解的连续性, 第一反应就应该是搬出它。几处核心去处:

- **动态规划值函数的连续性** (见后文“压缩映射与 Banach 不动点”一章)。Bellman 算子 $(Tf)(s) = \max_{a \in \Gamma(s)} \{r(s, a) + \beta f(\phi(s, a))\}$ 每一步都是一个参数化最优化: 状态 s 是参数、行动 a 是选择、 $\Gamma(s)$ 是约束对应。Berge 定理保证: 只要瞬时收益 r 连续、可行集对应 Γ 连续紧值, T 就把连续函数映成连续函数。这恰是用压缩映射定理求值函数时需要的一块——它确保迭代停在“连续有界函数”这个完备空间里, 于是值函数本身连续。最优策略对应则由 Berge 给出上半连续。
- **马歇尔需求与间接效用** (消费者理论)。需求 $x^*(p, w) = \arg \max_{x \in B(p, w)} u(x)$ 正是以预算集对应 $B(\cdot)$ 为约束的参数化最优化。本章已验 B 连续紧值, 故 Berge 立得: 间接效用 $v(p, w)$ 连续、需求对应上半连续; 若 u 严格拟凹则需求是连续函数。这是需求理论一切比较静态的“地面”。
- **博弈的最优反应对应** (见后文“不动点定理”一章)。玩家 i 的最优反应 $BR_i(\sigma_{-i}) = \arg \max_{\sigma_i} u_i(\sigma_i, \sigma_{-i})$ 把对手策略组映到自己的最优策略集——又一个参数化最优化, 参数是 σ_{-i} 。Berge 定理保证它上半连续 (且在混合策略下凸值、紧值)。而上半连续 + 凸紧值, 恰恰是 **Kakutani 不动点定理** 对集值映射的全部要求——纳什均衡的存在性证明, 正是把 Berge 的输出直接喂给 Kakutani。这条“Berge $\rightarrow$ Kakutani $\rightarrow$ 纳什”的链路, 是博弈论存在性定理的标准脚手架。

把本章放回 Part II 的脉络: 第九章的 Weierstrass 定理回答“单个最优化的解存不存在”, 本章 Berge 定理回答“一族参数化最优化的解怎样随参数变化”, 下一章不动点定理则回答“自指的均衡存不存在”。三者环环相扣, 而把它们焊在一起的, 正是“半连续”这把按方向拆开连续性的尺子——它让我们能精准地说出, 在最优化与均衡的每一处, 到底需要“连续”的哪一半。

第十一章 不动点定理与均衡存在性

用到的前置工具：紧致性、连续性与 Weierstrass 极值定理（第九章）；上/下半连续与最大值定理（第十章）；凸集与凸性（线性代数与凸分析部分）。

经济学反复在做同一件事：先定义一个“均衡”，然后断言它存在。可一旦把这些均衡的定义摊开来看，会发现它们惊人地相似——纳什均衡是“每个人都在对别人的策略做最优反应”，瓦尔拉斯均衡是“一组价格使所有市场恰好出清”，理性预期均衡是“大家的预期被自身验证”。它们都可以写成同一句话：某个映射把一个点又送回了它自己。求均衡，就是求这个映射的不动点。于是“均衡存在吗”这个看似各式各样的问题，统统归约成一个纯数学问题：**这个映射有不动点吗？**本章介绍回答它的核心机器——Brouwer 与 Kakutani 两个不动点定理，并演示经济学里两座存在性大厦（纳什均衡、一般均衡）如何就建在它们之上。下一章的压缩映射定理会从另一个方向补全这套工具：本章的定理只问“在不在”，压缩映射还要回答“唯不唯一、怎么算出来”。

11.1 为什么“均衡”就是“不动点”

先把“不动点”这个词钉死。

定义 11.1: 不动点

设 X 是一个集合， $f: X \rightarrow X$ 是从 X 到自身的映射。点 $x^* \in X$ 称为 f 的不动点 (fixed point)，如果

$$f(x^*) = x^*.$$

若 f 是一个对应 (correspondence，即取值为集合的映射) $\Phi: X \rightrightarrows X$ ，则 x^* 称为不动点当且仅当 $x^* \in \Phi(x^*)$ 。

这个定义本身平淡无奇，要紧的是经济学里“均衡”几乎总能改写成它。看三个例子，它们贯穿微观、宏观与博弈论：

- **纳什均衡**。每个玩家 i 在给定别人策略 s_{-i} 时，选自己的最优反应 $R_i(s_{-i})$ 。把所有人的最优反应叠在一起，得到一个从策略组合到策略组合的映射 $R(s) = (R_1(s_{-1}), \dots, R_n(s_{-n}))$ 。一个策略组合是纳什均衡，当且仅当没人想偏离——也就是 $s^* = R(s^*)$ ，恰是 R 的不动点。
- **一般均衡**。给定价格向量 p ，市场有超额需求 $z(p)$ （需求减供给）。瓦尔拉斯均衡是一组使所有市场出清的价格，即 $z(p^*) = 0$ 。这看似是“求零点”而非“求不动点”，

但通过一个“按超额需求调价”的映射 $p \mapsto T(p)$ （哪个市场超额需求为正就抬高它的价），可以把“超额需求为零”等价改写成 $T(p^*) = p^*$ 。详见后文。

- **理性预期 / Bellman 方程**。“给定预期、最优反应生成同样的预期”是不动点；动态规划的 $V = TV$ 更是直接写成不动点方程（下一章主题）。

一句话的工具性总结

经济学里绝大多数“均衡”都是某个映射的不动点。因此“均衡存在”这一论断，本质上不依赖具体模型，而依赖一条纯数学事实：在恰当的条件下，从一个集合到自身的映射必有不动点。本章的两个定理就是把“恰当的条件”说清楚——一旦你能把均衡写成不动点、并核验那几条条件，存在性便免费奉送，无须解出均衡本身。这与隐函数定理的精神一脉相承：不解方程，照样断言解的存在。

11.2 Brouwer 不动点定理

最基本的版本针对单值连续映射。

定理 11.2: Brouwer 不动点定理

设 $K \subseteq \mathbb{R}^n$ 是非空、紧致、凸的集合， $f: K \rightarrow K$ 连续。则 f 至少有一个不动点 $x^* \in K$ ，即 $f(x^*) = x^*$ 。

三个条件一个都不能少，缺哪个都能举出反例（见本节末）。先看为什么它“显然”成立——至少在一维上是显然的。

11.2.1 一维：连续曲线必与对角线相交

取 $K = [0, 1]$ ， $f: [0, 1] \rightarrow [0, 1]$ 连续。不动点方程 $f(x) = x$ 说的是：函数 $y = f(x)$ 的图像与对角线 $y = x$ 相交。能不能不相交？

定义辅助函数 $g(x) = f(x) - x$ ，它连续。在左端点，因为 $f(0) \in [0, 1]$ ，必有 $f(0) \geq 0$ ，故 $g(0) = f(0) - 0 \geq 0$ ；在右端点，因为 $f(1) \leq 1$ ，故 $g(1) = f(1) - 1 \leq 0$ 。一个连续函数在 0 处非负、在 1 处非正，由介值定理必在中间某点 x^* 取零值，即 $g(x^*) = 0$ ，也就是 $f(x^*) = x^*$ 。

这段两行的论证已经道出 Brouwer 定理的全部直觉：一条从方块左壁出发、终于右壁、始终待在方块内的连续曲线，无论怎么扭，都逃不过被对角线拦腰截断（图 11.1）。“ f 把 K 映回 K ”（自映射）逼得曲线两端分别落在对角线的上、下两侧，“连续”又不许它跳过对角线——两者合力，交点无可避免。

注（一维是介值定理，高维不是）。

一维证明只用了介值定理，干净利落。但它无法照搬到高维： $\mathbb{R}^n$ （ $n \geq 2$ ）里没有“介值定理”这种把“连续”直接兑换成“过零”的初等工具。高维 Brouwer 的真正根基是拓扑——圆盘不能连续地收缩到它的边界圈上（“无收缩定理”）。一个组合化




图 11.1: 一维 Brouwer。连续自映射 $f: [0, 1] \rightarrow [0, 1]$ 的图像（蓝）从对角线 $y = x$ 上方（ $f(0) \geq 0$ ）出发、到下方（ $f(1) \leq 1$ ）收尾，无论中途怎样起伏，必与对角线交于某点——该点即不动点 x^* 。

的等价表述是 **Sperner 引理**：把单纯形作三角剖分并按规则给顶点染色，则必存在一个“三色俱全”的小单纯形；让剖分越来越细，这些小单纯形收缩到的极限点正是不动点。Brouwer 定理因此可由一个纯组合的计数事实推出。本书按使用者的需要，只陈述定理并讲透一维直觉，高维的拓扑证明留给拓扑课。

11.2.2 三个条件各自在防什么

把任一条件拿掉，不动点就可能消失。记住这三个反例，胜过记定理本身——它们告诉你定理“为什么是这副模样”。

- **丢掉紧致（去掉有界）**：在 $K = \mathbb{R}$ 上取平移 $f(x) = x + 1$ ，连续、把 $\mathbb{R}$ 映回 $\mathbb{R}$ 也是凸的，但 $f(x) = x$ 无解——点被无限地往外推，永不回头。紧致性（在 $\mathbb{R}^n$ 中即有界闭）堵死了“跑到无穷远”这条逃路。
- **丢掉紧致（去掉闭）**：在开区间 $K = (0, 1)$ 上取 $f(x) = x/2 + 1/2$ （把 $(0, 1)$ 映进 $(1/2, 1) \subset (0, 1)$ ），唯一的候选不动点是 $x = 1$ ，却不在开集 K 内。闭性保证“极限点不被漏掉”。
- **丢掉凸（用带洞的集合）**：在圆环 $K = \{x \in \mathbb{R}^2 : 1 \leq \|x\| \leq 2\}$ 上取“旋转 90° ”，连续、自映射、 K 紧致，但旋转没有不动点——中心那个本该被固定的点恰好是环上的“洞”，被挖掉了。凸性（无洞、无凹陷）封死了这种“绕着洞转”的可能。

注（凸可以放宽成“可缩”）。

真正起作用的是拓扑性质而非凸性本身：Brouwer 定理对任何与闭球同胚（更一般地，可缩）的紧集都成立，凸只是一个好用好查的充分条件。经济学里策略单纯形、价格单纯形天生是凸紧的，故直接用凸版本最省事。

11.3 从函数到对应：Kakutani 不动点定理

Brouwer 要求 f 是单值的连续函数。可经济学里的“最优反应”常常不是单值的：当一个玩家面对的若干策略带来相同的最高收益时，他的最优反应是一整个集合，而非一个点。这时 R 是一个对应（correspondence） $\Phi: K \rightrightarrows K$ ，Brouwer 不再适用。Kakutani 定理正是为对应量身定做的推广。

要把 Brouwer 的“连续”和“映回自身”翻译到对应上，需要两个概念：值是凸的、图像是闭的（即上半连续）。这两条恰好是上一章“最大值定理”里出现过的同一批性质，此处把它们组装成不动点的条件。

假设 11.3: Kakutani 所需的三件套（针对对应 $\Phi: K \rightrightarrows K$ ）

1. 非空凸值：对每个 $x \in K$ ，像集 $\Phi(x)$ 非空，且是 K 中的凸集。
2. 闭图像（等价于此处的上半连续）：图像 $\{(x, y) : y \in \Phi(x)\}$ 是闭集。即若 $x_n \rightarrow x$ 、 $y_n \in \Phi(x_n)$ 、 $y_n \rightarrow y$ ，则必有 $y \in \Phi(x)$ 。
3. 定义域 $K \subseteq \mathbb{R}^n$ 非空、紧致、凸（与 Brouwer 相同）。

定理 11.4: Kakutani 不动点定理

设 $K \subseteq \mathbb{R}^n$ 非空、紧致、凸，对应 $\Phi: K \rightrightarrows K$ 满足上面假设的非空凸值与闭图像。则 Φ 有不动点：存在 $x^* \in K$ 使得

$$x^* \in \Phi(x^*).$$

注（两个新条件分别在堵什么漏洞）。

当 Φ 退化为单值函数 f 时，“凸值”自动满足（单点集是凸的）、“闭图像”恰好等价于 f 连续，于是 Kakutani 收缩回 Brouwer——它是货真价实的推广。新加的两条各有所司：闭图像是“连续”对集值情形的正确替身，它不许像集在极限处“突然塌缩”漏掉极限点（详见上一章的上/下半连续）；凸值则不许像集“开裂成互不相连的两块”。少了凸值，对应可以在该穿过对角线的地方一跃而过那条裂缝、从不与对角线相交——例如 $K = [0, 1]$ 上令 $\Phi(x) = \{1\}$ （当 $x < \frac{1}{2}$ ）、 $\Phi(\frac{1}{2}) = \{0, 1\}$ 、 $\Phi(x) = \{0\}$ （当 $x > \frac{1}{2}$ ）：它在 $x = \frac{1}{2}$ 处的像 $\{0, 1\}$ 非凸（缺了中间的 $\frac{1}{2}$ ），图像虽闭却没有不动点。把那个像“填实”成整段 $[0, 1]$ ，凸值即恢复， $x = \frac{1}{2}$ 立刻成为不动点。这正是“凸值”不可或缺的理由。

为什么经济学偏偏需要 Kakutani 而非 Brouwer

“最优反应”天生是对应：平局（多个最优选择并存）一旦出现，最优反应就从一个点变成一个集合。混合策略恰好保证了这个集合是凸的——若两个纯策略都是最优的，对它们的任意概率混合也最优，于是最优反应集是这些最优策略的凸

包。因此在博弈论里 Kakutani 不是“更高级的选配”，而是标配：纳什 1950 年那篇奠基论文正是用 Kakutani（不是 Brouwer）证出了一般 n 人博弈混合策略均衡的存在。

11.4 应用一：纳什均衡的存在

这是 Kakutani 在经济学里最著名的应用。我们要证：任何有限博弈（有限玩家、每人有限纯策略）都存在混合策略纳什均衡。证明是一套可复用的“三步装配”——把均衡写成不动点、核验 Kakutani 的条件、收网。

11.4.1 搭好舞台：混合策略单纯形

设有 n 个玩家，玩家 i 的纯策略集为有限集 A_i ， $|A_i| = m_i$ 。玩家 i 的混合策略 σ_i 是 A_i 上的一个概率分布，即

$$\sigma_i \in \Delta_i = \left\{ \sigma_i \in \mathbb{R}_{\geq 0}^{m_i} : \sum_{a \in A_i} \sigma_i(a) = 1 \right\}.$$

这个 Δ_i 是 $(m_i - 1)$ 维单纯形——它非空、紧致、凸（有界闭且任意两概率分布的凸组合仍是概率分布）。所有玩家的混合策略组合构成

$$\Delta = \Delta_1 \times \cdots \times \Delta_n,$$

有限多个凸紧集的笛卡尔积仍然凸紧。**Kakutani** 对定义域的要求（凸、紧、非空）就此自动满足——这正是“选混合策略而非纯策略”带来的第一个红利：纯策略集是离散点集，谈不上凸；一“混合”就把它撑成了凸紧的单纯形。

玩家 i 的期望收益 $u_i(\sigma_i, \sigma_{-i})$ 是各方混合概率的多重线性函数（对每个 σ_j 都是线性的），从而连续，且对自己的 σ_i 线性（自然是凹的）——这两点马上要用。

11.4.2 把均衡写成最优反应对应的不动点

定义玩家 i 的最优反应对应

$$B_i(\sigma_{-i}) = \arg \max_{\sigma_i \in \Delta_i} u_i(\sigma_i, \sigma_{-i}) \subseteq \Delta_i,$$

再把所有人的拼起来，得到从 Δ 到自身的对应

$$B(\sigma) = B_1(\sigma_{-1}) \times \cdots \times B_n(\sigma_{-n}), \quad B: \Delta \rightrightarrows \Delta.$$

按定义， σ^* 是纳什均衡 $\iff$ 每个 i 都在最优反应 $\iff \sigma_i^* \in B_i(\sigma_{-i}^*)$ 对所有 i 成立 $\iff$

$$\boxed{\sigma^* \in B(\sigma^*)}.$$

均衡就是最优反应对应 B 的不动点（图 11.2）。剩下的全部工作，就是核验 B 满足 Kakutani 的两个条件。




图 11.2: 两人博弈的最优反应曲线（此处恰为单值，画成两条线）：玩家 1 对玩家 2 的最优反应 R_1 与玩家 2 对玩家 1 的最优反应 R_2 。二者的交点 s^* 满足 $s^* = B(s^*)$ ，即谁都不想偏离——这就是纳什均衡。Kakutani 定理保证这样的交点总存在。

11.4.3 核验 Kakutani 的条件

(1) 非空。对固定的 σ_{-i} ， $u_i(\cdot, \sigma_{-i})$ 是紧集 Δ_i 上的连续函数，由 Weierstrass 极值定理（第九章）最大值可达，故 $B_i(\sigma_{-i}) \neq \emptyset$ 。

(2) 凸值。关键一步。 $B_i(\sigma_{-i})$ 是 $u_i(\cdot, \sigma_{-i})$ 在 Δ_i 上的所有最大值点。因为 u_i 关于自己的混合策略 σ_i 是线性的（从而凹），其最大值点之集是凸集：若 σ'_i, σ''_i 都取到同一最高值，则它们的任意凸组合 $\lambda\sigma'_i + (1-\lambda)\sigma''_i$ 因线性也取到同样的值，仍是最优反应。混合策略的“可凸组合”与收益的线性，在这里合谋造出了凸值——这正是 Kakutani 的硬要求，也是 Brouwer 给不了的。

(3) 闭图像（上半连续）。这是“最大值定理”（Berge，第十章）的直接推论：当目标函数 u_i 连续、约束集 Δ_i 不随参数变（恒为同一紧集）时， $\arg \max$ 对应 B_i 上半连续、有闭图像。直观地说，沿着 $\sigma_{-i}^{(k)} \rightarrow \sigma_{-i}$ 取一系列最优反应 $\sigma_i^{(k)} \rightarrow \sigma_i$ ，由 u_i 连续，极限 σ_i 仍是对极限 σ_{-i} 的最优反应，不会“塌缩”漏掉。

笛卡尔积保持这三条性质，故乘积对应 $B: \Delta \rightrightarrows \Delta$ 满足 Kakutani 的全部前提。

11.4.4 收网

定理 11.5: 纳什存在性定理 (1950)

每个有限博弈都至少存在一个混合策略纳什均衡。

证明. 取定义域为混合策略单纯形之积 $\Delta = \Delta_1 \times \cdots \times \Delta_n$ ，它非空、紧致、凸。取对

应为最优反应 $B: \Delta \rightrightarrows \Delta$ 。上一小节已逐条核验： B 非空凸值、有闭图像。Kakutani 不动点定理于是断言存在 $\sigma^* \in \Delta$ 使 $\sigma^* \in B(\sigma^*)$ 。依 B 的定义，这等价于每个玩家都在对其余人做最优反应，即 σ^* 是纳什均衡。□

这套“三步装配”可以照搬

注意证明的骨架与具体博弈无关，是一套通用模板：**(i)** 把策略空间做成凸紧集（混合策略单纯形之积）；**(ii)** 把“均衡”写成某个对应（最优反应）的不动点 $\sigma^* \in B(\sigma^*)$ ；**(iii)** 用 Weierstrass 验非空、用目标函数对自变量的凹性验凸值、用最大值定理验闭图像，套 Kakutani 收网。后续遇到“存在某种均衡”的论断（贝叶斯纳什、相关均衡、议价解……），几乎都能套这个模板，只需替换“策略空间”与“最优反应”的具体内容。认得这副骨架，你就掌握了博弈论里大半存在性证明的通法。

注（纯策略未必存在，混合才是“闭包”下的对的对象）。

“石头剪刀布”没有纯策略纳什均衡：对任何纯策略组合，总有人想偏离。但它有混合均衡（各 1/3）。这说明纯策略层面问题无解，根子在于纯策略集是离散的、非凸的，不满足不动点定理的前提。引入混合策略，等于把离散点集取了“凸化闭包”，让单纯形登场，存在性才得以成立。用混合策略不是为了“更一般”，而是为了让不动点机器能够开动。

11.5 应用二：一般均衡的存在

第二座大厦是竞争性一般均衡（瓦尔拉斯均衡）的存在。思路与纳什如出一辙，只是“均衡”换成“价格使所有市场出清”，对应换成“按超额需求调价”。

设有 ℓ 种商品，价格向量 $\mathbf{p} = (p_1, \dots, p_\ell)$ 。各消费者在预算约束下最大化效用、各厂商最大化利润，加总得到超额需求函数 $\mathbf{z}(\mathbf{p}) = (z_1(\mathbf{p}), \dots, z_\ell(\mathbf{p}))$ ，其中 z_k 为第 k 种商品的市场需求减供给。两条标准性质至关重要：

假设 11.6: 超额需求的两条结构性质

1. 零次齐次： $\mathbf{z}(\lambda \mathbf{p}) = \mathbf{z}(\mathbf{p})$ 对一切 $\lambda > 0$ 。只有相对价格有意义，故可把价格规范化到单位单纯形

$$\Delta = \{ \mathbf{p} \in \mathbb{R}_{\geq 0}^\ell : \sum_k p_k = 1 \},$$

它非空、紧致、凸——又是单纯形，又一次满足 Kakutani / Brouwer 对定义域的要求。

2. 瓦尔拉斯法则： $\mathbf{p} \cdot \mathbf{z}(\mathbf{p}) = 0$ 对一切 $\mathbf{p}$ 成立（每个消费者花光预算，加总后总支出恒等于总收入）。它的含义是：超额需求的“价值”恒为零。

目标是找 $\mathbf{p}^* \in \Delta$ 使 $\mathbf{z}(\mathbf{p}^*) \leq \mathbf{0}$ (自由处置下, 出清允许免费品供过于求)。把它化成不动点: 定义调价映射 $T: \Delta \rightarrow \Delta$,

$$T_k(\mathbf{p}) = \frac{p_k + \max\{0, z_k(\mathbf{p})\}}{1 + \sum_{j=1}^{\ell} \max\{0, z_j(\mathbf{p})\}}, \quad k = 1, \dots, \ell.$$

读法很直白: 哪种商品超额需求为正 ($z_k > 0$, 供不应求), 就抬高它的价格 p_k ; 分母只是把结果重新规范化回单纯形 Δ 。这个 T 连续 ($\mathbf{z}$ 连续、 $\max\{0, \cdot\}$ 连续)、把凸紧的 Δ 映回自身, 由 **Brouwer** 定理有不动点 $\mathbf{p}^* = T(\mathbf{p}^*)$ 。

剩下要说明: 这个不动点 $\mathbf{p}^*$ 正是均衡。在不动点处, 对每个 k ,

$$p_k^* = \frac{p_k^* + \max\{0, z_k(\mathbf{p}^*)\}}{1 + \sum_j \max\{0, z_j(\mathbf{p}^*)\}}.$$

记 $S = \sum_j \max\{0, z_j(\mathbf{p}^*)\} \geq 0$, 整理得 $p_k^* S = \max\{0, z_k(\mathbf{p}^*)\}$ 。两边同乘 $z_k(\mathbf{p}^*)$ 再对 k 求和: 左边 $= S \sum_k p_k^* z_k(\mathbf{p}^*) = S \cdot (\mathbf{p}^* \cdot \mathbf{z}) = 0$ (瓦尔拉斯法则); 右边 $= \sum_k z_k(\mathbf{p}^*) \max\{0, z_k(\mathbf{p}^*)\} = \sum_k (\max\{0, z_k(\mathbf{p}^*)\})^2 \geq 0$ 。一个非负的平方和等于零, 逼出每一项都是零, 即 $\max\{0, z_k(\mathbf{p}^*)\} = 0$, 也就是 $z_k(\mathbf{p}^*) \leq 0$ 对所有 k 。所有市场出清 (或免费品供过于求), $\mathbf{p}^*$ 是瓦尔拉斯均衡。

定理 11.7: 瓦尔拉斯均衡存在性 (要点版)

若超额需求 $\mathbf{z}$ 在价格单纯形 Δ 上连续、零次齐次并满足瓦尔拉斯法则, 则存在 $\mathbf{p}^* \in \Delta$ 使 $\mathbf{z}(\mathbf{p}^*) \leq \mathbf{0}$, 即竞争性一般均衡存在。

注 (严格证明要小心边界)。

上面用 Brouwer 的论证抓住了全部直觉, 但严格处理时有个技术麻烦: 某些价格趋于零 (某商品免费) 时需求可能爆炸, $\mathbf{z}$ 在 Δ 边界上未必连续或有界。Arrow 与 Debreu (1954) 的经典证明正是在此处下功夫——他们用 **Kakutani** (而非 Brouwer), 把消费者与厂商的最优选择直接处理成上半连续、凸值的需求/供给对应, 绕开了为超额需求显式造调价映射的边界难题。无论走 Brouwer 还是 Kakutani, 机器都是同一台不动点定理; 差别只在如何驯服边界。本书取 Brouwer 版以突出主干直觉。

11.6 它通向何处: 存在 vs. 唯一与构造

本章把“均衡存在”统一成了“不动点存在”, 并交给两台机器: 单值的 Brouwer、集值的 Kakutani。但它们只回答一个字——在。两件经济学家同样在意的事, 它们一概不管。

不动点定理给什么、不给什么

Brouwer 与 Kakutani 用拓扑条件 (凸、紧、连续 / 上半连续) 换来一般的存在性, 但既不保证唯一、也不告诉你怎么算。证明本身是非构造性的——它断言不动点在那儿, 却不交给你一条找到它的路径。多重均衡 (多个不动点) 在博弈论

与宏观里司空见惯，恰恰因为存在性定理对个数缄默。要补上“唯一”与“可计算”，得换一套更强的条件：**压缩映射**（下一章）。它对映射要求得更苛刻（一致地缩小距离），回报却是存在、唯一、外加一个保证收敛的迭代算法三者兼得。两章合起来才是完整的工具箱：Brouwer / Kakutani 管“有没有”，Banach 管“不唯一、怎么算”。

把本章这把工具接回经济学主干，它的去处主要有三处：

- **博弈论：纳什存在**（本章已证）。它是非合作博弈全部理论的入场券——没有这条存在性，“求解均衡”就成了无的放矢。贝叶斯纳什均衡、相关均衡、子博弈完美均衡的存在性，骨架都沿用本章的“Kakutani 三步装配”。
- **一般均衡：瓦尔拉斯均衡存在**（本章已证）。Arrow-Debreu 模型的存在性定理是现代价格理论的基石；福利经济学两大定理则进一步把这个均衡与帕累托最优挂钩。
- **动态规划：值函数的存在与唯一**。Bellman 方程 $V = TV$ 是不动点方程，但它活在无穷维的函数空间里——Brouwer 要的有限维凸紧集失效了，且这里真正需要的是“唯一 + 可迭代算出”，这正是**压缩映射**的主场（下一章建立压缩映射这件工具；完整的动态规划理论见 Part VII）。本章与下一章因此分工明确：拓扑给一般的存在（博弈、一般均衡），度量给存在加唯一加构造（值函数）。

这再次印证了本书的主线：认清“均衡即不动点”这一个抽象，许多看似无关的存在性问题，便归约成了同一个数学事实。

第十二章 压缩映射与 Banach 不动点定理

用到的前置工具：度量空间、序列收敛与完备性（第八章）；上一章的不动点定理（Brouwer、Kakutani）作对照；后文用到的范数与上确界（线性代数部分）。

上一章的 Brouwer 与 Kakutani 定理回答了“不动点在不在”——只要空间是凸紧的、映射连续，不动点就存在。但它们对两件经济学家同样在乎的事一概不答：这个不动点唯一吗？要怎么把它算出来？本章的压缩映射定理（即 Banach 不动点定理）正好补上这两块：它对映射要求得更苛刻（必须把距离一致地“压缩”），换来的回报也更丰厚——不仅给出存在性，还白送了唯一性、一个收敛的迭代算法，以及一个能事先估计算到第几步够精确的误差界。这套“存在 + 唯一 + 可计算”的组合，正是动态规划全部理论的地基：它保证 Bellman 方程的解（值函数）存在且唯一，并保证值迭代真的会收敛到它。本章先把压缩与定理本身讲透，再引出 Blackwell 那两个一眼可查的充分条件，最后落到 Bellman 算子上。

12.1 为什么需要“压缩”这个更强的条件

经济学里反复出现同一个数学动作：求解一个“自指”的方程

$$x = T(x),$$

即寻找映射 T 的不动点。理性预期均衡是“给定大家的预期、最优反应又生成同样的预期”；一般均衡的超额需求为零可化为一个不动点方程；而动态规划的核心——Bellman 方程 $V = TV$ ——根本就是一句“值函数等于自己经 Bellman 算子作用后的像”。

上一章的工具能断言这类不动点存在，却止步于此。可经济学常常还要追问两件事。其一，**唯一性**：若均衡（或值函数）不唯一，“比较静态”就无从谈起，模型的预测也含糊。其二，**可计算性**：现实中我们几乎从不解析地解出不动点，而是从某个初值出发反复迭代 $x_{n+1} = T(x_n)$ ，指望它收敛——但凭什么收敛？收敛到哪个不动点？Brouwer 定理对此一律沉默。

压缩条件就是为同时拿下这两件事而设的。直觉是：如果 T 把任意两点之间的距离都按同一个小于 1 的比例缩小，那么反复作用 T ，相邻迭代点会越来越靠近、挤成一个收敛的序列；而两个不同的不动点之间的距离作用一次本该缩小、却又必须保持不变（不动点嘛），这个矛盾逼出唯一性。下面把它形式化。

12.2 压缩映射

定义 12.1: 压缩映射

设 (X, d) 是度量空间。映射 $T: X \rightarrow X$ 称为**压缩映射** (contraction), 若存在常数 $c \in [0, 1)$, 使得对一切 $x, y \in X$ 都有

$$d(T(x), T(y)) \leq c d(x, y).$$

此 c 称为**压缩系数** (或压缩模)。

请把这个定义和它的“近亲”仔细分清, 差别全在那个 c 上 (图 12.1)。

注 (与 Lipschitz、与非扩张的区别)。

若上式中只要求某个常数 $L < \infty$ (不必小于 1) 成立, T 叫做 **Lipschitz 连续** (模为 L); 若 $L = 1$ (即 $d(T(x), T(y)) \leq d(x, y)$) 叫**非扩张** (nonexpansive)。压缩是“Lipschitz 模严格小于 1”这一最强情形。这个“严格”至关重要: 恒等映射 $T(x) = x$ 是非扩张的 ($c = 1$), 它的不动点多到铺满全空间——可见一旦放松到 $c = 1$, 唯一性立刻崩塌。平移 $T(x) = x + 1$ 同样非扩张却根本没有不动点。正是 $c < 1$ 把这些病态情形挡在门外。




图 12.1: 压缩映射把输入端的距离 $|x - y|$ 一致地压缩到输出端更短的距离 $|T(x) - T(y)| \leq c|x - y|$ (这里 $c < 1$)。曲线越平缓, 压缩得越狠。

注 (怎么验一个映射是不是压缩)。

在 $X \subseteq \mathbb{R}$ (或 $\mathbb{R}^n$ 取适当范数) 上, 最常用的判据来自中值定理: 若 T 可微且导数 (在多维是 Jacobian 的范数) 一致地被某个 $c < 1$ 界住,

$$\sup_x |T'(x)| = c < 1,$$

则 T 是以 c 为系数的压缩。直觉就是图 12.1 里“曲线斜率处处平缓”。注意这要求是一致的上界——只在某一点斜率小于 1 远远不够。

12.3 Banach 不动点定理

现在给出本章的主定理。它的力量在于结论之多: 一句压缩, 换来存在、唯一、构造性收敛、外加误差界四件事。

定理 12.2: Banach 不动点定理 (压缩映射原理)

设 (X, d) 是非空完备度量空间, $T: X \rightarrow X$ 是压缩系数为 $c \in [0, 1)$ 的压缩映射。则:

- (存在唯一) T 有且仅有一个不动点 $x^* \in X$, 即 $T(x^*) = x^*$ 。
- (全局收敛) 任取初值 $x_0 \in X$, 迭代 $x_{n+1} = T(x_n)$ 都收敛到 x^* 。
- (误差界) 收敛是几何 (线性) 速率的, 且有先验与后验两个误差估计:

$$d(x_n, x^*) \leq \frac{c^n}{1-c} d(x_1, x_0), \quad d(x_n, x^*) \leq \frac{c}{1-c} d(x_n, x_{n-1}).$$

证明本身就是一份“如何用完备性把序列收敛兑现成不动点”的范本, 值得逐步看清。

证明. 第一步: 迭代序列是 Cauchy 列。 固定 x_0 , 令 $x_{n+1} = T(x_n)$ 。把压缩性反复用在相邻两项上:

$$d(x_{n+1}, x_n) = d(T(x_n), T(x_{n-1})) \leq c d(x_n, x_{n-1}) \leq \cdots \leq c^n d(x_1, x_0).$$

于是相邻步长以几何速率衰减。对任意 $m > n$, 用三角不等式把跨度拆成一串相邻步长再求和:

$$d(x_m, x_n) \leq \sum_{k=n}^{m-1} d(x_{k+1}, x_k) \leq \sum_{k=n}^{m-1} c^k d(x_1, x_0) \leq d(x_1, x_0) \sum_{k=n}^{\infty} c^k = \frac{c^n}{1-c} d(x_1, x_0).$$

最后一步用了 $c < 1$ 时几何级数收敛 (这正是“ $c < 1$ ”第一次出力的地方)。当 $n \rightarrow \infty$, 右端 $\rightarrow 0$, 故 $\{x_n\}$ 是 Cauchy 列。

第二步: 用完备性取极限。 X 完备, 意味着每个 Cauchy 列都在 X 内有极限。于是存在 $x^* \in X$ 使 $x_n \rightarrow x^*$ 。这一步是完备性唯一被用到、也是不可或缺的地方: 在不

完备的空间里，迭代点可能挤向一个“本该是极限却不在空间里”的洞，定理随之失效（见后文注）。

第三步：极限是不动点。压缩映射必连续（取 Lipschitz 模 c 即知）。对 $x_{n+1} = T(x_n)$ 两边令 $n \rightarrow \infty$ ，左边 $x_{n+1} \rightarrow x^*$ ，右边 $T(x_n) \rightarrow T(x^*)$ （连续性），故 $x^* = T(x^*)$ 。

第四步：唯一性。设 x^* 与 y^* 都是不动点，则

$$d(x^*, y^*) = d(T(x^*), T(y^*)) \leq c d(x^*, y^*).$$

移项得 $(1-c)d(x^*, y^*) \leq 0$ 。因 $1-c > 0$ ，只能 $d(x^*, y^*) = 0$ ，即 $x^* = y^*$ 。这里 $c < 1$ 第二次出力：它让“距离缩小”与“不动点距离不变”互相矛盾。

第五步：误差界。在第一步那条 $d(x_m, x_n) \leq \frac{c^n}{1-c} d(x_1, x_0)$ 中令 $m \rightarrow \infty$ ($x_m \rightarrow x^*$ ，而度量对极限连续)，即得先验界

$$d(x_n, x^*) \leq \frac{c^n}{1-c} d(x_1, x_0).$$

后验界同理：从第 n 步起把序列看成新的迭代，得 $d(x_n, x^*) \leq \frac{c}{1-c} d(x_n, x_{n-1})$ 。□

Banach 定理一口气给了你四样东西

对照上一章：Brouwer / Kakutani 只回答**存在**，靠的是凸紧 + 连续这类拓扑条件，证明深而非构造性，对唯一与计算一概不管。Banach 定理换了一类条件（压缩，一个度量条件），代价是要求更强，回报是一次拿到四样：**(1) 存在、(2) 唯一、(3) 从任意初值迭代都收敛、(4) 几何收敛速率 + 可事先估计的误差界**。第 (3)(4) 两条尤其关键：它们把“不动点”从一个抽象的存在性对象，变成了一个你真能在计算机上算出来、并且知道要算几步的东西。这正是它成为数值不动点求解“工作马”的原因。

误差界里两条估计的分工值得记住。**先验界** (a priori) 只用第一步 $d(x_1, x_0)$ 就能在开算之前算出：要把误差压到 ε 以下，需迭代约 $n \approx \log(\varepsilon(1-c)/d(x_1, x_0))/\log c$ 步——压缩系数 c 越接近 1，所需步数越多、收敛越慢。**后验界** (a posteriori) 则用当前这一步的实际位移 $d(x_n, x_{n-1})$ 给出更紧的实时估计，是写迭代程序时的天然停机准则：一旦相邻两步挪动得足够小，就知道离真解已经足够近。

收敛的几何图像最直观呈现，是“蛛网图”（图 12.2）：在 (x_n, x_{n+1}) 平面上画出曲线 $y = T(x)$ 与对角线 $y = x$ ，不动点恰是二者的交点；从 x_0 出发，“竖到曲线、横到对角线”交替前进，因 T 平缓（斜率绝对值 < 1 ），台阶逐级缩小、稳稳收向交点。而误差以 c^n 的速率衰减、剩余距离被几何尾和 $\frac{c}{1-c}d_0$ 兜住的样子，见图 12.3。

注（完备性与“闭”缺一不可）。

两处常被忽略的前提都不能省。其一，**完备性**：在 $X = (0, 1]$ 上取 $T(x) = x/2$ ，它是系数 $1/2$ 的压缩，但 $(0, 1]$ 不完备，迭代 $x_n = x_0/2^n \rightarrow 0 \notin X$ ，于是没有不动点。其二， T 必须把 X 映回 X 自身 ($T: X \rightarrow X$)；若只在某个子集上压缩、却会把点甩出该子集，定理同样不适用——实践中常用的办法是先找一个 T 不变的闭子集 ($\mathbb{R}^n$ 中的闭集自动完备)，再在其上用定理。




图 12.2: 压缩迭代的蛛网图: 从 x_0 出发, “竖到曲线、横到对角线” 交替前进。因 T 平缓, 台阶逐级缩小, 迭代稳稳收敛到曲线与 45° 线的交点——唯一不动点 x^* 。




图 12.3: 几何收敛与误差界。相邻迭代步长以 c^k 衰减; 从任一步到不动点的剩余距离被几何尾和兜住, 故 $d(x_n, x^*) \leq \frac{c^n}{1-c} d(x_1, x_0)$ 。

例 (把 Banach 定理用作 “求根器”)。

求方程 $x = \cos x$ 的解。直接解不出来, 但右端 $T(x) = \cos x$ 在 $\mathbb{R}$ 上满足 $|T'(x)| = |\sin x| \leq 1$, 还不够 (端点取等)。把定义域收到不变闭区间 $[0, 1]$: T 把 $[0, 1]$ 映入 $[\cos 1, 1] \subset [0, 1]$, 且在其上 $|T'(x)| = \sin x \leq \sin 1 \approx 0.841 < 1$ 。故 T 是 $[0, 1]$ (完备) 上系数 $c = \sin 1$ 的压缩。

解。

从 $x_0 = 0.5$ 迭代 $x_{n+1} = \cos x_n$, 序列稳步收敛到 $x^* \approx 0.739085$ (即 Dottie 数)。它存在且唯一由 Banach 定理保证; 要预知精度, 用先验界: $d(x_1, x_0) = |\cos 0.5 - 0.5| \approx 0.378$, 于是

$$d(x_n, x^*) \leq \frac{c^n}{1-c} (0.378), \quad c = \sin 1 \approx 0.841.$$

因 c 颇接近 1, 先验界给出的步数偏多——要 10^{-6} 的精度, 按 $\frac{c^n}{1-c} (0.378) \leq 10^{-6}$ 解出 $n \approx 85$ (取整到 86 步)。先验界本就保守, 实际迭代约 32 步即已达到这一精度。无论如何, 这把 “解超越方程” 彻底变成了 “反复按计算器的 $\cos$ 键”, 且事先就知道一个稳妥的步数上界。

12.4 Blackwell 充分条件

Banach 定理虽好，用在动态规划上却有个现实障碍：直接验证 Bellman 算子 T 满足 sup-范数下的压缩不等式，往往要和绝对值、上确界缠斗一番，不直观也容易出错。Blackwell 给出两条一眼可查的充分条件，专为这类“函数空间上的算子”量身定制：只要算子保持单调、并对函数加常数有折现效应，它就自动是压缩。这正是宏观经济学里证明 Bellman 算子是压缩的标准做法。

先固定舞台：设 $X \subseteq \mathbb{R}^n$ ，考虑有界函数空间 $B(X)$ ，配上确界范数 $\|f\|_\infty = \sup_{s \in X} |f(s)|$ 。这个空间是完备的（一致收敛的极限仍有界），故可在其上动用 Banach 定理。算子 $T: B(X) \rightarrow B(X)$ 作用在函数上、产出新函数。

定理 12.3: Blackwell 充分条件

设 $T: B(X) \rightarrow B(X)$ 满足以下两条：

- **(单调性)** 若 $f, g \in B(X)$ 满足 $f(s) \leq g(s)$ 对一切 s 成立，则 $(Tf)(s) \leq (Tg)(s)$ 对一切 s 成立。
- **(折现)** 存在常数 $\beta \in [0, 1)$ ，使得对任意常数 $a \geq 0$ 与任意 $f \in B(X)$ ，

$$(T(f+a))(s) \leq (Tf)(s) + \beta a \quad \text{对一切 } s,$$

其中 $f+a$ 指处处加上常数 a 的函数。

则 T 是 $B(X)$ （配 sup-范数）上系数为 β 的压缩映射。

证明。 取任意 $f, g \in B(X)$ 。由 sup-范数的定义，对一切 s 有

$$f(s) \leq g(s) + \|f - g\|_\infty,$$

因为 $f(s) - g(s) \leq \sup_s |f - g| = \|f - g\|_\infty$ 。把右端看成函数 g 处处加上常数 $a := \|f - g\|_\infty \geq 0$ ，于是 $f \leq g + a$ 。对两边用单调性，再用折现：

$$Tf \leq T(g+a) \leq Tg + \beta a = Tg + \beta \|f - g\|_\infty.$$

即对一切 s ： $(Tf)(s) - (Tg)(s) \leq \beta \|f - g\|_\infty$ 。 f, g 地位对称，互换再来一遍得反向不等式，合起来

$$|(Tf)(s) - (Tg)(s)| \leq \beta \|f - g\|_\infty \quad (\forall s) \implies \|Tf - Tg\|_\infty \leq \beta \|f - g\|_\infty.$$

这正是系数 β 的压缩。 □

Blackwell 把“验压缩”降格成“查两条性质”

Blackwell 条件之所以好用，在于它只是充分而非必要，却覆盖了经济学里几乎所有重要算子；而它要查的两件事都极其直观——**单调性**（“喂进去更大的值函数，吐出来也更大”）几乎对任何“取最大值 + 求期望”的算子自动成立；**折现**（“未来统一抬高 a ，今天的现值只抬高 βa ”）的常数 β 就是模型里的折现因子，白纸黑字摆在那里。两条一查，压缩系数当场读出 $= \beta$ ，再接 Banach 定理，存在唯一与值迭代收敛一气呵成。

12.5 应用：Bellman 算子是压缩

现在把一切收束到动态规划的核心。考虑标准的（确定性或随机）无限期折现问题：状态 $s \in X$ 、行动 $a \in \Gamma(s)$ 、当期收益 $r(s, a)$ 有界、折现因子 $\beta \in [0, 1)$ 、状态按 $s' = \phi(s, a)$ （或某转移核）演化。定义 **Bellman 算子** T ，它把一个候选值函数 f 变成新函数：

$$(Tf)(s) = \max_{a \in \Gamma(s)} \left\{ r(s, a) + \beta f(\phi(s, a)) \right\}.$$

（随机情形把 $f(\phi(s, a))$ 换成条件期望 $\mathbb{E}(f(s') | s, a)$ ，下述论证一字不改。）所谓 **Bellman 方程**就是不动点方程 $V = TV$ ，其解 V 即值函数。我们要的正是：这个 V 存在、唯一，且从任意初值做值迭代 $V_{n+1} = TV_n$ 都收敛到它。验两条 Blackwell 条件即可。

单调性。 设 $f \leq g$ （处处）。对任意 s 与任意可行 a ，因 $\beta \geq 0$ 有

$$r(s, a) + \beta f(\phi(s, a)) \leq r(s, a) + \beta g(\phi(s, a)).$$

逐点占优的两族数，取最大值后仍占优，故 $(Tf)(s) \leq (Tg)(s)$ 。单调性成立——它本质上只用到“收益里 f 前的系数 $\beta \geq 0$ ”与“max 保序”。

折现。 对常数 $a \geq 0$ ：

$$\begin{aligned} (T(f + a))(s) &= \max_{a' \in \Gamma(s)} \left\{ r(s, a') + \beta (f(\phi(s, a')) + a) \right\} \\ &= \max_{a' \in \Gamma(s)} \left\{ r(s, a') + \beta f(\phi(s, a')) \right\} + \beta a = (Tf)(s) + \beta a. \end{aligned}$$

（常数 βa 与被最大化的 a' 无关，可提到 max 外。）折现条件以等号成立，其中的系数恰是折现因子 $\beta < 1$ 。

两条都满足，由 Blackwell 定理， T 是 sup-范数下系数 β 的压缩；而有界函数空间 $B(X)$ 完备。于是 Banach 定理一次性交付动态规划的三块地基：

动态规划的地基，就是本章这把工具

Bellman 算子 T 是压缩，立刻推出：

- **值函数存在且唯一**——Bellman 方程 $V = TV$ 有唯一解 V 。“值函数”这个概念因此良定义，无歧义。

- **值迭代收敛**——从任意初猜 V_0 (哪怕 $V_0 \equiv 0$) 反复作用 T , $V_n \rightarrow V$, 且误差以 β^n 几何衰减: $\|V_n - V\|_\infty \leq \frac{\beta^n}{1-\beta} \|V_1 - V_0\|_\infty$ 。这就是数值动态规划最基本的算法, 连“算几步够”都由误差界回答。
- **折现因子 β 即收敛速率**—— β 越接近 1 (越有耐心), 压缩越弱、值迭代越慢。这条朴素事实在校准与数值实践中天天碰到。

策略迭代 (policy iteration) 的收敛同样根植于此: 每步策略评估解的是一个线性不动点、策略改进由 T 的单调性保证不变差, 整体仍以压缩为骨架。

注 (为什么不直接用上一章的 Brouwer) .

值函数空间是无穷维的函数空间, 而 Brouwer 定理要的是有限维凸紧集; 推广到无穷维的 Schauder 不动点定理虽存在, 却仍只给存在性、不给唯一与算法。动态规划真正需要的是“唯一 + 可迭代计算”, 这恰是压缩映射的主场而非 Brouwer 的。两章合看, 分工一目了然: **Brouwer / Kakutani** 用拓扑条件换来一般的存在性 (博弈论纳什均衡、一般均衡的存在), **Banach** 用更强的度量条件 (压缩) 换来存在 + 唯一 + 构造性算法 (动态规划的值函数)。

12.6 它通向何处

本章这把工具的去处高度集中, 却都在经济学的要害上:

- **动态规划与递归方法** (动态最优化部分) 是它最大的主场。值函数的存在唯一、值迭代与策略迭代的收敛、乃至“猜一个函数形式再验证”的待定系数法能成立, 根都在 Bellman 算子是压缩。随机动态规划只是把期望接进算子, 论证不变。
- **隐函数定理的存在性证明** (见前文“隐函数定理”一章)。我们在那里把“ $x^*(p)$ 存在且可微”当作已知, 其严格证明的标准路线之一正是构造一个压缩映射、用 Banach 定理产出那条隐函数——本章补上了那处欠条。
- **数值求解不动点**是它在计算经济学里的日常身份: 理性预期均衡、一般均衡价格、博弈的对称均衡, 凡能写成 $x = T(x)$ 且 T (在合适范数下) 压缩的, 都能用简单迭代稳稳求出, 且有现成的误差界与停机准则。
- **Markov 链的遍历性** (随机过程部分) 与本章同源: 若转移算子在某个度量 (如总变差或 Wasserstein) 下压缩, 平稳分布便存在唯一、且任意初始分布迭代都收敛到它——又是一则 Banach 定理的化身。

把它和上一章并置, 本书的一个主线就清楚了: 面对“不动点存不存在”, 拓扑给一类答案 (Brouwer/Kakutani), 度量给另一类答案 (Banach); 前者宽松而只问存在, 后者严格而存在、唯一、可算三者兼得。经济学家两类都要——博弈与一般均衡多用前者, 动态规划专用后者。认准了“压缩”这一个条件, 就等于同时握住了动态规划全部理论的钥匙。

第三部分

多元微积分与比较静态

第十三章 偏导、梯度、Jacobian 与 Hessian

用到的前置工具：单变量微分（导数即局部线性逼近的斜率）；向量与矩阵、转置与矩阵乘法（线性代数部分）；正定矩阵的概念将在二阶条件处用到（对称矩阵与正定性，线性代数部分）。

单变量微积分里，“导数”是一个明确无误的对象：一个数，曲线在某点的斜率，也是该点附近最好的线性逼近的斜率。可经济学里要求导的函数几乎从来不是一元的——效用是消费束的函数，利润是一组投入的函数，似然是一整个参数向量的函数。一旦自变量变成向量、甚至因变量也变成向量，“导数”该长什么样？它还是一个数吗，还是一个向量、一个矩阵？

本章的任务，是把“多元函数的导数”这件事一次配齐。结论可以先剧透：随着“输入维数”和“输出维数”的不同，导数会呈现为三种形态——标量函数的导数是一个向量（**梯度**），向量值映射的导数是一个矩阵（**Jacobian**），而把标量函数求两次导得到的二阶信息又是一个矩阵（**Hessian**）。这三件套不是三件孤立的东西，它们共享同一个内核：导数就是最好的局部线性逼近。认清这个内核，最优化的一阶/二阶条件、隐函数定理与比较静态、概率里的变量变换、计量里的 Delta 法，才会显出它们其实是同一把工具在不同场合的化身。

13.1 偏导数与方向导数

最朴素的想法是：要看多元函数怎么变，就一次只动一个变量，其余按住不动。这就是偏导数。

定义 13.1: 偏导数

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $\mathbf{x} = (x_1, \dots, x_n)^\top$ 。 f 关于第 i 个变量的偏导数是

$$\frac{\partial f}{\partial x_i}(\mathbf{x}) = \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + h \mathbf{e}_i) - f(\mathbf{x})}{h},$$

其中 $\mathbf{e}_i$ 是第 i 个标准基向量。它就是把除 x_i 外的所有变量当常数、对 x_i 求的普通一元导数。

偏导数好算（按一元规则机械求导即可），但它有一个明显的局限：它只告诉你沿

坐标轴方向走时 f 的变化率。可经济学里关心的方向常常是斜的——预算线、等产量线、一条价格变动的路径，都不平行于坐标轴。要问“沿任意一个给定方向走， f 变多快”，就需要方向导数。

定义 13.2: 方向导数

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $\mathbf{u} \in \mathbb{R}^n$ 为一个单位向量 ($\|\mathbf{u}\| = 1$)。 f 在 $\mathbf{x}$ 处沿方向 $\mathbf{u}$ 的方向导数是

$$D_{\mathbf{u}}f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t} = \left. \frac{d}{dt} f(\mathbf{x} + t\mathbf{u}) \right|_{t=0}.$$

把 $g(t) = f(\mathbf{x} + t\mathbf{u})$ 看成沿直线 $\mathbf{x} + t\mathbf{u}$ 切出的一条一元曲线，方向导数就是它在 $t = 0$ 处的斜率。偏导数是方向导数取 $\mathbf{u} = \mathbf{e}_i$ 的特例。

注（偏导数全部存在，并不保证函数“光滑”）。

偏导数只探测了 n 个坐标方向，是相当弱的信息。存在这样的函数：在某点所有偏导数都存在，函数在该点却连续都谈不上，更别说沿斜方向可微。后面“可微性”一节会看到，真正“像一元导数那样好用”的条件比“偏导都存在”强得多。这正是多元微分比一元微分微妙的地方——不能想当然地把一元的直觉照搬过来。

13.2 梯度：把偏导数装进一个向量

把 f 的 n 个一阶偏导数排成一个列向量，就得到本章第一件主器——梯度。它看似只是“偏导数的打包”，几何含义却异常丰富。

定义 13.3: 梯度

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 处各偏导数存在。 f 的梯度是把偏导数排成的列向量

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix} \in \mathbb{R}^n.$$

（取成列向量、与自变量同形，是本书一贯的分母布局约定；见矩阵微积分一章。）

梯度真正的用处，藏在它和方向导数的关系里。下面这条恒等式是本节的枢纽。

定理 13.4: 方向导数 = 梯度与方向的内积

若 f 在 $\mathbf{x}$ 处可微（见下一节），则对任意单位向量 $\mathbf{u}$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \mathbf{u} = \|\nabla f(\mathbf{x})\| \cos \theta,$$

其中 θ 是 $\nabla f(\mathbf{x})$ 与 $\mathbf{u}$ 的夹角。

证明. 设 $g(t) = f(\mathbf{x} + t\mathbf{u})$ 。这是 f 与直线 $\mathbf{x} + t\mathbf{u}$ 的复合, 对 t 用链式法则 (其多元形式在本章后面给出),

$$g'(t) = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(\mathbf{x} + t\mathbf{u}) \cdot u_i = \nabla f(\mathbf{x} + t\mathbf{u}) \cdot \mathbf{u}.$$

取 $t = 0$ 即得 $D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \mathbf{u}$ 。再由内积的几何意义 $\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$, 并注意 $\|\mathbf{u}\| = 1$, 便得最右一式。□

这条简单的式子一口气回答了“梯度有什么几何意义”的全部问题。把 θ 当成可调的——也就是让方向 $\mathbf{u}$ 绕一圈—— $D_{\mathbf{u}}f = \|\nabla f\| \cos \theta$ 在 $\theta = 0$ ($\mathbf{u}$ 与梯度同向) 时取最大值 $\|\nabla f\|$, 在 $\theta = \pi$ (反向) 时取最小值 $-\|\nabla f\|$, 在 $\theta = \pi/2$ (垂直于梯度) 时为零。三句话连起来, 就是梯度的三条核心性质:

梯度的三件事 (一条内积式全包)

- (1) 方向。 ∇f 指向 f 上升最快的方向; $-\nabla f$ 指向下降最快的方向。
- (2) 大小。 $\|\nabla f\|$ 就是沿最速上升方向走时的变化率——梯度越长, 地势越陡。
- (3) 与等值线垂直。沿等值线 (f 取常数的方向) 方向导数为零, 故 ∇f 垂直于过该点的等值线 (等值面)。

第 (3) 条尤其值得记住: 要画出 ∇f , 先画过该点的那条等值线, 梯度就是从这条线垂直地“戳出去”、指向函数值更高一侧的箭头 (图 13.1)。微观经济学里这处处可见——无差异曲线的梯度就是边际效用向量, 与无差异曲线垂直; 最优化时“梯度与约束面法向平行”正是 Lagrange 条件的几何形态 (见后文“等式约束与 Lagrange 乘子”一章)。




图 13.1: 梯度 $\nabla f(\mathbf{x}_0)$ 垂直于过 $\mathbf{x}_0$ 的等值线、指向函数值更高的一侧 (最速上升方向); 沿等值线切向走 f 不变, 方向导数为零。

至于“为什么方向导数等于投影”，图 13.2 把那条内积式画了出来：固定梯度 ∇f 后，沿任意单位方向 $\mathbf{u}$ 的变化率，正是梯度在 $\mathbf{u}$ 上的投影长度 $\|\nabla f\| \cos \theta$ 。你越是偏离梯度方向（ θ 越大），走得越“不划算”；偏到与梯度垂直时，一步也没爬高。




图 13.2: 方向导数是梯度在所选方向 $\mathbf{u}$ 上的投影 $\|\nabla f\| \cos \theta$ ：与梯度同向（ $\theta = 0$ ）变化率最大且等于 $\|\nabla f\|$ ，与梯度垂直（ $\theta = \pi/2$ ）变化率为零。

例（等值线垂直性的直接验证）。

设 $f(x_1, x_2) = \frac{1}{4}x_1^2 + x_2^2$ （图 13.1 用的就是它）。在点 $\mathbf{x}_0 = (1.147, 0.819)$ 处求梯度，并验证它确实垂直于过该点的等值线。

解。

梯度为 $\nabla f = (\frac{1}{2}x_1, 2x_2)^\top$ ，在 $\mathbf{x}_0$ 处

$$\nabla f(\mathbf{x}_0) = (\frac{1}{2} \cdot 1.147, 2 \cdot 0.819)^\top = (0.574, 1.638)^\top.$$

等值线 $\frac{1}{4}x_1^2 + x_2^2 = 1$ 在该点的切向量，可由把 x_2 看成 x_1 的隐函数、对 x_1 求导得到： $\frac{1}{2}x_1 + 2x_2 x_2' = 0$ ，故切向斜率 $x_2' = -x_1/(4x_2) = -1.147/(4 \cdot 0.819) = -0.350$ ，一个切向量是 $(1, -0.350)$ 。它与梯度的内积

$$(0.574, 1.638) \cdot (1, -0.350) = 0.574 - 0.573 \approx 0.$$

内积为零，二者垂直——正与图中那个直角标记吻合。把切向斜率 -0.350 转成单位向量便是图里那条红色等值线切向。

13.3 全微分与可微性：导数即最佳线性逼近

到这里我们一直在用“可微”这个词，却没把它定义清楚。在一元里，可微就是导数存在，没什么可纠结的。多元则不然：上一节提醒过，“偏导数都存在”是个太弱的条件。真正配得上“可微”这个名号、并让整套微分工具好用的，是下面这个以线性逼近为核心的定义。它也正是把一元导数“斜率”升级到多元的正确方式。

定义 13.5: (全) 可微

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $\mathbf{x}$ 处可微, 是指存在一个向量 $\mathbf{a} \in \mathbb{R}^n$, 使得当增量 $\mathbf{h} \rightarrow \mathbf{0}$ 时

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{a} \cdot \mathbf{h} + r(\mathbf{h}), \quad \frac{r(\mathbf{h})}{\|\mathbf{h}\|} \rightarrow 0.$$

此时必有 $\mathbf{a} = \nabla f(\mathbf{x})$, 那一项 $\mathbf{a} \cdot \mathbf{h} = \nabla f(\mathbf{x}) \cdot \mathbf{h}$ 称为 f 在 $\mathbf{x}$ 处的全微分。

这个定义在说一句朴素的话: 在 $\mathbf{x}$ 附近, f 几乎就是一个仿射 (线性 + 常数) 函数, 而那一段线性部分 $\nabla f \cdot \mathbf{h}$ 就是“最好”的线性逼近——好到误差 $r(\mathbf{h})$ 比 $\|\mathbf{h}\|$ 本身还要快地趋于零 (即 $r(\mathbf{h}) = o(\|\mathbf{h}\|)$)。图 13.3 沿某个方向 $\mathbf{h}$ 把这件事切成一元图像来看: 曲线在切点附近被它的切线 (线性逼近) 紧紧贴住, 二者的缝隙是高阶小量。




图 13.3: 可微的含义: 沿方向 $\mathbf{h}$ 切出的曲线 $t \mapsto f(\mathbf{x}_0 + t\mathbf{h})$ 在 $t = 0$ 处被其切线 (线性逼近 $f(\mathbf{x}_0) + \nabla f \cdot t\mathbf{h}$) 贴住, 二者之差是 $o(|t|)$ 的高阶小量。

为什么要费劲用“线性逼近”来定义可微, 而不直接说“偏导都存在”? 因为只有线性逼近这个定义才能保证我们想要的好性质一并到位: 可微 $\implies$ 连续、可微 $\implies$ 一切方向导数都存在且等于 $\nabla f \cdot \mathbf{u}$ (上一节定理正是用了可微)。仅有偏导数则什么都保证不了。好在有一条便于检验的充分条件, 让我们在实践中几乎不必回到 ε - δ 定义。

定理 13.6: 连续可微 $\implies$ 可微

若 f 的各偏导数 $\partial f / \partial x_i$ 在 $\mathbf{x}$ 的某邻域内存在且连续 (记作 $f \in C^1$), 则 f 在 $\mathbf{x}$ 处可微。

注 (一条实用的“免检”规则)。

经济学里写下的函数——多项式、指数、对数、它们的和差积商与复合——只要在所考察的点上分母不为零、对数的真数为正，就都是 C^1 （往往是 C^∞ ）的，因而自动可微。于是日常工作中“可微”几乎从不需要验证，可以放心使用 ∇f 、方向导数公式以及后面的链式法则。真正要当心可微性的，是分段定义的函数、带绝对值或 $\max$ 的函数（如期权收益、参与约束的边界），以及理论证明里需要严格性的场合。

13.4 Jacobian：向量值映射的导数

到目前为止因变量都是一个标量。可经济学里大量对象是向量值的映射 $\mathbb{R}^n \rightarrow \mathbb{R}^m$ ：需求系统把价格与收入这一组数映成一组需求量，最优反应把对手的策略映成自己的最优策略，从结构参数到矩条件的映射也是向量到向量。它们的“导数”该是什么？沿用“导数即最佳线性逼近”这条主线，答案自然浮现——一个标量的最佳线性逼近用一个向量（梯度）描述，那么一个向量的最佳线性逼近就该用一个矩阵描述。这个矩阵就是 Jacobian。

定义 13.7: Jacobian 矩阵

设映射 $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，写成分量 $\mathbf{g}(\mathbf{x}) = (g_1(\mathbf{x}), \dots, g_m(\mathbf{x}))^\top$ 。它的 **Jacobian** 是把所有一阶偏导排成的 $m \times n$ 矩阵

$$\mathbf{D}_{\mathbf{x}} \mathbf{g} = \begin{bmatrix} \partial g_1 / \partial x_1 & \cdots & \partial g_1 / \partial x_n \\ \vdots & & \vdots \\ \partial g_m / \partial x_1 & \cdots & \partial g_m / \partial x_n \end{bmatrix} \in \mathbb{R}^{m \times n}, \quad [\mathbf{D}_{\mathbf{x}} \mathbf{g}]_{ij} = \frac{\partial g_i}{\partial x_j}.$$

它的第 i 行是分量函数 g_i 的梯度的转置 $(\nabla g_i)^\top$ 。

Jacobian 把“导数即最佳线性逼近”推到了最一般的形式：在 $\mathbf{x}$ 附近，

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + [\mathbf{D}_{\mathbf{x}} \mathbf{g}] \mathbf{h} + \mathbf{r}(\mathbf{h}), \quad \frac{\|\mathbf{r}(\mathbf{h})\|}{\|\mathbf{h}\|} \rightarrow 0.$$

也就是说，非线性映射 $\mathbf{g}$ 在一点的局部行为，最好地由一个线性映射——左乘矩阵 $\mathbf{D}_{\mathbf{x}} \mathbf{g}$ ——来近似。梯度与 Jacobian 在这里统一了起来：当 $m = 1$ （标量输出）时， $\mathbf{D}_{\mathbf{x}} \mathbf{g}$ 退化成一个 $1 \times n$ 的行向量，恰是 $(\nabla g)^\top$ ；标量函数的导数原来一直是 Jacobian 的特例。

三件套的统一视角：导数 = 最佳线性逼近

对象	形态	含义
$f : \mathbb{R}^n \rightarrow \mathbb{R}$ 的一阶导	向量 $\nabla f \in \mathbb{R}^n$	标量输出的最佳线性逼近
$\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的一阶导	矩阵 $\mathbf{D}_{\mathbf{x}} \mathbf{g} \in \mathbb{R}^{m \times n}$	向量输出的最佳线性逼近
$f : \mathbb{R}^n \rightarrow \mathbb{R}$ 的二阶导	矩阵 $\mathbf{H} \in \mathbb{R}^{n \times n}$	梯度场 ∇f 的 Jacobian

一句话：把非线性的东西在一点拍扁成线性的东西，那块“拍扁”的系数就是导数。输入输出维数决定它是向量还是矩阵。

当 $m = n$ （输入输出同维）时，方阵 $D_{\mathbf{x}} \mathbf{g}$ 的行列式 $\det(D_{\mathbf{x}} \mathbf{g})$ 叫 **Jacobian 行列式**，它度量这个线性逼近把体积放大或缩小的倍率（带符号，符号表示是否翻转定向）。这个量在两处反复登场：其一，它非零正是反函数定理与隐函数定理里那个“可逆”条件（见后文“隐函数定理与比较静态”一章——那里把内生变量的 Jacobian 可逆当作比较静态成立的前提）；其二，它是多维变量变换的换元因子。

例（极坐标变换的 Jacobian 行列式）。

平面上从极坐标 (r, θ) 到直角坐标的映射为 $x = r \cos \theta$ 、 $y = r \sin \theta$ 。求其 Jacobian 矩阵与 Jacobian 行列式。

解。

把 (x, y) 当输出、 (r, θ) 当输入，逐项求偏导：

$$D_{(r, \theta)} \mathbf{g} = \begin{bmatrix} \partial x / \partial r & \partial x / \partial \theta \\ \partial y / \partial r & \partial y / \partial \theta \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix},$$

行列式

$$\det(D_{(r, \theta)} \mathbf{g}) = \cos \theta \cdot r \cos \theta - (-r \sin \theta) \cdot \sin \theta = r (\cos^2 \theta + \sin^2 \theta) = r.$$

这正是重积分换元里那个熟悉的因子： $dx \, dy = r \, dr \, d\theta$ 。它的概率版本（密度函数在变量变换下要乘上 Jacobian 行列式的绝对值）将在“多维分布与变量变换”一章中给出——那里 $|\det(\cdot)|$ 保证概率质量守恒。

13.5 Hessian 与混合偏导的对称性

把一阶信息（梯度）再求一次导，得到二阶信息。对一元函数，二阶导是一个数，符号告诉你曲线是凸是凹；对多元函数，二阶导是一个矩阵——**Hessian**，它装着函数在一点附近的全部“弯曲”信息，是判别极大极小、做二阶逼近的核心对象。

定义 13.8: Hessian 矩阵

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 二阶偏导数存在。 f 的 **Hessian** 是二阶偏导排成的 $n \times n$ 矩阵

$$\mathbf{H}(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{bmatrix} \partial^2 f / \partial x_1^2 & \cdots & \partial^2 f / \partial x_1 \partial x_n \\ \vdots & & \vdots \\ \partial^2 f / \partial x_n \partial x_1 & \cdots & \partial^2 f / \partial x_n^2 \end{bmatrix}, \quad [\mathbf{H}]_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}.$$

它恰好是梯度场 $\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 的 Jacobian: $\mathbf{H} = D_{\mathbf{x}} \nabla f$ 。

最后那句话点出了三件套之间的血缘：Hessian 不是凭空多出来的第三种导数，它

就是“对梯度这个向量值映射再求一次 Jacobian”。这也立刻解释了为什么后面隐函数定理一章里，对一阶条件 $\nabla f = \mathbf{0}$ 套用隐函数定理时，那个关键的 Jacobian 恰好是 Hessian。

Hessian 有一条优美而实用的性质：在温和条件下它是对称矩阵。

定理 13.9: Young (Clairaut) 定理：混合偏导可交换

若 f 的二阶偏导数 $\partial^2 f / \partial x_i \partial x_j$ 在 $\mathbf{x}$ 的某邻域内连续（即 $f \in C^2$ ），则混合偏导与求导次序无关：

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad (\text{对一切 } i, j).$$

因而 Hessian 是对称矩阵： $\mathbf{H} = \mathbf{H}^\top$ 。

直觉上为什么次序可以换？看 i, j 两个方向。混合偏导 $\partial^2 f / \partial x_i \partial x_j$ 衡量的是“沿 x_j 走时， x_i 方向的斜率如何变化”。考虑由 $\mathbf{x}$ 出发、边长分别为 s, t 的小矩形四个顶点上的函数值，作“二阶差分”

$$\Delta = f(\mathbf{x} + s\mathbf{e}_i + t\mathbf{e}_j) - f(\mathbf{x} + s\mathbf{e}_i) - f(\mathbf{x} + t\mathbf{e}_j) + f(\mathbf{x}).$$

这个对称的组合除以 st ，当 $s, t \rightarrow 0$ 时既趋于 $\partial^2 f / \partial x_i \partial x_j$ ，也趋于 $\partial^2 f / \partial x_j \partial x_i$ ——因为 Δ 关于交换 $i \leftrightarrow j$ 显然不变，两个极限被夹在同一个量上，故相等。连续性是让这两次取极限可以交换次序的保证。

注（少了连续性，对称会破）。

C^2 不是可有可无的装饰。经典反例

$$f(x, y) = \frac{xy(x^2 - y^2)}{x^2 + y^2} \quad (x, y) \neq (0, 0), \quad f(0, 0) = 0,$$

在原点处两个混合偏导都存在却不相等：直接计算给出 $f_{xy}(0, 0) = -1$ 而 $f_{yx}(0, 0) = +1$ 。原因正是它的二阶偏导在原点不连续。所幸经济学里的目标函数几乎都是 C^2 的，可以放心地把 Hessian 当对称矩阵用。

Hessian 对称这件事用处极大。第一，对称矩阵有实特征值、可正交对角化（见线性代数部分的谱定理），于是“Hessian 负定 $\iff$ 局部严格凹 $\iff$ 内点极大”这套二阶条件才有干净的特征值刻画。第二，它是二阶 Taylor 展开 $f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla f \cdot \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H} \mathbf{h}$ 里那个二次型的矩阵——对称性让这个二次型写起来无歧义（见“Taylor 展开与二阶近似”一章）。

例 (Cobb–Douglas 生产函数的梯度与 Hessian)。

生产函数 $f(K, L) = AK^a L^b$ ($A, a, b > 0$)。求边际产品向量（梯度）与 Hessian，并验证混合偏导对称、解释各项符号的经济含义。

解。

一阶偏导即两种要素的边际产品：

$$\frac{\partial f}{\partial K} = aA K^{a-1} L^b = a \frac{f}{K}, \quad \frac{\partial f}{\partial L} = bA K^a L^{b-1} = b \frac{f}{L},$$

故梯度 $\nabla f = (af/K, bf/L)^\top$ ，两个分量都为正——多投入任一要素都增产，符合“边际产品为正”。二阶偏导：

$$\frac{\partial^2 f}{\partial K^2} = a(a-1)A K^{a-2} L^b, \quad \frac{\partial^2 f}{\partial L^2} = b(b-1)A K^a L^{b-2}, \quad \frac{\partial^2 f}{\partial K \partial L} = ab A K^{a-1} L^{b-1}.$$

两个混合偏导

$$\frac{\partial^2 f}{\partial K \partial L} = \frac{\partial^2 f}{\partial L \partial K} = ab A K^{a-1} L^{b-1}$$

确实相等（Young 定理的直接印证）。于是

$$\mathbf{H} = AK^{a-2}L^{b-2} \begin{bmatrix} a(a-1)L^2 & abKL \\ abKL & b(b-1)K^2 \end{bmatrix}.$$

符号上：对角元 $\partial^2 f / \partial K^2$ 在 $a < 1$ 时为负，即边际产品递减（多投同一要素，增产越来越慢）；交叉项 $\partial^2 f / \partial K \partial L = abf/(KL) > 0$ 为正，说明两要素互补——多用劳动会抬高资本的边际产品。这个交叉偏导的符号，正是比较静态里决定“一个参数动、最优选择朝哪走”的关键量（见后文从一阶条件做比较静态）。

13.6 链式法则的矩阵形式

复合是经济学建模的常态：效用是消费的函数、消费又是价格收入的函数；似然是参数的函数、参数又依赖样本。把这些复合关系求导，靠的是链式法则。它的多元形式之所以漂亮，是因为“导数即线性逼近”让一切归结为一句话——复合映射的最佳线性逼近，就是各段最佳线性逼近的复合；而线性映射的复合就是矩阵相乘。

定理 13.10: 链式法则（矩阵形式）

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在 $\mathbf{x}$ 处可微， $f: \mathbb{R}^m \rightarrow \mathbb{R}^k$ 在 $\mathbf{y} = g(\mathbf{x})$ 处可微。则复合 $f \circ g: \mathbb{R}^n \rightarrow \mathbb{R}^k$ 在 $\mathbf{x}$ 处可微，其 Jacobian 是两个 Jacobian 之积：

$$D_{\mathbf{x}}(f \circ g) = [D_{\mathbf{y}} f] [D_{\mathbf{x}} g] \quad (\text{维数 } k \times m \text{ 乘 } m \times n = k \times n).$$

证明. 两段各自的线性逼近为 $f(\mathbf{y} + \mathbf{k}) \approx f(\mathbf{y}) + [D_{\mathbf{y}} f] \mathbf{k}$ 与 $g(\mathbf{x} + \mathbf{h}) \approx g(\mathbf{x}) + [D_{\mathbf{x}} g] \mathbf{h}$ 。把后者代入前者（取 $\mathbf{k} = g(\mathbf{x} + \mathbf{h}) - g(\mathbf{x}) \approx [D_{\mathbf{x}} g] \mathbf{h}$ ）：

$$f(g(\mathbf{x} + \mathbf{h})) \approx f(\mathbf{y}) + [D_{\mathbf{y}} f] [D_{\mathbf{x}} g] \mathbf{h}.$$

按定义，复合在 $\mathbf{x}$ 处的最佳线性逼近的系数矩阵就是 $[D_{\mathbf{y}} f] [D_{\mathbf{x}} g]$ ，即其 Jacobian。（余项是高阶小量之和，仍为 $o(\|\mathbf{h}\|)$ ，严格论证从略。）逐元素看，这条矩阵恒等式就是熟

悉的“对所有中间变量求和”的链式法则

$$\frac{\partial(f_i \circ \mathbf{g})}{\partial x_j} = \sum_{l=1}^m \frac{\partial f_i}{\partial y_l} \frac{\partial g_l}{\partial x_j},$$

它正是矩阵乘法 $[\mathbf{D}_y \mathbf{f}] [\mathbf{D}_x \mathbf{g}]$ 的第 (i, j) 元。

□

记不住下标？用“维数对齐”来记

矩阵形式的链式法则有一个好处：你永远不必背“谁乘谁”。只要按从外到内的次序把各段 Jacobian 写下来—— $\mathbf{D}_y \mathbf{f}$ ($k \times m$) 在前、 $\mathbf{D}_x \mathbf{g}$ ($m \times n$) 在后——相邻矩阵的“内维” m 自动对消，剩下 $k \times n$ 恰是复合映射应有的尺寸。维数对不上，就说明顺序或转置写错了。这条“维数体操”在矩阵微积分一章里是反复用到的查错手段。

一个最常用的特例值得单列：标量函数与一条参数化路径复合。设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ， $\mathbf{x}(t)$ 是一条随标量 t 变动的路径 ($k=1$, $n \rightarrow n$, 内层输出维 = n)。链式法则给出

$$\frac{d}{dt} f(\mathbf{x}(t)) = \nabla f(\mathbf{x}(t)) \cdot \frac{d\mathbf{x}}{dt} = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \frac{dx_i}{dt}.$$

本章开头证方向导数公式时用的就是它（取 $\mathbf{x}(t) = \mathbf{x}_0 + t\mathbf{u}$ ，则 $d\mathbf{x}/dt = \mathbf{u}$ ）。宏观增长核算里“总产出增长率 = 各要素增长率按产出弹性加权之和”、跨期模型里沿最优路径对值函数求时间导数，骨子里都是这条路径链式法则。

13.7 三件套通向何处

本章配齐的梯度、Jacobian、Hessian，是后续几乎每一处多元微分的入口。把它们的主要去处列在一起，能看清这章在全书里的位置：

- **无约束最优化**（最优化部分）。内点极值的一阶必要条件是 $\nabla f = \mathbf{0}$ （梯度为零，沿任何方向都“爬不动了”）；二阶条件靠 Hessian 的定性——极大要 $\mathbf{H}$ 负定、极小要正定。梯度与 Hessian 正是一阶/二阶条件的两个主角。
- **隐函数定理与比较静态**（见后文“隐函数定理与比较静态”一章）。对一阶条件 $\nabla f = \mathbf{0}$ 这个方程组套用隐函数定理，关键的“可逆”条件落在 Hessian 上，比较静态公式 $\mathbf{D}_\theta \mathbf{x}^* = -\mathbf{H}^{-1} \nabla_{\mathbf{x}\theta}^2 f$ 里梯度、Hessian、交叉 Jacobian 一并出场。
- **多维变量变换**（概率与测度部分）。随机向量做非线性变换时，新密度要乘上变换 Jacobian 行列式的绝对值——这是“概率质量不会凭空增减”的数学表达，极坐标那个 r 是它最简单的版本。
- **Delta 法**（渐近统计部分）。已知 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$ ，要求一个非线性变换 $\mathbf{g}(\hat{\theta})$ 的渐近分布，就把 $\mathbf{g}$ 在 θ_0 处线性化——用的正是 Jacobian $\mathbf{D}\mathbf{g}$ ——得到 $\sqrt{n}(\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, [\mathbf{D}\mathbf{g}] \Sigma [\mathbf{D}\mathbf{g}]^T)$ 。Delta 法本质上就是“导数即最佳线性逼近”在随机变量上的应用。

- **生产与消费理论**（微观经济学）。生产函数的梯度就是边际产品向量，效用函数的梯度就是边际效用向量；它们与价格向量的比较，给出最优投入与最优消费的条件。

贯穿这五处的，始终是本章那句一以贯之的内核：导数就是最佳的局部线性逼近。维数决定它呈现为向量还是矩阵，但“把非线性的东西在一点拍扁成线性”这件事从未改变。把这一点吃透，下游那些看似各不相同的公式，便都成了同一把工具的不同用法。

第十四章 Taylor 展开与二阶近似

用到的前置工具：偏导数、梯度、Jacobian 与 Hessian（多元微分一章）；二次型与正定性（线性代数部分，谱定理一章，见第五章）。

经济学家研究的函数——效用、利润、似然、值函数——几乎都不是多项式那样“友好”的对象。它们往往非线性、形式复杂，甚至（如样本对数似然）根本写不成闭式。可我们对它们提的问题，却常常是局部的：在某个最优点附近，目标函数长什么样？参数稍微动一下，估计量会怎么挪？这正是 Taylor 展开登场的地方——它用一个低阶多项式，在一点附近逼近任意光滑函数，把“复杂”换成“可算”。一阶展开给出切线（局部线性化），二阶展开给出最贴合的抛物线（局部二次化）。本章先把一元、多元的展开公式连同余项讲清楚，再说明它最重要的一个用途：二阶项是一个由 Hessian 决定的二次型，于是“一个临界点到底是极小、极大还是鞍点”这件事，被彻底归结为 Hessian 的正定性。这条线索一头连着最优化的二阶条件，另一头连着渐近统计里估计量的展开，是全书使用频率最高的工具之一。

14.1 为什么要做近似

设想你已经找到了一个最优点 x^* ，想知道目标函数 f 在它附近的样子。最朴素的想法是：用 f 在 x^* 处的值、斜率、曲率，拼一个多项式去模仿它。零阶近似 $f(x) \approx f(x^*)$ 只记住了高度；一阶近似 $f(x) \approx f(x^*) + f'(x^*)(x - x^*)$ 加上了斜率，得到切线；二阶近似再添一项曲率，得到一条与 f 贴合得更紧的抛物线。阶数越高，在 x^* 附近就越像。Taylor 定理把这个“越来越像”说得精确：它不仅给出近似多项式，还给出误差有多大。

这件事之所以是经济学的核心工具，原因有三。其一，**二阶条件**：判断一个临界点是不是极值，靠的正是二阶近似那一项的符号。其二，**局部分分析与比较静态**：把均衡条件或一阶条件在某点线性化，复杂的非线性系统就退化成一个线性方程，可以直接求解、求导。其三，**渐近统计**：几乎所有估计量的极限分布，都是先把样本一阶条件围绕真值做 Taylor 展开、再取极限得到的——Delta 法是一阶展开，三明治协方差矩阵藏着二阶展开。换言之，“在一点附近用多项式替身”这一招，贯穿了微观的最优化、宏观的局部动态、计量的渐近理论。

14.2 一元 Taylor 定理

先把唯一一个自变量的情形讲透，多元情形不过是它的向量化。核心对象是 n 阶 Taylor 多项式：在点 x_0 处，用 f 直到 n 阶的导数信息拼出的多项式

$$P_n(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2}(x - x_0)^2 + \cdots$$

它被设计成在 x_0 处与 f “吻合到 n 阶”： P_n 与 f 在 x_0 的函数值、一阶到 n 阶导数全部相等。真正的问题是 $f - P_n$ 这个余项有多大。

定理 14.1: 一元 Taylor 定理 (Lagrange 余项)

设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 在包含 x_0 与 x 的开区间上 $(n+1)$ 次连续可微。则

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k + \underbrace{\frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0)^{n+1}}_{\text{余项 } R_n},$$

其中 ξ 是介于 x_0 与 x 之间的某一点。

证明. 取定 x 。令 $h = x - x_0$ ，定义关于 t （在 x_0 与 x 之间变动）的辅助函数

$$g(t) = f(x) - \sum_{k=0}^n \frac{f^{(k)}(t)}{k!} (x - t)^k.$$

直接验证 $g(x) = 0$ ，而 $g(x_0) = f(x) - P_n(x) = R_n$ 。求导时，和式里相邻两项的导数逐对相消（这正是 Taylor 多项式的设计精巧之处），只剩末项：

$$g'(t) = -\frac{f^{(n+1)}(t)}{n!} (x - t)^n.$$

再引入 $\varphi(t) = (x - t)^{n+1}$ ，它满足 $\varphi(x) = 0$ 、 $\varphi(x_0) = h^{n+1}$ 。对 g, φ 用 Cauchy 中值定理：存在介于 x_0, x 之间的 ξ ，使

$$\frac{g(x_0) - g(x)}{\varphi(x_0) - \varphi(x)} = \frac{g'(\xi)}{\varphi'(\xi)}.$$

左边为 R_n/h^{n+1} 。右边把 $g'(\xi)$ 与 $\varphi'(\xi) = -(n+1)(x - \xi)^n$ 代入， $(x - \xi)^n$ 约去，得 $R_n/h^{n+1} = f^{(n+1)}(\xi)/(n+1)!$ ，移项即所证。□

注 ($n = 0$ 就是中值定理)。

取 $n = 0$ ，定理说 $f(x) = f(x_0) + f'(\xi)(x - x_0)$ ，这正是 Lagrange 中值定理。所以 Taylor 定理可以看作中值定理的高阶推广：中值定理用“某点的斜率”精确表达一阶增量，Taylor 定理用“某点的 $(n+1)$ 阶导数”精确表达 n 阶近似的误差。整条思路——先造一个在两端取已知值的辅助函数，再用中值定理逮住一个中间点——是

分析里反复出现的套路。

Lagrange 余项给出误差的精确表达（代价是 ξ 不可知，只知它在区间内）。在很多场合我们其实只需要知道误差“阶数有多小”，这就是 Peano 形式。

定理 14.2: 一元 Taylor 定理 (Peano 余项)

设 f 在 x_0 处 n 次可微。则当 $x \rightarrow x_0$ 时

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k + o((x - x_0)^n),$$

即余项比 $(x - x_0)^n$ 更高阶地趋于零。

两种余项各管一摊

Lagrange 余项给的是“误差等于某个高阶导数乘以 h^{n+1} ”——它适合做定量的误差估计（例如要保证近似误差小于某个阈值，该取多少阶、邻域多大），数值分析靠它。**Peano** 余项给的是“误差是 $o(h^n)$ ”——它适合做定性的极限论证：在渐近统计里，我们把样本目标函数展开后让 $n \rightarrow \infty$ ，真正用到的就是“余项可忽略”这一句，而不关心它的精确大小。记住：要算误差用 Lagrange，要扔误差用 Peano。

例（二阶近似的误差控制）.

用二阶 Taylor 多项式在 $x_0 = 0$ 处近似 $f(x) = e^x$ ，并给出 $|x| \leq 0.1$ 时的误差上界。

解.

f 各阶导数都是 e^x ，故 $f(0) = f'(0) = f''(0) = 1$ ，二阶多项式为 $P_2(x) = 1 + x + \frac{1}{2}x^2$ 。Lagrange 余项 ($n = 2$) 为

$$R_2 = \frac{f'''(\xi)}{3!} x^3 = \frac{e^\xi}{6} x^3, \quad \xi \text{ 介于 } 0 \text{ 与 } x.$$

当 $|x| \leq 0.1$ 时 $e^\xi \leq e^{0.1} < 1.106$ ，于是

$$|R_2| \leq \frac{1.106}{6} (0.1)^3 < 1.85 \times 10^{-4}.$$

不必知道 ξ 究竟是多少，仅凭“ f''' 在小区间上有界”就锁定了误差量级。这正是 Lagrange 余项的用法：把不可知的 ξ 用一个保守的界放掉。

一阶 vs 二阶：图像。 图 14.1 把 $f(x) = e^x$ 与它在 $x_0 = 0$ 处的一阶近似（切线 $1 + x$ ）、二阶近似（抛物线 $1 + x + \frac{1}{2}x^2$ ）画在一起。三条曲线在 x_0 处相切；离开 x_0 后，切线很快与原函数分道扬镳，而抛物线一直贴着原函数走得更远——多出来的那一项 $\frac{1}{2}f''(x_0)(x - x_0)^2$ 补上了“弯曲”的信息。这张图就是“阶数越高、近似越好”的直

观注脚。




图 14.1: $f(x) = e^x$ 在 $x_0 = 0$ 处的一阶近似 (切线, 蓝) 与二阶近似 (抛物线, 红)。记 $\Delta = x - x_0$ 。二阶近似补上了曲率项 $\frac{1}{2}f''\Delta^2$, 在 x_0 附近比切线贴合得明显更紧。

14.3 多元 Taylor 展开

经济学里的目标函数几乎都是多元的: 消费束、要素投入、参数向量。把一元展开升级到 $\mathbb{R}^n$, 做法是沿着一条直线把多元函数变回一元函数, 再套用一元定理。

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 光滑, 要在点 $\mathbf{x}_0$ 附近展开。取增量 $\Delta = \mathbf{x} - \mathbf{x}_0$, 定义沿这条方向

$$\phi(t) = f(\mathbf{x}_0 + t\Delta), \quad t \in [0, 1].$$

我们关心的 $f(\mathbf{x}) = \phi(1)$, 而 $f(\mathbf{x}_0) = \phi(0)$ 。对 ϕ 在 $t = 0$ 处做一元 Taylor 展开即可。用链式法则算 ϕ 的导数:

$$\phi'(t) = \nabla f(\mathbf{x}_0 + t\Delta)^\top \Delta, \quad \phi''(t) = \Delta^\top \nabla^2 f(\mathbf{x}_0 + t\Delta) \Delta.$$

第一式是梯度与方向的内积 (方向导数); 第二式里 $\nabla^2 f$ 就是 Hessian 矩阵 $\mathbf{H}$, 于是 ϕ'' 是一个以 Δ 为自变量的二次型。在 $t = 0$ 处展开 $\phi(1) = \phi(0) + \phi'(0) + \frac{1}{2}\phi''(0) + \cdots$, 把上面两式代入, 便得到多元 Taylor 公式。

定理 14.3: 多元 Taylor 展开 (二阶)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $\mathbf{x}_0$ 的邻域内二次连续可微, $\Delta = \mathbf{x} - \mathbf{x}_0$ 。则

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \Delta + \frac{1}{2} \Delta^\top \nabla^2 f(\mathbf{x}_0) \Delta + o(\|\Delta\|^2)$$

当 $\|\Delta\| \rightarrow 0$ 。在同样的二次连续可微前提下, 余项还可写成 Lagrange 形式: 存在 $\theta \in (0, 1)$ 使

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \Delta + \frac{1}{2} \Delta^\top \nabla^2 f(\mathbf{x}_0 + \theta \Delta) \Delta.$$

此即一阶展开加一个用中间点处 Hessian 精确表达的二阶余项。

证明. 为把展开的“小参数”落到 $\|\Delta\|$ 上, 固定单位方向 $\mathbf{u} = \Delta / \|\Delta\|$, 记 $s = \|\Delta\| \geq 0$, 令 $\psi(s) = f(\mathbf{x}_0 + s\mathbf{u})$; 于是 $\mathbf{x} = \mathbf{x}_0 + s\mathbf{u}$, $\psi(s) = f(\mathbf{x})$, $\psi(0) = f(\mathbf{x}_0)$ 。由链式法则

$$\psi'(0) = \nabla f(\mathbf{x}_0)^\top \mathbf{u}, \quad \psi''(0) = \mathbf{u}^\top \nabla^2 f(\mathbf{x}_0) \mathbf{u}.$$

对 ψ 在 $s = 0$ 处用 Peano 形式的一元 Taylor 定理 ($n = 2$, 此处真正的小变量正是 s):

$$\psi(s) = \psi(0) + \psi'(0)s + \frac{1}{2}\psi''(0)s^2 + o(s^2), \quad s \rightarrow 0.$$

代入并用 $s\mathbf{u} = \Delta$ 、 $s^2 = \|\Delta\|^2$: 一阶项化为 $\nabla f(\mathbf{x}_0)^\top \Delta$, 二阶项化为 $\frac{1}{2} \Delta^\top \nabla^2 f(\mathbf{x}_0) \Delta$, 而余项 $o(s^2) = o(\|\Delta\|^2)$, 即得 Peano 形式。(因 $\nabla^2 f$ 在 $\mathbf{x}_0$ 处连续, 该 o 关于方向 $\mathbf{u}$ 一致, 故对趋于 $\mathbf{x}_0$ 的任意路径都成立。)

至于 Lagrange 形式: 回到沿直线的 $\phi(t) = f(\mathbf{x}_0 + t\Delta)$, $t \in [0, 1]$ 。 f 二次连续可微保证 $\phi \in C^2[0, 1]$, 对 ϕ 在 $t = 0$ 处用一元 $n = 1$ 的 Lagrange 余项定理 (其余项已含二阶导数): 存在 $\theta \in (0, 1)$ 使

$$\phi(1) = \phi(0) + \phi'(0) + \frac{1}{2}\phi''(\theta).$$

代入 $\phi(0) = f(\mathbf{x}_0)$ 、 $\phi'(0) = \nabla f(\mathbf{x}_0)^\top \Delta$, 以及 $\phi''(\theta) = \Delta^\top \nabla^2 f(\mathbf{x}_0 + \theta\Delta) \Delta$, 即得带精确中间点的形式——全程只用到 $f \in C^2$ 。 $\square$

把公式逐项读出来, 每一项都有清楚的几何与经济含义:

- **零阶项** $f(\mathbf{x}_0)$: 基准高度。
- **一阶项** $\nabla f(\mathbf{x}_0)^\top \Delta$: 梯度与位移的内积, 给出局部线性化 (切平面)。在临界点处 $\nabla f = \mathbf{0}$, 这一项消失。
- **二阶项** $\frac{1}{2} \Delta^\top \mathbf{H} \Delta$: 由 Hessian 决定的二次型, 刻画曲率。在临界点处, 正是它独自决定 f 在该点附近是上凸、下凹还是两者皆有。

注 (一阶展开本身就是一件大工具)。

只取到一阶, $f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \Delta$, 就是局部线性化。计量里的 Delta 法 (在渐近统计部分) 正是这一项: 若 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$, 要求一个光滑变换 $g(\hat{\theta})$ 的极限分布, 就把 g 在 θ_0 处一阶展开, $g(\hat{\theta}) \approx g(\theta_0) + \nabla g(\theta_0)^\top (\hat{\theta} - \theta_0)$, 于是 $\sqrt{n}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \nabla g^\top \Sigma \nabla g)$ 。高阶项被 O_p 、 o_p 记号收拾掉——这就是“扔误差用 Peano”那条原则的实战。

14.4 局部二次近似与临界点分类

现在把二阶展开用在它最锋利的地方。设 $\mathbf{x}_0$ 是 f 的一个临界点 (驻点), 即 $\nabla f(\mathbf{x}_0) = \mathbf{0}$ 。此时一阶项消失, 二阶展开化简为

$$f(\mathbf{x}) - f(\mathbf{x}_0) = \frac{1}{2} \Delta^\top \mathbf{H} \Delta + o(\|\Delta\|^2), \quad \mathbf{H} = \nabla^2 f(\mathbf{x}_0).$$

在 $\mathbf{x}_0$ 足够小的邻域内, 符号由主导项即二次型 $\Delta^\top \mathbf{H} \Delta$ 决定。于是“ $\mathbf{x}_0$ 是极小、极大还是鞍点”这个问题, 被完全翻译成“二次型 $\Delta^\top \mathbf{H} \Delta$ 的符号”——而后者正是矩阵正定性的定义 (见谱定理一章, 第五章)。

定理 14.4: 二阶充分条件 (临界点分类)

设 f 二次连续可微, $\nabla f(\mathbf{x}_0) = \mathbf{0}$, $\mathbf{H} = \nabla^2 f(\mathbf{x}_0)$ (对称)。则

- $\mathbf{H}$ 正定 $\Rightarrow \mathbf{x}_0$ 是严格局部极小;
- $\mathbf{H}$ 负定 $\Rightarrow \mathbf{x}_0$ 是严格局部极大;
- $\mathbf{H}$ 不定 (既有正特征值又有负特征值) $\Rightarrow \mathbf{x}_0$ 是鞍点 (非极值);
- $\mathbf{H}$ 半定但奇异 (有零特征值) $\Rightarrow$ 判别失效, 需更高阶信息。

证明. 只证正定情形, 其余对称或类似。 $\mathbf{H}$ 正定, 由谱定理其最小特征值 $\lambda_{\min} > 0$, 且对一切 Δ 有 $\Delta^\top \mathbf{H} \Delta \geq \lambda_{\min} \|\Delta\|^2$ (Rayleigh 商下界)。代入二阶展开:

$$f(\mathbf{x}) - f(\mathbf{x}_0) \geq \frac{1}{2} \lambda_{\min} \|\Delta\|^2 + o(\|\Delta\|^2) = \|\Delta\|^2 \left[\frac{1}{2} \lambda_{\min} + o(1) \right].$$

当 $\|\Delta\|$ 充分小, 方括号内 $o(1)$ 项的绝对值小于 $\frac{1}{4} \lambda_{\min}$, 故方括号 $> \frac{1}{4} \lambda_{\min} > 0$ 。于是在某去心邻域内 $f(\mathbf{x}) > f(\mathbf{x}_0)$, 即严格局部极小。不定情形: 取 $\mathbf{H}$ 的正特征值对应方向 $\mathbf{v}_+$, 沿之 f 上升; 取负特征值方向 $\mathbf{v}_-$, 沿之 f 下降——两个方向上“一升一降”, 故非极值, 是鞍点。□

临界点的性质 = Hessian 的正定性

这是本章与最优化、线性代数三者的交汇点。无约束最优化的全部二阶理论可以一句话概括: 在临界点处, 目标函数的局部形状由 Hessian 这一个二次型决定。判极小看 $\mathbf{H}$ 是否正定, 判极大看是否负定, 二者都不沾边就是鞍点。而“如何判

定一个对称矩阵正定”——看特征值符号、看顺序主子式（Sylvester 判据）、看 Cholesky 分解是否存在——是线性代数那一章的全部内容。Taylor 展开在这里扮演的角色，是把一个分析问题（函数的局部极值）精确地转交给一个代数问题（矩阵的定性），这正是它作为“桥梁工具”的典范用法。

图 14.2 把三种情形画成沿不同方向的曲率截面：正定时每个方向都向上弯（碗状，极小），负定时每个方向都向下弯（穹顶，极大），不定时至少有一个方向向上、一个方向向下（山口，鞍点）。




图 14.2: 临界点三态。横轴是沿某一方向偏离临界点的位移，纵轴是二阶项 $q(\Delta) = \frac{1}{2}\Delta^T \mathbf{H} \Delta$ 的值；每个面板画了沿两个代表方向的截面。正定：所有方向都上凸（碗，极小）；负定：所有方向都下凹（穹顶，极大）；不定：有的方向上凸、有的下凹（山口，鞍点）。

例（一个鞍点）。

判定 $f(x, y) = x^2 - y^2$ 在原点的临界点类型。

解。

$\nabla f = (2x, -2y)^T$ ，在原点为 $\mathbf{0}$ ，故原点是临界点。Hessian 为常数矩阵

$$\mathbf{H} = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix},$$

特征值 2 与 -2，一正一负， $\mathbf{H}$ 不定。故原点是鞍点：沿 x 轴 $f = x^2$ 取极小，沿 y 轴 $f = -y^2$ 取极大。这里二阶项恰好就是全部（ f 本身是二次型，更高阶导数为零），所以分类是精确的，而非仅局部成立。

例（二阶项是二次型：一个非对角的例子）。

求 $f(x, y) = x^2 + xy + y^2$ 在原点的二阶近似，并判定类型。

解。

$\nabla f = (2x + y, x + 2y)^\top$ 在原点为零，原点是临界点。Hessian

$$\mathbf{H} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

其顺序主子式为 $2 > 0$ 与 $\det \mathbf{H} = 4 - 1 = 3 > 0$ ，由 Sylvester 判据 $\mathbf{H}$ 正定（等价地，特征值 1, 3 均正）。故原点是严格局部极小。二阶近似

$$f(\mathbf{x}) \approx \frac{1}{2} \Delta^\top \mathbf{H} \Delta = x^2 + xy + y^2$$

在此恰好还原 f 本身。交叉项 xy 的存在提醒我们：Hessian 一般不是对角阵，临界点的“主轴方向”是 $\mathbf{H}$ 的特征向量方向，沿这些方向曲率取特征值——这把分类问题彻底交还给谱定理。

注（为什么半定时判别失效）。

若 $\mathbf{H}$ 半正定但奇异，沿零特征值对应的方向 $\mathbf{v}_0$ 有 $\mathbf{v}_0^\top \mathbf{H} \mathbf{v}_0 = 0$ ，二阶项在该方向消失， f 在这条线上的行为由三阶及更高阶项接管，二阶展开看不出来。例如 $f(x) = x^4$ 与 $g(x) = x^3$ 在原点都有 $f'' = g'' = 0$ （一维的“半定退化”），但前者是极小、后者是拐点。结论：二阶条件是充分而非必要——它判得出的一定对，判不出（退化）时要请更高阶的 Taylor 项出场。

14.5 去处：从牛顿法到渐近展开

Taylor 展开不是一个孤立的定理，而是一连串后续工具的共同地基。本节快速点出几个最重要的落点，它们会在后面相应的部分展开。

无约束最优化的二阶条件。 本章第 14.4 节的分类定理，就是无约束最优化（最优化部分）二阶充分条件的全部内容：找到使 $\nabla f = \mathbf{0}$ 的点（一阶条件）后，用 Hessian 的正/负定性确认它是极小还是极大。隐函数定理一章里“二阶条件让比较静态有良定义”的论断（负定 $\Rightarrow$ 可逆），其源头正是这里——负定的 $\mathbf{H}$ 不仅判出极大，还因可逆而启动了比较静态公式。

牛顿法：最小化二阶近似。 要数值地求 f 的极小，牛顿法的思路是：在当前点 $\mathbf{x}_k$ 把 f 用二阶 Taylor 多项式替代，然后精确地极小化这个二次替身。二次近似 $q(\Delta) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^\top \Delta + \frac{1}{2} \Delta^\top \mathbf{H}_k \Delta$ 的极小由 $\nabla q = \mathbf{0}$ 给出，即 $\mathbf{H}_k \Delta = -\nabla f(\mathbf{x}_k)$ ，于是迭代

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k).$$

每一步都在求解“当前二次近似的最优点”。当 $\mathbf{H}$ 正定且初值够近时，牛顿法二次收敛——这速度正是“二阶近似贴得紧”（图 14.1 里红线那种贴法）的回报。计量里 MLE 的数值求解、以及 BHHH、Fisher scoring 等变体，骨子里都是这条迭代。

M-估计量的渐近展开。 这是 Taylor 展开在计量里最深的一处用途（详见渐近统计部分）。设估计量 $\hat{\theta}$ 由样本一阶条件 $\Psi_n(\hat{\theta}) = \frac{1}{n} \sum_i \nabla_{\theta} m(z_i, \hat{\theta}) = \mathbf{0}$ 隐式定义。把 Ψ_n 在真值 θ_0 处做一阶 Taylor 展开：

$$\mathbf{0} = \Psi_n(\hat{\theta}) = \Psi_n(\theta_0) + D_{\theta} \Psi_n(\bar{\theta})(\hat{\theta} - \theta_0),$$

其中 $\bar{\theta}$ 介于 $\hat{\theta}$ 与 θ_0 之间（Lagrange 中间点）。解出并乘以 $\sqrt{n}$ ：

$$\sqrt{n}(\hat{\theta} - \theta_0) = -[D_{\theta} \Psi_n(\bar{\theta})]^{-1} \sqrt{n} \Psi_n(\theta_0).$$

对右边取极限：括号内的 Jacobian 依概率收敛到一个常数矩阵（Hessian 的期望）， $\sqrt{n} \Psi_n(\theta_0)$ 由中心极限定理趋于正态。两块拼起来就得到 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$ ，其中 Σ 是经典的“三明治”形式。可以看到：MLE、GMM、M-估计的渐近正态性，统统是“把一阶条件做一阶 Taylor 展开、再让 $n \rightarrow \infty$ ”这一招——这正是本章开头许诺的“渐近统计里估计量展开”的真面目。

一条主线

Taylor 展开把“复杂函数”换成“一点附近的多项式替身”，于是：一阶替身给出局部线性化（切线、切平面、Delta 法、M-估计的展开骨架）；二阶替身给出局部二次化，其曲率项是 Hessian 二次型，由它的正定性判定极值（二阶条件）、由它构造迭代（牛顿法）、由它（取期望后）拼出渐近方差。一件工具，串起最优化、数值方法与渐近统计三条线。下一步该问的自然是：什么样的函数，其二阶近似在**全局**都成立而非仅局部？答案是凹/凸函数——那是下一章的主题。

第十五章 隐函数定理与比较静态

用到的前置工具：偏导数、梯度、Jacobian 与 Hessian（第十三章）；矩阵求逆与正定矩阵（线性代数部分，正定性见第五章）。

如果要在经济学家天天使用的数学工具里只选一件作为“镇店之宝”，隐函数定理很可能当选。它之所以重要，不是因为它有多深，而是因为经济学问的问题恰好是它最擅长回答的那一类。本章先点明这类问题长什么样，再把单变量与多变量两个版本讲清楚，最后用两个经典场景说明：从市场的税负转嫁，到由一阶条件做的比较静态，背后都是同一把工具在起作用——甚至连“二阶条件”这种看似只关乎“是不是极大值”的东西，真正让比较静态有良定义的也是它。

15.1 从“解不出来”说起

经济学的结论，绝大多数是**比较静态**（comparative statics）的结论：某个外生条件——一项税、一笔收入、一个成本参数——动一下，作为均衡或最优选择的内生量会朝哪个方向、变动多少？需求曲线右移，价格涨还是跌、涨多少？征一笔从量税，消费者和生产者各承担多大份额？这些问句的数学形式，统统是“某个内生量对某个参数的导数”。

把这类问题抽象出来，总是同一个结构：有一个把内生量 x 与参数 p 联系起来的方程

$$F(x, p) = 0,$$

它可能是“供给等于需求”的市场出清条件，可能是“边际收益等于边际成本”的最优化一阶条件，也可能是某个不动点方程。我们真正关心的，是由它隐含地定义出来的关系 $x = x^*(p)$ ，尤其是它的导数 $\frac{dx^*}{dp}$ ——这正是比较静态。

麻烦在于：上面这个方程通常**解不出显式的** $x^*(p)$ 。需求与供给可能是任意的非线性函数，一阶条件可能是超越方程。换句话说，我们想要导数 $\frac{dx^*}{dp}$ ，却连函数 $x^*(p)$ 本身都写不出来。

隐函数定理正是为此而生。它告诉我们：只要在某一点满足一个温和的“非退化”条件，就不必解出 $x^*(p)$ ，也能断定这个函数在该点附近确实存在、而且可微，并直接给出它的导数表达式。这正是“工具性”的极致——把一个看似要先求解才能回答的问题，变成一道纯粹的求导练习。

15.2 单变量情形

定理 15.1: 隐函数定理 (单变量)

设 $F: \mathbb{R}^2 \rightarrow \mathbb{R}$ 在点 (x_0, p_0) 的某个邻域内连续可微, 且

$$F(x_0, p_0) = 0, \quad \frac{\partial F}{\partial x}(x_0, p_0) \neq 0.$$

则存在 p_0 的一个邻域 U 与定义在 U 上的连续可微函数 $x = x^*(p)$, 使得 $x^*(p_0) = x_0$, 并且对一切 $p \in U$ 都有 $F(x^*(p), p) = 0$ 。此外,

$$\frac{dx^*}{dp} = -\frac{\partial F / \partial p}{\partial F / \partial x}.$$

定理分两部分: “存在且可微”是较深的部分, “导数等于这个比值”是我们日常真正使用的部分。后者其实一眼可得。既然在 U 上恒有

$$F(x^*(p), p) \equiv 0,$$

这是一个关于 p 的恒等式, 两边对 p 求导 (左边用链式法则, 把 x^* 看成 p 的函数) 便得

$$\frac{\partial F}{\partial x} \cdot \frac{dx^*}{dp} + \frac{\partial F}{\partial p} = 0.$$

只要 $\partial F / \partial x \neq 0$, 就能把 $\frac{dx^*}{dp}$ 解出来, 正是定理中的公式。可以看到, 那个看似技术性的条件 $\partial F / \partial x \neq 0$, 恰恰就是“这一步除法做得下去”的保证。

注 (存在性是更深的部分) .

“ $x^*(p)$ 存在且可微”这半句话, 才是隐函数定理真正的数学内容, 其严格证明要用到压缩映射或反函数定理 (见第十二章)。直觉上它说的是: 曲线 $F = 0$ 在该点附近“不打弯成竖直”, 因而可以被看成以 p 为自变量的一条函数图像。本书按使用者的需要, 把存在性当作已知、把重点放在导数公式与它的经济学含义上。

几何图像。 方程 $F(x, p) = 0$ 在 (p, x) 平面上描出一条曲线——它是 F 的一条等值线 (零水平集)。条件 $\partial F / \partial x \neq 0$ 意味着这条曲线在该点处不是竖直的, 于是在该点附近, 曲线可以写成 x 关于 p 的函数图像 $x = x^*(p)$ (图 15.1)。沿着这条曲线移动时, 必须保持 F 的值不变 (始终为 0), 全微分 $\partial F / \partial x dx + \partial F / \partial p dp = 0$ 表达的正是这件事, 而它解出的 dx/dp 就是曲线的斜率。

注 (为什么 “ $\partial F / \partial x \neq 0$ ” 不可或缺) .

看 $F(x, p) = x^2 - p$ 在原点 $(0, 0)$: 此处 $\partial F / \partial x = 2x = 0$, 条件失效。事实上 $F = 0$ 给出 $x = \pm\sqrt{p}$ ——对 $p > 0$ 有上下两支、对 $p < 0$ 无解, 原点附近 x 根本不是 p 的单值函数 (曲线在此处切线竖直)。这时公式里的分母为零、导数“爆掉”, 对应的经济含义往往是均衡分叉或多重均衡。换言之, 那个非退化条件不是技术性累赘, 它




图 15.1: 零水平集 $F(x, p) = 0$ 在 (x_0, p_0) 附近不竖直, 故可表为函数图像 $x = x^*(p)$; 其斜率即由隐函数定理给出。

在守护“存在唯一一条可微的内生关系”这件事本身。

15.3 应用一：税负转嫁

考虑一个单一市场：消费者按价格 p 需求 $D(p)$, $D' < 0$; 政府对每单位交易向生产者征收从量税 t , 于是生产者实得 $p - t$, 供给为 $S(p - t)$, $S' > 0$ 。市场出清要求需求等于供给。把均衡价格 p 当内生量、税率 t 当参数, 出清条件写成

$$F(p, t) = D(p) - S(p - t) = 0.$$

我们想知道 $\frac{dp^*}{dt}$: 征税后消费者支付的价格会涨多少? 这正是“税最终由谁承担”的问题。即便 D, S 形式未知、 $p^*(t)$ 解不出来, 隐函数定理依然给得出答案。先算两个偏导:

$$\frac{\partial F}{\partial p} = D'(p) - S'(p - t) < 0, \quad \frac{\partial F}{\partial t} = S'(p - t) > 0.$$

于是

$$\frac{dp^*}{dt} = -\frac{\partial F / \partial t}{\partial F / \partial p} = -\frac{S'}{D' - S'} = \frac{S'}{S' - D'} \in (0, 1).$$

这个简洁的式子蕴含了全部的经济学。分母 $S' - D' > 0$, 故 $\frac{dp^*}{dt} \in (0, 1)$: 消费者价格的涨幅小于税额本身, 涨的那部分 $\frac{S'}{S' - D'}$ 就是消费者承担的税负份额, 余下的 $\frac{-D'}{S' - D'}$ 由生产者承担。当供给极富弹性 ($S' \rightarrow \infty$) 时份额趋于 1, 税几乎全压给消费者; 当需求极富弹性 ($D' \rightarrow -\infty$) 时份额趋于 0, 生产者几乎全担——“谁更难调整, 谁就承担更多”。这一整套结论, 我们没有解出 $p^*(t)$ 就拿到了。

15.4 多变量情形

经济学里内生量往往不止一个：一般均衡有一组价格，最优化有一组选择变量。把单变量定理升级到向量，关键的“非退化”条件从“一个偏导非零”变成“一个矩阵可逆”。

定理 15.2: 隐函数定理（一般形式）

设 $\mathbf{F}: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$ ，记作 $\mathbf{F}(\mathbf{x}, \mathbf{p})$ ，其中 $\mathbf{x} \in \mathbb{R}^n$ 为内生变量、 $\mathbf{p} \in \mathbb{R}^m$ 为参数。设 $\mathbf{F}$ 在 $(\mathbf{x}_0, \mathbf{p}_0)$ 邻域内连续可微， $\mathbf{F}(\mathbf{x}_0, \mathbf{p}_0) = \mathbf{0}$ ，且关于内生变量的 Jacobian

$$\mathbf{D}_{\mathbf{x}} \mathbf{F} = \left[\frac{\partial F_i}{\partial x_j} \right]_{n \times n}$$

在该点可逆。则在 $\mathbf{p}_0$ 附近存在唯一的连续可微映射 $\mathbf{x} = \mathbf{x}^*(\mathbf{p})$ ，满足 $\mathbf{x}^*(\mathbf{p}_0) = \mathbf{x}_0$ 与 $\mathbf{F}(\mathbf{x}^*(\mathbf{p}), \mathbf{p}) \equiv \mathbf{0}$ ，并且

$$\mathbf{D}_{\mathbf{p}} \mathbf{x}^* = - [\mathbf{D}_{\mathbf{x}} \mathbf{F}]^{-1} \mathbf{D}_{\mathbf{p}} \mathbf{F}.$$

推导与单变量如出一辙。把恒等式 $\mathbf{F}(\mathbf{x}^*(\mathbf{p}), \mathbf{p}) \equiv \mathbf{0}$ 两边关于 $\mathbf{p}$ 做全微分（链式法则的矩阵形式）：

$$\mathbf{D}_{\mathbf{x}} \mathbf{F} \mathbf{D}_{\mathbf{p}} \mathbf{x}^* + \mathbf{D}_{\mathbf{p}} \mathbf{F} = \mathbf{0}.$$

因为 $\mathbf{D}_{\mathbf{x}} \mathbf{F}$ 可逆，左乘其逆即解出 $\mathbf{D}_{\mathbf{p}} \mathbf{x}^*$ 。单变量里那个标量 $\partial F / \partial x \neq 0$ ，恰好是 $n = 1$ 时“矩阵可逆”的特例——可逆性扮演的就是“这一步矩阵除法做得下去”的角色。

15.5 应用二：从一阶条件做比较静态

这是隐函数定理在经济学里最常见、也最值得记住的用法。设决策者求解

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}; \boldsymbol{\theta}),$$

$\mathbf{x}$ 是选择变量、 $\boldsymbol{\theta} \in \mathbb{R}^m$ 是参数（偏好、价格、禀赋……）。内点最优解满足一阶条件

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*, \boldsymbol{\theta}) = \mathbf{0}.$$

这恰好是一个形如 $\mathbf{F}(\mathbf{x}, \boldsymbol{\theta}) = \mathbf{0}$ 的方程组，其中 $\mathbf{F} = \nabla_{\mathbf{x}} f$ 。对它套用隐函数定理，关键的 Jacobian 是

$$\mathbf{D}_{\mathbf{x}} \mathbf{F} = \mathbf{D}_{\mathbf{x}} \nabla_{\mathbf{x}} f = \nabla_{\mathbf{x}\mathbf{x}}^2 f = \mathbf{H},$$

也就是 f 关于选择变量的 **Hessian**——正是二阶条件里那个矩阵。于是比较静态公式为

$$\mathbf{D}_{\boldsymbol{\theta}} \mathbf{x}^* = -\mathbf{H}^{-1} \nabla_{\mathbf{x}\boldsymbol{\theta}}^2 f, \quad \nabla_{\mathbf{x}\boldsymbol{\theta}}^2 f = \left[\frac{\partial^2 f}{\partial x_i \partial \theta_k} \right].$$

二阶条件不只是“判极值”，它还让比较静态有良定义

内点极大值的二阶充分条件是 Hessian $\mathbf{H}$ 负定。负定矩阵必然可逆——而这恰恰就是隐函数定理对 $\mathbf{F} = \nabla_{\mathbf{x}} f$ 的适用前提！于是：只要你找到的是一个满足二阶条件的内点极大值，比较静态 $D_{\theta} \mathbf{x}^* = -\mathbf{H}^{-1} \nabla_{\mathbf{x}\theta}^2 f$ 就自动有定义、并可由此算出。换句话说，二阶条件一身二任：既保证你停在山顶，又保证“参数动一下、最优选择平滑地跟着动”。

在标量情形（一个选择变量 x 、一个参数 θ ）这条公式格外透亮：

$$\frac{dx^*}{d\theta} = -\frac{\partial^2 f / \partial x \partial \theta}{\partial^2 f / \partial x^2} = -\frac{f_{x\theta}}{f_{xx}}.$$

二阶条件是 $f_{xx} < 0$ ，所以

$$\text{sgn}\left(\frac{dx^*}{d\theta}\right) = \text{sgn}(f_{x\theta}).$$

最优选择随参数变动的方向，完全由目标函数的交叉偏导符号决定：若 θ 提高了选择变量的边际收益（ $f_{x\theta} > 0$ ，二者“互补”），则最优 x^* 随 θ 上升，反之下降。这个朴素的洞见，正是“单调比较静态”（第二十三章，Topkis 与超模性）的种子——后者更进一步，连可微、连 Hessian 可逆都不再需要，只靠“互补”这个序结构就能定出方向。

例（需求截距上升如何抬高垄断产量）。

线性需求 $p = a - bq$ ($a, b > 0$)、单位成本 c 的垄断者，利润为 $\pi(q; a) = (a - bq)q - cq$ 。求需求截距 a 上升对最优产量的影响 $\frac{dq^*}{da}$ 。

解。

这里 $f = \pi$ 、选择变量是 q 、参数取 a 。所需的两个二阶偏导为

$$\pi_{qq} = \frac{\partial^2 \pi}{\partial q^2} = -2b < 0 \quad (\text{二阶条件满足}), \quad \pi_{qa} = \frac{\partial^2 \pi}{\partial q \partial a} = \frac{\partial}{\partial a} (a - 2bq - c) = 1.$$

代入公式：

$$\frac{dq^*}{da} = -\frac{\pi_{qa}}{\pi_{qq}} = -\frac{1}{-2b} = \frac{1}{2b} > 0.$$

需求截距上升，最优产量随之上升。本例的一阶条件 $a - 2bq - c = 0$ 能直接解出 $q^* = (a - c)/(2b)$ ，对 a 求导同样得 $1/(2b)$ ——正好用这个能解的简单情形，印证隐函数定理给出的公式无误。真正的价值在于：当一阶条件无法显式求解时，上面这套做法照旧成立。

15.6 失效的时候，以及它通向何处

隐函数定理失效意味着什么

当 $D_x \mathbf{F}$ 奇异（行列式为零、Hessian 退化）时定理不适用。在经济学里这通常对应：均衡分叉、多重均衡、或目标函数恰在某个参数值上从单峰变为多峰的临界点。此时比较静态可能不连续、甚至无定义。两条出路：(i) 退一步，只问“方向”而不问“大小”——这正是**单调比较静态**（第二十三章）的领域，它不要求可微、也不要求 Hessian 可逆，只依赖目标函数的互补（超模）结构；(ii) 借助更强的拓扑工具（不动点、度理论，第十一章）讨论均衡的存在与个数。

最后值得记住的是，本章这把工具远不止用于微观。它的几处重要去处：

- **包络定理**（第二十二章）补上了另一半故事——隐函数定理告诉你“最优选择如何随参数变”，包络定理告诉你“最优值如何随参数变”，二者常常配套出现。
- **Slutsky 方程**是消费者理论里隐函数定理的集大成应用：对马歇尔需求背后的一阶条件做隐函数微分，就分解出替代效应与收入效应。
- **估计量的渐近分布**（第三十四章）。M-估计量 $\hat{\theta}$ 由样本一阶条件 $\frac{1}{n} \sum_i \nabla_{\theta} m(z_i, \hat{\theta}) = 0$ 隐含定义；把它对样本扰动做隐函数式的展开，正是导出 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(\cdot)$ 的核心一步——计量里的 Delta 法与三明治协方差矩阵，骨子里都是隐函数定理。

一件工具，三门核心课。这正是本书想反复呈现的：少数几个数学构造，被反复用在看似无关的经济学问题上；认清了工具本身，就等于同时拿到了许多扇门的钥匙。

第十六章 凹凸函数与拟凹、拟凸

用到的前置工具：偏导数、梯度与 Hessian（多元微分一章，第十三章）；Taylor 展开与二阶近似（第十四章）；对称矩阵的正定/半正定性（线性代数部分，谱定理与二次型见第五章）。

上一章的隐函数定理告诉我们，只要二阶条件成立，一阶条件就刻画了一个“好”的最优解、比较静态也随之有定义。但那里我们偷偷预设了一件事：手上这个一阶条件的解确实是我们想要的极大值，而不是极小值、鞍点，或者只是众多局部极大里不起眼的的一个。一阶条件 $\nabla f = \mathbf{0}$ 本身分不清这些情形——它只是“驻点”的方程。真正把驻点升格为“全局最优”的，是目标函数的形状：它得是“凹”的。

这正是本章要讲的工具。凹凸性是最优化的**保证书**：目标函数一旦凹，局部极大自动就是全局极大，一阶条件从“必要”升级为“充分”，“找到一个驻点”就等于“解完了问题”。这件事的分量怎么强调都不过分——经济学里几乎每一个“存在唯一最优解”的论断，背后都站着某种凹凸性假设。本章先把凸集与凹凸函数的几种等价说法讲清楚（弦、上方图、切线、Hessian 一层层递进），再证明那条核心承诺（凹 $\implies$ 局部最优即全局最优），然后推广到经济学真正需要的、比凹凸更弱的概念——**拟凹与拟凸**，它才是消费者理论里“凸偏好”的正确数学表达。最后用 Jensen 不等式把凹凸性接到风险厌恶上。

16.1 凸集：一切的地基

谈“凹凸函数”之前，得先有“凸集”——因为函数的定义域、约束集、以及后面要用的上方图、等值集，都需要是凸的才好谈。凸集的定义朴素到近乎平凡，但正是它撑起了整套理论。

定义 16.1: 凸集

集合 $C \subseteq \mathbb{R}^n$ 称为**凸集**，如果对任意两点 $\mathbf{x}, \mathbf{y} \in C$ 与任意 $\lambda \in [0, 1]$ ，都有

$$\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in C.$$

也就是说， C 中任意两点的连线段整段都落在 C 内。

表达式 $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ (λ 从 1 走到 0) 恰好扫过从 $\mathbf{x}$ 到 $\mathbf{y}$ 的整条线段，叫做这两点的**凸组合**。所以凸集就是“对取凸组合封闭”的集合（图 16.1）。常见的凸集：全空

间 $\mathbb{R}^n$ 、任意区间、半空间 $\{x: a^T x \leq b\}$ 、超平面、球、以及——这一点对最优化至关重要——任意一族凸集的交仍是凸集。预算集 $\{x \geq 0: p^T x \leq m\}$ 就是若干半空间的交，因而是凸的。




图 16.1: 凸集与非凸集。判据只看一件事：任取两点，连接它们的整条线段是否都留在集合内。

为什么经济学离不开凸集

凸集是消费者理论里“凸偏好”的几何载体（“混合”不差于极端，无差异曲线向原点弯），是生产理论里生产可能集的标准假设，更是凸规划赖以成立的前提——在凸集上极大化凹函数，局部最优即全局最优、KKT 条件充分（第二十、二十一章）。一旦约束集非凸（如“整数”约束、固定成本带来的不可分性），这些便利统统失效，问题立刻变难。

16.2 凹函数与凸函数

有了凸的定义域，就能谈函数的“弯法”。直觉是：凸函数像一只碗（开口朝上），凹函数像一座山（开口朝下）。把这句话精确化，最原始的方式是看弦与曲线的相对位置。

定义 16.2: 凹函数与凸函数

设 $C \subseteq \mathbb{R}^n$ 为凸集， $f: C \rightarrow \mathbb{R}$ 。称 f 为**凸函数**，如果对任意 $x, y \in C$ 与 $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y);$$

称 f 为**凹函数**，如果上式中的不等号反向 ($\geq$)。若 $x \neq y$ 、 $\lambda \in (0, 1)$ 时不等号严格成立，则分别称为**严格凸**、**严格凹**。

不等式右边 $\lambda f(x) + (1 - \lambda)f(y)$ 是连接两点 $(x, f(x))$ 、 $(y, f(y))$ 的弦在横坐标 $\lambda x + (1 - \lambda)y$ 处的高度；左边是函数本身在同一处的高度。于是定义说的正是：**凸函数的弦永远在曲线上方，凹函数的弦永远在曲线下方**（图 16.2）。立刻可见 f 凹 $\iff -f$ 凸——这条对偶让我们只需证一边的定理，另一边自动成立；本章证明多按凹函数来写，因为最优化里出场的是“极大化凹目标”。




图 16.2: 凹凸的“弦判据”。凸：弦在曲线上方；凹：弦在曲线下方。虚线段示意弦与曲线在内点处的高度差。

用“上方图/下方图”把函数翻译成集合

弦的定义虽直观，却把“函数”和“集合”两套语言混在一起。有一种更漂亮的等价刻画，能把凹凸性彻底翻译成凸集的语言，从而让上一节关于凸集的一切（特别是“凸集的交还是凸集”）都能拿来即用。

定义 16.3: 上方图与下方图

函数 $f: C \rightarrow \mathbb{R}$ 的下方图 (epigraph, “图像及其上方”) 与上方图 (hypograph, “图像及其下方”) 分别是 $\mathbb{R}^{n+1}$ 中的集合

$$\text{epi } f = \{(\mathbf{x}, t) : \mathbf{x} \in C, t \geq f(\mathbf{x})\}, \quad \text{hyp } f = \{(\mathbf{x}, t) : \mathbf{x} \in C, t \leq f(\mathbf{x})\}.$$

命题 16.4: 凹凸的集合刻画

f 是凸函数 $\iff \text{epi } f$ 是凸集; f 是凹函数 $\iff \text{hyp } f$ 是凸集。

证明. 只证凸函数一侧 (凹的情形对 $-f$ 用之即得)。设 f 凸, 取 $\text{epi } f$ 中两点 $(\mathbf{x}, s)$ 、 $(\mathbf{y}, t)$, 即 $s \geq f(\mathbf{x})$ 、 $t \geq f(\mathbf{y})$ 。对 $\lambda \in [0, 1]$, 由凸性与 s, t 的下界,

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}) \leq \lambda s + (1 - \lambda) t,$$

这说明 $(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}, \lambda s + (1 - \lambda) t) \in \text{epi } f$, 故 $\text{epi } f$ 凸。反之, 若 $\text{epi } f$ 凸, 取其上的两点 $(\mathbf{x}, f(\mathbf{x}))$ 、 $(\mathbf{y}, f(\mathbf{y}))$, 它们的凸组合 $(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}, \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}))$ 也在 $\text{epi } f$ 内, 按定义即得 $f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y})$, 即 f 凸。□

注 (这个翻译为什么值钱)。

“ f 凸 $\iff \text{epi } f$ 凸”把对函数的判断转成对集合的判断，许多性质于是“免费”得到。例如：一族凸函数的逐点上确界 $\sup_{\alpha} f_{\alpha}$ 仍凸——因为 $\text{epi}(\sup_{\alpha} f_{\alpha}) = \bigcap_{\alpha} \text{epi } f_{\alpha}$ 是凸集之交、自然是凸集。对偶地，一族凹函数的逐点下确界仍凹。后面讲值函数与对偶时（第二十一、二十二章），“上确界保持凸性”正是关键一步。

16.3 光滑情形：一阶判据与二阶判据

弦判据对一切函数都管用，但要逐对点去验未免笨拙。当 f 可微、乃至二阶可微时，凹凸性有两个用起来顺手得多的等价刻画——它们也正是日后做最优化时真正动手算的判据。

一阶判据：切线（切平面）兜住曲线

定理 16.5: 一阶判据

设 $C \subseteq \mathbb{R}^n$ 为开凸集， $f: C \rightarrow \mathbb{R}$ 连续可微。则

$$f \text{ 凹} \iff f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}) \quad \text{对一切 } \mathbf{x}, \mathbf{y} \in C.$$

凸函数对应不等号反向 ($\geq$)。严格凹/凸对应 $\mathbf{y} \neq \mathbf{x}$ 时严格不等。

证明. 证凹的情形。式子右边 $f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x})$ 正是 f 在 $\mathbf{x}$ 处的切平面在 $\mathbf{y}$ 点的高度；不等式说的是：凹函数处处落在它任一点的切平面之下（图 16.3 左）。

($\implies$) 设 f 凹。对 $\lambda \in (0, 1]$ ，由凹性

$$f(\mathbf{x} + \lambda(\mathbf{y} - \mathbf{x})) = f((1 - \lambda)\mathbf{x} + \lambda\mathbf{y}) \geq (1 - \lambda)f(\mathbf{x}) + \lambda f(\mathbf{y}),$$

移项整理得

$$\frac{f(\mathbf{x} + \lambda(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{\lambda} \geq f(\mathbf{y}) - f(\mathbf{x}).$$

令 $\lambda \downarrow 0$ ，左边趋于方向导数 $\nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x})$ ，于是 $\nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}) \geq f(\mathbf{y}) - f(\mathbf{x})$ ，即所证。

($\impliedby$) 设切平面不等式对一切点成立。取 $\mathbf{x}, \mathbf{y}, \lambda \in [0, 1]$ ，记凸组合 $\mathbf{z} = \lambda\mathbf{x} + (1 - \lambda)\mathbf{y}$ 。把不等式分别用在 $(\mathbf{z}, \mathbf{x})$ 与 $(\mathbf{z}, \mathbf{y})$ 上：

$$f(\mathbf{x}) \leq f(\mathbf{z}) + \nabla f(\mathbf{z})^T(\mathbf{x} - \mathbf{z}), \quad f(\mathbf{y}) \leq f(\mathbf{z}) + \nabla f(\mathbf{z})^T(\mathbf{y} - \mathbf{z}).$$

以权 $\lambda, 1 - \lambda$ 加权求和，注意 $\lambda(\mathbf{x} - \mathbf{z}) + (1 - \lambda)(\mathbf{y} - \mathbf{z}) = \mathbf{0}$ ，梯度项消去，得

$$\lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \leq f(\mathbf{z}) = f(\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}),$$

正是凹性。 □

二阶判据：Hessian 半负定

一阶判据已好用，但“对一切 $\mathbf{x}, \mathbf{y}$ 成立”仍是个全局条件。若 f 二阶可微，凹凸性可以被压缩成一个局部且逐点可验的条件——只看一个矩阵的符号。这是经济学里出场频率最高的判据。

定理 16.6: 二阶判据

设 $C \subseteq \mathbb{R}^n$ 为开凸集, $f: C \rightarrow \mathbb{R}$ 二阶连续可微, 记其 Hessian 为 $\mathbf{H}(\mathbf{x}) = \nabla^2 f(\mathbf{x})$ 。则

$$f \text{ 凹} \iff \mathbf{H}(\mathbf{x}) \text{ 半负定, 对一切 } \mathbf{x} \in C.$$

$f \text{ 凸} \iff \mathbf{H}$ 处处半正定。进一步, $\mathbf{H}$ 处处负定 $\implies f$ 严格凹 (反之不必, 如 $-x^4$)。

证明. 对任意 $\mathbf{x}, \mathbf{y} \in C$, 沿连线把 f 在 $\mathbf{x}$ 处做带 Lagrange 余项的二阶 Taylor 展开 (第十四章): 存在 $\xi \in (0, 1)$ 、记 $\mathbf{z} = \mathbf{x} + \xi(\mathbf{y} - \mathbf{x})$, 使

$$f(\mathbf{y}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x}) + \frac{1}{2}(\mathbf{y} - \mathbf{x})^\top \mathbf{H}(\mathbf{z})(\mathbf{y} - \mathbf{x}).$$

若 $\mathbf{H}$ 处处半负定, 二次型项 ≤ 0 , 于是 $f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$ ——这正是上一条定理里的一阶判据, 故 f 凹。反过来, 若某点 $\mathbf{x}_0$ 处 $\mathbf{H}(\mathbf{x}_0)$ 不半负定, 则存在方向 $\mathbf{v}$ 使 $\mathbf{v}^\top \mathbf{H}(\mathbf{x}_0) \mathbf{v} > 0$; 由连续性, 在 $\mathbf{x}_0$ 附近沿 $\mathbf{v}$ 走, 上式二次型项为正, 一阶判据被破坏, f 在该处非凹。半负定与凹由此互为充要。□




图 16.3: 左: 凹函数处处落在其任一点切平面之下 (一阶判据)。右: 单变量下, 凸是“碗” $f'' \geq 0$ 、凹是“山” $f'' \leq 0$; 多变量则换成 Hessian 半正定/半负定。

在 $n = 1$ 时, Hessian 退化为标量 $f''(x)$: 凹 $\iff f'' \leq 0$ 、凸 $\iff f'' \geq 0$, 正是中学“二阶导判凹凸”那条规则的母版。多变量下, “ $f'' \leq 0$ ”被“Hessian 半负定”接管——而半负定与否, 由谱定理 (特征值全 ≤ 0 , 见第五章) 或主子式判据来判定。

例 (Cobb–Douglas 是不是凹的)。

生产函数 $f(x_1, x_2) = x_1^a x_2^b$ ($x_1, x_2 > 0$, $a, b > 0$)。问：何时它在正象限上凹？

解.

先算梯度与 Hessian。一阶偏导

$$f_1 = a x_1^{a-1} x_2^b = \frac{a}{x_1} f, \quad f_2 = \frac{b}{x_2} f.$$

二阶偏导（利用 f_1, f_2 的上式再求导）：

$$f_{11} = \frac{a(a-1)}{x_1^2} f, \quad f_{22} = \frac{b(b-1)}{x_2^2} f, \quad f_{12} = \frac{ab}{x_1 x_2} f.$$

Hessian 半负定的判据 (2×2) 是：对角元 ≤ 0 且行列式 ≥ 0 。对角元 $f_{11} \leq 0$, $f_{22} \leq 0$ 要求 $a \leq 1$, $b \leq 1$ 。再看行列式：

$$\det \mathbf{H} = f_{11} f_{22} - f_{12}^2 = \frac{f^2}{x_1^2 x_2^2} [a(a-1)b(b-1) - a^2 b^2] = \frac{f^2}{x_1^2 x_2^2} ab[(a-1)(b-1) - ab].$$

方括号 $= (a-1)(b-1) - ab = 1 - a - b$ 。因 $ab > 0$ ，故 $\det \mathbf{H} \geq 0 \iff a + b \leq 1$ 。而 $a + b \leq 1$ 已蕴含 $a \leq 1, b \leq 1$ ，对角元条件自动满足。结论：**Cobb-Douglas 在正象限凹 $\iff a + b \leq 1$** ，即规模报酬不递增。这把一个纯数学条件（Hessian 半负定）翻译成了一句生产理论的话——可这同时暴露一个尴尬：规模报酬递增 ($a + b > 1$) 的 Cobb-Douglas 并不凹，难道效用/产出递增就没法谈最优化了？答案藏在下一节：它虽不凹，却仍拟凹，而拟凹往往已经够用。

16.4 核心承诺：凹函数的局部最大就是全局最大

现在兑现本章开头那张“保证书”。这条结论是凹凸性在最优化里全部价值的源头。

定理 16.7: 凹函数的局部最优即全局最优

设 $C \subseteq \mathbb{R}^n$ 为凸集， $f: C \rightarrow \mathbb{R}$ 凹。若 $\mathbf{x}^*$ 是 f 在 C 上的局部极大点，则它必是全局极大点。若 f 严格凹，则全局极大点至多一个。

证明. 反证。设 $\mathbf{x}^*$ 为局部极大，却存在 $\mathbf{y} \in C$ 使 $f(\mathbf{y}) > f(\mathbf{x}^*)$ 。因 C 凸，连线段 $\mathbf{z}_\lambda = (1-\lambda)\mathbf{x}^* + \lambda\mathbf{y}$ ($\lambda \in [0, 1]$) 整段落在 C 内。由凹性，

$$f(\mathbf{z}_\lambda) \geq (1-\lambda)f(\mathbf{x}^*) + \lambda f(\mathbf{y}) = f(\mathbf{x}^*) + \lambda[f(\mathbf{y}) - f(\mathbf{x}^*)] > f(\mathbf{x}^*) \quad \text{对一切 } \lambda \in (0, 1].$$

也就是说，从 $\mathbf{x}^*$ 朝 $\mathbf{y}$ 哪怕只挪一点点 (λ 任意小)，函数值都严格高于 $f(\mathbf{x}^*)$ 。这与“ $\mathbf{x}^*$ 是局部极大”（其某邻域内无更高点）矛盾。故不存在这样的 $\mathbf{y}$ ， $\mathbf{x}^*$ 是全局极大。

唯一性：设 f 严格凹， $\mathbf{x}_1 \neq \mathbf{x}_2$ 同为全局极大、值同为 M 。取中点 $\mathbf{m} = \frac{1}{2}\mathbf{x}_1 + \frac{1}{2}\mathbf{x}_2 \in C$ ，严格凹给出 $f(\mathbf{m}) > \frac{1}{2}f(\mathbf{x}_1) + \frac{1}{2}f(\mathbf{x}_2) = M$ ，比最大值还大，矛盾。□

这条定理的逆命题方向同样有用：它让一阶条件从“必要”升级为“充分”。无约束情形下，凹函数的驻点（ $\nabla f = \mathbf{0}$ ）自动是全局极大——因为一阶判据 $f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top(\mathbf{y} - \mathbf{x})$ 在 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 处直接退化为 $f(\mathbf{y}) \leq f(\mathbf{x}^*)$ 对一切 $\mathbf{y}$ 成立。

凹性 = “一阶条件就够用”的通行证

非凹问题里，一阶条件 $\nabla f = \mathbf{0}$ 只是必要条件：解出驻点后还得查二阶条件、还得操心它是不是众多局部极大里最高的那个、甚至会不会是鞍点。一旦 f 凹（且定义域凸），这些顾虑一扫而空：任一驻点都是全局极大，“求一阶条件的解”与“求全局最优”变成同一件事。这就是为什么经济学模型几乎言必称凹——它不是为了好看，而是为了让“一阶条件刻画最优”这套全书最常用的推理合法。约束情形下的对应物，是凸规划与 KKT 条件的充分性（第二十、二十一章）。

16.5 拟凹与拟凸：经济学真正需要的弱化

凹性很美，但它太强了。回看上一节的尴尬：规模报酬递增的 Cobb-Douglas 不凹；更要命的是，效用函数本该是序数的——对效用做一个单调递增变换（如 $u \mapsto u^3$ 或 $u \mapsto \log u$ ）不改变偏好、不改变任何需求行为，可这种变换轻易就能把凹函数变成非凹函数。既然偏好不变、最优选择不变，“凹”就不可能是偏好的本质属性。我们需要一个对单调变换免疫的、更弱的概念——它只关心“等值集的形状”，而非“曲线弯多狠”。这就是拟凹。

定义 16.8: 拟凹与拟凸

设 $C \subseteq \mathbb{R}^n$ 为凸集， $f: C \rightarrow \mathbb{R}$ 。称 f 拟凹，如果它的每个上等值集

$$U_c = \{\mathbf{x} \in C : f(\mathbf{x}) \geq c\}$$

都是凸集（对一切 $c \in \mathbb{R}$ ）；称 f 拟凸，如果它的每个下等值集 $\{\mathbf{x} : f(\mathbf{x}) \leq c\}$ 都是凸集。等价地， f 拟凹 $\iff$ 对任意 $\mathbf{x}, \mathbf{y}$ 与 $\lambda \in [0, 1]$,

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \geq \min\{f(\mathbf{x}), f(\mathbf{y})\}.$$

后一个等价说法（“凸组合处的值不低于两端的较小者”）最便于记忆：在两点之间，函数不会“塌陷”到比两端都低。这正是“单峰”的多维推广。在消费者理论里，上等值集 U_c 就是“不差于某条无差异曲线的所有消费束”——它凸，意味着把两个一样好的消费束混合起来，不会更差，这恰是“凸偏好”的标准假设，也是无差异曲线凸向原点的来由。




图 16.4: 一个拟凹但非凹的单峰函数。每条水平线 $f = c$ 切出的上等值集都是一段区间 (凸), 故拟凹; 但左侧上升段是凸的, 那里的弦落在曲线上方, 故不凹。

与凹凸的包含关系

命题 16.9: 凹 $\implies$ 拟凹 (反之不然)

凹函数必拟凹; 凸函数必拟凸。反之不成立。

证明. 设 f 凹, 取上等值集 U_c 中两点 $\mathbf{x}, \mathbf{y}$ (即 $f(\mathbf{x}) \geq c$ 、 $f(\mathbf{y}) \geq c$) 与 $\lambda \in [0, 1]$ 。由凹性,

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \geq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \geq \lambda c + (1 - \lambda)c = c,$$

故凸组合仍在 U_c 内, U_c 凸, f 拟凹。反例见图 16.4 的单峰函数: 它拟凹却不凹。更醒目的反例是任何单调函数—— $\mathbb{R}$ 上的单调 (增或减) 函数既拟凹又拟凸 (上、下等值集都是射线, 自然是凸的), 但单调函数一般既不凹也不凸 (如 $f(x) = x^3$)。□

这条包含关系是“拟凹比凹弱”的精确含义: 凹是“弦在曲线下方” (关乎高度), 拟凹只要“等值集是凸集” (关乎形状)。前者会被单调变换破坏, 后者不会——若 g 是严格增函数, 则 $g \circ f$ 与 f 有完全相同的上等值集 $\{x : g(f(x)) \geq g(c)\} = \{x : f(x) \geq c\}$, 故 f 拟凹 $\implies g \circ f$ 拟凹。这正是拟凹“对序数效用免疫”的根源。

例 (拟凹效用足以保证一阶条件刻画需求)。

为什么消费者理论只假设效用拟凹、而不强求凹?

解.

考虑预算约束下的效用极大化 $\max_{\mathbf{x}} u(\mathbf{x})$ s.t. $\mathbf{p}^\top \mathbf{x} \leq m$, $\mathbf{x} \geq \mathbf{0}$ 。预算集是凸的 (半空间之交)。若 u 拟凹且在最优点处梯度非零, 则“相切”的一阶条件 (边际替代率 = 价格比) 就足以定出最优消费束: 拟凹保证上等值集 $\{u \geq u(\mathbf{x}^*)\}$ 是凸集, 它与凸预算集在最优点相切而不交错, 于是没有别处能在预算内取得更高效用——切点

即全局最优。这恰好不需要凹性：把 u 换成 u^3 ，需求一点不变，而 u^3 可能已不凹。拟凹是“偏好凸”与“一阶条件刻画需求”的最弱充分条件，这也是它在微观里取代凹性、成为效用标准假设的原因。约束最优化里拟凹目标 + 凸约束何时让 KKT 充分，将在第二十、二十一章细讲。

16.6 Jensen 不等式：凹凸性遇上期望

把凹凸定义里的“两点凸组合”换成“一般概率分布下的期望”，弦判据就升级为概率论中分量极重的 Jensen 不等式。它是凹凸性通往不确定性与风险的桥。

定理 16.10: Jensen 不等式

设 X 是取值于凸集 $C \subseteq \mathbb{R}^n$ 的随机向量、期望 $\mathbb{E}(X)$ 存在。若 $f: C \rightarrow \mathbb{R}$ 凹，则

$$\mathbb{E}(f(X)) \leq f(\mathbb{E}(X)).$$

f 凸时不等号反向。若 f 严格凹且 X 非退化（不是几乎处处等于常数），则不等号严格。

证明. 用一阶判据，取 $\mathbf{x}_0 = \mathbb{E}(X)$ 。凹函数落在其在 $\mathbf{x}_0$ 处切平面之下，对每一个实现值 X 都有

$$f(X) \leq f(\mathbb{E}(X)) + \nabla f(\mathbb{E}(X))^T (X - \mathbb{E}(X)).$$

两边取期望。右边第二项 $\nabla f(\mathbb{E}(X))^T \mathbb{E}(X - \mathbb{E}(X)) = \nabla f(\mathbb{E}(X))^T \mathbf{0} = \mathbf{0}$ ，于是

$$\mathbb{E}(f(X)) \leq f(\mathbb{E}(X)),$$

即所证。严格性来自： f 严格凹时切平面只在 $\mathbf{x}_0$ 一点与曲线相切、别处严格在上方， X 非退化便以正概率取到 $\mathbf{x}_0$ 以外的值，期望处不等号严格。□

几何上（图 16.5），对两点等概率分布， $\mathbb{E}(f(X))$ 就是弦的中点高度、 $f(\mathbb{E}(X))$ 是曲线在中点的高度——凹函数弦在下，于是 $\mathbb{E}(f(X)) \leq f(\mathbb{E}(X))$ 。一般分布无非是“多点弦”（凸包）的推广。

凹效用 = 风险厌恶

设个体的财富效用 u 凹。面对一笔均值为 $\mathbb{E}(X)$ 的随机收益 X ，Jensen 给出

$$\mathbb{E}(u(X)) \leq u(\mathbb{E}(X)):$$

他对赌局的期望效用，不超过直接拿到期望财富 $\mathbb{E}(X)$ 的效用。换言之，他宁愿要确定的 $\mathbb{E}(X)$ 也不愿要均值同为 $\mathbb{E}(X)$ 的彩票——这正是风险厌恶的定义。曲线弯得越狠（ u'' 越负），Jensen 间隙越大，风险厌恶越强；间隙折算成确定性收益的损失，就是风险溢价。凹凸性在这里不再只是最优化的技术条件，它就是对风险态度的刻画。这套语言贯穿决策论、保险、资产定价与契约理论。




图 16.5: Jensen 不等式的几何 (两点等概率)。凹效用 u 的弦在曲线下方, 弦中点高度 $\mathbb{E}(u(X))$ 低于曲线在 $\mathbb{E}(X)$ 处的高度 $u(\mathbb{E}(X))$; 二者之差即 Jensen 间隙。

16.7 它通向何处

凹凸与拟凹凸是全书后续几大块的共同地基, 这里把去处一并标清, 方便日后回查:

- **消费者与生产理论。**拟凹效用给出凸偏好与凸向原点的无差异曲线, 使“边际替代率 = 价格比”的一阶条件刻画马歇尔需求; 凹生产函数 (如 $a+b \leq 1$ 的 Cobb–Douglas) 保证成本极小化与利润极大化有良性解。需求/供给的诸多比较静态 (上一章的隐函数微分) 都默认了这层凹凸性。
- **凸优化与 KKT 充分性** (第二十、二十一章)。“在凸集上极大化凹 (或拟凹) 目标”是凸规划, 本章的“局部最优即全局最优”在约束情形下升级为: KKT 一阶条件不再只是必要, 而成为充分——这是应用中“解一阶条件即解完问题”的合法性来源。对偶理论也建立在 epigraph 的凸性之上。
- **风险与不确定性。**凹效用 + Jensen = 风险厌恶, 进而是风险溢价、保险需求、Arrow–Pratt 风险厌恶度量、以及资产定价里的随机折现因子。决策论与契约理论里“凹”几乎等同于“谨慎”。
- **计量经济学。**许多估计量来自极大化一个目标函数: MLE 极大化对数似然, 许多模型 (如 Logit、Probit、指数族) 的对数似然全局凹, 于是数值优化必收敛到唯一全局极大、估计良性、不受初值困扰。GMM 与 M-估计的目标函数凹凸性, 同样决定了优化是否稳健。这也是为什么计量里“对数似然凹”被视为一个模型“好用”的重要信号。

凹凸性之所以贯穿这么多领域, 是因为它回答了一个所有最优化问题都绕不开的元问题: 什么时候一阶条件就够用? 凹 (或拟凹) 给出的答案是“现在就够”, 于是我们得以把“求最优”安心地化简为“解方程”——这正是经济学日常推理赖以运转的支点。

第十七章 齐次函数与欧拉定理

用到的前置工具：偏导数、梯度与链式法则（第十三章）；等值线与水平集（隐函数定理一章）；单调变换的概念（见后文『凹凸函数与拟凹/拟凸』一章）。

经济学里有一类问题，问的不是“某个量是多少”，而是“把所有投入同比例放大一倍，产出会怎么变”——规模报酬是不是不变？把所有价格和收入同时翻一番，需求会不会动——会不会有“货币幻觉”？竞争市场里每种要素都按它的边际产品取酬，加起来会不会恰好把总产出分光、一分不多一分不少？这三问表面上分属生产理论、消费理论与分配理论，却共用同一个数学性质：函数沿过原点的射线如何缩放。刻画这件事的工具就是**齐次函数**，而把“齐次度”与“各偏导之和”钉死在一起的，是**欧拉定理**。本章先讲清这两个对象，再说明它们如何一举回答上面三问，并把位似（homothetic）这个更宽松、却在消费理论里更常用的推广接上。

17.1 从“同比例放大”说起

先把动机摆透。考虑一个生产函数 $f(\mathbf{x})$ ， $\mathbf{x} = (x_1, \dots, x_n)$ 是各种要素投入量。一个最基本的问题是：如果把每一种投入都乘以同一个倍数 $t > 1$ （多上一倍人手、一倍机器、一倍原料），产出 $f(t\mathbf{x})$ 相对于原产出 $f(\mathbf{x})$ 是大于、等于还是小于 t 倍？

- 若恰好 $f(t\mathbf{x}) = t f(\mathbf{x})$ ——投入翻倍产出也翻倍——称**规模报酬不变**（CRS）。
- 若 $f(t\mathbf{x}) > t f(\mathbf{x})$ ——产出涨得比投入快——称**规模报酬递增**（IRS）。
- 若 $f(t\mathbf{x}) < t f(\mathbf{x})$ ——称**规模报酬递减**（DRS）。

这里的关键词是“同比例”：我们不是动一种投入，而是沿着从原点出发、穿过点 $\mathbf{x}$ 的那条射线移动（射线上的点正是 $t\mathbf{x}$ ， $t > 0$ ）。于是“规模报酬”这个经济概念，本质上是在问：函数沿过原点的射线如何缩放。齐次函数恰好是把这种缩放规律定得最干净的一类函数。

17.2 齐次函数

定义 17.1: k 次齐次函数

设 $f: D \rightarrow \mathbb{R}$, 定义域 $D \subseteq \mathbb{R}^n$ 是一个锥 (即 $\mathbf{x} \in D$ 蕴含 $t\mathbf{x} \in D$ 对一切 $t > 0$ 成立, 例如正卦限 $\mathbb{R}_{++}^n$)。称 f 为 k 次齐次 (homogeneous of degree k), 若对一切 $\mathbf{x} \in D$ 与一切 $t > 0$ 都有

$$f(t\mathbf{x}) = t^k f(\mathbf{x}).$$

这里 k 是任意实数, 称为 f 的齐次度。

齐次度 k 把上一节的规模报酬分类一网打尽: $k = 1$ 是 CRS, $k > 1$ 是 IRS, $0 < k < 1$ 是 DRS。沿一条固定射线看, 沿线的取值完全被 t^k 这一条曲线支配 (图 17.1): 选定一点 $\mathbf{x}$ 、记 $g(t) = f(t\mathbf{x})$, 则齐次性说 $g(t) = t^k g(1)$ 。 $k = 1$ 时 g 是过原点的直线, $k > 1$ 时凸 (加速上升), $0 < k < 1$ 时凹 (边际放缓)。




图 17.1: 沿过原点的射线, 齐次函数的取值由 $g(t) = t^k f(\mathbf{x})$ 支配 (图中已归一化 $f(\mathbf{x}) = 1$, 三条曲线都过 $(1, 1)$)。 $k = 1$ 时投入翻倍产出翻倍 (直线, 规模报酬不变); $k > 1$ 加速上升 (递增); $0 < k < 1$ 边际放缓 (递减)。

例 (几个齐次度的判定)。

判断下列函数是否齐次, 若是给出齐次度。(i) Cobb-Douglas $f(x_1, x_2) = Ax_1^a x_2^b$; (ii) CES $f(x_1, x_2) = (x_1^\rho + x_2^\rho)^{1/\rho}$; (iii) $h(x_1, x_2) = x_1^2 + x_2$ 。

解.

(i) $f(tx_1, tx_2) = A(tx_1)^a (tx_2)^b = t^{a+b} Ax_1^a x_2^b = t^{a+b} f(\mathbf{x})$, 故齐次度 $k = a + b$ 。指数之和决定规模报酬: $a + b = 1$ 即 CRS。

(ii) $f(t\mathbf{x}) = ((tx_1)^\rho + (tx_2)^\rho)^{1/\rho} = (t^\rho(x_1^\rho + x_2^\rho))^{1/\rho} = t f(\mathbf{x})$, 齐次度 $k = 1$ (CES 这种写法天生 CRS)。

(iii) $h(t\mathbf{x}) = t^2 x_1^2 + tx_2$ 。要等于 $t^k h(\mathbf{x}) = t^k (x_1^2 + x_2)$ 对一切 $\mathbf{x}, t$ 成立, 需 t^2 与 t 同指数, 不可能。故 h 不齐次——把两项不同“重量”的东西相加, 破坏了统一的

缩放律。

注（齐次度可以是负数或零）。

定义里 k 是任意实数。 $k = 0$ 的齐次函数满足 $f(t\mathbf{x}) = f(\mathbf{x})$ ——沿射线取值恒定，即 f 只取决于各分量的比例而与整体规模无关。这正是后文需求函数“零次齐次”的内容。 $k < 0$ 则随规模放大而缩小，例如把要素价格映到单位成本的某些构造。先记住：“零次齐次 = 只看比例”。

17.3 欧拉定理

齐次性是一条“整体”陈述（对每个 t 都成立的等式）。欧拉定理把它翻译成一条“局部”陈述——只关乎在某一点的各个偏导数。这一步翻译之所以宝贵，是因为偏导数正是经济学里的边际量（边际产品、边际效用），于是“缩放律”被改写成了“边际量之间的会计恒等式”。

定理 17.2: 欧拉定理

设 $f: D \rightarrow \mathbb{R}$ 在锥 $D \subseteq \mathbb{R}^n$ 上 k 次齐次且连续可微。则对一切 $\mathbf{x} \in D$,

$$\sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}(\mathbf{x}) = k f(\mathbf{x}) \quad \text{即} \quad \nabla f(\mathbf{x}) \cdot \mathbf{x} = k f(\mathbf{x}).$$

证明. 固定 $\mathbf{x} \in D$ ，把齐次性的定义式看成关于单一变量 $t > 0$ 的恒等式：

$$f(t\mathbf{x}) = t^k f(\mathbf{x}), \quad t > 0.$$

两边对 t 求导。左边用链式法则，把 f 的第 i 个自变量记为 $u_i = tx_i$ ，则 $\frac{du_i}{dt} = x_i$ ，于是

$$\frac{d}{dt} f(t\mathbf{x}) = \sum_{i=1}^n \frac{\partial f}{\partial u_i}(t\mathbf{x}) \cdot x_i = \sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}(t\mathbf{x}).$$

右边对 t 求导得 $k t^{k-1} f(\mathbf{x})$ 。两边相等：

$$\sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}(t\mathbf{x}) = k t^{k-1} f(\mathbf{x}).$$

这对一切 $t > 0$ 成立。令 $t = 1$ ，即得 $\sum_i x_i \partial f / \partial x_i(\mathbf{x}) = k f(\mathbf{x})$ 。 $\square$

注（一行证明的两个关键动作）。

整个证明只做了两件事：(1) 把多变量的齐次等式压成单变量 t 的恒等式（沿射线走），(2) 对 t 求导后令 $t = 1$ 回到原点所在的那条射线。这套“沿射线参数化、对参数求导、再回代特殊值”的手法在本书反复出现（隐函数定理对恒等式求导、包络定理对参数求导皆同此理）。值得一提的是欧拉定理还有逆命题：若连续可微的 f 在

锥上处处满足 $\nabla f \cdot \mathbf{x} = kf$, 则 f 必 k 次齐次——这条偏微分方程的解恰好就是齐次函数。所以“ k 次齐次”与“ $\nabla f \cdot \mathbf{x} = kf$ ”是等价的两种说法。

欧拉定理是“边际量的会计恒等式”

把欧拉定理读成经济语言：左边 $\sum_i x_i \partial f / \partial x_i$ 是各投入量 $\times$ 该投入的边际产品之和；右边是 k 乘以总产出。于是当 f 是 CRS ($k = 1$) 生产函数时，等式说各要素按其边际产品取酬，加总后恰好等于总产出——不多不少。这就是分配理论的数学内核，下一节展开。这条恒等式不是“近似”、不是“均衡条件”，它对任何 1 次齐次函数恒成立，纯粹是齐次性的代数后果。

17.4 偏导数的齐次度下降一阶

齐次函数有一条常被用到的“遗传”性质：它的偏导数也是齐次的，而且齐次度比母函数低一阶。这在经济学里立刻有解释——CRS ($k = 1$) 生产函数的边际产品是 0 次齐次的，也就是说边际产品只取决于要素配比、与生产规模无关。

命题 17.3: 偏导的齐次度

设 $f: D \rightarrow \mathbb{R}$ 在锥 D 上 k 次齐次且连续可微。则它的每个偏导数 $\partial f / \partial x_i$ 是 $(k - 1)$ 次齐次：

$$\frac{\partial f}{\partial x_i}(t\mathbf{x}) = t^{k-1} \frac{\partial f}{\partial x_i}(\mathbf{x}), \quad t > 0, i = 1, \dots, n.$$

证明. 从齐次性恒等式 $f(t\mathbf{x}) = t^k f(\mathbf{x})$ 出发，这次两边对第 i 个空间变量 x_i 求偏导 (t 视为常数)。左边用链式法则，注意第 i 个自变量 $u_i = tx_i$ 关于 x_i 的导数是 t ：

$$\frac{\partial}{\partial x_i} f(t\mathbf{x}) = \frac{\partial f}{\partial x_i}(t\mathbf{x}) \cdot t.$$

右边 $\frac{\partial}{\partial x_i} [t^k f(\mathbf{x})] = t^k \frac{\partial f}{\partial x_i}(\mathbf{x})$ 。两边相等并除以 $t > 0$ ：

$$\frac{\partial f}{\partial x_i}(t\mathbf{x}) = t^{k-1} \frac{\partial f}{\partial x_i}(\mathbf{x}). \quad \square$$

注 (CRS 下边际产品只看配比)。

对 CRS ($k = 1$) 生产函数， $\partial f / \partial x_i$ 是 0 次齐次： $\partial f / \partial x_i(t\mathbf{x}) = \partial f / \partial x_i(\mathbf{x})$ 。也就是说，资本与劳动同比例增加时，劳动的边际产品不变——增产纯靠堆量、效率不升不降。决定边际产品的是资本劳动比 K/L 而非各自的绝对水平。这正是增长理论里把变量“人均化”（除以劳动）后能用一个单变量函数 $f(k)$ ($k = K/L$) 描述整套技术的根据，见本节末。

17.5 应用一：欧拉的“产品耗尽”与分配

这是欧拉定理在经济学里最漂亮的应用，历史上称为欧拉的产品耗尽定理 (adding-up / product exhaustion)。设生产函数 $F(K, L)$ 规模报酬不变 (1 次齐次)。在完全竞争市场，厂商把要素价格当作给定，雇用要素至“边际产品价值 = 要素价格”：实际工资 $w = \partial F / \partial L$ 、实际租金 $r = \partial F / \partial K$ 。那么按边际产品付酬，付给劳动与资本的总报酬是

$$wL + rK = \frac{\partial F}{\partial L} L + \frac{\partial F}{\partial K} K.$$

由欧拉定理 ($k = 1$)，右边恰等于 $F(K, L)$ ，即总产出。于是

竞争 + CRS $\Rightarrow$ 利润为零、产出恰好分光

在完全竞争、且生产规模报酬不变时，各要素按边际产品取酬，总报酬恰好等于总产出：

$$\frac{\partial F}{\partial L} L + \frac{\partial F}{\partial K} K = F(K, L).$$

没有剩余、也不会不够分——**纯利润为零**。这不是某个“恰好”的巧合，而是 1 次齐次性经由欧拉定理逼出来的代数恒等式。它解释了为什么竞争性的长期均衡里利润趋于零，也是新古典分配论“要素各得其边际贡献”能自治的前提：若 $k \neq 1$ ，按边际产品付酬就会有缺口 (IRS 时不够分、DRS 时有剩余)，完全竞争与规模报酬递增因此天然冲突。

例 (Cobb–Douglas 的要素份额) .

设 $F(K, L) = AK^\alpha L^{1-\alpha}$ ($0 < \alpha < 1$ ，这是 CRS，因指数和为 1)。验证产品耗尽，并说明 α 的含义。

解.

两个边际产品为

$$\frac{\partial F}{\partial K} = \alpha AK^{\alpha-1} L^{1-\alpha} = \alpha \frac{F}{K}, \quad \frac{\partial F}{\partial L} = (1-\alpha)AK^\alpha L^{-\alpha} = (1-\alpha) \frac{F}{L}.$$

于是按边际产品付酬的总额

$$\frac{\partial F}{\partial K} K + \frac{\partial F}{\partial L} L = \alpha F + (1-\alpha)F = F,$$

正是产品耗尽。更进一步，资本得到的份额 $rK/F = \partial F / \partial K \cdot K/F = \alpha$ ，劳动份额 $wL/F = 1 - \alpha$ 。**Cobb–Douglas 指数 α 直接就是资本的收入份额**，且它是常数——不随 K, L 变。这正是 Cobb–Douglas 在宏观里历久不衰的原因：它内置了“要素份额大体稳定”这一经验规律。

注 (把变量“人均化”) .

CRS 让我们能给整套技术降维。 $F(K, L)$ 是 1 次齐次, 取 $t = 1/L$:

$$\frac{F(K, L)}{L} = F\left(\frac{K}{L}, 1\right) =: f(k), \quad k := \frac{K}{L}.$$

人均产出 $y = Y/L$ 只是人均资本 k 的单变量函数 $y = f(k)$ 。Solow 增长模型整套分析 (资本积累方程 $\dot{k} = sf(k) - (n + \delta)k$ 、稳态、黄金律) 都建立在这个“人均化”上, 而能这么做的全部根据, 就是生产函数的 1 次齐次性。这是齐次函数在宏观增长理论里的核心落点。

17.6 应用二：需求的零次齐次与无货币幻觉

第二个落点在消费理论。消费者解

$$\max_{\mathbf{x} \geq 0} u(\mathbf{x}) \quad \text{s.t.} \quad \mathbf{p} \cdot \mathbf{x} \leq m,$$

得到马歇尔需求 $\mathbf{x}^*(\mathbf{p}, m)$ 。现在把所有价格与收入同时乘以 $t > 0$: $(\mathbf{p}, m) \mapsto (t\mathbf{p}, tm)$ 。预算约束 $t\mathbf{p} \cdot \mathbf{x} \leq tm$ 与原约束 $\mathbf{p} \cdot \mathbf{x} \leq m$ 描述的是同一个可行集 (两边同除以 t)，目标函数 u 又没动, 所以最优选择不变:

$$\mathbf{x}^*(t\mathbf{p}, tm) = \mathbf{x}^*(\mathbf{p}, m) \quad \text{对一切 } t > 0.$$

按定义, 这正是说马歇尔需求关于 $(\mathbf{p}, m)$ 是 0 次齐次的。

零次齐次 = “没有货币幻觉”

需求 0 次齐次的经济含义是: 消费者只关心相对价格与实际收入, 而非价格与收入的名义水平。把所有标价和你的工资同时翻倍, 你的实际选择不该有任何变化——这就是“没有货币幻觉” (no money illusion)。这条性质不是额外假设, 它是“预算集只取决于价格与收入之比”这一事实的直接推论, 因而对任何理性消费者自动成立。在宏观里它对应货币中性的微观基础; 在计量需求估计里, 它是对需求系统施加的一条可检验的齐次性约束 (各价格弹性与收入弹性之和为零)。

用欧拉定理给这条齐次性“求导”, 就得到上面提到的弹性约束: 对 $x_i^*(\mathbf{p}, m)$ (0 次齐次) 套欧拉定理得 $\sum_j p_j \partial x_i^* / \partial p_j + m \partial x_i^* / \partial m = 0$, 两边除以 x_i^* 即“所有 (未补偿) 价格弹性与收入弹性之和为零”。

17.7 位似函数：齐次性的“有用推广”

齐次性对生产函数往往合适, 但对效用函数却嫌太强——效用本是序数的 (只有等值线的形状有意义, 具体数值可任意单调重标), 而“ $u(t\mathbf{x}) = t^k u(\mathbf{x})$ ”是一条加在具体数值上的基数式要求。我们真正想保留的, 只是齐次函数那条几何性质: 等值线沿过原点的射线等比例放大。把它从具体数值里解放出来, 就得到位似函数。

定义 17.4: 位似函数

称 $f: D \rightarrow \mathbb{R}$ (D 为锥) 为**位似的** (homothetic), 若存在一个 k 次齐次函数 h (某个 $k > 0$) 与一个严格递增函数 $\phi: \mathbb{R} \rightarrow \mathbb{R}$, 使得

$$f(\mathbf{x}) = \phi(h(\mathbf{x})).$$

也就是说, 位似函数 = 齐次函数经过一次严格单调变换。

单调变换 ϕ 不改变等值线的形状 (只给每条等值线重新贴个标签), 所以位似函数与它背后的齐次函数 h 共享同一族等值线。齐次函数的等值线有一条醒目的几何特征, 位似函数原封不动地继承了它:

命题 17.5: 位似函数的射线性质

设 $f = \phi \circ h$ 位似。则沿任一条过原点的射线, 等值线的切线斜率 (即边际替代率 MRS) 保持不变。等价地: 所有等值线都是同一条等值线沿射线的等比例放大, 从而连结各等值线对应切点的**扩张路径**是一条过原点的射线。

证明. 两点要核验。其一, 单调变换不改变 MRS。在两要素情形, 等值线斜率为

$$-\left.\frac{dx_2}{dx_1}\right|_f = \frac{\partial f / \partial x_1}{\partial f / \partial x_2} = \frac{\phi'(h) \partial h / \partial x_1}{\phi'(h) \partial h / \partial x_2} = \frac{\partial h / \partial x_1}{\partial h / \partial x_2},$$

$\phi' > 0$ 在分子分母同时出现、约掉, 故 f 与 h 的 MRS 处处相同。其二, 齐次 h 的 MRS 沿射线不变。由上一节, $\partial h / \partial x_i$ 是 $(k-1)$ 次齐次, 于是

$$\frac{\partial h / \partial x_1(t\mathbf{x})}{\partial h / \partial x_2(t\mathbf{x})} = \frac{t^{k-1} \partial h / \partial x_1(\mathbf{x})}{t^{k-1} \partial h / \partial x_2(\mathbf{x})} = \frac{\partial h / \partial x_1(\mathbf{x})}{\partial h / \partial x_2(\mathbf{x})},$$

t^{k-1} 上下约掉, MRS 只取决于配比 $\mathbf{x}$ 的方向、与沿射线走多远无关。两点合起来即得结论。□

这条性质有一个一眼可辨的图像 (图 17.2): 在固定相对价格下, 消费者 (或厂商) 随预算 (或产出目标) 扩大而选择的最优点, 全部落在同一条过原点的射线上——这条线就是**扩张路径** (expansion path), 也是收入提供曲线。

为什么消费理论偏爱位似

位似 (而非齐次) 才是消费理论里真正用得上的那一档: **偏好位似 $\iff$ 每种商品的需求都是收入的线性函数 (恩格尔曲线为过原点的直线)、且预算份额与收入无关**。直观地说, 你变富之后会把多出来的钱按原比例分配到各商品上。这条性质让加总变得干净——一群位似且偏好相同的消费者, 其总需求就像一个“代表性消费者”的需求, 与收入如何分配无关。宏观模型里频繁假设位似偏好, 正是为了召唤出这个“代表性家庭”。而齐次效用只是位似的一个特例 (取 $\phi = \text{id}$),




图 17.2: 位似函数的等值线沿过原点的射线等比例放大 (图中 $c_1 < c_2 < c_3$)。在固定相对价格下, 最优点 (切点) 随规模扩大而沿同一条过原点的射线移动——这条直线就是扩张路径。射线性质来自“偏导数 $(k-1)$ 次齐次”, 使边际替代率沿射线不变。

多出来的基数结构在序数效用框架里并无额外用处。

注 (齐次、位似、拟凹三者的关系)。

不要混淆三个相邻概念。齐次管的是“沿射线如何缩放” (基数性质); 位似是齐次的单调变换, 只保留“等值线沿射线放大”这条几何性质 (序数性质, 故适配效用); 拟凹 (见后文『凹凸函数与拟凹/拟凸』一章) 管的是“等值线凸向原点” (上等值集为凸集), 保证最优化有良好的内点解。三者彼此独立: 位似偏好未必拟凹, 拟凹偏好未必位似。但它们常被一并假设, 因为合起来能同时保证需求存在唯一 (拟凹) 与加总干净 (位似)。

17.8 小结: 一条缩放律, 三处落点

本章只讲了一件几何事实——函数沿过原点的射线如何缩放——以及把它局部化的欧拉定理, 却接通了经济学三大分支:

- **生产与分配** (微观/宏观)。齐次度即规模报酬类型; 欧拉定理给出 “CRS + 竞争 $\Rightarrow$ 产品耗尽、利润为零”, 这是新古典分配论的地基。CRS 还让生产函数可“人均化”, 撑起 Solow 增长模型。
- **消费与需求** (微观/计量)。马歇尔需求对 $(\mathbf{p}, m)$ 零次齐次 = 无货币幻觉, 是需求系统估计里的可检验约束; 位似偏好给出线性恩格尔曲线与可加总的代表性消费者。
- **弹性与会计恒等式** (贯穿)。把欧拉定理用在不同的齐次对象上, 就得到“要素份额加总为 1”“价格弹性加总为零”这类恒等式——它们不是经验发现, 而是齐次性的代数后果。

齐次函数与凹凸性 (见后文『凹凸函数与拟凹/拟凸』一章)、与最优化 (第四部分) 配合, 构成了刻画“生产/偏好”这类经济原语的标准工具箱。认得 “ $f(t\mathbf{x}) = t^k f(\mathbf{x})$ ”

这条简单的缩放律，你就同时握住了规模报酬、产品耗尽、货币幻觉与代表性家庭这一串看似无关的结论的共同钥匙。

第四部分

最优化

第十八章 无约束最优化：一阶与二阶条件

用到的前置工具：偏导数、梯度与 Hessian（多元微分一章，第十三章）；Taylor 二阶展开（第十四章）；对称矩阵的正定/半正定性与二次型（线性代数部分，谱定理一章，见第五章）；凹凸函数（第十六章）。

经济学几乎是一门“求极值”的学科：消费者最大化效用，厂商最大化利润，计量学家最大化对数似然，社会计划者最大化福利。这些问题在落到“约束”之前，骨架都是同一件事——给定一个目标函数 f ，找出让它取最大（或最小）值的那一点。本章处理其中最干净的一类：选择变量可以在整个 $\mathbb{R}^n$ 里自由取值、没有任何约束。它看似是约束优化的“退化特例”，实则是后者的地基：Lagrange 与 KKT 不过是把约束“折叠”进目标后，再对一个无约束问题用本章的条件。

本章要回答两个问题，也正是使用者每次做优化时都要过的两关。第一关：**怎么找候选点**？答案是一阶条件 $\nabla f = \mathbf{0}$ ——在内点最优处，梯度必为零。第二关：**怎么确认它真是最优**？一阶条件只筛出“驻点”，而驻点可能是极大、极小，甚至两头不靠的鞍点；要分辨它们，得看二阶信息，也就是 Hessian 的正负定性。最后我们会看到一件让人安心的事：如果目标函数是凹的，这两关就合并成一关——任何一个驻点自动是全局最大，“找到”即“解完”。

18.1 极大、极小：先把话说清楚

优化问题写作

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{或} \quad \min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}).$$

极小化 f 等同于极大化 $-f$ ，故本章以**极大化**为主线陈述，极小化的对应结论只需把不等号与正负定性整体翻转。先把“最优”这个词的两个层次分清楚：是只在一小片邻域里最高，还是放眼整个定义域都最高。

定义 18.1: 局部与全局极大

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 点 $\mathbf{x}^* \in \mathbb{R}^n$ 。

- 称 $\mathbf{x}^*$ 是 f 的全局极大点, 若对一切 $\mathbf{x} \in \mathbb{R}^n$ 都有 $f(\mathbf{x}) \leq f(\mathbf{x}^*)$ 。
- 称 $\mathbf{x}^*$ 是 f 的局部极大点, 若存在 $\mathbf{x}^*$ 的某个邻域 U , 使对一切 $\mathbf{x} \in U$ 都有 $f(\mathbf{x}) \leq f(\mathbf{x}^*)$ 。

若上面的不等号在 $\mathbf{x} \neq \mathbf{x}^*$ 时严格成立 ($f(\mathbf{x}) < f(\mathbf{x}^*)$), 则称**严格极大点**。把所有 $\leq$ 换成 $\geq$, 便得到 (局部 / 全局, 严格 / 非严格) **极小点**的定义。

区分这两个层次绝非咬文嚼字。我们手上的工具——梯度与 Hessian——都是**局部**信息：它们只知道一点附近的斜率与曲率，对远处的山头一无所知。因此微积分能直接验证的，永远只是“局部最优”。把局部最优升格为全局最优，要么靠额外的全局结构（凹性，见第 18.5 节），要么靠先验证存在性、再逐个比较所有局部最优的高度（Weierstrass 极值定理保证了紧集上连续函数取得最大值，见分析与拓扑部分）。

注（“内点”这个限定词不能省）。

本章讲的一阶条件 $\nabla f = \mathbf{0}$ 只适用于落在定义域内部的最优点。若最优点恰在边界上（例如要求 $\mathbf{x} \geq \mathbf{0}$ 而最优消费在某一维取 0），梯度未必为零——它可能“还想往外推”，只是被边界挡住了。这正是不等式约束与 KKT 条件要处理的情形（见后文“KKT 条件”一章）；那里的“互补松弛”说的就是“要么梯度分量为零、要么约束起作用”。本章默认最优点是内点，把边界情形留给后续。

18.2 一阶必要条件：梯度为零

第一关的工具是一阶必要条件（first-order necessary condition, FONC）。它的内容朴素得近乎显然：如果你站在山顶，那么往任何方向看，地面都不再上升——否则朝那个上升方向挪一步就能更高，你就不在山顶了。把“往任何方向”翻译成方向导数，就得到 $\nabla f = \mathbf{0}$ 。

定理 18.2: 一阶必要条件

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在内点 $\mathbf{x}^*$ 处可微。若 $\mathbf{x}^*$ 是 f 的局部极大（或局部极小）点，则

$$\nabla f(\mathbf{x}^*) = \mathbf{0}.$$

满足此式的点称为 f 的**驻点**（stationary point）或**临界点**（critical point）。

证明. 设 $\mathbf{x}^*$ 是局部极大点。任取一个方向 $\mathbf{d} \in \mathbb{R}^n$ ，考察沿这条直线的一元函数

$$\varphi(t) = f(\mathbf{x}^* + t\mathbf{d}), \quad t \in \mathbb{R}.$$

因为 $\mathbf{x}^*$ 是 f 的局部极大点，且当 $t = 0$ 时 $\mathbf{x}^* + t\mathbf{d} = \mathbf{x}^*$ ，所以 $t = 0$ 是一元函数 φ 的局部极大点。由一元微积分的费马引理（可微函数在内部极值点处导数为零），

$$\varphi'(0) = 0.$$

另一方面，链式法则给出

$$\varphi'(0) = \nabla f(\mathbf{x}^*)^\top \mathbf{d}.$$

于是 $\nabla f(\mathbf{x}^*)^\top \mathbf{d} = 0$ 对一切方向 $\mathbf{d}$ 成立。一个向量与所有向量都正交，只能是零向量——取 $\mathbf{d} = \nabla f(\mathbf{x}^*)$ 便得 $\|\nabla f(\mathbf{x}^*)\|^2 = 0$ ，故 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 。□

一阶条件是“候选名单”，不是“录取通知”

$\nabla f = \mathbf{0}$ 是局部极值的必要条件，不是充分条件。它做的事是把整个 $\mathbb{R}^n$ 里无穷多个点，缩小为一张通常有限的“候选名单”（驻点）。真正的极大点一定在名单上，但名单上的点未必是极大点——它可能是极小、是鞍点。一阶条件负责筛选，二阶条件负责甄别。这套“先解方程定候选、再验二阶定身份”的两步法，是从消费者问题到极大似然估计通用的求解范式。

在标量情形 $\nabla f = \mathbf{0}$ 退化为熟悉的 $f'(x^*) = 0$ ；在 n 维则是 n 个方程 $\partial f / \partial x_i = 0$ ($i = 1, \dots, n$) 组成的方程组。

图 18.1 把一阶条件“切线水平”的几何含义画了出来：无论是局部极大还是局部极小，曲线在该点的切线都是水平的——这正是 $f' = 0$ 。可见一阶条件确实分不清极大与极小，这是下一节二阶条件要补的课。




图 18.1: 一阶条件的几何含义：在局部极大与局部极小处，切线都水平 ($f' = 0$)。两点都满足一阶条件，可见单靠一阶条件无法区分极大与极小。

18.3 二阶条件：Hessian 的正负定性

筛出驻点之后，要甄别它的身份，得借助曲率信息。直觉上，山顶处曲面向各个方向都向下弯，山谷处向各个方向都向上弯，而鞍点处一些方向向上弯、另一些向下弯。

“弯的方向”由二阶导数刻画，多元情形即 Hessian 矩阵

$$\mathbf{H}(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{n \times n}.$$

它的正负定性如何决定身份，根子在 Taylor 二阶展开（第十四章）。

从 Taylor 展开读出二阶条件

设 f 二次连续可微， $\mathbf{x}^*$ 是一个驻点 ($\nabla f(\mathbf{x}^*) = \mathbf{0}$)。在 $\mathbf{x}^*$ 附近做二阶 Taylor 展开，记位移 $\mathbf{h} = \mathbf{x} - \mathbf{x}^*$ ：

$$f(\mathbf{x}^* + \mathbf{h}) = f(\mathbf{x}^*) + \underbrace{\nabla f(\mathbf{x}^*)^\top \mathbf{h}}_{=0} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

一阶项因驻点条件消失，于是 f 在 $\mathbf{x}^*$ 附近的增量由那个二次型主导：

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) \approx \frac{1}{2} \mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h}.$$

这一步是全章的枢纽。它把“ $\mathbf{x}^*$ 是不是局部极大”——一个关于函数局部形状的问题——彻底翻译成“二次型 $\mathbf{h}^\top \mathbf{H} \mathbf{h}$ 的符号”——一个纯线性代数问题。判断一个对称矩阵导出的二次型恒正、恒负还是变号，正是谱定理与正定性理论（第五章）给出的对象。

二阶条件的本质：把“极值判定”归结为“二次型定号”

在驻点处， f 的局部行为由 $\frac{1}{2} \mathbf{h}^\top \mathbf{H} \mathbf{h}$ 决定。于是：

- $\mathbf{H}$ 负定（一切 $\mathbf{h} \neq \mathbf{0}$ 使 $\mathbf{h}^\top \mathbf{H} \mathbf{h} < 0$ ） $\implies$ 各方向都向下弯 $\implies$ 严格局部极大；
- $\mathbf{H}$ 正定 $\implies$ 各方向都向上弯 $\implies$ 严格局部极小；
- $\mathbf{H}$ 不定（既有正方向又有负方向） $\implies$ 鞍点，既非极大也非极小。

正负定性可用特征值（全负 / 全正 / 有正有负）或顺序主子式判别，详见谱定理一章。

必要与充分：半定与定的差别

二阶条件有“必要”与“充分”两个版本，差别恰好是半负定与负定之间的一线之隔——这条线就是“弱”与“严”的分水岭。

定理 18.3: 二阶必要条件

设 f 在内点 $\mathbf{x}^*$ 处二次连续可微。若 $\mathbf{x}^*$ 是局部极大点，则

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad \text{且} \quad \mathbf{H}(\mathbf{x}^*) \text{ 半负定 (即 } \mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} \leq 0 \forall \mathbf{h}).$$

(对局部极小, Hessian 须半正定。)

证明. 一阶条件已由上一节给出, 只证半负定。任取方向 $\mathbf{h} \neq \mathbf{0}$, 沿这条线把上面的 Taylor 展开写成关于步长 t 的式子 (令位移为 $t\mathbf{h}$):

$$f(\mathbf{x}^* + t\mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} t^2 \mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} + o(t^2).$$

因 $\mathbf{x}^*$ 是局部极大点, 对一切充分小的 t 左边 ≤ 0 。两边除以 $t^2 > 0$:

$$\frac{1}{2} \mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} + \frac{o(t^2)}{t^2} \leq 0.$$

令 $t \rightarrow 0$, 余项 $o(t^2)/t^2 \rightarrow 0$, 得 $\mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} \leq 0$ 。 $\mathbf{h}$ 任意, 故 $\mathbf{H}(\mathbf{x}^*)$ 半负定。 $\square$

定理 18.4: 二阶充分条件

设 f 在内点 $\mathbf{x}^*$ 处二次连续可微。若

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad \text{且} \quad \mathbf{H}(\mathbf{x}^*) \text{ 负定},$$

则 $\mathbf{x}^*$ 是 f 的严格局部极大点。(若 Hessian 正定, 则为严格局部极小点。)

证明. 设 $\mathbf{H}(\mathbf{x}^*)$ 负定。负定对称矩阵的最大特征值 $\lambda_{\max} < 0$, 由谱定理 (Rayleigh 商) 知, 对一切 $\mathbf{h}$ 有

$$\mathbf{h}^\top \mathbf{H}(\mathbf{x}^*) \mathbf{h} \leq \lambda_{\max} \|\mathbf{h}\|^2.$$

代入 Taylor 展开:

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) \leq \frac{1}{2} \lambda_{\max} \|\mathbf{h}\|^2 + o(\|\mathbf{h}\|^2) = \|\mathbf{h}\|^2 \left[\frac{1}{2} \lambda_{\max} + \frac{o(\|\mathbf{h}\|^2)}{\|\mathbf{h}\|^2} \right].$$

当 $\mathbf{h} \rightarrow \mathbf{0}$ 时方括号里的余项趋于 0, 而 $\frac{1}{2} \lambda_{\max} < 0$ 是个固定的负数。故存在 $\mathbf{x}^*$ 的某个邻域, 在其中 ($\mathbf{h} \neq \mathbf{0}$) 方括号严格为负, 于是 $f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) < 0$ 。这正是严格局部极大。 $\square$

为什么必要条件只能要“半”、充分条件却要“定”

这道缝隙是无约束优化里最常被搞混的地方，值得记牢：

- **必要方向**（已知是极大 $\implies$ 推 Hessian）：极大只保证二次型 ≤ 0 ，挤不出严格 < 0 。例如 $f(x) = -x^4$ 在 0 处是严格极大，但 $f''(0) = 0$ ，Hessian 仅半负定不负定。所以必要条件最多敢说“半负定”。
- **充分方向**（已知 Hessian $\implies$ 推是极大）：只有严格的负定才压得住 Taylor 的高阶余项、保证邻域内函数确实下降；半负定留了“ $= 0$ ”的方向，那个方向上的高阶项可正可负，结论就悬了。例如 $g(x) = x^3$ 在 0 处 $g''(0) = 0$ （半负定也半正定），却是鞍点（拐点）； $f(x) = -x^4$ 同样 $f''(0) = 0$ 却是极大——可见 Hessian 退化（半定但不定）时二阶条件失效，须看更高阶导数。

一句话：必要条件是“极大留下的痕迹”（弱），充分条件是“保证极大的证据”（强）。

例（二元函数的驻点甄别）。

求 $f(x, y) = -x^2 - y^2 + 2x + 4y$ 的极值点并判定其类型。

解。

一阶条件：

$$\frac{\partial f}{\partial x} = -2x + 2 = 0, \quad \frac{\partial f}{\partial y} = -2y + 4 = 0 \implies (x^*, y^*) = (1, 2).$$

唯一驻点是 $(1, 2)$ 。Hessian 为常数矩阵

$$\mathbf{H} = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}.$$

它的两个特征值都是 $-2 < 0$ ，故 $\mathbf{H}$ 负定。由二阶充分条件， $(1, 2)$ 是严格局部极大点。又因 $\mathbf{H}$ 处处负定， f 是（严格）凹函数，于是这个局部极大同时是全局极大（下一节）。代入得最大值 $f(1, 2) = -1 - 4 + 2 + 8 = 5$ 。

18.4 鞍点：驻点未必是极值

驻点队伍里最容易被一阶条件“放进来”却不是极值的，是鞍点（saddle point）。在鞍点处梯度为零，但 Hessian 不定：沿某些方向函数向上弯（像谷底），沿另一些方向向下弯（像山顶），整体形如马鞍。

最干净的例子是 $f(x, y) = x^2 - y^2$ 。它的梯度 $\nabla f = (2x, -2y)^T$ 仅在原点为零，故原点是唯一驻点。Hessian

$$\mathbf{H} = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$$

的特征值为 $+2$ 与 -2 ，一正一负——不定。具体看：沿 x 轴 $f(x, 0) = x^2$ 在原点取极小，沿 y 轴 $f(0, y) = -y^2$ 在原点取极大。同一个点，从两个方向看身份相反，故它既非局部极大也非局部极小（图 18.2）。




图 18.2: 鞍点 $f(x, y) = x^2 - y^2$ 在原点的等值线（双曲线）。梯度在原点为零，但沿 x 方向 f 上升（原点是该方向的极小）、沿 y 方向 f 下降（原点是该方向的极大），故原点既非极大也非极小，对应 Hessian 不定。

注（鞍点不是病态特例，而是优化里的常客）。

鞍点在高维问题里极为普遍：一个 $n \times n$ 的 Hessian 要负定，需要 n 个特征值全部为负，随着维数升高，“恰好全负”是越来越苛刻的事，更多驻点会落成“有正有负”的鞍点。这件事在两处尤其要紧：其一，数值优化（梯度下降、牛顿法）会被鞍点“绊住”，因为那里梯度也为零，算法分不清自己停在了极值还是马鞍；其二，博弈论里的纳什均衡、min-max 问题（如对抗性估计、稳健优化）本身就是找鞍点——一方求极大、另一方求极小的交汇处。所以“甄别驻点”不是吹毛求疵，而是优化实践的日常。

18.5 凹性：让局部极大升格为全局极大

到此为止，所有结论都带着“局部”二字——这是微积分工具的天然局限。经济学却常常需要全局的论断：“这个消费组合是最优的”，指的是没有任何别的组合更好，而不只是邻域里最好。把局部升格为全局，需要给目标函数加上一层全局结构，最常用、也最贴合经济学直觉的，就是**凹性**（第十六章）。

凹函数的图像处处“向下弯”，不会出现“这边一个小山头、那边一个更高山头”的多峰地形——而多峰正是局部最优区别于全局最优的唯一来源。一旦地形单峰，“爬到一个山顶”就等于“爬到了最高峰”。

定理 18.5: 凹函数的局部极大即全局极大

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凹函数。若 $\mathbf{x}^*$ 是 f 的局部极大点，则它是 f 的全局极大点。

证明. 反证。设 $\mathbf{x}^*$ 是局部极大点，但存在某点 $\mathbf{y}$ 使 $f(\mathbf{y}) > f(\mathbf{x}^*)$ 。考虑从 $\mathbf{x}^*$ 到 $\mathbf{y}$ 的线段上的点

$$\mathbf{x}_\lambda = (1 - \lambda)\mathbf{x}^* + \lambda\mathbf{y}, \quad \lambda \in (0, 1).$$

由凹性（凹函数图像位于其任意弦之上，即函数值不低于弦值）：

$$f(\mathbf{x}_\lambda) \geq (1 - \lambda)f(\mathbf{x}^*) + \lambda f(\mathbf{y}) > (1 - \lambda)f(\mathbf{x}^*) + \lambda f(\mathbf{x}^*) = f(\mathbf{x}^*),$$

中间的严格不等号用到了 $f(\mathbf{y}) > f(\mathbf{x}^*)$ 与 $\lambda > 0$ 。也就是说，线段上每一点（哪怕 λ 取得再小、 $\mathbf{x}_\lambda$ 离 $\mathbf{x}^*$ 再近）都严格高于 $\mathbf{x}^*$ 。但 $\mathbf{x}^*$ 是局部极大点，存在邻域 U 使其中的点都不高于 $\mathbf{x}^*$ ；取 λ 足够小让 $\mathbf{x}_\lambda \in U$ ，便与 $f(\mathbf{x}_\lambda) > f(\mathbf{x}^*)$ 矛盾。故不存在更高的 $\mathbf{y}$ ， $\mathbf{x}^*$ 是全局极大点。□

图 18.3 把这件事画清楚了：凹函数只有一个“山头”，峰处切线水平且整条曲线都压在切线下方，所以那个唯一的驻点既是局部极大、也是全局极大。




图 18.3: 凹函数的唯一驻点即全局极大点。峰处切线水平（一阶条件），整条曲线都在切线下方（凹），任意弦都落在曲线下方。地形单峰，故“局部最高”即“全局最高”。

这条定理与二阶条件合起来，给出经济学里最常援引的一组充分条件：

推论 18.6: 凹优化的“一关通过”

设 f 二次连续可微且为凹函数（等价地，Hessian $\mathbf{H}(\mathbf{x})$ 在定义域上处处半负定）。则任何满足一阶条件 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 的点 $\mathbf{x}^*$ 都是 f 的全局极大点。若 f 严格凹（Hessian 处处负定即为一种充分情形），则全局极大点至多一个。

凹性把“两关”并成“一关”

一般情形下，求最优要走两步：解一阶条件定候选，再验二阶条件定身份，且只得到局部结论。一旦目标函数凹，这两关合并：

- 一阶条件从必要升格为充分—— $\nabla f = \mathbf{0}$ 不再只是“候选”，而直接是全局最优；
- 不必再单独验二阶条件，凹性已经包办（处处半负定）；
- 结论是全局的，不再是局部的；严格凹时最优解还唯一。

这就是为什么经济学模型几乎总要假设效用凹、生产集凸、似然在真值附近凹——凹性是“存在唯一全局最优”这一论断的标准买路钱。验证一个最优化问题良定义，第一件事往往就是检查目标函数的凹性。

18.6 它通向何处

本章的两关——一阶条件定候选、二阶条件（或凹性）定身份——是后续几乎所有优化与估计理论的母板。几处重要去处：

- **约束优化**（Lagrange 与 KKT，见后文相应各章）。把约束用乘子“折叠”进目标后，最优性条件仍是“某个梯度为零”加“某个二阶条件”——只不过梯度换成 Lagrange 函数的梯度、Hessian 换成在约束切空间上的“有边 Hessian”。本章是它们脱去约束外衣后的内核。
- **比较静态**（已见隐函数定理一章，第十五章）。最优选择 $\mathbf{x}^*(\boldsymbol{\theta})$ 由一阶条件 $\nabla_{\mathbf{x}} f(\mathbf{x}^*, \boldsymbol{\theta}) = \mathbf{0}$ 隐式定义；对它用隐函数定理，需要的可逆 Jacobian 恰是本章的 Hessian $\mathbf{H}$ 。二阶充分条件（ $\mathbf{H}$ 负定）保证了 $\mathbf{H}$ 可逆，从而比较静态 $D_{\boldsymbol{\theta}} \mathbf{x}^* = -\mathbf{H}^{-1} \nabla_{\mathbf{x}\boldsymbol{\theta}}^2 f$ 有定义——二阶条件一身二任，既定身份，又让参数变动的响应良定义。
- **极大似然与 M-估计**（见渐近统计部分）。估计量 $\hat{\boldsymbol{\theta}}$ 由样本一阶条件——得分方程 $\nabla_{\boldsymbol{\theta}} \frac{1}{n} \sum_i \log f(\mathbf{z}_i; \boldsymbol{\theta}) = \mathbf{0}$ ——定义，正是本章的 $\nabla f = \mathbf{0}$ ；而其渐近方差里的信息矩阵，来自对数似然的（期望）Hessian，正是本章的二阶项。“得分为零”与“信息矩阵”这对计量基石，骨子里就是无约束优化的一阶、二阶条件。
- **牛顿法**。要数值求解 $\nabla f = \mathbf{0}$ ，把梯度在当前点线性化（ $\nabla f(\mathbf{x} + \mathbf{h}) \approx \nabla f(\mathbf{x}) + \mathbf{H}(\mathbf{x})\mathbf{h}$ ）并令其为零，得迭代 $\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{H}(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$ 。Hessian 又一次出场——优化的“找点”与“算点”两件事，都绕着一阶、二阶条件转。

一阶条件给方程，二阶条件给保证，凹性给全局与唯一。这三件套朴素到几乎不像“定理”，却是整座最优化大厦——连同它在微观、宏观、计量里的全部应用——共同的地基。

第十九章 等式约束与 Lagrange 乘子

用到的前置工具：梯度与方向导数（第十三章）；隐函数定理（第十五章）；无约束最优化的一阶/二阶条件（第十八章）；正定/负定矩阵与二次型（线性代数部分）。

经济学里几乎没有“随便选”的最大化——选择总是被某样东西卡住的。消费者想让效用最高，但花的钱不能超过收入；厂商想压低成本，但产量必须达标；计量里估参数，有时要让估计落在某个约束面上。这些问题的共同形状是“在一条曲线（或一个曲面）上找目标函数的最高点”。本章要讲的 Lagrange 乘子法，正是解这类等式约束问题的标准工具。它做的事有两层：一层是怎么找到带约束的最优点（把约束揉进一个新的目标函数，再当无约束问题处理）；另一层——也是经济学家更看重的——是它顺手交出的那个乘子 λ ，它不是中间产物里的废料，而是一个有血有肉的经济量：影子价格，即把约束放松一个单位，能给最优值带来多少边际改善。学会读这个 λ ，等于学会了“收入的边际效用”“资源的边际价值”这一整类概念的数学出处。

19.1 从无约束到有约束：问题长什么样

前一章处理的是无约束最优化：在整个 $\mathbb{R}^n$ 上找 f 的极值，最优点的标志是 $\nabla f = \mathbf{0}$ ——所有方向上都走不动了。但经济学的选择几乎从不能在整个空间里自由游走。把典型问题写下来，它总是

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{s.t.} \quad g(\mathbf{x}) = 0.$$

这里 f 是目标函数（效用、利润、负成本……）， $g(\mathbf{x}) = 0$ 是一条等式约束，它把可行的选择限制在 $\mathbb{R}^n$ 里的一张曲面（ $n = 2$ 时是一条曲线）上。两个最经典的例子先摆出来，本章会反复回到它们。

例（预算约束下的效用最大化）。

消费者在两种商品上分配收入 m ，价格为 p_1, p_2 ，效用为 $u(x_1, x_2)$ 。他求解

$$\max_{x_1, x_2} u(x_1, x_2) \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = m.$$

约束 $g(x_1, x_2) = p_1 x_1 + p_2 x_2 - m = 0$ 就是预算线。解出的 $\mathbf{x}^*(\mathbf{p}, m)$ 是马歇尔需求。

例（给定产量的成本最小化）。

厂商要生产固定产量 $\bar{q}$, 投入 x_1, x_2 的价格为 w_1, w_2 , 生产函数为 $F(x_1, x_2)$ 。他求解

$$\min_{x_1, x_2} w_1 x_1 + w_2 x_2 \quad \text{s.t.} \quad F(x_1, x_2) = \bar{q}.$$

约束 $g = F(x_1, x_2) - \bar{q} = 0$ 是一条等产量线。解出的最小成本作为 $(w, \bar{q})$ 的函数就是成本函数。

求最小值与求最大值在方法上没有区别: $\min f$ 等价于 $\max(-f)$, 下文一律以 $\max$ 叙述, 结论照搬到 $\min$ 即可。先看为什么无约束那一套 (令 $\nabla f = \mathbf{0}$) 在这里直接失灵: 约束面上的最优点, 几乎从不是 f 的无约束驻点。在预算约束的例子中, 若 u 是“越多越好”的, 无约束最大值在无穷远处, 根本不存在; 真正的最优点落在预算线上, 那里 $\nabla u \neq \mathbf{0}$ 。所以我们需要一个新的最优性标志——它要回答的是: 站在约束面上的一点, 怎么判断“沿着约束面再也走不高了”?

19.2 相切: 一阶条件的几何来源

把目光锁在 $n = 2$ 、单约束的情形, 几何最透亮。约束 $g(x_1, x_2) = 0$ 是平面上一条曲线 C 。目标 f 有一族等值线 (level curves) $\{f = k\}$, k 越大代表 f 越高。在约束曲线上求 f 的最大值, 就是问: 沿着 C 走, 最高能蹭到哪一条等值线?

设想我们站在 C 上某点, 那里 C 与某条等值线 $\{f = k\}$ 相交而不相切。相交意味着两条曲线在该点切线方向不同, 于是沿 C 往某一侧挪一小步, 就能跨到一条更高的等值线上—— f 还能涨, 这点不可能是最优。能反过来堵死“还能涨”的, 只有一种局面: C 与某条等值线在该点相切。相切处, 沿 C 的移动方向恰好与等值线方向一致, 一阶上 f 不再变化——这就是约束最优点的标志 (图 19.1)。

相切这件几何事, 怎么翻成方程? 关键是把“切线方向一致”换成“法线方向一致”——后者好写得多。回忆第十三章: 函数的梯度垂直于它自己的等值线。所以 ∇f 垂直于 f 的等值线, ∇g 垂直于约束曲线 $g = 0$ (它是 g 的等值线)。两条曲线相切 $\iff$ 切线平行 $\iff$ 法线平行 $\iff$ 两个梯度共线:

$$\nabla f(\mathbf{x}^*) = \lambda \nabla g(\mathbf{x}^*) \quad \text{对某个标量 } \lambda.$$

这就是 Lagrange 一阶条件。它说的是: 最优点处, 目标的梯度被约束的梯度“完全解释”了—— ∇f 没有任何分量是平行于约束面的, 否则沿那个分量方向挪一步就能把 f 顶高、且一阶上不违反约束。那个把两个梯度联系起来的比例系数 λ , 就是 **Lagrange 乘子**。

约束最优的一阶标志: 梯度共线

内点无约束最优要求 $\nabla f = \mathbf{0}$ (哪个方向都走不动); 等式约束最优放宽了这一点, 只要求 ∇f 落在约束的法线方向上, 即 $\nabla f = \lambda \nabla g$ 。直觉: ∇f 沿约束面的“切向分量”必须为零——只要它非零, 就能在不违反约束的前提下让 f 继续上升。乘子 λ 量的正是“目标的法向冲动”相对“约束的法向”有多强。




图 19.1: 约束曲线 $g = 0$ 与目标的等值线族。最优点处二者相切: 再高的等值线 ($f = 13$) 已离开约束、不可达, 再低的 ($f = 5$) 则没用尽约束。相切点的两条法向量 ∇f 与 ∇g 共线。

注 (同向还是反向)。

共线包含同向 ($\lambda > 0$) 与反向 ($\lambda < 0$)。在“越多越好”的效用最大化里, ∇f 指向效用上升、 ∇g 指向约束更紧的方向, 二者同向, $\lambda > 0$ (图 19.1 即此情形)。 λ 的符号本身有经济含义: 下一节会看到 λ 等于“放松约束”带来的边际收益, 对“有用”的约束它为正则正。先记住共线是核心, 符号随问题而定。

19.3 Lagrange 函数: 把约束揉进目标

梯度共线条件 $\nabla f = \lambda \nabla g$ 加上约束 $g = 0$, 已经能定出最优点。但逐个写梯度分量很笨。Lagrange 的天才之处, 是把这套条件“打包”成一个无约束问题的一阶条件。引入新变量 λ , 构造 **Lagrange 函数**

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) - \lambda g(\mathbf{x}).$$

定义 19.1: Lagrange 函数与一阶条件

对等式约束问题 $\max f(\mathbf{x})$ s.t. $g(\mathbf{x}) = 0$, 定义 Lagrange 函数 $\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) - \lambda g(\mathbf{x})$ 。把 $\mathbf{x}$ 与 λ 一起当成自由变量, 令 $\mathcal{L}$ 的全部偏导为零, 得到 Lagrange 一阶条件:

$$\begin{cases} \nabla_{\mathbf{x}} \mathcal{L} = \nabla f(\mathbf{x}) - \lambda \nabla g(\mathbf{x}) = \mathbf{0}, \\ \frac{\partial \mathcal{L}}{\partial \lambda} = -g(\mathbf{x}) = 0. \end{cases}$$

这套条件的两行恰好就是我们要的两件事，丝毫不多不少。对 $\mathbf{x}$ 求偏导给出梯度共线 $\nabla f = \lambda \nabla g$ ；对 λ 求偏导，把约束 $g(\mathbf{x}) = 0$ 自动吐了回来。于是“在约束面上找驻点”被改写成了“在扩大的变量空间 $(\mathbf{x}, \lambda)$ 里找 $\mathcal{L}$ 的无约束驻点”——前一章那套求驻点的机器可以原样开动。 λ 在这里既是“待定的比例系数”，又是“强制约束成立的旋钮”：正是 $\partial \mathcal{L} / \partial \lambda = 0$ 这一行把 $\mathbf{x}$ 摁回约束面上。

符号约定： $\mathcal{L} = f - \lambda g$ 与 $\mathcal{L} = f + \lambda g$ 都有人用，区别只是 λ 差一个正负号；本书取减号，好处是下一节 $\lambda = \partial v / \partial c$ 时符号最干净（影子价格直接等于乘子）。

例（用 Lagrange 函数解效用最大化）。

取 $u(x_1, x_2) = x_1 x_2$ （一种 Cobb-Douglas 效用），预算约束 $x_1 + x_2 = 6$ （已令 $p_1 = p_2 = 1, m = 6$ ）。求最优消费束与乘子。

解。

Lagrange 函数 $\mathcal{L} = x_1 x_2 - \lambda(x_1 + x_2 - 6)$ 。三个一阶条件：

$$\frac{\partial \mathcal{L}}{\partial x_1} = x_2 - \lambda = 0, \quad \frac{\partial \mathcal{L}}{\partial x_2} = x_1 - \lambda = 0, \quad \frac{\partial \mathcal{L}}{\partial \lambda} = -(x_1 + x_2 - 6) = 0.$$

前两式给 $x_1 = x_2 = \lambda$ ，代入第三式得 $2\lambda = 6$ ，故

$$x_1^* = x_2^* = 3, \quad \lambda^* = 3.$$

最优效用 $u^* = x_1^* x_2^* = 9$ 。这正是图 19.1 里那个相切点， $\nabla u = (x_2, x_1) = (3, 3)$ 与 $\nabla g = (1, 1)$ 确实共线，比例恰为 $\lambda^* = 3$ 。

注（消去 λ 就回到“边际替代率 = 价格比”）。

把前两个一阶条件相除消去 λ ： $\frac{u_{x_1}}{u_{x_2}} = \frac{p_1}{p_2}$ （上例里两价格都是 1）。左边是边际替代率（无差异曲线的斜率），右边是价格比（预算线的斜率）。这一行就是微观课上“最优消费的切点条件”，它不过是梯度共线 $\nabla u = \lambda \nabla g$ 把 λ 约掉后的样子。Lagrange 法的好处是连 λ 本身都保留了下来——而 λ 正是下一节的主角。

19.4 乘子的经济含义：影子价格

到此 λ 还只是个解方程时冒出来的辅助数。它真正的分量，要在约束水平变动时才显出来。把约束右端从 0 改成一个可调的水平 c ，研究最优值如何随 c 变化：

$$v(c) = \max_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad g(\mathbf{x}) = c.$$

v 叫**值函数**（value function）。在消费者问题里， c 就是收入 m ， $v(m)$ 是“给定收入能达到的最高效用”——即间接效用函数；在成本最小化里， c 是要求的产量 $\bar{q}$ ， v 是成本函数。我们要证明的结论极其干净：

定理 19.2: Lagrange 乘子是值函数的斜率

设 $v(c) = \max_{\mathbf{x}} \{f(\mathbf{x}) : g(\mathbf{x}) = c\}$ ，且最优解 $\mathbf{x}^*(c)$ 与乘子 $\lambda^*(c)$ 随 c 连续可微。则

$$\frac{dv}{dc} = \lambda^*(c).$$

即：把约束放松一个单位，最优值的边际增量恰好等于 Lagrange 乘子。

证明. 最优解满足约束 $g(\mathbf{x}^*(c)) = c$ 与一阶条件 $\nabla f(\mathbf{x}^*) = \lambda^* \nabla g(\mathbf{x}^*)$ 。沿 c 对值函数求导，用链式法则：

$$\frac{dv}{dc} = \nabla f(\mathbf{x}^*)^\top \frac{d\mathbf{x}^*}{dc}.$$

代入一阶条件 $\nabla f(\mathbf{x}^*) = \lambda^* \nabla g(\mathbf{x}^*)$ ：

$$\frac{dv}{dc} = \lambda^* \nabla g(\mathbf{x}^*)^\top \frac{d\mathbf{x}^*}{dc}.$$

再看约束恒等式 $g(\mathbf{x}^*(c)) \equiv c$ ，两边对 c 求导得 $\nabla g(\mathbf{x}^*)^\top \frac{d\mathbf{x}^*}{dc} = 1$ 。代回即得 $\frac{dv}{dc} = \lambda^* \cdot 1 = \lambda^*$ 。□

这条结果是本章的心脏，值得逐字咀嚼。证明里出现了一个“奇迹”： $\frac{d\mathbf{x}^*}{dc}$ （最优选择如何随约束移动）本来是个麻烦的、要靠隐函数定理才能算的量，可它在最后一步被彻底消掉了——最优值对 c 的全部敏感性，只通过 λ^* 这一个数体现。这不是巧合，而是**包络定理**的雏形：在最优点上，因变量微调带来的间接影响是二阶小量，可以忽略，只剩约束水平变动的直接影响。这一点本书会在包络定理（第二十二章）正式展开。




图 19.2: 值函数 $v(c)$ 随约束水平 c 的变化；其在 c_0 处的切线斜率正是该处的 Lagrange 乘子 λ 。这把“乘子”与“约束的边际价值”钉在了一起。

有了 $\frac{dv}{dc} = \lambda$ ，乘子的所有经济叫法就都站得住了。

λ 是影子价格

$\lambda = \frac{dv}{dc}$ 说的是：约束放松一单位，目标的最优值能多涨多少——这就是该约束所约束的那份资源的**边际价值**，称为**影子价格** (shadow price)。它是“价格”，但不是市场上挂牌的价，而是这份资源对这个决策者而言的内在估值。几个落点：

- 效用最大化里，约束是预算， $c = m$ ，于是 $\lambda = \frac{dv}{dm}$ 是**收入的边际效用**——多给一块钱能多换多少效用。
- 成本最小化里，约束是产量， $\lambda = \frac{d(\text{成本})}{dq}$ 正是**边际成本**。
- 厂商面对一个紧的产能约束时， λ 是“这台机器再多一小时”值多少利润——它给出了为放松约束愿意支付的最高价。

例（读出影子价格）。

承接前例 $u = x_1 x_2$ ，但把收入设为可变的 m ，约束 $x_1 + x_2 = m$ 。求间接效用 $v(m)$ 与收入的边际效用，并验证它等于乘子。

解。

重做一阶条件： $x_2 = \lambda$ ， $x_1 = \lambda$ ， $x_1 + x_2 = m$ ，得 $x_1^* = x_2^* = m/2$ ， $\lambda^* = m/2$ 。于是间接效用

$$v(m) = x_1^* x_2^* = \left(\frac{m}{2}\right)^2 = \frac{m^2}{4}.$$

直接求导： $\frac{dv}{dm} = \frac{m}{2} = \lambda^*$ 。两者相等，正合定理。图 19.2 画的就是这个 $v(c) = c^2/4$ ：在 $c_0 = 6$ 处切线斜率 $= 6/2 = 3$ ，恰是前例算出的 $\lambda^* = 3$ 。收入越高， λ 越大，意味着这里多一块钱反而更值钱——因为 $u = x_1 x_2$ 不是凹到“边际效用递减”那一型；换一个凹效用就会得到递减的 λ ，这正是“收入边际效用递减”的来历。

注（量纲检查帮你记住 λ 是什么）。

$\lambda = \frac{dv}{dc}$ 的量纲是“目标单位每约束单位”。效用最大化里是“效用 / 元”，故 λ 是收入的边际效用；成本最小化里目标是元、约束是产量， λ 是“元 / 件”，即边际成本。每当忘了某个乘子代表什么，写出 $\frac{dv}{dc}$ 的量纲即可现场重建——这比硬背可靠得多。

19.5 多约束情形

约束不止一条时（ m 条等式约束， $m < n$ ），每条约束配一个自己的乘子。问题写成

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{s.t.} \quad g_1(\mathbf{x}) = 0, \dots, g_m(\mathbf{x}) = 0.$$

Lagrange 函数把每条约束各乘一个 λ_j 减进去：

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \sum_{j=1}^m \lambda_j g_j(\mathbf{x}), \quad \boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_m)^\top.$$

一阶条件 $\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0}$ 给出

$$\nabla f(\mathbf{x}^*) = \sum_{j=1}^m \lambda_j \nabla g_j(\mathbf{x}^*),$$

再加上 m 条约束 $g_j(\mathbf{x}^*) = 0$ 。几何意义是梯度共线的推广：最优点处， ∇f 落在诸约束梯度 $\{\nabla g_j\}$ 张成的子空间里——也就是约束面（各 $g_j = 0$ 的交集）的法空间。等价地， ∇f 没有任何分量平行于这张约束面，否则沿那个切向分量挪动既能升高 f 、又一阶地不违反任何约束。

为让 λ 唯一确定、Lagrange 法成立，需要约束在最优点处“互不冗余”：

假设 19.3: 约束品性（线性无关约束规范）

诸约束梯度 $\nabla g_1(\mathbf{x}^*), \dots, \nabla g_m(\mathbf{x}^*)$ 线性无关（等价地，Jacobian $D_{\mathbf{x}} \mathbf{g}$ 行满秩）。

注（为什么需要约束品性）。

若约束梯度线性相关，约束面在该点会“退化”（出现尖点或自相交）， ∇f 在法空间里的表示就不唯一，乘子 λ 可能不存在或不唯一。这与隐函数定理里那个“Jacobian 可逆”是同一类非退化要求：都是为了保证“在约束面上做微积分”这件事良好定义。单约束时它退化为 $\nabla g(\mathbf{x}^*) \neq \mathbf{0}$ 。本书在 KKT 条件（第二十章）会再次遇到它的不等式版本。

例（两约束约束）。

求 $f(\mathbf{x}) = x_1 + x_2 + x_3$ 在球面 $x_1^2 + x_2^2 + x_3^2 = 1$ 与平面 $x_1 + x_2 = 0$ 之交（一个圆）上的最大值。

解。

两约束 $g_1 = x_1^2 + x_2^2 + x_3^2 - 1, g_2 = x_1 + x_2$ 。Lagrange 函数 $\mathcal{L} = x_1 + x_2 + x_3 - \lambda_1 g_1 - \lambda_2 g_2$ ，一阶条件：

$$1 - 2\lambda_1 x_1 - \lambda_2 = 0, \quad 1 - 2\lambda_1 x_2 - \lambda_2 = 0, \quad 1 - 2\lambda_1 x_3 = 0.$$

前两式相减得 $2\lambda_1(x_2 - x_1) = 0$ 。在最优点 $\lambda_1 \neq 0$ （否则第三式 $1 = 0$ 矛盾），故 $x_1 = x_2$ ；配上约束 $x_1 + x_2 = 0$ 得 $x_1 = x_2 = 0$ 。代入球面约束得 $x_3^2 = 1$ ，即 $x_3 = \pm 1$ 。目标 $f = x_3$ 在 $x_3 = 1$ 处取最大值 1，最优点 $(0, 0, 1)$ 。（由第三式 $\lambda_1 = \frac{1}{2}$ ，再回代 $\lambda_2 = 1$ 。）

19.6 二阶条件：bordered Hessian

和无约束最优化一样，一阶条件只筛出“驻点”，要区分约束下的极大与极小还得看二阶。区别在于：约束最优不要求目标的 Hessian 整体负定，只要求它在约束面的切向上负定——沿着不可行的方向 f 怎么弯都无所谓，反正走不过去。把“只看切方向”这件事编码进矩阵，得到的就是加边 Hessian（bordered Hessian）。

对单约束问题，定义在最优点处的加边 Hessian 为

$$\bar{\mathbf{H}} = \begin{bmatrix} 0 & \nabla g^\top \\ \nabla g & \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L} \end{bmatrix} = \begin{bmatrix} 0 & g_{x_1} & g_{x_2} \\ g_{x_1} & \mathcal{L}_{x_1 x_1} & \mathcal{L}_{x_1 x_2} \\ g_{x_2} & \mathcal{L}_{x_2 x_1} & \mathcal{L}_{x_2 x_2} \end{bmatrix},$$

其中 $\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}$ 是 Lagrange 函数关于选择变量的 Hessian（已在乘子定下后求值），第一行/列用约束梯度 ∇g “加边”。它把约束信息镶进了 Hessian 的边框，使得只有约束切方向上的曲率被检验。判据如下（陈述，不逐行证）。

事实 19.4: 加边 Hessian 二阶充分条件 (n 变量、 m 约束)

设一阶条件在 $(\mathbf{x}^*, \lambda^*)$ 满足，约束品性成立。考察加边 Hessian $\bar{\mathbf{H}}$ 末端的一串顺序主子式。

- 局部极大的充分条件：从第 $2m+1$ 阶起的顺序主子式符号交替，且最后一个（整个 $\bar{\mathbf{H}}$ 的行列式）的符号为 $(-1)^n$ 。
- 局部极小的充分条件：这些顺序主子式同号，皆与 $(-1)^m$ 同号。

两种判据本质都是在说：把二次型 $\mathbf{z}^\top (\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}) \mathbf{z}$ 限制到约束切空间 $\{\mathbf{z} : \nabla g_j^\top \mathbf{z} = 0 \forall j\}$ 上，它分别负定（极大）或正定（极小）。

记不住符号规则不要紧——下面这条最常用的特例几乎覆盖了课程里的全部需求。

两变量单约束：只看一个行列式

$n=2, m=1$ 时，加边 Hessian 是 3×3 ，判据塌缩成一句话：

$$\det \bar{\mathbf{H}} > 0 \implies \text{约束局部极大}, \quad \det \bar{\mathbf{H}} < 0 \implies \text{约束局部极小}.$$

（对应通则里 $(-1)^n = (-1)^2 = +1$ 取极大、 $(-1)^m = -1$ 取极小。）消费者问题里 $\det \bar{\mathbf{H}} > 0$ 等价于无差异曲线凸向原点——这正是微观课“偏好凸性保证内点最优”的代数化身。

例（验证效用最大化的二阶条件）。

对 $u = x_1 x_2$ 、约束 $x_1 + x_2 = 6$ 的最优点 $(3, 3)$ ，用加边 Hessian 确认它是约束极大。

解。

$\mathcal{L} = x_1 x_2 - \lambda(x_1 + x_2 - 6)$ ，关于 $\mathbf{x}$ 的二阶偏导： $\mathcal{L}_{x_1 x_1} = 0$ ， $\mathcal{L}_{x_2 x_2} = 0$ ， $\mathcal{L}_{x_1 x_2} = 1$ 。约束梯度 $\nabla g = (1, 1)$ 。于是

$$\bar{\mathbf{H}} = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}, \quad \det \bar{\mathbf{H}} = 0 \cdot (0 - 1) - 1 \cdot (0 - 1) + 1 \cdot (1 - 0) = 2 > 0.$$

■ $\det \bar{\mathbf{H}} = 2 > 0$, 故 $(3, 3)$ 确是约束局部极大——与图 19.1 的相切图像一致。

加边 Hessian 看着比无约束的 Hessian 麻烦, 但思想是一回事: 二阶条件就是“在所有可行方向上, 目标都向下弯”。加边只是把“可行方向”这个限制塞进了线性代数里。

19.7 这把工具通向何处

Lagrange 法是整个最优化部分的枢纽, 它的去处密集而重要:

- **消费者与生产者理论**。马歇尔需求、希克斯需求、成本函数与支出函数, 全部来自带约束的最优化; 它们之间的对偶关系 (Shephard 引理、Roy 恒等式) 本质上都是“乘子 = 值函数斜率”这条定理在不同约束上的实例。
- **影子价格与资源配置**。 λ 作为资源的边际价值, 是机制设计、最优课税、一般均衡里“价格即影子价格”等思想的数学起点; 线性规划的对偶变量也是同一个 λ 。
- **KKT 条件** (第二十章)。现实约束多是不等式 (“花不超过收入”而非“恰好花光”)。KKT 把本章推广到不等式: 每条约束仍配一个乘子, 但要求 $\lambda_j \geq 0$ 且满足互补松弛——约束不紧时其影子价格为零。本章是它的“约束全部取等”特例。
- **包络定理** (第二十二章)。本章 $\frac{\partial \mathcal{L}}{\partial c} = \lambda$ 已经是包络定理的一个切片: 最优值对参数的导数, 等于 Lagrange 函数对该参数的偏导在最优点的取值。包络定理把它推广到任意参数, 并解释了为什么“间接影响可忽略”。
- **约束估计**。计量里的约束最小二乘、约束极大似然, 把参数限制写成等式约束后正是本章的问题; 乘子的大小还连着检验约束是否成立的 Lagrange 乘子检验 (LM 检验)——它的名字就来自这里。

一句话收束: 等式约束最优化用一个乘子 λ 把“怎么选” (梯度共线) 和“约束值多少” (影子价格) 这两件事一并交到你手里。认住这个 λ 的双重身份, 消费者理论、对偶、KKT、包络定理乃至 LM 检验, 就都成了同一把钥匙开的几扇门。

第二十章 不等式约束与 KKT 条件

用到的前置工具：梯度与 Jacobian (多元微分一章, 第十三章); 等式约束下的 Lagrange 乘子法 (见前一章「等式约束与 Lagrange 乘子」); 凹凸函数与凸集 (第十六章)。

上一章的 Lagrange 乘子法处理的是“恰好取等”的约束：预算花光、资源用尽、产量正好等于订单。可现实里的约束多半不是这副样子。消费者“花费不超过收入”——但他完全可以存一点；厂商“产量不超过产能”——但淡季时产能根本闲着；几乎每个经济变量还自带一条“不能为负”的底线。这些都是不等式约束 $g(\mathbf{x}) \leq 0$ ，它带来一个 Lagrange 法没有的新问题：约束到底起不起作用，要等解出来才知道。本章要讲的 KKT 条件，正是把 Lagrange 法推广到不等式约束的那把工具——它用一组优雅的“互补”关系，一次性地把“哪些约束紧、哪些松”和“各自的乘子”都刻画了出来。这是带约束优化真正的主力一阶条件，也是凸优化、受约束估计、机制设计里反复登场的同一套语言。

20.1 不等式约束带来的新问题

先看等式约束法在哪里不够用。考虑标准的约束极大化问题

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{s.t.} \quad g_j(\mathbf{x}) \leq 0, \quad j = 1, \dots, m.$$

(任何“ $\geq$ ”约束写成 $-g \leq 0$ ，等式约束 $h = 0$ 拆成 $h \leq 0$ 与 $-h \leq 0$ 即可，所以这一种形式已经足够一般。)

如果把每条 $g_j \leq 0$ 都当成 $g_j = 0$ 去套 Lagrange 法，立刻会出错。问题在于：在最优点处，有些约束恰好取等 ($g_j(\mathbf{x}^*) = 0$)，我们说这条约束是**起作用的**或**紧的**，active / binding)，有些则严格松弛 ($g_j(\mathbf{x}^*) < 0$)，约束是**不起作用的**或**松的**，inactive / slack)。

不等式约束的核心难点：起作用集是内生的

紧的约束像一堵墙，最优点被它顶住，它会像等式约束那样在一阶条件里贡献一个乘子；松的约束则形同虚设，最优点离它还远，挪一挪它丝毫不影响最优，它不该出现在一阶条件里。麻烦在于：**究竟哪些约束紧、哪些松，是问题的解的一部分，事先并不知道**。我们不能像等式约束那样直接列方程，必须让一阶条件本身有能力“自动判别”每条约束的死活——这正是 KKT 条件比 Lagrange 法多出来的那层结构。




图 20.1: 不等式约束极大化的几何。可行域（浅蓝三角）由 $x_1 \geq 0$, $x_2 \geq 0$, $x_1 + x_2 \leq 5$ 围成；目标 f 的等值线是以无约束最优 $\mathbf{x}^u = (4, 4)$ 为圆心、半径越小值越大的同心圆。无约束最优落在可行域外，于是约束最优 $\mathbf{x}^* = (2.5, 2.5)$ 被边界 $g_1 = 0$ 顶住：等值圆在此与边界相切， ∇f 与起作用约束的 ∇g_1 同向（都指向可行域外侧），二者共线——这正是 KKT 驻点条件 $\nabla f = \lambda_1 \nabla g_1$ ($\lambda_1 > 0$) 的图像。 $x_1 \geq 0$, $x_2 \geq 0$ 两条约束在此处松弛，对应乘子为零。

图 20.1 把这件事画了出来。当无约束最优落在可行域之外，最优解被某条边界顶住，在那里目标的等值线与边界相切，目标梯度 ∇f 沿着“往可行域外推”的方向，恰好与起作用约束的梯度 ∇g_j 共线。下面要做的，是把这幅图翻译成一组代数条件。

20.2 KKT 条件：四件套

仿照 Lagrange 法，给每条约束 $g_j \leq 0$ 配一个乘子 λ_j ，写出 Lagrange 函数

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \sum_{j=1}^m \lambda_j g_j(\mathbf{x}), \quad \boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_m).$$

（这里取减号，是为了让 $\lambda_j \geq 0$ ；符号约定的来由稍后细说。）刻画最优点的，是下面四组条件。

定理 20.1: Karush–Kuhn–Tucker 必要条件

设 $f, g_1, \dots, g_m$ 在 $\mathbf{x}^*$ 附近连续可微, $\mathbf{x}^*$ 是上述问题的局部极大点, 且在 $\mathbf{x}^*$ 处满足某个约束规范 (见第 20.3 节)。则存在乘子 $\lambda_1^*, \dots, \lambda_m^*$, 使得:

- | | |
|--------------------------------------|---|
| (i) 驻点 (stationarity): | $\nabla f(\mathbf{x}^*) = \sum_{j=1}^m \lambda_j^* \nabla g_j(\mathbf{x}^*);$ |
| (ii) 原始可行 (primal feasibility): | $g_j(\mathbf{x}^*) \leq 0, \quad j = 1, \dots, m;$ |
| (iii) 对偶可行 (dual feasibility): | $\lambda_j^* \geq 0, \quad j = 1, \dots, m;$ |
| (iv) 互补松弛 (complementary slackness): | $\lambda_j^* g_j(\mathbf{x}^*) = 0, \quad j = 1, \dots, m.$ |

这四条各管一摊, 缺一不可, 值得逐条体会其含义。

(i) 驻点。 这是 Lagrange 一阶条件的直接翻版: 在最优点, 目标梯度被起作用约束的梯度“撑住”。写开就是

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) - \sum_j \lambda_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}.$$

它说的是: 在最优点再没有一个“既可行又能让 f 上升”的移动方向了。任何想让 f 增大的方向 (即与 ∇f 夹角小于 90° 的方向), 都会顶到某条起作用约束的墙上。

(ii) 原始可行。 平凡但不可省: 最优点首先得在可行域里。

(iii) 对偶可行。 乘子非负, $\lambda_j^* \geq 0$ 。这是不等式约束相对等式约束最关键的新增条件——等式约束的乘子可正可负, 不等式约束的乘子却被钉死在非负一侧。其根源是不等式约束只朝一个方向限制你 (见下节符号约定)。

(iv) 互补松弛。 $\lambda_j^* g_j(\mathbf{x}^*) = 0$ 对每个 j 成立——这是 KKT 的灵魂。它说: 对每条约束, 乘子 λ_j^* 与松弛量 $g_j(\mathbf{x}^*)$ 至少有一个为零, 二者不能同时非零。换言之

互补松弛把“起作用集是内生的”这一难点一举化解

互补松弛 $\lambda_j^* g_j(\mathbf{x}^*) = 0$ 等价于一句大白话:

- 约束松 ($g_j(\mathbf{x}^*) < 0$, 离墙还远) $\implies$ 它的乘子 $\lambda_j^* = 0$, 它不进一阶条件, 仿佛不存在;
- 乘子为正 ($\lambda_j^* > 0$, 这条约束在出力) $\implies$ 必有 $g_j(\mathbf{x}^*) = 0$, 约束紧, 最优点正贴在这堵墙上。

于是我们不必事先知道哪些约束起作用: 互补松弛让一阶条件自动关掉所有松约束、只留下紧约束, 恰好实现了第 20.1 节那个“自动判别约束死活”的诉求。乘子 λ_j^* 在这里有了清晰的经济含义——它是把第 j 条约束放松一单位 (资源多

给一点、预算多一块钱)所能换来的目标增量,即约束的**影子价格**。松约束的影子价格自然为零:你手上的资源还没用完,再多给也不值钱。

注(互补松弛不是说“恰好一个为零”)。

$\lambda_j^* g_j = 0$ 允许两者同时为零:约束恰好取等($g_j = 0$)但其乘子也恰是 0。这种“临界”情形(约束刚刚好顶上、却不出力)在分析里要小心,它对应起作用集发生切换的边界,也是后面比较静态可能不光滑的地方。严格互补(每条起作用约束的乘子都 > 0)是一个更强、更“好”的假设,常被额外加上以保证解的良态。

20.2.1 符号约定:为什么 $\lambda \geq 0$

乘子非负不是约定俗成,而是几何强加的。在一个起作用约束 $g_j(\mathbf{x}^*) = 0$ 处,可行域局部位位于 $g_j \leq 0$ 一侧,梯度 ∇g_j 指向 g_j 增大的方向——也就是离开可行域、朝禁区去的外法向。最优点既然被这堵墙顶住,目标必定还想往墙外走才对: ∇f 必须指向可行域外侧,即与外法向 ∇g_j 同向(在多约束时,是落在诸 ∇g_j 张成的“外推锥”里)。“同向”就意味着展开式

$$\nabla f(\mathbf{x}^*) = \sum_{j: \text{起作用}} \lambda_j^* \nabla g_j(\mathbf{x}^*)$$

里的系数 λ_j^* 必须非负。若某个 $\lambda_j^* < 0$, 则 ∇f 有一个指向可行域内部的分量,意味着“往里挪一点 f 还能涨”——那 $\mathbf{x}^*$ 根本不是极大点,矛盾。

$\lambda \geq 0$ 的方向逻辑(一句话记住)

不等式约束只朝一个方向挡你:它不让你越过墙,却随你后退。所以在最优点,目标的“上山方向”只可能朝墙外、不可能朝墙里—— ∇f 与外法向 ∇g 同侧,乘子因此非负。等式约束两侧都挡,乘子才可正可负。记号警示: $\lambda \geq 0$ 的正负号死死绑定在你怎么写约束($g \leq 0$ 还是 $g \geq 0$)和 $\mathcal{L}$ 里用加号还是减号上;换了写法符号就翻。本书统一取“ $g \leq 0$ 、 $\mathcal{L} = f - \sum \lambda_j g_j$ 、 $\lambda \geq 0$ ”这一套,用前务必核对自己的约定是否一致。

20.2.2 从 Lagrange 到 KKT 的推导直觉

KKT 条件可以这样“凑”出来:在最优点 $\mathbf{x}^*$,把起作用集记为 $A = \{j : g_j(\mathbf{x}^*) = 0\}$ 。只有起作用的约束才在局部约束你,松约束因为有余量,在 $\mathbf{x}^*$ 的一个小邻域内自动满足、可以暂时忽略。于是在该邻域内,问题退化成一个只带等式约束 $\{g_j = 0 : j \in A\}$ 的 Lagrange 问题,其一阶条件正是

$$\nabla f(\mathbf{x}^*) = \sum_{j \in A} \lambda_j^* \nabla g_j(\mathbf{x}^*).$$

对松约束 $j \notin A$, 令 $\lambda_j^* = 0$, 上式就能写成对所有 j 求和的形式 (i); 而“ $j \notin A \implies \lambda_j^* = 0$ ”与“ $j \in A \implies g_j = 0$ ”合起来恰是互补松弛 (iv)。剩下的非负性 (iii) 由上一小

节的方向论证补足，可行性 (ii) 是最优点的定义。四件套就此凑齐。

这套“先猜起作用集、再当等式约束解”的思路，也正是手算 KKT 问题的标准套路（见下例）：枚举若干种起作用集的情形，每种情形下把紧约束当等式解出候选点，再回头验证它满足全部四条 KKT 条件——尤其是被忽略约束的可行性与所求乘子的非负性。

注（严格的推导需要约束规范）。

上面“退化成等式约束 Lagrange 问题”这一步偷偷用了一个前提：起作用约束的梯度 $\{\nabla g_j(\mathbf{x}^*) : j \in A\}$ 表现得足够“规整”，使得可行域在 $\mathbf{x}^*$ 处的局部形状真的被这些梯度的线性结构刻画。这个前提就是约束规范。它不成立时，乘子可能根本不存在，KKT 条件随之失效——下节专门讨论。严格的证明（用 Farkas 引理或分离超平面把“不存在可行上升方向”翻译成“ ∇f 落在 ∇g_j 张成的锥里”）属于较重的凸分析构造，这里只给上述直觉，不逐行搭建。

20.3 约束规范：为什么需要它

KKT 是必要条件，但有一个前提常被初学者忽略：它只在最优点满足某个约束规范（constraint qualification, CQ）时才保证乘子存在。约束规范是对可行域在最优点处“不太病态”的技术性要求；它失效时，一个货真价实的最优点也可能凑不出满足 (i)–(iv) 的乘子。

定义 20.2: 线性无关约束规范 (LICQ)

称问题在可行点 $\mathbf{x}^*$ 处满足线性无关约束规范，如果起作用约束的梯度族

$$\{\nabla g_j(\mathbf{x}^*) : j \in A\}, \quad A = \{j : g_j(\mathbf{x}^*) = 0\}$$

线性无关。

LICQ 是最常用、也最容易检验的一种约束规范。此外还有更弱的若干种，例如 Mangasarian – Fromovitz 条件与 Slater 条件；凸问题下尤以后者常用（见下节）。它的作用是保证：可行域在 $\mathbf{x}^*$ 处的“可行方向”真的由这些梯度的线性结构决定，从而上一节那套“退化成等式 Lagrange”的推导站得住脚。

CQ 为何不可省？根子在于 KKT 驻点条件 (i) 谈的是梯度之间的线性关系，而梯度只看约束函数的一阶信息。如果可行域的真实形状在 $\mathbf{x}^*$ 处出现了一阶信息“看不见”的尖角或退化（比如两条约束在此相切、梯度共线），那么“ ∇f 落在 ∇g_j 张成的锥里”这件事就可能对真正的最优点也不成立。

例（约束规范失效，KKT 凑不出乘子）。

求解 $\max_{x_1, x_2} x_1$ ，约束为

$$g_1(\mathbf{x}) = x_2 - (1 - x_1)^3 \leq 0, \quad g_2(\mathbf{x}) = -x_2 \leq 0.$$

可行域被 $x_2 \geq 0$ 与 $x_2 \leq (1 - x_1)^3$ 夹住。直观上 x_1 越大越好，最优点是 $\mathbf{x}^* = (1, 0)$

(此处两约束都取等)。检验 KKT 是否成立。

解.

在 $\mathbf{x}^* = (1, 0)$ 处两约束都起作用。算梯度：

$$\nabla g_1 = (3(1 - x_1)^2, 1) \Big|_{(1,0)} = (0, 1), \quad \nabla g_2 = (0, -1).$$

两者共线（一个是另一个的 -1 倍），线性相关——LICQ 在此失效。再看 KKT 驻点条件需要

$$\nabla f = (1, 0) = \lambda_1(0, 1) + \lambda_2(0, -1) = (0, \lambda_1 - \lambda_2).$$

左边第一个分量是 1，右边第一个分量恒为 0：方程无解。于是在真正的最优点 $(1, 0)$ 处根本不存在 KKT 乘子。这不是因为 $(1, 0)$ 不是最优，而是因为约束规范失效——可行域在该点收成一个“尖”（两条边界相切），一阶梯度信息看不出 x_1 还能不能增大。这个反例提醒我们：套用 KKT 前，至少要瞥一眼起作用约束的梯度是不是线性无关。

约束规范的实用态度

绝大多数应用里，约束要么是线性的（预算、资源、非负约束——线性约束自动满足一种约束规范，无需另检），要么可行域“凸而内点非空”（满足 Slater 条件，见下节）。这两类情形覆盖了经济学里的几乎全部问题，所以约束规范通常不是障碍。真正要警惕的，是非线性约束在某点相切、或起作用约束个数超过变量个数时——这时务必检查 LICQ，别让一个失效的乘子方程把你引向错误结论。

20.4 凸问题下 KKT 是充分条件

到此为止 KKT 都只是必要条件：最优点（在 CQ 下）必满足 KKT，但满足 KKT 的点未必最优——它可能是局部极小、鞍点，或诸多局部极大里的一个。这跟无约束情形里“一阶条件只给驻点”是同一个毛病。补上这道缺口的，仍然是凸凸性。

定理 20.3: KKT 在凸问题下充分

考虑问题 $\max f(\mathbf{x})$ s.t. $g_j(\mathbf{x}) \leq 0$ ($j = 1, \dots, m$)，并设

- 目标 f 是凹函数；
- 每个约束函数 g_j 是凸函数（于是可行域 $\{\mathbf{x} : g_j(\mathbf{x}) \leq 0, \forall j\}$ 是凸集）。

若 $\mathbf{x}^*$ 连同某组乘子 $\lambda^* \geq 0$ 满足全部 KKT 条件 (i)–(iv)，则 $\mathbf{x}^*$ 是全局最优解。

证明. 设 $\mathbf{x}^*, \boldsymbol{\lambda}^*$ 满足 KKT。构造 Lagrange 函数关于 $\mathbf{x}$ 的截面

$$\phi(\mathbf{x}) = f(\mathbf{x}) - \sum_j \lambda_j^* g_j(\mathbf{x}).$$

因为 f 凹、每个 g_j 凸、且 $\lambda_j^* \geq 0$ ，所以 $-\lambda_j^* g_j$ 凹， ϕ 作为凹函数之和仍凹。凹函数的一个基本性质是“切平面在其上方”（一阶条件，见第十六章）：对任意可行点 $\mathbf{x}$ ，

$$\phi(\mathbf{x}) \leq \phi(\mathbf{x}^*) + \nabla \phi(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

而 KKT 驻点条件 (i) 恰说 $\nabla \phi(\mathbf{x}^*) = \nabla f(\mathbf{x}^*) - \sum_j \lambda_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$ ，故上式右端的线性项消失：

$$\phi(\mathbf{x}) \leq \phi(\mathbf{x}^*) \quad \text{对一切 } \mathbf{x}.$$

现把 ϕ 还原。任取一个可行的 $\mathbf{x}$ (即 $g_j(\mathbf{x}) \leq 0$)。由对偶可行 $\lambda_j^* \geq 0$ ，有 $\sum_j \lambda_j^* g_j(\mathbf{x}) \leq 0$ ，因此

$$f(\mathbf{x}) = \phi(\mathbf{x}) + \sum_j \lambda_j^* g_j(\mathbf{x}) \leq \phi(\mathbf{x}) \leq \phi(\mathbf{x}^*).$$

再看 $\mathbf{x}^*$ 这一头：由互补松弛 (iv)， $\sum_j \lambda_j^* g_j(\mathbf{x}^*) = 0$ ，于是 $\phi(\mathbf{x}^*) = f(\mathbf{x}^*)$ 。两段拼起来，对一切可行 $\mathbf{x}$ 都有

$$f(\mathbf{x}) \leq \phi(\mathbf{x}^*) = f(\mathbf{x}^*).$$

即 $\mathbf{x}^*$ 是全局最大值点。 □

凸性把 KKT 从“候选”升级为“答案”

这条定理是凸优化全部威力的来源，其分量与上一章“凹 $\implies$ 局部最优即全局最优”完全平行：在凸问题（凹目标 + 凸可行域）里，KKT 条件既必要又充分。于是“解优化问题”彻底等价于“解 KKT 方程组”——找到任何一个满足四件套的 $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ ，就一劳永逸地拿到了全局最优，无需再担心局部解、无需比较多个候选。线性规划、二次规划、几乎所有现代凸优化求解器，骨子里都在求解 KKT 系统。此外凸问题里 Slater 条件（存在严格内点 $\bar{\mathbf{x}}$ 使所有 $g_j(\bar{\mathbf{x}}) < 0$ ）即可充当约束规范，比 LICQ 更易验证。

注（凸问题里 KKT 与对偶的接口）。

在凸问题中，KKT 条件还正好是原问题与其 Lagrange 对偶问题之间“强对偶”（对偶间隙为零）成立的刻画： $\mathbf{x}^*$ 原问题最优、 $\boldsymbol{\lambda}^*$ 对偶问题最优，当且仅当二者满足 KKT。对偶视角（下一章「凸优化与对偶」）会把乘子 $\boldsymbol{\lambda}^*$ 进一步解读为对偶问题的解，并把影子价格的含义讲透。这里先记住：互补松弛正是连接原始与对偶两个世界的那座桥。

20.5 实例：带预算与非负约束的消费选择

把四件套用一遍，最透亮的例子是消费者问题里的角点解——这也是 KKT 在微观经济学里最经典的落点。

例（角点解与互补松弛）。

消费者在两种商品上求效用极大，效用 $u(x_1, x_2) = \alpha \ln x_1 + x_2$ ($\alpha > 0$ ，“拟线性”偏好)，价格均为 1，收入为 $I > 0$ 。问题是

$$\max_{x_1, x_2} \alpha \ln x_1 + x_2 \quad \text{s.t.} \quad x_1 + x_2 \leq I, \quad x_1 \geq 0, \quad x_2 \geq 0.$$

用 KKT 求解，并说明收入 I 很小时会出现什么。

解。

把约束统一写成 $g \leq 0$ 的形式： $g_1 = x_1 + x_2 - I \leq 0$ （预算）， $g_2 = -x_1 \leq 0$ ， $g_3 = -x_2 \leq 0$ （两条非负约束）。配乘子 $\lambda_1, \lambda_2, \lambda_3 \geq 0$ ，Lagrange 函数

$$\mathcal{L} = \alpha \ln x_1 + x_2 - \lambda_1(x_1 + x_2 - I) - \lambda_2(-x_1) - \lambda_3(-x_2).$$

驻点条件 (i)（对 x_1, x_2 分别求偏导置零）：

$$\frac{\partial \mathcal{L}}{\partial x_1} = \frac{\alpha}{x_1} - \lambda_1 + \lambda_2 = 0, \quad \frac{\partial \mathcal{L}}{\partial x_2} = 1 - \lambda_1 + \lambda_3 = 0.$$

效用对 x_1 的边际 α/x_1 在 $x_1 \rightarrow 0$ 时趋于 $+\infty$ （Inada 型），故最优必有 $x_1 > 0$ ；由互补松弛 $\lambda_2 x_1 = 0$ 得 $\lambda_2 = 0$ 。又因为多消费总有正效用（ x_2 的边际为 $1 > 0$ ），预算必花光， $g_1 = 0$ 即 $x_1 + x_2 = I$ ，对应 $\lambda_1 > 0$ 。剩下要判别的是 x_2 这条非负约束的死活——这正是有没有角点解的关键。

情形一：内点解（ $x_2 > 0$ ）。则 $\lambda_3 = 0$ ，第二式给 $\lambda_1 = 1$ ，第一式给 $\alpha/x_1 = \lambda_1 - \lambda_2 = 1$ ，即

$$x_1^* = \alpha, \quad x_2^* = I - \alpha.$$

要 $x_2^* > 0$ 须 $I > \alpha$ 。这时拟线性偏好的标志性结论出现了： $x_1^* = \alpha$ 与收入无关，收入的增减全部砸在 x_2 上。

情形二：角点解（ $x_2 = 0$ ）。当 $I \leq \alpha$ ，上面的 $x_2^* = I - \alpha \leq 0$ 不可行，最优被逼到边界 $x_2 = 0$ 上。此时 $\lambda_3 \geq 0$ 不再为零，预算花光给 $x_1^* = I$ ，第一式（ $\lambda_2 = 0$ ）给 $\lambda_1 = \alpha/x_1 = \alpha/I$ ，第二式给

$$\lambda_3 = \lambda_1 - 1 = \frac{\alpha}{I} - 1.$$

当 $I < \alpha$ 时 $\lambda_3 > 0$ ，对偶可行满足，互补松弛 $\lambda_3 x_2 = \lambda_3 \cdot 0 = 0$ 自动成立——这是一个合格的 KKT 点。它的含义是：收入太低，消费者把钱全花在商品 1 上，商品 2 一点不买，非负约束 $x_2 \geq 0$ 在此紧绷，其影子价格 $\lambda_3 = \alpha/I - 1 > 0$ 度量“如果允许 x_2 取负值能多榨出多少效用”。

由于 u 凹、约束全线性（自动凸、自动满足约束规范），由第 20.4 节的充分性定

理，上面找到的 KKT 点就是全局最优。两种情形在 $I = \alpha$ 处平滑接上 (λ_3 从 0 开始变正)，互补松弛在此完成了从“ x_2 约束松”到“ x_2 约束紧”的切换。

图 20.2 把这两种情形并排画出，是理解互补松弛“切换”的最好图像。




图 20.2: 互补松弛的切换。左: 收入较高 ($I > \alpha$), 无差异曲线与预算线在内部相切, 两种商品都买, 非负约束 $x_2 \geq 0$ 松弛、 $\lambda_3 = 0$ 。右: 收入较低 ($I < \alpha$), 在边界 $x_2 = 0$ 处无差异曲线比预算线更陡 (边际替代率始终大于价格比), 最优被顶到角点, $x_2 \geq 0$ 紧绷、影子价格 $\lambda_3 = \alpha/I - 1 > 0$ 。从左到右, 正是互补松弛把约束 $x_2 \geq 0$ 由“松”切到“紧”。

20.6 它通向何处

KKT 是带约束优化的通用语言，本章这把工具的去处密布在三大核心课乃至应用领域里：

- **微观经济学：角点解与非负约束。** 消费者理论里“某商品买零”、生产理论里“某要素不投入”、以及一切“非负”变量，都是非负约束起作用的角点解，全靠互补松弛刻画。上例的拟线性需求只是冰山一角。
- **机制设计与契约理论：IC 与 IR 约束。** 激励相容 (IC) 与参与 (IR) 约束本质都是不等式约束，最优契约的特征 (哪条 IC 紧、哪条 IR 紧) 正是一组互补松弛的结论——“哪类代理人的约束绑定”往往就是整个机制的设计要点。
- **凸优化与对偶 (下一章)。** 凸问题下 KKT 充分性 + Slater 约束规范，是整个凸优化与 Lagrange 对偶理论的支点；线性规划、二次规划都是其特例。
- **受约束的估计：受限 MLE / GMM。** 当参数被理论先验地限制 (方差非负、概率落在单纯形上、份额加总为一、单调性或不等式形状约束)，极大似然或 GMM 就变成带不等式约束的优化，其解由 KKT 刻画；约束是否起作用还直接影响检验统计量的渐近分布 (边界上的参数会让标准正态近似失效，这是“边界参数推断”问题的根源，渐近统计部分会再遇到)。

一句话收束

Lagrange 法回答“约束恰好取等时怎么办”,KKT 把它推广到“约束可松可紧”的真实世界,代价只是多了一组对偶可行 ($\lambda \geq 0$) 与互补松弛 ($\lambda_j g_j = 0$) 的条件——而后者恰恰自动解决了“哪些约束起作用”这个最棘手的问题。再叠上凹凸性, KKT 就从“最优的必要特征”升格为“找到全局最优的充要判据”,成为凸优化与一切受约束决策、受约束估计的共同地基。

第二十一章 凸优化与对偶

用到的前置工具：凸集、凹凸函数与上方图/下方图（凹凸性一章，第十六章）；梯度与一阶判据（多元微分一章，第十三章）；Lagrange 乘子与 KKT 条件（约束最优化，第十九、二十章）；分离超平面的几何（第十六章）。

到上一章为止，我们已经知道“凹目标 + 凸约束”是一类格外友好的最优化问题：局部最优即全局最优，一阶条件从必要升级为充分。这一章把这件事正式命名为**凸优化**，并揭示它身上一个深刻而实用的结构——**对偶**。

对偶之所以值得单独成章，有两个理由。其一，它是个算界的工具：哪怕原问题难解，我们也能从它的对偶问题廉价地得到一个界，把“最优值大概在哪儿”框住。其二，也是经济学家更该在意的，对偶给了许多经济量第二副面孔：约束最优化里的 Lagrange 乘子，在对偶视角下正是“松动一单位约束值多少钱”的**影子价格**；成本最小化与效用最大化、生产前沿的投入与产出、线性规划的资源与定价，这些看似各说各话的经济模型，骨子里都是同一个对偶关系的两面。学会在原问题与对偶问题之间自由切换，等于多了一种重写经济模型的语言。

本章先把凸优化问题界定清楚，再从 Lagrangian 出发构造对偶函数，证明它无论原问题如何都是凹的；接着给出永远成立的弱对偶、以及在 Slater 条件下成立的强对偶；最后把这一切翻译成鞍点与极小极大的语言，并指出它在微观、计量、机器学习里的诸多落点。

21.1 什么是凸优化问题

先把研究对象框定。本章统一采用**极小化**的标准写法（凹的极大化问题取负号即化为凸的极小化，二者完全对称，只是对偶理论的文献惯例如此）。

定义 21.1: 凸优化问题（标准形式）

形如

$$\min_{\mathbf{x} \in \mathbb{R}^n} f_0(\mathbf{x}) \quad \text{s.t.} \quad f_i(\mathbf{x}) \leq 0 \ (i = 1, \dots, m), \quad \mathbf{a}_j^\top \mathbf{x} = b_j \ (j = 1, \dots, p)$$

的问题称为**凸优化问题**，如果目标 f_0 与每个不等式约束函数 f_i 都是凸函数，而等式约束是仿射的（即 $\mathbf{a}_j^\top \mathbf{x} = b_j$ ，线性等式）。它的**可行域**

$$\mathcal{X} = \{ \mathbf{x} : f_i(\mathbf{x}) \leq 0 \ \forall i, \ \mathbf{a}_j^\top \mathbf{x} = b_j \ \forall j \}$$

是一个凸集，目标在其上凸。记最优值为 $p^* = \inf_{\mathbf{x} \in \mathcal{X}} f_0(\mathbf{x})$ 。

为什么可行域必凸？每个 $\{ \mathbf{x} : f_i(\mathbf{x}) \leq 0 \}$ 是凸函数 f_i 的一个下等值集，由凸性它是凸集（见第十六章）；每个仿射等式 $\mathbf{a}_j^\top \mathbf{x} = b_j$ 是一张超平面，也凸；可行域是这些凸集的交，仍凸。于是凸优化恰好就是上一章那张“保证书”适用的场景。

为什么凸优化被称作“可解”的优化

凸优化几乎是非线性最优化里唯一一类“算得动”的问题，原因正是上一章的核心承诺在约束情形下依然成立：

- **局部即全局**。可行域凸、目标凸，任一局部极小都是全局极小，不必担心陷在某个次优的山谷里。
- **KKT 充要**。一般约束问题里 KKT 只是必要条件；而对凸问题（在 Slater 等温和条件下），**KKT 条件成为充分必要**——解出 KKT 系统就等于解出全局最优。
- **多项式时间可解**。从理论到实践（内点法），凸问题有成熟高效的算法保证。

正因如此，“把一个问题识别或改写成凸优化”本身就是一种本领：一旦坐进凸优化的框架，可解性、唯一性、灵敏度分析就都是现成的。本章的对偶理论，则是这个框架里最锋利的一把刀。

并非所有凸约束集都写成“ $f_i \leq 0$ 且 f_i 凸”的样子——但只要可行域是凸集、目标是凸函数，问题就是凸的。标准形式只是为了让后面的 Lagrange 对偶有统一的记号载体。注意约束写成 $f_i(\mathbf{x}) \leq 0$ 是一种规范：“ $g(\mathbf{x}) \geq c$ ”型约束先改写成 $c - g(\mathbf{x}) \leq 0$ ，这要求 $-g$ （即 g 凹）才保持凸性。

21.2 Lagrangian 与对偶函数

对偶的全部出发点，是一个把约束“价格化”的老办法——Lagrangian。上一章（约束最优化）里它是用来写一阶条件的；这一章我们换个用法：把它对原变量取下确界，得到一个只依赖乘子的新函数。

定义 21.2: Lagrangian 与对偶函数

对上述标准凸问题，引入不等式约束的乘子 $\lambda \in \mathbb{R}^m$ ($\lambda_i \geq 0$) 与等式约束的乘子 $\nu \in \mathbb{R}^p$ ，定义 **Lagrangian**

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j (a_j^\top x - b_j).$$

对原变量 x 取下确界，得到 **Lagrange 对偶函数**

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu).$$

直觉上，乘子 λ_i 是给违反第 i 条约束开出的罚价：约束 $f_i \leq 0$ 若被违反 ($f_i > 0$)，就在目标上加一笔正的罚款 $\lambda_i f_i$ 。Lagrangian 把“硬约束”软化成“软惩罚”；对 x 取 $\inf$ ，则是问“在这套罚价下，决策者最低能把（被惩罚后的）目标压到多少”。这个最低值就是对偶函数。

对偶函数有一条无论原问题凸不凸都成立的、近乎神奇的性质：

定理 21.3: 对偶函数恒为凹

对偶函数 $g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$ 是关于 (λ, ν) 的凹函数，且取值在 $[-\infty, +\infty)$ 中——即便原问题非凸，这一点也成立。

证明. 关键在于：固定 x ，Lagrangian $L(x, \lambda, \nu)$ 是 (λ, ν) 的仿射函数 (λ_i, ν_j 都只一次方出现，系数是 $f_i(x)$ 、 $a_j^\top x - b_j$ 这些与乘子无关的常数)。仿射函数当然既凹又凸。而对偶函数是这一族（以 x 为指标的）仿射函数的逐点下确界：

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu).$$

凹凸性一章已证（第十六章）：一族凹函数的逐点下确界仍凹（用上方图刻画—— $\text{hyp } g = \bigcap_x \text{hyp } L(x, \cdot)$ 是一族凸集之交，故凸，故 g 凹）。仿射尤其是凹，故 g 凹。证毕。□

对偶函数为何“白送”一个凹结构

这条定理是整个对偶理论的引擎。它说：不管你的原问题多么糟糕（非凸、不连续、组合的），它的对偶函数总是凹的，因而对偶问题——极大化 g ——总是一个凸优化问题。于是哪怕原问题难解，对偶问题也是“好”的。这就是为什么人们愿意绕到对偶那边去：那里风景永远是凸的。代价是对偶只给出原问题的一个界（下一节的弱对偶），界紧不紧则取决于强对偶是否成立。

注（对偶函数可以取到 $-\infty$ ）。

对某些 (λ, ν) , Lagrangian 关于 $\mathbf{x}$ 无下界, 此时 $g = -\infty$ 。这并不是毛病: 这些乘子对求界毫无帮助 (给出的下界是 $-\infty$), 自然会在极大化 g 时被排除。对偶函数真正“有用”的定义域 $\text{dom } g = \{(\lambda, \nu) : g > -\infty\}$ 是一个凸集, 对偶问题只在其上做文章。

一个能算到底的例子

例 (等式约束二次极小化的对偶)。

求 $\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T \mathbf{x}$ s.t. $\mathbf{Ax} = \mathbf{b}$, 其中 $\mathbf{A} \in \mathbb{R}^{p \times n}$ 行满秩。写出对偶函数。

解.

Lagrangian (只有等式约束, 乘子 ν):

$$L(\mathbf{x}, \nu) = \frac{1}{2} \mathbf{x}^T \mathbf{x} + \nu^T (\mathbf{Ax} - \mathbf{b}).$$

固定 ν , 对 $\mathbf{x}$ 求下确界。 L 关于 $\mathbf{x}$ 是凸二次型, 令梯度为零:

$$\nabla_{\mathbf{x}} L = \mathbf{x} + \mathbf{A}^T \nu = \mathbf{0} \implies \mathbf{x}^* = -\mathbf{A}^T \nu.$$

代回:

$$g(\nu) = L(\mathbf{x}^*, \nu) = \frac{1}{2} (\mathbf{A}^T \nu)^T (\mathbf{A}^T \nu) - \nu^T \mathbf{A} \mathbf{A}^T \nu - \nu^T \mathbf{b} = -\frac{1}{2} \nu^T \mathbf{A} \mathbf{A}^T \nu - \mathbf{b}^T \nu.$$

果然是 ν 的凹二次函数 ($\mathbf{A} \mathbf{A}^T$ 行满秩故正定, $-\frac{1}{2} \nu^T \mathbf{A} \mathbf{A}^T \nu$ 凹)。对偶问题 $\max_{\nu} g(\nu)$ 又是一个无约束凸二次极大化, 可一步解出 $\nu^* = -(\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$, 回代即得原问题最优值 $p^* = \frac{1}{2} \mathbf{b}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$ 。这个例子里对偶把一个 n 维带约束问题压成了一个 p 维无约束问题 (通常 $p \ll n$), 还顺手给出了显式解——对偶“降维”的威力可见一斑。

21.3 弱对偶: 永远成立的那道界

对偶函数的每一个值, 都是原问题最优值的一个下界。这件事不需要任何凸性, 对一切优化问题成立——这就是弱对偶。

定理 21.4: 弱对偶

对任意 $\lambda \geq \mathbf{0}$ 与任意 ν , 对偶函数给出原问题最优值的下界:

$$g(\lambda, \nu) \leq p^*.$$

于是对偶问题

$$d^* = \max_{\lambda \geq \mathbf{0}, \nu} g(\lambda, \nu)$$

的最优值满足 $d^* \leq p^*$ 。差额 $p^* - d^* \geq 0$ 称为对偶间隙。

证明. 取任意可行点 $\tilde{\mathbf{x}} \in \mathcal{X}$ (满足 $f_i(\tilde{\mathbf{x}}) \leq 0$ 、 $\mathbf{a}_j^\top \tilde{\mathbf{x}} = b_j$) 与任意 $\boldsymbol{\lambda} \geq \mathbf{0}$ 、 $\boldsymbol{\nu}$ 。逐项看 Lagrangian 在 $\tilde{\mathbf{x}}$ 处的值:

$$L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f_0(\tilde{\mathbf{x}}) + \underbrace{\sum_i \lambda_i f_i(\tilde{\mathbf{x}})}_{\leq 0} + \underbrace{\sum_j \nu_j (\mathbf{a}_j^\top \tilde{\mathbf{x}} - b_j)}_{=0} \leq f_0(\tilde{\mathbf{x}}).$$

两个花括号: 第一项因 $\lambda_i \geq 0$ 且 $f_i(\tilde{\mathbf{x}}) \leq 0$ 故 ≤ 0 ; 第二项因 $\tilde{\mathbf{x}}$ 满足等式约束故 $= 0$ 。再用对偶函数是对所有 $\mathbf{x}$ 取下确界, 自然不超过它在 $\tilde{\mathbf{x}}$ 这一点的值:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) \leq L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f_0(\tilde{\mathbf{x}}).$$

这对每个可行 $\tilde{\mathbf{x}}$ 都成立, 故 $g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq \inf_{\tilde{\mathbf{x}} \in \mathcal{X}} f_0(\tilde{\mathbf{x}}) = p^*$ 。对左边关于 $(\boldsymbol{\lambda}, \boldsymbol{\nu})$ 取上确界即得 $d^* \leq p^*$ 。□

弱对偶的逻辑朴素得令人安心: 两条不等号, 一条来自“约束的罚项不会帮倒忙” ($\lambda_i f_i \leq 0$), 一条来自“inf 不超过任一点的值”。它的实用价值在于廉价取界——随手代入一个 $\boldsymbol{\lambda} \geq \mathbf{0}$, 算出 $g(\boldsymbol{\lambda}, \boldsymbol{\nu})$, 就立刻得到 p^* 的一个可证下界, 无需解出原问题。这在分支定界、组合优化里是核心招数。

对偶间隙: 你离最优还有多远证书

若你手上有一个可行解 $\tilde{\mathbf{x}}$ (给出上界 $f_0(\tilde{\mathbf{x}}) \geq p^*$) 和一组对偶可行的 $(\boldsymbol{\lambda}, \boldsymbol{\nu})$ (给出下界 $g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq p^*$), 那么

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq p^* \leq f_0(\tilde{\mathbf{x}}),$$

于是 $f_0(\tilde{\mathbf{x}}) - g(\boldsymbol{\lambda}, \boldsymbol{\nu})$ 是一个可计算的最优性证书: 它框住了 p^* , 也框住了你当前解 $\tilde{\mathbf{x}}$ 的次优程度。一旦这个间隙缩到零, 你就证明了 $\tilde{\mathbf{x}}$ 是最优的——无需任何额外论证。这正是内点法“原始-对偶”迭代里用来判停的依据。

21.4 强对偶与 Slater 条件

弱对偶恒成立, 但它可能很松 (间隙 > 0)。我们真正想要的是**强对偶**: $d^* = p^*$, 间隙为零, 对偶问题与原问题给出同一个最优值 (图 21.1)。强对偶不会凭空成立——但对凸问题, 一个温和的“内部点”条件就足以保证它。




图 21.1: 弱对偶与强对偶。弱对偶恒成立：对偶界 d^* 永远不超过原问题最优 p^* ，二者可能留有正的对偶间隙（右）。强对偶（凸 + Slater）则把间隙压到零，对偶界恰好顶到原问题最优、两端相接（左）。

定义 21.5: Slater 条件

称凸优化问题满足 **Slater 条件**，如果存在一个严格可行点：某个 $\mathbf{x}$ 使

$$f_i(\mathbf{x}) < 0 \ (i = 1, \dots, m), \quad \mathbf{a}_j^\top \mathbf{x} = b_j \ (j = 1, \dots, p),$$

即所有不等式约束都严格成立（等式约束照常成立）。对仿射的不等式约束，可放宽为非严格成立——这版常称“弱化的 Slater 条件”。

定理 21.6: 强对偶 (Slater)

若原问题为凸且满足 Slater 条件，则**强对偶成立**：

$$d^* = p^*,$$

对偶间隙为零，且只要 p^* 有限，对偶最优值就在某个 (λ^*, ν^*) 处取到。

这条定理的严格证明依赖凸集的**分离超平面定理**（见第十六章），属于本书“只陈述加直觉、不逐行搭”的那一类。下面把直觉讲透，让你能自己重建它的骨架。

强对偶的几何直觉。把原问题的所有“约束取值-目标取值”组合收集成一个集合，画在以约束值为横轴、目标值为纵轴的平面上（这里以单个不等式约束为例）：

$$\mathcal{A} = \{(u, t) : \exists \mathbf{x}, f_1(\mathbf{x}) \leq u, f_0(\mathbf{x}) \leq t\}.$$

$\mathcal{A}$ 是 $\mathbb{R}^2$ 中“向右上方张开”的区域。原问题最优值 p^* 是 $\mathcal{A}$ 与纵轴 ($u = 0$) 相交部分的最低点高度——即“约束恰好满足 ($u \leq 0$) 时目标能压到多低”。

凸性保证 $\mathcal{A}$ 是凸集（这正是用到 f_0, f_1 凸的地方）。于是可以在 $\mathcal{A}$ 的下边界点 $(0, p^*)$ 处放一条**支撑直线**（分离超平面在 $\mathbb{R}^2$ 即直线）：它托在 $\mathcal{A}$ 之下、恰好碰到 $(0, p^*)$ 。这条支撑线的斜率（取负）正对应一个乘子 $\lambda^* \geq 0$ ，而它在 $u = 0$ 处的截距，恰好等于对偶最优值 $g(\lambda^*) = d^*$ 。支撑线碰到 $(0, p^*)$ 这件事，几何上就是 $d^* = p^*$ 。

Slater 条件在哪里登场？它保证 $\mathcal{A}$ 在纵轴左侧（ $u < 0$ ，即严格可行处）有内点，于是过 $(0, p^*)$ 的支撑超平面不会“竖起来”成竖直线——竖直的支撑线对应 $\lambda^* = +\infty$ 那种退化情形，会让对偶取不到、间隙打开。换句话说，Slater 的“内部留有余地”恰好排除了支撑超平面退化，从而保证支撑线斜率有限、对偶最优在有限处取到、间隙归零（图 21.2）。完整证明把这套二维图景升到 $\mathbb{R}^{m+1}$ ，用分离超平面定理把凸集 $\mathcal{A}$ 与一个开半空间分开。□




图 21.2: 强对偶的几何（单不等式约束）。凸集 $\mathcal{A}$ 记录所有可达的“约束值-目标值”组合； p^* 是它在纵轴 $u = 0$ 上的最低高度。过 $(0, p^*)$ 的支撑直线托住 $\mathcal{A}$ ，其纵轴截距即对偶最优 $d^* = g(\lambda^*)$ 。Slater 条件保证 $\mathcal{A}$ 在 $u < 0$ 处有内点，支撑线不致竖直退化，于是截距恰好顶到 p^* ，间隙归零。

注（强对偶不是凸的免费午餐）。

凸 + Slater $\implies$ 强对偶，但凸性本身不够：存在满足凸性却无严格可行点、从而间隙 > 0 的反常例子（典型是某些含 $\exp$ 的二维凸问题，可行域贴着边界、内部为空）。Slater 要的“内部点”正是用来堵住这个漏洞。好在经济学里绝大多数模型自带宽裕的内部（预算线内部、生产集内部非空），Slater 通常自动满足，强对偶可以放心使用。

21.5 鞍点与极小极大

强对偶还有一副更对称、也更适合博弈论直觉的面孔：它等价于 Lagrangian 存在一个**鞍点**，等价于“先 min 后 max”与“先 max 后 min”可以交换次序。

先看一个对任何函数都成立的不等式——它是弱对偶的“裸”版本。

引理 21.7: 极小极大不等式 ($\max\text{--}\min \leq \min\text{--}\max$)

对任意函数 $L(\mathbf{x}, \mathbf{y})$ 与任意定义域, 总有

$$\sup_{\mathbf{y}} \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{y}) \leq \inf_{\mathbf{x}} \sup_{\mathbf{y}} L(\mathbf{x}, \mathbf{y}).$$

证明. 对任意固定的 $\mathbf{x}_0, \mathbf{y}_0$, 显然 $\inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{y}_0) \leq L(\mathbf{x}_0, \mathbf{y}_0) \leq \sup_{\mathbf{y}} L(\mathbf{x}_0, \mathbf{y})$. 左端只依赖 $\mathbf{y}_0$ 、右端只依赖 $\mathbf{x}_0$. 对左端关于 $\mathbf{y}_0$ 取上确界、对右端关于 $\mathbf{x}_0$ 取下确界, 不等号方向不变, 即得。一句话: “先承诺者吃亏”——后行动的一方总能针对性地占便宜, 所以 $\max$ 在内 (后动) 不弱于 $\max$ 在外 (先动)。□

把这条引理用到 Lagrangian 上, 就认出了原问题与对偶问题。关键观察: 对 Lagrangian 先对乘子取上确界, 恰好“复原”出原问题——

$$\sup_{\lambda \geq 0, \nu} L(\mathbf{x}, \lambda, \nu) = \begin{cases} f_0(\mathbf{x}), & \mathbf{x} \text{ 可行}, \\ +\infty, & \mathbf{x} \text{ 不可行}. \end{cases}$$

道理是: 若 $\mathbf{x}$ 违反某条约束 ($f_i(\mathbf{x}) > 0$, 或等式不成立), 把对应乘子取到 $+\infty$ 即可把 $\sup$ 顶到 $+\infty$; 若 $\mathbf{x}$ 可行, 则罚项最优地取 0, 剩下 $f_0(\mathbf{x})$ 。于是

$$\underbrace{\inf_{\mathbf{x}} \sup_{\lambda \geq 0, \nu} L}_{= p^* \text{ (原问题)}} \geq \underbrace{\sup_{\lambda \geq 0, \nu} \inf_{\mathbf{x}} L}_{= d^* \text{ (对偶问题)}}.$$

原问题 = “先 $\min$ 后 $\max$ ”, 对偶问题 = “先 $\max$ 后 $\min$ ”; 二者的差 $p^* - d^*$ 就是极小极大不等式里的间隙, 也就是对偶间隙。强对偶 $d^* = p^*$ 于是等价于这两个次序可交换。而次序可交换, 又等价于 L 有鞍点:

定义 21.8: 鞍点

称 $(\mathbf{x}^*, \lambda^*, \nu^*)$ ($\lambda^* \geq 0$) 是 Lagrangian 的鞍点, 如果它对 $\mathbf{x}$ 是极小、对 (λ, ν) 是极大, 即对一切 $\mathbf{x}$ 与一切 $\lambda \geq 0, \nu$,

$$L(\mathbf{x}^*, \lambda, \nu) \leq L(\mathbf{x}^*, \lambda^*, \nu^*) \leq L(\mathbf{x}, \lambda^*, \nu^*).$$

鞍点的形状如其名: 沿 $\mathbf{x}$ 方向是谷底 (往上翘), 沿 λ 方向是峰顶 (往下垂), 像一副马鞍 (图 21.3)。在鞍点处, 谁先动都不吃亏—— $\min$ 与 $\max$ 可以交换。

定理 21.9: 鞍点 $\iff$ 强对偶且最优在两端取到

$(\mathbf{x}^*, \lambda^*, \nu^*)$ 是 L 的鞍点, 当且仅当 $\mathbf{x}^*$ 是原问题最优解、 (λ^*, ν^*) 是对偶问题最优解, 且强对偶成立 ($p^* = d^* = L(\mathbf{x}^*, \lambda^*, \nu^*)$)。




图 21.3: Lagrangian 在鞍点处的几何。沿原变量 x 方向是谷底 (取极小), 沿乘子 λ 方向是峰顶 (取极大), 形如马鞍。强对偶成立当且仅当这样的鞍点存在——此时“先 min 后 max”与“先 max 后 min”给出同一个值。

证明. ($\Rightarrow$) 设鞍点存在。鞍点不等式右半 $L(x^*, \lambda^*, \nu^*) \leq L(x, \lambda^*, \nu^*)$ 对一切 x 成立, 说明 x^* 极小化 $L(\cdot, \lambda^*, \nu^*)$, 故 $g(\lambda^*, \nu^*) = L(x^*, \lambda^*, \nu^*)$ 。左半 $L(x^*, \lambda, \nu) \leq L(x^*, \lambda^*, \nu^*)$ 对一切 $\lambda \geq 0, \nu$ 成立, 说明 (λ^*, ν^*) 极大化 $L(x^*, \cdot)$, 即 $\sup_{\lambda \geq 0, \nu} L(x^*, \cdot) = L(x^*, \lambda^*, \nu^*)$ ——而我们刚算过这个 sup 等于 $f_0(x^*)$ (且强制 x^* 可行)。串起来:

$$g(\lambda^*, \nu^*) = L(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

左端 $\leq d^* \leq p^* \leq$ 右端 (弱对偶), 而两端相等, 故全链相等: $d^* = p^*$, 且 $x^*, (\lambda^*, \nu^*)$ 分别是原、对偶最优。

($\Leftarrow$) 反过来, 若 $x^*, (\lambda^*, \nu^*)$ 各为最优且 $p^* = d^*$, 则 $f_0(x^*) = g(\lambda^*, \nu^*) = \inf_x L(x, \lambda^*, \nu^*) \leq L(x^*, \lambda^*, \nu^*)$ 。但又 $L(x^*, \lambda^*, \nu^*) = f_0(x^*) + \sum_i \lambda_i^* f_i(x^*) \leq f_0(x^*)$ (罚项 ≤ 0)。两个不等式夹出等号, 逼出 $\sum_i \lambda_i^* f_i(x^*) = 0$ (即互补松弛: $\lambda_i^* f_i(x^*) = 0$ 逐项成立) 与 x^* 极小化 $L(\cdot, \lambda^*, \nu^*)$, 恰好凑齐鞍点两条不等式。□

对偶的三种等价说法, 与影子价格

对凸问题 (Slater 下), 下面三件事是同一件事:

- 强对偶: $p^* = d^*$, 对偶间隙为零;
- 鞍点: Lagrangian 有鞍点 (x^*, λ^*, ν^*) ;
- 极小极大可交换: $\inf_x \sup_{\lambda, \nu} L = \sup_{\lambda, \nu} \inf_x L$ 。

而最优乘子 λ^* 不只是个证书。它正是约束的影子价格: 把第 i 条约束的右端从 0 松动到 u_i , 最优值的变化率恰是 $-\lambda_i^*$ (这是下一章包络定理给出的灵敏度, 对

偶在此与包络合流)。鞍点不等式里隐含的互补松弛 $\lambda_i^* f_i(\mathbf{x}^*) = 0$ 则说：约束不紧 ($f_i < 0$) 时影子价格为零，约束一文不值；只有顶着约束 ($f_i = 0$) 的资源才标得出正价。这把抽象的乘子翻译成了经济学最熟悉的语言——**稀缺才有价**。

21.6 它通向何处

对偶不是一个孤立的技巧，而是一种贯穿经济学与统计学的结构。把去处标清，方便日后回查。

- **成本函数与支出函数的对偶**。生产理论里，“给定产量最小化成本”与“给定成本最大化产量”互为对偶；消费者理论里马歇尔需求（效用最大化）与希克斯需求（支出最小化）互为对偶。由此得到的成本/支出函数对价格的导数即要素需求（Shephard 引理）、即希克斯需求——而这恰是**包络定理**（下一章）的内容：对偶给出“谁是影子价格”，包络给出“值函数对参数的导数就是最优乘子”。两章合起来才是完整的“对偶 + 灵敏度”工具。
- **线性规划与资源配置**。线性规划是凸优化里最干净的特例，强对偶（在可行时）无条件成立。一家厂商在资源约束下最大化产值，其对偶恰是给每种资源定一个内部影子价、使总资源估值最小——原始问的是“怎么用”，对偶问的是“值多少”。线性规划对偶因此是“资源的边际价值”最纯粹的数学表达，活跃在运筹、拍卖与一般均衡定价里。
- **最优传输与匹配**。“如何以最小总成本把一堆供给运到一堆需求”（Monge–Kantorovich 问题）是个大型线性/凸规划，它的对偶（Kantorovich 对偶）给每个产地、每个销地各派一个“价格”，把运输问题翻译成定价问题。这套对偶是匹配市场、稳定匹配定价、以及近年计量里“可识别的转移效用模型”的数学内核。
- **机器学习**。支持向量机（SVM）的原始问题是带间隔约束的凸二次规划，其对偶只依赖样本两两内积，从而打开了“核技巧”的大门；岭回归、Lasso 等正则化问题的对偶给出对偶范数与稀疏性的几何刻画。机器学习里“原始–对偶”几乎是标准词汇。
- **稳健与最坏情形优化**。“在最坏的参数实现下做到最好”天然是一个 $\min_{\mathbf{x}} \max_{\theta}$ 的极小极大问题；本章的鞍点理论给出它何时等于 $\max_{\theta} \min_{\mathbf{x}}$ 、何时存在稳健最优解。这正是稳健控制、分布稳健优化、以及对抗式学习的理论起点，也与博弈论里“混合策略均衡 = 双人零和博弈的鞍点”（von Neumann 极小极大定理）一脉相承。

一句话记住对偶

原问题在“初始变量”上做决策，对偶问题在“约束的价格”上做决策；弱对偶说价格永远给出一个保守的界，强对偶（凸 + Slater）说在最优处这个界严丝合缝、价格变成真实的影子价格。**凡是看到“资源/约束”与“价格/估值”成对出现的经济模型，背后多半就是一对原–对偶问题**。学会在两侧切换，等于同时握

住了“怎么配”与“值多少”这两半答案。

第二十二章 值函数与包络定理

用到的前置工具：偏导数、梯度与链式法则（多元微分一章，第十三章）；最优化的一阶条件（无约束最优化一章，第十八章）；Lagrange 乘子（等式约束与 Lagrange 乘子一章，第十九章）；隐函数定理（隐函数定理一章，第十五章）。

上一把镇店之宝——隐函数定理——回答的是“参数动一下，最优选择如何变”。但经济学家追问的另一半问题往往是：参数动一下，最优值如何变？厂商的利润随某种要素涨价掉多少？消费者的最大效用随收入升多少？一国的最优福利随某项政策参数移多少？这些问题的答案，原则上要先把最优选择 $\mathbf{x}^*(\boldsymbol{\theta})$ 解出来、代回目标、再对参数求导——一条又长又绕的链。包络定理给出的捷径几乎令人难以置信：在最优点处，那条长链里所有“经由最优选择变动”的项统统消失，只剩下目标函数对参数的直接偏导。本章先把值函数这个对象立起来，再把包络定理（无约束与约束两种情形）连同它出人意料的简洁直觉讲清楚，最后说明它如何一举生出微观里的 Shephard 引理、Roy 恒等式、Hotelling 引理，以及动态规划里对 Bellman 值函数求导的 Benveniste-Scheinkman 公式。

22.1 值函数：把“最优值”看成参数的函数

先把对象定清楚。一个带参数的最优化问题，除了交出最优选择，还交出一个最优值；把这个最优值看成参数的函数，就是值函数。

定义 22.1: 值函数与最优解

设目标函数 $f: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ ， $\mathbf{x} \in \mathbb{R}^n$ 是选择变量、 $\boldsymbol{\theta} \in \mathbb{R}^m$ 是参数。对每个 $\boldsymbol{\theta}$ 考虑

$$v(\boldsymbol{\theta}) = \max_{\mathbf{x}} f(\mathbf{x}, \boldsymbol{\theta}), \quad \mathbf{x}^*(\boldsymbol{\theta}) = \arg \max_{\mathbf{x}} f(\mathbf{x}, \boldsymbol{\theta}).$$

称 v 为该问题的值函数（value function）， $\mathbf{x}^*$ 为最优解（argmax）。二者由同一个恒等式相连：

$$v(\boldsymbol{\theta}) = f(\mathbf{x}^*(\boldsymbol{\theta}), \boldsymbol{\theta}).$$

这条恒等式是全章的支点。它说：值函数等于把最优选择代回目标函数后得到的复合函数。 $\boldsymbol{\theta}$ 通过两条路影响 v ——一条直接走（ $\boldsymbol{\theta}$ 作为 f 的第二组自变量），一条间接走（ $\boldsymbol{\theta}$ 先动了最优选择 $\mathbf{x}^*$ ， $\mathbf{x}^*$ 再进 f ）。要算 $\frac{dv}{d\boldsymbol{\theta}}$ ，朴素的想法是把这两条路的贡献都算上。包络定理的全部惊奇，正在于间接那条路的贡献恰好为零。

注 (取 $\min$ 与带约束的情形同理)。

若问题是 $\min$ ，把下文一切 $\max$ 换成 $\min$ 、“峰顶”换成“谷底”，结论一字不改（一阶条件仍是 $\nabla_{\mathbf{x}} f = \mathbf{0}$ ）。带约束的情形 ($\max_{\mathbf{x}} f$ s.t. $\mathbf{g}(\mathbf{x}, \boldsymbol{\theta}) = \mathbf{c}$) 放到第 22.3 节，用 Lagrangian 处理，结论形式完全平行。本章默认最优解是内点且可微地依赖于 $\boldsymbol{\theta}$ ——后者正由隐函数定理（隐函数定理一章，第十五章）在二阶条件下保证：Hessian 负定 $\Rightarrow \mathbf{x}^*(\boldsymbol{\theta})$ 存在且 C^1 。

22.2 包络定理（无约束）

定理 22.2: 包络定理（无约束）

设 $f(\mathbf{x}, \boldsymbol{\theta})$ 连续可微，对每个 $\boldsymbol{\theta}$ 内点最优解 $\mathbf{x}^*(\boldsymbol{\theta})$ 存在、满足一阶条件 $\nabla_{\mathbf{x}} f(\mathbf{x}^*, \boldsymbol{\theta}) = \mathbf{0}$ ，且 $\mathbf{x}^*(\cdot)$ 可微。则值函数 $v(\boldsymbol{\theta}) = f(\mathbf{x}^*(\boldsymbol{\theta}), \boldsymbol{\theta})$ 可微，且

$$\frac{\partial v}{\partial \theta_k}(\boldsymbol{\theta}) = \frac{\partial f}{\partial \theta_k}(\mathbf{x}^*(\boldsymbol{\theta}), \boldsymbol{\theta}), \quad k = 1, \dots, m.$$

即：先对参数求偏导，再在最优点取值——求导时把 $\mathbf{x}$ 当作不随 $\boldsymbol{\theta}$ 变的常数。

证明. 直接对支点恒等式 $v(\boldsymbol{\theta}) = f(\mathbf{x}^*(\boldsymbol{\theta}), \boldsymbol{\theta})$ 求 $\partial/\partial\theta_k$ ，用多元链式法则。 θ_k 影响 f 的两条路（经由各 x_i^* 的间接路，与作为第 k 个参数的直接路）都要算上：

$$\frac{\partial v}{\partial \theta_k} = \underbrace{\sum_{i=1}^n \frac{\partial f}{\partial x_i}(\mathbf{x}^*, \boldsymbol{\theta}) \frac{\partial x_i^*}{\partial \theta_k}}_{\text{间接：经由最优选择变动}} + \underbrace{\frac{\partial f}{\partial \theta_k}(\mathbf{x}^*, \boldsymbol{\theta})}_{\text{直接}}.$$

现在动用一阶条件。在最优点， $\nabla_{\mathbf{x}} f(\mathbf{x}^*, \boldsymbol{\theta}) = \mathbf{0}$ ，即每一个 $\partial f/\partial x_i(\mathbf{x}^*, \boldsymbol{\theta}) = 0$ 。于是间接项里的求和逐项为零：

$$\sum_{i=1}^n \underbrace{\frac{\partial f}{\partial x_i}(\mathbf{x}^*, \boldsymbol{\theta})}_{=0} \frac{\partial x_i^*}{\partial \theta_k} = 0.$$

间接路整条消失，只剩直接项，即得 $\partial v/\partial \theta_k = \partial f/\partial \theta_k(\mathbf{x}^*, \boldsymbol{\theta})$ 。□

证明短得几乎像变戏法，但它给的东西极实在：要算最优值对参数的导数，你不必知道 $\mathbf{x}^*(\boldsymbol{\theta})$ 怎么随 $\boldsymbol{\theta}$ 变（即不必算那些麻烦的 $\partial x_i^*/\partial \theta_k$ ），也不必求出 $\mathbf{x}^*(\boldsymbol{\theta})$ 的显式表达——只要知道最优点的位置 $\mathbf{x}^*$ ，把它代进 $\partial f/\partial \theta_k$ 即可。

包络定理：在最优点，间接效应为零

$\frac{dv}{d\boldsymbol{\theta}}$ 表面上有两块：参数直接进目标的那块，与参数先动最优选择、最优选择再进目标的那块。在最优点，后一块恒等于零，因为最优选择已使目标对每个选择

变量的边际贡献归零（一阶条件）。所以

$$\frac{\partial v}{\partial \theta_k} = \left. \frac{\partial f}{\partial \theta_k} \right|_{\mathbf{x}=\mathbf{x}^*} \quad (\text{对 } \mathbf{x} \text{ 视作常数求偏导, 再代入 } \mathbf{x}^*).$$

一句话：已经站在山顶，脚下微调走位不改高度——值的变化全由“地形随参数整体抬升”贡献。这正是把一条繁琐的链式求导塌缩成一个偏导的根据。

为什么间接效应为零：一张图

间接效应消失，靠的是一个极朴素的几何事实：光滑函数在峰顶的切线是水平的。把 θ 固定， $f(\cdot, \theta)$ 作为选择变量 x 的函数在最优点 x^* 取得峰值，于是该点的切平面水平、梯度为零。这意味着：在峰顶附近挪动选择变量，目标值的变化是二阶的（正比于位移的平方），一阶项为零（图 22.1）。参数变动 $d\theta$ 把最优选择推动了 $dx^* = O(d\theta)$ ，可这点位移落在“峰顶水平”的区域里，对值的贡献只有 $O((dx^*)^2) = O((d\theta)^2)$ ——在一阶导数里看不见。能被一阶导数捕捉到的，唯有目标地形随参数的直接抬升。




图 22.1: 为什么间接效应为零。固定 θ ，目标 $f(\cdot, \theta)$ 在最优点 x^* 处峰顶切线水平 ($\partial f / \partial x = 0$)。把选择变量挪动 Δx ，值的下降只有 $\sim (\Delta x)^2$ ——二阶小量，一阶导数看不见。于是参数推动最优选择所带来的“间接”贡献在 $dv/d\theta$ 里消失。

例（用包络定理算利润对成本的导数）。

厂商面对产品价格 p (暂固定)，单位成本为参数 c ，产量 q 为选择变量，利润 $\pi(q, c) = pq - \frac{1}{2}bq^2 - cq$ ($b > 0$ ，二次成本使内点解存在)。问最大利润 $v(c) = \max_q \pi(q, c)$ 对 c 的导数。

解。

包络法。直接对 c 求 π 的偏导、把 q 当常数：

$$\frac{\partial \pi}{\partial c} = -q \implies \frac{dv}{dc} = \left. \frac{\partial \pi}{\partial c} \right|_{q=q^*} = -q^*(c).$$

最大利润对单位成本的导数，恰等于当前最优产量的相反数——成本每涨一块钱，最优利润下降的速率正好是你此刻在产的数量。

硬算法对照。一阶条件 $\partial \pi / \partial q = p - bq - c = 0$ 给 $q^*(c) = (p - c)/b$ ，代回得 $v(c) = \frac{(p-c)^2}{2b}$ ，于是 $\frac{dv}{dc} = -\frac{p-c}{b} = -q^*(c)$ 。两法一致。注意硬算法要先解出 q^* 、平方、再求导，包络法一步到位且根本不需要 q^* 的显式公式——这正是其价值：当一阶条件无法解析求解时， $\frac{dv}{dc} = -q^*$ 依然成立。

值函数是一族曲线的上包络——“包络”之名的由来

定理叫“包络”，因为值函数在几何上正是一族曲线的**上包络**。把每一个固定的选择 x 看成一条曲线 $\theta \mapsto f(x, \theta)$ （不同的 x 给不同的曲线）。在每个 θ 处，值函数挑出这一族曲线里最高的那条的高度： $v(\theta) = \max_x f(x, \theta)$ 。于是 v 的图像从上方“罩住”整族曲线，并恰好在每一点与“当前最优”那条相切（图 22.2）。相切，正是包络定理的几何化身——在切点处， v 与那条 $f(x^*, \cdot)$ 不仅取值相等，斜率也相等，而后者的斜率就是 $\partial f / \partial \theta$ （对固定的 x^* 沿 θ 求导）。




图 22.2: 值函数 $v(\theta) = \max_x f(x, \theta)$ 是一族曲线 $\{\theta \mapsto f(x, \theta)\}_x$ （每个固定的 x 一条）的**上包络**。在每个 θ 处， v 恰与达到它的那条相切（图中三个切点）——切点处取值与斜率都相同，而那条曲线的斜率正是 $\partial f / \partial \theta$ 。这就是“包络”之名与包络定理 $\partial v / \partial \theta = \partial f / \partial \theta|_{x^*}$ 的几何来源。

上包络这个视角还顺带说明了 v 的一条凸性：一族关于 θ 凸（或仿射）的函数取逐点上确界，结果仍凸（见“凸优化与对偶”一章，第二十一章，“上确界保持凸性”）。所以若 $f(x, \cdot)$ 对每个固定 x 是 θ 的凸函数，则 v 必凸——利润函数对价格凸、成本函数对要素价格凹，根都在这里。

22.3 约束情形：包络定理与 Lagrange 乘子

经济学里的最优化大多带约束（预算、技术、资源）。所幸包络定理对约束问题有一个同样干净版本，代价只是把“目标函数”换成“Lagrangian”。设

$$v(\theta) = \max_{\mathbf{x}} f(\mathbf{x}, \theta) \quad \text{s.t.} \quad \mathbf{g}(\mathbf{x}, \theta) = \mathbf{c},$$

其中约束有 ℓ 条， $\mathbf{g} : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^\ell$ ， $\mathbf{c} \in \mathbb{R}^\ell$ 是约束水平。引入 Lagrange 乘子 $\boldsymbol{\lambda} \in \mathbb{R}^\ell$ 与 Lagrangian

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \theta) = f(\mathbf{x}, \theta) + \boldsymbol{\lambda}^\top (\mathbf{c} - \mathbf{g}(\mathbf{x}, \theta)).$$

内点最优解 $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ 满足一阶条件（见“等式约束与 Lagrange 乘子”一章，第十九章）

$$\nabla_{\mathbf{x}} \mathcal{L} = \nabla_{\mathbf{x}} f - \sum_j \lambda_j^* \nabla_{\mathbf{x}} g_j = \mathbf{0}, \quad \mathbf{g}(\mathbf{x}^*, \theta) = \mathbf{c}.$$

定理 22.3: 包络定理（约束情形）

在上述设定下，若 $(\mathbf{x}^*(\theta), \boldsymbol{\lambda}^*(\theta))$ 可微，则值函数对参数的导数等于 Lagrangian 对该参数的偏导、在最优点 $(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ 取值：

$$\frac{\partial v}{\partial \theta_k} = \frac{\partial \mathcal{L}}{\partial \theta_k}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \theta) = \frac{\partial f}{\partial \theta_k} - \sum_{j=1}^{\ell} \lambda_j^* \frac{\partial g_j}{\partial \theta_k} \quad (\text{在 } \mathbf{x} = \mathbf{x}^* \text{ 处}).$$

特别地，对约束水平 c_j 求导（取 $\theta_k = c_j$ ，注意 $\partial \mathcal{L} / \partial c_j = \lambda_j$ ）：

$$\frac{\partial v}{\partial c_j} = \lambda_j^*.$$

证明. 关键观察：在最优点，约束束紧， $\mathbf{g}(\mathbf{x}^*(\theta), \theta) = \mathbf{c}$ ，于是括号 $\mathbf{c} - \mathbf{g}(\mathbf{x}^*, \theta) = \mathbf{0}$ ，因此

$$v(\theta) = f(\mathbf{x}^*, \theta) = \mathcal{L}(\mathbf{x}^*(\theta), \boldsymbol{\lambda}^*(\theta), \theta).$$

也就是说，沿最优路径，值函数与 Lagrangian 取值相同——那一项乘子乘约束余量恒为零。现在对右边求 $\partial / \partial \theta_k$ ，把 $\mathbf{x}^*, \boldsymbol{\lambda}^*$ 都看成 θ 的函数，用链式法则：

$$\frac{\partial v}{\partial \theta_k} = \underbrace{\nabla_{\mathbf{x}} \mathcal{L} \cdot \frac{\partial \mathbf{x}^*}{\partial \theta_k}}_{(A)} + \underbrace{\nabla_{\boldsymbol{\lambda}} \mathcal{L} \cdot \frac{\partial \boldsymbol{\lambda}^*}{\partial \theta_k}}_{(B)} + \frac{\partial \mathcal{L}}{\partial \theta_k}.$$

两块间接项都死掉：(A) 因为 $\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0}$ （对 $\mathbf{x}$ 的一阶条件）；(B) 因为 $\nabla_{\boldsymbol{\lambda}} \mathcal{L} = \mathbf{c} - \mathbf{g}(\mathbf{x}^*, \theta) = \mathbf{0}$ （约束本身）。于是只剩直接项 $\partial \mathcal{L} / \partial \theta_k$ ，即所证。取 $\theta_k = c_j$ 时 $\partial \mathcal{L} / \partial c_j = \lambda_j$ ，得 $\partial v / \partial c_j = \lambda_j^*$ 。□

约束版与无约束版是同一个故事：把目标换成 Lagrangian，间接效应照样在最优

点逐项归零——只是这次要归零的有两组一阶条件（对 $\mathbf{x}$ 的与对 λ 的，后者即约束）。

Lagrange 乘子 = 约束放松一单位的“影子价格”

$\partial v / \partial c_j = \lambda_j^*$ 给乘子赋予了它最重要的经济含义：第 j 条约束的乘子，等于把该约束的水平 c_j 放松一个单位时最优值的增量。乘子不是求解过程里顺手冒出来的代数辅助量，它本身就是一个有价格量纲的边际估值——影子价格（shadow price）。在消费者问题里，预算约束的乘子是“收入的边际效用”（多一块钱能多买到多少效用）；在生产计划里，某种资源约束的乘子是“这种资源的内部估值”（多一单位该资源能多赚多少），它告诉你该出多高的价去购买、或该向哪条紧约束倾斜投资。这条等式是“对偶”思想的源头之一（见“凸优化与对偶”一章，第二十一章）。

例（预算的边际效用）。

消费者求 $v(m) = \max_{\mathbf{x}} u(\mathbf{x})$ s.t. $\mathbf{p} \cdot \mathbf{x} = m$, $\mathbf{p}$ 给定、收入 m 是参数。说明 $\frac{dv}{dm} = \lambda^*$ 的含义，并在 Cobb-Douglas $u = x_1^a x_2^{1-a}$ 下验证。

解。

这里约束水平就是收入 m ，由约束版包络定理直接得 $\frac{dv}{dm} = \lambda^*$ ：间接效用对收入的导数等于乘子，即收入的边际效用——多一块钱能换来的最大效用增量。

验证：Lagrangian $\mathcal{L} = x_1^a x_2^{1-a} + \lambda(m - p_1 x_1 - p_2 x_2)$ 。一阶条件给需求 $x_1^* = \frac{am}{p_1}$ 、 $x_2^* = \frac{(1-a)m}{p_2}$ ，且

$$\lambda^* = \frac{\partial u}{\partial x_1} / p_1 = \frac{a x_2^{1-a}}{x_1^{1-a} p_1} = a^a (1-a)^{1-a} p_1^{-a} p_2^{-(1-a)}.$$

另一方面，把需求代回得间接效用 $v(m) = a^a (1-a)^{1-a} p_1^{-a} p_2^{-(1-a)} m$ ，它对 m 是线性的，斜率恰为 $\frac{dv}{dm} = a^a (1-a)^{1-a} p_1^{-a} p_2^{-(1-a)} = \lambda^*$ 。两者吻合。（间接效用对收入线性，是 Cobb-Douglas 这一“位似偏好”特例的体现：恩格尔曲线为过原点直线，见“齐次函数与欧拉定理”一章，第十七章。）

22.4 去处一：Shephard 引理、Roy 恒等式、Hotelling 引理

包络定理在微观里最高产的去处，是把一连串“某个最优值函数对某个价格求导，等于某个最优数量”的恒等式一网打尽。它们看似各自独立、在课本里分散出现，其实是同一条包络定理换不同的目标函数与参数而已。下表先给全景，再逐条落实。

名称	值函数	对谁求导	得到
Shephard 引理	成本 $C(\mathbf{w}, y)$	要素价格 w_i	条件要素需求 x_i^*
Hotelling 引理	利润 $\Pi(p, \mathbf{w})$	产品价格 p	供给 y^*
Roy 恒等式	间接效用 $V(\mathbf{p}, m)$	价格 p_i 、收入 m	马歇尔需求 x_i^*

表 22.1: 包络定理的三个“引理”：换一个最优化问题、换一个被求导的价格，就换出一条“值函数的导数 = 最优数量”的恒等式。

Shephard 引理

厂商在给定产量 y 下求最小成本：要素价格 $\mathbf{w}$ ，要素投入 $\mathbf{x}$ ，

$$C(\mathbf{w}, y) = \min_{\mathbf{x}} \mathbf{w} \cdot \mathbf{x} \quad \text{s.t.} \quad F(\mathbf{x}) = y,$$

最优投入 $\mathbf{x}^*(\mathbf{w}, y)$ 称**条件要素需求** (conditional factor demand)。这是个带约束的问题，本该走约束版：Lagrangian 是 $\mathcal{L} = \mathbf{w} \cdot \mathbf{x} - \mu(F(\mathbf{x}) - y)$ ，而要素价格 w_i 只直接进入目标（系数恰是 x_i ）、不进约束 $F(\mathbf{x}) = y$ 。于是 $\partial \mathcal{L} / \partial w_i = \partial(\mathbf{w} \cdot \mathbf{x}) / \partial w_i = x_i$ ，约束版那条“ $-\sum_j \lambda_j \partial g_j / \partial w_i$ ”的修正项整块为零——约束版在此退化成与无约束版一模一样的形式。换句话说，这里用的依旧是约束版包络定理（成本是带约束 min），只是因为 w_i 不进约束，那个含乘子的修正项恰好消失，公式表面上看起来才与无约束版无异。于是对 w_i 求导、把 $\mathbf{x}$ 当常数：

$$\frac{\partial C}{\partial w_i}(\mathbf{w}, y) = x_i^*(\mathbf{w}, y) \quad (\text{Shephard 引理}).$$

Shephard 引理：成本对要素价格求导 = 条件要素需求

成本函数对第 i 种要素价格的偏导，就是该要素的条件需求量。直觉一句话：第 i 种要素涨价 dw_i ，成本首当其冲的上升是“你正用着的那 x_i^* 单位 $\times dw_i$ ”；至于涨价后你会重新调整要素配比以省钱——那是“沿等产量线挪动选择”的间接效应，而它在最优点是二阶的，对成本的一阶导数没有贡献。于是从一个估出来的成本函数，求一次导就读出全部要素需求，无须再解最优化——这是实证产业组织里需求系统估计的支柱。

Hotelling 引理

厂商求最大利润：产品价格 p 、要素价格 $\mathbf{w}$ 、产量 y 、投入 $\mathbf{x}$ ，

$$\Pi(p, \mathbf{w}) = \max_{y, \mathbf{x}} [p y - \mathbf{w} \cdot \mathbf{x}] \quad \text{s.t.} \quad F(\mathbf{x}) = y.$$

价格 p 只直接进目标（系数是 y ）， w_i 只直接进目标（系数是 $-x_i$ ）。对利润函数用包络定理：

$$\boxed{\frac{\partial \Pi}{\partial p} = y^*(p, w)}, \quad \boxed{\frac{\partial \Pi}{\partial w_i} = -x_i^*(p, w)} \quad (\text{Hotelling 引理}),$$

即利润对产品价格求导得供给、对要素价格求导得要素需求的相反数。

Roy 恒等式

消费者的间接效用 $V(p, m) = \max_{\mathbf{x}} u(\mathbf{x})$ s.t. $\mathbf{p} \cdot \mathbf{x} = m$ 。这次价格 p_i 不在目标 u 里、而在约束里，所以要走约束版包络定理（用 Lagrangian $\mathcal{L} = u(\mathbf{x}) + \lambda(m - \mathbf{p} \cdot \mathbf{x})$ ）。对 p_i 与对 m 分别求导：

$$\frac{\partial V}{\partial p_i} = \left. \frac{\partial \mathcal{L}}{\partial p_i} \right|_* = -\lambda^* x_i^*, \quad \frac{\partial V}{\partial m} = \left. \frac{\partial \mathcal{L}}{\partial m} \right|_* = \lambda^*.$$

两式相除消去那个不易直接观测的乘子 λ^* ，得

$$\boxed{x_i^*(p, m) = -\frac{\partial V / \partial p_i}{\partial V / \partial m}} \quad (\text{Roy 恒等式}).$$

为什么三条引理是“一件事”

Shephard、Hotelling、Roy 不是三个需要分别背诵的公式，而是同一条包络定理的三次应用：每次都是“最优值函数对某个价格求导 = 相应的最优数量”。差别只在于这个价格是直接进目标（Shephard 的 w_i 、Hotelling 的 p, w_i ，用无约束版）还是经由约束进（Roy 的 p_i ，用约束版、再除掉乘子）。认出这一点，你就不必把它们当三件孤立的工具记，而是记一条母定理、外加“价格在目标里还是在约束里”这个二选一。这也正是“对偶”（primal-dual）在消费者与厂商理论里反复出现的根：值函数（成本/利润/间接效用）与最优数量（要素需求/供给/马歇尔需求）互为导数关系。

22.5 去处二：动态规划的 Benveniste–Scheinkman 公式

包络定理的另一大主场在动态最优化。递归形式的动态规划把整个跨期问题压成一个 Bellman 方程（见“压缩映射与 Banach 不动点”一章，第十二章，建立其存在唯一）：

$$V(s) = \max_{a \in \Gamma(s)} [r(s, a) + \beta V(\phi(s, a))],$$

状态 s 、行动 a 、当期收益 r 、折现因子 β 、状态转移 $s' = \phi(s, a)$ 。要做欧拉方程、要刻画最优策略的性质，常常需要 $V'(s)$ ——可 V 本身只是“由一个最大化定义”的对象，根本没有显式表达式。这恰是包络定理大显身手之处。

把状态 s 当参数、行动 a 当选择变量。在内点最优行动 $a^*(s)$ 处，对 a 的一阶条件成立，于是对值函数恒等式 $V(s) = r(s, a^*(s)) + \beta V(\phi(s, a^*(s)))$ 求 $\frac{d}{ds}$ 时，所有经由 $a^*(s)$ 的间接项被一阶条件消去，只剩 s 的直接通道：

定理 22.4: Benveniste–Scheinkman

在上述递归问题中，若 $a^*(s)$ 为内点最优、 V 可微，则

$$\begin{aligned} V'(s) &= \frac{\partial}{\partial s} \left[r(s, a) + \beta V(\phi(s, a)) \right]_{a=a^*(s)} \\ &= r_s(s, a^*) + \beta V'(\phi(s, a^*)) \phi_s(s, a^*) \end{aligned}$$

对 s 求导时，把最优行动 a^* 当作常数。

证明. 对 $V(s) = r(s, a^*(s)) + \beta V(\phi(s, a^*(s)))$ 求 $\frac{d}{ds}$ ，链式法则给出对 s 的直接项加上经由 $a^*(s)$ 的间接项：

$$V'(s) = \underbrace{r_s + \beta V'(\phi) \phi_s}_{\text{直接}} + \underbrace{[r_a + \beta V'(\phi) \phi_a]}_{=0(\text{对 } a \text{ 的一阶条件})} \frac{da^*}{ds}.$$

方括号里恰是内点最优对 a 的一阶条件 $\partial/\partial a [r + \beta V(\phi)] = 0$ ，故间接项为零，余下直接项即所证。□

Benveniste–Scheinkman 让“对值函数求导”变得合法可算

动态规划里反复要用 $V'(s)$ （边际值函数），却没有 V 的显式式子。这条公式说：尽管放心地把 Bellman 方程右边对状态 s 求导，并把最优行动 a^* 当常数——间接项自动归零。它把“对一个隐式定义的值函数求导”这件看似没把握的事，变成一次直接的偏导。最干净的一个特例是状态“只进收益、不进转移”的情形：若 $r = r(s, a)$ 、转移 ϕ 不显含 s ，则 $V'(s) = r_s(s, a^*)$ ——边际值函数等于当期收益对状态的边际，立刻可代进欧拉方程。这是递归宏观（最优增长、实际经济周期、资产定价）做一阶分析的标准入口。

可微性本身需要一点小心：Bellman 方程的解 V 未必处处可微（max 运算可能造成折点）。Benveniste 与 Scheinkman (1979) 的原始贡献正是给出 V 在最优内点处可微的充分条件（大意是：能找到一个可微函数从下方相切于 V ）。在本书的工具性立场上，记住结论与适用条件即可——一旦 V 在该点可微，导数就由上面这条公式给出。

22.6 小结：选择之导与值之导，配成一对

把本章与隐函数定理一章（第十五章）并看，比较静态的两半正好拼齐：

- 隐函数定理回答“最优选择如何随参数变”： $D_{\theta} x^* = -H^{-1} \nabla_{x\theta}^2 f$ 。它要算 Hessian 的逆，较费力，给的是选择的移动。

- **包络定理**回答“最优值如何随参数变”： $\partial v / \partial \theta_k = \partial f / \partial \theta_k |_{\mathbf{x}^*}$ 。它不必知道选择如何移动，一个直接偏导即可，给的是值的移动。

二者常常配套登场：要刻画一个政策对福利的边际影响（值），用包络；要追踪它对行为的扭曲（选择），用隐函数定理。本章的核心机制——在最优点，经由最优选择变动的间接效应为零——还会在后续不断回响：它是对偶理论（成本/利润/间接效用与各自最优数量互为导数）的引擎，是单调比较静态（见后文“单调比较静态与超模性”一章，第二十三章）退而只问方向时的背景，更是递归方法里对值函数求导的通行证。认得“峰顶切线水平”这一句朴素的几何事实，你就同时握住了 Shephard、Roy、Hotelling 与 Benveniste-Scheinkman 这一串看似无关的结论的共同钥匙。

第二十三章 单调比较静态与超模性 (Topkis)

用到的前置工具：偏序与格的基本概念（本章自带速览）；最优化的一阶/二阶条件（第十八章）；隐函数定理与比较静态（第十五章），本章正是它的“非光滑”对照。

隐函数定理那一章给了我们一台精密的比较静态机器：写下一阶条件 $\nabla_x f = 0$ ，假设 Hessian 负定（可逆），就能把 $D_\theta x^*$ 算到小数点后。但这台机器对原料挑剔——它要目标函数可微、要内点解、要二阶条件成立、要 Hessian 不退化。一旦选择变量是离散的（建几条生产线、开几家分店）、目标函数有拐角（带固定成本、带不可分投资）、或者我们干脆不愿意假设凹性，这台机器就熄火了。

可经济学真正想问的，往往只是一个方向：成本降了，企业会多投资还是少投资？对手更激进了，我该更激进还是更收敛？我们要的常常不是 $\frac{dx^*}{d\theta}$ 的数值，而只是它的符号。本章要讲的，正是一套只回答方向、却几乎不要任何光滑性的工具——它把比较静态从微积分搬到了序（order）的世界。核心结论惊人地干净：只要“参数越高、越值得把选择变量调高”这一条序的性质成立，那么“参数升 $\Rightarrow$ 最优选择升”就自动为真，无需可微、无需凹、无需内点。这套方法由 Topkis 奠基、经 Milgrom、Shannon、Vives 等人发扬，今天是产业组织、超模博弈、机制设计与匹配理论的主力工具。

23.1 从符号到序：动机

回忆隐函数定理在标量情形给出的那条“镇店公式”：当 $f_{xx} < 0$ （二阶条件）时，

$$\operatorname{sgn}\left(\frac{dx^*}{d\theta}\right) = \operatorname{sgn}(f_{x\theta}).$$

最优选择随参数变动的方向，完全由交叉偏导 $f_{x\theta} = \frac{\partial^2 f}{\partial x \partial \theta}$ 的符号决定。 $f_{x\theta} > 0$ 的含义是：参数 θ 越高，选择变量 x 的边际回报 $\frac{\partial f}{\partial x}$ 越大——经济学叫 x 与 θ 互补。直觉再朴素不过：如果调高 θ 让“多做一点 x ”变得更划算，那最优的 x 当然该往上走。

这条洞见的形式（求两次导、看一个符号）是光滑世界的特产，但它的内容（“互补 $\Rightarrow$ 同向变动”）根本不依赖光滑。 $f_{x\theta} > 0$ 无非是在说一句关于差分的话：

把“互补”翻译成不求导也成立的语言

$f_{x\theta} \geq 0$ 等价于：对任意 $x' > x$ ，差值

$$\Delta(\theta) := f(x', \theta) - f(x, \theta)$$

是 θ 的不减函数。也就是说，“从 x 升到 x' 能多赚多少”这件事，随参数 θ 越来越有利。这句话里没有出现任何导数——它对离散的 x 、带拐角的 f 一字不差地成立。这就是**递增差** (increasing differences)，本章的出发点。

我们要做的，就是把这个差分版的“互补”当作公理，然后证明：它足以逼出最优选择的单调性。代价是放弃“变动多少”、只保留“往哪个方向变”；回报是彻底摆脱可微、凹性、内点这些假设。先把工作的舞台——序与格——铺好。

23.2 格、递增差与超模性

偏序与格：最低限度的几何

序方法的舞台不是 $\mathbb{R}^n$ 的“长度与角度”，而是“谁比谁大”。我们需要的结构少得可怜：一个偏序，外加“任意两点都有最小的共同上界和最大的共同下界”。

定义 23.1: 偏序集与格

集合 X 上的**偏序** $\succeq$ 是满足自反、反对称、传递的二元关系（允许两个元素不可比）。设 $x, y \in X$ 。它们的**上确界** (join, 取大) $x \vee y$ 是最小的同时 $\succeq x$ 与 $\succeq y$ 的元素；**下确界** (meet, 取小) $x \wedge y$ 是最大的同时 $\preceq x$ 与 $\preceq y$ 的元素。若 X 中任意两元素的 join 与 meet 都存在且仍属于 X ，则称 $(X, \succeq)$ 为一个**格** (lattice)。

最贴近经济学的例子是 $\mathbb{R}^n$ **配分量序**： $\mathbf{x} \succeq \mathbf{y}$ 当且仅当每个分量都有 $x_i \geq y_i$ 。此时

$$\mathbf{x} \vee \mathbf{y} = (\max(x_1, y_1), \dots, \max(x_n, y_n)), \quad \mathbf{x} \wedge \mathbf{y} = (\min(x_1, y_1), \dots, \min(x_n, y_n)).$$

取大就是逐分量取较大者，取小就是逐分量取较小者（图 23.1）。注意分量序是偏序而非全序： $(1, 3)$ 与 $(3, 1)$ 谁都不 $\succeq$ 谁，它们不可比——而正是这种不可比，才让 join 与 meet 成为真正有内容的运算。任何区间格 $[\mathbf{a}, \mathbf{b}] = \{\mathbf{x} : \mathbf{a} \preceq \mathbf{x} \preceq \mathbf{b}\}$ 、任何有限点集配以分量序，都是格；离散的选择集（如 $\{0, 1, 2, \dots\}^n$ ，“各开几家店”）同样是格。这正是序方法能容纳离散选择的根源。

递增差：参数与选择的互补

现在让目标函数依赖一个选择变量 $\mathbf{x}$ （取自格 X ）和一个参数 θ （取自偏序集 Θ ）。互补的差分版定义如下。




图 23.1: $\mathbb{R}^2$ 配分量序。不可比的两点 $\mathbf{a} = (1, 3)$ 、 $\mathbf{b} = (3, 1)$ 张成一个矩形，其右上角为 join $\mathbf{a} \vee \mathbf{b} = (3, 3)$ (逐分量取大)，左下角为 meet $\mathbf{a} \wedge \mathbf{b} = (1, 1)$ (逐分量取小)。

定义 23.2: 递增差 (increasing differences)

设 $f: X \times \Theta \rightarrow \mathbb{R}$ 。称 f 在 $(\mathbf{x}, \theta)$ 上具有递增差，若对任意 $\mathbf{x}' \succeq \mathbf{x}$ (X 中) 与任意 $\theta' \succeq \theta$ (Θ 中)，

$$f(\mathbf{x}', \theta') - f(\mathbf{x}, \theta') \geq f(\mathbf{x}', \theta) - f(\mathbf{x}, \theta).$$

等价地，“升高 $\mathbf{x}$ 的收益” $f(\mathbf{x}', \cdot) - f(\mathbf{x}, \cdot)$ 是 θ 的不减函数；对称地，“升高 θ 的收益”也是 $\mathbf{x}$ 的不减函数。

这就是上一节那句要点的正式版：参数越高，把选择调高越值得。它把“ $f_{x\theta} \geq 0$ ”从一个关于二阶导的陈述，换成了一个关于四个函数值之差的陈述——后者对离散、对拐角、对任何 f 都讲得通。光滑时二者一致：

命题 23.3: 光滑情形下递增差就是交叉偏导非负

若 f 二阶连续可微，则 f 在 $X \times \Theta \subseteq \mathbb{R} \times \mathbb{R}$ 上具有递增差，当且仅当

$$\frac{\partial^2 f}{\partial x \partial \theta} \geq 0 \quad \text{处处成立.}$$

证明. 把定义中的不等式重排为 $[f(\mathbf{x}', \theta') - f(\mathbf{x}', \theta)] - [f(\mathbf{x}, \theta') - f(\mathbf{x}, \theta)] \geq 0$ 。对固定的 $\mathbf{x}$ ， $g_{\mathbf{x}}(\theta) := f(\mathbf{x}, \theta)$ ，则方括号内是 $g_{\mathbf{x}'}(\theta') - g_{\mathbf{x}'}(\theta)$ 与 $g_{\mathbf{x}}(\theta') - g_{\mathbf{x}}(\theta)$ 。由微积分基本定理，

$$[f(\mathbf{x}', \theta') - f(\mathbf{x}', \theta)] - [f(\mathbf{x}, \theta') - f(\mathbf{x}, \theta)] = \int_{\mathbf{x}}^{\mathbf{x}'} \int_{\theta}^{\theta'} \frac{\partial^2 f}{\partial x \partial \theta} d\theta dx.$$

若被积的 $f_{x\theta} \geq 0$ ，则对一切 $\mathbf{x}' \geq \mathbf{x}$ ， $\theta' \geq \theta$ 该重积分非负，即递增差成立；反之，若某点 $f_{x\theta} < 0$ ，取充分小的矩形使被积函数在其上保持负号，重积分为负，递增差被破

坏。

□

超模性：多维选择内部的互补

递增差刻画的是“选择 $\mathbf{x}$ ”与“参数 θ ”之间的互补。当选择本身是多维的 ($\mathbf{x} = (x_1, \dots, x_n)$)，我们往往还需要刻画不同选择分量之间的互补：多招一个工人，是否让多买一台机器更划算？这就是超模性。

定义 23.4: 超模函数 (supermodular)

设 X 是格。称 $f: X \rightarrow \mathbb{R}$ 超模，若对一切 $\mathbf{x}, \mathbf{y} \in X$,

$$f(\mathbf{x} \vee \mathbf{y}) + f(\mathbf{x} \wedge \mathbf{y}) \geq f(\mathbf{x}) + f(\mathbf{y}).$$

不等号反向则称 次模 (submodular)。

这个不等式初看费解，换成图 23.1 的矩形就一目了然：左端是“两个对角顶点（取大与取小）”的值之和，右端是“两个不可比顶点”的值之和。超模说的是：把两个折中的选择“拉到两个极端”（一个全高、一个全低）不会更差——这正是“分量同向”的偏好。下面的等价刻画把它与递增差接上了头。

命题 23.5: 超模性 = 两两递增差 = 交叉偏导非负

设 $f: \prod_i X_i \rightarrow \mathbb{R}$ ，各 $X_i \subseteq \mathbb{R}$ 。

1. f 超模 $\iff$ 对每一对 $i \neq j$, f 关于 (x_i, x_j) (固定其余分量) 具有递增差。
2. 若 f 二阶连续可微，则 f 超模 $\iff \frac{\partial^2 f}{\partial x_i \partial x_j} \geq 0$ 对一切 $i \neq j$ 处处成立。

注 (超模、递增差与正定，三件事别混)。

留意：超模/递增差管的是交叉偏导 ($i \neq j$) 的符号，与对角的 $\partial^2 f / \partial x_i^2$ 无关——因此超模与凹凸彼此独立。 $f(x_1, x_2) = x_1 x_2$ 超模 ($f_{12} = 1 > 0$) 却既不凹也不凸； $-x_1^2 - x_2^2$ 凹却 (交叉导为零) 只是“弱”超模。这正是序方法挣脱凹性的技术根源：它只盯交叉项。相比之下，二阶条件要的 Hessian 负定是关于所有二阶导 (含对角) 的整体性质，二者管辖的区域几乎不重叠。

例 (柯布-道格拉斯式生产函数是超模的)。

设产出 $f(L, K) = A L^\alpha K^\beta$, $A, \alpha, \beta > 0$ 。验证它在 $(L, K) \in \mathbb{R}_{++}^2$ 上超模，并说明其经济含义。

解。

交叉偏导

$$\frac{\partial^2 f}{\partial L \partial K} = \frac{\partial}{\partial K} (A \alpha L^{\alpha-1} K^\beta) = A \alpha \beta L^{\alpha-1} K^{\beta-1} > 0.$$

由命题 (光滑情形), f 超模。经济含义即劳动与资本互补: 资本存量越高, 多投一单位劳动的边际产出 $\partial f / \partial L = A\alpha L^{\alpha-1} K^\beta$ 越大。注意此结论与 f 是否凹无关—— $\alpha + \beta > 1$ (规模报酬递增、 f 非凹) 时它照样超模。这正预示: 哪怕丢掉凹性, “ K 升 $\Rightarrow$ 最优 L 升” 这类比较静态仍可断言。

23.3 Topkis 单调性定理

万事俱备。我们要的结论是: 目标对 $(\mathbf{x}, \theta)$ 具递增差 (且对 $\mathbf{x}$ 超模), 则随 θ 上升, 最优选择集整体 “往上抬”。先把 “最优集往上抬” 说精确——选择集是集合, 得用集合之间的序。

定义 23.6: 强集序 (strong set order)

设 A, B 是格 X 的两个子集。称 B 在强集序下高于 A , 记 $A \preceq_s B$, 若对一切 $a \in A, b \in B$ 都有

$$a \wedge b \in A \quad \text{且} \quad a \vee b \in B.$$

直觉: 任取低集中一点 a 、高集中一点 b , 把它们 “往下捏” 得到的 $a \wedge b$ 仍落在低集, “往上提” 得到的 $a \vee b$ 仍落在高集——高集确实被 “顶” 到了上方。在 $X \subseteq \mathbb{R}$ (全序) 上, $A \preceq_s B$ 就退化为 “ A 的每个点都 $\leq B$ 的每个点” 的自然含义, 且 $\max$ 、 $\min$ 都随之不减。

定理 23.7: Topkis 单调性定理

设 X 是格, Θ 是偏序集, $f: X \times \Theta \rightarrow \mathbb{R}$ 。对每个 θ 定义最优选择集

$$\mathcal{X}^*(\theta) = \arg \max_{\mathbf{x} \in X} f(\mathbf{x}, \theta).$$

若

1. $f(\cdot, \theta)$ 对每个固定的 θ 在 X 上超模, 且
2. f 在 $X \times \Theta$ 上具有递增差,

则 $\theta \mapsto \mathcal{X}^*(\theta)$ 在强集序下不减: $\theta' \succeq \theta \Rightarrow \mathcal{X}^*(\theta) \preceq_s \mathcal{X}^*(\theta')$ 。

特别地, 当各 $\mathcal{X}^*(\theta)$ 非空时, 其最大选择 $\bar{x}(\theta) = \sup \mathcal{X}^*(\theta)$ 与最小选择 $\underline{x}(\theta) = \inf \mathcal{X}^*(\theta)$ 都是 θ 的不减函数。

证明. 取 $\theta' \succeq \theta$, 任取 $\mathbf{a} \in \mathcal{X}^*(\theta)$ 与 $\mathbf{b} \in \mathcal{X}^*(\theta')$ 。须证 $\mathbf{a} \wedge \mathbf{b} \in \mathcal{X}^*(\theta)$ 且 $\mathbf{a} \vee \mathbf{b} \in \mathcal{X}^*(\theta')$ 。证明的全部力气在下面这条链式不等式——它把超模与递增差各用一次。

因为 $\mathbf{a}$ 在 θ 下最优, 把它换成 $\mathbf{a} \wedge \mathbf{b}$ 不会更好:

$$f(\mathbf{a}, \theta) \geq f(\mathbf{a} \wedge \mathbf{b}, \theta). \quad (*)$$

我们要由此推出对称的一句: 在 θ' 下把 $\mathbf{b}$ 换成 $\mathbf{a} \vee \mathbf{b}$ 不会更差。先用超模性 (对 θ):

以 $\mathbf{a}, \mathbf{b}$ 代入超模不等式 $f(\mathbf{a} \vee \mathbf{b}, \theta) + f(\mathbf{a} \wedge \mathbf{b}, \theta) \geq f(\mathbf{a}, \theta) + f(\mathbf{b}, \theta)$, 整理得

$$f(\mathbf{a} \vee \mathbf{b}, \theta) - f(\mathbf{b}, \theta) \geq f(\mathbf{a}, \theta) - f(\mathbf{a} \wedge \mathbf{b}, \theta) \geq 0, \quad (1)$$

末一步用了 (*). 再用**递增差**: 式 (1) 左边是“从 $\mathbf{b}$ 升到 $\mathbf{a} \vee \mathbf{b} \succeq \mathbf{b}$ 的收益”在参数 θ 下的值; 递增差说这收益随参数不减, 故在 $\theta' \succeq \theta$ 下只多不少:

$$f(\mathbf{a} \vee \mathbf{b}, \theta') - f(\mathbf{b}, \theta') \geq f(\mathbf{a} \vee \mathbf{b}, \theta) - f(\mathbf{b}, \theta) \geq 0. \quad (2)$$

但 $\mathbf{b} \in \mathcal{X}^*(\theta')$ 已是 θ' 下的最优, 故 $f(\mathbf{a} \vee \mathbf{b}, \theta') \leq f(\mathbf{b}, \theta')$, 即 (2) 最左端 ≤ 0 . 这就把 (2) 的整条不等式夹成等式, 逐段读出: $f(\mathbf{a} \vee \mathbf{b}, \theta') = f(\mathbf{b}, \theta')$ (故 $\mathbf{a} \vee \mathbf{b}$ 也是 θ' 下的最优, $\mathbf{a} \vee \mathbf{b} \in \mathcal{X}^*(\theta')$), 且 $f(\mathbf{a} \vee \mathbf{b}, \theta) - f(\mathbf{b}, \theta) = 0$. 把后一个等式代回 (1), 其最左端为零, 于是 (1) 也被夹成等式, 得 $f(\mathbf{a}, \theta) = f(\mathbf{a} \wedge \mathbf{b}, \theta)$, 即 $\mathbf{a} \wedge \mathbf{b} \in \mathcal{X}^*(\theta)$. 两条都得证, $\mathcal{X}^*(\theta) \preceq_s \mathcal{X}^*(\theta')$.

最后由 $\mathcal{X}^*(\theta) \preceq_s \mathcal{X}^*(\theta')$ 推出最大、最小选择的单调性。记 $A = \mathcal{X}^*(\theta)$ 、 $B = \mathcal{X}^*(\theta')$ 。**最小选择**: 对任意 $\mathbf{a} \in A$ 与任意 $\mathbf{b} \in B$, 强集序给出 $\mathbf{a} \wedge \mathbf{b} \in A$, 故 $\underline{x}(\theta) = \inf A \preceq \mathbf{a} \wedge \mathbf{b} \preceq \mathbf{b}$; 对一切 $\mathbf{b} \in B$ 取下确界得 $\underline{x}(\theta) \preceq \inf B = \underline{x}(\theta')$ 。**最大选择**: 对任意 $\mathbf{a} \in A$ 与任意 $\mathbf{b} \in B$, 强集序给出 $\mathbf{a} \vee \mathbf{b} \in B$, 故 $\mathbf{a} \preceq \mathbf{a} \vee \mathbf{b} \preceq \sup B = \bar{x}(\theta')$; 对一切 $\mathbf{a} \in A$ 取上确界得 $\bar{x}(\theta) \preceq \bar{x}(\theta')$ 。二者皆不减。□

注 (这个证明里到底发生了什么)。

两条假设各司其职、缺一不可: **超模性**保证“把 $\mathbf{b}$ 往 $\mathbf{a}$ 的方向抬到 $\mathbf{a} \vee \mathbf{b}$ ”在同一个参数下不吃亏 (式 1); **递增差**再保证这件“不吃亏”的事在更高的参数下只会更好 (式 2)。前者是选择分量之间的互补, 后者是选择与参数之间的互补。注意全程没有求一次导、没用一次凹性、没碰过内点——动用的只有“取大/取小”与四个函数值的大小比较。若选择是一维的 ($X \subseteq \mathbb{R}$), 超模性自动成立 (一维格上 $\mathbf{a} \vee \mathbf{b} = \max$ 、 $\mathbf{a} \wedge \mathbf{b} = \min$, 超模不等式恒为等式), 定理便只剩递增差这一条要求。

把 Topkis 定理画出来, 就是图 23.2 与图 23.3: 前者是“峰随参数右移”的连续直观, 后者是定理真正承诺的对象——一条可以带平台、带竖直跳跃 (多重最优) 的、单调不降的选择对应。

Topkis 定理的工具性一句话

目标超模 + 目标对参数有递增差 $\Rightarrow$ 最优选择随参数单调不降 (强集序意义下, 含最大、最小选择)。证明只用“取大/取小”与函数值比较, 因此: 选择可以离散、目标可以不可微、可以不凹、可以无内点解、可以多重最优——这些隐函数定理逐一要求的条件, 这里一个都不需要。




图 23.2: 递增差的直观: $\theta_H > \theta_L$ 时, 高参数曲线相对低参数曲线的“超出” $f(x, \theta_H) - f(x, \theta_L) = 1.6x$ 随 x 越来越大, 于是峰顶 (argmax) 由 $x^*(\theta_L)$ 右移到 $x^*(\theta_H)$ 。两点均精确落在各自曲线峰顶。

23.4 单交叉条件 (Milgrom–Shannon)

递增差还可以再削薄。仔细看 Topkis 的证明: 递增差是通过“收益 $f(x', \cdot) - f(x, \cdot)$ 随 θ 不减”来用的, 但我们真正需要的, 只是这收益“一旦变正就不再变负”——它的具体大小、是否单调上升, 无关紧要。这就引出比递增差更弱、且对单调比较静态“恰到好处”的条件。

定义 23.8: 单交叉性质 (single crossing property)

设 $X, \Theta \subseteq \mathbb{R}$, $f: X \times \Theta \rightarrow \mathbb{R}$ 。称 f 关于 $(x; \theta)$ 满足单交叉, 若对任意 $x' > x$, 差值

$$g(\theta) := f(x', \theta) - f(x, \theta)$$

满足: $\theta' > \theta$ 时,

$$g(\theta) \geq 0 \Rightarrow g(\theta') \geq 0, \quad \text{且} \quad g(\theta) > 0 \Rightarrow g(\theta') > 0.$$

即 g 作为 θ 的函数, 至多变号一次, 且只能由负到正 (“单向穿越零”)。

递增差要求 g 整体不减; 单交叉只要求 g 的符号由负到正、不许回头 (图 23.4)。后者明显更弱: g 可以在转正之后再回落、甚至剧烈波动, 只要不重新变负即可。它捕




图 23.3: Topkis 定理承诺的对象：最优选择对应 $x^*(\theta)$ 在强集序下不减。它可以是一条带平台、带竖直跳跃的阶梯——竖直段（红）处 argmax 是整段区间（多重最优），但最大选择与最小选择仍各自单调不降。无需可微，亦无需 x^* 是单值函数。

捉的是“一旦升高 x 变得划算，参数再涨也依旧划算”这件序上的事，而把“划算多少”彻底丢开。




图 23.4: 单交叉： $g(\theta) = f(x_H, \theta) - f(x_L, \theta)$ （升高选择的收益）作为 θ 的函数，只能由负到正穿越零一次，零点 θ_0 即“开始值得选高者”的临界参数。转正之后即便回落（如图右段下行）也不再返负——这正是它比递增差弱的地方：递增差要求 g 整条不减，单交叉只管符号不回头。

惊人的是，把递增差换成更弱的单交叉，Topkis 式的结论几乎原样成立——这是 Milgrom 与 Shannon 的定理。更深刻的是，他们证明了单交叉是单调比较静态的充要条件。

定理 23.9: Milgrom–Shannon 单调选择定理

设 $X, \Theta \subseteq \mathbb{R}$, $f: X \times \Theta \rightarrow \mathbb{R}$ 。则 $\operatorname{argmax}_{x \in X \cap [\underline{x}, \bar{x}]} f(x, \theta)$ 对每一个约束区间 $[\underline{x}, \bar{x}]$ 都在强集序下随 θ 不减，当且仅当 f 关于 $(x; \theta)$ 满足单交叉性质。

注 (为什么是充要、为什么要“对每个约束区间”)。

“充分”方向与 Topkis 证明同构：把式 (2) 那一步的“收益随 θ 不减”换成“收益的符号不回头”即可贯通。“必要”方向是真正的洞见：若单交叉被破坏（存在 g 先正后负），Milgrom-Shannon 构造出一个把最优解压进合适约束区间的情形，使最优选择逆着 θ 走。正因要排除一切这类反例，定理才要求对每个约束集都单调——这也解释了为何单交叉是“序不变”的正确推广：它恰好是那条在任意单调变换、任意约束下都守得住单调比较静态的最弱条件。

该用递增差还是单交叉？

递增差（及其多维版超模性）是**基数**（cardinal）条件——依赖 f 的具体数值，且在分量间可“叠加”，故是多维选择（Topkis）与超模博弈的通用语言。单交叉是**序数**（ordinal）条件——只看符号，对 f 做任意严格增变换都不改变它，是一维选择下单调比较静态的充要刻画。一维问题用单交叉最省力；多维或要做博弈的策略互补时，回到超模/递增差。

例（价格上涨如何抬高最优存货：无需凹性）。

零售商持有存货 $x \geq 0$ ，售价 θ ，利润 $f(x, \theta) = \theta R(x) - C(x)$ ，其中 R 是销量（ $R' > 0$ ）、 C 是持有与采购成本。这里不假设 f 凹（ R, C 可任意弯曲，甚至有规模经济使 f 多峰）。问售价 θ 上升时最优存货 $x^*(\theta)$ 怎样变化？

解。

取 $x' > x$ ，看升高存货的收益

$$g(\theta) = f(x', \theta) - f(x, \theta) = \theta \underbrace{[R(x') - R(x)]}_{>0} - [C(x') - C(x)].$$

它是 θ 的仿射增函数（斜率 $R(x') - R(x) > 0$ ），故随 θ 严格上升——递增差成立，单交叉自然成立（仿射增函数至多由负变正一次）。由 Milgrom-Shannon（或直接由 Topkis）， $x^*(\theta)$ 随 θ 单调不降。全程未用 f 的凹性：哪怕 f 在 x 上多峰、最优存货发生跳跃式跃迁，“售价升 $\Rightarrow$ 存货升”的方向依旧铁定成立。若改用隐函数定理，则需 $f_{xx} < 0$ 处处成立——本例正是它失效、而序方法照常工作的典型。

23.5 与隐函数定理的对照

把两套比较静态工具并排，能看清它们各自的领地。隐函数定理是光滑世界的定量工具，序方法是序世界的定性工具；它们在交叉偏导这一点上“握手”，但要价与产出截然不同。

	隐函数定理 (第十五章)	单调比较静态 (本章)
目标可微?	需 C^1 (甚至 C^2)	不需要
需要二阶条件 / 凹性?	需 Hessian 负定 (可逆)	不需要
选择变量	连续、内点解	可离散、可在边界、可格上
“互补”的形式	$\frac{\partial^2 f}{\partial x \partial \theta} \geq 0$	递增差 / 单交叉 (差分版)
产出	方向与大小 $\frac{dx^*}{d\theta}$	仅方向 (单调不降)
多重最优时	失效 (须单值可微)	照常 (最大、最小选择皆单调)

表 23.1: 两套比较静态工具的分工。光滑情形下二者一致： $\frac{\partial^2 f}{\partial x \partial \theta} \geq 0$ 既是隐函数定理给出 $\text{sgn}(\frac{dx^*}{d\theta}) = \text{sgn}(f_{x\theta})$ 的依据，也正是本章“格、递增差与超模性”一节里的递增差。

同一个交叉偏导，两种读法

光滑、内点、凹的“好”情形下， $\frac{\partial^2 f}{\partial x \partial \theta} \geq 0$ 同时被两套理论征用：隐函数定理读它为“ $\frac{dx^*}{d\theta} = -f_{x\theta}/f_{xx} \geq 0$ 的分子符号”，连大小一并给出；序方法读它为“递增差成立”，只取方向却把可微、凹性、内点统统省下。于是一句口诀：**要数值，且原料够光滑，用隐函数定理；只要方向，或原料不光滑，用单调比较静态**。后者是前者在“定性、稳健”方向上的极限——把要价压到最低，只换回那个最常被真正需要的东西：符号。

23.6 去处

序方法之所以成为现代理论的主力，是因为“参数升 $\Rightarrow$ 选择升”这个模板，在博弈、投资、市场设计与匹配里反复出现，且往往出现在隐函数定理够不着的非光滑、博弈互动场景。

超模博弈与策略互补。 这是 Topkis 思想最耀眼的去处。若每个局中人的支付对自己的策略超模、且对他人的策略具有递增差（“别人更激进，我更激进越划算”——策略互补），则博弈称为**超模博弈**。把每个人的最优反应看成“以他人策略为参数”的 argmax ，Topkis 定理立刻给出：**最优反应随对手策略单调上升**。配合格上的不动点定理 (Tarski)，可证纯策略 Nash 均衡存在，且存在最大与最小均衡；再叠一次递增差（支付对某外生参数也递增），又得“参数升 $\Rightarrow$ 极端均衡随之单调”的比较静态。Bertrand 价格竞争、军备竞赛、技术采纳、网络外部性下的协调，都是超模博弈。这套结论无需支付可微或凹，正是序方法的胜场。

投资与技术互补。 “资本与劳动互补”（前面柯布-道格拉斯一例）只是开端。更广地，当多种投资两两超模（一项的回报随另一项上升），Topkis 给出投资决策的协同单调：补贴或成本下降会让所有互补的投资同向上调。宏观增长里“技能-技术互补”、组织经济学里“互补性实践成簇出现”（如精益生产的各环节捆绑采用），骨架都是这个。

稳健的比较静态。 许多应用模型对函数形式（需求多弯、成本是否凹）并无把握。序方法让我们把结论建立在定性假设（“这两样东西互补”）而非定量假设（“效用是 CRRA 且 $\gamma = 2$ ”）之上，因而对设定误差稳健。这正是它在实证导向的产业组织与机制设计中受青睐的原因：要的是不被函数形式绑架的结论。

拍卖、机制设计与匹配。 单交叉是机制设计的命脉。在私人价值拍卖与筛选模型里，“类型越高、越愿意选更高的行动（出价/数量）”正是单交叉（常称 Spence–Mirrlees 单交叉条件），它保证最优机制里分配随类型单调、激励相容的局部条件能积分为全局条件。在匹配市场，若配对产出对双方类型超模，则稳定匹配是**正向匹配**（positive assortative matching）——“强强联手、弱弱配”；这一 Becker 的经典结论，本质上就是 Topkis 定理在匹配格上的一次应用。

一以贯之的，是把比较静态从微积分的语言翻译成序的语言：放弃“变多少”、紧扣“往哪变”，换来对不可微、离散、博弈互动、函数形式未知等一大片隐函数定理无能为力的疆域的掌控。当你日后在某篇产业组织或机制设计论文里读到“by supermodularity / single crossing, the equilibrium is increasing in θ ”而不见一个导数时，你已经知道，那背后站着的正是本章这两条朴素的序不等式。

第五部分

概率与测度

第二十四章 概率空间、 σ -代数与测度

用到的前置工具：集合运算与可数性（实分析预备）；上确界、下确界与单调序列的极限（分析与拓扑部分）；开集与 $\mathbb{R}^n$ 的拓扑（度量空间，第八章）。

到目前为止，本书谈概率时一直停留在朴素的层面：有一堆“结果”，每个结果配一个“概率”，加起来等于一。掷骰子、抽卡这类问题，这套朴素框架够用——样本空间是有限的，给每个结果赋个数、要算某事件的概率就把里面的结果加起来，万事大吉。可经济学和计量真正要处理的对象，几乎全都越出了这个舒适区：一个连续型随机变量取任何单个值的概率都是零，“加起来”加什么？大数定律谈的是“ $n \rightarrow \infty$ 时样本均值收敛”，这要在一个装得下可数无穷次抛掷的样本空间里才说得清；条件期望要把信息组织成“越来越细的事件族”；随机过程要给“截止到时刻 t 我知道了什么”一个精确的数学身份。这些都需要一个能严格驾驭“无穷”与“不可数”的框架。这个框架就是**测度论**，而本章——Part V 的开篇——要把它的地基浇好：样本空间、 σ -代数、（概率）测度，以及它们合成的**概率空间** $(\Omega, \mathcal{F}, \mathbb{P})$ 。

本章比前面几章都更抽象，但抽象是有回报的：一旦建立起这套语言，随机变量、Lebesgue 积分与期望、条件期望、各种收敛模式与极限定理，乃至随机过程里的信息流，都将站在同一块地基上。读者不必把每个集合论细节都嚼烂；要记住的是为什么需要这些构造，以及它们各自在守护什么。

24.1 为什么朴素概率不够用

朴素概率的做法是：列出样本空间 Ω （所有可能结果之集），给每个结果 ω 赋一个概率 $p(\omega) \geq 0$ ，使 $\sum_{\omega} p(\omega) = 1$ ；任一事件 $A \subseteq \Omega$ 的概率就是 $\mathbb{P}(A) = \sum_{\omega \in A} p(\omega)$ 。当 Ω 有限或可数时，这套做法天衣无缝。麻烦从 Ω 不可数时开始。

第一道坎：连续型随机变量。设 X 在 $[0, 1]$ 上“均匀分布”。直觉上每个点“一样可能”，可若给每个 $x \in [0, 1]$ 赋同一个正概率 $p > 0$ ，那么取可数无穷个点其概率之和已是 $+\infty$ ，遑论不可数个，与 $\mathbb{P}(\Omega) = 1$ 矛盾。唯一自洽的选择是 $\mathbb{P}(X = x) = 0$ 对每一个 x 。但这样一来“逐点求和”彻底失效： $[0, 1]$ 里每个点概率为零，整段概率却是一。概率不再能从单点累加得到，而必须直接安放在事件（如区间 $[a, b]$ ，其概率为 $b - a$ ）上。概率的载体从“点”变成了“集合”——这是测度论最根本的视角转换。

第二道坎：可数无穷的样本空间。大数定律说“反复抛硬币，正面频率趋于 $1/2$ ”。要让这句话有数学意义，样本空间必须容得下一整条无穷长的抛掷序列 $\omega = (\omega_1, \omega_2, \dots)$ ，即 $\Omega = \{0, 1\}^{\mathbb{N}}$ 。这个集合是不可数的（与 $[0, 1]$ 一样大）。“频率收敛到 $1/2$ ”本身是一个事件——由满足某种极限条件的无穷序列组成——要给它赋概率，就得有能力对这

种由可数个更简单事件经“取极限”搭起来的复杂集合谈论概率。朴素的逐点求和在这里同样无能为力。

第三道坎：要对事件做无穷次集合运算。“频率收敛”这类陈述，写成集合语言全是可数并、可数交的叠床架屋（“对任意 ε ，存在 N ，对一切 $n \geq N$ ……”逐句翻译就是 $\bigcap_{\varepsilon} \bigcup_N \bigcap_{n \geq N}$ ）。我们需要一个事件的集合，它对这些可数次运算**封闭**——做完运算得到的还是个能赋概率的事件。这正是 σ -代数的来由。

测度论解决的核心问题

朴素概率把概率赋给点、靠求和得到事件概率；这在不可数样本空间上崩溃（每点概率为零却要凑出总概率一）。测度论换一条路：直接把概率赋给事件（集合），并要求这套赋值在可数次集合运算下保持自治。代价是必须先讲清楚两件事——(i) 哪些集合算作“可赋概率的事件”（这就是 σ -代数），(ii) 赋值要满足哪几条公理（这就是测度）。本章把这两件事讲透，它们是现代概率、渐近理论与随机过程共同的、不可绕过的地基。

24.2 样本空间与事件

先把最朴素的两个对象钉死，它们不需要测度论也成立。

定义 24.1: 样本空间与样本点

一次随机试验所有可能结果构成的集合 Ω 称为**样本空间**（sample space），其中每个元素 $\omega \in \Omega$ 称为一个**样本点**（或基本结果）。 Ω 的某些子集 $A \subseteq \Omega$ 称为**事件**（event）；当试验结果 ω 落在 A 中（ $\omega \in A$ ）时，称“事件 A 发生”。

集合运算与事件的逻辑一一对应，记牢这本“词典”后续会反复用到：并 $A \cup B$ 是“ A 或 B 发生”，交 $A \cap B$ 是“ A 与 B 同时发生”，补 $A^c = \Omega \setminus A$ 是“ A 不发生”， $A \subseteq B$ 是“ A 发生则 B 必发生”，空集 $\emptyset$ 是“不可能事件”，全集 Ω 是“必然事件”。

理想情形下，我们希望对每一个子集 $A \subseteq \Omega$ 都能谈论 $\mathbb{P}(A)$ ，也就是把概率定义在全体子集之族 $\mathcal{P}(\Omega)$ （即幂集）上。当 Ω 有限或可数时确实可以这么做。但下一节会看到：在不可数的 Ω 上，强行给幂集里每个集合都赋上自治的概率会导致逻辑矛盾。于是我们退而求其次——只在 Ω 的某个子族 $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ 上定义概率。这个子族必须足够“规整”，规整到能容纳一切我们实际想问其概率的事件、并对必要的集合运算封闭。这样的子族就是 σ -代数。

24.3 σ -代数：可以放概率的事件族

定义 24.2: σ -代数


设 Ω 是一个集合。 Ω 的子集构成的族 $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ 称为 Ω 上的一个 σ -代数 (σ -algebra, 或 σ -域), 如果它满足三条:

1. 含全集: $\Omega \in \mathcal{F}$ 。
2. 对补封闭: 若 $A \in \mathcal{F}$, 则 $A^c \in \mathcal{F}$ 。
3. 对可数并封闭: 若 $A_1, A_2, \dots \in \mathcal{F}$ (可数多个), 则 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ 。

满足这三条的二元组 $(\Omega, \mathcal{F})$ 称为一个可测空间 (measurable space), $\mathcal{F}$ 中的成员称为可测集 (在概率语境下即“事件”)。

这三条看似简朴, 却恰好封住了我们需要的全部集合运算 (图 24.1)。由它们立刻可以导出其余的封闭性, 无须另立公理:

- 含空集: $\emptyset = \Omega^c \in \mathcal{F}$ (由第 1、2 条)。
- 对可数交封闭: 由 De Morgan 律, $\bigcap_n A_n = (\bigcup_n A_n^c)^c$ 。每个 $A_n^c \in \mathcal{F}$ (第 2 条), 可数并仍在 $\mathcal{F}$ (第 3 条), 再取补仍在 $\mathcal{F}$ (第 2 条)。这正是为什么只须把“可数并”列为公理——可数交是它经由取补的免费推论。
- 对有限并、有限交、差封闭: 有限并是可数并的特例 (把多余的项填成 $\emptyset$); $A \setminus B = A \cap B^c$ 。



$\mathcal{F}$ 收集 $\emptyset, \Omega, A, B$ 及它们的补、可数并、可数交——一族「可被赋予概率的事件」

图 24.1: 样本空间 Ω 与其上的一个 σ -代数 $\mathcal{F}$ 。 $\mathcal{F}$ 不是任意一堆子集, 而是对取补、可数并、可数交封闭的一族事件——它正好装得下我们想谈论概率的全部集合。

σ 这个前缀的含义，以及为何非要“可数”不可

代数 (algebra) 只要求对有限次并、交、补封闭；前缀 σ 把要求升级为对可数次封闭——这正是“ σ ”的全部分量所在。它不可或缺，因为概率论的核心陈述（“频率收敛”，“几乎必然发生”，“尾事件”）天然写成可数次集合运算的极限；而下一节要讲的测度公理里那条可数可加性，也唯有当可数并仍是合法事件时才谈得上。一句话： σ -代数对可数运算的封闭，与测度的可数可加性，是为彼此量身定做的一对。但“可数”也是上限——若贪心地要求对不可数次并封闭，几乎任何集合都能由其中的单点拼出， $\mathcal{F}$ 会膨胀回整个幂集，从而（下一节将看到）与自洽地赋概率相冲突。可数，不多不少，恰是能撑起概率论又不至于自毁的那个尺度。

例（两个极端的 σ -代数）.

给定 Ω ，写出最小与最大的 σ -代数，并说明它们在“信息”上的含义。

解.

最小的是平凡 σ -代数 $\mathcal{F} = \{\emptyset, \Omega\}$ ：含全集、对补封闭（ $\emptyset^c = \Omega$ ）、可数并也跑不出这两个集合。它只能区分“必然”与“不可能”，对应“什么信息都没有”。最大的是幂集 $\mathcal{F} = \mathcal{P}(\Omega)$ （全体子集）：显然满足三条公理，对应“信息完备、任何事件都可分辨”。一般的 σ -代数夹在两者之间， $\mathcal{F}$ 越大、能分辨的事件越多—— σ -代数的大小，正是“信息量”的数学度量。这个“ σ -代数 = 信息”的观念，到条件期望与随机过程的 filtration 一章会成为主角。

24.4 为什么不能给所有子集赋概率：不可测集

既然幂集 $\mathcal{P}(\Omega)$ 本身就是个 σ -代数、又是最大最全的那个，为什么不干脆永远用它、对每个子集都赋概率，省去“挑一个子族”的麻烦？因为在不可数的 Ω 上，这个愿望与几条最朴素的要求自相矛盾。下面以 $[0, 1]$ 上的均匀概率为例说明这个矛盾的来源——这就是著名的 **Vitali 不可测集**。我们只勾勒构造与直觉，不逐行严格化。

设想在 $\Omega = [0, 1)$ 上有一个“长度”意义下的均匀概率 $\mathbb{P}$ ，它理应满足两条不容商量的性质：

- **平移不变**：把一个集合沿圆周（即模 1 的加法，把 $[0, 1)$ 首尾相接）整体平移，其概率不变——“均匀”的本意就是各处一视同仁。
- **可数可加**：可数多个两两不交事件之并的概率，等于各自概率之和（这是下一节测度公理的核心，也是“概率”最起码的要求）。

现在构造一个会出事的集合。在 $[0, 1)$ 上定义等价关系： $x \sim y$ 当且仅当 $x - y$ 是有理数。它把 $[0, 1)$ 切成不相交的等价类，每个类形如“某个数加上全体有理数”（模 1）。借助选择公理，从每一个等价类里各挑一个代表元，把这些代表元收集成一个集合 V （这就是 Vitali 集）。关键观察有两点：

1. 把 V 沿圆周平移所有可能的有理位移 $q \in \mathbb{Q} \cap [0, 1)$, 得到可数多个集合 $V_q = V + q \pmod{1}$. 它们两两不交 (不同代表元之间的差是无理数, 不可能被有理平移对上), 且它们的并恰好铺满 $[0, 1)$ (任何 x 都与它所在类的代表元差一个有理数, 故必属于某个 V_q). 于是

$$[0, 1) = \bigsqcup_{q \in \mathbb{Q} \cap [0, 1)} V_q \quad (\text{可数个、两两不交}).$$

2. 平移不变意味着所有 V_q 有相同的概率, 记为 $c = \mathbb{P}(V)$ 。

把可数可加性用到这个分解上:

$$1 = \mathbb{P}([0, 1)) = \sum_{q \in \mathbb{Q} \cap [0, 1)} \mathbb{P}(V_q) = \sum_q c.$$

右边是可数无穷个相同的数 c 相加。若 $c = 0$, 和为 $0 \neq 1$; 若 $c > 0$, 和为 $+\infty \neq 1$ 。无论 c 取何值都凑不出 1——**矛盾**。结论只能是: V 根本无法被赋予一个与“平移不变 + 可数可加”相容的概率。这样的 V 就是一个**不可测集**。

不可测集逼着我们引入 σ -代数

矛盾的根源不是哪条性质太苛刻——平移不变、可数可加都是“均匀概率”最低限度的要求; 根源是想给幂集里每一个集合都赋概率这个奢望太贪心。Vitali 集表明: 在不可数的 $[0, 1)$ 上, 一个平移不变、可数可加、且 $\mathbb{P}([0, 1)) = 1$ 的概率, 不可能定义在全体子集上。出路只有一条——缩小定义域: 放弃给那些病态集合赋概率, 只在一个“规整”的子族 $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ 上定义 $\mathbb{P}$ 。这个子族要对可数运算封闭 (这样可数可加才有意义), 又要把一切“来历正当”的集合 (区间及其可数次运算的产物) 都装进去。这样的 $\mathcal{F}$ 就是下一节的 Borel σ -代数。 σ -代数不是数学家的洁癖, 而是不可测集逼出来的必需品。

注 (选择公理与构造性) .

Vitali 集的存在依赖**选择公理** (从不可数多个等价类里同时各取一个代表元)。这意味着不可测集无法被“显式写出”, 只能断言其存在。事实上若放弃选择公理、改采某些替代公理, 可以让“ $\mathbb{R}$ 的一切子集皆 Lebesgue 可测”成为相容的。但主流数学接受选择公理, 于是不可测集确实存在, σ -代数也就确实不可省。对使用者而言, 只需记住结论: 在 $\mathbb{R}$ 上, 并非任意子集都能赋予长度/概率, 故必须先框定一族可测集。

24.5 测度与概率空间

可测空间 $(\Omega, \mathcal{F})$ 只规定了“哪些集合可以谈概率”, 还没说概率是多少。补上这一步的, 就是测度。

定义 24.3: 测度与概率测度

设 $(\Omega, \mathcal{F})$ 是可测空间。函数 $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 称为 $(\Omega, \mathcal{F})$ 上的一个**测度** (measure), 如果

1. **非负**: $\mu(A) \geq 0$ 对一切 $A \in \mathcal{F}$ (已含在值域里); 且 $\mu(\emptyset) = 0$ 。
2. **可数可加性** (σ -可加): 对任意可数多个两两不交的 $A_1, A_2, \dots \in \mathcal{F}$,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

若额外有 $\mu(\Omega) = 1$, 则称 μ 为**概率测度**, 通常记作 $\mathbb{P}$ 。此时三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 称为一个**概率空间** (probability space)。

公理少得惊人——非负、空集为零、可数可加, 加上“全空间为一”——但整座概率论大厦都建在它们之上。值得逐条体会它们各自的分量。

可数可加性是灵魂。把不交事件之并的概率拆成各自概率之和, 这件事在有限个事件上谁都觉得理所当然 (“ A 或 B 发生”的概率, 当二者互斥时就是两概率相加)。公理的真正力量在于把它推广到可数无穷个——正是这条, 让我们能从简单事件 (区间) 的概率, 经由可数次拼接, 算出复杂事件 (如“频率收敛”那种集合) 的概率。它也正是上一节那个矛盾里被违反不得的那条。

注 (为何是“可数”可加而非“有限”或“不可数”)。

只要“有限可加”, 对付不了极限: 算 $[0, 1]$ 的长度要把它写成可数多个小区间之并再求和, 有限可加给不出这个跨越。另一头, “不可数可加”又太强会自爆: $[0, 1] = \bigcup_{x \in [0, 1]} \{x\}$ 是不可数个单点之并, 每个单点概率为零, 若要求不可数可加就得 $1 = \sum_x 0 = 0$ 。可数可加恰好是“够用又不自毁”的那个平衡点——这与上一节 σ -代数“恰好封闭到可数”是同一个尺度, 二者天生配套。

由这几条公理, 一批日用性质立刻跟着出来, 证明都只是把可数可加性用在巧妙的分解上。

命题 24.4: 概率测度的基本性质

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B \in \mathcal{F}$ 。则

1. **补事件**: $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$; 特别地 $\mathbb{P}(A) \leq 1$ 。
2. **单调性**: 若 $A \subseteq B$, 则 $\mathbb{P}(A) \leq \mathbb{P}(B)$ 。
3. **容斥 (两集)**: $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ 。
4. **可数次可加性 (Boole 不等式)**: $\mathbb{P}(\bigcup_n A_n) \leq \sum_n \mathbb{P}(A_n)$ (不要求不交)。

证明. (1) $\Omega = A \sqcup A^c$ 是不交分解, 由 (有限) 可加性 $1 = \mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c)$ 。

(2) 若 $A \subseteq B$, 则 $B = A \sqcup (B \setminus A)$ 是不交分解, 故 $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A)$, 因为概率非负。

(3) 把 $A \cup B$ 拆成三块不交之并 $(A \setminus B) \sqcup (A \cap B) \sqcup (B \setminus A)$, 分别加可加性, 与 $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ 、 $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$ 联立消元即得。

(4) 用“不交化”技巧: 令 $B_1 = A_1$ 、 $B_n = A_n \setminus \bigcup_{k < n} A_k$ 。则 B_n 两两不交、 $\bigcup_n B_n = \bigcup_n A_n$ 、且 $B_n \subseteq A_n$ 。由可数可加与单调性, $\mathbb{P}(\bigcup_n A_n) = \mathbb{P}(\bigcup_n B_n) = \sum_n \mathbb{P}(B_n) \leq \sum_n \mathbb{P}(A_n)$ 。□

第 (4) 条里那招“不交化”(把一系列集合 A_n 改写成两两不交且并集不变的 $B_n = A_n \setminus \bigcup_{k < n} A_k$) 极其常用, 下一节的连续性定理还要再用一次——它是把“可数可加”这把只对不交集合好使的工具, 撬到一般集合列上的标准杠杆。

24.6 生成的 σ -代数与 Borel 集

回到一个悬而未决的问题: 在 $\Omega = \mathbb{R}$ (或 $[0, 1]$) 上, 我们到底该用哪个 σ -代数? 幂集太大 (含不可测集, 赋不了概率), 平凡 σ -代数太小 (连区间都分辨不了)。我们想要一个“刚刚好”的——它必须包含一切我们实际关心的集合 (首先是区间, 因为随机变量的分布是靠“ X 落在某区间”来描述的), 又要对可数运算封闭, 但不要大到塞进病态集合。如何精确地造出这个“刚刚好”? 答案是“由想要的集合生成”。

定理 24.5: 任意多个 σ -代数的交仍是 σ -代数

设 $\{\mathcal{F}_i\}_{i \in I}$ 是 Ω 上任意一族 (可以不可数多个) σ -代数。则它们的交 $\bigcap_{i \in I} \mathcal{F}_i$ (即同时属于每一个 $\mathcal{F}_i$ 的那些集合) 仍是 Ω 上的一个 σ -代数。

证明. 逐条验证。 Ω 属于每个 $\mathcal{F}_i$, 故属于交。若 A 属于交, 则 A 在每个 $\mathcal{F}_i$ 里, 由各自对补封闭, A^c 也在每个 $\mathcal{F}_i$ 里, 故 A^c 属于交。可数并同理: 若 $A_1, A_2, \dots$ 都属于交, 则它们都在每个 $\mathcal{F}_i$ 里, 由各自对可数并封闭, $\bigcup_n A_n$ 在每个 $\mathcal{F}_i$ 里, 故属于交。三条都成立。□

这条看似平淡的事实是“生成”的引擎。给定任意一族我们想让它们可测的集合 $\mathcal{C}$, 全体包含 $\mathcal{C}$ 的 σ -代数构成一族 (至少幂集是其中之一, 故非空); 把它们全部交起来, 由上面定理仍是 σ -代数, 而且它包含 $\mathcal{C}$ 、又被任何包含 $\mathcal{C}$ 的 σ -代数所包含——它是“包含 $\mathcal{C}$ 的最小 σ -代数”。


定义 24.6: 由集类生成的 σ -代数

设 $\mathcal{C} \subseteq \mathcal{P}(\Omega)$ 是任意一族子集。包含 $\mathcal{C}$ 的最小 σ -代数

$$\sigma(\mathcal{C}) = \bigcap \{ \mathcal{F} : \mathcal{F} \text{ 是 } \sigma\text{-代数且 } \mathcal{C} \subseteq \mathcal{F} \}$$

称为由 $\mathcal{C}$ 生成的 σ -代数。它是“在仍保持 σ -代数结构的前提下, 恰好把 $\mathcal{C}$ 装进去”的那一个——既不多塞、也不少装。

直观上, $\sigma(\mathcal{C})$ 是从 $\mathcal{C}$ 出发、不断对成员取补、取可数并、取可数交, 把所有这样生成的集合都收进来, 直到再也生不出新集合为止的“闭包”(图 24.2)。“取最小”这个手法保证了它不会无端膨胀——只装下 $\mathcal{C}$ 经合法运算必然导致的那些集合, 一个不多。



取 $\Omega = \mathbb{R}$ 、 $\mathcal{C} = \{\text{所有开区间}\}$, 使得 **Borel σ -代数** $\mathcal{B}(\mathbb{R}) = \sigma(\mathcal{C})$; 它严格小于 $\mathcal{P}(\mathbb{R})$ ——存在不属于 $\mathcal{B}(\mathbb{R})$ 的子集 (不可测集)。

图 24.2: 由集类 $\mathcal{C}$ 生成 σ -代数: 从 $\mathcal{C}$ 出发反复施加取补、可数并、可数交, 得到恰好包含 $\mathcal{C}$ 的最小 σ -代数 $\sigma(\mathcal{C})$, 它仍真包含于幂集 $\mathcal{P}(\Omega)$ 。当 $\mathcal{C}$ 取 $\mathbb{R}$ 上所有开区间时, $\sigma(\mathcal{C})$ 就是 Borel σ -代数。

最重要的一例, 是取 $\Omega = \mathbb{R}$ 、 $\mathcal{C}$ 为全体开集 (等价地, 全体开区间)。

定义 24.7: Borel σ -代数

$\mathbb{R}$ 上由全体开集生成的 σ -代数, 称为 **Borel σ -代数**, 记作 $\mathcal{B}(\mathbb{R})$; 其成员称为 **Borel 集**。一般地, 任一拓扑空间 (如 $\mathbb{R}^n$) 上由开集生成的 σ -代数称为该空间的 Borel σ -代数 $\mathcal{B}(\mathbb{R}^n)$ 。

Borel σ -代数是概率论的“默认”可测结构。它有几个让人安心的特点:

- **该有的都有。**一切开集、闭集、半开半闭区间、单点集 ($\{a\} = \bigcap_n (a - \frac{1}{n}, a + \frac{1}{n})$ 是可数交)、可数集 (如 $\mathbb{Q}$, 是可数个单点之并) ……统统是 Borel 集。凡是能从区间出发、经可数次运算够得着的集合, 都在里头——这恰好涵盖了 we 实际想问其概率的一切集合。
- **由区间生成也一样。** $\sigma(\{\text{开区间}\}) = \sigma(\{\text{开集}\}) = \mathcal{B}(\mathbb{R})$, 因为 $\mathbb{R}$ 上每个开集都是可数个开区间之并; 甚至只用形如 $(-\infty, a]$ ($a \in \mathbb{Q}$) 的“半射线”也能生成同一个 $\mathcal{B}(\mathbb{R})$ 。这条在下一章定义随机变量时关键: 只需检验 $\{X \leq a\}$ 这一类事件可测, 就够保证 X 关于 Borel 结构整体可测。
- **它真比幂集小。**可以证明 $\mathcal{B}(\mathbb{R})$ 与 $\mathbb{R}$ 等势 (基数为连续统 $\mathfrak{c}$), 而幂集 $\mathcal{P}(\mathbb{R})$ 的基数为 $2^{\mathfrak{c}}$, 严格更大。所以“绝大多数”子集不是 Borel 集——上一节的 Vitali 集就在 $\mathcal{B}(\mathbb{R})$ 之外。这正是我们当初要的: 大到装下一切有用集合, 又小到避开病态集合。

为何 Borel σ -代数是“刚刚好”的那一个

σ -代数的“生成”构造解决了第 24.4 节留下的两难：幂集太大、平凡 σ -代数太小，而 $\mathcal{B}(\mathbb{R}) = \sigma(\text{开集})$ 不偏不倚——它是能容纳所有区间（从而所有“ X 落在某范围”型事件）的最小 σ -代数。“最小”保证不混入不可测的麻烦集合，“含开集”保证一切实用事件在内。今后凡在 $\mathbb{R}$ （或 $\mathbb{R}^n$ ）上谈随机变量、分布、可测函数，默认的可测结构都是 Borel σ -代数；它是连接“拓扑（开集）”与“概率（可测）”的标准接口。

24.7 测度的连续性

可数可加性还有一个极其有用的等价面貌：测度对单调集合列连续。这是把概率与极限挂钩的桥梁——以后凡是“ $\mathbb{P}(A_n) \rightarrow \mathbb{P}(A)$ ”型的论证（大数定律、各种“几乎必然”的陈述）都从它出发。

定理 24.8: 测度的连续性

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间， $A_n \in \mathcal{F}$ 。

1. 从下连续：若 $A_1 \subseteq A_2 \subseteq \cdots$ 单调递增，记 $A = \bigcup_n A_n$ （写作 $A_n \uparrow A$ ），则

$$\mathbb{P}(A_n) \rightarrow \mathbb{P}(A) = \mathbb{P}\left(\bigcup_n A_n\right) \quad (n \rightarrow \infty).$$

2. 从上连续：若 $A_1 \supseteq A_2 \supseteq \cdots$ 单调递减，记 $A = \bigcap_n A_n$ （写作 $A_n \downarrow A$ ），则

$$\mathbb{P}(A_n) \rightarrow \mathbb{P}(A) = \mathbb{P}\left(\bigcap_n A_n\right) \quad (n \rightarrow \infty).$$

证明. 从下连续（图 24.3）。把递增列差分成两两不交的“环带”：令 $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$ ($n \geq 2$)。则 B_n 两两不交，且对每个 N 有 $A_N = \bigsqcup_{n=1}^N B_n$ ，并 $\bigcup_n B_n = \bigcup_n A_n = A$ 。用可数可加性：

$$\mathbb{P}(A) = \mathbb{P}\left(\bigcup_n B_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(B_n) = \lim_{N \rightarrow \infty} \sum_{n=1}^N \mathbb{P}(B_n) = \lim_{N \rightarrow \infty} \mathbb{P}\left(\bigsqcup_{n=1}^N B_n\right) = \lim_{N \rightarrow \infty} \mathbb{P}(A_N).$$

中间一步无穷和等于部分和的极限正是“级数即部分和之极限”的定义，这一步把“可数可加”兑换成了“ $\mathbb{P}(A_N)$ 的极限”——连续性由此而来。

从上连续由从下连续取补即得。若 $A_n \downarrow A$ ，则补事件 $A_n^c \uparrow A^c$ 递增，对它用从下连续： $\mathbb{P}(A_n^c) \rightarrow \mathbb{P}(A^c)$ 。再代入 $\mathbb{P}(A_n^c) = 1 - \mathbb{P}(A_n)$ 、 $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ ，两边各减一取负，即 $\mathbb{P}(A_n) \rightarrow \mathbb{P}(A)$ 。□

连续性与可数可加性其实等价：在“有限可加”的前提下，“从下（或从上）连续”反过来也能推出“可数可加”。所以可以把连续性看作可数可加性“面向极限”的等价表述——日后凡涉及事件列取极限，用连续性往往比直接搬可数可加更顺手。




图 24.3: 从下连续。递增事件列 $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots$ 像同心环带一样向极限 $A = \bigcup_n A_n$ (虚线) 填充, 其概率随之单调上升、收敛到 $\mathbb{P}(A)$ 。这是可数可加性的等价化身, 也是把概率接到极限运算上的桥梁。

例 (尾事件概率为零的典型用法)。

设 A_n 是事件, 且 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$ 。证明“无穷多个 A_n 同时发生”这一事件的概率为零。(这是 Borel-Cantelli 引理的前半, 几乎必然收敛的常用入口。)

解.

“无穷多个 A_n 发生”写成集合是 $A = \bigcap_{N=1}^{\infty} \bigcup_{n \geq N} A_n$ (对任意 N , 总还有 $n \geq N$ 使 A_n 发生)。记 $C_N = \bigcup_{n \geq N} A_n$, 则 $C_1 \supseteq C_2 \supseteq \dots$ 递减且 $A = \bigcap_N C_N$ 。由从上连续, $\mathbb{P}(A) = \lim_{N \rightarrow \infty} \mathbb{P}(C_N)$ 。再由可数次可加性 (Boole 不等式),

$$\mathbb{P}(C_N) = \mathbb{P}\left(\bigcup_{n \geq N} A_n\right) \leq \sum_{n \geq N} \mathbb{P}(A_n) \xrightarrow{N \rightarrow \infty} 0,$$

因为收敛级数 $\sum_n \mathbb{P}(A_n)$ 的尾和趋于零。故 $\mathbb{P}(A) = 0$ 。从上连续 + Boole 不等式两件本章工具一配合, 就把一个关于“无穷多次发生”的极限陈述化成了一道级数尾和的估计——这正是连续性定理的典型威力。

24.8 几乎处处与几乎必然

测度论给了我们一个在朴素概率里说不清的、却无处不在的概念: “某性质除了一个概率为零的例外集之外处处成立”。连续型随机变量逼着我们正视它——既然每个单点概率为零, “ $X = x$ ”这种事件就该被当作“可以忽略”来处理。

定义 24.9: 几乎处处 / 几乎必然

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $P(\omega)$ 是关于样本点 ω 的某个性质 (命题)。称 P **几乎必然** (almost surely, 记 a.s.) 成立, 或在测度论的一般语境下称 **几乎处处** (almost everywhere, 记 a.e.) 成立, 如果使 P 不成立的样本点构成一个概率 (测度) 为零的集合:

$$\mathbb{P}(\{\omega : P(\omega) \text{ 不成立}\}) = 0,$$

等价地 $\mathbb{P}(\{\omega : P(\omega) \text{ 成立}\}) = 1$ 。一个满足 $\mathbb{P}(N) = 0$ 的集合 $N \in \mathcal{F}$ 称为**零测集** (null set)。

零测集“可以忽略”的精确含义是: 它对任何概率计算都不产生贡献。两个随机变量若只在一个零测集上取值不同, 则在概率论看来它们无法区分 (同分布、同期望、参与任何极限的结果都一样)——这种“差一个零测集”的等同关系, 是后面 L^p 空间、几乎必然收敛、条件期望“几乎处处唯一”等论述的基础。

“几乎必然”与“必然”的差别, 正是测度论比朴素概率精细的地方。“必然”要求对每一个 ω 都成立 (例外集为空集 $\emptyset$); “几乎必然”只要求例外集测度为零 (可以非空, 甚至可以是不可数无穷集——如 $[0, 1]$ 上 $\mathbb{Q} \cap [0, 1]$ 那样的可数稠密集, 测度为零却处处皆是)。在连续概率里几乎一切有用的结论都是“几乎必然”而非“必然”的。

例 (“均匀分布几乎必然取到无理数”)。

设 X 在 $[0, 1]$ 上均匀分布 (即 $\mathbb{P}(X \in [a, b]) = b - a$)。说明 X 几乎必然是无理数。

解.

有理数集 $\mathbb{Q} \cap [0, 1]$ 可数, 可枚举为 $\{q_1, q_2, \dots\}$ 。每个单点是零测集 ($\mathbb{P}(X = q_k) \leq \mathbb{P}(X \in [q_k, q_k]) = 0$)。由可数次可加性,

$$\mathbb{P}(X \in \mathbb{Q}) = \mathbb{P}(\bigcup_k \{X = q_k\}) \leq \sum_k \mathbb{P}(X = q_k) = 0.$$

故 $\mathbb{P}(X \in \mathbb{Q}) = 0$, 等价地 $\mathbb{P}(X \notin \mathbb{Q}) = 1$: X 几乎必然取无理数值。注意例外集 $\mathbb{Q} \cap [0, 1]$ 在 $[0, 1]$ 里稠密 (任何区间都含有理数), 却仍是零测——这把“几乎必然”与“处处”的差距演示得淋漓尽致: 一个测度为零的集合可以稠密到“到处都是”, 概率论却照样可以放心忽略它。

24.9 它通向何处

本章浇下的地基本身不解任何经济学问题, 但 Part V 之后几乎每一块砖都砌在它上面。把这套抽象接回主干, 去处主要有五处, 正好对应后续各章:

- **随机变量与分布** (下一章)。随机变量将被定义为可测空间之间的可测映射 $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ——“可测”的含义是 $\{X \leq a\} \in \mathcal{F}$ 对一切 a , 借此把 $\mathbb{R}$ 上的 Borel 结构“拉回”到 Ω 上。 X 的分布则是它把 $\mathbb{P}$ 推到 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上得到的概率测度。本章的 σ -代数与 Borel 集, 正是为此铺路。

- **Lebesgue 积分与期望**（后续章）。期望 $\mathbb{E}(X) = \int_{\Omega} X \, d\mathbb{P}$ 是关于概率测度的积分。它不像 Riemann 积分那样“沿 x 轴切”，而是“沿 y 轴切”——按函数值分层、用测度量每层的“大小”。这种构造对连续型、离散型乃至更怪的随机变量一视同仁，统一了“求和”与“积分”两套期望公式。没有测度，这种统一无从谈起。
- **条件期望作为投影**（后续章）。给定一个子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ （代表“部分信息”），条件期望 $\mathbb{E}(X|\mathcal{G})$ 是 X 在 $\mathcal{G}$ -可测函数空间上的正交投影。这里“ σ -代数 = 信息”的观念（见第 24.3 节的两极例子）成为主角：信息越多（ $\mathcal{G}$ 越大），条件期望越精细。
- **几乎必然收敛与大数定律**（渐近统计部分）。强大数定律断言样本均值几乎必然收敛到期望；它的陈述与证明都离不开本章的“几乎必然”与连续性定理（Borel–Cantelli 正是上面那道例题）。各种收敛模式（依概率、几乎必然、依分布、 L^p ）的精确区分，全靠测度论才说得清。
- **随机过程里的 filtration = 信息流**（随机过程部分）。一系列递增的子 σ -代数 $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots$ 刻画“信息随时间积累”—— $\mathcal{F}_t$ 是“截止到时刻 t 所能知道的一切”。鞅、停时、布朗运动都建在这套“信息流”上；它与博弈论里贝叶斯更新的信念结构（“信息一章”）本质相通：都是用 σ -代数来给“知道了什么”一个数学身份。

本章在本书中的位置

如果说线性代数是计量的引擎、拓扑是存在性的语言，那么测度论就是现代概率与渐近理论的操作系统——它本身不直接产出经济学结论，却是其上一切应用（随机变量、期望、条件期望、收敛、随机过程）得以严格运行的底层。本章只要求记住三件事：(i) 概率的载体是事件而非点，故需先框定一族可测事件，即 σ -代数；(ii) 不可数空间上不能给所有子集赋概率（Vitali），故用“由开集生成”的 Borel σ -代数作为标准可测结构；(iii) 概率测度的灵魂是可数可加，它等价地表现为对单调事件列的连续性，并催生“几乎必然”这一连续概率中无处不在的概念。带着这三点往下读，Part V 余下各章都会顺理成章。

第二十五章 可测函数、随机变量与分布

用到的前置工具：概率空间、 σ -代数与测度（见前章『概率空间、 σ -代数与测度』）；集合的原像与基本拓扑（分析与拓扑部分）。

上一章我们费了不少力气，才把“概率”安放在一个三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 上：样本空间 Ω 、可赋概率的事件族 $\mathcal{F}$ 、以及测度 $\mathbb{P}$ 。但经济学家几乎从不直接和 Ω 打交道。我们写下 $X \sim \mathcal{N}(0, 1)$ 、谈一个收益率的分布、对一个估计量求期望——所用的语言全都活在实数轴上，而非那个抽象的 Ω 。本章要搭的正是这座桥：把“随机性”严格定义成一个从 Ω 到 $\mathbb{R}$ 的可测函数（随机变量），再让它把概率从 Ω 上“推”到实轴上，得到一个只关乎实数的对象——**分布**。一旦有了分布，我们就可以忘掉 Ω ，只在熟悉的实数轴上做积分、求矩、比较收敛。本章末尾会看到，计量经济学里天天用的 CDF、密度、似然，统统是这座桥另一端的产物。

25.1 动机：为什么要把随机性写成函数

先想清楚我们到底要什么。掷一枚硬币、做一次试验、抽一个样本——结果是某个 $\omega \in \Omega$ ，它可能是“正面”“反面”这样的抽象记号，没有数值可言。但我们关心的从来不是 ω 本身，而是它的某个数值特征：赌局的赔付、资产的收益、被访者的收入。把“结果”对应到“一个实数”，这个对应就是一个函数 $X : \Omega \rightarrow \mathbb{R}$ 。这一步把抽象的随机试验翻译成了实数轴上的随机点，正是“随机变量”这个名字的由来——它名为变量，实为函数。

但光是“函数”还不够。我们想问的问题形如“收益落在 $[a, b]$ 里的概率是多少”，也就是

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(\{\omega : a \leq X(\omega) \leq b\}).$$

等式右边要有意义，集合 $\{\omega : a \leq X(\omega) \leq b\}$ 必须是 $\mathcal{F}$ 里的一个事件——否则 $\mathbb{P}$ 根本无从赋值。换句话说，我们需要的不是任意函数，而是这样一类函数：它把实轴上“我们关心的集合”拉回去，得到的总是 $\mathcal{F}$ 中的合法事件。这个“拉回去仍合法”的要求，就是**可测性**。可测性不是数学家自找的麻烦，而是“让 $\mathbb{P}(X \in B)$ 这句话有定义”的最低门槛。

随机变量的两层身份

随机变量 X 一身二任：作为函数 $X : \Omega \rightarrow \mathbb{R}$ ，它把每个试验结果翻译成一个实数；作为可测函数，它保证“ X 落在某集合里”这件事永远对应一个能赋概率的事件。前者让随机性有了数值，后者让概率计算有了立足点。本章先把这两层讲清楚，再看它如何诱导出实数轴上的分布。

25.2 可测函数

要把“拉回去仍合法”说精确，先要指定实轴那一端“我们关心的集合”是哪些。答案是 Borel σ -代数 $\mathcal{B}(\mathbb{R})$ ：它由全体开区间生成，包含一切区间、开集、闭集，以及由它们经可数次并、交、补得到的集合——日常遇到的实数集合无一例外都在其中（见前章）。于是“可测”的定义自然成形。

定义 25.1: 可测函数

设 $(\Omega, \mathcal{F})$ 与 $(E, \mathcal{E})$ 是两个可测空间（各配一个 σ -代数）。称函数 $X : \Omega \rightarrow E$ 可测（关于 $\mathcal{F}$ 与 $\mathcal{E}$ ），若对一切 $B \in \mathcal{E}$ 都有

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{F}.$$

即： X 把目标端每个可测集，原像拉回成出发端的一个可测集。

注（为什么是原像，而不是像）。

可测性用原像定义，绝非随意。原像运算和集合的并、交、补完美交换： $X^{-1}(B^c) = (X^{-1}(B))^c$ ， $X^{-1}(\bigcup_n B_n) = \bigcup_n X^{-1}(B_n)$ 。正因如此，“原像落回 $\mathcal{F}$ ”这个性质会自动地在补、可数并、可数交下保持——而这恰是 σ -代数的运算。像运算就没有这么好的代数性质（像不与补交换），用它来定义会处处碰壁。这是测度论里反复出现的主题：可测性顺着原像走。

逐个去验证“每个 Borel 集的原像都在 $\mathcal{F}$ 里”是不现实的，因为 Borel 集多得没法逐一检查。所幸有一条极其好用的简化：只需在一族生成元上验证即可。

引理 25.2: 只验生成元就够

设 $\mathcal{E} = \sigma(\mathcal{C})$ 由集类 $\mathcal{C}$ 生成。若对一切 $C \in \mathcal{C}$ 都有 $X^{-1}(C) \in \mathcal{F}$ ，则 X 可测（即对一切 $B \in \mathcal{E}$ 都有 $X^{-1}(B) \in \mathcal{F}$ ）。

证明。关键在于原像与集合运算交换。考察目标端的集类

$$\mathcal{D} = \{B \subseteq E : X^{-1}(B) \in \mathcal{F}\}.$$

由 $X^{-1}(E) = \Omega \in \mathcal{F}$ 、 $X^{-1}(B^c) = (X^{-1}B)^c$ 、 $X^{-1}(\bigcup_n B_n) = \bigcup_n X^{-1}(B_n)$ ，且 $\mathcal{F}$ 对这些运算封闭，知 $\mathcal{D}$ 本身就是一个 σ -代数。前提说 $\mathcal{C} \subseteq \mathcal{D}$ ，于是 $\mathcal{D} \supseteq \sigma(\mathcal{C}) = \mathcal{E}$ 。这正是说对一切 $B \in \mathcal{E}$ 有 $X^{-1}(B) \in \mathcal{F}$ 。□

把这条用在 $E = \mathbb{R}$ 、 $\mathcal{E} = \mathcal{B}(\mathbb{R})$ 上： $\mathcal{B}(\mathbb{R})$ 由形如 $(-\infty, x]$ 的半直线生成（这族集合的可数并交补能造出全体 Borel 集）。于是一条函数 $X : \Omega \rightarrow \mathbb{R}$ 可测，当且仅当

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F} \quad \text{对一切 } x \in \mathbb{R}.$$

这就是随机变量在实操中真正要核验的条件——只看 $\{X \leq x\}$ ，一族最简单的事件。

25.3 随机变量

定义 25.3: 随机变量

给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ ，一个（实值）随机变量是一个可测函数

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})),$$

即对一切 $x \in \mathbb{R}$ 都有 $\{X \leq x\} \in \mathcal{F}$ 。

至此“随机变量”被彻底去神秘化了：它就是定义在样本空间上、取实数值、且“ $\{X \leq x\}$ 永远是事件”的函数。图 25.1 把这幅图像画出来—— X 把样本点送到实轴上的像点，而阈值 x 在 Ω 一侧拉出一个原像事件 $\{X \leq x\}$ 。可测性要的就是：无论阈值 x 取在哪里，这块阴影区域总落在 $\mathcal{F}$ 中。




图 25.1: 随机变量 $X : \Omega \rightarrow \mathbb{R}$ 把样本点映到实轴。阈值 x 在 Ω 一侧拉回一个原像事件 $\{X \leq x\}$ （阴影）；可测性要求它对一切 x 都落在 $\mathcal{F}$ 中。图中 ω_3 的像不超过 x ，故 ω_3 落在阴影里。

例（示性函数是最简单的随机变量）。

设 $A \in \mathcal{F}$ 是一个事件，定义 $X = \mathbf{1}_A$ ，即 $X(\omega) = 1$ 若 $\omega \in A$ 、否则为 0。验证 X 是随机变量。

解.

逐一看 $\{X \leq x\}$ ：当 $x < 0$ 时它是 $\emptyset$ ；当 $0 \leq x < 1$ 时它是 $\{X = 0\} = A^c$ ；当 $x \geq 1$ 时它是整个 Ω 。三者 $\emptyset, A^c, \Omega$ 都在 $\mathcal{F}$ 中（因为 $A \in \mathcal{F}$ 且 $\mathcal{F}$ 对补封闭）。故对一切 x 都有 $\{X \leq x\} \in \mathcal{F}$ ， $\mathbf{1}_A$ 是随机变量。这个小例子点出一个事实：“一个集合是事件”与“它的示性函数是随机变量”是同一件事的两种说法。

25.4 分布：把概率搬到实数轴上

现在收获这一切的回报。随机变量 X 在手，我们就能把 Ω 上的测度 $\mathbb{P}$ 推前（push forward）到实轴上，得到一个只关乎实数的测度。

定义 25.4: 分布（像测度 / law）

随机变量 X 的分布（也称 law、像测度）是定义在 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上的测度 $\mathbb{P}_X$ ，由

$$\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}(X \in B), \quad B \in \mathcal{B}(\mathbb{R})$$

给出。

注（ $\mathbb{P}_X$ 确实是一个概率测度）。

要确认 $\mathbb{P}_X$ 名副其实。首先 $\mathbb{P}_X(\mathbb{R}) = \mathbb{P}(X^{-1}(\mathbb{R})) = \mathbb{P}(\Omega) = 1$ 。其次对两两不交的 Borel 集 $\{B_n\}$ ，它们的原像 $\{X^{-1}(B_n)\}$ 也两两不交（ X 是函数，一个 ω 的像只落在一个 B_n 里），于是


$$\mathbb{P}_X\left(\bigcup_n B_n\right) = \mathbb{P}\left(\bigcup_n X^{-1}(B_n)\right) = \sum_n \mathbb{P}(X^{-1}(B_n)) = \sum_n \mathbb{P}_X(B_n),$$

中间一步用了 $\mathbb{P}$ 的可数可加性。可数可加 + 全测度为 1， $\mathbb{P}_X$ 就是 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上一个不折不扣的概率测度。可测性在这里是隐形的功臣：正因 $X^{-1}(B) \in \mathcal{F}$ ，右边的 $\mathbb{P}(\cdots)$ 才总有定义。

图 25.2 是这次“搬运”的示意：实轴上取一个 Borel 集 B ，它在 Ω 里的原像 $X^{-1}(B)$ 是一个事件，分布 $\mathbb{P}_X$ 赋给 B 的质量，恰好就是原像那块事件原本拥有的概率。

有了分布，就可以忘掉 Ω

$(\Omega, \mathcal{F}, \mathbb{P})$ 是搭台用的脚手架，一旦分布 $\mathbb{P}_X$ 算出来，关于 X 的一切概率问题——任何 $\mathbb{P}(X \in B)$ 、任何期望 $\mathbb{E}(g(X))$ 、任何矩——都能只凭 $\mathbb{P}_X$ 回答，再不必回头看 Ω 长什么样。这就是为什么我们能放心地写 $X \sim \mathcal{N}(0, 1)$ 而从不指定 Ω ：两个建在完全不同样本空间上的随机变量，只要分布相同（记 $X \stackrel{d}{=} Y$ ），在所有概率计算中就完全可以互换。这条“只谈分布”的便利，是整个概率论与计



像测度 (分布): $\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B)) = \mathbb{P}(X \in B)$

图 25.2: 分布 $\mathbb{P}_X$ 是 $\mathbb{P}$ 沿 X 的推前: 实轴上 Borel 集 B 的质量, 定义为它在 Ω 中原像 $X^{-1}(B)$ 的概率。

量建模赖以运转的支点。

25.5 分布函数 (CDF)

测度 $\mathbb{P}_X$ 作用在全体 Borel 集上, 信息量很大却不便手算。幸好, 一维情形下, 整个分布可以被一个实变量的实值函数完全编码——这就是分布函数。

定义 25.5: 累积分布函数 (CDF)

随机变量 X 的分布函数 (CDF) 为

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}_X((-\infty, x]), \quad x \in \mathbb{R}.$$

CDF 之所以能编码整个分布, 是因为半直线 $(-\infty, x]$ 生成了 $\mathcal{B}(\mathbb{R})$: 知道了 $\mathbb{P}_X$ 在所有这种半直线上的值, 由测度的唯一性它在全体 Borel 集上的值也就定死了。于是“CDF 相同”等价于“分布相同”, 一维分布与 CDF 一一对应。下面这条定理给出 CDF 的“指纹”——三条性质刻画了它的全部形状。

定理 25.6: CDF 的三条性质

任何随机变量的 CDF $F = F_X$ 满足：

1. (单调不减) $x_1 \leq x_2 \Rightarrow F(x_1) \leq F(x_2)$;
2. (端点极限) $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1$;
3. (右连续) 对一切 $x, \lim_{y \downarrow x} F(y) = F(x)$ 。

反之，任何满足这三条的函数都是某个随机变量的 CDF。

证明. 三条性质都直接来自概率测度的两个核心特征——单调性与对单调集列的连续性（见前章测度的连续性）。

单调性. 若 $x_1 \leq x_2$ ，则 $(-\infty, x_1] \subseteq (-\infty, x_2]$ ，故由 $\mathbb{P}_X$ 的单调性 $F(x_1) = \mathbb{P}_X((-\infty, x_1]) \leq \mathbb{P}_X((-\infty, x_2]) = F(x_2)$ 。

端点极限. 取 $x_n \rightarrow +\infty$ ，则集列 $(-\infty, x_n]$ 单调上升趋向 $\mathbb{R}$ ，由测度对上升集列的连续性， $F(x_n) = \mathbb{P}_X((-\infty, x_n]) \rightarrow \mathbb{P}_X(\mathbb{R}) = 1$ 。同理取 $x_n \rightarrow -\infty$ ，集列单调下降趋向 $\emptyset$ ，由测度对下降集列的连续性（有限测度下成立）， $F(x_n) \rightarrow \mathbb{P}_X(\emptyset) = 0$ 。

右连续. 取 $y_n \downarrow x$ ，则 $(-\infty, y_n]$ 单调下降，且 $\bigcap_n (-\infty, y_n] = (-\infty, x]$ （关键：右端点 x 本身被每个 $(-\infty, y_n]$ 包含，因 $y_n \geq x$ ，故落在交里）。再由下降集列的连续性， $F(y_n) \rightarrow \mathbb{P}_X((-\infty, x]) = F(x)$ 。

反方向（任一满足三条的 F 都来自某随机变量）需用前章的测度扩张构造一个以 F 为 CDF 的测度，再取 $\Omega = \mathbb{R}$ 、 $X(\omega) = \omega$ 即可。此处只陈述、不展开。□

注（为什么是“右”连续，不是左连续）.

右连续这条常令初学者意外，根子在于 CDF 用的是闭半直线 $(-\infty, x]$ （即“ $\leq$ ”而非“ $<$ ”）。在跳点处， F 的左极限 $F(x^-) = \lim_{y \uparrow x} F(y) = \mathbb{P}(X < x)$ ，而 $F(x) = \mathbb{P}(X \leq x)$ ，二者之差正是该点的质量：

$$F(x) - F(x^-) = \mathbb{P}(X = x).$$

于是 F 在 x 处的跳幅，恰等于 X 取到 x 这个值的概率。把定义改成 $\mathbb{P}(X < x)$ 就会得到左连续的版本——纯属约定，但全世界（连同每一个计量软件）都用前者，务必记牢。

图 25.3 对照两类典型的 CDF：离散型是阶梯（在每个质量点处跳跃，跳幅为该点概率，且右连续——故跳点取右侧的实心值），连续型则光滑上升、处处无跳。两者都从 0 单调升到 1。

25.6 离散型、连续型与混合型

CDF 的形状把随机变量分成几类，分类的依据正是“概率质量是怎么铺开的”。




图 25.3: 两类典型 CDF。左：离散型，在质量点 1, 2, 3 处各跳 1/3，跳点取右侧实心值（右连续），左极限为空心。右：连续型，光滑单调上升、处处无跳。两者皆自 0 升至 1。

定义 25.7: 离散型与（绝对）连续型

离散型： X 的取值集中在至多可数个点 $\{a_1, a_2, \dots\}$ 上，分布完全由概率质量函数（pmf） $p(a_k) = \mathbb{P}(X = a_k)$ 给出，且 $\sum_k p(a_k) = 1$ 。其 CDF 是阶梯函数。

（绝对）连续型：存在一个非负可积函数 f （密度，pdf），使得对一切 x ，

$$F(x) = \int_{-\infty}^x f(t) dt.$$

此时 $\mathbb{P}(X = x) = 0$ 对每个单点成立，概率被密度“抹开”在区间上：
 $\mathbb{P}(a \leq X \leq b) = \int_a^b f$ 。

注（“连续”有两种意思，别混）。

CDF 连续（无跳）不等于存在密度。前者只排除了质量点；后者（“绝对连续”）还要求 CDF 能写成密度的积分。存在反例（如 Cantor 分布）：CDF 处处连续、却没有密度，质量诡异地藏在一个 Lebesgue 测度为零的集合上。这类“奇异连续”分布在经济学里几乎不登场，但提醒我们：“有密度”是比“CDF 连续”更强的要求。下一小节的 Radon-Nikodym 定理会把“何时存在密度”讲清楚。

更现实的是**混合型**：一部分质量集中在若干点（CDF 在那里跳），其余质量由密度铺开（CDF 在别处光滑上升）。这在经济数据里极其常见。

例（一个混合型随机变量：有删失的支出）。

设家庭对某项可选服务的支出 $X \geq 0$ ：有正概率 $\mathbb{P}(X = 0) = \pi$ 完全不消费（角点解），在 $X > 0$ 上则按某密度 g 连续分布。它既非纯离散（ $X > 0$ 部分是连续的），也非纯连续（ $x = 0$ 处有质量 $\pi > 0$ ）。它的 CDF 在 0 处跳一段高 π ，之后光滑上升到 1（形状见图 25.4）。这类“一堆零 + 连续正值”的结构，正是 Tobit 模型与角点解需求的标准设定。




图 25.4: 混合型 CDF (删失 / 角点解)。\$X \ge 0\$, 故 \$x < 0\$ 处 \$F \equiv 0\$、无连续上升段; 在角点 \$x = 0\$ 跳一段高 \$\mathbb{P}(X = 0) = \pi\$ (右连续: 取右侧实心值), 其后由 \$X > 0\$ 上的密度 \$g\$ 光滑铺开、单调升至 1。这正是 Tobit 模型“一堆零 + 连续正值”的标准形状。

密度作为 Radon–Nikodym 导数

“密度”其实有一个统一而深刻的来源：它是分布 \$\mathbb{P}_X\$ 相对于 Lebesgue 测度的 Radon–Nikodym 导数。要看清这点，先要一个概念。

定义 25.8: 绝对连续 (测度间)

设 \$\mu, \nu\$ 是同一可测空间上的两个测度。称 \$\nu\$ 关于 \$\mu\$ 绝对连续，记 \$\nu \ll \mu\$，若

$$\mu(B) = 0 \implies \nu(B) = 0.$$

即：\$\mu\$ 看不见（零测）的集合，\$\nu\$ 也看不见。

定理 25.9: Radon–Nikodym

设 \$\mu\$ 是 \$\sigma\$-有限测度，\$\nu\$ 是有限测度，且 \$\nu \ll \mu\$。则存在一个非负可测函数 \$f\$ (记 \$f = \frac{d\nu}{d\mu}\$，称 Radon–Nikodym 导数)，使得对一切可测集 \$B\$，

$$\nu(B) = \int_B f \, d\mu.$$

且 \$f\$ 在 \$\mu\$-几乎处处的意义下唯一。

这条定理本章只陈述、给直觉，不搭它的纯测度论证明（标准证明走 Hilbert 空间投影或 Hahn 分解，属于“极重的纯数学构造”，按本书体例略去）。直觉是这样的：\$\nu \ll \mu\$ 保证 \$\nu\$ 不会在 \$\mu\$ 的零测集上“凭空”堆出质量，于是 \$\nu\$ 的质量必然是“沿着 \$\mu\$ 铺开”的——而 \$f(x)\$ 量的就是在点 \$x\$ 处，\$\nu\$ 的质量相对 \$\mu\$ 浓还是稀，是一个局部的“密度比”。把这把刀切在 \$\mu = \text{Lebesgue 测度}\$ 上，立刻得到我们熟悉的概率密度。

概率密度 = 分布关于 Lebesgue 测度的 R-N 导数

取 $\mu = \lambda$ (实轴上的 Lebesgue 测度, 即“长度”), $\nu = \mathbb{P}_X$ (X 的分布)。当且仅当 $\mathbb{P}_X \ll \lambda$ (即 X 是绝对连续型: 凡长度为零的集合概率也为零、没有质量点) 时, Radon-Nikodym 定理保证存在密度

$$f_X = \frac{d\mathbb{P}_X}{d\lambda}, \quad \mathbb{P}(X \in B) = \int_B f_X d\lambda.$$

这就是“密度”最本质的定义。它把“连续型”一词解释得通透: 连续型 = 分布关于长度绝对连续 = R-N 导数(密度)存在。离散型则相反, 质量全压在零长度的点上, 相对 Lebesgue 测度根本不绝对连续, 故没有这种密度; 它的“密度”要换一把尺子——相对计数测度的 R-N 导数, 那恰好就是 pmf。pmf 与 pdf 在 R-N 的框架下被统一了, 区别只在背景测度选谁: 计数测度给出 pmf, Lebesgue 测度给出 pdf。

这个统一视角不只是漂亮: 下一部分讲期望时, “ $\mathbb{E}(g(X)) = \int g d\mathbb{P}_X$ ” 对离散与连续是同一个积分式, 只是背景测度不同——无需把求和与积分分开记两套公式。

25.7 可测性在运算下的封闭性

随机变量很少单独出现: 我们要做 $X + Y$ 、 XY 、 $\max\{X, Y\}$, 要取一系列随机变量的极限 $\lim_n X_n$ (样本均值、估计量都是这么来的)。若这些运算会把“随机变量”做成“非随机变量”(即破坏可测性), 整套理论就崩了。所幸可测性极其稳固。

命题 25.10: 可测函数对代数运算与极限封闭

设 X, Y 与 $\{X_n\}_{n \geq 1}$ 都是 $(\Omega, \mathcal{F})$ 上的随机变量, $c \in \mathbb{R}$ 。则下列函数也都是随机变量:

$$cX, \quad X + Y, \quad XY, \quad \max\{X, Y\}, \quad \min\{X, Y\},$$

以及(当下列极限对每个 ω 存在或取值于扩充实数时)

$$\sup_n X_n, \quad \inf_n X_n, \quad \limsup_n X_n, \quad \liminf_n X_n, \quad \lim_n X_n.$$

证明思路. 代数运算这部分有一条干净的捷径: 连续函数把可测函数复合后仍可测。具体地, 若 $\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}$ 连续、 X, Y 可测, 则 $\varphi(X, Y)$ 可测——因为 $(X, Y): \Omega \rightarrow \mathbb{R}^2$ 是可测的(两个分量都可测即可推出向量可测), 而连续 φ 把 Borel 集的原像拉回 Borel 集, 两步复合后原像仍落在 $\mathcal{F}$ 里。取 $\varphi(u, v) = u + v, uv, \max\{u, v\}$ 等连续函数, 立得各代数运算封闭。

极限这部分要害在于一个等式。对 $\sup_n X_n$, 注意

$$\left\{ \sup_n X_n \leq x \right\} = \bigcap_n \{X_n \leq x\}.$$

右边是可数个事件 $\{X_n \leq x\} \in \mathcal{F}$ 的交，而 $\mathcal{F}$ 对可数交封闭，故左边 $\in \mathcal{F}$ ，对一切 x 成立，即 $\sup_n X_n$ 可测。 $\inf_n X_n = -\sup_n (-X_n)$ 同理。再由

$$\limsup_n X_n = \inf_m \sup_{n \geq m} X_n, \quad \liminf_n X_n = \sup_m \inf_{n \geq m} X_n,$$

两次套用上一步即得二者可测。当 $\lim_n X_n$ 存在时它等于 $\limsup_n X_n$ ，故也可测。□

为什么这条性质是“地基级”的

“可测性在可数次极限下不塌”这一点，是后面一切“渐近”理论得以成立的暗中前提。样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i \leq n} X_i$ 、极大似然估计量 $\hat{\theta}_n$ 、乃至大数定律 / 中心极限定理里出现的种种极限，全是“随机变量经可数次运算与取极限”得来的。本命题保证它们仍是随机变量、仍有分布、仍能求概率与期望——这件事看似理所当然，却正是它在默默撑着整座大厦。注意“可数”不可省：可测性只对可数次运算封闭，不可数个随机变量的上确界未必可测，这也是随机过程理论里需要“可分性”等额外条件的根源。

25.8 它通向何处

本章把“随机性”钉死成了“ Ω 上的可测函数”，又用推前把概率搬到了实数轴上，得到分布、CDF 与密度。这三样是后续几乎所有内容的入口：

- **期望即对分布积分**（见后文『Lebesgue 积分与期望』一章）。一旦有了分布 $\mathbb{P}_X$ ，期望就是 $\mathbb{E}(g(X)) = \int_{\mathbb{R}} g \, d\mathbb{P}_X$ ；对连续型化为 $\int g(x)f_X(x) \, dx$ 、对离散型化为 $\sum_k g(a_k)p(a_k)$ ——两者本是同一积分对不同背景测度的写法。矩、矩母函数、特征函数都由此而来。
- **常见分布族与变量变换**。正态 $\mathcal{N}(\mu, \sigma^2)$ 等分布族就是一族具体的 $\mathbb{P}_X$ ；而“ $Y = g(X)$ 的分布是什么”（变量变换、Jacobian 公式）正是对推前测度再做一次推前，见后文『多维分布、独立性与变量变换』一章。
- **似然就是密度**。把密度 $f_X(x; \theta)$ 看成参数 θ 的函数，就是似然函数——极大似然、贝叶斯更新（『贝叶斯更新与信息』一章）全建在它上面。R-N 视角还解释了为什么似然比 $f(x; \theta_1)/f(x; \theta_0)$ 这种“两个分布之比”是良定义的对象。
- **依分布收敛 = CDF 收敛**。在渐近统计部分， $X_n \xrightarrow{d} X$ 的定义正是 $F_{X_n}(x) \rightarrow F_X(x)$ 在 F_X 的连续点上成立。本章建立的 CDF，是中心极限定理那句 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 之所以能被陈述的语言。

一句话收束：上一章给了概率一个家 $(\Omega, \mathcal{F}, \mathbb{P})$ ，本章则教会概率搬家——搬到我们真正会算的实数轴上。此后整本书谈“一个随机变量的分布”时，背后都是这套推前机制在运转，而 Ω 早已功成身退、退居幕后。

第二十六章 Lebesgue 积分与期望

用到的前置工具：概率空间、 σ -代数与测度（见前文「概率空间、测度」一章）；可测函数与随机变量（见前文「可测函数、随机变量与分布」一章）；序列与极限的基本语言（分析与拓扑部分）。

到这一章为止，我们已经有了概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 、有了可测函数（随机变量） $X : \Omega \rightarrow \mathbb{R}$ ，却还没有真正定义那个经济学家天天在写的符号——期望 $\mathbb{E}(X)$ 。本科教材里的写法你很熟悉：离散时 $\mathbb{E}(X) = \sum_x x \mathbb{P}(X = x)$ ，连续时 $\mathbb{E}(X) = \int x f(x) dx$ 。这两条公式各管一摊，靠的还是中学的 Riemann 积分。本章要做的事，是把它们统一成同一个更结实的对象： $\mathbb{E}(X) = \int_{\Omega} X d\mathbb{P}$ ，一个对任何随机变量都讲得通的积分——**Lebesgue 积分**。

为什么非换不可？因为渐近统计、动态规划这些后续课程里，最要命的操作是**把极限与积分（期望）交换次序**：“样本量趋于无穷时，样本均值的期望趋于……”、“无穷期贴现效用的期望等于逐期期望的贴现和”。Riemann 积分对这种交换极不友好——很多时候极限函数干脆就不再 Riemann 可积。Lebesgue 积分换了一种构造积分的思路，恰好把“极限进得去积分号”这件事变得异常顺手，三条主力定理（单调收敛、Fatou、控制收敛）就是干这个的。这一章既给你这个新积分的来历，也把这三件“换序”利器交到你手上。

26.1 为什么 Riemann 积分不够用

Riemann 积分的做法你再熟悉不过：要算 $\int_a^b f$ ，就把定义域 $[a, b]$ 切成许多窄条，每条上用一个矩形（高取该条上某点的函数值）去逼近曲线下的面积，再令条宽趋于零。它在处理“规矩”的函数（连续、分段连续）时无懈可击。问题出在两类经济学与统计学绕不开的场景。

第一类：极限与积分不易交换。 考虑一系列函数 f_n ，逐点收敛到 f （即对每个 x 都有 $f_n(x) \rightarrow f(x)$ ）。我们极想断言

$$\lim_{n \rightarrow \infty} \int f_n = \int \lim_{n \rightarrow \infty} f_n = \int f.$$

但在 Riemann 框架里，这一步常常不成立，甚至右边那个 $\int f$ 根本不存在。最干净的反例如下。

例（逐点极限把可积函数逼成不可积）。

把 $[0, 1]$ 中的有理数排成一列 $q_1, q_2, q_3, \dots$ (有理数可数, 故可以排)。令

$$f_n(x) = \mathbf{1}\{x \in \{q_1, \dots, q_n\}\},$$

即在前 n 个有理点取 1、别处取 0。每个 f_n 只在有限个点上非零, Riemann 可积且 $\int_0^1 f_n = 0$ 。

解.

逐点看, $f_n(x) \rightarrow f(x) = \mathbf{1}\{x \in \mathbb{Q} \cap [0, 1]\}$, 这就是著名的 Dirichlet 函数: 有理点取 1、无理点取 0。它在 $[0, 1]$ 上处处不连续。Riemann 和的上和恒为 1 (每个窄条里都有有理点)、下和恒为 0 (每个窄条里都有无理点), 上下和永不相遇—— f 不是 Riemann 可积的。于是

$$\lim_n \int_0^1 f_n = 0, \quad \int_0^1 \lim_n f_n = \int_0^1 f \text{ (不存在) }.$$

一系列规规矩矩、积分都为 0 的函数, 逐点极限竟跌出了 Riemann 可积的世界。

这恰恰是渐近统计的家常便饭: 样本量 n 增大时我们手里是一列统计量 T_n , 想知道极限的期望、或期望的极限, 两者能不能对调。如果连“极限对象可不可积”都没保证, 整个推断就悬在半空。Lebesgue 积分会让 Dirichlet 函数变得可积 (它的积分等于 0, 因为有理数集的“长度”为零), 并且配上一组干净的换序定理。

第二类: 离散与连续各算各的。 Riemann 积分 $\int x f(x) dx$ 只认有密度的连续型随机变量; 离散型只能用求和 $\sum_x x \mathbb{P}(X = x)$ 。混合型 (比如“有 30% 概率取 0、其余按某密度分布”的删失变量, 计量里到处都是) 就两头不靠, 得手工拼接。我们需要一个不分离散连续、一视同仁的期望定义。

症结在于“沿哪个方向切”

Riemann 沿定义域 (x 轴) 竖切: 先固定一小段自变量, 再问函数在那儿大约多高。这对“自变量动一点、函数值就乱跳”的函数 (如 Dirichlet) 毫无办法。Lebesgue 反过来, 沿值域 (y 轴) 横切: 先固定一个函数值的区间, 再问有多大一坨自变量让函数落在这个区间里——也就是去量原像集的测度。换个切法, 可积的函数大大变多, 而且能直接架在抽象测度空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上, 离散连续混合一锅端。

图 26.1 和图 26.2 把这两种切法摆在一起对照。

注 (“横切”为什么非要可测函数不可)。

Lebesgue 切法每一步都在问“函数值落在某区间里的那部分自变量有多大”, 即去量集合 $f^{-1}([y_k, y_{k+1}])$ 。要让这件事讲得通, 这些原像集必须是可测集 (属于 σ -代数 $\mathcal{F}$)——这恰好就是上一章“可测函数”的定义所保证的。换句话说, 可测性不是抽象的洁癖, 而是 Lebesgue 横切法能落地的最低门槛: 只有原像可量, “值 $\times$ 测度”




图 26.1: Riemann 积分：沿 x 轴竖切。把定义域分成小段 $[x_k, x_{k+1}]$ ，每段配一个宽 Δx_k 、高 $f(x_k)$ 的矩形，面积之和逼近曲线下面积。




图 26.2: Lebesgue 积分：沿 y 轴横切。把值域分成小带 $[y_k, y_{k+1}]$ ，对每带去量它的原像集 $f^{-1}([y_k, y_{k+1}])$ 有多大（测度），用“值 $\times$ 原像测度”求和。这正是需要“可测”的地方——原像必须可量。

才有意义。

26.2 Lebesgue 积分的三步构造

新积分按“由简到繁”分三步搭起来，每一步都用上一步当砖。全程在一个测度空间 $(\Omega, \mathcal{F}, \mu)$ 上进行；要谈期望，把 μ 取成概率测度 $\mathbb{P}$ 即可。

第一步：简单函数。 最容易积分的函数，是只取有限个值的可测函数。

定义 26.1: 简单函数

设 $A_1, \dots, A_m \in \mathcal{F}$ 是一组两两不交的可测集, $c_1, \dots, c_m \geq 0$ 是常数。形如

$$\varphi(\omega) = \sum_{k=1}^m c_k \mathbf{1}\{\omega \in A_k\}$$

的函数称为**(非负)简单函数**: 它在每个“色块” A_k 上取常值 c_k 。其积分定义为

$$\int \varphi \, d\mu = \sum_{k=1}^m c_k \mu(A_k),$$

即“取值 $\times$ 该值对应集合的测度”之和。

这一步把图 26.2 的直觉钉成了定义: 积分就是每个高度乘以达到该高度的那块地的测度。注意它对测度 μ 是普适的—— μ 可以是 $\mathbb{R}$ 上的长度 (Lebesgue 测度), 也可以是概率 $\mathbb{P}$, 公式一字不改。

第二步: 非负可测函数 (用简单函数从下逼近)。 任何非负可测函数 $f \geq 0$, 都能被一系列简单函数从下方单调地逼近: 存在简单函数列 φ_n 满足 $0 \leq \varphi_1 \leq \varphi_2 \leq \dots$ 且 $\varphi_n(\omega) \uparrow f(\omega)$ 对每个 ω 成立 (构造法见下注)。于是自然地定义

定义 26.2: 非负可测函数的积分

对可测的 $f \geq 0$,

$$\int f \, d\mu = \sup \left\{ \int \varphi \, d\mu : \varphi \text{ 为简单函数, } 0 \leq \varphi \leq f \right\}.$$

即用所有“垫在 f 下面”的简单函数的积分取上确界。这个上确界总存在 (可能为 $+\infty$)。

注 (从下逼近的标准造法)。

取定 n , 把值域 $[0, n)$ 等切成宽 2^{-n} 的小带, 令

$$\varphi_n = \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbf{1}\left\{\frac{k}{2^n} \leq f < \frac{k+1}{2^n}\right\} + n \mathbf{1}\{f \geq n\}.$$

也就是把 f 的值向下取整到最近的 2^{-n} 网格、并在 n 处封顶。带越切越细 (n 增大) 则 φ_n 单调上升、逐点逼近 f 。图 26.3 画的就是某个 φ_n : 一座垫在 f 下面的阶梯, 台阶恰落在各层值上。这正是“沿 y 轴横切”的算法化身。




图 26.3: 第二步: 用简单函数从下方逼近。阶梯 φ_n (橙) 整条垫在 f (蓝) 之下, 台阶恰取各层值 c_k 、在 f 穿过该层处跳升。把带切细 ($n \uparrow$), 阶梯单调升高、逐点贴近 f , 其积分的上确界即 $\int f \, d\mu$ 。

第三步: 一般可测函数 (拆成正负两半)。 对一般的可测函数 f (可正可负), 拆成正部与负部:

$$f^+ = \max\{f, 0\} \geq 0, \quad f^- = \max\{-f, 0\} \geq 0, \quad f = f^+ - f^-, \quad |f| = f^+ + f^-.$$

两半都是非负可测函数, 已经能按第二步积分。于是定义

定义 26.3: 可积与积分

若 $\int f^+ \, d\mu$ 与 $\int f^- \, d\mu$ 中至少一个有限, 就定义

$$\int f \, d\mu = \int f^+ \, d\mu - \int f^- \, d\mu.$$

若两者都有限 (等价地 $\int |f| \, d\mu < \infty$), 称 f 为 **(Lebesgue) 可积**, 记 $f \in L^1(\mu)$ 。

三步走, 记住它

简单函数 (取有限个值, 积分 = $\sum c_k \mu(A_k)$) $\rightarrow$ **非负可测** (用下方简单函数的积分取上确界) $\rightarrow$ **一般可测** (拆 $f = f^+ - f^-$ 分别积分再相减)。三步全靠“值 $\times$ 原像测度”这一个念头反复加细。可积的判据干净利落: $f \in L^1 \iff \int |f| < \infty$ ——绝对可积。

Lebesgue 积分要求绝对可积 ($\int |f| < \infty$), 这与某些反常 Riemann 积分“条件收敛” (如 $\int_0^\infty \frac{\sin x}{x} \, dx$ 收敛但 $\int_0^\infty \left| \frac{\sin x}{x} \right| \, dx = \infty$) 不同。在概率论里这不是损失: 期望 $\mathbb{E}(X)$ 本就要求 $\mathbb{E}(|X|) < \infty$ 才算“存在”, 二者口径一致。

26.3 期望就是一个 Lebesgue 积分

把上面的测度空间取成概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 、被积函数取成随机变量 X ，期望的定义便一字不改地落地。

定义 26.4: 期望

随机变量 X 的期望定义为它关于概率测度 $\mathbb{P}$ 的 Lebesgue 积分

$$\mathbb{E}(X) = \int_{\Omega} X \, d\mathbb{P},$$

只要 $\int_{\Omega} |X| \, d\mathbb{P} = \mathbb{E}(|X|) < \infty$ (即 $X \in L^1(\mathbb{P})$) 就说期望存在。

这一个定义同时吞并了本科那两条分头的公式。看离散情形: 若 X 只取值 $x_1, x_2, \dots$, 令 $A_k = \{X = x_k\}$, 则 $X = \sum_k x_k \mathbf{1}_{A_k}$ 是简单函数 (或其极限), 按第一步的积分定义直接得

$$\mathbb{E}(X) = \int_{\Omega} X \, d\mathbb{P} = \sum_k x_k \mathbb{P}(A_k) = \sum_k x_k \mathbb{P}(X = x_k),$$

正是熟悉的求和式。连续情形的 $\int x f(x) \, dx$ 则要靠下一节的换元公式接回去。关键在于: 现在它们是同一个积分的两种特例, 混合型随机变量也自动有定义, 不必再手工拼接。

Lebesgue 积分的基本性质。 下面几条对后续推导反复要用, 证明都顺着三步构造由简单函数推上去, 这里只陈述。

命题 26.5: 积分的基本性质

设 $X, Y \in L^1(\mathbb{P})$, $a, b \in \mathbb{R}$ 。则

- 线性: $\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y)$ 。
- 单调: 若 $X \leq Y$ (几乎处处), 则 $\mathbb{E}(X) \leq \mathbb{E}(Y)$; 特别地 $|\mathbb{E}(X)| \leq \mathbb{E}(|X|)$ 。
- 常数: $\mathbb{E}(c) = c$; 且 $\mathbb{E}(\mathbf{1}_A) = \mathbb{P}(A)$ (概率是示性函数的期望)。
- 零测无关: 若 $X = Y$ 几乎处处 (即 $\mathbb{P}(X \neq Y) = 0$), 则 $\mathbb{E}(X) = \mathbb{E}(Y)$ 。

注 (“几乎处处” 是 Lebesgue 框架的一大便利)。

“几乎处处” (almost everywhere, 概率里叫 “几乎必然” a.s.) 指 “除一个测度为零的集合外处处成立”。Lebesgue 积分对零测集上的改动完全免疫: Dirichlet 函数与零函数仅在有理数 (零测集) 上不同, 故 $\int_0^1 \mathbf{1}_{\mathbb{Q}} = 0$ 。这条性质让我们能放心地 “忽略概率为零的坏事”——计量与概率论里 “a.s.” 满天飞, 根子就在这里。

26.4 极限与积分交换：三大主力定理

这是本章的命根子。Lebesgue 积分真正压倒 Riemann 的地方，就是下面三条“极限进得去积分号”的定理。它们是渐近统计（期望与极限互换）、动态规划（期望与无穷贴现和互换）的发动机。三条都只陈述加直觉，证明属于较重的纯分析、本书从略。

定理 26.6: 单调收敛定理 (MCT)

设 $0 \leq f_1 \leq f_2 \leq \cdots$ 是一列单调不减的非负可测函数，逐点收敛到 f （即 $f_n \uparrow f$ ）。则

$$\lim_{n \rightarrow \infty} \int f_n \, d\mu = \int f \, d\mu.$$

换言之，对单调上升的非负函数列，极限号与积分号可以直接对调（两边都允许等于 $+\infty$ ）。

直觉： f_n 一路往上垫高、绝不“偷走”面积，涨上去的面积无处可逃，只能恰好补成 $\int f$ 。第二步构造里 $\varphi_n \uparrow f$ 正是 MCT 的原型场景——MCT 保证了“ $\int f = \lim \int \varphi_n$ ”这件看似显然的事真的成立。

定理 26.7: Fatou 引理

设 $f_n \geq 0$ 是任意一系列非负可测函数（不要求单调、也不要求收敛）。则

$$\int \left(\liminf_{n \rightarrow \infty} f_n \right) \, d\mu \leq \liminf_{n \rightarrow \infty} \int f_n \, d\mu.$$

即“先取下极限再积分”不会超过“先积分再取下极限”。

Fatou 只给单向不等式，但它最宽容——对任何非负函数列都成立。它说的是：取极限时面积可能漏掉一部分（不等号），但绝不会凭空多出。它常作为证明 MCT、DCT 的跳板，也是“面积可能逃逸”这一现象的精确刻画。

例（面积可以逃向无穷：Fatou 取严格不等号）。

在 $\mathbb{R}$ 上取 $f_n = \mathbf{1}_{[n, n+1]}$ （高度 1、宽度 1 的方块，向右滑走）。逐点看每个 x 终将被方块甩在后头，故 $\liminf_n f_n = 0$ 。但每个 $\int f_n = 1$ 。于是

$$\int \liminf_n f_n = 0 < 1 = \liminf_n \int f_n.$$

解.

面积没有消失，而是逃到了无穷远——极限函数（ $\equiv 0$ ）的积分捕捉不到它，所以 Fatou 只能给出“ $\leq$ ”。这个例子也顺带说明：若没有额外控制（如下面 DCT 的可积控制函数），极限与积分一般不能随便对调。

定理 26.8: 控制收敛定理 (DCT)

设可测函数列 $f_n \rightarrow f$ 逐点收敛, 且存在一个可积的控制函数 $g \in L^1(\mu)$ ($\int g \, d\mu < \infty$) 使得

$$|f_n(\omega)| \leq g(\omega) \quad \text{对一切 } n \text{ 与 (几乎) 一切 } \omega.$$

则 $f \in L^1(\mu)$, 且

$$\lim_{n \rightarrow \infty} \int f_n \, d\mu = \int f \, d\mu, \quad \text{更强地} \quad \int |f_n - f| \, d\mu \rightarrow 0.$$

DCT 是三者里日常用得最多的“换序”定理: 只要找得到一个不依赖 n 、积分有限的“天花板” g 把整列 f_n 罩住, 极限与积分就能放心对调。上例 $f_n = \mathbf{1}_{[n, n+1]}$ 的失败正因为找不到这样的 g ——能罩住所有右滑方块的只有 $g \equiv 1$, 而它在 $\mathbb{R}$ 上积分为 ∞ , 不可积。“有可积控制”恰好堵住了“面积逃向无穷”这个唯一的漏洞。

为什么 Lebesgue 换得了极限、Riemann 换不了

Riemann 积分是定义在“黎曼可积函数”这个很窄的圈子里的, 逐点极限动辄把你踢出这个圈子 (如 Dirichlet 函数), 换序无从谈起。Lebesgue 积分定义在宽得多的可测函数上, 对逐点极限封闭 (可测函数的逐点极限仍可测), 于是“极限对象一定还在场内”; 剩下要担心的只是“面积会不会逃逸”, 而 MCT (靠单调)、DCT (靠可积控制) 正是堵住逃逸的两道闸。一句话: Lebesgue 把换序问题从“极限还可积吗”简化成了“面积逃逸了吗”, 而后者有现成的闸门可关。

26.5 换元: 把期望算到分布上去

定义 $\mathbb{E}(X) = \int_{\Omega} X \, d\mathbb{P}$ 把期望架在抽象样本空间 Ω 上, 干净, 却没法直接算——我们手上有的从来不是 Ω , 而是 X 的分布。下面这条换元公式 (统计学家爱称“无意识统计学家定律”, LOTUS) 把积分从 Ω 搬到熟悉的实数轴上。

定理 26.9: 换元公式 (期望化为对分布的积分)

设 X 是随机变量, P_X 是它在 $\mathbb{R}$ 上的分布 (即 $P_X(B) = \mathbb{P}(X \in B)$)。则对任意 (使期望有定义的) 可测函数 h ,

$$\mathbb{E}(h(X)) = \int_{\Omega} h(X) \, d\mathbb{P} = \int_{\mathbb{R}} h(x) \, dP_X(x).$$

取 $h(x) = x$ 即得 $\mathbb{E}(X) = \int_{\mathbb{R}} x \, dP_X(x)$ 。

证明. 照三步构造“由简到繁”推。先看示性函数 $h = \mathbf{1}_B$: 左边 $\mathbb{E}(\mathbf{1}_B(X)) = \mathbb{P}(X \in B) =$

$P_X(B)$, 右边 $\int_{\mathbb{R}} \mathbf{1}_B dP_X = P_X(B)$, 两边相等——这正是分布 P_X 的定义。由积分的线性, 等式推广到简单函数 $h = \sum_k c_k \mathbf{1}_{B_k}$ 。对一般非负可测的 h , 取简单函数 $h_n \uparrow h$, 两边各用一次 MCT 取极限即得。最后对一般 h 拆 $h = h^+ - h^-$ 分别处理。□

这条公式说明: 算期望只需要分布 P_X , 不需要原始概率空间 Ω ——这正是统计实践的常态 (我们建模分布, 从不建模 Ω)。再把它接到本科那两条公式上:

例 (换元如何还原出 “求和” 与 “ $\int x f dx$ ”)。

分别在离散与连续两种分布下展开 $\int_{\mathbb{R}} x dP_X$ 。

解.

离散型: P_X 把质量 $p_k = \mathbb{P}(X = x_k)$ 堆在各点 x_k 上, 对这种 “点质量” 测度积分就是逐点求和,

$$\mathbb{E}(X) = \int_{\mathbb{R}} x dP_X = \sum_k x_k p_k.$$

连续型: X 有密度 f 意味着 $dP_X = f(x) dx$ (分布对 Lebesgue 测度有密度), 于是

$$\mathbb{E}(X) = \int_{\mathbb{R}} x dP_X = \int_{\mathbb{R}} x f(x) dx.$$

两条本科公式就此从同一个 Lebesgue 积分里掉出来, 差别只在分布 P_X 长什么样——点质量还是有密度。混合型分布把两者叠加, 公式照样成立。

26.6 三个常用不等式

有了 Lebesgue 期望, 下面三条不等式是矩、收敛、 L^p 空间里反复出现的 “算盘”。这里给陈述与一句直觉, 证明留待相关章节。

定理 26.10: Jensen 不等式

设 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, X 与 $\varphi(X)$ 都可积。则

$$\varphi(\mathbb{E}(X)) \leq \mathbb{E}(\varphi(X)).$$

φ 为凹时不等号反向。

直觉: 凸函数 “下托弦上”, 期望 (平均) 穿过函数时会被这道弯 “往上抬”。它是 “风险厌恶” 的数学骨架——效用 u 凹则 $\mathbb{E}(u(X)) \leq u(\mathbb{E}(X))$, 确定的均值优于带风险的彩票; 也给出 $\mathbb{E}(X^2) \geq (\mathbb{E}(X))^2$ (取 $\varphi(x) = x^2$), 即方差非负。

定理 26.11: Hölder 不等式

设 $p, q > 1$ 且 $\frac{1}{p} + \frac{1}{q} = 1$ (共轭指数)。则

$$\mathbb{E}(|XY|) \leq (\mathbb{E}(|X|^p))^{1/p} (\mathbb{E}(|Y|^q))^{1/q}.$$

$p = q = 2$ 即 **Cauchy-Schwarz**: $\mathbb{E}(|XY|) \leq \sqrt{\mathbb{E}(X^2)}\sqrt{\mathbb{E}(Y^2)}$ 。

Hölder 是“两个随机变量乘积的期望，被各自的 L^p 大小控制住”。它保证了协方差有限（当二阶矩有限时）、是定义 L^p 空间对偶配对的核心； $p = q = 2$ 的特例直接给出相关系数 $|\text{Corr}(X, Y)| \leq 1$ 。

定理 26.12: Minkowski 不等式 (L^p 三角不等式)

设 $p \geq 1$ 。则

$$(\mathbb{E}(|X + Y|^p))^{1/p} \leq (\mathbb{E}(|X|^p))^{1/p} + (\mathbb{E}(|Y|^p))^{1/p}.$$

记 $\|X\|_p = (\mathbb{E}(|X|^p))^{1/p}$ ，Minkowski 就是 $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$ ——这正是三角不等式，它使 L^p 成为一个赋范空间（范数 $\|\cdot\|_p$ ）。 L^2 还带内积 $\langle X, Y \rangle = \mathbb{E}(XY)$ ，是下文把条件期望看成“投影”的舞台。

26.7 它通向何处

Lebesgue 积分与这一整套换序工具，是后面好几门核心课程的地基。几处主要去处：

- **矩与矩母函数**。各阶矩 $\mathbb{E}(X^k)$ 、矩母函数 $M_X(t) = \mathbb{E}(e^{tX})$ 都是 Lebesgue 积分；“对 M_X 求导能换出矩”这一步，靠的正是 DCT 把求导（极限）放进期望号。
- **大数定律与中心极限定理**（见后文渐近统计部分）。LLN/CLT 的证明处处在交换期望与极限——特征函数法、截断论证里 MCT 与 DCT 是反复出现的主角。
- **条件期望**（见后文「条件期望」一章）。条件期望 $\mathbb{E}(X|\mathcal{G})$ 是 L^2 空间里的投影，立足于本章的 L^2 结构与 Hölder/Minkowski 给出的范数。
- **动态规划**（见后文动态最优化解部分）。要把无穷期贴现期望效用 $\mathbb{E}\left(\sum_{t \geq 0} \beta^t u(c_t)\right)$ 拆成逐期形式 $\sum_{t \geq 0} \beta^t \mathbb{E}(u(c_t))$ ，本质上是把期望搬进无穷和里，正是 MCT/DCT 的应用；Bellman 方程的合法性有赖于此。
- **对数似然**。 $\ell(\theta) = \mathbb{E}(\log f_\theta(X))$ 是积分；最大似然的渐近理论（一致性、渐近正态）反复要求“ $\mathbb{E}()$ 与 ∂_θ 、与 $\lim$ 可交换”，每一步都在引用本章的定理。

一句话收束：期望不是两条分头的公式，而是一个 Lebesgue 积分；而“极限能进期望号”这件在本科里被默认、在博士阶段却步步要交代的事，正是由 MCT、Fatou、

DCT 三条定理撑起来的。认清这一点，渐近统计与动态规划里大量“想当然”的换序，才算真正站稳了脚跟。

第二十七章 多维分布、独立性与变量变换

用到的前置工具：随机变量与分布、概率密度（第二十五章）；Lebesgue 积分与期望（第二十六章）；行列式（线性代数部分）、Jacobian 与多元微积分（第十三章）；正定矩阵与谱定理（线性代数部分）。

到目前为止我们大多盯着一个随机变量。但计量经济学里几乎没有一个问题只牵涉一个随机量：一份样本是 n 个观测的联合体，一个回归把因变量、解释变量、误差项绑在一起，一个估计量是全体数据的函数。要谈“ X 和 Y 是否相关”“样本均值的分布长什么样”“这个统计量服从 χ^2 还是 t ”，都必须先有一套描述多个随机变量一起如何取值的语言。这正是本章要建立的。

本章的主线是四个互相咬合的工具。**联合分布**是底座，它一次性记录所有变量的取值规律，而每个变量自己的分布（边缘分布）只是它的“投影”。**独立性**是这套语言里最省力的假设——它把联合分布拆成乘积，把“期望”和“乘法”交换次序，是 iid 抽样得以展开的全部依据。**变量变换公式**回答“一个随机向量经过映射后，新分布是什么”，它是推导抽样分布（ χ^2, t, F ）、做 MLE 重参数化、理解 Delta 法的统一手柄；其核心——密度按 Jacobian 行列式的绝对值缩放——正是“行列式量度体积”那条几何事实在概率上的化身。最后，**多元正态分布**把这一切收束：它在线性变换下封闭、不相关即独立、条件期望恰好线性，又是中心极限定理的极限对象，因此成了整个渐近统计的“通用货币”。

27.1 联合分布与边缘分布

定义 27.1: 联合分布与联合密度

设 X, Y 是定义在同一概率空间上的随机变量。它们的**联合分布函数**为

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y).$$

若存在非负函数 $f_{X,Y} : \mathbb{R}^2 \rightarrow [0, \infty)$ 使得对一切 Borel 集 $A \subseteq \mathbb{R}^2$

$$\mathbb{P}((X, Y) \in A) = \iint_A f_{X,Y}(x, y) \, dx \, dy,$$

则称 (X, Y) 为**(联合)连续型**, $f_{X,Y}$ 为其**联合密度**。对随机向量 $\mathbf{X} = (X_1, \dots, X_n)^\top$ 的定义完全平行, 密度记 $f_{\mathbf{X}}(\mathbf{x})$, $\mathbf{x} \in \mathbb{R}^n$ 。

联合密度的全部信息量, 正在于它能回答“ (X, Y) 落进任意区域 A 的概率”这一类问题——而单看每个变量各自的分布做不到这一点。把注意力收缩回单个变量, 就得到边缘分布。

定义 27.2: 边缘密度

连续型 (X, Y) 的**边缘密度**由对另一变量积掉得到:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx.$$

这一步“积掉”有着干净的直觉: 要知道 $X \approx x$ 的密度, 就把所有 $X = x$ 但 Y 取遍各种值的可能性全加起来。几何上, 联合密度是 (x, y) 平面上方的一座“山”, 边缘密度是把这座山分别朝两条坐标轴方向“压扁”得到的剖影 (图 27.1)。

注 (从边缘回不到联合) .

反过来一般不成立: 知道 f_X 与 f_Y 并不能定出 $f_{X,Y}$ 。无穷多个不同的联合密度可以共享同一对边缘密度——它们的区别正在于 X 与 Y 之间的“依赖结构” (这一思想被 copula 理论系统化)。图 27.1 画的是其中最特殊的一种: 联合密度恰好等于两个边缘密度之积, 即下一节的独立。

27.2 独立性

独立性是概率论里最强、也最好用的结构性假设。直观上, “ X 与 Y 独立”是说: 知道 X 取了什么值, 对 Y 的分布毫无信息增益。把这句话翻译成密度, 就是联合密度分解为边缘密度之积。




图 27.1: 联合密度的等高线(中)与它向两轴的“投影”——边缘密度 f_X (下)、 f_Y (左)。边缘密度是把另一变量积掉的结果。

定义 27.3: 独立性

随机变量 X, Y 独立 (记 $X \perp Y$)，若对一切 x, y

$$F_{X,Y}(x, y) = F_X(x) F_Y(y);$$

连续型情形等价地

$$f_{X,Y}(x, y) = f_X(x) f_Y(y).$$

更一般地, $X_1, \dots, X_n$ 相互独立, 若联合分布函数(或密度)对一切自变量都分解为各边缘之积。

注意“相互独立”强于“两两独立”：前者要求任意子集都分解，后者只要求每一对分解，二者并不等价。本书凡说“独立同分布”(iid)均指相互独立。

独立性最常被使用的形态，并不是密度的分解本身，而是它的一个推论：独立变量的乘积，期望可以拆开算。这条性质看似平淡，却是后续几乎所有“算方差”步骤的引擎。

定理 27.4: 独立 $\implies$ 期望可乘

若 $X \perp Y$ ，且 g, h 使得 $\mathbb{E}(g(X))$ 、 $\mathbb{E}(h(Y))$ 都存在，则

$$\mathbb{E}(g(X) h(Y)) = \mathbb{E}(g(X)) \mathbb{E}(h(Y)).$$

特别地 (取 g, h 为恒等映射) $\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$ 。

证明. 直接在联合密度上算, 用独立性把密度拆开, 再用 Fubini 定理 (第二十六章) 把二重积分写成两个一重积分之积:

$$\begin{aligned}\mathbb{E}(g(X)h(Y)) &= \iint g(x)h(y)f_{X,Y}(x,y) \, dx \, dy \\ &= \iint g(x)h(y)f_X(x)f_Y(y) \, dx \, dy \\ &= \left(\int g(x)f_X(x) \, dx \right) \left(\int h(y)f_Y(y) \, dy \right) = \mathbb{E}(g(X)) \mathbb{E}(h(Y)).\end{aligned}$$

关键的第二个等号正是独立性 $f_{X,Y} = f_X f_Y$, 第三个等号是 Fubini 把可分离的被积函数拆成两个积分相乘。离散情形把积分换成求和、密度换成概率质量, 论证一字不差。□

独立把“期望”与“乘法”解耦

$\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$ 这条等式, 是从联合行为下降到“逐个处理”的桥梁。它让我们在算 $\text{Var}(X+Y)$ 、算样本均值的方差、推导 OLS 的 $\mathbb{E}(\epsilon\epsilon^T)$ 结构时, 能把交叉项一笔勾销。下一节会看到, 它正好等价于“协方差为零”——独立的变量必不相关。但请记住方向: 独立 $\implies$ 不相关, 反之一般不成立。

27.3 协方差与相关

独立是“非此即彼”的强条件, 现实里我们更常想量化依赖的程度与方向。协方差与相关系数就是为此而设的一阶刻画。

定义 27.5: 协方差与相关系数

设 X, Y 二阶矩有限。协方差

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X) \mathbb{E}(Y).$$

当 $\text{Var}(X), \text{Var}(Y) > 0$ 时, 相关系数

$$\text{Corr}(X, Y) = \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \sqrt{\text{Var}(Y)}} \in [-1, 1].$$

对随机向量 $\mathbf{X} \in \mathbb{R}^n$, 协方差矩阵

$$\Sigma = \text{Var}(\mathbf{X}) = \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))^T), \quad \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

两条性质值得当作肌肉记忆。其一, 协方差关于线性变换是双线性的, 由此得到方差的“展开式”:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

正是这里的交叉项 $2\text{Cov}(X, Y)$ ，在 $X \perp\!\!\!\perp Y$ 时归零，于是独立和的方差等于方差之和——iid 样本均值 $\text{Var}(\bar{X}) = \sigma^2/n$ 的那个 $1/n$ 就是这么来的。其二，对随机向量与常数矩阵 $\mathbf{A}$ ，

$$\text{Var}(\mathbf{A}\mathbf{X}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

这条线性变换法则会在多元正态和 OLS 的协方差推导里反复出现。

ρ 只看到“线性”那部分依赖

相关系数度量的是线性相依： $|\rho| = 1$ 当且仅当 Y 几乎处处是 X 的仿射函数。它对非线性依赖是“色盲”的——见下例。这也是“不相关 $\nRightarrow$ 独立”的根源：协方差只捕捉一阶共动，独立却要求所有阶、所有函数都解耦。

例（不相关却不独立）。

设 $X \sim \mathcal{N}(0, 1)$ ，令 $Y = X^2$ 。显然 Y 由 X 完全决定，二者远谈不上独立。它们相关吗？

解。

算协方差需要 $\mathbb{E}(XY) = \mathbb{E}(X^3)$ 。标准正态的奇数阶矩为零，故 $\mathbb{E}(X^3) = 0$ ，而 $\mathbb{E}(X) = 0$ ，于是

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = 0 - 0 \cdot \mathbb{E}(X^2) = 0.$$

即 $\rho_{XY} = 0$ ： X 与 $Y = X^2$ 完全不相关，却有着最强的（函数）依赖。原因是它们的依赖是纯二次的、对称的，没有任何线性成分能被协方差看见。这个例子是“独立 $\Rightarrow$ 不相关”不可逆的标准反例，也提醒我们：回归里“零相关”远不等于“无关系”。

依赖的几何，最直观地体现在联合密度的等高线形状上。独立（这里取联合正态）对应正圆形等高线——沿任一方向切，条件分布的形状都不变；正相关把等高线沿主对角线拉成椭圆—— X 偏大时 Y 也倾向偏大（图 27.2）。

27.4 多维变量变换公式

现在来到本章的技术核心。问题是：已知随机向量 $\mathbf{X}$ 的密度 $f_{\mathbf{X}}$ ，又有一个可微映射 $\mathbf{Y} = \mathbf{g}(\mathbf{X})$ ，那么 $\mathbf{Y}$ 的密度 $f_{\mathbf{Y}}$ 是什么？这件事在计量里无处不在——抽样分布 χ^2, t, F 全是某些基本随机变量经过变换得到的，MLE 换参数时似然如何变也由它管。

答案的关键，是回忆行列式的几何意义：一个线性映射把单位体积的小块拉伸为体积 $|\det|$ 的小块（见行列式一章的“体积”解读）。密度是“单位面积上的概率”，所以当映射把面积放大 $|\det \mathbf{J}|$ 倍时，为了让总概率守恒，密度必须相应地除以这个因子。




图 27.2: 联合正态密度的等高线。独立对应正圆 (a); 正相关把等高线沿主对角线 (虚线) 拉成椭圆 (b), 椭圆主轴的倾斜程度由 ρ 决定。

定理 27.6: 变量变换公式 (多维)

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 在开集上是一一对应的连续可微映射, 其逆 g^{-1} 也连续可微 (即微分同胚)。记 $\mathbf{Y} = g(\mathbf{X})$, $\mathbf{X} = g^{-1}(\mathbf{Y})$ 。则 $\mathbf{Y}$ 的密度为

$$f_Y(\mathbf{y}) = f_X(g^{-1}(\mathbf{y})) |\det \mathbf{J}_{g^{-1}}(\mathbf{y})|,$$

其中 $\mathbf{J}_{g^{-1}}(\mathbf{y}) = D_{\mathbf{y}} g^{-1}(\mathbf{y})$ 是逆映射的 Jacobian 矩阵。等价地, 用正向 Jacobian $\mathbf{J}_g$ 写作

$$f_Y(\mathbf{y}) = \frac{f_X(g^{-1}(\mathbf{y}))}{|\det \mathbf{J}_g(\mathbf{x})|} \Big|_{\mathbf{x}=g^{-1}(\mathbf{y})}.$$

证明. 论证就是“概率守恒 + 积分换元”。任取像空间里的 Borel 集 B , 设其原像 $A = g^{-1}(B)$ 。事件 $\{\mathbf{Y} \in B\}$ 与 $\{\mathbf{X} \in A\}$ 是同一个事件, 故概率相等:

$$\mathbb{P}(\mathbf{Y} \in B) = \mathbb{P}(\mathbf{X} \in A) = \int_A f_X(\mathbf{x}) d\mathbf{x}.$$

对右边做积分换元 $\mathbf{x} = g^{-1}(\mathbf{y})$ 。多元微积分的换元公式给出体积元的变换

$$d\mathbf{x} = |\det \mathbf{J}_{g^{-1}}(\mathbf{y})| d\mathbf{y},$$

于是

$$\mathbb{P}(\mathbf{Y} \in B) = \int_B f_X(g^{-1}(\mathbf{y})) |\det \mathbf{J}_{g^{-1}}(\mathbf{y})| d\mathbf{y}.$$

这对一切 B 成立, 故被积函数就是 $\mathbf{Y}$ 的密度, 即定理的公式。两种写法的等价性来自逆函数定理 $\mathbf{J}_{g^{-1}}(\mathbf{y}) = \mathbf{J}_g(\mathbf{x})^{-1}$, 取行列式得 $|\det \mathbf{J}_{g^{-1}}| = 1/|\det \mathbf{J}_g|$ 。□

注 (绝对值不可丢)。

公式里是 $|\det \mathbf{J}|$ 而非 $\det \mathbf{J}$ 。行列式本身带符号，它编码了映射是否“翻转”了定向；但密度恒非负、概率不在乎定向，所以只取大小。这与第二十六章把积分换元写成 $dx = |g'(u)| du$ （一维情形）是同一回事——一维的 $|g'|$ 正是 1×1 Jacobian 行列式的绝对值。

图 27.3 把这件事画出来：原空间里一小块面积为 $du dv$ 的方块，被映射 T 送成像空间里的一个平行四边形，其面积恰好是 $|\det \mathbf{J}| du dv$ 。密度乘以这个面积才是落进该块的概率，两边的概率相等正是公式的内容。




图 27.3: 变量变换的几何。映射 g 把原空间一小块（面积 $du dv$ ）送成像空间的平行四边形（面积 $|\det \mathbf{J}| du dv$ ）。密度按这个面积比缩放，正是行列式作为“体积放大率”在概率上的体现。

例（线性变换下的密度）。

设 $\mathbf{X} \in \mathbb{R}^n$ 有密度 $f_{\mathbf{X}}$ ， $\mathbf{A}$ 为可逆矩阵、 $\mathbf{b} \in \mathbb{R}^n$ 常向量，令 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 。求 $f_{\mathbf{Y}}$ 。

解。

这里 $g(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ ，其 Jacobian 是常矩阵 $\mathbf{J}_g = \mathbf{A}$ ， $\det \mathbf{J}_g = \det \mathbf{A}$ 。逆映射 $\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$ 。代入公式：

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})).$$

线性映射的 Jacobian 处处是同一个 $\mathbf{A}$ ，所以缩放因子 $1/|\det \mathbf{A}|$ 是全局常数——这恰好与“线性映射把所有小块按同一倍率 $|\det \mathbf{A}|$ 放大”吻合。下一节的多元正态密度，正是把这条规则用在 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 上得到的。

27.5 卷积：独立和的分布

经济与计量里“求和”无处不在：样本和 $\sum_i X_i$ 、累积冲击、组合资产的损益。当被加的变量独立时，和的分布有一个干净的公式——卷积。它其实是变量变换公式的一个特例。

定理 27.7: 独立和的密度是卷积

设 $X \perp Y$, 密度分别为 f_X, f_Y , 令 $Z = X + Y$ 。则 Z 的密度为卷积

$$f_Z(z) = (f_X * f_Y)(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx.$$

证明. 做变换 $(X, Y) \mapsto (Z, W) = (X + Y, Y)$, 这是线性可逆映射, 逆为 $X = Z - W, Y = W$, Jacobian

$$\mathbf{J} = D_{(z,w)} \begin{pmatrix} z - w \\ w \end{pmatrix} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}, \quad |\det \mathbf{J}| = 1.$$

由变量变换公式 (缩放因子为 1) 及独立性 $f_{X,Y} = f_X f_Y$:

$$f_{Z,W}(z, w) = f_{X,Y}(z - w, w) = f_X(z - w) f_Y(w).$$

把多余的 W 积掉得边缘密度

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(z - w) f_Y(w) dw,$$

换积分变量即得卷积式。 □

几何上 (图 27.4), 求 $f_Z(z)$ 就是把联合密度沿直线 $x + y = z$ “扫一遍” 并累加: 固定 z , 让 (x, y) 跑遍该反对角线, 把 $f_{X,Y}(x, z - x)$ 沿线积分。 z 增大, 这条线平行地向右上方平移。




图 27.4: 卷积的几何。 $f_Z(z)$ 是把联合密度沿反对角线 $x + y = z$ 积分; z 增大时该线平行平移。点 $(x, z - x)$ 是积分变量沿线的代表位置。

例 (正态的可加性) .

设 $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ 、 $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ 且独立。求 $Z = X + Y$ 的分布。

解.

直接卷积要算一个高斯积分，可以做，但配方过程略繁。这里只报告结果并指出其结构： $Z \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。均值相加是期望的线性（无需独立）；方差相加用到 $\text{Cov}(X, Y) = 0$ （用到独立），正是 §27.3 的方差展开式；而和仍是正态这一点——卷积没有把分布族变出去——才是正态独有的“自再生”性质。它使得 iid 正态样本的任意线性组合（尤其是样本均值 $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ ）仍精确正态，这是有限样本下许多检验得以“精确”的根基。

卷积也解释了中心极限定理的“味道”：把许多独立小冲击相加，等价于把它们的密度反复卷积；卷积有“磨平”效应，反复卷积后形状趋向正态——这正是下一部分中心极限定理的直观来源。

27.6 多元正态分布

多元正态是整本计量的“中心枢纽”：它是中心极限定理的极限对象，因而是所有渐近分布理论的落点；它在线性运算下保持封闭，使得 OLS 这类线性估计量的分布可以精确刻画；它还有一串异常友好的性质，让本来困难的条件期望、独立性判定都变得平凡。

定义 27.8: 多元正态分布

随机向量 $\mathbf{X} \in \mathbb{R}^n$ 服从多元正态分布 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，其中 $\boldsymbol{\mu} \in \mathbb{R}^n$ 、 $\boldsymbol{\Sigma}$ 为 $n \times n$ 对称正定矩阵，若其密度为

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} (\det \boldsymbol{\Sigma})^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right).$$

此时 $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$ 、 $\text{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$ 。

这个密度不必硬记——它可以从标准正态推出来，过程恰好把本章的工具串成一条线。

从标准正态推出一一般密度。取 n 个独立的标准正态 $Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ ，堆成 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。由独立性，联合密度是各边缘之积：

$$f_{\mathbf{Z}}(\mathbf{z}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-z_i^2/2} = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2}\mathbf{z}^T \mathbf{z}}.$$

因 $\boldsymbol{\Sigma}$ 对称正定，由谱定理可作“矩阵平方根” $\boldsymbol{\Sigma}^{1/2}$ （对称正定，满足 $\boldsymbol{\Sigma}^{1/2} \boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Sigma}$ ）。定义线性变换

$$\mathbf{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2} \mathbf{Z}.$$

用上一节的线性变换密度公式，这里 $\mathbf{A} = \Sigma^{1/2}$ 、 $\mathbf{b} = \boldsymbol{\mu}$ ， $\det \mathbf{A} = (\det \Sigma)^{1/2}$ ，逆变换 $\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu})$ ，于是

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(\det \Sigma)^{1/2}} f_{\mathbf{Z}}(\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu})) = \frac{1}{(2\pi)^{n/2}(\det \Sigma)^{1/2}} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})},$$

末步用了 $\mathbf{z}^T \mathbf{z} = (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \boldsymbol{\mu}) = (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ 。这正是定义里的密度。多元正态不过是标准正态做了一次仿射变换——这句话就是它一切良好性质的总根。

多元正态 = 标准正态的仿射像

记住 $\mathbf{X} = \boldsymbol{\mu} + \Sigma^{1/2} \mathbf{Z}$ 这一个表示，多元正态的几乎所有性质都能一眼看出：仿射变换的复合还是仿射，所以正态的线性像还是正态；密度里 Σ^{-1} 决定的二次型等高线是椭球，主轴方向是 Σ 的特征向量（呼应图 27.2）；下面三条性质都是这个表示的直接推论。

多元正态的三条性质，是它在渐近统计里被反复调用的原因。

命题 27.9: 多元正态的三条核心性质

设 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ 。

1. 线性变换封闭：对常数矩阵 $\mathbf{A}$ （行满秩）与常向量 $\mathbf{b}$ ，

$$\mathbf{A}\mathbf{X} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^T).$$

每个边缘、每个线性组合 $\mathbf{a}^T \mathbf{X}$ 因此都是（一元）正态。

2. 不相关 $\implies$ 独立：若把 $\mathbf{X}$ 分块为 $(\mathbf{X}_1, \mathbf{X}_2)$ ，则

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0} \iff \mathbf{X}_1 \perp\!\!\!\perp \mathbf{X}_2.$$

3. 条件分布仍正态、条件期望线性：

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}(\boldsymbol{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

性质 1 与 2 的要点. 性质 1. 把 $\mathbf{X} = \boldsymbol{\mu} + \Sigma^{1/2} \mathbf{Z}$ 代入： $\mathbf{A}\mathbf{X} + \mathbf{b} = (\mathbf{A}\boldsymbol{\mu} + \mathbf{b}) + (\mathbf{A}\Sigma^{1/2})\mathbf{Z}$ ，仍是标准正态的仿射像，故仍正态；其均值、协方差由期望线性与 $\text{Var}(\mathbf{A}\mathbf{X}) = \mathbf{A}\Sigma\mathbf{A}^T$ 直接读出。

性质 2. “独立 $\implies$ 不相关”对任何分布都成立。反向是正态独有的：当 $\Sigma_{12} = \mathbf{0}$ 时 Σ 是分块对角的， Σ^{-1} 也分块对角，于是密度里的二次型 $(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ 裂成只含 $\mathbf{x}_1$ 的部分加只含 $\mathbf{x}_2$ 的部分，指数变成乘积、 $\det \Sigma = \det \Sigma_{11} \det \Sigma_{22}$ ，整个密度因式分解为 $f_1(\mathbf{x}_1)f_2(\mathbf{x}_2)$ ——这正是独立的定义。§27.3 那个 $Y = X^2$ 的反例说明此性质只对正态成立。□

注（条件期望为何“恰好”线性）。

性质 3 里条件均值 $\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$ 是 x_2 的线性（仿射）函数。这绝非巧合，而是回归理论的基石：当 $(Y, \mathbf{X})$ 联合正态时，最优预测 $E(Y | \mathbf{X})$ 精确地是线性回归函数，斜率 $\Sigma_{12}\Sigma_{22}^{-1}$ 正是总体回归系数。换言之，“线性回归设定正确”在联合正态下是定理而非假设。这个系数与第二十八章把条件期望当“投影”来理解的视角完全一致——它就是 Y 在 $\mathbf{X}$ 张成的空间上的投影。

27.7 它们通向何处

本章四件工具，几乎每一件都直接喂给后面的渐近统计与计量。

- **iid 抽样与抽样分布**。独立同分布是“样本”的数学定义；独立 $\implies$ 期望可乘、 $\implies$ 方差可加，是 $E(\bar{X}) = \mu$ 、 $\text{Var}(\bar{X}) = \sigma^2/n$ 这些起点的全部依据。把正态样本经变量变换，就推出 $\chi^2 = \sum Z_i^2$ 、 t 、 F 这三大抽样分布——它们都是“正态做变换”的产物。
- **中心极限定理（第三十二章）**。独立和的卷积“磨平”效应，其极限形态就是多元正态： $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ 。本章的多元正态正是为这个极限准备的“容器”。
- **Delta 法与连续映射（第三十三章）**。估计量常是某个渐近正态量的非线性变换 $g(\hat{\boldsymbol{\theta}})$ ；Delta 法把变量变换线性化——用 g 的 Jacobian 近似——从而 $\sqrt{n}(g(\hat{\boldsymbol{\theta}}) - g(\boldsymbol{\theta}_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{J}_g \boldsymbol{\Sigma} \mathbf{J}_g^T)$ 。这里出现的 $\mathbf{J}_g \boldsymbol{\Sigma} \mathbf{J}_g^T$ 正是本章线性变换方差法则与变量变换公式的合流。
- **回归（第二十八章及计量主干）**。联合正态下条件期望线性，使“线性回归”从一个建模假设升格为可证的事实；不相关即独立，让正态误差下的诸多正交性论证（如 OLS 估计量与残差独立）成立。

把这四件工具连起来看，会发现它们其实在讲同一个故事：多个随机变量的联合行为，最干净的情形是独立（拆成乘积）与正态（仿射封闭），而连接“已知分布”与“想要分布”的那座桥，永远是按 Jacobian 行列式缩放的变量变换。认清这一点，渐近统计里那一长串变换、卷积、协方差矩阵的演算，骨子里都是本章这几样东西在循环使用。

第二十八章 条件期望（作为投影）

用到的前置工具：内积、正交与投影定理（第三章）；概率空间、 σ -代数与测度（概率与测度部分）；随机变量与 Lebesgue 积分意义下的期望（同上）。

如果说隐函数定理是微观比较静态的“镇店之宝”，那么条件期望就是计量、宏观预期与博弈论信念这三处的共同地基。“给定已知信息，对未知量的最好猜测是什么”——这个问句几乎是整个经济计量学的母题：回归 $\mathbb{E}(Y|X)$ 是它，理性预期 $\mathbb{E}(p_{t+1}|\mathcal{F}_t)$ 是它，博弈中根据观察更新的信念是它，鞅与动态规划里“对下一期取期望”也是它。本章要讲的，正是把“最好的猜测”这件直觉的事，锻造成一个有定义、可计算、性质丰富的数学对象。

本章的主线是一句话：条件期望就是投影。读者在线性代数部分已经见过正交投影——把一个向量垂直地落到某个子空间上，得到“子空间里离它最近的点”。我们将看到，把“向量”换成“随机变量”、“子空间”换成“某组信息下可知的随机变量”、“欧氏距离”换成“均方误差”，那同一张“垂直落下”的图就重现了，而它的垂足正是条件期望。于是“最好的猜测”有了精确含义：均方意义下离真值最近的、且只依赖已知信息的那个预测。

28.1 从“给定信息的最好猜测”说起

设想要预测一个随机变量 Y （明天的销量、某人的工资、一项资产的回报）。如果手上什么信息都没有，最朴素的“单点预测”该取多少？一个自然的标准是让均方误差最小：在所有常数 c 里选一个使 $\mathbb{E}((Y - c)^2)$ 最小的。展开

$$\mathbb{E}((Y - c)^2) = \text{Var}(Y) + (\mathbb{E}(Y) - c)^2,$$

右边第一项与 c 无关，第二项在 $c = \mathbb{E}(Y)$ 时取零。于是无信息时的最优常数预测就是无条件期望 $\mathbb{E}(Y)$ 。这个小计算已经埋下全章的种子：“最好的预测”被定义成“均方最近”，而答案是某种期望。

现实里我们通常有信息。也许我们能观测到另一个变量 X （受教育年数、昨天的价格、一个信号），或者更一般地，能观测到“某些事件是否发生”所携带的全部信息。问题随之升级：在所有“可以用这些信息算出来”的预测 g （不再限于常数）里，哪一个的均方误差 $\mathbb{E}((Y - g)^2)$ 最小？

这个升级版问题的答案，就是条件期望。本章按“信息”的精细程度分三步走：先看最初等的“给定一个事件”与“给定一个离散变量”，它们用初等概率就能写出；再把

“信息”抽象成一个 σ -代数 $\mathcal{G}$ ，给出 Kolmogorov 的一般定义；最后亮出全章的统一视角——条件期望是 L^2 空间里向“ $\mathcal{G}$ -可测函数”子空间的正交投影，即均方最近的预测。

28.2 初等条件期望：给定事件、给定离散变量

最熟悉的起点是条件概率。给定一个概率为正的事件 B ，事件 A 的条件概率是

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

它把概率“重新标准化”到 B 内部。把这套重标准化用到随机变量上，就得到给定事件的条件期望。

定义 28.1: 给定事件的条件期望

设 $\mathbb{P}(B) > 0$ ，随机变量 X 可积。 X 给定事件 B 的条件期望定义为在 B 上重标准化后的平均：

$$\mathbb{E}(X|B) = \frac{\mathbb{E}(X \mathbf{1}_B)}{\mathbb{P}(B)},$$

其中 $\mathbf{1}_B$ 是 B 的示性函数。它就是“只在 B 发生的那些情形里、按条件概率重新加权”算出的 X 的平均值。

下一步，把“一个事件”换成“一个离散变量取各个值”。设 Z 是离散随机变量，取值 $z_1, z_2, \dots$ ，每个 $\{Z = z_k\}$ 概率为正。对每个 z_k ，可以问“在 $Z = z_k$ 这一支里 X 的平均是多少”，即 $\mathbb{E}(X|Z = z_k)$ 。把这些数按“ Z 实际取了哪个值”拼起来，就得到一个随机变量。

定义 28.2: 给定离散变量的条件期望

设 Z 离散、每个 $\{Z = z_k\}$ 概率为正。 X 给定 Z 的条件期望 $\mathbb{E}(X|Z)$ 是这样一随机变量：当 $Z(\omega) = z_k$ 时它取值

$$\mathbb{E}(X|Z = z_k) = \frac{\mathbb{E}(X \mathbf{1}_{\{Z=z_k\}})}{\mathbb{P}(Z = z_k)}.$$

换言之， $\mathbb{E}(X|Z) = g(Z)$ ，其中 $g(z_k) := \mathbb{E}(X|Z = z_k)$ 。

这里有一个关键的观念转变，值得停下来强调： $\mathbb{E}(X|Z)$ 不是一个数，而是一个随机变量——它是 Z 的函数。它的取值随 Z 落在哪一支而变；只有当你进一步对它再取一次期望、把所有支平均掉，才回到一个数 $\mathbb{E}(X)$ 。这正是下一节“塔性质”要讲的事，也是把条件期望理解成“投影”（投影的像是个向量，不是标量）的第一道伏笔。

两个层次的“条件期望”，别混淆

$\mathbb{E}(X|Z = z_k)$ 是一个数：在 Z 恰好等于 z_k 这一支里 X 的平均。

$\mathbb{E}(X|Z)$ 是一个随机变量：把上面那些数按 Z 的实际取值“装配”起来，得到的

Z 的函数。计量里写 $\mathbb{E}(Y|X)$ （回归函数）时，指的几乎总是后者——一条随 X 而变的曲线，而非单个数。

例（抛两枚均匀硬币，给定正面总数预测第一枚）。

抛两枚独立均匀硬币，正面记 1、反面记 0。设 X 为第一枚的结果， $Z = X_1 + X_2$ 为正面总数（取值 0, 1, 2）。求 $\mathbb{E}(X|Z)$ 。

解。

逐支计算 $g(z) = \mathbb{E}(X|Z=z)$ 。

$Z = 0$: 两枚都反面， $X = 0$ ，故 $g(0) = 0$ 。

$Z = 2$: 两枚都正面， $X = 1$ ，故 $g(2) = 1$ 。

$Z = 1$: 恰一枚正面，等概率地是“第一枚正”或“第二枚正”，故 X 以各 $1/2$ 取 1 与 0， $g(1) = \frac{1}{2}$ 。

于是

$$\mathbb{E}(X|Z) = g(Z) = \begin{cases} 0, & Z = 0, \\ \frac{1}{2}, & Z = 1, \\ 1, & Z = 2. \end{cases}$$

它确实是 Z 的函数、是随机变量。顺手验证一下塔性质： $\mathbb{E}(\mathbb{E}(X|Z)) = 0 \cdot \frac{1}{4} + \frac{1}{2} \cdot \frac{1}{2} + 1 \cdot \frac{1}{4} = \frac{1}{2} = \mathbb{E}(X)$ ，与第一枚正面概率 $1/2$ 吻合。

28.3 一般条件期望：Kolmogorov 的定义

初等定义有个硬伤：它要求事件概率为正、变量离散。可经济学里要条件化的对象常是连续的——给定一个连续协变量 X 预测 Y ，事件 $\{X = x\}$ 的概率往往为零，“除以 $\mathbb{P}(X = x) = 0$ ”当场失效。我们需要一个不依赖“概率为正”、能处理任意信息的定义。Kolmogorov 给出的办法漂亮而抽象：不再逐点定义，而是用两条“整体”性质把 $\mathbb{E}(X|\mathcal{G})$ 唯一钉住。

先要把“信息”本身数学化。一个 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ 代表“一组我们能够分辨的事件”——对 $\mathcal{G}$ 里的每个事件，我们都知道它到底发生了没有。“一个预测只依赖 $\mathcal{G}$ 中的信息”，精确地说就是它 $\mathcal{G}$ -可测：它在每个 $\mathcal{G}$ -事件上的取值是定下来的。

定义 28.3: 一般条件期望 (Kolmogorov)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, X 可积, $\mathcal{G} \subseteq \mathcal{F}$ 是子 σ -代数. X 关于 $\mathcal{G}$ 的条件期望是任一满足下列两条的随机变量, 记作 $\mathbb{E}(X | \mathcal{G})$:

- (i) 可测性. $\mathbb{E}(X | \mathcal{G})$ 是 $\mathcal{G}$ -可测的 (即 “只用 $\mathcal{G}$ 里的信息就能算出”).
- (ii) 平均匹配. 对每个事件 $G \in \mathcal{G}$,

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}) \mathbf{1}_G) = \mathbb{E}(X \mathbf{1}_G).$$

满足这两条的随机变量在 “几乎必然相等” 的意义下唯一. 当 $\mathcal{G} = \sigma(Z)$ (由变量 Z 生成的 σ -代数) 时, 记 $\mathbb{E}(X | Z) := \mathbb{E}(X | \sigma(Z))$.

这两条该怎么读? 条件 (i) 说预测只能用手头的信息; 条件 (ii) 说在任何一块 “信息能分辨出来” 的区域上, 预测的总账要和真值的总账对得上——你不必逐点猜对 X , 但在每个 $\mathcal{G}$ -事件上 “加总起来” 必须无误差. 把 (ii) 里的 G 取成 Ω , 立得 $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$, 这正是塔性质.

注 (这定义和初等定义对得上吗) .

对得上. 在离散情形 $\mathcal{G} = \sigma(Z)$, $\mathcal{G}$ -可测就是 “ Z 的函数”, 它在每个原子 $\{Z = z_k\}$ 上为常数. 把 (ii) 里的 G 取成单个原子 $\{Z = z_k\}$, 得 $\mathbb{E}(X | \mathcal{G}) \cdot \mathbb{P}(Z = z_k) = \mathbb{E}(X \mathbf{1}_{\{Z = z_k\}})$, 解出那个常数正是 $\mathbb{E}(X | Z = z_k) = \mathbb{E}(X \mathbf{1}_{\{Z = z_k\}}) / \mathbb{P}(Z = z_k)$. Kolmogorov 定义不过是把这套 “逐原子求平均” 推广到了没有原子 (连续) 的情形——这时 “在每个 $\mathcal{G}$ -事件上对账” 接管了 “除以原子概率” 的角色.

定义只说 “满足两条的随机变量唯一”, 却没说它存在. 存在性的标准证明走 Radon–Nikodym 定理, 下面只陈述其骨架、给直觉, 不逐行展开 (极重的测度论构造按本书惯例只点到为止).

存在性的来路: Radon–Nikodym

固定可积的 $X \geq 0$. 在 $\mathcal{G}$ 上定义一个新测度 $\nu(G) := \mathbb{E}(X \mathbf{1}_G)$ (“按 X 加权的概率”). 它对 $\mathbb{P}$ 绝对连续: $\mathbb{P}(G) = 0 \implies \nu(G) = 0$. Radon–Nikodym 定理断言, 这种绝对连续的测度必有一个 $\mathcal{G}$ -可测的 “密度” h , 使 $\nu(G) = \mathbb{E}(h \mathbf{1}_G)$ 对一切 $G \in \mathcal{G}$ 成立. 这个密度 h 恰好同时满足定义的 (i)(ii), 于是 $\mathbb{E}(X | \mathcal{G}) := h$. 一般的 X 拆成正负部分分别处理即可. 记住这一句: 条件期望就是 “ X 加权测度” 关于原测度、在信息 $\mathcal{G}$ 上的 Radon–Nikodym 导数.

28.4 核心视角: 条件期望是 L^2 投影

Kolmogorov 定义干净却抽象, “为什么是它” 并不直观. 本节给出全章最重要的解释: 当 X 平方可积时, $\mathbb{E}(X | \mathcal{G})$ 就是把 X 向 “ $\mathcal{G}$ -可测的平方可积随机变量” 这个子空间作的正交投影——也即均方意义下离 X 最近的、只依赖 $\mathcal{G}$ 信息的预测. 这一节把概

率论直接接回了投影定理（第三章）。

要套用投影定理，先要有内积空间。把平方可积的随机变量看成“向量”，定义内积

$$\langle X, Y \rangle := \mathbb{E}(XY),$$

则范数 $\|X\| = \sqrt{\mathbb{E}(X^2)}$ 度量“大小”，而“正交” $\langle X, Y \rangle = 0$ 就是 $\mathbb{E}(XY) = 0$ 。全体平方可积随机变量在这个内积下构成空间 $L^2(\Omega, \mathcal{F})$ ；其中“只用 $\mathcal{G}$ 信息”的那些（ $\mathcal{G}$ -可测且平方可积）构成子空间 $L^2(\Omega, \mathcal{G})$ 。它正是投影定理里的那个“子空间”，而 X 就是要投影的“向量”。

定理 28.4: 条件期望即正交投影

设 $\mathbb{E}(X^2) < \infty$ 。则 $\mathbb{E}(X|\mathcal{G})$ 是 X 在子空间 $L^2(\Omega, \mathcal{G})$ 上的正交投影；等价地，它是该子空间中使均方误差最小的元素：

$$\mathbb{E}(X|\mathcal{G}) = \arg \min_{\substack{W \text{ } \mathcal{G}\text{-可测} \\ \mathbb{E}(W^2) < \infty}} \mathbb{E}((X - W)^2).$$

其残差 $X - \mathbb{E}(X|\mathcal{G})$ 与每个 $\mathcal{G}$ -可测的平方可积 W 正交： $\mathbb{E}((X - \mathbb{E}(X|\mathcal{G}))W) = 0$ 。

证明. 投影定理（第三章）保证： X 在子空间 $L^2(\Omega, \mathcal{G})$ 上存在唯一的正交投影 PX ，其特征是残差垂直于整个子空间，即对一切 $\mathcal{G}$ -可测平方可积 W 有 $\mathbb{E}((X - PX)W) = 0$ 。我们只需验证：这条正交性恰好等价于 Kolmogorov 定义的 (i)(ii)。

PX 在子空间里，故 $\mathcal{G}$ -可测，(i) 满足。把正交性中的 W 取成示性函数 $\mathbf{1}_G$ ($G \in \mathcal{G}$ ，它 $\mathcal{G}$ -可测且有界故平方可积)：

$$\mathbb{E}((X - PX)\mathbf{1}_G) = 0 \iff \mathbb{E}(PX\mathbf{1}_G) = \mathbb{E}(X\mathbf{1}_G),$$

正是 (ii)。反过来，若某 $\mathcal{G}$ -可测的 W^* 满足 (ii)，则它与每个示性函数 $\mathbf{1}_G$ 的对账成立；由于 $\mathcal{G}$ -可测的简单函数是示性函数的线性组合、而它们在 $L^2(\Omega, \mathcal{G})$ 中稠密，对账由示性函数推广到整个子空间，即残差 $X - W^*$ 与子空间正交。于是 $W^* = PX$ 。故 Kolmogorov 的条件期望与 L^2 投影是同一个对象。

“最近”由投影定理的最近性刻画直接得到：正交投影 PX 是子空间中离 X 最近的点，“距离”在此即 $\|X - W\| = \sqrt{\mathbb{E}((X - W)^2)}$ ，故 PX 最小化均方误差。□

图 28.1 与第三章 OLS 的几何全貌图逐元素对应：那里的 $\mathbf{y}$ 在此是 X ，那里的列空间 $\text{col}(\mathbf{X})$ 在此是 $\mathcal{G}$ -可测函数子空间，那里的拟合值 $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$ 在此是 $\mathbb{E}(X|\mathcal{G})$ ，那里的残差 $\mathbf{e}$ 在此是预测误差。OLS 是这张图在有限维欧氏空间里的特例（投影到几条回归元张成的有限维子空间）；条件期望是它在随机变量空间里的版本（投影到一个可能无穷维的子空间）。




图 28.1: 条件期望作为 L^2 投影: 把随机变量 X 垂直地落到“ $\mathcal{G}$ -可测函数”子空间 $L^2(\Omega, \mathcal{G})$ 上, 垂足就是 $\mathbb{E}(X|\mathcal{G})$; 残差 $X - \mathbb{E}(X|\mathcal{G})$ 正交于整个子空间, 对应均方误差最小。与第三章 OLS 的投影图是同一张图, 只是把欧氏空间换成了随机变量空间。

为什么“投影”视角值得记住

三件事一次到手。其一, 含义: $\mathbb{E}(X|\mathcal{G})$ 就是“用 $\mathcal{G}$ 信息能给出的均方最优预测”, “最好的猜测”从此有了精确定义。其二, 性质: 投影是线性算子、幂等（投影里的东西再投不动）、且“塔性质”不过是“先投到大子空间再投到小子空间 = 直接投到小子空间”——下一节将看到这些性质几乎都能从投影一眼读出。其三, 统一: OLS、最优线性预测、GLS、条件期望、卡尔曼滤波里的更新, 全是同一个正交投影换了空间; 学一次, 处处通用。

注 (L^2 之外: 靠稠密延拓到 L^1)。

投影视角要求 $\mathbb{E}(X^2) < \infty$ 。但条件期望对一切可积 ($\mathbb{E}(|X|) < \infty$) 的 X 都有定义——这正是 Kolmogorov 定义和 Radon-Nikodym 路线的好处, 它们不需要二阶矩。两条路线在 L^2 上给出同一个对象; 超出 L^2 时, 可用条件 Jensen 不等式 (下节) 控制 $\|\cdot\|_1$ 范数, 把 L^2 上的结论由稠密性延拓到 L^1 。本书在直觉层面以 L^2 投影为主图, 需要完全一般性时回到 Kolmogorov 的两条公理即可。

28.5 性质: 塔性质、提出已知量、条件 Jensen

条件期望的威力, 一大半来自一组干净的运算性质。它们既可由 Kolmogorov 公理直接验证, 又能从“投影”图里看个明白。下面给出最常用的几条。

命题 28.5: 条件期望的基本性质

设相关变量都可积, $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ 为嵌套的子 σ -代数。则（均在“几乎必然”意义下）：

- (a) 线性。 $\mathbb{E}(aX + bY | \mathcal{G}) = a\mathbb{E}(X | \mathcal{G}) + b\mathbb{E}(Y | \mathcal{G})$ 。
- (b) 提出已知量。若 Z 是 $\mathcal{G}$ -可测的（“在 $\mathcal{G}$ 下已知”）且 ZX 可积, 则 $\mathbb{E}(ZX | \mathcal{G}) = Z\mathbb{E}(X | \mathcal{G})$ 。
- (c) 塔性质（迭代期望）。 $\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$ ；特别地取 $\mathcal{H} = \{\emptyset, \Omega\}$ 得 $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$ 。
- (d) 独立则退化为无条件。若 X 与 $\mathcal{G}$ 独立, 则 $\mathbb{E}(X | \mathcal{G}) = \mathbb{E}(X)$ 。
- (e) 条件 Jensen。若 φ 为凸函数且 $\varphi(X)$ 可积, 则 $\varphi(\mathbb{E}(X | \mathcal{G})) \leq \mathbb{E}(\varphi(X) | \mathcal{G})$ 。

证明. (a) **线性**：投影是线性算子, 故立得；也可直接核验——右边 $\mathcal{G}$ -可测, 且对每个 G , $\mathbb{E}((a\mathbb{E}(X | \mathcal{G}) + b\mathbb{E}(Y | \mathcal{G}))\mathbf{1}_G) = a\mathbb{E}(X\mathbf{1}_G) + b\mathbb{E}(Y\mathbf{1}_G) = \mathbb{E}((aX + bY)\mathbf{1}_G)$, 符合公理 (ii)。

(b) **提出已知量**：右边 $Z\mathbb{E}(X | \mathcal{G})$ 是两个 $\mathcal{G}$ -可测量之积, 仍 $\mathcal{G}$ -可测, (i) 成立。验 (ii)：要证对一切 $G \in \mathcal{G}$, $\mathbb{E}(Z\mathbb{E}(X | \mathcal{G})\mathbf{1}_G) = \mathbb{E}(ZX\mathbf{1}_G)$ 。当 $Z = \mathbf{1}_{G'}$ ($G' \in \mathcal{G}$) 时, 左边 = $\mathbb{E}(\mathbb{E}(X | \mathcal{G})\mathbf{1}_{G \cap G'}) = \mathbb{E}(X\mathbf{1}_{G \cap G'}) = \mathbb{E}(ZX\mathbf{1}_G)$, 对账成立。由线性推广到 $\mathcal{G}$ -可测简单函数, 再由单调收敛推广到一般 $\mathcal{G}$ -可测 Z 。直觉上：在 $\mathcal{G}$ 下 Z 已是“已知常数”, 常数自然可以提到期望外。

(c) **塔性质**：记 $W = \mathbb{E}(X | \mathcal{G})$ 。要证 $\mathbb{E}(W | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$ 。右边 $\mathcal{H}$ -可测, (i) 满足。验 (ii)：对每个 $H \in \mathcal{H}$, 因 $\mathcal{H} \subseteq \mathcal{G}$ 故 $H \in \mathcal{G}$, 于是

$$\mathbb{E}(W\mathbf{1}_H) = \mathbb{E}(\mathbb{E}(X | \mathcal{G})\mathbf{1}_H) = \mathbb{E}(X\mathbf{1}_H),$$

末步用了 $W = \mathbb{E}(X | \mathcal{G})$ 的公理 (ii) (H 当 $\mathcal{G}$ -事件用)。这恰是 $\mathbb{E}(X | \mathcal{H})$ 该满足的对账, 故 $\mathbb{E}(W | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$ 。

(d) **独立**：常数 $\mathbb{E}(X)$ 平凡地 $\mathcal{G}$ -可测。验 (ii)：由独立性 $\mathbb{E}(X\mathbf{1}_G) = \mathbb{E}(X)\mathbb{P}(G) = \mathbb{E}(\mathbb{E}(X)\mathbf{1}_G)$, 对一切 $G \in \mathcal{G}$ 成立。

(e) **条件 Jensen**：凸函数 φ 在任一点 a 处有支撑线 $\varphi(x) \geq \varphi(a) + \lambda(a)(x - a)$ 。取 $a = \mathbb{E}(X | \mathcal{G})$ (它 $\mathcal{G}$ -可测), 代 $x = X$ ：

$$\varphi(X) \geq \varphi(\mathbb{E}(X | \mathcal{G})) + \lambda(\mathbb{E}(X | \mathcal{G}))(X - \mathbb{E}(X | \mathcal{G})).$$

两边对 $\mathcal{G}$ 取条件期望, 用线性与“提出已知量” ($\varphi(\mathbb{E}(X | \mathcal{G}))$ 与 $\lambda(\mathbb{E}(X | \mathcal{G}))$ 都 $\mathcal{G}$ -可测), 第二项的条件期望因子 $\mathbb{E}(X - \mathbb{E}(X | \mathcal{G}) | \mathcal{G}) = 0$ 而消失, 余下 $\mathbb{E}(\varphi(X) | \mathcal{G}) \geq \varphi(\mathbb{E}(X | \mathcal{G}))$ 。□

塔性质是其中最常被调用的一条, 值得用投影的语言再说一遍, 因为那个画面一旦记住就再不会忘。

塔性质 = “粗投影吃掉细投影”

信息越多，子空间越大。 $\mathcal{H} \subseteq \mathcal{G}$ 意味着 $L^2(\Omega, \mathcal{H}) \subseteq L^2(\Omega, \mathcal{G})$ （小子空间套在大子空间里）。塔性质说的是：先把 X 投到大子空间（得 $\mathbb{E}(X | \mathcal{G})$ ），再把结果投到小子空间，等于一步到位直接投到小子空间。这在欧氏几何里是显然的：先投到一张大平面、再投到平面里的一条线，和直接投到那条线落点相同。“信息可以逐步丢弃，顺序不影响最终的粗预测”——迭代期望定律的全部内容，就是这句几何常识。

图 28.2 把塔性质画在最具体的离散情形： $\mathcal{G}$ 把样本空间划成若干“原子”， $\mathbb{E}(X | \mathcal{G})$ 在每个原子上取 X 在该原子内的平均（一条阶梯），而对这些阶梯再按原子概率加权平均，就抹平成一条水平线 $\mathbb{E}(X)$ ——这正是 $\mathcal{H} = \{\emptyset, \Omega\}$ （最粗信息）时的塔性质。




图 28.2: 离散情形下的条件期望与塔性质： $\mathcal{G}$ 把样本空间分成原子 $G_1, \dots, G_4$ ， $\mathbb{E}(X | \mathcal{G})$ （蓝色阶梯）在每个原子上等于 X 在该原子内的平均（散点围绕阶梯上下对称）；把这条阶梯按原子概率再平均一次，抹平成全局均值 $\mathbb{E}(X)$ （红色虚线），即 $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$ 。

例（用塔性质算复合期望）。

设某商品的需求量 X 依赖于市场状态 Z ：景气（ $Z = 1$ ，概率 0.4）时 $\mathbb{E}(X | Z = 1) = 100$ ；萧条（ $Z = 0$ ，概率 0.6）时 $\mathbb{E}(X | Z = 0) = 60$ 。求总体平均需求 $\mathbb{E}(X)$ 。

解。

直接用塔性质 $\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X | Z))$ ，把条件均值按状态概率加权：

$$\mathbb{E}(X) = \mathbb{E}(X | Z = 1) \mathbb{P}(Z = 1) + \mathbb{E}(X | Z = 0) \mathbb{P}(Z = 0) = 100 \cdot 0.4 + 60 \cdot 0.6 = 76.$$

这就是计量与决策里无处不在的“分层再加总”：先在每一层（状态）内算条件平均，再按各层概率把它们平均掉。看似琐碎，却是全期望公式、全方差分解、乃至动态规划“向后归纳”的基本动作。

注（全方差公式：方差的勾股分解）。

塔性质有个孪生兄弟，专管方差：

$$\text{Var}(X) = \mathbb{E}(\text{Var}(X | \mathcal{G})) + \text{Var}(\mathbb{E}(X | \mathcal{G})).$$

读作“总方差 = 组内方差的平均 + 组间（条件均值的）方差”。它正是第三章那条勾股分解 $\|\mathbf{y} - \bar{\mathbf{y}}\mathbf{1}\|^2 = \|\mathbf{e}\|^2 + \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\mathbf{1}\|^2$ 在随机变量空间里的化身： X 减去其条件均值（残差，贡献组内方差）与条件均值减去总均值（已解释部分，贡献组间方差）正交，方差像长度平方一样可加。ANOVA、随机效应模型、信息价值的度量都建在这条分解上。

28.6 回归函数： $\mathbb{E}(Y | X)$ 与它的去处

把上面的抽象机器对准计量经济学最核心的对象，一切落地。给定协变量向量 X 预测结果 Y ，“均方最优预测”就是条件期望 $\mathbb{E}(Y | X)$ ；当 $\mathcal{G} = \sigma(X)$ 时它必是 X 的某个（可测）函数。

定义 28.6: 回归函数

Y 关于 X 的回归函数（又称条件期望函数，CEF）是

$$m(x) := \mathbb{E}(Y | X = x),$$

而随机变量 $\mathbb{E}(Y | X) = m(X)$ 。它是所有 X 的函数中均方误差最小者： $m = \arg \min_g \mathbb{E}((Y - g(X))^2)$ 。

这把“回归”从“画一条直线”的操作，提升为一个不依赖任何函数形式假设的总体对象： $m(x)$ 是真实世界里“ $X = x$ 那一群体的 Y 平均”。图 28.3 给出它的画面——一条穿过散点云的曲线，在每个 x 处落在该竖直切片里 Y 的均值上。




图 28.3: 回归函数 $m(x) = \mathbb{E}(Y | X = x)$ 是穿过散点云的“条件均值曲线”：在每个 x 处，它落在该竖直切片内 Y 取值的平均上（图中 x_0 处的红点即该切片的条件均值）。计量里的“回归”本质上就是在估计这条曲线。

回归函数 m 一般不是线性的。但当我们把预测限制在 X 的线性函数里时，得到的

最优线性预测正是总体版的 OLS——这把本章和第三章扣得严丝合缝。

OLS 是“投影到线性子空间”的特例

全条件期望 $m(X) = \mathbb{E}(Y|X)$ 是把 Y 投到全体 X -可测函数（一个大子空间）上。若改投到其中更小的线性子空间 $\{x^T\beta : \beta \in \mathbb{R}^k\}$ ，得到的是**最优线性预测**，其系数

$$\beta^* = \mathbb{E}(XX^T)^{-1} \mathbb{E}(XY)$$

正是第三章 OLS 公式 $(X^T X)^{-1} X^T y$ 的总体对应（样本矩换成总体矩）。两者是同一个正交投影，只是子空间一大一小：当真实 m 恰好线性时二者重合，否则 OLS 给的是 m 的最佳线性逼近。这解释了“回归系数”的总体含义，也说明了为什么误设线性时 OLS 仍是“最好的线性近似”。

最后，把这条工具线索引向它在各门核心课里的落点。

条件期望通向何处

计量：回归与条件矩的全部理论以 $\mathbb{E}(Y|X)$ 为对象；工具变量法的识别条件 $\mathbb{E}(u|Z) = 0$ （残差对工具的条件期望为零）就是一句正交性；GMM 把模型写成一族条件矩约束 $\mathbb{E}(g(\cdot)|Z) = 0$ 。

宏观：理性预期假设个体的主观预期等于真实的条件期望 $\mathbb{E}(p_{t+1}|\mathcal{F}_t)$ ；动态规划里 Bellman 方程对未来值函数“取条件期望” $\mathbb{E}(V(s_{t+1})|s_t)$ ，正是本章的运算。博弈论 / 决策论：贝叶斯更新后的信念就是给定观察的条件分布，其期望即条件期望——这是下一章“贝叶斯更新与信息”的主角。

随机过程：鞅的定义 $\mathbb{E}(X_{t+1}|\mathcal{F}_t) = X_t$ （“给定至今信息，下一期的最优预测就是当前值”）逐字是条件期望；它撑起了资产定价的无套利、随机积分与最优停时的整套理论。

一个对象，四门核心课。条件期望之所以能同时是回归、是预期、是信念、是鞅，正因为它们共享同一个数学内核——向“已知信息”子空间的正交投影。认清了这条“均方最优预测”的主线，这许多看似分散的工具便收束成了同一把钥匙。

第二十九章 贝叶斯更新与信息

用到的前置工具：条件期望（上一章，作为投影理解）；概率空间、 σ -代数与测度（第二十四章）；条件概率与独立性（第二十七章）；正态分布的密度与配方。

经济学里有一整类问题，主角不是“价格”或“产量”，而是**信念**。一个买家不知道二手车是好是坏，但卖家的报价透露了一点风声；一个雇主看不见求职者的能力，但学历是个信号；中央银行不确定经济处在什么状态，但每个月的数据都在挤牙膏式地泄露真相；一个计量经济学家手上有参数 θ 的先验看法，而样本一到，看法就该随之调整。这些情形的共同结构是：决策者对某个未知量持有一个**概率性的看法**，然后观察到一条信息，需要把看法**更新**成一个新的概率分布。贝叶斯定理就是做这件事的唯一一致的算法。

本章按使用者的顺序展开：先把贝叶斯定理的离散与连续两个版本讲清楚——它们其实是同一句话的两种写法；再引入共轭先验，说明为什么某些先验能让更新变成纯代数、并算两个最常用的例子（Beta-二项、正态-正态）；接着用 σ -代数把“信息”本身形式化，说明“信息更多”精确地等于“ σ -代数更细”；然后转向博弈论，看信号如何更新信念；最后点出一个深刻而朴素的事实——**后验信念是一个鞅**，也就是“你没法预先知道自己将被说服往哪边”。这些机制是不完全信息博弈、信息经济学、宏观学习与贝叶斯计量共同的发动机。

29.1 贝叶斯定理：把看法翻过来

29.1.1 离散形式

贝叶斯定理没有任何新内容，它只是条件概率定义的一个重排。对两个事件 A, B （设 $\mathbb{P}(B) > 0$ ），条件概率定义为

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

把交集 $\mathbb{P}(A \cap B)$ 用两种方式拆开—— $\mathbb{P}(A|B)\mathbb{P}(B)$ 与 $\mathbb{P}(B|A)\mathbb{P}(A)$ ——令二者相等，立刻得到

定理 29.1: 贝叶斯定理 (离散)

设 $\{H_1, \dots, H_k\}$ 是样本空间的一个划分 (互斥且穷尽, 各 $\mathbb{P}(H_i) > 0$), E 为一个 $\mathbb{P}(E) > 0$ 的事件。则对每个 i ,

$$\mathbb{P}(H_i | E) = \frac{\mathbb{P}(E | H_i) \mathbb{P}(H_i)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E | H_i) \mathbb{P}(H_i)}{\sum_{j=1}^k \mathbb{P}(E | H_j) \mathbb{P}(H_j)}.$$

这里 H_i 是“假设”(未知世界的诸种可能状态), E 是观察到的“证据”。分母用的是全概率公式 $\mathbb{P}(E) = \sum_j \mathbb{P}(E | H_j) \mathbb{P}(H_j)$, 它把 E 的总概率沿所有假设展开。这个公式的全部作用, 是把你容易写下的方向 (在每个假设下证据出现的概率 $\mathbb{P}(E | H_i)$) 翻转成你真正想要的方向 (看到证据后每个假设的概率 $\mathbb{P}(H_i | E)$)。

贝叶斯定理的四个名字

把上式按比例读, 是理解一切贝叶斯推断的关键:

$$\underbrace{\mathbb{P}(H_i | E)}_{\text{后验}} \propto \underbrace{\mathbb{P}(E | H_i)}_{\text{似然}} \times \underbrace{\mathbb{P}(H_i)}_{\text{先验}}.$$

先验是看到证据前的看法, **似然**是“这个假设有多能解释已见到的证据”, **后验**是更新后的看法。分母 $\mathbb{P}(E)$ 不依赖 i , 只是把右边归一化成一个概率分布的常数——所以更新的方向与相对强度全在“似然 $\times$ 先验”里, 分母只管“凑成 1”。记住“后验 $\propto$ 似然 $\times$ 先验”, 比记那个带分母的完整公式有用得多。

例 (疾病检测: 为什么阳性不等于患病) .

某病在人群中患病率 $\mathbb{P}(H) = 0.01$ 。一种检测对病人有 99% 的灵敏度 ($\mathbb{P}(E | H) = 0.99$), 对健康人有 5% 的假阳性率 ($\mathbb{P}(E | H^c) = 0.05$)。一个人检测呈阳性 (事件 E), 他真的患病的概率 $\mathbb{P}(H | E)$ 是多少?

解.

直接套公式:

$$\begin{aligned} \mathbb{P}(H | E) &= \frac{\mathbb{P}(E | H) \mathbb{P}(H)}{\mathbb{P}(E | H) \mathbb{P}(H) + \mathbb{P}(E | H^c) \mathbb{P}(H^c)} \\ &= \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} = \frac{0.0099}{0.0099 + 0.0495} \approx 0.167. \end{aligned}$$

阳性者中真正患病的不到 17%。直觉上的“99% 准”之所以骗人, 是因为它忽略了先验: 健康人是病人的 99 倍, 哪怕每个健康人只有 5% 概率误报, 误报的绝对数量 (0.0495) 仍远超真阳性 (0.0099)。这正是先验的力量——它是贝叶斯更新里“忽略不得”的那一项, 也是直觉最常出错的地方。

29.1.2 连续形式：后验 $\propto$ 似然 $\times$ 先验

经济学里未知量常常是连续的参数 θ （一枚硬币的正面概率、一个分布的均值、需求弹性……）。这时“划分”变成 θ 的取值连续区间，概率质量换成概率密度，求和换成积分，但那句口诀一字不改。

定理 29.2: 贝叶斯定理（连续 / 密度形式）

设未知参数 θ 有先验密度 $\pi(\theta)$ ，数据 x 在给定 θ 下的条件密度（即似然）为 $f(x | \theta) = L(\theta; x)$ 。则 θ 的后验密度为

$$\pi(\theta | x) = \frac{f(x | \theta) \pi(\theta)}{\int f(x | \theta') \pi(\theta') d\theta'} \propto L(\theta; x) \pi(\theta).$$

分母 $m(x) = \int f(x | \theta') \pi(\theta') d\theta'$ 称为边际似然（证据），是关于 θ 的常数。

注（为什么实践中可以盯着比例号不放）。

分母 $m(x)$ 往往是个难算的积分，但它不依赖 θ 。许多时候我们根本不必算它：先把 $L(\theta; x)\pi(\theta)$ 写出来，认出它正比于某个已知分布的密度核，再补上那个分布该有的归一化常数即可。下一节的共轭先验把这套“认核”的手法用到极致——更新退化成对参数做加减法。 $m(x)$ 本身也不是废料：在模型比较里它就是“这个模型整体上多能解释数据”的度量（贝叶斯因子的成分）。

多个观测如何累积？若数据 $x_1, \dots, x_n$ 在给定 θ 下条件独立同分布，似然就是连乘 $L(\theta) = \prod_{i=1}^n f(x_i | \theta)$ 。一个等价而更能说明问题的看法是：贝叶斯更新可以串行进行——今天的后验恰好充当明天的先验。

贝叶斯更新是可迭代的，且与数据次序无关

把前 $n-1$ 个观测处理完得到的后验 $\pi(\theta | x_{1:n-1})$ 当作先验，再乘上第 n 个观测的似然 $f(x_n | \theta)$ ，得到的后验

$$\pi(\theta | x_{1:n}) \propto f(x_n | \theta) \pi(\theta | x_{1:n-1})$$

与一次性用全部数据 $\propto \prod_i f(x_i | \theta) \pi(\theta)$ 完全相同。于是信念的更新是递归的（这正是卡尔曼滤波与宏观学习模型的运作方式：来一个新数据点，就把信念往前推一步），而且——因为乘法可交换——最终后验不依赖数据到达的先后顺序，只依赖见到了哪些数据。

29.2 共轭先验：让更新变成代数

一般而言后验是个新的、未必有名字的分布，分母那个积分也未必算得出。但若先验选得“聪明”，似然乘上先验后仍落在同一个分布族里，更新就只是把先验的参数挪一

挪。

定义 29.3: 共轭先验

对一个给定的似然族 $\{f(x|\theta)\}$, 若先验 $\pi(\theta)$ 与后验 $\pi(\theta|x)$ 属于同一个参数化分布族, 则称该先验族为这一似然的共轭先验族。

共轭性不是天降的巧合, 而是似然函数作为 θ 的函数其“形状”被先验复刻的结果: 只要先验的密度核与似然的核是同一种代数形式, 二者相乘后形式不变, 更新自然退化为参数的加减。下面两例是全经济学用得最多的。

29.2.1 Beta—二项: 更新就是数数

设未知量是一枚硬币 (或“成功率”、“违约率”、“某政策被支持的比例”) 的正面概率 $\theta \in [0, 1]$ 。先验取 $\text{Beta}(\alpha, \beta)$, 其密度核为

$$\pi(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}.$$

观测 n 次独立投掷, 得到 s 次正面、 $n-s$ 次反面。二项似然的核 (把 $\binom{n}{s}$ 这种不含 θ 的常数丢进比例号) 是

$$L(\theta) \propto \theta^s(1-\theta)^{n-s}.$$

两者相乘:

$$\pi(\theta|s) \propto \theta^s(1-\theta)^{n-s} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{(\alpha+s)-1}(1-\theta)^{(\beta+n-s)-1}.$$

这正是 $\text{Beta}(\alpha+s, \beta+n-s)$ 的核。于是

命题 29.4: Beta—二项更新

若先验为 $\theta \sim \text{Beta}(\alpha, \beta)$, 观测到 s 次成功、 $f = n-s$ 次失败, 则后验为

$$\theta | \text{数据} \sim \text{Beta}(\alpha+s, \beta+f).$$

更新法则美到近乎透明: 见一次成功, 把第一个参数加一; 见一次失败, 把第二个参数加一。先验参数 (α, β) 因此可以解读为“伪计数”——仿佛你在看真数据之前, 已经“虚拟地”见过 $\alpha-1$ 次成功、 $\beta-1$ 次失败。后验均值

$$\mathbb{E}(\theta | \text{数据}) = \frac{\alpha+s}{\alpha+\beta+n}$$

是先验均值 $\frac{\alpha}{\alpha+\beta}$ 与样本频率 $\frac{s}{n}$ 的加权平均; 数据越多 (n 越大), 权重越偏向数据, 后验也越集中。图 29.1 把这个“越学越窄、众数随证据移动”的过程画了出来。

注 (无信息先验与拉普拉斯接续律)。

取 $\alpha = \beta = 1$ 即 $[0, 1]$ 上的均匀分布 (“无信息”先验)。此时观测 s 次成功、 $n-s$ 次失败后, 后验均值 $\frac{s+1}{n+2}$ 正是历史上著名的“拉普拉斯接续律”。它给“到目前为止




图 29.1: Beta-二项更新中后验密度的演化。先验 $\text{Beta}(2,2)$ 平而宽；随观测增多，后验既向数据所示的频率（这里正面偏多）移动，又越来越窄——证据越多，信念越笃定。三条曲线的众数分别约在 0.5, 0.67, 0.72。

全是成功”（ $s = n$ ）的情形一个不为 1 的预测 $\frac{n+1}{n+2}$ ——朴素频率会鲁莽地断言“下次必成”，贝叶斯则因先验的存在而留有余地。

29.2.2 正态-正态：精度相加、均值加权

设未知量是一个连续参数 μ （某资产的真实预期收益、某地区的真实平均工资、状态变量的真值），观测带有正态噪声。这是宏观学习与卡尔曼滤波的核心结构。

假设 29.5: 正态-正态模型

先验 $\mu \sim \mathcal{N}(\mu_0, \tau_0^2)$ 。给定 μ ，观测一个数据点 $y \sim \mathcal{N}(\mu, \sigma^2)$ ，其中观测方差 σ^2 已知。

写出后验的核（把不含 μ 的因子统统并入比例号）：

$$\pi(\mu | y) \propto \exp\left[-\frac{(y - \mu)^2}{2\sigma^2}\right] \exp\left[-\frac{(\mu - \mu_0)^2}{2\tau_0^2}\right].$$

指数上是关于 μ 的二次式，所以后验必是正态；剩下的只是配方找出它的均值与方差。把两个二次式中的 μ^2 与 μ 项归并：

$$-\frac{1}{2} \left[\left(\frac{1}{\sigma^2} + \frac{1}{\tau_0^2} \right) \mu^2 - 2 \left(\frac{y}{\sigma^2} + \frac{\mu_0}{\tau_0^2} \right) \mu \right] + \text{常数}.$$

与 $\mathcal{N}(\mu_1, \tau_1^2)$ 的核 $-\frac{1}{2\tau_1^2}(\mu - \mu_1)^2 = -\frac{1}{2} \left(\frac{1}{\tau_1^2} \mu^2 - \frac{2\mu_1}{\tau_1^2} \mu \right) + \text{常数}$ 逐项比对系数，立刻读出后验参数。引入精度（方差的倒数） $\rho \equiv 1/\sigma^2$ 、 $\rho_0 \equiv 1/\tau_0^2$ 后，结论格外干净：

命题 29.6: 正态-正态更新

在上述假设下，后验为 $\mu | y \sim \mathcal{N}(\mu_1, \tau_1^2)$ ，其中

$$\underbrace{\frac{1}{\tau_1^2}}_{\rho_1} = \underbrace{\frac{1}{\tau_0^2}}_{\rho_0} + \underbrace{\frac{1}{\sigma^2}}_{\rho}, \quad \mu_1 = \frac{\rho_0 \mu_0 + \rho y}{\rho_0 + \rho} = \frac{\tau_0^{-2} \mu_0 + \sigma^{-2} y}{\tau_0^{-2} + \sigma^{-2}}.$$

这两个式子值得刻进脑子。**精度相加**：后验精度等于先验精度加数据精度——信息是可叠加的“确定性”。**均值是按精度加权的平均**：后验均值落在先验均值 μ_0 与观测 y 之间，谁的精度高就更靠近谁。先验越散 (τ_0^2 大、 ρ_0 小)，后验越被数据牵着走；观测噪声越大 (σ^2 大、 ρ 小)，后验越守着先验不动。图 29.2 画的正是这件事：后验夹在先验与似然之间、且比两者都更尖。




图 29.2: 正态-正态更新。后验均值 μ_1 是先验均值 μ_0 与观测 y 的精度加权平均，必落在二者之间（此处数据精度高于先验，故 μ_1 更靠近 y ）；后验精度是二者之和，故后验比先验和似然都更尖。

注（这就是卡尔曼滤波的一步）。

把上式中的“一个观测”换成一批观测的均值 $\bar{y}$ （其精度为 n/σ^2 ），再让 μ 随时间按某个状态方程演化，把“今天的后验”当“明天的先验”反复迭代，正态-正态更新就长成了**卡尔曼滤波**：每一步都是“预测—观测—按精度加权地修正”。宏观学习模型（agent 用过去数据估计未知参数、再据此决策）的递归核心，往往就是这个公式。

29.3 信息的语言： σ -代数

到此我们一直在更新关于参数的分布。但“信息”本身——你知道什么、能分辨什么——也需要一个数学对象来承载，尤其在博弈论与动态模型里，“谁在何时知道什么”是问题的全部。这个对象就是 σ -代数（第二十四章已作为可测性的载体引入；这里给它一个“信息”的解读）。

直觉是这样的：你掌握的信息，等于你能回答的所有“是非问句”的集合。能不能分辨“状态落在集合 A 里还是 A 外”？若能， A 就是你信息结构中的一个“可知事件”。所有这些可知事件构成一个对补集、可数并封闭的集类——一个 σ -代数。

σ -代数就是“可分辨的事件”之集

把 σ -代数 $\mathcal{F} \subseteq 2^\Omega$ 读作“持有信息 $\mathcal{F}$ 的人能够分辨的事件全体”。 $A \in \mathcal{F}$ 意味着此人能判断真实状态是否落在 A 中。封闭性恰好对应推理的封闭性：若你能分辨 A ，就能分辨它的反面 A^c （否定）；若你能分辨 A 与 B ，就能分辨 $A \cup B$ （析取）。一个随机变量 X 关于 $\mathcal{F}$ 可测，正是说“知道 $\mathcal{F}$ 的人就知道 X 的取值”。

由此，“信息多少”有了精确的比较标准：

定义 29.7: 信息的精粗 (σ -代数的细化)

设 $\mathcal{G}, \mathcal{F}$ 都是 Ω 上的 σ -代数。若 $\mathcal{G} \subseteq \mathcal{F}$ ，则称 $\mathcal{F}$ 比 $\mathcal{G}$ 更细 ($\mathcal{G}$ 比 $\mathcal{F}$ 更粗)。此时凡 $\mathcal{G}$ 能分辨的事件 $\mathcal{F}$ 都能分辨，故“ $\mathcal{F}$ 携带的信息不少于 $\mathcal{G}$ ”。

最干净的图景是把信息看成对 Ω 的一个划分：你知道真实状态落在划分的哪一块，但块内无法再细分。信息变多，等于把某些块进一步切碎——划分变细，对应的 σ -代数随之变细，能分辨的事件随之变多（图 29.3）。




图 29.3: 信息越多 $\Rightarrow$ 划分越细 $\Rightarrow$ σ -代数越细 $\Rightarrow$ 可分辨的事件越多。右图保留了左图的分界 ($\mathcal{G} \subseteq \mathcal{F}$)，只是把每块进一步切开。条件期望 $\mathbb{E}(X|\mathcal{F})$ 就是“在每一块上取平均”，块越细，平均越逼近 X 本身。

这套语言把上一章的条件期望接了回来。 $\mathbb{E}(X|\mathcal{F})$ 是“在 $\mathcal{F}$ 这个信息下对 X 的最优预测”：在划分的每一块上把 X 抹平成块内均值。 $\mathcal{F}$ 越细（信息越多），每块越小，块内均值越贴近 X 的真值——预测越准。在两个极端上： $\mathcal{F} = \{\emptyset, \Omega\}$ （什么都不知）时 $\mathbb{E}(X|\mathcal{F}) = \mathbb{E}(X)$ 退化成无条件均值； $\mathcal{F}$ 细到 X 关于它可测（完全知道 X ）时 $\mathbb{E}(X|\mathcal{F}) = X$ 。“学习”在这套语言里，就是 σ -代数随时间逐步变细的过程。

29.4 信号与信念更新：博弈论的视角

不完全信息博弈里，参与者对某个未知量（对手的“类型”、世界的“状态”）持有先验信念，再观察到一个与该未知量相关的信号，据此更新信念后行动。贝叶斯定理正是这里“更新”二字的定义。

定义 29.8: 信号结构与后验信念

设状态 θ 取值于有限集 Θ , 先验为 $\pi(\theta)$ 。一个信号 (或信息结构) 由一族条件分布 $\{p(s | \theta)\}_{\theta \in \Theta}$ 给出: 在状态 θ 下收到信号 s 的概率。观察到 s 后的后验信念为

$$\mu(\theta | s) = \frac{p(s | \theta) \pi(\theta)}{\sum_{\theta' \in \Theta} p(s | \theta') \pi(\theta')}.$$

这与离散贝叶斯定理一字不差, 换了套博弈论的说法而已: 状态 θ 是“假设”, 信号 s 是“证据”, $p(s | \theta)$ 是似然。信号的“信息量”可以用它在多大程度上改变信念来衡量——一个与 θ 完全独立的信号 ($p(s | \theta)$ 不依赖 θ) 让后验等于先验, 毫无信息; 一个能完美区分状态的信号 (不同 θ 给出不相交的 s 支撑) 让后验退化成一点, 揭示全部真相。绝大多数现实信号介于两者之间。

例 (一个二值信号如何更新信念) .

状态 $\theta \in \{1, 0\}$ (“高/低”), 先验 $\pi(1) = \pi(0) = \frac{1}{2}$ 。信号 $s \in \{g, b\}$ 满足 $p(g | 1) = 0.8$, $p(g | 0) = 0.2$ (高状态更可能发出“好”信号)。收到 $s = g$ 后, 关于 $\theta = 1$ 的后验信念是多少?

解.

$$\mu(1 | g) = \frac{p(g | 1)\pi(1)}{p(g | 1)\pi(1) + p(g | 0)\pi(0)} = \frac{0.8 \times 0.5}{0.8 \times 0.5 + 0.2 \times 0.5} = \frac{0.4}{0.5} = 0.8.$$

信念从 0.5 升到 0.8。对称地, 收到 $s = b$ 时 $\mu(1 | b) = \frac{0.2 \times 0.5}{0.2 \times 0.5 + 0.8 \times 0.5} = 0.2$, 信念降到 0.2。信号把一个“五五开”的先验, 分裂成“八二开”或“二八开”两种后验——信号越精确 ($p(g | 1)$ 与 $p(g | 0)$ 差得越开), 分裂得越厉害。

这就是贝叶斯纳什均衡的“信念”部件

不完全信息博弈的均衡 (贝叶斯纳什均衡、完美贝叶斯均衡) 由两件相互咬合的东西组成: (i) 给定信念, 每个类型的策略是最优的; (ii) 信念由先验加上“沿均衡路径观察到的行动/信号”按贝叶斯定理更新而来。本节的更新公式正是 (ii)。信号传递博弈 (如教育作为能力信号)、筛选 (如保险菜单甄别风险类型)、信息设计 / 贝叶斯劝说 (设计 $p(s | \theta)$ 去影响接收者的后验、进而影响其行动), 骨架全是“先验 + 信号 $\rightarrow$ 后验”这一步。

29.5 后验信念是鞅: 你说服不了自己往哪边走

本章最后一个事实, 初看玄妙, 证起来只是一行, 却管着“学习”能与不能做到什么。问题是这样的: 明天会有一个信号到来, 把今天的信念 π 更新成某个后验。在看到信号之前, 我对明天那个后验的期望是多少? 答案是: 还是 π 。

命题 29.9: 后验信念的鞅性

设今天的信念为 $\pi(\theta) = \mathbb{P}(\theta)$ ，明天将观察到信号 s （其在状态 θ 下的分布为 $p(s | \theta)$ ）。则对每个状态 θ ，以今天的信息取期望，明天的后验信念的期望等于今天的信念：

$$\mathbb{E}(\mu(\theta | s)) = \sum_s \mathbb{P}(s) \mu(\theta | s) = \pi(\theta).$$

证明. 按全概率公式，今天看明天，信号 s 出现的（边际）概率是 $\mathbb{P}(s) = \sum_{\theta'} p(s | \theta') \pi(\theta')$ ，它正是贝叶斯公式的分母。于是

$$\sum_s \mathbb{P}(s) \mu(\theta | s) = \sum_s \mathbb{P}(s) \cdot \frac{p(s | \theta) \pi(\theta)}{\mathbb{P}(s)} = \sum_s p(s | \theta) \pi(\theta) = \pi(\theta) \sum_s p(s | \theta) = \pi(\theta),$$

最后一步用了 $\sum_s p(s | \theta) = 1$ （信号分布对 s 求和为一）。 $\mathbb{P}(s)$ 在分子分母约掉，是这个“回到先验”的恒等式的全部机关。□

把这个结论沿时间串起来：随着信号一个个到来，信念序列 $\{\pi_t\}$ 满足 $\mathbb{E}(\pi_{t+1} | \text{今天信息}) = \pi_t$ ——这正是鞅的定义（详见后文“鞅”一章）。它的含义掷地有声：

信念无法被系统性地、可预测地移动

鞅性说的是：你不可能预先知道一个未来信号会把你的信念往哪个方向推。若你今天就能断定“明天的证据多半会让我更信 $\theta = 1$ ”，那你今天的信念本就该更高——否则就违反了 $\mathbb{E}(\pi_{t+1}) = \pi_t$ 。换句话说，理性信念的变动只能是“意外”，不能是“可预测的漂移”。这条原理直接派生出若干著名结论：金融里资产价格（作为对未来现金流的理性信念）近似为鞅，故“可预测的超额收益”难以存在（有效市场的形式表达）；信息设计里“发送者无法靠信号系统性抬高接收者对某状态的平均信念”（贝叶斯劝说的 Bayes-plausibility 约束，正是这条鞅性）。能被预测地移动的信念，等于桌上没捡的钱。

注（鞅性不是说“信念不动”）。

注意鞅性约束的是后验的期望，不是后验本身。明天的信念几乎一定会变（信号一来， $\mu(\theta | s)$ 通常 $\neq \pi$ ）；鞅性只说这些变动平均起来为零、方向无法预知。学习仍在发生、信念仍在收敛——只是每一步的“惊讶”事前不可预测。这与上一节图 29.3 的 σ -代数细化是同一枚硬币的两面：信息在增加（ σ -代数在变细、后验在变窄），但增量是不可预测的。

下图把鞅性具象化：先验是一个点，信号把它分裂成两个后验，而两个后验按各自出现的概率加权平均，又回到先验那个点。




图 29.4: 后验信念的鞅性。一个二值信号把先验 $\pi = 0.5$ 分裂成 0.8（概率 0.5）与 0.2（概率 0.5）两个后验；两者按出现概率加权平均，又精确回到 $\pi = 0.5$ 。信念会变，但事前的期望不变——这正是 $\mathbb{E}(\pi_{t+1} | \text{今}) = \pi_t$ 。

29.6 它通向何处

贝叶斯更新是少数几个“一处学会、处处遇见”的机制之一。把本章的工具接回经济学主干：

- **不完全信息博弈。**贝叶斯纳什均衡与完美贝叶斯均衡把“信念按贝叶斯定理更新”写进了均衡定义本身；信号传递（教育、广告）、筛选（保险、合同菜单）都是它的应用。
- **信息经济学与信息设计。**从 Akerlof 的柠檬市场到贝叶斯劝说，核心都是“谁能观察到什么信号、信号如何重塑后验”；上一节的鞅性（Bayes-plausibility）是信息设计可行性约束的来源。
- **宏观学习。**当 agent 不知道模型参数、只能边观察边学习时，“信念的演化”成为模型的状态变量；正态-正态更新与卡尔曼滤波是其标准工具，且“信念是鞅”限制了学习能制造怎样的动态。
- **贝叶斯计量。**把参数 θ 当随机的、给它先验、用数据算后验，是与频率派并行的一整套推断范式；后验均值（即条件期望，承接上一章）是常用的点估计，后验分位数给出可信区间。共轭先验让少数模型有解析后验，其余则靠 MCMC 从后验抽样。
- **动态规划中的信念状态。**部分可观测的动态决策问题（POMDP、带学习的最优停时）里，“当前后验信念”本身就是 Bellman 方程的状态变量，更新法则即本章的递归式（见后文动态规划部分）。

一条由条件概率定义重排而来的式子，串起了博弈论、信息经济学、宏观与计量。这再次印证全书的主线：认清一件工具的内核，等于一次拿到许多扇门的钥匙——而贝叶斯定理，是其中开门最多的那一把之一。

第六部分

渐近统计

第三十章 收敛模式

用到的前置工具：随机变量、分布与 CDF（见前文『可测函数、随机变量与分布』一章）；测度对单调集列的连续性（概率与测度部分）；Markov / Chebyshev 不等式（同上）；序列与极限的 ε 语言（分析与拓扑部分）。

到这一部分为止，我们手里的随机变量都是“静止”的：一个 X 、一个分布、一个期望。可计量经济学几乎全部的有效结论，都关乎一系列随机变量 $X_1, X_2, \dots$ 在 $n \rightarrow \infty$ 时“趋向”某个东西——样本均值趋向总体均值、估计量趋向真参数、检验统计量趋向某个已知分布。这一“趋向”就是**收敛**。麻烦在于：随机变量不是实数，“ X_n 趋向 X ”可以有好几种互不等价的含义，而且它们恰好对应计量里几类不同的论断。把“收敛”这一个词拆成它真正的几种意思，正是整个渐近统计部分能开口说话的前提。本章就来做这件事。

30.1 为什么“收敛”必须分清几种意思

先看两句计量里天天讲的话，它们听上去都像“收敛”，其实说的是两件不同的事。

第一句：估计量是一致的。我们说 OLS 估计量 $\hat{\beta}_n$ “一致”，意思是样本越大、它越贴近真值 β_0 ——大样本下几乎不会偏离 β_0 太远。这是关于“估计量落点”的论断：随机的 $\hat{\beta}_n$ 把它的概率质量越来越紧地压在那个确定的点 β_0 上。

第二句：检验统计量渐近服从 χ^2 。我们说某个 Wald 统计量“渐近 χ^2 ”，意思是大大样本下它的分布形状越来越像 χ^2 ，于是可以查 χ^2 表定临界值。这里的极限根本不是一个点，而是一整个分布；统计量本身始终是随机的、有散布的，并不缩成一点。

这两句话用的是不同的收敛。第一句要的是“随机量塌缩到一个常数”，第二句要的是“随机量的分布逼近另一个分布”。若混为一谈，“大数定律”与“中心极限定理”就会彼此矛盾——前者说 $\bar{X}_n$ 缩成常数 μ ，后者却说 $\sqrt{n}(\bar{X}_n - \mu)$ 摊成一个正态分布，二者怎能并存？答案是它们说的是不同模式的收敛，各自成立、互不冲突。本章给出四种收敛模式的精确定义、它们之间谁强谁弱、以及一套描述“收敛速度”的简便记号 (o_p, O_p) 。

一句话定调

“一致性”是**依概率收敛**（估计量塌缩到真值这个点）；“渐近分布”是**依分布收敛**（统计量的分布逼近某极限分布）。它们是两种不同的收敛，分别由大数定律与中心极限定理供给。本章把这两种、连同更强的“几乎必然”与“ L^p ”收敛一并理

清，是后面 LLN、CLT、Slutsky、Delta 法得以严格陈述的语言地基。

30.2 四种收敛模式

设 X_n 与 X 都定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上（依分布收敛是例外，见下）。下面四个定义，由强到弱大致排列。

定义 30.1: 几乎必然收敛 (a.s.)

称 X_n 几乎必然收敛到 X ，记 $X_n \xrightarrow{\text{a.s.}} X$ ，若

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) = 1.$$

即：除一个概率为零的例外集外，对每一个样本点 ω ，实数列 $X_n(\omega)$ 都（按普通的实数极限）收敛到 $X(\omega)$ 。

定义 30.2: 依概率收敛 ($\xrightarrow{p}$)

称 X_n 依概率收敛到 X ，记 $X_n \xrightarrow{p} X$ ，若对任意 $\varepsilon > 0$ ，

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

即：对每个固定的容差 ε ，“ X_n 离 X 超过 ε ”这件事的概率随 n 趋于零。

定义 30.3: L^p 收敛 (均方为 $p = 2$)

设 $\mathbb{E}(|X_n|^p) < \infty$ 。称 X_n 在 L^p 中收敛到 X ，记 $X_n \xrightarrow{L^p} X$ ，若

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0.$$

$p = 2$ 的情形称均方收敛，要求 $\mathbb{E}((X_n - X)^2) \rightarrow 0$ 。

定义 30.4: 依分布收敛 ($\xrightarrow{d}$)

称 X_n 依分布收敛到 X ，记 $X_n \xrightarrow{d} X$ ，若它们的 CDF 满足

$$F_{X_n}(x) \longrightarrow F_X(x) \quad \text{在每个使 } F_X \text{ 连续的点 } x \text{ 处.}$$

前三种收敛要求 X_n 与 X 活在同一个 Ω 上、可以逐点相减；依分布收敛则只关乎 CDF（即分布）， X_n 与 X 甚至可以建在不同的样本空间上——它根本不比较 X_n 与 X 这两个函数，只比较它们的分布形状。这正是上一节“第二句话”要的那种收敛：极限是一个分布，不是一个具体的随机量。

注（为什么依分布收敛只要求“连续点”处的 CDF 收敛）。

这条限制不是技术洁癖，不加它定义就会把该算收敛的情形错判成不收敛。看一个最简单的例子： $X_n = 1/n$ （退化随机变量），它显然收敛到 $X = 0$ 。 X 的 CDF 是 $F_X(x) = \mathbf{1}\{x \geq 0\}$ ，在 $x = 0$ 处从 0 跳到 1。而 $F_{X_n}(x) = \mathbf{1}\{x \geq 1/n\}$ ，于是在跳点 $x = 0$ 处 $F_{X_n}(0) = 0$ 对一切 n 成立，永远不等于 $F_X(0) = 1$ ——若要求在所有点收敛，就会荒谬地判定 $1/n \not\rightarrow 0$ 。但 $x = 0$ 恰是 F_X 的不连续点；在其余所有点（ F_X 的连续点）上 $F_{X_n}(x) \rightarrow F_X(x)$ 都成立。把跳点豁免掉，定义才与直觉一致。直觉是：依分布收敛刻画分布“形状”的逼近，而单个跳点处的取值是 CDF 那个“ $\leq$ 还是 $<$ ”的约定细节（见前文 CDF 的右连续性讨论），不该左右收敛与否。

例（依分布的极限可以是常数）。

若 $X_n \xrightarrow{d} c$ ，其中 c 是常数（即极限分布是退化在 c 的点质量），这等价于什么？

解。

极限 $X = c$ 的 CDF 是阶跃 $F_X(x) = \mathbf{1}\{x \geq c\}$ ，其唯一不连续点是 $x = c$ 。依分布收敛要求在所有 $x \neq c$ 处 $F_{X_n}(x) \rightarrow \mathbf{1}\{x \geq c\}$ 。取 x 略小于 c 得 $F_{X_n}(x) \rightarrow 0$ ，取 x 略大于 c 得 $F_{X_n}(x) \rightarrow 1$ ；合起来正是说 X_n 的概率质量全部挤向 c ，即 $\mathbb{P}(|X_n - c| > \varepsilon) \rightarrow 0$ 。所以当极限是常数时，依分布收敛与依概率收敛等价。这条小事实后面极有用：它是 Slutsky 定理（把依概率收敛到常数的项“塞进”依分布收敛的乘积里）能够成立的关键接口。

30.3 蕴含关系：谁强谁弱

四种模式不是平起平坐的，它们之间有明确的强弱次序。先把结论摆出来（图 30.1），再逐条证明。




图 30.1: 四种收敛模式的蕴含关系。几乎必然与 L^p 各自都蕴含依概率，依概率又蕴含依分布；实线箭头方向的反向一般不成立（如依分布回到依概率，见后例）。此外，几乎必然与 L^p 之间互不蕴含——二者都比依概率强，但强的方向不同。

定理 30.5: 蕴含链

设 X_n, X 在同一概率空间上。则

$$\begin{aligned}(X_n \xrightarrow{\text{a.s.}} X) &\implies (X_n \xrightarrow{P} X), & (X_n \xrightarrow{L^p} X) &\implies (X_n \xrightarrow{P} X), \\ (X_n \xrightarrow{P} X) &\implies (X_n \xrightarrow{d} X).\end{aligned}$$

反向蕴含一般都不成立；几乎必然收敛与 L^p 收敛之间也互不蕴含。

下面三段把三条蕴含分别讲清，每条都给一个可自行重建的论证。

(一) 几乎必然 $\Rightarrow$ 依概率

几乎必然 $\Rightarrow$ 依概率. 固定 $\varepsilon > 0$. 定义“从第 n 项起一直离得远”的事件

$$A_n = \bigcup_{m \geq n} \{|X_m - X| > \varepsilon\}.$$

A_n 关于 n 单调下降 (n 越大, 并的项越少)。它的极限交集 $\bigcap_n A_n$ 是“有无穷多个 m 使 $|X_m - X| > \varepsilon$ ”的事件。但在 $X_n(\omega) \rightarrow X(\omega)$ 的那些 ω 上 (按假设这是概率为 1 的集合), 实数收敛意味着只有有限个 m 能让 $|X_m(\omega) - X(\omega)| > \varepsilon$, 故这些 ω 都不属于 $\bigcap_n A_n$ 。于是 $\mathbb{P}(\bigcap_n A_n) = 0$ 。再由测度对下降集列的连续性 (见概率与测度部分),

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \mathbb{P}(A_n) \downarrow \mathbb{P}\left(\bigcap_n A_n\right) = 0.$$

左端被一个趋于零的量压住, 故 $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$. ε 任意, 即 $X_n \xrightarrow{P} X$. $\square$

注 (直觉: “逐路径”比“逐时刻”强)。

这条证明的核心, 是把“逐路径收敛”翻译成“尾部事件 A_n 的概率消失”。几乎必然收敛管的是整条路径 $n \mapsto X_n(\omega)$ 的最终行为 (除掉概率零的坏路径), 它自然控制住了“尾部还有大偏差”的概率; 而依概率收敛只管每个单独时刻 n 的偏差概率, 不追问同一条路径在不同时刻的联动。前者对后者的蕴含, 本质上就是“控制了整条尾巴”必然“控制得住任一时刻”。图 30.2 把这两幅图像并排画出; 下一节的打字机反例会再把它们的差距撑开。

(二) $L^p \Rightarrow$ 依概率

$L^p \Rightarrow$ 依概率. 这是 Markov 不等式的一行推论。对 $\varepsilon > 0$, 把 Markov 不等式用在非负随机变量 $|X_n - X|^p$ 上:

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{P}(|X_n - X|^p > \varepsilon^p) \leq \frac{\mathbb{E}(|X_n - X|^p)}{\varepsilon^p}.$$




图 30.2: 几乎必然 vs 依概率的两幅图像。左：几乎必然收敛盯住逐条样本路径——固定 ω ，整条折线 $n \mapsto X_n(\omega)$ 作为普通实数列收敛到 $X(\omega)$ 。右：依概率收敛盯住逐个时刻——在每个 n 上看 X_n 的分布，随 n 增大其概率质量越来越紧地集中到极限值附近（钟形越来越高窄），但并不追问同一条路径跨时刻的行为。前者强于后者。

右端分子按假设趋于 0（这正是 L^p 收敛的定义），分母是固定常数，故左端 $\rightarrow 0$ 。 ε 任意，得 $X_n \xrightarrow{p} X$ 。 $p = 2$ 时这就是 Chebyshev 不等式的形态： $\mathbb{P}(|X_n - X| > \varepsilon) \leq \mathbb{E}((X_n - X)^2) / \varepsilon^2$ 。□

均方收敛是证一致性的“傻瓜”路径

要证 $X_n \xrightarrow{p} X$ ，最省力的常见做法是退而证更强的均方收敛 $\mathbb{E}((X_n - X)^2) \rightarrow 0$ ，因为后者往往只需把均方误差拆成“偏差平方 + 方差”两块、各自算趋零即可：

$$\mathbb{E}((X_n - X)^2) = \underbrace{(\mathbb{E}(X_n) - X)^2}_{\text{偏差}^2} + \underbrace{\text{Var}(X_n)}_{\text{方差}} \quad (\text{当 } X \text{ 为常数}).$$

样本均值 $\bar{X}_n$ 的一致性最干净的证明就是这条： $\mathbb{E}(\bar{X}_n) = \mu$ 故偏差为零， $\text{Var}(\bar{X}_n) = \sigma^2/n \rightarrow 0$ 故方差趋零，于是 $\mathbb{E}((\bar{X}_n - \mu)^2) \rightarrow 0$ ，由本小节立得 $\bar{X}_n \xrightarrow{p} \mu$ 。这是大数定律最初等的一个版本（“ L^2 弱大数律”）。

(三) 依概率 $\Rightarrow$ 依分布

依概率 $\Rightarrow$ 依分布. 设 x 是 F_X 的连续点，要证 $F_{X_n}(x) \rightarrow F_X(x)$ 。思路是用一个小缓冲 $\varepsilon > 0$ 把 $\{X_n \leq x\}$ 夹在 X 的两个邻近事件之间。

上界。若 $X_n \leq x$, 则要么 $X \leq x + \varepsilon$, 要么 $X > x + \varepsilon$ 但 X_n 把它拉低了至少 ε (即 $|X_n - X| > \varepsilon$)。于是

$$F_{X_n}(x) = \mathbb{P}(X_n \leq x) \leq \mathbb{P}(X \leq x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) = F_X(x + \varepsilon) + o(1),$$

末项由 $X_n \xrightarrow{p} X$ 趋于 0。取 $\limsup$: $\limsup_n F_{X_n}(x) \leq F_X(x + \varepsilon)$ 。

下界。对称地, 若 $X \leq x - \varepsilon$, 则要么 $X_n \leq x$, 要么 $|X_n - X| > \varepsilon$, 故

$$F_X(x - \varepsilon) \leq \mathbb{P}(X_n \leq x) + \mathbb{P}(|X_n - X| > \varepsilon) = F_{X_n}(x) + o(1),$$

取 $\liminf$: $F_X(x - \varepsilon) \leq \liminf_n F_{X_n}(x)$ 。

合并两端:

$$F_X(x - \varepsilon) \leq \liminf_n F_{X_n}(x) \leq \limsup_n F_{X_n}(x) \leq F_X(x + \varepsilon).$$

现在让 $\varepsilon \downarrow 0$ 。因为 x 是 F_X 的连续点, $F_X(x \pm \varepsilon) \rightarrow F_X(x)$, 把 $\liminf$ 与 $\limsup$ 挤成同一个值 $F_X(x)$ 。故 $F_{X_n}(x) \rightarrow F_X(x)$ 。□

正是这一步证明里出现了“缓冲 ε 把 X_n 与 X 的事件互相夹住”的手法——它是渐近统计里反复出现的“ ε 夹逼”, Slutsky 定理与连续映射定理的证明都用同一招。

30.4 反向不成立: 四个经典反例

蕴含链是单向的。把每个反向都用一个反例堵死, 才算真正理解了这四种模式的差别。

依概率 $\nrightarrow$ 几乎必然: 打字机序列

最著名的反例是打字机序列 (typewriter sequence)。在 $\Omega = [0, 1]$ 配 Lebesgue 测度 (即均匀分布) 上构造: 把 $[0, 1]$ 依次切成长度 $1, \frac{1}{2}, \frac{1}{3}, \dots$ 的小区间, 让支撑块在 $[0, 1]$ 上一遍遍“扫过”。具体地, 第 k 代把 $[0, 1]$ 均分成 k 段, 对每一段定义一个示性函数随机变量。前几项是

$$\begin{aligned} X_1 &= \mathbf{1}_{[0,1]}; \\ X_2 &= \mathbf{1}_{[0,1/2]}, \quad X_3 = \mathbf{1}_{[1/2,1]}; \\ X_4 &= \mathbf{1}_{[0,1/3]}, \quad X_5 = \mathbf{1}_{[1/3,2/3]}, \quad X_6 = \mathbf{1}_{[2/3,1]}; \quad \dots \end{aligned}$$

图 30.3 画出了这个“扫描”过程。

依概率收敛成立。第 k 代里每个 X_n 的支撑块长度是 $1/k$, 所以 $\mathbb{P}(X_n = 1) = 1/k \rightarrow 0$ ($n \rightarrow \infty$ 时代数 $k \rightarrow \infty$)。于是对任意 $\varepsilon \in (0, 1)$, $\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_n = 1) = 1/k \rightarrow 0$, 即 $X_n \xrightarrow{p} 0$ 。

几乎必然收敛失败。固定任意 $\omega \in [0, 1]$ 。每一代都恰有一块盖住 ω (因为每代的若干块拼成整个 $[0, 1]$), 那一块对应的 X_n 在 ω 处取值 1。于是序列 $X_n(\omega)$ 里有无穷




图 30.3: 打字机序列。支撑块逐代细分（长度 $\rightarrow 0$ ），并在 $[0, 1]$ 上来回扫过。任意固定的 ω （图中红虚线）每一代都会被某一块“扫中”一次，故 $X_n(\omega) = 1$ 沿 n 无穷多次出现——该路径不收敛。但块的长度 $\rightarrow 0$ ，故 $\mathbb{P}(X_n = 1) \rightarrow 0$ ，依概率收敛成立。

多个 1，同时（块在移动）也有无穷多个 0——它在 0 和 1 之间永远跳动，对每一个 ω 都不收敛。使 $X_n(\omega)$ 收敛的 ω 集合是空集，概率为 $0 \neq 1$ ，故 $X_n \not\rightarrow 0$ 。

打字机告诉我们什么

依概率收敛只看“每个时刻 n 偏差大的概率有多小”，它完全允许同一条路径在不同时刻反复“闪”出大偏差——只要每次闪的概率越来越小。几乎必然收敛则盯住“整条路径最终是否安定下来”。打字机序列就是“逐时刻越来越好、但逐路径永不安定”的典型：质量块越扫越细（逐时刻好转），却永远在扫（逐路径不收敛）。这是“依概率”严格弱于“几乎必然”的活样本。

依概率 $\not\Rightarrow L^p$ ：质量小但跑得远

依概率收敛只关心“偏差大”的概率，不关心偏差到底有多大； L^p 收敛却要对偏差的大小（的 p 次方）求期望，一个小概率的巨大偏差就能把期望顶起来。令

$$X_n = \begin{cases} n, & \text{以概率 } 1/n, \\ 0, & \text{以概率 } 1 - 1/n. \end{cases}$$

则 $\mathbb{P}(|X_n| > \varepsilon) = 1/n \rightarrow 0$ ，故 $X_n \xrightarrow{p} 0$ 。但

$$\mathbb{E}(|X_n - 0|^2) = n^2 \cdot \frac{1}{n} = n \rightarrow \infty,$$

均方误差不仅不趋零、反而发散，故 $X_n \not\xrightarrow{L^2} 0$ 。依概率收敛管不住矩：偏差出现的概率虽小（ $1/n$ ），偏差的幅度（ n ）却大到让二阶矩爆炸。这解释了为什么证一致性时“均方收敛”是充分而非必要的——有些一致的估计量其矩根本不存在或不收敛。

依分布 $\not\Rightarrow$ 依概率：对称分布的反例

依分布收敛只比较分布，根本不要求 X_n 与 X 这两个随机量逐点靠近。取 $X \sim \mathcal{N}(0, 1)$ ，令 $X_n = -X$ 对一切 n 。每个 X_n 都服从 $\mathcal{N}(0, 1)$ （正态对称），与 X 分布完

全相同，故 $F_{X_n} = F_X$ ，平凡地 $X_n \xrightarrow{d} X$ 。但

$$|X_n - X| = |-X - X| = 2|X|,$$

它根本不依赖 n ，更不会随 n 缩小； $\mathbb{P}(2|X| > \varepsilon)$ 是一个固定的正数，不趋于零，故 $X_n \not\xrightarrow{p} X$ 。图 30.4 把这件事画清楚：左边 X_n 与 X 同分布（依分布收敛），右边它们的差 $X_n - X = -2X \sim \mathcal{N}(0, 4)$ 的质量根本不向 0 收缩（依概率收敛失败）。




图 30.4: 依分布 $\not\Rightarrow$ 依概率。取 $X \sim \mathcal{N}(0, 1)$ 、 $X_n = -X$ ：左图二者分布相同，故 $X_n \xrightarrow{d} X$ 平凡成立；右图它们的差 $X_n - X = -2X \sim \mathcal{N}(0, 4)$ 的概率质量始终摊在 0 两侧、不向 0 收缩，故 $X_n \not\xrightarrow{p} X$ 。“分布一样”远不等于“取值贴近”。

注（那个“一般不成立”什么时候变成“成立”）。

依分布回到依概率，唯一的例外是上一节那个例子：当极限是常数时， $X_n \xrightarrow{d} c$ 与 $X_n \xrightarrow{p} c$ 等价。原因正是上面反例失效的地方——若极限 $X \equiv c$ 是个不动的点，“分布挤向 c ”就只能靠“取值挤向 c ”来实现，没有对称翻转之类的花样可玩。这条例外不是边角料：大数定律的结论 $\bar{X}_n \xrightarrow{p} \mu$ 与 Slutsky 定理里“ $\hat{\sigma}_n \xrightarrow{p} \sigma$ ”这类“收敛到常数”的语句，全靠它在依分布与依概率之间自由换乘。

几乎必然与 L^p 互不蕴含

最后补一句对称性：几乎必然与 L^p 都强于依概率，但彼此谁也不蕴含谁。上面“质量小但跑得远”的例子（ $X_n = n$ 以概率 $1/n$ ）可调成几乎必然收敛到 0（让支撑事件可加和，用 Borel-Cantelli 第一引理保证只发生有限次），却仍有 $\mathbb{E}(X_n^2) \rightarrow \infty$ ——这是 a.s. 成立而 L^2 失败。反过来，打字机序列的一个加权版本可做到 L^2 收敛（块的高度配合长度使 $\mathbb{E}(X_n^2) \rightarrow 0$ ）却仍逐路径不收敛——这是 L^p 成立而 a.s. 失败。“逐路径安定”与“矩趋零”是两种不同方向的强，没有高下，故图 30.1 里它们并列、各自单向指向依概率。

30.5 速度的语言： o_p 与 O_p

知道“ X_n 收敛”还不够，渐近分析里我们常要比较“谁比谁收敛得快”、要把一串小项干净地丢掉。确定性分析有 $o(\cdot)$ 与 $O(\cdot)$ 记号干这事；它们有一对随机版本 o_p （“依概率的小 o ”）与 O_p （“依概率的大 O ”），是渐近推导里最省事的速记。

定义 30.6: o_p 与 O_p

设 $\{a_n\}$ 是一列正数 (“基准速度”)。

- 记 $X_n = o_p(a_n)$, 若 $\frac{X_n}{a_n} \xrightarrow{p} 0$, 即对任意 $\varepsilon > 0$, $\mathbb{P}(|X_n/a_n| > \varepsilon) \rightarrow 0$ 。读作 “ X_n 是比 a_n 高阶的小量”。
- 记 $X_n = O_p(a_n)$, 若 $\frac{X_n}{a_n}$ 依概率有界: 对任意 $\delta > 0$, 存在常数 M 与 N , 使 $\mathbb{P}(|X_n/a_n| > M) < \delta$ 对一切 $n \geq N$ 成立。读作 “ X_n 与 a_n 同阶 (至多同阶)”。

两个最常用的特例: $X_n = o_p(1)$ 就是 $X_n \xrightarrow{p} 0$ (依概率收敛的另一种写法); $X_n = O_p(1)$ 就是 “ X_n 依概率有界” (一系列不发散的随机量, 典型如依分布收敛的序列)。

注 (为什么 $\xrightarrow{d}$ 蕴含 $O_p(1)$) .

若 $X_n \xrightarrow{d} X$, 则 $X_n = O_p(1)$ 。直觉: 极限分布 X 把几乎所有质量装在某个有限区间里, 于是对大 n , X_n 的质量也逃不出一个 (稍大的) 有限区间, 故依概率有界。这条小事实极常用: 中心极限定理给出 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, V)$, 立刻就有 $\sqrt{n}(\hat{\theta}_n - \theta_0) = O_p(1)$, 等价地 $\hat{\theta}_n - \theta_0 = O_p(n^{-1/2})$ ——这正是 “估计量以 $\sqrt{n}$ 速度收敛” 这句话的精确含义。

这套记号真正的威力, 在于它服从一套简单的代数, 让人能像处理普通小量那样在证明里成批消化误差项。

命题 30.7: o_p/O_p 的运算规则

设 $a_n, b_n > 0$ 。下列规则成立 (等号读作 “左边是右边那一类”):

1. (吸收) $o_p(a_n) + o_p(a_n) = o_p(a_n)$, $O_p(a_n) + O_p(a_n) = O_p(a_n)$;
2. (小压大) $o_p(a_n) + O_p(a_n) = O_p(a_n)$;
3. (相乘加阶) $o_p(a_n) o_p(b_n) = o_p(a_n b_n)$, $O_p(a_n) O_p(b_n) = O_p(a_n b_n)$,
 $o_p(a_n) O_p(b_n) = o_p(a_n b_n)$;
4. (小吃大) $O_p(a_n) o_p(1) = o_p(a_n)$;
5. (数乘与嵌套) $o_p(O_p(1)) = o_p(1)$, 即一个依概率有界量乘上 $o_p(1)$ 仍是 $o_p(1)$ 。

证明思路. 这些规则全部从定义加基本不等式得来, 思路与确定性的 o/O 演算一致。举两条代表。

规则 3 中的 $o_p(a_n) O_p(b_n) = o_p(a_n b_n)$ 。设 $U_n/a_n \xrightarrow{p} 0$, $V_n/b_n = O_p(1)$ 。要证

$U_n V_n / (a_n b_n) \xrightarrow{p} 0$ 。写

$$\frac{U_n V_n}{a_n b_n} = \underbrace{\frac{U_n}{a_n}}_{\xrightarrow{p} 0} \cdot \underbrace{\frac{V_n}{b_n}}_{O_p(1)}.$$

一个依概率趋零的量乘一个依概率有界的量，仍依概率趋零：给定 $\varepsilon, \delta > 0$ ，取 M 使 $\mathbb{P}(|V_n/b_n| > M) < \delta/2$ （依概率有界），再取 n 大使 $\mathbb{P}(|U_n/a_n| > \varepsilon/M) < \delta/2$ （依概率趋零）；在两个小概率事件都不发生时乘积的绝对值 $\leq M \cdot (\varepsilon/M) = \varepsilon$ ，故 $\mathbb{P}(|U_n V_n / (a_n b_n)| > \varepsilon) < \delta$ 。 δ 任意即得。

规则 2，小压大 $o_p(a_n) + O_p(a_n) = O_p(a_n)$ 。设 $U_n/a_n \xrightarrow{p} 0$ （从而依概率有界）、 $V_n/a_n = O_p(1)$ 。由三角不等式

$$\left| \frac{U_n + V_n}{a_n} \right| \leq \left| \frac{U_n}{a_n} \right| + \left| \frac{V_n}{a_n} \right|,$$

两个依概率有界量之和仍依概率有界（对右端两项各取一半的界），故 $U_n + V_n = O_p(a_n)$ 。□

例（用 o_p/O_p 一行读出收敛速度）。

设估计量满足 $\hat{\theta}_n = \theta_0 + O_p(n^{-1/2})$ ，又有一个余项 $R_n = o_p(n^{-1/2})$ 。问 $\hat{\theta}_n + R_n - \theta_0$ 是什么阶？ $n(\hat{\theta}_n - \theta_0)^2$ 又是什么阶？

解。

第一问： $\hat{\theta}_n + R_n - \theta_0 = O_p(n^{-1/2}) + o_p(n^{-1/2}) = O_p(n^{-1/2})$ （规则 2，小项被吸收），即加上一个高阶余项不改变收敛速度——这正是渐近展开里“丢掉余项”的合法性依据。第二问： $(\hat{\theta}_n - \theta_0)^2 = (O_p(n^{-1/2}))^2 = O_p(n^{-1})$ （规则 3 相乘加阶），故 $n(\hat{\theta}_n - \theta_0)^2 = n \cdot O_p(n^{-1}) = O_p(1)$ ，依概率有界——这就是为什么 $n(\hat{\theta}_n - \theta_0)^2$ 这类二次型能有非退化的极限分布（如 χ^2 ），是 Wald 统计量“渐近 χ^2 ”的速度账。

o_p/O_p 是渐近证明的“记账系统”

几乎所有渐近结果的证明，最后都化成“主项 + 一堆余项”，其中主项给出极限分布、余项必须被证明可忽略。 o_p/O_p 记号让这件事变成机械的代数：把每一项贴上速度标签，按上面的规则相加相乘，主项之外的统统坍缩成 $o_p(1)$ 丢掉。Delta 法的一阶 Taylor 展开、M-估计量的渐近正态、GMM 的标准误，骨架都是这套记账。学会熟练地“丢 o_p ”，是读懂现代计量证明的基本功。

30.6 它通向何处

本章把“收敛”这个词拆成了四种精确的模式，排好了强弱、堵死了反向、配上了速度记号。这套语言是整个渐近统计部分的地基，后续每一块都直接踩在它上面：

- **大数定律**（见后文『大数定律』一章）就是关于样本均值的收敛定理：弱大数律断言 $\bar{X}_n \xrightarrow{p} \mu$ （依概率），强大数律断言 $\bar{X}_n \xrightarrow{a.s.} \mu$ （几乎必然）。“弱”与“强”之分，用的正是本章 a.s. 严格强于 $\xrightarrow{p}$ 这一层级。一致性（ $\text{plim } \hat{\theta}_n = \theta_0$ ）就是估计量版的弱大数律。
- **中心极限定理**（见后文『中心极限定理』一章）是一条依分布收敛的定理： $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 。它和大数定律不矛盾，恰因二者是不同模式的收敛——一个把 $\bar{X}_n$ 塌成常数 μ ，另一个把放大后的涨落 $\sqrt{n}(\bar{X}_n - \mu)$ 摊成正态。本章开头那个“看似矛盾”的疑问，到这里彻底解开。
- **连续映射定理、Slutsky 与 Delta 法**（见后文『连续映射定理、Slutsky 与 Delta 法』一章）是组合这些收敛的运算法则。Slutsky 定理的可用，关键就靠本章那条“依分布收敛到常数 = 依概率收敛到常数”的等价（把 $\hat{\sigma}_n \xrightarrow{p} \sigma$ 塞进 $\xrightarrow{d}$ 的乘积里）；Delta 法的余项控制，则是 o_p/O_p 代数的直接应用。
- **极值估计的统一框架**（见后文『极值估计的统一框架』一章）。MLE、GMM、M-估计量的一致性要 $\xrightarrow{p}$ 、渐近正态是 $\xrightarrow{d}$ 、标准误的相合是又一个 $\xrightarrow{p}$ ；整套“三明治”协方差矩阵的推导，从头到尾都在用本章的四种模式与 o_p/O_p 记账。

收束一句：实数收敛只有一种意思，随机变量的收敛却有四种，而计量经济学恰好把它们都用上了——一致性要 $\xrightarrow{p}$ 、渐近分布要 $\xrightarrow{d}$ 、强相合要 $\xrightarrow{a.s.}$ 、矩的控制要 L^p 。分清它们，不是数学上的吹毛求疵，而是让“估计量好”与“检验有效”这两类核心论断各归其位的前提。

第三十一章 大数定律

用到的前置工具：随机变量、期望与方差（概率与测度部分）；收敛模式——依概率收敛 $\xrightarrow{P}$ 、几乎必然收敛 $\xrightarrow{a.s.}$ （见前一章“收敛模式”）；Lebesgue 积分意义下的期望与基本不等式（概率与测度部分）。

经济学家手里几乎所有的“用数据说话”，归根结底都依赖同一句承诺：把样本平均起来，就能逼近你真正关心的那个总体量。问卷里 1000 个人的平均收入，能代表全人群的期望收入吗？把过去 240 个月的股票超额收益平均一下，能当作真实的风险溢价吗？蒙特卡洛里抽 10^6 个随机数取平均，能算出那个解析上写不出来的积分吗？这些操作天天在做，但它们凭什么成立？大数定律（Law of Large Numbers, LLN）正是这句承诺的严格兑现：在适当条件下，样本均值 $\bar{X}_n$ 会收敛到总体期望 $\mu = \mathbb{E}(X)$ 。

本章要做三件事。先点明这条定律为何是整个统计推断的地基——没有它，“用样本估计总体”就成了无据的信仰；再把它证出来，从一条朴素得近乎显然的不等式（Markov 不等式）出发，三步到达弱大数定律，并交代去掉方差假设需要的“截断”技巧；最后说清它通向何处——矩估计、GMM、极大似然的一致性，蒙特卡洛积分，经验分布函数，乃至时间序列里的遍历定理，骨子里都是大数定律在各处的化身。

31.1 它在守护什么：从样本到总体的桥

把问题摆清楚。我们关心一个总体的某个数字特征——通常是某随机变量 X 的期望 $\mu = \mathbb{E}(X)$ （“平均收入”“平均回报”“某事件的真实概率”都属此类，后者是 $X = \mathbf{1}_A$ 的期望）。我们手上没有整个总体，只有一组观测 $X_1, \dots, X_n$ 。最自然的估计就是**样本均值**

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

问题是：凭什么相信这个由有限个、带随机性的观测算出来的数，会接近那个我们看不见的 μ ？

直觉上的理由人人都有：样本越大，“运气”越被摊薄。但直觉不是定理。 $\bar{X}_n$ 本身是随机变量——换一组样本就换一个值，它永远不会恰好等于 μ 。所谓“收敛”，必须是某种概率意义下的收敛（这正是前一章“收敛模式”要分清依概率 $\xrightarrow{P}$ 、几乎必然 $\xrightarrow{a.s.}$ 、依分布 $\xrightarrow{d}$ 的原因）。大数定律的内容，就是把“样本越大越准”这句口语，钉成一个可证的极限命题：

大数定律是一切“样本矩估计总体矩”的执照

几乎每一种估计方法的一致性，最终都化约为一句“某个样本平均收敛到对应的总体期望”：矩估计直接拿样本矩当总体矩，GMM 让样本矩条件趋于零，极大似然让样本平均对数似然趋于其期望，蒙特卡洛拿样本平均当积分。大数定律就是这张执照——没有它，“ n 大了就准”只是信念；有了它，它是定理。后续“极值估计的统一框架”一章会反复调用本章的结论。

31.2 两件趁手的不等式

证明大数定律出乎意料地省力，靠的是一条几乎显然、却异常有用的不等式。它把“期望”这一个数，翻译成对“尾部概率”的控制——而“ $\bar{X}_n$ 偏离 μ 太远”恰恰就是一个尾部事件。

定理 31.1: Markov 不等式

设 $Y \geq 0$ 是非负随机变量， $a > 0$ 。则

$$\mathbb{P}(Y \geq a) \leq \frac{\mathbb{E}(Y)}{a}.$$

证明. 关键是一个“指示函数被放大”的逐点不等式。对任意结果 ω ，比较两个非负量：若 $Y(\omega) \geq a$ ，则 $\mathbf{1}_{\{Y \geq a\}}(\omega) = 1$ ，而 $Y(\omega)/a \geq 1$ ，故 $\mathbf{1}_{\{Y \geq a\}} \leq Y/a$ ；若 $Y(\omega) < a$ ，则左边为 0，而右边非负，不等式同样成立。于是逐点有

$$\mathbf{1}_{\{Y \geq a\}} \leq \frac{Y}{a}.$$

两边取期望（期望保序，且 $\mathbb{E}(\mathbf{1}_A) = \mathbb{P}(A)$ ）：

$$\mathbb{P}(Y \geq a) = \mathbb{E}(\mathbf{1}_{\{Y \geq a\}}) \leq \mathbb{E}\left(\frac{Y}{a}\right) = \frac{\mathbb{E}(Y)}{a}. \quad \square$$

注（一行证明里藏着全部直觉）。

Markov 不等式说的是一件朴素的事：一个非负量若平均值不大，它就不可能经常取很大的值。若平均工资是 5 万，那么挣到 50 万以上的人占比至多 1/10——否则光这一撮人就把平均拉过 5 万了。它把对均值的一点知识，兑换成对尾部的控制。整个大数定律的证明，就是把“ $\bar{X}_n$ 远离 μ ”这件事识别成一个尾部事件，再用它来夹。

把 Markov 用到“偏离均值的平方”上，立刻得到一条以方差控制离散程度的不等式——它是弱大数定律的直接引擎。

定理 31.2: Chebyshev 不等式

设随机变量 X 有有限均值 $\mu = \mathbb{E}(X)$ 与有限方差 $\sigma^2 = \text{Var}(X)$ 。则对任意 $\varepsilon > 0$,

$$\mathbb{P}(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

证明. 令 $Y = (X - \mu)^2 \geq 0$, 这是个非负随机变量, 其期望恰是方差: $\mathbb{E}(Y) = \mathbb{E}((X - \mu)^2) = \sigma^2$ 。注意事件等价

$$\{|X - \mu| \geq \varepsilon\} = \{(X - \mu)^2 \geq \varepsilon^2\} = \{Y \geq \varepsilon^2\},$$

对 Y 用 Markov 不等式 (取 $a = \varepsilon^2$):

$$\mathbb{P}(|X - \mu| \geq \varepsilon) = \mathbb{P}(Y \geq \varepsilon^2) \leq \frac{\mathbb{E}(Y)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}. \quad \square$$

Chebyshev 不等式的形态值得记牢: **偏离均值至少 ε 的概率, 被方差与 ε^2 的比值压住**。方差越小、 X 越集中, 这个上界越紧。大数定律的诀窍正在于: 样本均值 $\bar{X}_n$ 的方差会随 n 趋于零, 于是把 X 换成 $\bar{X}_n$ 、把这条上界往零里赶, 就得到了收敛。

31.3 弱大数定律: 三步证完

先在最透亮的假设下把定理拿下: 观测两两不相关、同均值、且有相同的有限方差。这覆盖了 i.i.d. (独立同分布) 有限方差这一最常用的情形, 而证明短到可以一眼看穿。

假设 31.3: 两两不相关、同均值、方差有界

$X_1, X_2, \dots$ 各有相同均值 $\mathbb{E}(X_i) = \mu$ 与相同方差 $\text{Var}(X_i) = \sigma^2 < \infty$, 且两两不相关: $i \neq j$ 时 $\text{Cov}(X_i, X_j) = 0$ 。(i.i.d. 是其特例。)

定理 31.4: 弱大数定律 (WLLN, 有限方差)

在上述假设下, 样本均值依概率收敛到总体均值:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu,$$

即对任意 $\varepsilon > 0$, $\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \rightarrow 0$ ($n \rightarrow \infty$)。

证明. 三步: 算 $\bar{X}_n$ 的均值、算它的方差、套 Chebyshev。

第一步: 均值不变。期望是线性的,

$$\mathbb{E}(\bar{X}_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \cdot n\mu = \mu.$$

所以 $\bar{X}_n$ 是 μ 的无偏估计——它没有系统性的偏差，平均而言瞄准了靶心。

第二步：方差像 $1/n$ 那样塌缩。这是全证明的心脏。由两两不相关，和的方差等于方差之和（交叉的协方差项全为零）：

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0.$$

注意那个 $1/n^2$ ：把和缩成均值时除了一个 n ，方差里就变成除以 n^2 ，而被加的项只有 n 个——一进一出，净剩 $1/n$ 。这就是“样本越大越准”的全部数学内容：估计量绕着靶心的抖动，按 $1/n$ 的速度被摊平。

第三步：Chebyshev 收口。把 Chebyshev 不等式用到 $\bar{X}_n$ 上（它的均值是 μ 、方差是 σ^2/n ）：对任意 $\varepsilon > 0$,

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

固定 ε 让 $n \rightarrow \infty$ ，右边趋于零，左边被夹到零。这正是 $\bar{X}_n \xrightarrow{P} \mu$ 的定义。 $\square$

注（为什么叫“弱”）。

这里证出的是依概率收敛：对每个固定的 n ，“ $\bar{X}_n$ 偏离 μ 超过 ε ”的概率很小，且随 n 趋于零。但它没有断言：沿着某一条具体的样本路径 $\bar{X}_1, \bar{X}_2, \dots$ 看过去，这串数最终会稳稳停在 μ 附近不再大幅跳出。后者是更强的“几乎必然”收敛，由强大数定律给出。“弱”与“强”的分野，正是前一章“收敛模式”里 $\xrightarrow{P}$ 与 $\xrightarrow{a.s.}$ 的分野——记住： $\xrightarrow{a.s.} \Rightarrow \xrightarrow{P}$ ，反之不然。

图 31.1 把第二步的直觉画了出来：样本均值的分布随 n 增大越挤越窄地堆到 μ 上，于是落在 μ 的任意 ε -邻域之外的概率被挤向零。




图 31.1: 样本均值 $\bar{X}_n$ 的分布随 n 增大越挤越窄地集中到 μ （这里 $\sigma = 1$ ，方差 σ^2/n 依次为 $1/4, 1/16, 1/64$ ）。落在 ε -邻域 $[\mu - \varepsilon, \mu + \varepsilon]$ 之外的概率随之被挤向零，这正是 $\bar{X}_n \xrightarrow{P} \mu$ 。

31.4 去掉方差假设：Khinchin 与截断的骨架

Chebyshev 证法漂亮，但它欠下一笔债：用到了有限方差 $\sigma^2 < \infty$ 。可经济学里偏偏有不少厚尾分布（收入、城市规模、金融收益）方差是发散的；对它们，“期望”仍然有限、有意义，我们照样想要“样本均值收敛到期望”。Khinchin 的定理正补上这一块：只要 i.i.d. 且期望有限，弱大数定律就成立——方差可以不存在。

定理 31.5: Khinchin 弱大数定律

设 $X_1, X_2, \dots$ 独立同分布，期望有限： $\mathbb{E}(|X_1|) < \infty$ ，记 $\mu = \mathbb{E}(X_1)$ 。则

$$\bar{X}_n \xrightarrow{P} \mu.$$

完整证明（特征函数法只需两行，但要用到尚未介绍的特征函数）超出本章主线。这里给截断法的骨架——它是渐近统计里反复出现的标准招式，值得看清其轮廓。困难在于方差可能无穷，Chebyshev 用不上；办法是把每个变量在一个随 n 增长的阈值处“砍头”，分成“截断部分”与“尾巴部分”分别对付。

截断法三步骨架（直觉）

取一个随 n 缓慢增长的阈值 $b_n \rightarrow \infty$ ，把每个 X_i 拆成截断与残余两块：

$$X_i = \underbrace{X_i \mathbf{1}_{\{|X_i| \leq b_n\}}}_{Y_i(\text{截断, 有界})} + \underbrace{X_i \mathbf{1}_{\{|X_i| > b_n\}}}_{Z_i(\text{残余, 少见})}.$$

(1) 截断块 Y_i 有界，故方差有限，可对 $\bar{Y}_n$ 用 Chebyshev——这块照搬上一节的论证；只需把 b_n 调得让方差项仍趋于零。(2) 残余块可忽略：因 $\mathbb{E}(|X_1|) < \infty$ ，落在阈值之外的概率与贡献都随 $b_n \rightarrow \infty$ 被 $\mathbb{E}(|X_1| \mathbf{1}_{\{|X_1| > b_n\}}) \rightarrow 0$ 压住（这一步正是“期望有限”发挥作用之处）。(3) 截断后的均值不偏太多： $\mathbb{E}(Y_i) \rightarrow \mu$ 。把三块拼起，便得 $\bar{X}_n \xrightarrow{P} \mu$ 。有限期望——而非有限方差——才是弱大数定律真正需要的最低要求。

注（为什么期望有限不可再省）。

“期望有限”是底线，不能再弱。经典反例是柯西分布（密度 $\frac{1}{\pi(1+x^2)}$ ）：它对称、看着“中心在 0”，但 $\mathbb{E}(|X|) = \infty$ ，期望根本不存在。对它， $\bar{X}_n$ 不会收敛到任何常数——事实上 $\bar{X}_n$ 与单个 X_1 同分布，再多的样本也不会让平均值安定下来。这正说明：大数定律不是“取平均”这一动作本身的魔法，而是“存在一个有限期望可供收敛”这一前提的兑现。

31.5 强大数定律：沿路径的收敛

弱大数定律谈的是“每个 n 上的概率”；强大数定律谈的是“整条样本路径的命运”。把同一个 ω （一整次实验、一整条无穷长的观测序列）固定下来，就得到一串确定的数

$\bar{X}_1(\omega), \bar{X}_2(\omega), \dots$ 。强大数定律断言：除了一个概率为零的坏样本集合之外，每一条这样的路径作为普通数列都收敛到 μ 。

定理 31.6: Kolmogorov 强大数定律 (SLLN)

设 $X_1, X_2, \dots$ 独立同分布且期望有限 $\mathbb{E}(|X_1|) < \infty$, $\mu = \mathbb{E}(X_1)$ 。则样本均值几乎必然收敛到 μ ：

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1, \quad \text{即} \quad \bar{X}_n \xrightarrow{\text{a.s.}} \mu.$$

(反之亦真：若 $\bar{X}_n$ 几乎必然收敛到某有限常数，则 $\mathbb{E}(|X_1|)$ 必有限。故对 i.i.d. 而言，有限期望既充分又必要。)

严格证明依赖 Kolmogorov 的极大不等式与三级数定理（或 Etemadi 的子序列截断论证），属于较重的纯概率构造，本书按使用者的需要只陈述、给直觉，不逐行搭建。要抓住的是“强”比“弱”强在哪里：

$\xrightarrow{\text{a.s.}}$ 与 $\xrightarrow{p}$ 的差别，画在一张图上才看得清

依概率（弱）：盯住某个固定的时刻 n ，问“此刻偏离超 ε 的概率多大”——它随 n 趋零。但它允许某条路径在 $n = 10^3, 10^6, 10^9, \dots$ 处一次次偶发地跳出 ε -带，只要这种跳出越来越稀疏即可。

几乎必然（强）：盯住一整条路径，问“它最终会不会永远留在 μ 的任意 ε -带里”——强大数定律说，除一个零概率的例外集外，会。也就是：对几乎每条路径，存在一个时刻 $N(\omega)$ ，此后再不跳出。

一句话：弱定律管“某一刻”，强定律管“从某刻起的全部将来”。 $\xrightarrow{\text{a.s.}} \Rightarrow \xrightarrow{p}$ ；反向一般不成立。

图 31.2 画几条真实模拟出来的样本均值路径：横轴 n （对数刻度，好让早期的剧烈摆动与后期的安定同框可见），纵轴 $\bar{X}_n$ 。早期各路径在宽处乱晃，随 n 增大被一条按 $\propto 1/\sqrt{n}$ 收紧的波动带逼回，最终一起贴向水平线 μ 。强大数定律保证的，正是这种“逐条路径收敛”。

31.6 大数定律就是“一致性”

把大数定律放进计量的语言，它的名字叫**一致性** (consistency)。一个估计量 $\hat{\theta}_n$ 称为 θ_0 的（弱）一致估计，如果 $\hat{\theta}_n \xrightarrow{p} \theta_0$ 。对样本均值 $\bar{X}_n$ 估计 μ 这件事，“弱大数定律”与“ $\bar{X}_n$ 是 μ 的一致估计”是同一句话的两种说法。

无偏与一致是两回事，别混

无偏 (unbiasedness) 是固定样本量下的性质： $\mathbb{E}(\hat{\theta}_n) = \theta_0$ ，平均而言瞄准靶心。

一致 (consistency) 是样本量趋于无穷下的性质： $\hat{\theta}_n \xrightarrow{p} \theta_0$ ，估计量本身（而非




图 31.2: 四条样本均值路径 $\{\bar{X}_n\}$ (i.i.d. 抽样, $\mu = 2$)。早期在宽处乱晃, 随 n 增大被一条按 $\propto 1/\sqrt{n}$ 收紧的波动带逼回水平线 μ 。强大数定律保证: 除一个零概率的例外集外, 每一条这样的路径都收敛到 μ 。

其平均) 越来越逼近真值。二者既不互推、也常常错位: 样本均值既无偏又一致; 样本方差除以 n (而非 $n-1$) 的版本有偏, 却仍一致; 存在无偏却不一致的估计 (如只用第一个观测 $\hat{\theta}_n = X_1$, 永远无偏, 但根本不收敛)。计量里真正不可或缺的是**一致性**——它说“数据够多就对”, 这恰是大数定律所给。

最常用、也最该记住的推广方式, 是“连续函数不破坏一致性”。这一步把“样本均值”升级成“几乎任何由样本矩拼出来的估计量”, 是从大数定律走向 GMM、MLE 一致性的关键转接口。

定理 31.7: 连续映射保持一致性

若 $\hat{\theta}_n \xrightarrow{p} \theta_0$, 且 g 在 θ_0 处连续, 则 $g(\hat{\theta}_n) \xrightarrow{p} g(\theta_0)$ 。

这条结论的完整名字是连续映射定理, 将在后文“连续映射定理、Slutsky 与 Delta 法”一章里证明并推广 (它对依分布收敛也成立)。它的威力在于: 很多估计量本身不是某个简单平均, 却是若干样本矩的连续函数。比如样本方差

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2,$$

它是两个样本矩 $\frac{1}{n} \sum X_i^2 \xrightarrow{p} \mathbb{E}(X^2)$ 与 $\bar{X}_n \xrightarrow{p} \mathbb{E}(X)$ 的连续函数 ($g(a, b) = a - b^2$)。于是由大数定律加连续映射, 立刻有 $s_n^2 \xrightarrow{p} \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = \sigma^2$ ——样本方差是总体方差的一致估计。大数定律给“一阶”的样本矩收敛, 连续映射把它批发给一大类非线性估计量。

例 (样本相关系数的一致性)。

设 (X_i, Y_i) i.i.d., 各阶矩有限。说明样本相关系数

$$\hat{\rho}_n = \frac{\frac{1}{n} \sum_i X_i Y_i - \bar{X}_n \bar{Y}_n}{\sqrt{\left(\frac{1}{n} \sum_i X_i^2 - \bar{X}_n^2\right) \left(\frac{1}{n} \sum_i Y_i^2 - \bar{Y}_n^2\right)}}$$

是总体相关系数 $\rho = \text{Corr}(X, Y)$ 的一致估计。

解.

$\hat{\rho}_n$ 完全由五个样本矩搭成: $\frac{1}{n} \sum X_i Y_i$, $\frac{1}{n} \sum X_i^2$, $\frac{1}{n} \sum Y_i^2$, $\bar{X}_n$, $\bar{Y}_n$ 。由大数定律, 这五个样本矩分别依概率收敛到对应的总体矩

$$\mathbb{E}(XY), \quad \mathbb{E}(X^2), \quad \mathbb{E}(Y^2), \quad \mathbb{E}(X), \quad \mathbb{E}(Y).$$

而 $\hat{\rho}_n$ 是这五个量的一个函数 g , 它在极限点处连续 (只要分母里两个方差都为正, g 在该点是初等运算与开方的复合, 连续)。由连续映射定理,

$$\hat{\rho}_n \xrightarrow{P} g(\mathbb{E}(XY), \mathbb{E}(X^2), \mathbb{E}(Y^2), \mathbb{E}(X), \mathbb{E}(Y)) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \rho.$$

没有动用任何分布形式假设、也没碰收敛速度——一致性是大数定律加连续性“白送”的。

31.7 它通向何处

大数定律不是概率论里一条孤立的极限定理, 它是整张“用样本逼近总体”的网的中心结点。几处主要去处:

- **矩估计与 GMM**。矩估计直接拿样本矩当总体矩——其一致性就是大数定律。GMM 把模型写成一组总体矩条件 $\mathbb{E}(g(\mathbf{Z}, \boldsymbol{\theta}_0)) = \mathbf{0}$, 估计量让对应的样本矩 $\frac{1}{n} \sum_i g(\mathbf{Z}_i, \boldsymbol{\theta})$ 尽量接近零; 大数定律保证样本矩函数 (逐点) 收敛到总体矩函数, 这是 GMM 一致性证明的第一块砖。
- **极大似然**。MLE 最大化样本平均对数似然 $\frac{1}{n} \sum_i \log f(X_i; \boldsymbol{\theta})$ 。大数定律说它 (逐点) 收敛到其期望 $\mathbb{E}(\log f(X; \boldsymbol{\theta}))$, 而后者在真值处取最大 (信息不等式)。“样本目标函数收敛到总体目标函数、各自的最大值点也随之靠拢”——这套论证 (需配上一致收敛与可识别性) 是 MLE 一致性的骨架, 详见后文“极值估计的统一框架”一章。
- **蒙特卡洛积分**。要算 $\mathbb{E}(h(X)) = \int h \, dF$ 而积分写不出解析解时, 抽 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$ 、用 $\frac{1}{n} \sum_i h(X_i)$ 近似。这正是大数定律: 样本平均 $\xrightarrow{P}$ 期望。整个随机模拟方法论 (贝叶斯计算、结构估计里的模拟矩) 都站在这一句上。
- **经验分布函数与 Glivenko–Cantelli**。对每个固定的 t , 经验分布 $\hat{F}_n(t) = \frac{1}{n} \sum_i \mathbf{1}_{\{X_i \leq t\}}$ 是示性变量的样本均值, 故 $\hat{F}_n(t) \xrightarrow{P} F(t)$ ——又一次大数定律。Glivenko–Cantelli 定理把这一“逐点”收敛加强为一致收敛 $\sup_t |\hat{F}_n(t) - F(t)| \xrightarrow{a.s.} 0$, 是“统计学基本定理”, 为一切基于经验分布的方法 (分位数估计、自助法) 奠基。

- **时间序列的遍历定理。**经济数据多是时间序列, 观测前后相关, 不满足 i.i.d.。此时把大数定律推广成**遍历定理**: 对平稳遍历过程, 时间平均 $\frac{1}{n} \sum_{t=1}^n X_t \xrightarrow{a.s.} \mathbb{E}(X_1)$ 仍成立。它让“用一条历史路径估计总体期望”在相依数据下重新合法, 是宏观计量与金融计量的命脉。

一句话收束

大数定律把“样本平均逼近总体期望”从信念变成定理; 连续映射定理把这一条结论批发给几乎所有由样本矩搭成的估计量。**一致性**——估计方法“数据够多就对”的最低承诺——其根全在这里。它的下一站是问“逼近得有多快、误差长什么样”, 那就是中心极限定理的领地。

第三十二章 中心极限定理

用到的前置工具：随机变量、分布与期望（概率与测度部分）；独立性与多元正态（『多维分布、独立性与变量变换』一章）；依分布收敛（见前文『收敛模式』一章）；大数定律（见前文『大数定律』一章）；Taylor 展开（多元微积分部分）。

上一章的大数定律告诉我们样本均值会收敛到总体均值——它定住了估计量的“靶心”，却没说估计量在靶心周围如何抖动。可计量经济学真正赖以生存的，恰恰是后者：一个置信区间要多宽、一个 t 统计量该和什么分布比、一个 Wald 检验的临界值从哪来，全都取决于估计量围绕真值的波动形态。中心极限定理（central limit theorem, CLT）正是回答这个问题的工具。它给出一个出人意料地干净的答案：只要把样本均值减去其期望、再按 $\sqrt{n}$ 放大，无论原始数据服从什么分布，这个标准化后的量都会收敛到同一个极限——标准正态。

这件事的份量怎么强调都不过分。大数定律说“ $\bar{X}_n$ 趋于 μ ”，是一句关于“位置”的话；中心极限定理说“ $\sqrt{n}(\bar{X}_n - \mu)$ 趋于 $\mathcal{N}(0, \sigma^2)$ ”，是一句关于“形状”的话——而正是这个形状，让我们能给估计量配上标准误、画出置信区间、算出 p 值。本章先说清这件工具解决什么问题、 $\sqrt{n}$ 这个标度从何而来，再用特征函数法把“为什么极限恰是正态”讲透，然后陈述放松了同分布假设的版本（Lyapunov / Lindeberg）与多元版本，最后指明它在计量推断里的几处主战场。

32.1 问题：估计量围绕真值如何波动

设 $X_1, \dots, X_n$ 独立同分布（iid），均值 $\mathbb{E}(X_i) = \mu$ 、方差 $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$ 。样本均值

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

是 μ 的最自然估计。大数定律给出 $\bar{X}_n \xrightarrow{P} \mu$ ：随 $n \rightarrow \infty$ ，整条抽样分布会塌缩到 μ 这一个点。但“塌缩”本身没法用来做推断——若极限是一个退化于 μ 的点质量，我们就无从谈论“ $\bar{X}_n$ 偏离 μ 多远算正常”。

要看清波动的形状，得把这个不断收缩的分布放大到一个非退化的尺度上。先算一下该放大多少。由独立性，

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

方差以 $1/n$ 的速率趋于 0，故标准差以 $1/\sqrt{n}$ 的速率趋于 0。要让放大后的量有一个固定（不为 0 也不发散）的方差，就得乘以 $\sqrt{n}$ ：

$$\text{Var}(\sqrt{n}(\bar{X}_n - \mu)) = n \cdot \text{Var}(\bar{X}_n) = n \cdot \frac{\sigma^2}{n} = \sigma^2.$$

这正是 $\sqrt{n}$ 标度的来历——它不是凑出来的魔法常数，而是恰好抵消方差收缩速率的那个唯一标度。乘少了（比如只乘 $n^{1/4}$ ）量仍塌缩到 0，乘多了（比如乘 n ）量发散到无穷；唯有 $\sqrt{n}$ 把分布定格在一个固定的、可供推断的非退化形状上。

$\sqrt{n}$ 标度是 CLT 的中枢

样本均值的方差是 σ^2/n 。为把不断收缩的抽样分布稳定到一个非退化极限，标准化必须按 $\sqrt{n}$ 放大： $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$ 。计量里一切以 $\sqrt{n}(\hat{\theta} - \theta_0)$ 形式出现的渐近结果，量纲上的根据都在这里：估计量以 $O_p(n^{-1/2})$ 的速率收敛，故须用 $\sqrt{n}$ 校准才能看清其极限分布。

剩下的问题只有一个：放大后这个量长什么形状？中心极限定理的回答是——总是同一个钟形。

32.2 Lindeberg-Lévy 中心极限定理

定理 32.1: Lindeberg-Lévy 中心极限定理 (iid 情形)

设 $X_1, X_2, \dots$ 独立同分布， $\mathbb{E}(X_i) = \mu$ ， $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$ 。则

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \quad \text{等价地} \quad \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1).$$

这里只要求“有限的二阶矩”——存在均值与方差，别无其它。不需要数据本身正态，不需要对称，不需要连续；离散的、偏斜的、重尾但二阶矩仍有限的分布，统统适用。结论里那个正态，是从这些五花八门的原始分布里涌现出来的，而非假设进去的。

图 32.1 把这件事画了出来：左边是一个明显右偏、毫不像正态的原始总体；右边是其样本均值标准化后的抽样分布，随 n 增大一步步贴近黑色的 $\mathcal{N}(0, 1)$ 钟形。 $n = 2$ 时仍带着原分布的偏斜， $n = 5$ 时偏斜大幅减弱，到 $n = 30$ 已很接近极限钟形（仔细看仍留一点右偏的尾巴——指数总体收敛偏慢）。

注 (CLT 与 LLN 是同一现象的两个尺度)。

大数定律与中心极限定理说的是同一个收缩过程，只是看的放大倍率不同。不放大（看 $\bar{X}_n$ 本身）：分布塌缩到点 μ ，这是 LLN。放大 $\sqrt{n}$ 倍（看 $\sqrt{n}(\bar{X}_n - \mu)$ ）：塌缩被恰好抵消，露出一个固定的钟形，这是 CLT。所以 CLT 常被称作 LLN 的“二阶”细化：LLN 给收敛的位置，CLT 给收敛的速率与涨落形状。




图 32.1: 即便原始总体明显偏斜 (左), 其样本均值的标准化抽样分布也随 n 增大逐步逼近标准正态钟形 (右)。这里原始总体取指数分布; $n = 30$ 的曲线已很接近 $\mathcal{N}(0, 1)$ (仍带一丝可见的右偏)。

32.3 为什么极限恰是正态：特征函数法

要证明“标准化和趋于正态”，最锋利的工具是特征函数。它把“独立随机变量相加”这件在密度层面要做卷积的麻烦事，变成“特征函数相乘”这件代数上的易事；而依分布收敛，又恰好可由特征函数的逐点收敛来判别（Lévy 连续性定理）。两者一合，证明几乎是自动展开的。

定义 32.2: 特征函数

随机变量 X 的特征函数 (characteristic function) 为

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \mathbb{E}(\cos tX) + i \mathbb{E}(\sin tX), \quad t \in \mathbb{R}.$$

它对一切随机变量都有定义（被积函数有界， $|e^{itX}| = 1$ ），且唯一地决定分布。

特征函数有两条性质是这整套证明的全部支柱。

事实 32.3: 特征函数的两条关键性质

设 X, Y 独立， a, b 为常数。则

1. 独立和化为乘积： $\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t)$ ；更一般地，对线性变换 $\varphi_{aX+b}(t) = e^{itb} \varphi_X(at)$ 。

2. 矩生成 Taylor 系数：若 $\mathbb{E}(|X|^2) < \infty$ ，则在 $t = 0$ 附近

$$\varphi_X(t) = 1 + it \mathbb{E}(X) - \frac{1}{2} t^2 \mathbb{E}(X^2) + o(t^2).$$

第一条来自独立时期望可分解： $\mathbb{E}(e^{it(X+Y)}) = \mathbb{E}(e^{itX} e^{itY}) = \mathbb{E}(e^{itX}) \mathbb{E}(e^{itY})$ 。第二条来自把 e^{itX} 在 $t = 0$ 处对 t 做 Taylor 展开 $e^{itX} = 1 + itX - \frac{1}{2} t^2 X^2 + \dots$ 再取期望（有限二阶矩保证逐项取期望与余项控制成立）。把这两条性质对准“标准化的 iid 和”，正态就会自己长出来。

定理 32.4: Lévy 连续性定理

设 $\{Z_n\}$ 为随机变量列, φ_{Z_n} 为其特征函数。若存在函数 φ , 它在 $t=0$ 处连续, 且对每个 t 都有 $\varphi_{Z_n}(t) \rightarrow \varphi(t)$, 则 φ 是某随机变量 Z 的特征函数, 且 $Z_n \xrightarrow{d} Z$ 。

这条定理是把“特征函数收敛”翻译成“分布收敛”的桥。它的深刻处(即“逐点收敛的极限确实是一个特征函数”)属于纯分析, 本书按使用者的需要把它当作已知工具, 重点放在如何用它收尾。有了它, 证明 $Z_n \xrightarrow{d} \mathcal{N}(0, 1)$ 就只剩一件事: 证明 $\varphi_{Z_n}(t) \rightarrow e^{-t^2/2}$ ——因为 $e^{-t^2/2}$ 恰是标准正态的特征函数。

定理 32.5: Lindeberg-Lévy CLT (特征函数法)

不妨设 $\mu = 0$ 、 $\sigma^2 = 1$ (否则先做 $X_i \mapsto (X_i - \mu)/\sigma$, 这不改变结论的形式)。要证 $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i \xrightarrow{d} \mathcal{N}(0, 1)$ 。

定理的证明

记 $\varphi(t) = \varphi_{X_i}(t)$ 为单个 X_i 的特征函数(iid, 故各项相同)。由性质 1, $Z_n = \frac{1}{\sqrt{n}} \sum_i X_i$ 是独立项之和再缩放, 其特征函数为

$$\varphi_{Z_n}(t) = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{\sqrt{n}}\right) = \left[\varphi\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

由性质 2, 并代入 $\mathbb{E}(X_i) = 0$ 、 $\mathbb{E}(X_i^2) = \sigma^2 = 1$, 把自变量取作 $t/\sqrt{n}$ (当 $n \rightarrow \infty$ 时它趋于 0, 故 Taylor 展开适用):

$$\varphi\left(\frac{t}{\sqrt{n}}\right) = 1 + i \frac{t}{\sqrt{n}} \cdot 0 - \frac{1}{2} \frac{t^2}{n} \cdot 1 + o\left(\frac{1}{n}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

于是

$$\varphi_{Z_n}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n.$$

对固定的 t , 用极限 $(1 + \frac{a_n}{n})^n \rightarrow e^a$ (当 $a_n \rightarrow a$)——这里 $a_n = -\frac{t^2}{2} + o(1) \rightarrow -\frac{t^2}{2}$ ——得

$$\varphi_{Z_n}(t) \longrightarrow e^{-t^2/2} \quad (\forall t).$$

极限 $e^{-t^2/2}$ 在 $t=0$ 处连续, 正是 $\mathcal{N}(0, 1)$ 的特征函数。由 Lévy 连续性定理, $Z_n \xrightarrow{d} \mathcal{N}(0, 1)$ 。

这条证明把“为什么是正态”说得一清二楚。看那个关键展开: 单项特征函数的一阶项 $it\mathbb{E}(X)$ 因中心化而消失, 留下的最低阶信息是二阶项 $-\frac{1}{2}t^2\mathbb{E}(X^2)$ ——也就是说, 标准化之后, 原始分布的所有细节(偏度、峰度、是离散还是连续)都退到 $o(t^2)$ 的高阶项里, 唯有“方差”这一个数留在主导项上。 n 个这样的因子相乘(特征函数取 n 次幂), 把 $1 - \frac{t^2}{2n}$ 复利式地累积成 $e^{-t^2/2}$ 。

正态是“唯一记得均值与方差、忘掉其余”的吸引子

标准化抹平了一阶项，于是不同分布在 $\sqrt{n}$ 标度下的差异只剩二阶（方差）；而 $\left[1 - \frac{t^2}{2n}\right]^n \rightarrow e^{-t^2/2}$ 把这唯一残存的二阶信息卷成了高斯。正因为“只有方差幸存”，形形色色的原始分布才统统被吸进同一个极限——正态分布是独立小扰动累加的吸引子。这也解释了经验世界里钟形为何无处不在：任何由大量独立小因素叠加而成的量（测量误差、身高、资产收益的短期累积）都倾向于近似正态。

图 32.2 把这个“二阶吻接 $\Rightarrow$ 高斯”的机理画了出来：任意有限二阶矩分布的标准化特征函数 $\varphi_{Z_n}(t)$ ，在 $t=0$ 处都与同一条抛物线 $1 - \frac{t^2}{2}$ 二阶相切（它们的二阶 Taylor 系数被标准化锁成同一个），而把这条共同的“种子”按 n 次幂累积，极限就是高斯特征函数 $e^{-t^2/2}$ 。




图 32.2: 特征函数法的几何。标准化后，任意（有限二阶矩）分布的特征函数 $\varphi_{Z_n}(t)$ 在 $t=0$ 处都与同一条抛物线 $1 - \frac{t^2}{2}$ 二阶相切；把这个共同的二阶种子取 n 次幂复利累积，极限就是高斯特征函数 $e^{-t^2/2}$ （黑线）。纵轴已缩放，顶点对应 $\varphi(0) = 1$ 。

注（为什么不用矩母函数）。

矩母函数 $M_X(t) = \mathbb{E}(e^{tX})$ 也能把独立和化为乘积，证明读起来更省力。但它的硬伤是不一定存在——重尾分布（如 Cauchy、某些幂律收益）连均值都没有，矩母函数在 $t=0$ 之外可能发散。特征函数把 e^{tX} 换成 e^{itX} ，被积函数恒有界、期望永远存在，因此对一切分布都管用。这就是渐近统计宁用特征函数、不用矩母函数的原因。

32.4 放松同分布：Lyapunov 与 Lindeberg

iid 假设在计量里常常太强。回归里每个观测的解释变量取值不同，异方差使各项方差不等，面板与时间序列里各项的分布更是逐个相异。我们要的是：在“各项独立但不同分布”时，标准化和何时仍趋于正态？关键直觉是——只要没有任何单独一项支配整个和，正态性就保得住。把这句话定量化，就得到 Lindeberg 条件。

设 $X_1, \dots, X_n$ 独立（不必同分布）， $\mathbb{E}(X_i) = \mu_i$ ， $\text{Var}(X_i) = \sigma_i^2$ ，记总方差 $s_n^2 = \sum_{i=1}^n \sigma_i^2$ 。考察标准化和 $\frac{1}{s_n} \sum_{i=1}^n (X_i - \mu_i)$ 。

定理 32.6: Lindeberg 中心极限定理

若对每个 $\varepsilon > 0$ 都有 **Lindeberg 条件**

$$\frac{1}{s_n^2} \sum_{i=1}^n \mathbb{E}((X_i - \mu_i)^2 \mathbf{1}\{|X_i - \mu_i| > \varepsilon s_n\}) \rightarrow 0 \quad (n \rightarrow \infty),$$

则

$$\frac{1}{s_n} \sum_{i=1}^n (X_i - \mu_i) \xrightarrow{d} \mathcal{N}(0, 1).$$

Lindeberg 条件读起来吓人，含义却朴素：方括号里的示性函数只挑出“偏离自身均值超过总标准差 εs_n ”的那部分大涨落，条件要求所有这些大涨落对总方差的贡献一致地可忽略。换句话说，没有哪一项（或哪几项）的尾巴大到能左右整个和——和是由许多势均力敌的小项堆出来的。这正是“众多小因素叠加”那句直觉的严格版本。

实践中 Lindeberg 条件不好直接验，于是常用一个更强、却好查的充分条件：

推论 32.7: Lyapunov 中心极限定理

若存在某个 $\delta > 0$ 使 **Lyapunov 条件**

$$\frac{1}{s_n^{2+\delta}} \sum_{i=1}^n \mathbb{E}(|X_i - \mu_i|^{2+\delta}) \rightarrow 0 \quad (n \rightarrow \infty),$$

则 Lindeberg 条件成立，从而 $\frac{1}{s_n} \sum_{i=1}^n (X_i - \mu_i) \xrightarrow{d} \mathcal{N}(0, 1)$ 。

Lyapunov 条件只要求一个比方差略高的矩（取 $\delta = 1$ 即三阶绝对矩、 $\delta = 2$ 即四阶矩）一致受控，便足以排除单项支配。它是计量实证里验证非同分布 CLT 最常用的入口——比如证明异方差下 OLS 估计量的渐近正态时，对误差项加一条“ $2 + \delta$ 阶矩有界”的矩条件，走的就是 Lyapunov 这条路。

注（iid 是非同分布版本的特例）。

当 X_i iid 时， $\sigma_i^2 \equiv \sigma^2$ ， $s_n^2 = n\sigma^2$ ， $s_n = \sigma\sqrt{n}$ ，于是 $\frac{1}{s_n} \sum_i (X_i - \mu) = \frac{1}{\sigma\sqrt{n}} \sum_i (X_i - \mu) = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$ ——正好回到 Lindeberg-Lévy 的标准化形式。此时 Lyapunov 条件退化为“ $\mathbb{E}\left(|X_i - \mu|^{2+\delta}\right) < \infty$ ”（自动成立，因为 $\frac{n \cdot C}{(\sigma\sqrt{n})^{2+\delta}} = \frac{C}{\sigma^{2+\delta}} n^{-\delta/2} \rightarrow 0$ ）。所以 iid CLT 是这套更一般框架的一个干净特例。

32.5 多元中心极限定理

计量里的估计量几乎总是向量：一条回归有一整组系数，GMM 有一组矩条件。我们需要的是“随机向量的样本均值”的联合渐近分布——它决定了系数们一起如何波动，也就决定了联合检验（Wald）的分布。所幸，多元版本可以由一元版本直接搭出来，靠的是一条把“向量收敛”归约到“所有标量方向收敛”的工具。

定理 32.8: Cramér-Wold 投影法则

$\mathbb{R}^k$ 中的随机向量列 $\{\mathbf{Z}_n\}$ 依分布收敛到 $\mathbf{Z}$, 当且仅当对每个固定方向 $\boldsymbol{\lambda} \in \mathbb{R}^k$, 标量投影都收敛:

$$\boldsymbol{\lambda}^\top \mathbf{Z}_n \xrightarrow{d} \boldsymbol{\lambda}^\top \mathbf{Z} \quad (\forall \boldsymbol{\lambda} \in \mathbb{R}^k).$$

这条法则的用处是“降维”: 要判定一个向量列的依分布收敛, 只需对它的每一条一维投影用我们已经会的一元 CLT。把它和 iid 一元 CLT 一拼, 多元 CLT 立得。

定理 32.9: 多元中心极限定理

设 $\mathbf{X}_1, \mathbf{X}_2, \dots$ 为 $\mathbb{R}^k$ 中的 iid 随机向量, 均值 $\mathbb{E}(\mathbf{X}_i) = \boldsymbol{\mu}$, 协方差矩阵 $\text{Var}(\mathbf{X}_i) = \boldsymbol{\Sigma}$ (各元素有限)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}),$$

其中 $\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$, $\mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ 是均值 $\mathbf{0}$ 、协方差 $\boldsymbol{\Sigma}$ 的多元正态。

证明. 取任意固定方向 $\boldsymbol{\lambda} \in \mathbb{R}^k$, 把向量问题投影成标量。令 $Y_i = \boldsymbol{\lambda}^\top \mathbf{X}_i$, 则 $Y_1, Y_2, \dots$ 是 iid 标量随机变量, 其均值与方差为

$$\mathbb{E}(Y_i) = \boldsymbol{\lambda}^\top \boldsymbol{\mu}, \quad \text{Var}(Y_i) = \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda}.$$

对这列标量用一元 Lindeberg-Lévy CLT:

$$\sqrt{n}(\bar{Y}_n - \boldsymbol{\lambda}^\top \boldsymbol{\mu}) = \boldsymbol{\lambda}^\top \sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{d} \mathcal{N}(0, \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda}).$$

而 $\mathcal{N}(0, \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda})$ 恰是 $\boldsymbol{\lambda}^\top \mathbf{W}$ 的分布, 其中 $\mathbf{W} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ (因为多元正态的线性投影 $\boldsymbol{\lambda}^\top \mathbf{W} \sim \mathcal{N}(0, \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda})$, 见『多维分布、独立性与变量变换』一章)。于是对每个 $\boldsymbol{\lambda}$ 都有 $\boldsymbol{\lambda}^\top \sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{d} \boldsymbol{\lambda}^\top \mathbf{W}$ 。由 Cramér-Wold 法则, $\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{d} \mathbf{W} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ 。□

这里浮现的协方差矩阵 $\boldsymbol{\Sigma}$ 就是后续一切“渐近协方差”的源头: 它的对角元给出各分量的渐近方差 (标准误的平方), 非对角元给出分量间的渐近相关——正是联合假设检验需要的全部信息。

32.6 去处: 渐近推断的总枢纽

把估计量的渐近正态接回计量推断, 是本章工具的归宿。下面这些是它的主战场。

从 CLT 到一个置信区间

对 iid 样本, CLT 给 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 。用样本方差 $\hat{\sigma}^2 \xrightarrow{p} \sigma^2$ 替换未知的 σ^2 (这一步替换的合法性由 Slutsky 定理保证, 见后文『连续映射定理、Slutsky

与 Delta 法』一章)，得 t 形式的枢轴量

$$\frac{\bar{X}_n - \mu}{\hat{\sigma}/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

于是 μ 的渐近 95% 置信区间是 $\bar{X}_n \pm 1.96 \hat{\sigma}/\sqrt{n}$ 。区间宽度以 $1/\sqrt{n}$ 收缩——样本翻四倍，区间才缩一半，这条“ $\sqrt{n}$ 速率”贯穿整个渐近推断。

- **估计量的渐近正态。**计量里的主流估计量（OLS、MLE、GMM、更一般的 M-估计量）几乎都能写成“某个 iid（或独立）量的样本平均”的形式，或经由一阶条件归约到这种形式。对那个平均用 CLT，就得到统一的结论 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{V})$ 。这正是后文『极值估计的统一框架』一章的主线，那里的“三明治”协方差矩阵 $\mathbf{V}$ 就来自把 CLT 用在样本一阶条件上、再配上隐函数式的线性化。
- **t 、Wald、LM 检验。**一旦有了 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{V})$ ，标准的检验统计量就都有了极限分布：单参数的 t 比趋于 $\mathcal{N}(0, 1)$ ；多约束的 Wald 统计量 $\sqrt{n}(\hat{\theta} - \theta_0)^\top \hat{\mathbf{V}}^{-1} \sqrt{n}(\hat{\theta} - \theta_0)$ 趋于 χ^2 （正态向量的二次型，见线性代数部分的二次型与谱定理）。这些临界值之所以“通用”，根子就在 CLT 把五花八门的数据统一压成了正态。
- **Delta 法。**估计量常是某个渐近正态量的非线性变换 $g(\hat{\theta})$ （弹性、比值、长期乘子……）。Delta 法用 g 的一阶 Taylor 把变换线性化，再借 CLT 的正态性得 $\sqrt{n}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(0, \mathbf{J}_g \mathbf{V} \mathbf{J}_g^\top)$ 。这正是下一章（『连续映射定理、Slutsky 与 Delta 法』）的内容；它整套建立在本章的渐近正态之上。
- **自助法 (bootstrap) 的理论依据。**重抽样为何能逼近估计量的抽样分布？核心论证仍是 CLT：自助样本均值围绕原样本均值的标准化的量，与 $\sqrt{n}(\bar{X}_n - \mu)$ 收敛到同一个正态极限，于是用重抽样分布去近似真实抽样分布在一阶上成立。CLT 是自助法一致性的底层保证。

一条定理，一整套渐近推断。这是本书反复呈现的主题在统计这一端的化身：一个数学构造（标准化和趋于正态），被同一套逻辑反复用在每一个估计量、每一种检验、每一个置信区间上。认清了 CLT 这把钥匙，渐近统计后续诸章——Slutsky、Delta 法、极值估计的统一框架——便都成了对它的展开与精修。

第三十三章 连续映射定理、Slutsky 与 Delta 法

用到的前置工具：依概率收敛与依分布收敛（收敛模式一章）；大数定律与中心极限定理（同一部分）；Taylor 一阶展开（Taylor 展开一章）；梯度与 Jacobian（多元微分一章）。

大数定律和中心极限定理是渐近统计的两块基石，但它们直接管的对象很窄：样本均值。一个收敛到常数（LLN），一个标准化后收敛到正态（CLT）。可计量经济学里真正想要极限分布的，几乎从来不是一个干净的样本均值，而是若干样本矩拼出来的非线性函数——两个均值的比值（弹性、风险比）、一个均值的对数、样本方差、 t 统计量、 R^2 。这些量没有现成的极限定理。本章要装配的三件工具，正是把 LLN 与 CLT “组合”成这类复杂估计量极限分布的通用接口：**连续映射定理**（CMT）说连续函数保持收敛，是底层；**Slutsky 定理**处理“一个收敛到分布的量”与“一个收敛到常数的量”相加、相乘；**Delta 法**处理对一个渐近正态的量做光滑非线性变换。掌握了它们，你就能从“ $\bar{X}_n$ 怎么样”一路推到“ $g(\bar{X}_n, \bar{Y}_n)$ 怎么样”——而这正是几乎每一个渐近推导的最后一公里。

33.1 为什么需要“组合”工具

先把问题摆清楚。假设你已经从 CLT 知道了样本均值的极限行为，比如

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2),$$

又从 LLN 知道样本方差 $\hat{\sigma}^2 \xrightarrow{P} \sigma^2$ 。你真正想报告的，往往是下面这类量的极限分布：

- **t 统计量** $\frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}}$ ——分子收敛到 $\mathcal{N}(0, \sigma^2)$ ，分母收敛到常数 σ 。它们的比值收敛到什么？
- **对数或比值变换**如 $\log \bar{X}_n$ 、 $\bar{X}_n/\bar{Y}_n$ ——对一个渐近正态的量做了非线性函数，新量的极限分布、尤其是它的渐近方差是多少？
- **二次型**如 Wald 统计量 $\sqrt{n}(\hat{\theta} - \theta_0)^\top \hat{\mathbf{V}}^{-1} \sqrt{n}(\hat{\theta} - \theta_0)$ ——把一个收敛到正态的向量，夹在一个收敛到常数矩阵的二次型里。

这些量的共同结构是：把“收敛到分布的部分”和“收敛到常数的部分”用连续运算（加、乘、除、取对数、平方）拼在一起。LLN 和 CLT 各自只给出其中一块，要得

到整体的极限分布，需要一套规则告诉我们收敛性在连续运算下如何传递。这套规则就是本章的三件工具。它们之间是层层搭建的关系：CMT 是地基，Slutsky 是 CMT 在“分布部分 + 常数部分”这一最常见情形下的专用版本，Delta 法则进一步用 Taylor 展开把“非线性变换”线性化，再回头调用 CLT 与 Slutsky。

33.2 连续映射定理

最底层的事实简单得近乎显然：如果一串随机变量收敛，那么对它们施加一个连续函数，收敛仍然保持，而且极限就是“函数作用在极限上”。这对三种收敛模式都成立。

定理 33.1: 连续映射定理 (CMT)

设 $g: \mathbb{R}^k \rightarrow \mathbb{R}^m$ 在随机向量 X 的取值上几乎处处连续（即 X 落在 g 的不连续点集的概率为零）。则三种收敛模式都被 g 保持：

$$\begin{aligned} X_n &\xrightarrow{\text{a.s.}} X \Rightarrow g(X_n) \xrightarrow{\text{a.s.}} g(X), \\ X_n &\xrightarrow{p} X \Rightarrow g(X_n) \xrightarrow{p} g(X), \\ X_n &\xrightarrow{d} X \Rightarrow g(X_n) \xrightarrow{d} g(X). \end{aligned}$$

证明. 我们把三种情形里“直觉最透”的两种讲明白，依分布那条只点出关键。

依概率情形（连续函数版本，便于看清机制）。先设 g 在 $\mathbb{R}^k$ 上处处连续，证 $X_n \xrightarrow{p} X \Rightarrow g(X_n) \xrightarrow{p} g(X)$ 。要证对任意 $\varepsilon > 0$, $\mathbb{P}(\|g(X_n) - g(X)\| > \varepsilon) \rightarrow 0$ 。固定一个大的半径 M 。在紧集 $\{\|x\| \leq M\}$ 上 g 一致连续，故存在 $\delta > 0$ ，只要 $\|x - y\| \leq \delta$ 且二者都在该紧集内，就有 $\|g(x) - g(y)\| \leq \varepsilon$ 。于是事件 $\{\|g(X_n) - g(X)\| > \varepsilon\}$ 必落入下面三类之一： $\{\|X_n - X\| > \delta\}$ ，或 $\{\|X\| > M\}$ ，或 $\{\|X_n\| > M\}$ 。第一项由 $X_n \xrightarrow{p} X$ 趋于零；后两项可通过把 M 取得足够大，使 X 跑出半径 M 的概率任意小来控制（ X_n 那一项再借 $X_n \xrightarrow{p} X$ 转嫁给 X ）。 ε 任意，得证。一般的“几乎处处连续”只需把上面的紧集再挖去不连续点的一个小邻域，论证骨架不变。

几乎必然情形。这条最直接：在 $X_n \rightarrow X$ 成立的那个概率为 1 的样本点集合上，逐点用 g 的连续性即得 $g(X_n) \rightarrow g(X)$ ；只要这些样本点又避开 g 的不连续点（其概率为零），收敛就保持，故 $g(X_n) \xrightarrow{\text{a.s.}} g(X)$ 。

依分布情形。这条不能逐点谈（依分布收敛根本不要求 X_n 与 X 定义在同一空间上）。标准做法是用依分布收敛的等价刻画： $X_n \xrightarrow{d} X$ 当且仅当对一切有界连续函数 f 有 $\mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X))$ 。给定有界连续的 f ，复合 $f \circ g$ 在 X 的取值上仍几乎处处连续且有界，于是 $\mathbb{E}(f(g(X_n))) \rightarrow \mathbb{E}(f(g(X)))$ ，这正说明 $g(X_n) \xrightarrow{d} g(X)$ 。（严格地用到 Portmanteau 定理处理不连续点集为零测的情形，此处不展开。）□

注（“几乎处处连续”而非“处处连续”）。

定理允许 g 有不连续点，只要极限变量 X 几乎不落在那里。这个放宽很有用：例如 $g(x) = 1/x$ 在 0 处不连续，但只要极限 X 取值恒正（如 $X = \sigma > 0$ ），CMT 照样适用，于是 $\hat{\sigma} \xrightarrow{p} \sigma > 0 \Rightarrow 1/\hat{\sigma} \xrightarrow{p} 1/\sigma$ 。这正是后面把 t 统计量的分母处理掉所需要

的那一步。

CMT 是渐近推导里最朴素也最常用的一步

凡是“已知某个量收敛，对它做一个连续运算（取倒数、开方、取对数、求行列式、矩阵求逆……），结论是运算后的量也收敛到运算作用在极限上”——用的都是 CMT。它本身不产生新的分布，只是搬运收敛性。 $\hat{\sigma} \xrightarrow{p} \sigma \Rightarrow \hat{\sigma}^2 \xrightarrow{p} \sigma^2$ 、 $\hat{\mathbf{V}} \xrightarrow{p} \mathbf{V} \Rightarrow \hat{\mathbf{V}}^{-1} \xrightarrow{p} \mathbf{V}^{-1}$ （在 $\mathbf{V}$ 可逆处求逆是连续运算）都是它的直接应用。记住这一点能省去大量“重新证一遍收敛”的力气。

33.3 Slutsky 定理

CMT 有一个限制：它要求所有自变量收敛到同一个极限对象，并且本质上依赖“联合收敛”。但渐近推导里最常见的局面是混合型的——一部分量收敛到分布（如 CLT 给出的 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}$ ），另一部分量收敛到常数（如 LLN 给出的 $\hat{\sigma} \xrightarrow{p} \sigma$ ）。Slutsky 定理正是为这个混合局面量身定做的。

定理 33.2: Slutsky 定理

设 $X_n \xrightarrow{d} X$ （ X 为某随机向量）， $Y_n \xrightarrow{p} c$ （ c 为常数向量或矩阵），且维数相容。则

$$X_n + Y_n \xrightarrow{d} X + c, \quad Y_n X_n \xrightarrow{d} cX, \quad Y_n^{-1} X_n \xrightarrow{d} c^{-1}X \quad (\text{当 } c \text{ 可逆}).$$

要点全在那个“ Y_n 收敛到常数”上。如果把 c 换成一个真正随机的极限 Y ，结论一般不成立——因为 $X_n + Y_n$ 的极限分布会依赖 X 与 Y 的联合分布，而单凭各自的边缘收敛 $X_n \xrightarrow{d} X$ 、 $Y_n \xrightarrow{d} Y$ 决定不了联合分布。极限是常数时这个麻烦消失了：常数与任何东西都“独立”，联合分布被边缘分布唯一确定。这就是 Slutsky 成立的全部秘密，下面的证明把它讲清楚。

证明. 关键引理：若 $X_n \xrightarrow{d} X$ 且 $Y_n \xrightarrow{p} c$ （常数），则联合地 $(X_n, Y_n) \xrightarrow{d} (X, c)$ 。一旦有了这个联合收敛，三条结论就都是 CMT 的直接推论——因为加法 $(x, y) \mapsto x + y$ 、乘法 $(x, y) \mapsto yx$ 、以及在 c 可逆处的 $(x, y) \mapsto y^{-1}x$ 都是（在极限点 (X, c) 附近）连续映射，把联合收敛 $\xrightarrow{d} (X, c)$ 经 CMT 送过去即得 $\xrightarrow{d} X + c$ 、 cX 、 $c^{-1}X$ 。

为什么联合收敛成立。先看一个直觉版本： $Y_n \xrightarrow{p} c$ 意味着 Y_n 的整个分布越来越挤到常数 c 这一点上（图 33.1）。在极限处它退化成 c 处的点质量，没有任何“随机性”可言，于是它与 X_n 之间无论有怎样的相依结构都被“压平”了——极限的联合分布只能是 X 的分布与 c 点质量的乘积。

把这件事说严格：要证对一切有界连续 f ， $\mathbb{E}(f(X_n, Y_n)) \rightarrow \mathbb{E}(f(X, c))$ 。用三角不

等式拆成两段，

$$|\mathbb{E}(f(X_n, Y_n)) - \mathbb{E}(f(X, c))| \leq \underbrace{\mathbb{E}(|f(X_n, Y_n) - f(X_n, c)|)}_{(I)} + \underbrace{|\mathbb{E}(f(X_n, c)) - \mathbb{E}(f(X, c))|}_{(II)}.$$

第 (II) 项：固定第二个自变量为常数 c ， $x \mapsto f(x, c)$ 是有界连续函数，由 $X_n \xrightarrow{d} X$ 直接得 (II) $\rightarrow 0$ 。第 (I) 项：因 $Y_n \xrightarrow{p} c$ ， Y_n 以高概率落在 c 的任意小邻域内；在该邻域上 f 一致连续，故 $|f(X_n, Y_n) - f(X_n, c)|$ 以高概率小于任意 ε ，而在小概率的“坏”事件上由 f 有界 ($\leq 2 \sup |f|$) 控制。两块合起来令 (I) $\rightarrow 0$ 。证毕。 $\square$




图 33.1: Slutsky 定理的机制: $Y_n \xrightarrow{p} c$ 意味着 Y_n 的分布越来越集中、最终退化成常数 c 处的点质量。退化的极限不带任何随机性，于是它与 X_n 的相依结构被“压平”，联合极限分布只能是 X 与 c 点质量的乘积——这正是只凭边缘收敛就能拼出联合收敛、进而对加法乘法用 CMT 的原因。

注 (Y_n 的极限必须是常数)。

反例能说明“常数”不可省。设 $X_n \xrightarrow{d} X \sim \mathcal{N}(0, 1)$ ，并取 $Y_n = -X_n$ ，则 $Y_n \xrightarrow{d} Y \sim \mathcal{N}(0, 1)$ （边缘上确实收敛到一个标准正态）。但 $X_n + Y_n = 0$ 恒等于零，其极限是退化于 0 的点质量，绝非 $X + Y$ 那个 $\mathcal{N}(0, 2)$ 。问题正出在 Y_n 收敛到的是一个随机极限、且与 X_n 强相依——这时边缘收敛给不出联合分布。Slutsky 之所以好用，就在于它要求的 $Y_n \xrightarrow{p} c$ 是收敛到常数，自动绕开了联合分布这道坎。

例 (t 统计量的极限分布)。

设 $X_1, \dots, X_n$ 独立同分布，均值 μ 、方差 $\sigma^2 \in (0, \infty)$ 。 $\bar{X}_n$ 为样本均值， $\hat{\sigma}$ 为一个相合的标准差估计 ($\hat{\sigma} \xrightarrow{p} \sigma$)。求 t 统计量

$$T_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}}$$

的极限分布。

解。

分子由中心极限定理给出 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 。分母处理两步： $\hat{\sigma} \xrightarrow{p} \sigma > 0$ ，由 CMT ($x \mapsto 1/x$ 在 $\sigma > 0$ 处连续) 得 $1/\hat{\sigma} \xrightarrow{p} 1/\sigma$ 。现在把 T_n 写成“分布部分 $\times$ 常数部分”：

$$T_n = \underbrace{\sqrt{n}(\bar{X}_n - \mu)}_{\xrightarrow{d} \mathcal{N}(0, \sigma^2)} \cdot \underbrace{\frac{1}{\hat{\sigma}}}_{\xrightarrow{p} 1/\sigma}.$$

正是 Slutsky 的乘积形式 ($X_n \xrightarrow{d} X, Y_n \xrightarrow{p} c = 1/\sigma$)。于是

$$T_n \xrightarrow{d} \frac{1}{\sigma} \cdot \mathcal{N}(0, \sigma^2) = \mathcal{N}\left(0, \frac{1}{\sigma^2} \cdot \sigma^2\right) = \mathcal{N}(0, 1).$$

这就是为什么“把未知的 σ 换成相合估计 $\hat{\sigma}$ ”不改变 t 统计量的渐近标准正态分布：Slutsky 保证了用 $\hat{\sigma}$ 代替 σ 在极限里“免费”。注意这里我们没有假设数据正态——有限样本下 T_n 服从 t 分布要靠正态假设，但渐近的标准正态只需 CLT 加 Slutsky。

33.4 Delta 法

CMT 与 Slutsky 处理的是“加、乘、除”这类运算。但常常我们要对一个渐近正态的估计量做更一般的光滑非线性变换 g ——取对数、取倒数、做比值、算弹性。直接对 $g(\hat{\theta})$ 谈极限分布，CMT 只告诉我们 $g(\hat{\theta}) \xrightarrow{p} g(\theta_0)$ （收敛到常数），却看不出“围绕这个常数的正态波动有多大”。要抓住这个波动，需要把 g 在 θ_0 处线性化——这正是 Taylor 一阶展开的活，接上去就是 Delta 法。

定理 33.3: Delta 法（一元）

设标量估计量 $\hat{\theta}_n$ 满足

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, \sigma^2),$$

g 在 θ_0 处可微且 $g'(\theta_0) \neq 0$ 。则

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta_0)]^2 \sigma^2).$$

证明. 对 g 在 θ_0 处做带 Lagrange（或 Peano）余项的一阶 Taylor 展开。存在介于 $\hat{\theta}_n$ 与 θ_0 之间的 $\bar{\theta}_n$ ，使

$$g(\hat{\theta}_n) = g(\theta_0) + g'(\bar{\theta}_n)(\hat{\theta}_n - \theta_0).$$

两边减 $g(\theta_0)$ 再乘 $\sqrt{n}$ ：

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) = g'(\bar{\theta}_n) \cdot \sqrt{n}(\hat{\theta}_n - \theta_0).$$

现在逐块取极限。前提 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 蕴含 $\hat{\theta}_n - \theta_0 = O_p(n^{-1/2}) \xrightarrow{p} 0$ ，即 $\hat{\theta}_n \xrightarrow{p} \theta_0$ ；而 $\bar{\theta}_n$ 被夹在 $\hat{\theta}_n$ 与 θ_0 之间，故也有 $\bar{\theta}_n \xrightarrow{p} \theta_0$ 。 g' 在 θ_0 处连续，由 CMT 得

$g'(\bar{\theta}_n) \xrightarrow{p} g'(\theta_0)$ (一个常数)。于是右边是“常数部分 $\times$ 分布部分”:

$$\underbrace{g'(\bar{\theta}_n)}_{\xrightarrow{p} g'(\theta_0)} \cdot \underbrace{\sqrt{n}(\hat{\theta}_n - \theta_0)}_{\xrightarrow{d} \mathcal{N}(0, \sigma^2)}.$$

对它用 Slutsky 的乘积形式, 极限为 $g'(\theta_0) \cdot \mathcal{N}(0, \sigma^2) = \mathcal{N}(0, [g'(\theta_0)]^2 \sigma^2)$ 。□

可以看到 Delta 法不是一个独立的新定理, 而是 Taylor 一阶展开 + CMT + Slutsky 三者的组合拳: Taylor 把非线性的 g 换成它在 θ_0 处的切线 (斜率 $g'(\theta_0)$), CMT 保证中间点处的斜率收敛到真斜率, Slutsky 把“收敛的斜率”与“渐近正态的波动”乘起来。

几何图像。 图 33.2 给出 Delta 法最直观的画面。把 $\hat{\theta}_n$ 围绕 θ_0 的渐近正态波动画成横轴上的一口钟; g 在 θ_0 处的切线 (斜率 $g'(\theta_0)$) 把横轴的小波动“斜射”到纵轴上, 得到 $g(\hat{\theta}_n)$ 围绕 $g(\theta_0)$ 的波动, 仍是一口钟。关键在于: 切线把宽度按斜率缩放——输入标准差 $\sigma/\sqrt{n}$ 经斜率 $g'(\theta_0)$ 变成输出标准差 $|g'(\theta_0)| \sigma/\sqrt{n}$, 方差因此乘上 $[g'(\theta_0)]^2$ 。图中 g 是凹的、 $|g'| < 1$, 故输出那口钟比输入窄——这就是方差缩放因子 $[g'(\theta_0)]^2$ 的几何含义。




图 33.2: Delta 法的几何。横轴上 $\hat{\theta}$ 围绕 θ_0 的渐近正态波动, 经 g 在 θ_0 处的切线 (斜率 $g'(\theta_0)$) 映到纵轴, 得到 $g(\hat{\theta})$ 围绕 $g(\theta_0)$ 的波动。切线按斜率缩放宽度: 标准差乘 $|g'(\theta_0)|$, 方差乘 $[g'(\theta_0)]^2$ 。图中 g 凹且斜率小于 1, 故输出那口钟比输入窄。

注 (为什么要求 $g'(\theta_0) \neq 0$) .

若 $g'(\theta_0) = 0$, 一阶项整个消失, $\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(0, 0)$ 退化为常数 0——一阶 Delta 法给出“零方差”, 等于没说。这时真正的波动藏在二阶项里: 要做二阶 Delta 法, 把 Taylor 展到平方项,

$$g(\hat{\theta}_n) - g(\theta_0) \approx \frac{1}{2}g''(\theta_0)(\hat{\theta}_n - \theta_0)^2,$$

于是 $n(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} \frac{1}{2}g''(\theta_0)\sigma^2\chi_1^2$ ——收敛速度从 $\sqrt{n}$ 降到 n ，极限也从正态变成（缩放的）卡方。一阶导为零是“变换在该点恰好把一阶波动抹平”的临界情形，需更高阶展开接管，与 Taylor 一章里“二阶条件退化要看更高阶”是同一种现象。

例（对数变换的标准误）。

设 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 且 $\theta_0 > 0$ 。求 $\log \hat{\theta}_n$ 的渐近分布，并写出其标准误。

解。

取 $g(x) = \log x$ ，则 $g'(x) = 1/x$ ， $g'(\theta_0) = 1/\theta_0 \neq 0$ 。直接代 Delta 法公式：

$$\sqrt{n}(\log \hat{\theta}_n - \log \theta_0) \xrightarrow{d} \mathcal{N}\left(0, \frac{\sigma^2}{\theta_0^2}\right).$$

于是 $\log \hat{\theta}_n$ 的渐近方差为 $\sigma^2/(n\theta_0^2)$ ，其标准误（用相合估计 $\hat{\theta}_n, \hat{\sigma}$ 代入）为

$$\text{se}(\log \hat{\theta}_n) = \frac{\hat{\sigma}}{\sqrt{n} \hat{\theta}_n}.$$

这是“变换量的标准误”的典型算法：原量的标准误是 $\hat{\sigma}/\sqrt{n}$ ，取对数后乘上 $|g'(\hat{\theta}_n)| = 1/\hat{\theta}_n$ 。同理，倒数 $1/\hat{\theta}_n$ 的渐近方差是 $\sigma^2/(n\theta_0^4)$ ，因为 $g(x) = 1/x$ 的导数是 $-1/x^2$ ，平方后得 $1/\theta_0^4$ 。

33.5 多元 Delta 法

经济学里的估计量大多是向量，而我们想要的变换常常把这个向量映成一个标量（如两个均值的比值）或另一个向量。把一元 Delta 法升级到多元，只需把“导数 g' ”换成“梯度 / Jacobian”，把“ $[g']^2\sigma^2$ ”换成相应的二次型。

定理 33.4: Delta 法（多元）

设 $\theta_0 \in \mathbb{R}^k$ ，估计量 $\hat{\theta}_n$ 满足

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma),$$

$g: \mathbb{R}^k \rightarrow \mathbb{R}^m$ 在 θ_0 处连续可微，Jacobian $\mathbf{G} = D_{\theta} g(\theta_0)$ ($m \times k$ 矩阵) 满秩。则

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{G} \Sigma \mathbf{G}^T).$$

当 $m = 1$ （标量变换）时 $\mathbf{G} = \nabla g(\theta_0)^T$ 是行向量，渐近方差化为 $\nabla g(\theta_0)^T \Sigma \nabla g(\theta_0)$ 。

证明. 与一元完全平行, 只是 Taylor 展开取向量形式。把 g 在 θ_0 处一阶展开,

$$g(\hat{\theta}_n) = g(\theta_0) + \mathbf{G}(\hat{\theta}_n - \theta_0) + o_p(\|\hat{\theta}_n - \theta_0\|),$$

其中余项是比 $\|\hat{\theta}_n - \theta_0\|$ 更高阶的小量。两边乘 $\sqrt{n}$:

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta_0)) = \mathbf{G} \cdot \sqrt{n}(\hat{\theta}_n - \theta_0) + o_p(1),$$

最后一项是 $o_p(1)$, 因为 $\sqrt{n}\|\hat{\theta}_n - \theta_0\| = O_p(1)$ 乘以 $o_p(1)$ 仍是 $o_p(1)$ 。 $\mathbf{G}$ 是常数矩阵, 对 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$ 用 CMT (线性映射连续) 得 $\mathbf{G} \cdot \sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathbf{G} \cdot \mathcal{N}(\mathbf{0}, \Sigma) = \mathcal{N}(\mathbf{0}, \mathbf{G}\Sigma\mathbf{G}^\top)$, 再用 Slutsky 把 $o_p(1)$ 项扔掉 (一个 $\xrightarrow{d}$ 正态、一个 $\xrightarrow{p} 0$, 和仍 $\xrightarrow{d}$ 同一正态)。这里用到正态向量的线性变换公式: 若 $Z \sim \mathcal{N}(\mathbf{0}, \Sigma)$, 则 $\mathbf{G}Z \sim \mathcal{N}(\mathbf{0}, \mathbf{G}\Sigma\mathbf{G}^\top)$ 。□

记住夹心公式 $\mathbf{G}\Sigma\mathbf{G}^\top$

多元 Delta 法的渐近协方差是一个夹心: 变换的 Jacobian 从两侧夹住原协方差矩阵 Σ 。这个结构在计量里反复出现——它就是“把 $\hat{\theta}$ 的不确定性, 通过变换 g 的局部线性映射传播到 $g(\hat{\theta})$ 上”。标量情形 $\nabla g^\top \Sigma \nabla g$ 是它的特例。后面 M-估计的三明治协方差矩阵、两步估计的修正方差, 骨架都是这同一个“Jacobian 夹 Σ ”的形状。一旦你能默写 $\mathbf{G}\Sigma\mathbf{G}^\top$, 绝大多数“变换量的标准误”就是代公式。

例 (两个均值之比的渐近方差)。

设 $(\bar{X}_n, \bar{Y}_n)$ 满足

$$\sqrt{n} \begin{pmatrix} \bar{X}_n - \mu_X \\ \bar{Y}_n - \mu_Y \end{pmatrix} \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma), \quad \Sigma = \begin{bmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{bmatrix}, \quad \mu_Y \neq 0.$$

求比值 $\hat{r}_n = \bar{X}_n / \bar{Y}_n$ 的渐近分布。

解.

取 $g(x, y) = x/y$, 这是把 $\mathbb{R}^2$ 映到 $\mathbb{R}$ 的标量变换 ($m=1$)。在 (μ_X, μ_Y) 处算梯度:

$$\frac{\partial g}{\partial x} = \frac{1}{y} = \frac{1}{\mu_Y}, \quad \frac{\partial g}{\partial y} = -\frac{x}{y^2} = -\frac{\mu_X}{\mu_Y^2}, \quad \nabla g = \begin{bmatrix} 1/\mu_Y \\ -\mu_X/\mu_Y^2 \end{bmatrix}.$$

渐近方差是夹心二次型 $\nabla g^\top \Sigma \nabla g$ 。展开:

$$\begin{aligned} V &= \begin{bmatrix} 1/\mu_Y & -\mu_X/\mu_Y^2 \end{bmatrix} \begin{bmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{bmatrix} \begin{bmatrix} 1/\mu_Y \\ -\mu_X/\mu_Y^2 \end{bmatrix} \\ &= \frac{\sigma_X^2}{\mu_Y^2} - \frac{2\mu_X \sigma_{XY}}{\mu_Y^3} + \frac{\mu_X^2 \sigma_Y^2}{\mu_Y^4}. \end{aligned}$$

于是

$$\sqrt{n} \left(\frac{\bar{X}_n}{\bar{Y}_n} - \frac{\mu_X}{\mu_Y} \right) \xrightarrow{d} \mathcal{N}(0, V).$$

把 V 提出公因子 $r^2 = (\mu_X/\mu_Y)^2$ 可写成更眼熟的“相对方差”形式：

$$V = r^2 \left[\frac{\sigma_X^2}{\mu_X^2} - \frac{2\sigma_{XY}}{\mu_X\mu_Y} + \frac{\sigma_Y^2}{\mu_Y^2} \right],$$

即比值的相对方差约等于分子的相对方差、加分母的相对方差、减两倍的相对协方差。这条公式在实务中无处不在：弹性估计、风险比、人均量的比较，凡是“一个估计量除以另一个”，它的标准误都由这个夹心算出。注意若 $\bar{X}_n$ 与 $\bar{Y}_n$ 正相关 ($\sigma_{XY} > 0$)，比值的方差会被那个减号压低——分子分母同涨同落，比值反而更稳。

注（多元 Delta 法包含 Slutsky 的乘积与商）。

前面用 Slutsky 处理的“ $\bar{X}_n/\bar{Y}_n$ ”（当其中一个收敛到常数）其实是多元 Delta 法的退化特例。更一般地，只要把“两个都随机”的情形交给多元 Delta 法、把“一个随机一个收敛到常数”的情形交给 Slutsky，就覆盖了实务里几乎所有的代入式估计量。三件工具的分工是：CMT 管“单个量过连续函数”，Slutsky 管“分布部分与常数部分相加相乘”，Delta 法管“随机向量过光滑非线性变换”。

33.6 去处：渐近推断的通用引擎

本章三件工具很少单独登场，它们几乎总是作为更大推导链条里的“连接件”出现。把它们放回经济学与计量的主干，最重要的几处落点如下。

标准误与置信区间。 任何“变换量”的标准误都来自 Delta 法。报告弹性、半弹性、边际效应、几率比 (odds ratio)、长期乘数时，原始参数 $\hat{\theta}$ 的协方差矩阵 $\hat{\Sigma}/n$ 是已知的，要的是 $g(\hat{\theta})$ 的标准误——代夹心公式 $\sqrt{\widehat{\nabla g}^\top (\hat{\Sigma}/n) \widehat{\nabla g}}$ 即可。统计软件里 “nlcom”、“margins” 这类命令，内核就是数值地算 Jacobian 再夹 $\hat{\Sigma}$ 。

t 检验与 Wald 检验。 t 统计量用未知 σ 的相合估计替换之后仍渐近标准正态——这一步是 Slutsky（见本章 t 统计量例）。多维的 Wald 统计量 $\sqrt{n}(\hat{\theta} - \theta_0)^\top \hat{\Sigma}^{-1} \sqrt{n}(\hat{\theta} - \theta_0)$ 收敛到 χ^2 ：先由 CMT 把 $\hat{\Sigma}^{-1} \xrightarrow{p} \Sigma^{-1}$ ，再由 Slutsky 把它与渐近正态的二次型拼起来，最后由 CMT（二次型是连续映射）得到 χ^2 极限。检验非线性约束 $g(\theta_0) = \mathbf{0}$ 时，约束的 Jacobian 经 Delta 法进入 Wald 统计量的方差——这正是“非线性约束 Wald 检验”的来历。

极值估计的渐近正态性。 这是三件工具与 Taylor 展开合力的终点（详见后文极值估计的统一框架一章）。M-估计量 $\hat{\theta}$ 由样本一阶条件隐式定义，把一阶条件在真值处做 Taylor 展开后解出

$$\sqrt{n}(\hat{\theta} - \theta_0) = -[D_{\theta} \Psi_n(\bar{\theta})]^{-1} \sqrt{n} \Psi_n(\theta_0),$$

右边正是“一个收敛到常数矩阵的逆”(CMT + LLN)乘以“一个渐近正态的得分”(CLT),再由 Slutsky 拼成乘积——极限是 $\mathcal{N}(\mathbf{0}, \mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1})$ 那个经典的三明治。可以看到,MLE、GMM、M-估计渐近正态性的“最后一公里”,走的全是本章的路:Taylor 把方程线性化,CMT 搬运矩阵的收敛,Slutsky 把常数块与分布块相乘,必要时 Delta 法再把参数变换的不确定性传播出去。

三件工具,一条装配线

LLN 给“收敛到常数”,CLT 给“收敛到正态”——这是原料。本章三件工具是把原料装配成成品的流水线:CMT 让收敛性穿过任意连续运算;Slutsky 把“分布块”与“常数块”安全地相加相乘(前提是后者收敛到常数);Delta 法用一阶 Taylor 把光滑非线性变换就地线性化,再调用前两者。几乎每一个估计量的渐近分布、每一个标准误、每一个检验统计量的极限,最终都是这条装配线的产出。记住它们的分工,渐近推导的“最后一公里”就不再是黑箱,而是一串可以自己走完的标准步骤。

第三十四章 极值估计的统一框架 (MLE/GMM/M-估计)

用到的前置工具：大数定律与中心极限定理（渐近统计部分前几章）；连续映射定理、Slutsky 与 Delta 法（前一章）；Taylor 展开（第十四章）；无约束最优化的一阶、二阶条件（第十八章）；隐函数定理（第十五章）；矩阵求逆与正定矩阵（线性代数部分）。

这是全书的汇流处。前面几百页里我们一件一件地磨工具：大数定律保证样本平均收敛、中心极限定理给出正态极限、Slutsky 与 Delta 法把收敛在四则运算与光滑变换下传递、Taylor 展开把复杂函数在一点附近换成多项式替身、二阶条件用 Hessian 判极值、隐函数定理把“由方程隐含定义的解”对参数求导。本章要做的，是把这些工具一次性拧在一起，回答计量经济学里那个最核心的问题：一个估计量，它的极限是什么？它围着真值怎样波动？这个波动有多大？

令人惊讶的是，计量里几乎所有的估计量——最小二乘、极大似然、广义矩、非线性最小二乘、分位数回归——都能装进同一个模子：它们都是某个“样本目标函数”的极大（或极小）点。这个模子叫**极值估计量**（extremum estimator）。本章先把这个统一框架立起来，再沿着两条主线把它的渐近理论一气推完：一致性（估计量收敛到真值）靠的是大数定律加一个识别条件；渐近正态（围着真值的波动是正态的）靠的是对样本一阶条件做 Taylor 展开，再让大数定律定住二阶项、中心极限定理定住一阶项。推完你会看到一个反复出现的对象——三明治协方差矩阵 $\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$ ——以及它在极大似然下如何坍缩成信息矩阵的逆（这就是 Cramér–Rao 下界）。最后我们把 GMM 与 QMLE 接进同一框架，并指明它通向假设检验三位一体与稳健标准误的去处。

34.1 一个模子装下所有估计量

先看为什么“极大化一个样本目标”能囊括这么多看似不同的估计量。手上有数据 $\mathbf{z}_1, \dots, \mathbf{z}_n$ （独立同分布， $\mathbf{z}_i$ 可以包含因变量、回归元等一切观测到的东西），要估计一个参数 $\boldsymbol{\theta} \in \Theta \subseteq \mathbb{R}^p$ 。

定义 34.1: 极值估计量

给定一个样本目标函数 $Q_n(\boldsymbol{\theta})$ (它依赖数据, 故是随机的), 称

$$\hat{\boldsymbol{\theta}}_n = \arg \max_{\boldsymbol{\theta} \in \Theta} Q_n(\boldsymbol{\theta})$$

为一个极值估计量。常见情形里 Q_n 是一个样本平均

$$Q_n(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n q(\mathbf{z}_i, \boldsymbol{\theta}),$$

其中 q 是某个事先选定的“单观测准则函数”。取极小的情形 (如最小二乘) 只需把 q 换成 $-q$, 故不失一般性只谈极大。

这个定义的威力, 全在于换不同的 q 就换出不同的经典估计量。下表把它们一字排开——请注意它们共享的结构: 都是“把一个单观测准则在样本上平均, 再极大化”。

估计量	单观测准则 $q(\mathbf{z}_i, \boldsymbol{\theta})$	目标 Q_n 的含义
极大似然 (MLE)	$\log f(\mathbf{z}_i; \boldsymbol{\theta})$	样本对数似然
非线性最小二乘	$-(y_i - g(\mathbf{x}_i, \boldsymbol{\theta}))^2$	负的样本残差平方和
普通最小二乘 (OLS)	$-(y_i - \mathbf{x}_i^\top \boldsymbol{\theta})^2$	NLLS 的线性特例
分位数回归	$-\rho_\tau(y_i - \mathbf{x}_i^\top \boldsymbol{\theta})$	负的样本“弹球”损失
广义矩 (GMM)	见第 34.5 节	加权矩条件的二次型

表 34.1: 换一个单观测准则 q , 就换出一个经典估计量。它们都是“把 q 在样本上平均、再极大化”——这正是极值估计框架要统一的事。

为什么值得把它们统一起来

逐个去推 OLS、MLE、GMM 的渐近分布, 是一年级计量里最劝退的部分——每个都要重来一遍“展开、取极限、拼方差”。极值估计框架告诉你: 它们是同一个推导。一致性是“ Q_n 一致收敛到 Q 且峰唯一”的直接推论; 渐近正态是“对一阶条件做一阶 Taylor 展开”的直接推论。把这套母推导吃透一次, 所有具体估计量的渐近性质就成了代入而非重做。这正是本书一贯的主张: 认清工具本身, 等于同时拿到许多扇门的钥匙。

整章的逻辑分两步走, 与极值的两个最优性条件一一对应:

- **一致性** ($\hat{\boldsymbol{\theta}}_n \xrightarrow{P} \boldsymbol{\theta}_0$) ——用到的是“极大点”这件事本身: 样本目标的峰, 收敛到总体目标的峰。
- **渐近正态** ($\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}$) ——用到的是“一阶条件 $\nabla Q_n(\hat{\boldsymbol{\theta}}_n) = \mathbf{0}$ ”: 对它做 Taylor 展开。

我们逐一来。

34.2 一致性：样本的峰收敛到总体的峰

直觉先行。样本目标 $Q_n(\theta)$ 是个随机函数，随抽样而起伏；但只要它是样本平均，大数定律就保证它逐点收敛到一个确定的总体目标

$$Q(\theta) = \mathbb{E}(q(z, \theta)).$$

如果这个总体目标有一个唯一的峰，且它的位置恰是我们要估的真值 θ_0 ，那么——只要随机起伏在整个 Θ 上一致地被压下去——样本目标的峰 $\hat{\theta}_n$ 就别无选择，只能挤向总体目标的峰 θ_0 。图 34.1 把这件事画了出来。




图 34.1: 随机的样本目标 Q_n (细线) 围着确定的总体目标 Q (粗线) 起伏。 Q 有唯一的峰在真值 θ_0 。当样本量增大、起伏被一致地压下， Q_n 的峰 $\hat{\theta}_n$ 被迫挤向 Q 的峰 θ_0 ——这就是一致性。注意：是“唯一峰”加“一致收敛”两件事一起，才逼出 $\hat{\theta}_n \rightarrow \theta_0$ 。

把直觉翻成两条假设。第一条管“峰唯一”，第二条管“起伏一致地小”。

假设 34.2: 识别 (唯一峰)

总体目标 $Q(\theta) = \mathbb{E}(q(z, \theta))$ 在 θ_0 处取得严格唯一的极大：对任意 $\theta \neq \theta_0$ 都有 $Q(\theta) < Q(\theta_0)$ 。

假设 34.3: 一致收敛

样本目标在参数空间上一致地收敛于总体目标:

$$\sup_{\theta \in \Theta} |Q_n(\theta) - Q(\theta)| \xrightarrow{P} 0.$$

(在紧致 Θ 上, 逐点的大数定律加上 $q(z, \cdot)$ 关于 θ 的某种等度连续性, 即可升级为这条一致收敛——这类结论叫一致大数定律, 本章取其结论。)

定理 34.4: 极值估计量的一致性

设 Θ 紧致、 Q 连续, 并满足上面的识别与一致收敛两条假设。则

$$\hat{\theta}_n \xrightarrow{P} \theta_0.$$

证明. 证明只是把图 34.1 的直觉写严格, 核心是一个“夹挤”。固定真值处的取值作参照。由 $\hat{\theta}_n$ 是 Q_n 的极大点, 先有

$$Q_n(\hat{\theta}_n) \geq Q_n(\theta_0).$$

现在用一致收敛把这条关于 Q_n 的不等式翻译回 Q 。记 $\varepsilon_n = \sup_{\theta} |Q_n(\theta) - Q(\theta)| \xrightarrow{P} 0$ 。则

$$Q(\hat{\theta}_n) \geq Q_n(\hat{\theta}_n) - \varepsilon_n \geq Q_n(\theta_0) - \varepsilon_n \geq Q(\theta_0) - 2\varepsilon_n.$$

第一、三个不等号各用一次一致收敛 (Q 与 Q_n 在任意点相差不超过 ε_n), 中间用极大性。于是

$$Q(\theta_0) - Q(\hat{\theta}_n) \leq 2\varepsilon_n \xrightarrow{P} 0.$$

也就是说, $\hat{\theta}_n$ 处的总体目标值, 被挤到了与峰值 $Q(\theta_0)$ 任意接近。最后一步把“目标值接近峰值”翻成“位置接近峰点”: 这正是识别假设 (唯一峰) 的用武之地——它保证 Q 只有在 θ_0 附近才接近峰值, 故 $\hat{\theta}_n$ 必落在 θ_0 的任意小邻域内 (紧致性确保不会“跑到无穷远处”逃逸)。即 $\hat{\theta}_n \xrightarrow{P} \theta_0$ 。□

一致性 = 唯一识别 + 一致收敛

这条证明值得记住它的“零件分工”: 大数定律 (藏在一致收敛里) 负责把随机的 Q_n 钉到确定的 Q 上; 识别 (唯一峰) 负责把“目标值接近”升级成“位置接近”。两者缺一不可——少了一致收敛, 样本峰可能被某处的随机凸起带跑; 少了识别, 即便 $Q_n \rightarrow Q$, 也可能有两个并列的峰让 $\hat{\theta}_n$ 无所适从。识别不是技术细节, 它是计量里“参数到底估不估得出来”这一根本问题的数学名字 (共线性、弱工具、标签互换, 本质上都是识别的失败)。

注 (识别为什么常常成立) .

在 MLE 里识别有一个漂亮的来源。设真分布是 $f(\cdot; \theta_0)$ 。总体目标是 $Q(\theta) = \mathbb{E}_{\theta_0}(\log f(z; \theta))$ ，于是

$$Q(\theta_0) - Q(\theta) = \mathbb{E}_{\theta_0} \left(\log \frac{f(z; \theta_0)}{f(z; \theta)} \right) = \text{KL}(f_{\theta_0} \parallel f_{\theta}) \geq 0,$$

即 Kullback–Leibler 散度，由 Jensen 不等式非负，且仅当 $f_{\theta} = f_{\theta_0}$ （几乎处处）时为零。所以只要参数化是“可识别的”（不同 θ 给不同分布），总体对数似然的唯一峰自动落在真值 θ_0 ——这就是“极大似然估真值”最深处的道理：真值是让平均对数似然最大的那个参数，因为它让模型与真相的 KL 距离为零。

34.3 渐近正态：对一阶条件做 Taylor 展开

一致性说的是“ $\hat{\theta}_n$ 落在 θ_0 附近”，但没说有多近、波动是什么形状。要回答这个，得放大来看：把误差 $\hat{\theta}_n - \theta_0$ 乘上 $\sqrt{n}$ 这个“放大镜”，再问它的极限分布。答案几乎总是正态，而推导是一段已经在 Taylor 展开一章预演过的标准动作（第十四章），这里把它走完整。

假设 $\hat{\theta}_n$ 是内点极大且 Q_n 光滑，则它满足样本一阶条件（得分为零）

$$s_n(\hat{\theta}_n) := \nabla_{\theta} Q_n(\hat{\theta}_n) = 0, \quad s_n(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta} q(z_i, \theta).$$

这里 s_n 称为**样本得分** (score)。把它在真值 θ_0 处做一阶 Taylor 展开（对向量值映射用矩阵形式的中值定理）：

$$0 = s_n(\hat{\theta}_n) = s_n(\theta_0) + \mathbf{H}_n(\bar{\theta}_n) (\hat{\theta}_n - \theta_0),$$

其中 $\mathbf{H}_n(\theta) = D_{\theta} s_n(\theta) = \nabla_{\theta}^2 Q_n(\theta)$ 是样本目标的 Hessian， $\bar{\theta}_n$ 是介于 $\hat{\theta}_n$ 与 θ_0 之间的某个中间点。只要 $\mathbf{H}_n(\bar{\theta}_n)$ 可逆，解出误差并乘 $\sqrt{n}$ ：

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = -[\mathbf{H}_n(\bar{\theta}_n)]^{-1} \sqrt{n} s_n(\theta_0).$$

这条恒等式是整章的枢纽。它把我们想要的随机量（左边）表成了两块已知极限行为的東西的乘积，右边正好一块用大数定律、一块用中心极限定理：

- **Hessian 块（大数定律）**。 $\mathbf{H}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta}^2 q(z_i, \theta)$ 是样本平均，由大数定律收敛到其期望；又因 $\bar{\theta}_n$ 被 $\hat{\theta}_n$ 夹着趋于 θ_0 （一致性！），得

$$\mathbf{H}_n(\bar{\theta}_n) \xrightarrow{p} \mathbf{H}_0 := \mathbb{E}(\nabla_{\theta}^2 q(z, \theta_0)) = -\mathbf{A},$$

其中我们定义 $\mathbf{A} = -\mathbf{H}_0 = -\mathbb{E}(\nabla^2 q(z, \theta_0))$ （在极大点 Hessian 负定，故 $\mathbf{A}$ 正定）。 $\mathbf{A}$ 度量的是总体目标在峰处的曲率。

- **得分块（中心极限定理）**。在 θ_0 处，单观测得分 $\nabla q(z_i, \theta_0)$ 是独立同分布的随机向量，而且均值为零（见下面的注），所以 $\sqrt{n} s_n(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \nabla q(z_i, \theta_0)$ 由中心极

限定理趋于正态:

$$\sqrt{n} \mathbf{s}_n(\boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{B}), \quad \mathbf{B} := \text{Var}(\nabla q(\mathbf{z}, \boldsymbol{\theta}_0)) = \mathbb{E}(\nabla q \nabla q^\top).$$

$\mathbf{B}$ 度量的是得分的抽样方差。

注 (为什么真值处的得分均值为零)。

这是上面 CLT 能用的关键, 也是整个理论的“支点恒等式”。因为 $\boldsymbol{\theta}_0$ 是总体目标 $Q(\boldsymbol{\theta}) = \mathbb{E}(q(\mathbf{z}, \boldsymbol{\theta}))$ 的内点极大, 对它求一阶条件并交换期望与求导的次序 (合法性由控制收敛保证, 见 Lebesgue 积分一章):

$$\nabla_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}_0) = \mathbb{E}(\nabla_{\boldsymbol{\theta}} q(\mathbf{z}, \boldsymbol{\theta}_0)) = \mathbf{0}.$$

即总体得分在真值处期望为零。这正是“真值让平均准则最优”的一阶刻画——也是为什么 $\sqrt{n} \mathbf{s}_n(\boldsymbol{\theta}_0)$ 是一个中心化的和、可以直接喂给 CLT。

把两块用 Slutsky 定理 (前一章) 拼起来: $[\mathbf{H}_n]^{-1} \xrightarrow{p} -\mathbf{A}^{-1}$ 是收敛到常数矩阵的因子, $\sqrt{n} \mathbf{s}_n(\boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{B})$ 是依分布收敛的因子, 二者相乘的极限分布是把常数矩阵作用到正态上:

定理 34.5: 极值估计量的渐近正态性

在上述正则条件 (内点、光滑、 $\mathbf{A}$ 正定、CLT 适用) 下,

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}),$$

其中

$$\mathbf{A} = -\mathbb{E}(\nabla_{\boldsymbol{\theta}}^2 q(\mathbf{z}, \boldsymbol{\theta}_0)) \quad (\text{曲率/负 Hessian 的期望}), \quad \mathbf{B} = \mathbb{E}(\nabla q \nabla q^\top) \big|_{\boldsymbol{\theta}_0} \quad (\text{得分方差}).$$

证明. 承接枢纽恒等式 $\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) = -[\mathbf{H}_n(\bar{\boldsymbol{\theta}}_n)]^{-1} \sqrt{n} \mathbf{s}_n(\boldsymbol{\theta}_0)$ 。由一致性 $\hat{\boldsymbol{\theta}}_n \xrightarrow{p} \boldsymbol{\theta}_0$ 知 $\bar{\boldsymbol{\theta}}_n \xrightarrow{p} \boldsymbol{\theta}_0$, 配合一致大数定律得 $\mathbf{H}_n(\bar{\boldsymbol{\theta}}_n) \xrightarrow{p} -\mathbf{A}$, 再由“矩阵求逆是连续映射” (连续映射定理, $\mathbf{A}$ 可逆故 $-\mathbf{A}$ 附近求逆连续) 得 $[\mathbf{H}_n(\bar{\boldsymbol{\theta}}_n)]^{-1} \xrightarrow{p} -\mathbf{A}^{-1}$ 。另一方面 $\sqrt{n} \mathbf{s}_n(\boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{B})$ 。一个依概率收敛到常数矩阵、一个依分布收敛, Slutsky 定理允许相乘:

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} -(-\mathbf{A}^{-1}) \mathcal{N}(\mathbf{0}, \mathbf{B}) = \mathbf{A}^{-1} \mathcal{N}(\mathbf{0}, \mathbf{B}).$$

最后用“正态在线性变换下封闭”: 若 $\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{B})$, 则 $\mathbf{M}\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{M}\mathbf{B}\mathbf{M}^\top)$ 。取 $\mathbf{M} = \mathbf{A}^{-1}$ (对称, 故 $\mathbf{M}^\top = \mathbf{A}^{-1}$) 得方差 $\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$ 。□

三明治方差的解剖

$\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$ 这个“三明治”——两片面包 $\mathbf{A}^{-1}$ 夹着一块馅 $\mathbf{B}$ ——不是巧合的代数形状，它是两种力量的产物： $\mathbf{B}$ 是得分的抽样噪声（一阶条件因抽样而抖动多少）， $\mathbf{A}$ 是总体目标的曲率（峰有多尖）。估计误差 = 噪声 ÷ 曲率：噪声越大、误差越大（ $\mathbf{B}$ 在分子），曲率越大、峰越尖、误差越小（ $\mathbf{A}$ 在分母，出现两次因为它先把得分翻译成位置、又因方差是二次而平方）。图 34.2 把标量情形画了出来——这也正是隐函数定理的影子：估计量由一阶条件 $s_n(\hat{\theta}_n) = 0$ 隐含定义，对它做的 Taylor 展开，本质上就是“对恒等式求导、用 Hessian 的逆解出”那一招（第十五章）在随机扰动下的版本。




图 34.2: 三明治方差的来源（标量情形）。粗线是总体得分 $\mathbb{E}(s_n(\theta)) = -A(\theta - \theta_0)$ ，过 $(\theta_0, 0)$ ，斜率 $-A$ 即曲率。抽样让样本得分在粗线上下抖动，幅度（带的竖直高度）由得分方差 B 决定。估计量 $\hat{\theta}_n$ 落在样本得分等于零之处；竖直的得分噪声 B 经斜率翻译成 $\hat{\theta}_n$ 的水平分散，幅度 $\propto B/A^2 = \mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$ 。噪声越大、曲率越小，估计越不准。

注（标准误从哪来）。

渐近正态性还没法直接拿来推断，因为 $\mathbf{A}, \mathbf{B}$ 都含未知的真值与总体期望。实践中用样本对应物去估它们（“即插即用”）：

$$\hat{\mathbf{A}} = -\frac{1}{n} \sum_{i=1}^n \nabla^2 q(\mathbf{z}_i, \hat{\theta}_n), \quad \hat{\mathbf{B}} = \frac{1}{n} \sum_{i=1}^n \nabla q(\mathbf{z}_i, \hat{\theta}_n) \nabla q(\mathbf{z}_i, \hat{\theta}_n)^\top.$$

由一致性与连续映射定理, $\hat{\mathbf{A}} \xrightarrow{p} \mathbf{A}$, $\hat{\mathbf{B}} \xrightarrow{p} \mathbf{B}$, 故 $\hat{\boldsymbol{\theta}}_n$ 的估计协方差矩阵

$$\widehat{\text{Var}}(\hat{\boldsymbol{\theta}}_n) = \frac{1}{n} \hat{\mathbf{A}}^{-1} \hat{\mathbf{B}} \hat{\mathbf{A}}^{-1}$$

是 $\frac{1}{n} \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$ 的相合估计。它对角元的平方根就是**标准误**。这个用样本三明治拼出来的版本, 正是计量软件里那个“稳健标准误”(robust / sandwich SE) 的来历——见本章末。

34.4 极大似然：信息矩阵等式与 Cramér–Rao

把上面的母定理代入 $q = \log f$, 就得到极大似然的全部渐近理论。最漂亮的一点是：在 MLE (且模型正确设定) 下, 三明治会神奇地坍塌——两片面包和馅变成同一个矩阵。

定理 34.6: 信息矩阵等式

设模型正确设定, 即数据真的来自 $f(\cdot; \boldsymbol{\theta}_0)$ 。则在 $\boldsymbol{\theta}_0$ 处, 得分方差等于负的期望 Hessian, 二者都等于 **Fisher 信息矩阵** $\mathcal{I}$:

$$\mathbf{A} = -\mathbb{E}(\nabla^2 \log f(\mathbf{z}; \boldsymbol{\theta}_0)) = \mathbb{E}(\nabla \log f \nabla \log f^\top) |_{\boldsymbol{\theta}_0} = \mathbf{B} =: \mathcal{I}.$$

证明. 从恒等式 $\int f(\mathbf{z}; \boldsymbol{\theta}) d\mathbf{z} = 1$ (密度积分为一, 对一切 $\boldsymbol{\theta}$) 出发, 两次对 $\boldsymbol{\theta}$ 求导 (交换积分与求导, 正则条件下合法)。第一次:

$$\int \nabla f d\mathbf{z} = \mathbf{0} \implies \int (\nabla \log f) f d\mathbf{z} = \mathbb{E}(\nabla \log f) = \mathbf{0},$$

(用了 $\nabla f = (\nabla \log f) f$) ——这重新得到“真值处得分均值为零”。第二次, 对上式再求一次导:

$$\int [\nabla^2 \log f + (\nabla \log f)(\nabla \log f)^\top] f d\mathbf{z} = \mathbf{0}.$$

(对 $(\nabla \log f) f$ 用乘积法则: $\nabla[(\nabla \log f) f] = (\nabla^2 \log f) f + (\nabla \log f)(\nabla f)^\top = (\nabla^2 \log f) f + (\nabla \log f)(\nabla \log f)^\top f$ 。) 取期望即得

$$\mathbb{E}(\nabla^2 \log f) + \mathbb{E}((\nabla \log f)(\nabla \log f)^\top) = \mathbf{0},$$

也就是 $-\mathbf{A} + \mathbf{B} = \mathbf{0}$, 即 $\mathbf{A} = \mathbf{B} = \mathcal{I}$ 。 □

把 $\mathbf{A} = \mathbf{B} = \mathcal{I}$ 代回三明治, 两片面包与馅合体:

$$\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1} = \mathcal{I}^{-1} \mathcal{I} \mathcal{I}^{-1} = \mathcal{I}^{-1}.$$

推论 34.7: 极大似然估计量的渐近分布

正确设定下,

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}^{-1}).$$

渐近方差就是信息矩阵的逆。

这个 $\mathcal{I}^{-1}$ 不是任意的好——它是能达到的最小方差。Cramér–Rao 不等式说, 任何 (渐近无偏的) 估计量的渐近方差都 $\succeq \mathcal{I}^{-1}$ (矩阵意义上不小于), 而 MLE 恰好取到这个下界。所以正确设定下的 MLE 是渐近有效的: 没有别的正则估计量能比它更精确。

信息越多, 估计越准——一句话的几何

信息矩阵 $\mathcal{I} = -\mathbb{E}(\nabla^2 \log f)$ 就是平均对数似然在峰处的曲率。曲率大 = 峰尖, 意味着“偏离真值一点点, 似然就掉得很厉害”, 数据对参数的位置很“敏感”, 于是估计很准 (方差 $\mathcal{I}^{-1}$ 小); 曲率小 = 峰平, 似然对参数不敏感, 估计就糊 (方差大)。图 34.3 把这条“曲率 $\rightarrow$ 信息 $\rightarrow$ 精度”的链子画了出来。这也解释了为什么 $\mathcal{I}$ 叫“信息”: 它量的正是一个观测平均能为定位参数提供多少分辨力。Cramér–Rao 下界 $\mathcal{I}^{-1}$ 则是这句话的极致——没有任何手法能从同样的信息里榨出更高的精度。




图 34.3: Fisher 信息 = 平均对数似然 $\bar{\ell}$ 在峰处的曲率。左: 峰尖 (大曲率 = 大信息), 似然对参数敏感, $\hat{\theta}_n$ 的抽样分布窄 (方差 $\mathcal{I}^{-1}$ 小)。右: 峰平 (小曲率 = 小信息), $\hat{\theta}_n$ 的分布宽。这就是“信息越多、估计越准”, 以及 Cramér–Rao 下界 $\mathcal{I}^{-1}$ 的直观来源。

例 (正态均值的 MLE 与信息) .

设 $z_1, \dots, z_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, σ^2 已知, 估 μ 。写出对数似然、得分、信息, 并给出 $\hat{\mu}$ 的渐近分布。

解.

单观测对数似然 $\log f(z; \mu) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(z - \mu)^2}{2\sigma^2}$ 。对 μ 求导得分

$$\frac{\partial \log f}{\partial \mu} = \frac{z - \mu}{\sigma^2}, \quad \frac{\partial^2 \log f}{\partial \mu^2} = -\frac{1}{\sigma^2}.$$

Hessian 是常数 $-1/\sigma^2$ ，故信息（用 **A** 那一侧最省事）

$$\mathcal{I} = -\mathbb{E}\left(\frac{\partial^2 \log f}{\partial \mu^2}\right) = \frac{1}{\sigma^2}.$$

（用 **B** 那一侧核对： $\text{Var}\left(\frac{z - \mu}{\sigma^2}\right) = \frac{\text{Var}(z)}{\sigma^4} = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}$ ，两侧相等，信息矩阵等式当场兑现。）样本得分为零 $\frac{1}{n} \sum_i \frac{z_i - \mu}{\sigma^2} = 0$ 解出 $\hat{\mu} = \bar{z}$ ，于是

$$\sqrt{n}(\hat{\mu} - \mu) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}^{-1}) = \mathcal{N}(0, \sigma^2).$$

这与直接对样本均值用中心极限定理 ($\sqrt{n}(\bar{z} - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$) 给出的结论分毫不差——正好用这个一切都能手算的特例，验证了极值估计的整套机器无误。它真正的价值在于：当似然不再有闭式解（probit、logit、Tobit、混合模型……）时，同一套公式照样给出渐近分布与标准误。

34.5 GMM：矩条件与最优权重

很多经济模型不直接给出似然，却给出一组矩条件：理论预言某些函数在真值处期望为零。最典型的是工具变量——“工具与扰动正交”就是一条矩条件。广义矩估计 (GMM) 把这类信息系统化。

定义 34.8: 矩条件与 GMM 估计量

设理论给出 k 维矩函数 $\mathbf{g}(\mathbf{z}, \boldsymbol{\theta})$ ，在真值处期望为零：

$$\mathbb{E}(\mathbf{g}(\mathbf{z}, \boldsymbol{\theta}_0)) = \mathbf{0} \quad (k \text{ 条矩条件}).$$

记样本矩 $\bar{\mathbf{g}}_n(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \mathbf{g}(\mathbf{z}_i, \boldsymbol{\theta})$ 。给定一个对称正定权重矩阵 $\mathbf{W}$ ，GMM 估计量是

$$\hat{\boldsymbol{\theta}}_n = \arg \min_{\boldsymbol{\theta}} \bar{\mathbf{g}}_n(\boldsymbol{\theta})^\top \mathbf{W} \bar{\mathbf{g}}_n(\boldsymbol{\theta}).$$

当矩条数 k 多于参数数 p （过度识别）时，一般找不到让所有样本矩同时为零的 $\boldsymbol{\theta}$ ；GMM 退而求其次，让样本矩“尽量接近零”，而 $\mathbf{W}$ 决定了“哪个方向上的偏离更应该被惩罚”。把它套进极值框架（取 $\mathbf{Q}_n = -\bar{\mathbf{g}}_n^\top \mathbf{W} \bar{\mathbf{g}}_n$ ）走一遍前面的推导，可得渐近分布——推导同前，结果如下。

定理 34.9: GMM 的渐近分布与最优权重

记矩函数的 Jacobian $\mathbf{G} = \mathbb{E}(\mathbf{D}_{\boldsymbol{\theta}} \mathbf{g}(\mathbf{z}, \boldsymbol{\theta}_0))$ ($k \times p$) 与矩的方差 $\mathbf{S} = \text{Var}(\mathbf{g}(\mathbf{z}, \boldsymbol{\theta}_0))$ ($k \times k$)。则

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V}_{\mathbf{W}}), \quad \mathbf{V}_{\mathbf{W}} = (\mathbf{G}^{\top} \mathbf{W} \mathbf{G})^{-1} \mathbf{G}^{\top} \mathbf{W} \mathbf{S} \mathbf{W} \mathbf{G} (\mathbf{G}^{\top} \mathbf{W} \mathbf{G})^{-1}.$$

在所有正定 $\mathbf{W}$ 里, 取

$$\mathbf{W}^* = \mathbf{S}^{-1}$$

使 $\mathbf{V}_{\mathbf{W}}$ 达到矩阵意义下的最小, 此时方差坍缩为

$$\mathbf{V}^* = (\mathbf{G}^{\top} \mathbf{S}^{-1} \mathbf{G})^{-1}.$$

最优权重的直觉 (不逐行). 完整的渐近展开与前一节同构 (对一阶条件 $\mathbf{G}^{\top} \mathbf{W} \bar{\mathbf{g}}_n(\hat{\boldsymbol{\theta}}_n) = \mathbf{0}$ 做 Taylor 展开), 这里只点明 “ $\mathbf{W}^* = \mathbf{S}^{-1}$ 最优” 的来历. 各条样本矩的可信度不同: 方差大的矩 ($\mathbf{S}$ 的大特征值方向) 噪声大、信息少, 方差小的矩信息多. 最优权重应当按可信度加权——给噪声小的矩高权、噪声大的矩低权, 而 “按方差倒数加权” 正是 $\mathbf{S}^{-1}$. 这与广义最小二乘里 “用误差协方差的逆做权重” 是同一个原理, 也是 Gauss–Markov/Aitken 式 “逆方差加权最有效” 思想在矩空间里的化身. 代数上, 把 $\mathbf{W} = \mathbf{S}^{-1}$ 代入 $\mathbf{V}_{\mathbf{W}}$ 立刻约掉中间一截, 得 $\mathbf{V}^* = (\mathbf{G}^{\top} \mathbf{S}^{-1} \mathbf{G})^{-1}$; 而 $\mathbf{V}_{\mathbf{W}} - \mathbf{V}^* \succeq \mathbf{0}$ 对任意 $\mathbf{W}$ 成立 (标准的二次型配方可证), 即 $\mathbf{V}^*$ 最小. $\square$

注 (可行的两步 GMM).

最优权重 $\mathbf{S}^{-1}$ 含未知的 $\mathbf{S}$, 故实务上分两步: 第一步用任意权重 (常取 $\mathbf{W} = \mathbf{I}$) 算一个相合但未必有效的 $\hat{\boldsymbol{\theta}}^{(1)}$; 用它估出 $\hat{\mathbf{S}} = \frac{1}{n} \sum_{i=1}^n \mathbf{g}(\mathbf{z}_i, \hat{\boldsymbol{\theta}}^{(1)}) \mathbf{g}(\mathbf{z}_i, \hat{\boldsymbol{\theta}}^{(1)})^{\top}$; 第二步以 $\mathbf{W} = \hat{\mathbf{S}}^{-1}$ 重新极小化, 得到有效的两步 GMM. 过度识别时还附赠一个检验: 在 $\mathbf{W}^*$ 下, $n \bar{\mathbf{g}}_n(\hat{\boldsymbol{\theta}}_n)^{\top} \hat{\mathbf{S}}^{-1} \bar{\mathbf{g}}_n(\hat{\boldsymbol{\theta}}_n) \xrightarrow{d} \chi_{k-p}^2$, 即 Hansen 的 J 检验——它问 “这些多出来的矩条件彼此相容吗”, 是对模型设定的整体检验。

GMM 把恰好识别 ($k = p$) 的矩估计、工具变量、两阶段最小二乘全收作特例: 恰好识别时样本矩能被精确清零, 权重 $\mathbf{W}$ 无关紧要, GMM 退化为解 $\bar{\mathbf{g}}_n(\hat{\boldsymbol{\theta}}_n) = \mathbf{0}$ 。

34.6 M-估计与 QMLE: 当模型可能错

回到最一般的 M-估计 ($\hat{\boldsymbol{\theta}}_n = \arg \max \frac{1}{n} \sum_i q(\mathbf{z}_i, \boldsymbol{\theta})$, q 是任选准则). 它最重要的用场之一是拟极大似然 (QMLE): 你照常极大化某个似然, 但并不真信这个似然就是数据生成过程——比如对计数或分数数据硬套正态、或对面板套 Poisson. 这时模型 “设定错了”, 信息矩阵等式 $\mathbf{A} = \mathbf{B}$ 不再成立 (它的证明用到 “真分布就是 $f_{\boldsymbol{\theta}_0}$ ”), 于是渐近方差回到完整的三明治 $\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$, 不能再用 $\mathcal{I}^{-1}$ 。

三明治 vs. 信息逆：一张判断表

什么时候方差是 $\mathbf{A}^{-1}$ ($= \mathcal{I}^{-1}$)、什么时候是三明治 $\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$? ——取决于 $\mathbf{A} = \mathbf{B}$ 成不成立。

- 模型正确设定的 MLE: 信息矩阵等式成立, $\mathbf{A} = \mathbf{B} = \mathcal{I}$, 方差 $= \mathcal{I}^{-1}$, 且达到 Cramér–Rao 下界 (有效)。此时三明治退化、用简洁的 $\mathcal{I}^{-1}$ 即可。
- QMLE / 一般 M-估计 / 设定可疑: $\mathbf{A} \neq \mathbf{B}$, 必须用三明治 $\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$, 否则标准误会错。代价是放弃有效性, 换来对设定错误的稳健性。

经验法则: 拿不准设定对不对, 就报三明治 (稳健) 标准误——它在正确设定时也对 (只是没榨干效率), 在错误设定时仍然对。这就是为什么现代实证论文几乎一律默认稳健标准误。

例 (OLS 的稳健标准误正是三明治)。

线性模型 $y_i = \mathbf{x}_i^T \boldsymbol{\beta} + u_i$, 用准则 $q = -(y_i - \mathbf{x}_i^T \boldsymbol{\theta})^2$ (即 OLS)。算出 $\mathbf{A}, \mathbf{B}$, 说明同方差与异方差下标准误的差别。

解.

得分 $\nabla q = 2\mathbf{x}_i(y_i - \mathbf{x}_i^T \boldsymbol{\theta})$, 在真值处 $= 2\mathbf{x}_i u_i$; Hessian $\nabla^2 q = -2\mathbf{x}_i \mathbf{x}_i^T$ 。于是 (吸收到常数 2, 它在三明治里上下抵消)

$$\mathbf{A} = -\mathbb{E}(\nabla^2 q) = 2\mathbb{E}(\mathbf{x}\mathbf{x}^T), \quad \mathbf{B} = \text{Var}(\nabla q) = 4\mathbb{E}(u^2 \mathbf{x}\mathbf{x}^T).$$

代入 $\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$ (常数 2, 4 约成 1) 得 OLS 的渐近方差

$$(\mathbb{E}(\mathbf{x}\mathbf{x}^T))^{-1} \mathbb{E}(u^2 \mathbf{x}\mathbf{x}^T) (\mathbb{E}(\mathbf{x}\mathbf{x}^T))^{-1}.$$

同方差 ($\mathbb{E}(u^2 | \mathbf{x}) = \sigma^2$ 常数) 时, 中间块 $\mathbb{E}(u^2 \mathbf{x}\mathbf{x}^T) = \sigma^2 \mathbb{E}(\mathbf{x}\mathbf{x}^T)$, 三明治坍塌成 $\sigma^2 (\mathbb{E}(\mathbf{x}\mathbf{x}^T))^{-1}$ ——这正是教科书里那个“经典”OLS 方差公式。异方差时中间块不再约分, 必须留着完整的三明治——其样本版本 $(\sum \mathbf{x}_i \mathbf{x}_i^T)^{-1} (\sum \hat{u}_i^2 \mathbf{x}_i \mathbf{x}_i^T) (\sum \mathbf{x}_i \mathbf{x}_i^T)^{-1}$ 就是 White (异方差稳健) 标准误。可见“稳健标准误”并不神秘: 它不过是不假设同方差、直接用样本三明治而已。

34.7 收束：三位一体的检验与全书的汇流

有了 $\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V})$, 假设检验是水到渠成的一步。要检验 $H_0: \mathbf{r}(\boldsymbol{\theta}_0) = \mathbf{0}$, 有三种互补的造法, 合称检验三位一体, 它们各从极值图景的一个侧面入手:

- **Wald 检验**: 直接量“估计量离原假设有多远”。用 $\hat{\boldsymbol{\theta}}_n$ 和它的渐近方差构造 $\mathbf{r}(\hat{\boldsymbol{\theta}}_n)^T \widehat{\text{Var}}(\hat{\boldsymbol{\theta}}_n)^{-1} \mathbf{r}(\hat{\boldsymbol{\theta}}_n) \xrightarrow{d} \chi^2$ 。只需估无约束模型。
- **似然比 / 距离检验 (LR)**: 量“加上约束后, 目标函数的峰降了多少”—— $2[Q_n(\hat{\boldsymbol{\theta}}_n) - Q_n(\tilde{\boldsymbol{\theta}}_n)]$, 其中 $\tilde{\boldsymbol{\theta}}_n$ 是约束下的估计。需估两个模型。

- **拉格朗日乘子 / 得分检验 (LM)**: 量“在约束解处, 得分离零有多远”——若约束是真的, 约束解处的得分 $s_n(\tilde{\theta}_n)$ 应接近零。只需估约束模型。

三者在 H_0 下渐近等价、都趋于同一个 χ^2 , 差别只在“从哪个侧面逼近极值”——离峰的水平距离 (Wald)、峰的高度落差 (LR)、还是峰处的斜率 (LM)。这三把尺子量的是同一座山的同一个顶。

一章收束全书

回望这一章用到了多少前面的工具, 就明白为什么说它是汇流处: 大数定律定住 Hessian (给出 **A**)、中心极限定理定住得分 (给出 **B**)、Slutsky 与连续映射定理把两块拼成极限分布、Taylor 展开把一阶条件线性化、隐函数定理的精神支配着“由一阶条件隐含定义的解”如何随扰动移动、矩阵求逆与正定性撑起三明治的代数、二阶条件 (Hessian 负定 $\Rightarrow$ **A** 正定) 保证一切有定义、Lebesgue 控制收敛许可“期望与求导交换”那几步关键操作、Kullback-Leibler 散度 (凸性/Jensen) 解释了识别。一个公式 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1})$, 把全书前面散落的工具一次性收进了计量推断。

它的去处, 则是你接下来要上的每一门计量课与每一篇实证论文:

- **所有估计量的标准误**。OLS/IV/2SLS、probit/logit/Tobit、Poisson 回归、分位数回归、NLLS——它们的标准误全是某个 $\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}$ (或正确设定下的 $\mathcal{I}^{-1}$) 的样本版本。会读软件输出里“Robust SE”那一系列, 靠的就是本章。
- **稳健与聚类标准误**。把三明治中间的 **B** 换成允许异方差 (White) 或组内相关 (cluster) 的估计, 是同一框架的直接推广。
- **GMM 与结构估计**。宏观的 Euler 方程估计、产业组织的需求估计、动态离散选择, 骨架都是 GMM 或模拟矩, 最优权重 $\mathbf{S}^{-1}$ 与 J 检验来自本章。
- **检验三位一体**。Wald/LR/LM 在每一门计量课、每一次模型设定检验里反复出现, 它们的渐近 χ^2 性质就建立在本章的渐近正态之上。

至此, 本书前七个 Part 磨出的工具, 在这里被一次性焊成了计量经济学的渐近推断引擎。这正是“认清工具本身、等于同时拿到许多扇门钥匙”的最终兑现——你现在握着的, 是打开一年级计量理论顶点的那把总钥匙。

第七部分

动态最优化

第三十五章 差分方程与稳定性

用到的前置工具：特征值、特征向量与对角化（第四章）；矩阵的幂与相似变换（第四章）；对称矩阵与谱定理（第五章）；复数与模（基础，本书直接借用）。

经济学里几乎所有“随时间演化”的模型，最终都落成一条差分方程：今天的状态决定明天的状态，明天的又决定后天的，如此递推下去。增长模型问资本存量会不会爬向稳态，新凯恩斯模型问通胀与产出缺口在一次冲击后如何回归，理性预期模型问一组前瞻变量怎样选才不至于发散——这些问题表面上各不相干，骨子里都是同一个问句：一个由 $\mathbf{x}_{t+1} = \mathbf{g}(\mathbf{x}_t)$ 驱动的序列，长期会收敛到稳态、绕着它震荡、还是一去不返地发散？本章把这个问句的线性版本彻底讲透。线性是起点也是核心：非线性系统在稳态附近的行为，由它的线性化（Jacobian）决定（这一步是隐函数定理与 Taylor 展开的直接应用），所以“线性差分方程稳不稳”这件事，恰好就是判断一切动态经济模型局部稳定性的通用判据。

我们会看到，一阶系统 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 的全部秘密都写在 $\mathbf{A}$ 的特征值里：解是 $\mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0$ ，对角化后 $\mathbf{A}^t = \mathbf{P} \mathbf{\Lambda}^t \mathbf{P}^{-1}$ ，于是“收敛与否”简化为“特征值的模是否都小于 1”。当特征值有的在单位圆内、有的在圆外时，系统是鞍点——既非全局收敛也非全局发散，而是只有从一个特定子空间出发才会收敛。这个看似纯数学的几何事实，正是理性预期均衡之所以唯一的全部原因（Blanchard-Kahn 条件），也是本章最值得带走的一件工具。

35.1 从递推到“长期会怎样”

一个（自治）差分方程是一条形如

$$x_{t+1} = g(x_t), \quad t = 0, 1, 2, \dots$$

的递推关系：给定初值 x_0 ，它唯一地定出整条轨道 $x_0, x_1, x_2, \dots$ 。“自治”指 g 不显含时间 t 。我们最关心两件事：是否存在一个稳态（steady state，或称不动点） x^* 满足 $x^* = g(x^*)$ ——到了那里就再也不动；以及从任意初值出发，轨道是否会收敛到这个稳态。

定义 35.1: 稳态与（局部渐近）稳定性

点 x^* 称为差分方程 $x_{t+1} = g(x_t)$ 的**稳态**，若 $g(x^*) = x^*$ 。称 x^* **局部渐近稳定**，若存在它的一个邻域，使得从该邻域内任一初值出发的轨道都满足 $x_t \rightarrow x^*$ ($t \rightarrow \infty$)；若反之邻域内（除 x^* 外）任一初值出发的轨道都离开该邻域，则称 x^* **不稳定**。

注（为什么先把模型线性化）。

真实模型里 g 几乎总是非线性的，直接判稳很难。但局部稳定性只关心稳态附近的行为，于是把 g 在 x^* 处做一阶 Taylor 展开（第十四章）：记偏离量 $\hat{x}_t = x_t - x^*$ ，则

$$\hat{x}_{t+1} = g(x^*) + g'(x^*)\hat{x}_t + o(\hat{x}_t) - x^* \approx g'(x^*)\hat{x}_t.$$

偏离量近似服从一条线性差分方程，其系数就是 g 在稳态处的导数 $a = g'(x^*)$ 。这正是本章只需把线性情形讲透的原因：非线性系统的局部稳定性，被它的线性化完全接管（这一结论的严格版本是 Hartman-Grobman 定理，本书只用其结论）。多维情形里 a 换成 Jacobian $Dg(x^*)$ ，下文系统部分照此处理。

35.2 一阶线性差分方程

最简单也最该吃透的，是单变量一阶线性方程

$$x_{t+1} = ax_t + b,$$

其中 a, b 为常数。它已经包含了“齐次解 + 特解”与“稳定性由系数模决定”这两件本章反复用到的核心结构。

齐次解与特解。 先看齐次部分 $x_{t+1} = ax_t$ 。逐步代入即得 $x_t = a^t x_0$ ——齐次解是一条几何序列。再找一个**特解**：最自然的尝试是常数解 $x_t \equiv x^*$ ，代入得 $x^* = ax^* + b$ ，只要 $a \neq 1$ 就解出稳态

$$x^* = \frac{b}{1-a}.$$

通解是“齐次解 + 特解”。把通解写成 $x_t = Ca^t + x^*$ ，用初值 x_0 定常数 $C = x_0 - x^*$ ，得到闭式解

一阶线性差分方程的解

当 $a \neq 1$ 时， $x_{t+1} = ax_t + b$ 的解为

$$x_t = \underbrace{a^t (x_0 - x^*)}_{\text{齐次解: 偏离稳态的部分}} + \underbrace{x^*}_{\text{特解: 稳态}}, \quad x^* = \frac{b}{1-a}.$$

偏离稳态的量 $x_t - x^* = (x_0 - x^*)a^t$ 每期乘以一个因子 a 。于是收敛与否完全由 $|a|$ 决定： $|a| < 1$ 时 $a^t \rightarrow 0$ ，轨道收敛到 x^* ； $|a| > 1$ 时 a^t 爆炸，发散； $|a| = 1$ 是临界情形。

这条结论分四种典型形态，记住它们能让你一眼看穿轨道的样子：

- $0 < a < 1$ ：单调收敛，偏离量逐期同号缩小。
- $-1 < a < 0$ ：震荡收敛，偏离量逐期变号、幅度缩小（“阻尼震荡”）。
- $a > 1$ ：单调发散。
- $a < -1$ ：震荡发散，幅度越来越大、符号交替。

蛛网图：把递推画出来。 一阶差分方程的全部动态可以在一张图上看清。在 (x_t, x_{t+1}) 平面上画两条线：递推关系 $x_{t+1} = g(x_t)$ （这里是直线 $g(x) = ax + b$ ）与 45° 对角线 $x_{t+1} = x_t$ 。二者的交点正是稳态 $(g(x^*) = x^*)$ 。从 x_0 出发，“竖直走到曲线、再水平走到对角线”反复迭代，就得到**蛛网图**（cobweb diagram）。直线 g 的斜率 a 与 45° 线的相对陡缓，决定了蛛网是向内卷（收敛）还是向外甩（发散），见图 35.1：斜率绝对值小于 1（比对角线平）则收敛，大于 1（比对角线陡）则发散。




图 35.1：一阶线性差分方程 $x_{t+1} = ax_t + b$ 的蛛网图。稳态 x^* 在直线 g 与 45° 线的交点处。左： $|a| < 1$ （ g 比对角线平），蛛网向内卷， $x_t \rightarrow x^*$ 。右： $|a| > 1$ （ g 比对角线陡），蛛网向外甩，轨道发散。 g 斜率相对 45° 线的陡缓，就是稳定性的全部判据。

例（一个会收敛的简单宏观调整）。

设某变量按 $x_{t+1} = 0.5x_t + 10$ 调整，初值 $x_0 = 4$ 。求稳态、判稳定性，并写出闭式解。

解。

稳态 $x^* = \frac{b}{1-a} = \frac{10}{1-0.5} = 20$ 。因 $a = 0.5$ ， $|a| = 0.5 < 1$ ，稳态局部（实则全局，因方程是线性的）渐近稳定。偏离量 $x_0 - x^* = 4 - 20 = -16$ ，故

$$x_t = 20 + (-16) \cdot 0.5^t = 20 - 16 \cdot 2^{-t}.$$

轨道 4, 12, 16, 18, 19, ... 单调上升趋于 20。每期偏离量缩小一半, 这个“缩小因子”就是 a ——它度量了收敛速度: a 越接近 0 收敛越快, 越接近 1 收敛越慢。

注 (临界情形 $|a| = 1$ 与 $a = 1$) .

$a = 1$ 时常数特解不存在 (分母为零), 方程 $x_{t+1} = x_t + b$ 的解是 $x_t = x_0 + bt$, 线性漂移、不收敛——这正是计量里单位根 (随机游走 $x_{t+1} = x_t + \varepsilon_{t+1}$ 是其随机版本) 所对应的非平稳行为。 $a = -1$ 时轨道在两个值间永久震荡、不收敛也不发散。临界情形在动态经济学里往往标志着“正好失去稳定”的分界, 需单独小心。

35.3 高阶线性差分方程

许多模型天然是高阶的: 今天依赖昨天和前天。 p 阶线性齐次差分方程

$$x_t = a_1 x_{t-1} + a_2 x_{t-2} + \cdots + a_p x_{t-p}$$

的解法, 是把一阶情形的“试几何序列”推广开来。代入试探解 $x_t = \lambda^t$ ($\lambda \neq 0$), 两边除以 λ^{t-p} , 得到特征方程

$$\lambda^p = a_1 \lambda^{p-1} + a_2 \lambda^{p-2} + \cdots + a_p,$$

即 $\lambda^p - a_1 \lambda^{p-1} - \cdots - a_p = 0$ 。它的 p 个根 $\lambda_1, \dots, \lambda_p$ 称为特征根。

高阶齐次方程的通解 = 特征根撑起的几何序列之和

若特征根 $\lambda_1, \dots, \lambda_p$ 互不相同, 则通解是它们各自几何序列的线性组合

$$x_t = C_1 \lambda_1^t + C_2 \lambda_2^t + \cdots + C_p \lambda_p^t,$$

常数 $C_1, \dots, C_p$ 由 p 个初始条件 (如 $x_0, \dots, x_{p-1}$) 定出。非齐次方程 $x_t = \sum_j a_j x_{t-j} + c$ 的通解再加上一个特解 (常数 c 时取常数特解 $x^* = c/(1 - \sum_j a_j)$) 即可。

注 (重根与复根) .

若 λ_0 是 m 重根, 它贡献的不是一项而是 m 项: $\lambda_0^t, t\lambda_0^t, \dots, t^{m-1}\lambda_0^t$ (与微分方程里重根配多项式因子同理)。若出现一对共轭复根 $\lambda = re^{\pm i\theta}$, 则对应的实值解是 $r^t \cos(\theta t)$ 与 $r^t \sin(\theta t)$: 模 r 控制幅度的涨落 ($r < 1$ 衰减、 $r > 1$ 放大), 辐角 θ 控制震荡的频率。复根正是经济周期性波动的数学来源——一对模小于 1 的复根给出“阻尼周期”, 冲击后产出会一边收敛一边来回摆动。

由通解形式立刻读出稳定性: 每一项 λ_j^t 收敛到 0 当且仅当 $|\lambda_j| < 1$ 。于是

定理 35.2: 高阶线性差分方程的稳定性判据

p 阶线性差分方程的稳态局部渐近稳定, 当且仅当其特征方程的所有特征根 (含复根, 按复数的模计) 都满足

$$|\lambda_j| < 1, \quad j = 1, \dots, p,$$

即所有特征根都落在复平面的单位圆内。只要有一个根的模大于 1, 对应的几何序列就会爆炸, 系统不稳定。

证明. 非齐次方程的解等于稳态加上齐次解, 故稳定性只取决于齐次解 $x_t - x^* = \sum_j C_j \lambda_j^t$ (重根、复根情形把对应项替换为上面那条注里给出的形式, 论证不变)。对每一项, $|\lambda_j^t| = |\lambda_j|^t$: 当 $|\lambda_j| < 1$ 时 $\rightarrow 0$, 当 $|\lambda_j| > 1$ 时 $\rightarrow \infty$ 。带多项式因子的项 $t^k \lambda_j^t$ 同样由 $|\lambda_j|$ 主导——因为对任意固定 k , 只要 $|\lambda_j| < 1$ 就有 $t^k |\lambda_j|^t \rightarrow 0$ (指数衰减压过任何多项式增长)。于是和式收敛到 0 (对一切初值给出的 C_j) 当且仅当每个 $|\lambda_j| < 1$ 。复根成对出现, 其线性组合取实部, 模仍是 $|\lambda_j| = r$, 结论一致。□

把 p 阶方程改写成一阶向量系统 (下一节) 后, 特征根恰好就是系统矩阵 $\mathbf{A}$ 的特征值, “所有特征根模 < 1 ” 与下一节 “谱半径 < 1 ” 是同一句话——这也是为什么本章把高阶与系统统一处理。

35.4 一阶系统: $x_{t+1} = \mathbf{A}x_t$

经济模型里通常有一组状态变量同时演化 (资本与消费、通胀与产出缺口、多国汇率……), 写成向量形式

$$x_{t+1} = \mathbf{A}x_t, \quad x_t \in \mathbb{R}^n, \mathbf{A} \in \mathbb{R}^{n \times n}.$$

(含常数项的 $x_{t+1} = \mathbf{A}x_t + b$ 可先解稳态 $x^* = (\mathbf{I} - \mathbf{A})^{-1}b$, 再令 $\hat{x}_t = x_t - x^*$ 化为齐次, 故下面只看齐次。) 这个系统不仅本身重要, 前一节的 p 阶方程也能化成它的特例: 令 $x_t = (x_t, x_{t-1}, \dots, x_{t-p+1})^T$, 则 $x_{t+1} = \mathbf{A}x_t$, 其中 $\mathbf{A}$ 是以系数 a_j 为首行的伴随矩阵, 其特征多项式正是上一节的特征方程。所以 “一阶系统” 是本章真正的主战场。

解就是矩阵的幂。逐步代入立得

$$x_t = \mathbf{A}^t x_0.$$

形式上一行就解完了——但 $\mathbf{A}^t$ 是什么样子、会不会爆炸, 得把矩阵的幂算清楚。这正是对角化 (第四章) 登场的地方。设 $\mathbf{A}$ 可对角化, $\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^{-1}$, 其中 $\mathbf{P}$ 的各列是特征向量、 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ 是特征值对角阵。则矩阵幂坍缩成对角阵的幂:

$$\mathbf{A}^t = (\mathbf{P} \mathbf{\Lambda} \mathbf{P}^{-1})^t = \mathbf{P} \mathbf{\Lambda} \underbrace{\mathbf{P}^{-1} \mathbf{P}}_{\mathbf{I}} \mathbf{\Lambda} \cdots \mathbf{P}^{-1} = \mathbf{P} \mathbf{\Lambda}^t \mathbf{P}^{-1}, \quad \mathbf{\Lambda}^t = \text{diag}(\lambda_1^t, \dots, \lambda_n^t).$$

中间一连串 $\mathbf{P}^{-1}\mathbf{P}$ 全部抵消，只剩两端的 $\mathbf{P}, \mathbf{P}^{-1}$ 夹着 $\mathbf{\Lambda}^t$ 。于是

对角化把系统解耦成 n 条独立的一阶方程

$\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 的解为

$$\mathbf{x}_t = \mathbf{A}^t \mathbf{x}_0 = \mathbf{P} \mathbf{\Lambda}^t \mathbf{P}^{-1} \mathbf{x}_0, \quad \mathbf{\Lambda}^t = \text{diag}(\lambda_1^t, \dots, \lambda_n^t).$$

其几何含义：令 $\mathbf{z}_t = \mathbf{P}^{-1}\mathbf{x}_t$ 为特征坐标（把状态按特征向量基展开的坐标），则每个分量各自服从一条解耦的一阶方程 $z_{i,t+1} = \lambda_i z_{i,t}$ ，解为 $z_{i,t} = \lambda_i^t z_{i,0}$ 。原向量是这些独立模态的叠加

$$\mathbf{x}_t = \sum_{i=1}^n \lambda_i^t z_{i,0} \mathbf{p}_i,$$

$\mathbf{p}_i$ 为第 i 个特征向量。沿每个特征方向，系统就是一个“乘以 λ_i ”的一维差分方程——纠缠的多维动态被对角化拆成 n 条互不干扰的几何序列。

谱半径判据。 既然 $\mathbf{x}_t = \sum_i \lambda_i^t z_{i,0} \mathbf{p}_i$ ，整体收敛到 $\mathbf{0}$ 当且仅当每个模态 $\lambda_i^t \rightarrow 0$ ，即每个 $|\lambda_i| < 1$ 。把“最大的那个模”单拎出来命名：

定义 35.3: 谱半径

方阵 $\mathbf{A}$ 的谱半径（spectral radius）是其特征值模的最大值

$$\rho(\mathbf{A}) = \max_i |\lambda_i|.$$

（复特征值按复数的模计。）它度量了在所有特征方向中“伸缩最猛”的那一个方向的伸缩因子。

定理 35.4: 线性系统的稳定性判据

对 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ ，原点 $\mathbf{0}$ 局部（对线性系统即全局）渐近稳定，当且仅当

$$\boxed{\rho(\mathbf{A}) < 1} \quad \text{即} \quad |\lambda_i| < 1 \text{ 对一切 } i.$$

此时对任意初值 $\mathbf{x}_0$ 都有 $\mathbf{A}^t \rightarrow \mathbf{0}$ ，故 $\mathbf{x}_t \rightarrow \mathbf{0}$ 。若 $\rho(\mathbf{A}) > 1$ ，则除落在特定子空间上的初值外，轨道发散。

证明。 设 $\mathbf{A}$ 可对角化（一般情形见下注）。由 $\mathbf{x}_t = \mathbf{P} \mathbf{\Lambda}^t \mathbf{P}^{-1} \mathbf{x}_0$ ，而 $\mathbf{\Lambda}^t = \text{diag}(\lambda_1^t, \dots, \lambda_n^t)$ 。若所有 $|\lambda_i| < 1$ ，则 $\lambda_i^t \rightarrow 0$ ，故 $\mathbf{\Lambda}^t \rightarrow \mathbf{0}$ ，从而 $\mathbf{A}^t = \mathbf{P} \mathbf{\Lambda}^t \mathbf{P}^{-1} \rightarrow \mathbf{0}$ ，对任意 $\mathbf{x}_0$ 得 $\mathbf{x}_t \rightarrow \mathbf{0}$ 。反之，若某 $|\lambda_k| > 1$ ，取 $\mathbf{x}_0 = \mathbf{p}_k$ （第 k 个特征向量），则 $\mathbf{x}_t = \lambda_k^t \mathbf{p}_k$ ，其范数 $|\lambda_k|^t \rightarrow \infty$ ，发散。故 $\rho(\mathbf{A}) < 1$ 既充分又必要。 $\square$

注（不可对角化时谱半径判据依然成立）。

若 $\mathbf{A}$ 亏损、不可对角化（第四章），可换用 Jordan 标准形 $\mathbf{A} = \mathbf{PJP}^{-1}$ ； $\mathbf{J}^t$ 的元素是形如 $\binom{t}{k}\lambda^{t-k}$ （即 $t^k\lambda^t$ 量级）的项，仍由 $|\lambda|$ 主导： $|\lambda| < 1$ 时 $t^k|\lambda|^t \rightarrow 0$ 。所以谱半径判据 $\rho(\mathbf{A}) < 1$ 对一般方阵都成立，不依赖可对角化。这与上一节高阶方程里“重根配多项式因子仍由模主导”是同一件事——伴随矩阵的重特征值，正对应特征方程的重根。

注（与谱半径的一个常用不等式）。

直接算特征值有时麻烦，下面这条上界常被用来快速判稳：对任意从属（算子）范数 $\|\cdot\|$ 都有 $\rho(\mathbf{A}) \leq \|\mathbf{A}\|$ 。因此只要找到某一个矩阵范数使 $\|\mathbf{A}\| < 1$ （例如行和范数 $\|\mathbf{A}\|_\infty = \max_i \sum_j |a_{ij}| < 1$ ），就立刻断定 $\rho(\mathbf{A}) < 1$ 、系统稳定，连特征值都不必解。这是压缩映射（前文“压缩映射与 Banach 不动点”一章）在线性情形的影子： $\|\mathbf{A}\| < 1$ 说的正是“ $\mathbf{A}$ 是压缩”。

例（二维系统的稳定性）。

判断 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 是否稳定，其中

$$\mathbf{A} = \begin{bmatrix} 0.8 & 0.3 \\ 0.1 & 0.6 \end{bmatrix}.$$

解。

解特征方程 $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$ ：

$$(0.8 - \lambda)(0.6 - \lambda) - 0.3 \cdot 0.1 = \lambda^2 - 1.4\lambda + 0.45 = 0.$$

判别式 $1.4^2 - 4 \cdot 0.45 = 1.96 - 1.8 = 0.16$ ，故

$$\lambda = \frac{1.4 \pm 0.4}{2} = \{0.9, 0.5\}.$$

两个特征值都是实数且 $|0.9| < 1$ 、 $|0.5| < 1$ ，所以 $\rho(\mathbf{A}) = 0.9 < 1$ ，系统渐近稳定：从任意初值出发 $\mathbf{x}_t \rightarrow \mathbf{0}$ 。收敛速度由最大特征值 0.9 主导——长期看，偏离稳态的量大致每期乘 0.9，比单看某一维更慢的那个模态最终决定整体的收敛快慢。

二阶系统有一条不必解根的速记（迹-行列式判据）：设 $\tau = \text{tr } \mathbf{A} = \lambda_1 + \lambda_2$ ， $\delta = \det \mathbf{A} = \lambda_1 \lambda_2$ ，则两特征值都在单位圆内当且仅当 $|\delta| < 1$ 且 $|\tau| < 1 + \delta$ 。本例 $\tau = 1.4$ ， $\delta = 0.45$ ： $0.45 < 1$ 且 $1.4 < 1.45$ ，成立，与上面一致。

35.5 鞍点路径与跳跃变量

到此为止，“稳”与“不稳”是非黑即白：要么所有特征值在单位圆内（处处收敛），要么有特征值在圆外（几乎处处发散）。但经济学里最重要的情形恰恰落在中间——部分特征值在圆内、部分在圆外。这类系统叫鞍点（saddle path），它表面上“不稳定”，却正是理性预期模型赖以选定唯一解的机制。

考虑 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$, 设 $\mathbf{A}$ 有的特征值 $|\lambda_i| < 1$ (稳定模态)、有的 $|\lambda_j| > 1$ (不稳定模态)。由 $\mathbf{x}_t = \sum_i \lambda_i^t z_{i,0} \mathbf{p}_i$, 轨道收敛到 $\mathbf{0}$ 的充要条件是: 所有不稳定模态的初始权重为零, 即 $z_{j,0} = 0$ 对每个 $|\lambda_j| > 1$ 成立。满足这些条件的初值 $\mathbf{x}_0$ 构成一个子空间——稳定特征向量张成的**稳定特征子空间** (stable subspace), 通常称为**稳定臂**或**鞍点路径**。

鞍点收敛的几何: 只有落在稳定臂上才回得来

把状态空间按特征方向分解为稳定子空间 ($|\lambda_i| < 1$ 的特征向量张成) 与不稳定子空间 ($|\lambda_j| > 1$ 的特征向量张成)。则:

- 初值若恰好落在稳定子空间上, 所有不稳定模态权重为零, 轨道沿稳定臂收敛到稳态;
- 初值若有任何不稳定模态的分量 ($z_{j,0} \neq 0$), 该分量按 λ_j^t 放大, 轨道终将被甩向无穷。

收敛的初值是一个“测度为零”的子空间——但这恰恰是好消息, 下面说明为什么。

图 35.2 画出二维鞍点 (一个 $|\lambda_s| < 1$ 、一个 $|\lambda_u| > 1$) 的相图: 稳定臂上箭头指向稳态 (沿它进来), 不稳定臂上箭头背离稳态 (沿它出去), 其余轨线都是先被稳定方向拉近、再被不稳定方向甩出的双曲线。

跳跃变量挑出唯一收敛解。 如果“只有落在稳定臂上才收敛”意味着收敛要靠运气, 那它对经济学有什么用? 关键在于经济模型里的变量分两类。**状态变量** (predetermined, 如资本存量、债务) 由历史决定, 今天不能随意改动——它们的初值是给定的。**跳跃变量** (jump variable, 如消费、资产价格、通胀) 是前瞻的, 由经济主体当下的最优选择决定——它们的初值是内生的, 可以被选定。

于是模型自带一个“选解”机制: 跳跃变量会调整到恰好把系统放上稳定臂的那个值。因为任何偏离稳定臂的选择都会让前瞻变量发散到无穷 (违反横截性条件或预算约束、经济上不可行), 理性的主体只会选那个唯一让系统收敛的初值。**鞍点结构**于是从“不稳定”翻转成“唯一性的保证”: 稳定臂的维数恰好等于跳跃变量的个数时, 跳跃变量被唯一钉死, 理性预期均衡存在且唯一。

Blanchard-Kahn 条件: 数对了, 均衡就唯一

设系统有 n 个变量, 其中 k 个是前瞻 (跳跃) 变量、 $n - k$ 个是预定 (状态) 变量。记 $\mathbf{A}$ 落在单位圆外的特征值个数为 m (不稳定模态数)。则理性预期均衡存在且唯一当且仅当

$$m = k,$$

即**不稳定特征值的个数恰好等于跳跃变量的个数**。直觉: 每个跳跃变量提供一个“自由度”去消掉一个不稳定模态。若 $m > k$ (不稳定模态太多、自由度不够), 消不完, 没有收敛解 (不存在); 若 $m < k$ (自由度太多), 有多个收敛解 (不确定, indeterminacy, 对应“太阳黑子”均衡)。




图 35.2: 二维鞍点相图。绿色**稳定臂** ($|\lambda_s| < 1$ 的特征方向) 上轨道收敛到稳态 $\mathbf{0}$; 灰色**不稳定臂** ($|\lambda_u| > 1$ 的特征方向) 上轨道发散。其余初值 (蓝色双曲轨线) 先被稳定方向拉近、再被不稳定方向甩向无穷。只有恰好落在稳定臂上的初值才收敛——这条线就是鞍点路径。

这条计数规则即 Blanchard & Kahn (1980) 条件，是求解线性化 DSGE 模型的标准第一步：先把模型线性化成 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ (加上外生冲击)，数 $\mathbf{A}$ 单位圆外的特征值，再与跳跃变量个数比对，即知均衡是唯一、不存在、还是不确定。

例 (鞍点路径如何选定唯一初值)。

设二维系统 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 的特征值为 $\lambda_s = 0.5$ (特征向量 $\mathbf{p}_s = (1, 1)^\top$) 与 $\lambda_u = 2$ (特征向量 $\mathbf{p}_u = (1, -1)^\top$)。其中第一坐标 x_1 是预定变量、初值给定为 $x_{1,0} = 3$ ；第二坐标 x_2 是跳跃变量。问：为使系统收敛， $x_{2,0}$ 必须取何值？

解。

按特征向量展开初值： $\mathbf{x}_0 = z_s \mathbf{p}_s + z_u \mathbf{p}_u$ ，即

$$\begin{bmatrix} x_{1,0} \\ x_{2,0} \end{bmatrix} = z_s \begin{bmatrix} 1 \\ 1 \end{bmatrix} + z_u \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} z_s + z_u \\ z_s - z_u \end{bmatrix}.$$

收敛要求不稳定模态权重为零： $z_u = 0$ 。于是 $\mathbf{x}_0$ 必须落在稳定臂 $\text{span}\{\mathbf{p}_s\}$ 上，即 $\mathbf{x}_0 = z_s(1, 1)^\top$ ，两坐标相等。由预定的 $x_{1,0} = 3$ 得 $z_s = 3$ ，因此跳跃变量必须取

$$x_{2,0} = z_s = 3.$$

任何 $x_{2,0} \neq 3$ 都使 $z_u \neq 0$ ，于是 $z_u \cdot 2^t$ 项爆炸、系统发散。这里恰好“1 个不稳定特征值 = 1 个跳跃变量”，满足 Blanchard–Kahn 条件，故收敛解唯一：跳跃变量被鞍点路径唯一钉死在 $x_{2,0} = 3$ 。

35.6 这套工具通向何处

差分方程与稳定性是动态经济学的通用语法，本章这把工具的去处遍布三大方向：

- **宏观动态模型。**Ramsey/新古典增长模型、新凯恩斯模型在稳态附近线性化后都是 $\mathbf{x}_{t+1} = \mathbf{A}\mathbf{x}_t$ 形式，资本是预定变量、消费/通胀是跳跃变量。鞍点稳定性与 Blanchard–Kahn 计数决定了均衡轨道——经济沿鞍点路径收敛到稳态，正是“消费会怎样跳到正确水平”这一经典结论的来源。本章是后续动态规划与 Bellman 方程一章的动态地基：那里求出的最优策略 $\mathbf{x}_{t+1} = \mathbf{g}(\mathbf{x}_t)$ ，其稳态附近的收敛性正用本章判据来分析。
- **理性预期与均衡唯一性。**前瞻变量靠“跳上稳定臂”被唯一选定，这是理性预期方法论的核心。Blanchard–Kahn 条件是判断线性化 DSGE 模型解之存在唯一的标准工具，本章给出了它的全部数学内核。
- **计量：时间序列的平稳性。**VAR 模型 $\mathbf{x}_t = \mathbf{A}\mathbf{x}_{t-1} + \boldsymbol{\varepsilon}_t$ 平稳的条件正是 $\rho(\mathbf{A}) < 1$ （伴随矩阵的特征根全在单位圆内）——与本章的稳定性判据逐字相同（接特征值与对角化一章）。 $\rho(\mathbf{A}) = 1$ 对应单位根与协整，是非平稳时间序列分析的起点；脉冲响应函数的衰减速度，则由谱半径（最大特征值的模）度量，正是本章“收敛速度”概念在计量里的化身。

一条递推式，三门核心课。把“长期会怎样”归结为“特征值落在单位圆内还是圆外”，再把“均衡唯一吗”归结为“单位圆外的特征值数对不对得上跳跃变量”——本章想留下的，正是这两把能反复开门的钥匙。

第三十六章 变分法与 Euler 方程

用到的前置工具：偏导数、链式法则与全微分（多元微积分部分）；分部积分（一元微积分）；无约束最优化的一阶条件（最优化部分）；差分方程与稳定性（前一章）。

到目前为止，本书谈的最优化几乎都是在有限个数上做选择：选一个向量 $\mathbf{x} \in \mathbb{R}^n$ 使目标最大。可经济学里有一大类问题，选的不是几个数，而是一整条随时间展开的路径——一个人一辈子每个时点消费多少、一家企业每一年投资多少、一个经济体如何随时间积累资本。这时决策变量是一个函数 $x(\cdot)$ ，目标是把它代进某个积分后得到的一个数。在所有可行路径里挑出使这个积分取极值的那一条，就是**变分法**（calculus of variations）要解决的问题。本章先说清这类问题长什么样、为什么普通求导用不上，再把它的核心工具——Euler–Lagrange 方程——从头推出来，并交代端点自由时补上的横截条件。学完会看到：连续时间宏观里反复出现的“消费 Euler 方程”，正是本章方程的一个特例；而下一章的最优控制（Pontryagin），则是把这里的思路再推广一层。

36.1 从“选一个数”到“选一条路径”

先看一个具体场景。一个人计划在 $[0, T]$ 这段时间里安排消费 $c(t)$ ，瞬时效用为 $u(c)$ 、主观贴现率为 ρ ，他想最大化一生的贴现效用

$$\int_0^T e^{-\rho t} u(c(t)) \, dt.$$

这里要选的不是一个消费水平，而是每个时点的消费——也就是整条函数 $c: [0, T] \rightarrow \mathbb{R}$ 。目标也不再是一个普通函数 $f(c)$ ，而是“把一整条曲线喂进去、吐出一个数”的东西。我们把这种“函数的函数”叫**泛函**。

定义 36.1: 泛函与最简泛函问题

设 $L(t, x, v)$ 是一个三元连续可微函数（称为**被积函数**或 Lagrange 量），端点 $a < b$ 与端点值 x_a, x_b 给定。对每条连续可微路径 $x: [a, b] \rightarrow \mathbb{R}$ ，定义**泛函**

$$J[x] = \int_a^b L(t, x(t), \dot{x}(t)) \, dt,$$

其中 $\dot{x} = dx/dt$ 。最简变分问题是在满足端点条件 $x(a) = x_a$ 、 $x(b) = x_b$ 的所有路径中，求使 $J[x]$ 取极值（极小或极大）的那条 x^* 。

记号上要分清两层括号： $J[x]$ 用方括号，强调输入是整条函数；而 $L(t, x, \dot{x})$ 用圆括号，它是普通的多元函数，只不过我们习惯把它的三个槽位分别叫“时间” t 、“状态” x 、“速度” $\dot{x}$ 。求 $\partial L / \partial x$ 与 $\partial L / \partial \dot{x}$ 时，就把 L 当成以 $t, x, \dot{x}$ 为三个独立变量的普通函数来偏导——这一点初学时最容易绊住，务必记牢。

为什么不能直接用普通求导

普通最优化是“目标对一个数求导、令其为零”。可这里的自变量是一条函数，没有“一个数”可供求导。变分法的整套技巧，本质上是把“在函数空间里取极值”这件无从下手的事，化归成“沿每一个允许的扰动方向取极值”——而每个方向上又退回成熟悉的一元求导。下一节就把这条化归落实成一个可计算的微分方程。

这类问题在经济学里的三大主场，正好对应三个名字：**最优增长**（Ramsey 模型的连续时间版，选资本积累路径）、**最优消费**（选一生的消费路径）、以及**带调整成本的投资**（选投资路径，使建造成本与调整成本的现值最小）。它们的共同点都是“在一整条时间路径上做选择”，这正是变分法的用武之地。

36.2 Euler–Lagrange 方程

36.2.1 取变分：把函数极值化归成一元求导

设 x^* 是问题的解。变分法的核心想法是：既然 x^* 是“最好”的路径，那么从它出发、朝任何允许的方向做一点点偏移，目标都不该变得更好。怎么描述“一个方向”？取一条任意的、在两端为零的扰动函数 $\eta(t)$,

$$\eta(a) = 0, \quad \eta(b) = 0,$$

两端为零是为了让偏移后的路径仍满足同样的端点条件。再用一个小标量 ε 控制偏移幅度，构造一族邻近路径

$$x_\varepsilon(t) = x^*(t) + \varepsilon \eta(t).$$

当 $\varepsilon = 0$ 时回到最优路径， $\varepsilon \neq 0$ 时是它的一个扰动（图 36.1）。把这一族路径代进泛函，得到一个只依赖于一个数 ε 的普通函数：

$$\Phi(\varepsilon) = J[x^* + \varepsilon \eta] = \int_a^b L(t, x^* + \varepsilon \eta, \dot{x}^* + \varepsilon \dot{\eta}) \, dt.$$

现在 Φ 是一个普通的一元函数， x^* 最优意味着 $\varepsilon = 0$ 是 Φ 的极值点。于是它必须满足熟悉的一元一阶条件

$$\Phi'(0) = 0.$$

几何上，把 Φ 画成 ε 的曲线（图 36.2），最优性要求它在 $\varepsilon = 0$ 处驻定——切线水平。这一步是整套方法的支点：函数空间里“取极值”这件抽象的事，被压成了“一族一元曲线全都在原点驻定”。




图 36.1: 最优路径 $x^*(t)$ (实线) 与两条端点重合的邻近变分路径 $x^* \pm \varepsilon\eta$ (虚线)。扰动 η 在两端 a, b 为零, 故所有路径共用同样的端点。




图 36.2: 沿任一扰动方向 η , 泛函的值 $\Phi(\varepsilon) = J[x^* + \varepsilon\eta]$ 是 ε 的普通函数。最优路径使它在 $\varepsilon = 0$ 处驻定 (切线水平), 即一阶变分为零。

36.2.2 算出 $\Phi'(0)$ 并分部积分

把 Φ 对 ε 求导。积分号下对 ε 求导, 再用链式法则 (注意 L 的第二槽 x 处增量是 $\varepsilon\eta$ 、第三槽 $\dot{x}$ 处增量是 $\varepsilon\dot{\eta}$):

$$\Phi'(\varepsilon) = \int_a^b \left[\frac{\partial L}{\partial x}(t, x_\varepsilon, \dot{x}_\varepsilon) \eta(t) + \frac{\partial L}{\partial \dot{x}}(t, x_\varepsilon, \dot{x}_\varepsilon) \dot{\eta}(t) \right] dt.$$

令 $\varepsilon = 0$ (此时 $x_\varepsilon = x^*$ 、 $\dot{x}_\varepsilon = \dot{x}^*$), 并把在 x^* 处取值的偏导简记为 $L_x, L_{\dot{x}}$, 一阶条件 $\Phi'(0) = 0$ 化为

$$\int_a^b [L_x \eta + L_{\dot{x}} \dot{\eta}] dt = 0, \quad \text{对一切满足 } \eta(a) = \eta(b) = 0 \text{ 的 } \eta. \quad (36.1)$$

左边这个量叫泛函的一阶变分，常记作 δJ 。现在的麻烦是：式 (36.1) 里同时出现了 η 和它的导数 $\dot{\eta}$ ，无法直接把 η 当作“任意”提出来。出路是对含 $\dot{\eta}$ 的那一项做分部积分，把导数从 η 身上“搬”到 $L_{\dot{x}}$ 身上：

$$\int_a^b L_{\dot{x}} \dot{\eta} \, dt = \underbrace{[L_{\dot{x}} \eta]_a^b}_{=0} - \int_a^b \frac{d}{dt} (L_{\dot{x}}) \eta \, dt.$$

边界项 $[L_{\dot{x}} \eta]_a^b$ 因 $\eta(a) = \eta(b) = 0$ 而消失——这正是“两端为零”的扰动派上的用场。代回式 (36.1)，把两项合并、提出公因子 η ：

$$\int_a^b \left[L_x - \frac{d}{dt} (L_{\dot{x}}) \right] \eta(t) \, dt = 0, \quad \text{对一切两端为零的 } \eta. \quad (36.2)$$

36.2.3 变分基本引理：从“积分恒为零”到“被积式恒为零”

式 (36.2) 说的是“某个固定函数乘以任意 η 、积分总为零”。直觉上，能对所有扰动都正交的函数只能是零函数。这一步要靠一条小引理把它说严密。

引理 36.2: 变分基本引理

设 $h : [a, b] \rightarrow \mathbb{R}$ 连续。若对一切满足 $\eta(a) = \eta(b) = 0$ 的连续可微函数 η 都有 $\int_a^b h(t) \eta(t) \, dt = 0$ ，则 $h(t) \equiv 0$ 于 $[a, b]$ 。

证明. 反证。设某点 $t_0 \in (a, b)$ 处 $h(t_0) \neq 0$ ，不妨 $h(t_0) > 0$ 。由连续性，存在 t_0 的一个小区间 $(c, d) \subseteq (a, b)$ ，在其上 $h > 0$ 。专门挑一个“只在这小区间上凸起、别处为零”的扰动：令

$$\eta(t) = \begin{cases} (t-c)^2(d-t)^2, & t \in (c, d), \\ 0, & \text{其它,} \end{cases}$$

它连续可微、两端为零、且在 (c, d) 内严格为正。于是 $\int_a^b h \eta \, dt = \int_c^d h \eta \, dt > 0$ （正乘正的积分为正），与假设矛盾。故 h 处处为零。□

注（这条引理的“经济”读法）。

把 η 想成“你可以朝任意方向、任意局部地推一把”的检验扰动。若被积式 h 在某处不为零，你总能精准地“只在那一处推一把”而把积分顶离零——这正是上面那个局部凸起函数干的事。反过来说，唯一能扛住一切局部扰动的，只有处处为零。变分法里“任意扰动”的威力，全在于此。

把引理用到式 (36.2)（其中 $h = L_x - \frac{d}{dt} L_{\dot{x}}$ ）上，立刻得到本章的主结果。

定理 36.3: Euler - Lagrange 方程

若连续可微路径 x^* 在满足端点条件 $x(a) = x_a, x(b) = x_b$ 的路径中使 $J[x] = \int_a^b L(t, x, \dot{x}) dt$ 取极值, 则它在 $[a, b]$ 上满足

$$\frac{d}{dt} \left(\frac{\partial L}{\partial \dot{x}} \right) = \frac{\partial L}{\partial x}.$$

这是一个关于未知函数 $x(t)$ 的二阶常微分方程: 把全导数 $\frac{d}{dt}$ 展开 ($L_{\dot{x}}$ 通过 $t, x, \dot{x}$ 依赖 t), 会出现 $\ddot{x}$ 。它配上两个端点条件, 原则上就把最优路径定了下来。

注 (这是必要条件, 不是充分条件)。

Euler - Lagrange 方程来自一阶条件 $\Phi'(0) = 0$, 因此只是“驻定”的必要条件——它筛出的是极小、极大与拐点的候选。要断定确实是极小 (或极大), 需要二阶条件 (沿任意 η 有 $\Phi''(0) \geq 0$): 其必要形式是 Legendre 条件 $L_{\dot{x}\dot{x}} \geq 0$ (求极小时), 强化为 $L_{\dot{x}\dot{x}} > 0$ 并附 Jacobi (共轭点) 条件后才充分。本书按使用者的需要, 重点放在用 E-L 方程解出候选路径上; 经济学问题里目标函数往往天然凹 (效用凹、成本凸), 驻定路径即为所求, 二阶条件多半自动满足。

36.2.4 两个能省力的特例

E-L 方程在两类常见结构下可以“降一阶”, 值得单独记住。

两个守恒型特例

(i) L 不显含 x (只含 $t, \dot{x}$)。则 $\partial L / \partial x = 0$, E-L 退化为 $\frac{d}{dt}(\partial L / \partial \dot{x}) = 0$, 即

$$\frac{\partial L}{\partial \dot{x}} = \text{常数}.$$

这个守恒量是“广义动量”。(ii) L 不显含 t (只含 $x, \dot{x}$, 称自治)。则有 Beltrami 恒等式

$$L - \dot{x} \frac{\partial L}{\partial \dot{x}} = \text{常数}.$$

两种情形都把二阶方程降成一阶, 往往能直接积分出来。

特例 (ii) 的来历值得一推, 因为它示范了“沿最优路径某个量守恒”这一在动态经济学里反复出现的母题。沿任一路径, 按链式法则

$$\frac{d}{dt} (L - \dot{x} L_{\dot{x}}) = \underbrace{(L_t + L_x \dot{x} + L_{\dot{x}} \ddot{x})}_{dL/dt} - \ddot{x} L_{\dot{x}} - \dot{x} \frac{d}{dt} L_{\dot{x}}.$$

自治时 $L_t = 0$; 再把 E-L 方程 $\frac{d}{dt} L_{\dot{x}} = L_x$ 代入末项, 得

$$\frac{d}{dt} (L - \dot{x} L_{\dot{x}}) = L_x \dot{x} + L_{\dot{x}} \ddot{x} - \ddot{x} L_{\dot{x}} - \dot{x} L_x = 0.$$

故 $L - \dot{x} L_{\dot{x}}$ 沿最优路径恒定。

本节守恒的量是 $L - \dot{x} L_{\dot{x}}$ ；把它取负号得到 $\dot{x} L_{\dot{x}} - L$ ，正是后文将出现的 Hamilton 量 H 的雏形（在物理里即能量）。变分法里“时间不显含 $\Rightarrow$ 某量守恒”的现象，在最优控制与物理里都对应“Hamilton 量守恒”。

36.3 横截条件：端点自由时补上的边界

上一节假设两端点 x_a, x_b 都给定，所以扰动被迫两端为零。可经济学里末端往往是自由的：一个人到了寿命终点 T ，留多少遗产 $x(T)$ 并不外生给定，而要由最优化内生决定。这时 $\eta(b)$ 不必为零，分部积分里那个边界项就不会自动消失，反而会给我们补上一个缺失的边界条件——**横截条件**（transversality condition）。

把端点自由的情形重做一遍：左端 $x(a) = x_a$ 仍固定（ $\eta(a) = 0$ ），右端 $x(b)$ 自由（ $\eta(b)$ 任意）。一阶变分经分部积分后是

$$\Phi'(0) = \int_a^b \left[L_x - \frac{d}{dt} L_{\dot{x}} \right] \eta \, dt + [L_{\dot{x}} \eta]_a^b = 0.$$

边界项现在只剩右端 $L_{\dot{x}}(b) \eta(b)$ （左端因 $\eta(a) = 0$ 仍为零）。要让所有允许的 η 都使 $\Phi'(0) = 0$ ，先取那些恰好 $\eta(b) = 0$ 的扰动——它们逼出内部的 E-L 方程照旧成立，于是积分项归零；剩下的就要求边界项对任意 $\eta(b)$ 都为零。这只能是

$$\boxed{\frac{\partial L}{\partial \dot{x}} \Big|_{t=b} = 0}.$$

横截条件的来历与含义

横截条件不是额外强加的，它是同一个一阶变分在“端点不再被钉死”时自然吐出的边界条件——端点一旦获得自由，相应的边界项就必须独立为零。它恰好补上了因放开一个端点条件而“少掉”的那一个定解条件，使二阶 E-L 方程仍有唯一解。在不同设定下它换不同的面孔：末端值自由时是 $L_{\dot{x}}(b) = 0$ ；带贴现、末端要求 $x(T) \geq 0$ （如不许负遗产）时，化为带互补松弛的 $e^{-\rho T} \lambda(T) x(T) = 0$ 形式——也就是宏观里那条“资本的影子价值现值在终点归零”的著名条件。

无穷期问题（ $T \rightarrow \infty$ ）里横截条件取极限形式 $\lim_{t \rightarrow \infty} e^{-\rho t} \lambda(t) x(t) = 0$ ，用来排除“庞氏式”地无限累积或挥霍资本的发散路径。它在连续时间增长与最优控制里是判定路径是否最优的关键一环，下一章会再正式登场。

36.4 应用：最优消费路径

现在用 E-L 方程把本章开头那个消费问题解到底，看它如何吐出宏观里天天用的“消费 Euler 方程”。

例（贴现效用下的最优消费增长）。

个体在 $[0, T]$ 内持有资本 $k(t)$, 以利率 r 取得资本收益, 预算约束 (资本运动方程) 为

$$\dot{k} = rk - c, \quad k(0) = k_0, \quad k(T) = k_T \text{ 给定.}$$

他最大化贴现效用 $\int_0^T e^{-\rho t} u(c) dt$, 其中 u 严格增、严格凹。求最优消费路径满足的方程; 再取等弹性效用 $u(c) = \frac{c^{1-\sigma}}{1-\sigma}$ ($\sigma > 0$, 跨期替代弹性的倒数) 算出消费的增长率。

解.

约束 $\dot{k} = rk - c$ 把消费表成 $c = rk - \dot{k}$ 。代入目标, 问题就化成了一个以 k 为路径、最简形式的变分问题, 被积函数为

$$L(t, k, \dot{k}) = e^{-\rho t} u(rk - \dot{k}).$$

算两个偏导 (对 L 的第二槽 k 与第三槽 $\dot{k}$, 记 $u' = u'(c)$):

$$\frac{\partial L}{\partial k} = e^{-\rho t} u'(c) \cdot r, \quad \frac{\partial L}{\partial \dot{k}} = e^{-\rho t} u'(c) \cdot (-1) = -e^{-\rho t} u'(c).$$

代进 E-L 方程 $\frac{d}{dt} (\partial L / \partial \dot{k}) = \partial L / \partial k$:

$$\frac{d}{dt} [-e^{-\rho t} u'(c)] = r e^{-\rho t} u'(c).$$

左边求导 (乘积法则, $u'(c)$ 再经 c 依赖 t):

$$\rho e^{-\rho t} u'(c) - e^{-\rho t} u''(c) \dot{c} = r e^{-\rho t} u'(c).$$

两边除以 $e^{-\rho t}$ 并整理, 得**消费 Euler 方程**

$$-\frac{u''(c)}{u'(c)} \dot{c} = r - \rho.$$

它的读法很干净: 左边是“消费每变动一点带来的边际效用相对变化”, 右边是“市场回报 r 与不耐烦 ρ 之差”。当 $r > \rho$ (市场回报跑赢贴现), 个体愿意推迟消费、让消费随时间上升; $r < \rho$ 则相反; $r = \rho$ 时消费平滑为常数。

取等弹性效用 $u(c) = c^{1-\sigma}/(1-\sigma)$, 则 $u' = c^{-\sigma}$ 、 $u'' = -\sigma c^{-\sigma-1}$, 于是 $-u''/u' = \sigma/c$, 左边成 $\sigma \dot{c}/c$ 。代入得消费增长率

$$\boxed{\frac{\dot{c}}{c} = \frac{r - \rho}{\sigma}}.$$

增长率为常数, 故消费沿指数路径 $c(t) = c_0 e^{(r-\rho)t/\sigma}$ 演化, 三种情形如图 36.3。 σ 越大 (越不愿在时间上替代消费), 同样的 $r - \rho$ 推动的增长越平缓。




图 36.3: 等弹性效用下的最优消费路径 $c(t) = c_0 e^{(r-\rho)t/\sigma}$: $r > \rho$ 时上升、 $r = \rho$ 时平直、 $r < \rho$ 时下降。斜率由 $r - \rho$ 定方向、由跨期替代参数 σ 定陡缓。

注（本例用了哪些前置工具）。

注意整条求解链：用约束把控制 c 消成只剩状态路径 k （化归成最简问题）、对三槽函数 L 取偏导（多元微积分）、用乘积与链式法则展开全导数、最后解出一个一阶常微分方程得增长率（前一章的差分方程在连续时间的对应物）。这正是本书反复强调的：一个“高级”结果，拆开都是几件基础工具的组合。

36.5 它通向何处

变分法是连续时间动态最优化的第一块基石，它的几处主要去处把本章接回更大的版图：

- **最优控制与 Pontryagin 最大值原理**（下一章）。本章把控制变量 c “塞回”约束、化成纯状态的变分问题；可一旦约束复杂（控制有上下界、状态受不等式约束），这条“代入消元”的路就走不通了。最优控制把状态 k 与控制 c 分开处理，引入协态变量（影子价格） λ 与 Hamilton 量 $\mathcal{H} = u(c) + \lambda(rk - c)$ ，最优性条件 $\partial \mathcal{H} / \partial c = 0$ 、 $\dot{\lambda} = \rho \lambda - \partial \mathcal{H} / \partial k$ 正是 E-L 方程的推广——把 $\partial \mathcal{H} / \partial c = 0$ 与协态方程联立消去 λ ，又会回到本章的消费 Euler 方程。变分法是它的特例：“无约束”或“约束可代入”的那一类。
- **连续时间增长与 Hamilton 量**。Ramsey - Cass - Koopmans 最优增长模型的连续时间版，骨架就是本章这套：被积函数是贴现效用、约束是资本运动方程、解出的就是消费与资本的 Euler 方程加横截条件。本章自治情形下守恒的 $L - \dot{x} L_{\dot{x}}$ ，正是 Hamilton 量的前身。
- **消费 Euler 方程，连续与离散**。本章解出的 $\dot{c}/c = (r - \rho)/\sigma$ 是宏观与资产定价里最常被引用的关系之一。它的离散时间表亲 $u'(c_t) = \beta(1 + r) \mathbb{E}(u'(c_{t+1}))$ 来自动态规划的 Bellman 方程（见后文“动态规划”一章），两者讲的是同一件事——边际效用沿最优路径如何随时间移动——只是一个用微分方程、一个用差分方程表达。计量

上，把后者的随机版本作为矩条件去估参数，就是宏观结构估计里经典的 Euler 方程 GMM（见渐近统计部分的极值估计框架）。

一条贯穿的主线于是浮现：在整条时间路径上做选择，离散版是动态规划、连续版是变分法与最优控制，而它们最终都落到同一句话上——沿最优路径，相邻时点的边际权衡必须恰好相等。本章给了这句话最直接的微分形式。

第三十七章 最优控制与 Pontryagin 最大值原理

用到的前置工具：变分法与 Euler 方程（前一章）；Lagrange 乘子与一阶条件（最优化部分）；隐函数定理与比较静态（第十五章）；差分/微分方程与稳定性、鞍点动态（动态最优化部分前几章）；包络定理（最优化部分）。

宏观经济学的核心问题几乎都是同一句话：在时间上分配一个有限的资源。一个社会今天多消费一点，明天可投资的资本就少一点；一个矿主今天多采一吨，地下的存量就永久少一吨；一家企业今天多装一台机器，未来的产出会高，但眼下要付出调整成本。这些问题的共同结构是：有一个随时间演化的状态（资本、矿藏、机器存量），它的演化速度由我们当期选择的一个控制（消费、开采率、投资率）决定，而我们要在整条时间路径上把某个累积的收益最大化。

变分法（前一章）已经能处理这类问题的一个特例，但它有两处不够用：一是它要求把问题写成对一条路径 $x(t)$ 求泛函极值，控制隐含在 $\dot{x}$ 里，一旦控制本身受到约束（开采率非负、投资不能为负）就难以处理；二是它给不出一个在经济学里极其有用的对象——影子价格的动态路径。最优控制理论补上了这两块。它把“状态”与“控制”明确分开，引入一个随时间变化的乘子 $\lambda(t)$ ——状态的动态影子价格，并把整个动态最优化问题压缩成一个静态的逐期最大化加上两条微分方程。这套语言就是 **Pontryagin 最大值原理**，它是连续时间动态最优化的主力工具，也是宏观增长理论、最优政策、资源经济学与投资理论共同的脚手架。

37.1 问题的结构：状态、控制与运动方程

我们把一大类连续时间动态最优化问题统一写成下面的标准型。决策者在时间区间 $[0, T]$ 上，每一时刻 t 选一个控制 $u(t)$ ，它通过一个运动方程驱动状态 $x(t)$ 的演化，目标是把一路上累积的瞬时收益最大化：

$$\max_{u(\cdot)} \int_0^T f(x(t), u(t), t) dt \quad \text{s.t.} \quad \dot{x}(t) = g(x(t), u(t), t), \quad x(0) = x_0.$$

这里 x_0 是给定的初始状态， f 是瞬时收益（如效用流、利润流）， g 给出状态的变化率。终端时刻 T 可以有限也可以无穷；终端状态 $x(T)$ 可以自由、可以固定、也可以有下界约束，下文会看到不同的终端设定对应不同的横截条件。

定义 37.1: 状态、控制与运动方程

状态变量 $x(t)$ 概括了系统在 t 时刻的全部相关历史信息——它是“存量”（资本、矿藏、财富）。控制变量 $u(t)$ 是决策者每期可自由选择的“流量”决策（消费、开采、投资）。二者由运动方程（state equation） $\dot{x} = g(x, u, t)$ 联系：当期的控制决定状态此刻的变化速度。给定初始状态 $x(0) = x_0$ 与一条控制路径 $u(\cdot)$ ，运动方程就唯一地解出整条状态路径 $x(\cdot)$ 。

注（状态 vs. 控制：谁是“存量”谁是“流量”）。

区分状态与控制是用好这套工具的第一步，判据很简单：状态是不能瞬间跳变的量（它只能通过 $\dot{x}$ 连续地累积或耗散），控制是可以每期重选的量。Ramsey 增长里，资本 k 是状态（今天的资本是昨天投资攒下来的，不能凭空跳一截），消费 c 是控制（每期任选）。Hotelling 开采里，地下存量 S 是状态，开采率是控制。同一个经济量在不同模型里角色可能互换，关键看它在你的问题里是“被累积的”还是“被选择的”。

这个问题的难点在于它是无穷维的：我们要选的不是几个数，而是一整条函数 $u(\cdot)$ ，而且当期的选择会通过运动方程改变未来所有时刻的状态，进而改变未来的收益。直接对每个 $u(t)$ 求偏导是不行的——它们彼此通过 $x(\cdot)$ 纠缠在一起。最大值原理的全部巧妙之处，就在于它用一个乘子把这种“跨期纠缠”解开，让问题重新变得可以逐期处理。

37.2 Hamilton 量与影子价格

解开纠缠的办法，本质上是把运动方程当成一族逐时刻的约束，对每个时刻配一个 Lagrange 乘子。回忆静态约束最优化（Lagrange 一章）：要在约束 $h(x) = 0$ 下极大化 $f(x)$ ，我们构造 $\mathcal{L} = f + \lambda h$ ，乘子 λ 度量“约束放松一单位，最优值涨多少”——它是约束的影子价格。现在约束是一条微分方程，对每个时刻 t 都有一份“约束” $\dot{x} - g = 0$ ，于是乘子也变成一条时间路径 $\lambda(t)$ 。

把这些逐期约束并进目标，并定义一个核心对象：

定义 37.2: Hamilton 量

对标准型最优控制问题，定义 Hamilton 量（Hamiltonian）

$$H(x, u, \lambda, t) = \underbrace{f(x, u, t)}_{\text{当期收益}} + \underbrace{\lambda g(x, u, t)}_{\text{状态变化的估值}}.$$

其中 $\lambda(t)$ 称为协态变量（costate）或伴随变量，它是状态 x 的动态影子价格。

Hamilton 量的经济解读极其干净，值得反复体会：它是当期的“总价值流”。第一项 f 是此刻直接落袋的收益；第二项 $\lambda g = \lambda \dot{x}$ 是此刻状态正在增加的速度 $\dot{x}$ 乘以每单位状态的价值 λ ，也就是“此刻我们正在为未来积累的价值”按影子价格折算后的流量。于是

Hamilton 量 = 当期享受 + 为未来攒下的家当（按影子价格计）

最大化 H 就是在每个瞬间权衡现在与将来：控制 u 一方面直接影响当期收益 f ，另一方面通过 g 影响状态的积累速度、从而影响未来。协态 λ 正是把“未来”翻译成“当期可比的价格”的汇率。一旦有了正确的 $\lambda(t)$ ，原本牵一发而动全身的跨期问题，就被还原成每个时刻独立地最大化一个 H ——这就是下一节最大值原理的核心。

37.3 Pontryagin 最大值原理

有了 Hamilton 量，最优性条件可以异常简洁地陈述出来。

定理 37.3: Pontryagin 最大值原理

设 $(x^*(\cdot), u^*(\cdot))$ 是标准型最优控制问题的最优解， f, g 关于 (x, u) 连续可微。则存在一条连续的协态路径 $\lambda(t)$ ，使得对几乎所有 $t \in [0, T]$ ：

1. (最大值条件) 最优控制逐点最大化 Hamilton 量：

$$u^*(t) \in \arg \max_u H(x^*(t), u, \lambda(t), t).$$

若最优控制是内点解、 H 关于 u 可微，这等价于 $\frac{\partial H}{\partial u} = 0$ 。

2. (协态方程) 协态的演化由

$$\dot{\lambda}(t) = -\frac{\partial H}{\partial x}(x^*(t), u^*(t), \lambda(t), t)$$

给出。

3. (运动方程) 状态满足 $\dot{x}(t) = \frac{\partial H}{\partial \lambda} = g(x^*(t), u^*(t), t)$ 。

4. (横截条件) 终端约束按下表配对：

$$\begin{cases} x(T) \text{ 固定：} & \text{无条件 } (x(T) = x_T \text{ 已定}), \\ x(T) \text{ 自由：} & \lambda(T) = 0, \\ x(T) \geq \bar{x} \text{ (不等约束)：} & \lambda(T) \geq 0, \lambda(T)(x(T) - \bar{x}) = 0. \end{cases}$$

这四条里，最大值条件与协态方程是真正的“新东西”，值得逐一给出推导骨架与直觉。

最大值条件从哪来。 最直接的看法是把它当成 Lagrange 一阶条件的逐期版本。把目标写成对偶形式：用乘子路径 $\lambda(t)$ 把约束 $\dot{x} - g = 0$ 并入目标，

$$J = \int_0^T [f(x, u, t) + \lambda(g(x, u, t) - \dot{x})] dt = \int_0^T [H(x, u, \lambda, t) - \lambda \dot{x}] dt.$$

对最后一项分部积分， $-\int_0^T \lambda \dot{x} dt = -\lambda x|_0^T + \int_0^T \dot{\lambda} x dt$ ，于是

$$J = \int_0^T [H(x, u, \lambda, t) + \dot{\lambda} x] dt - \lambda(T)x(T) + \lambda(0)x_0.$$

现在考虑对最优路径做一个小扰动：控制变 $u^* + \epsilon \delta u$ 、状态随之变 $x^* + \epsilon \delta x$ ($\delta x(0) = 0$ ，因初值固定)。令 J 对 ϵ 的一阶变化为零：

$$\delta J = \int_0^T \left[\underbrace{\left(\frac{\partial H}{\partial x} + \dot{\lambda} \right)}_{\text{配 } \delta x} \delta x + \underbrace{\frac{\partial H}{\partial u}}_{\text{配 } \delta u} \delta u \right] dt - \lambda(T) \delta x(T) = 0.$$

δx 与 δu 不独立（前者由后者经运动方程决定），但 λ 还没定——我们有权选它。妙处正在这里：选 λ 使 δx 的系数恒为零，即令 $\dot{\lambda} = -\partial H / \partial x$ （这就是协态方程！），就把 δx 项整条消掉；剩下的 $\int \frac{\partial H}{\partial u} \delta u dt = 0$ 对任意 δu 成立，逼出 $\partial H / \partial u = 0$ （最大值条件）；而边界项 $-\lambda(T) \delta x(T) = 0$ 在 $x(T)$ 自由（ $\delta x(T)$ 任意）时逼出 $\lambda(T) = 0$ （横截条件）。三条主条件就这样一次性从同一个变分里掉出来。

选 λ 消掉状态扰动——这才是协态方程的来历

协态方程不是凭空规定的：它是“恰好让间接的状态扰动 δx 对目标无一阶影响”的那条乘子路径。一旦 λ 这样选定，控制的扰动就只剩下直接效应 $\partial H / \partial u$ ，于是逐期最大化 H 成立。这与静态 Lagrange 里“选乘子消掉约束方向的梯度”是同一个念头，只是这里“约束”是连续一条、乘子也连续一条。

注（为什么叫“最大值”原理而非“一阶条件”）。

注意定理第 1 条说的是 u^* 最大化 H ，而不仅是 $\partial H / \partial u = 0$ 。这是最大值原理比变分法强的关键：当控制受约束（如 $u \geq 0$ ，或 $u \in [\underline{u}, \bar{u}]$ ）时，最优控制可能落在边界上，此时 $\partial H / \partial u \neq 0$ ，但 u^* 仍是 H 在可行集上的最大点。“取 H 的 $\arg \max$ ”这一表述自动涵盖了内点解、边界解乃至 H 关于 u 线性时的 bang-bang（在边界间跳切）解。变分法的 Euler 方程做不到这一点。

协态方程的直觉：影子价格的“套利”方程。 把协态方程 $\dot{\lambda} = -\partial H / \partial x$ 展开， $\partial H / \partial x = f_x + \lambda g_x$ ，得

$$-\dot{\lambda} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial x}.$$

读作一条资产定价式： λ 是“持有一单位状态”这项资产的影子价格。多持有一单位状态，本期带来两项回报——直接的边际收益 f_x ，以及它让状态增长更快（ g_x ）从而进一步增值 λg_x ；这两项之和就是该资产的“股息流”。而 $\dot{\lambda}$ 是它的资本利得（影子价格

随时间的升降)。等式 $-\dot{\lambda} = f_x + \lambda g_x$ 把这两者绑在一起说：股息流加资本利得恰好为零。这是 present-value 形式特有的读法——折现已经并进了 λ 本身的衰减里，所以扣掉折现后的“超额”总回报归零；这正是无套利。（更干净的“要求回报 = 股息 + 资本利得”那条无套利式，要到下一节剥出折现因子的 current-value 形式才出现。）协态变量随时间的演化，就是影子价格为了维持跨期无套利而必须遵循的轨迹。

37.4 折现与 current-value Hamilton 量

经济学问题几乎总带折现：目标是 $\int_0^\infty e^{-\rho t} f(x, u) dt$, $\rho > 0$ 是折现率，且 f, g 通常不显含 t （自治）。直接套上一节的 Hamilton 量会得到带 $e^{-\rho t}$ 的协态方程，乘子本身随时间衰减，相图里参数不再是常数，很不方便。标准做法是把折现因子“剥出来”。

记原始（present-value）Hamilton 量 $H = e^{-\rho t} f + \lambda g$ ，并定义 current-value 协态 $m(t) = e^{\rho t} \lambda(t)$ ——即把影子价格换算到“当期币值”。相应地：

定义 37.4: current-value Hamilton 量

对折现问题 $\max \int_0^\infty e^{-\rho t} f(x, u) dt$ s.t. $\dot{x} = g(x, u)$ ，定义当期值 Hamilton 量

$$\mathcal{H}(x, u, m) = f(x, u) + m g(x, u), \quad m(t) = e^{\rho t} \lambda(t).$$

它就是把折现因子从 H 中整体提出后剩下的部分： $H = e^{-\rho t} \mathcal{H}$ 。

用 $\mathcal{H}$ 重写最优性条件，折现率 ρ 会以一个干净的形式出现在协态方程里。最大值条件不变（ $e^{-\rho t}$ 是正的公因子，不影响 $\arg \max_u$ ）：

$$\frac{\partial \mathcal{H}}{\partial u} = 0.$$

协态方程需要换算。由 $\lambda = e^{-\rho t} m$ ，求导得 $\dot{\lambda} = e^{-\rho t}(\dot{m} - \rho m)$ 。又原始协态方程 $\dot{\lambda} = -\partial H / \partial x = -e^{-\rho t} \partial \mathcal{H} / \partial x$ 。两式相等、约去 $e^{-\rho t}$ ：

current-value 协态方程（折现问题的主力公式）

$$\dot{m} = \rho m - \frac{\partial \mathcal{H}}{\partial x} \iff \boxed{\rho m = \frac{\partial \mathcal{H}}{\partial x} + \dot{m}}.$$

右边的盒装形式是它最该记住的样子，又一条资产定价式：要求回报率 ρ （左边，机会成本）= 股息 $\partial \mathcal{H} / \partial x$ + 资本利得 $\dot{m}$ （右边）。折现率 ρ 在这里扮演“无风险利率”，影子价格 m 必须挣到这个回报，否则就该把资源挪作他用。

折现问题的横截条件也相应改写。对 $T \rightarrow \infty$ 的自治折现问题，最常用的是注（无穷期横截条件）。

$T \rightarrow \infty$ 时, 自由终端的 $\lambda(T) = 0$ 推广为极限横截条件

$$\lim_{t \rightarrow \infty} e^{-\rho t} m(t) x(t) = 0 \quad (\text{即 } \lim_{t \rightarrow \infty} \lambda(t) x(t) = 0).$$

直觉: 折现后“留在无穷远处的状态的价值”必须归零——否则要么留下了本可享用的资源(次优), 要么借了永远还不清的债。在 Ramsey 这类模型里, 它正是排除爆炸路径、把无穷多条满足欧拉方程的轨道收窄到唯一一条稳定臂的那个条件。

37.5 应用一: Ramsey 增长与 Keynes–Ramsey 规则

最优控制最著名的落点是 Ramsey–Cass–Koopmans 最优增长模型。社会计划者选择消费路径 $c(t)$ 以最大化折现效用, 资本 k 按“产出减消费减折旧”积累:

$$\max_{c(\cdot)} \int_0^{\infty} e^{-\rho t} u(c) dt \quad \text{s.t.} \quad \dot{k} = F(k) - c - \delta k, \quad k(0) = k_0,$$

其中 $u' > 0, u'' < 0, F' > 0, F'' < 0, \delta$ 为折旧率。状态是 k 、控制是 c 。当期值 Hamilton 量为

$$\mathcal{H} = u(c) + m(F(k) - c - \delta k).$$

例 (导出 Keynes–Ramsey 规则) .

对上面的 Ramsey 问题, 写出三条最优性条件并消去协态 m , 得到最优消费增长率满足的方程。

解.

最大值条件 (c 内点):

$$\frac{\partial \mathcal{H}}{\partial c} = u'(c) - m = 0 \implies m = u'(c).$$

影子价格等于消费的边际效用——多攒一单位资本的价值, 正是它能换来的边际效用。协态方程:

$$\dot{m} = \rho m - \frac{\partial \mathcal{H}}{\partial k} = \rho m - m(F'(k) - \delta) = m(\rho - F'(k) + \delta).$$

现在消去 m 。由 $m = u'(c)$ 对时间求导, $\dot{m} = u''(c)\dot{c}$ 。代入协态方程并两边除以 $m = u'(c)$:

$$\frac{u''(c)\dot{c}}{u'(c)} = \rho - F'(k) + \delta.$$

整理出 Keynes–Ramsey 规则:

$$\boxed{\frac{\dot{c}}{c} = \frac{1}{\sigma(c)}(F'(k) - \delta - \rho)}, \quad \sigma(c) \equiv -\frac{c u''(c)}{u'(c)} > 0,$$

其中 $\sigma(c)$ 是相对风险厌恶系数 (消费的跨期替代弹性之倒数)。

这条规则是宏观的“ $F=ma$ ”级别的结果，它说的是：消费增长当且仅当资本的净边际回报 $F'(k) - \delta$ 超过折现率 ρ 。回报高于不耐烦程度，就值得推迟消费、让消费随时间上升；二者相等时 $\dot{c} = 0$ ，达到稳态。曲率 σ 决定调整速度——人越不愿在时间上替代消费（ σ 大），同样的回报差异引起的消费倾斜就越平缓。

注（这正是协态方程在干活）。

注意整个推导的发动机是协态方程：它把“影子价格如何随时间演化”翻译成了“消费如何随时间演化”。 $m = u'(c)$ 把价格挂到消费上，协态方程给出价格的运动，链式法则把它转成消费的运动。没有 Pontryagin 的协态语言，这条规则也能用变分法（前一章的 Euler 方程）凑出来，但协态版本把“ m 是资本的影子价格”这层经济含义摆在了明面上。

相图与鞍点路径。 Ramsey 模型的两条动态方程——消费的 Keynes-Ramsey 规则与资本的运动方程——在 (k, c) 平面上给出一个鞍点系统。两条“零变化线”（nullcline）为：

$$\dot{c} = 0: F'(k) = \delta + \rho \Rightarrow k = k^* \quad (\text{一条竖直线});$$

$$\dot{k} = 0: c = F(k) - \delta k \quad (\text{一条驼峰曲线}).$$

二者交于稳态 (k^*, c^*) 。在该点附近系统是鞍点：四个象限里轨线的方向（由 $\dot{c}, \dot{k}$ 的符号决定）使得只有一条“稳定臂”（saddle path）通向稳态，其余轨道都发散。给定初始资本 k_0 ，计划者唯一能做的最优选择，就是把初始消费 c_0 跳到稳定臂上——这恰好由前面的极限横截条件挑出。图 37.1 画出了这个相图。




图 37.1: Ramsey 模型在 (k, c) 平面上的相图。竖直线 $\dot{c} = 0$ 与驼峰曲线 $\dot{k} = 0$ 交于稳态 $E = (k^*, c^*)$ ，该点是鞍点；蓝色稳定臂是唯一通向 E 的轨道。给定 k_0 ，最优策略是把初始消费跳到稳定臂上，此后沿臂趋向稳态。灰色小箭头示意四个象限里 $(\dot{k}, \dot{c})$ 的方向。

37.6 应用二：Hotelling 与可耗竭资源开采

最优控制在资源经济学里给出了著名的 **Hotelling 规则**。一个矿主拥有可耗竭存量 $S(t)$ ，初始 $S(0) = S_0$ ，每期开采 $q(t) \geq 0$ 出售，存量按 $\dot{S} = -q$ 耗减。设市场价格为 p 、开采成本为零，矿主最大化折现利润：

$$\max_{q(\cdot) \geq 0} \int_0^\infty e^{-\rho t} p(t) q(t) dt \quad \text{s.t.} \quad \dot{S} = -q, \quad S(0) = S_0, \quad S(t) \geq 0.$$

状态是 S 、控制是 q 。当期值 Hamilton 量

$$\mathcal{H} = pq + m(-q) = (p - m)q.$$

注意 $\mathcal{H}$ 关于 q 是线性的——这正是最大值条件优于变分法之处：内点一阶条件会要求 $p - m = 0$ ，但若 $p > m$ 矿主想无限开采、若 $p < m$ 则完全不采。最优内点路径恰好维持 $p = m$ （影子价格等于市价：留在地下的边际价值等于卖出的边际收入），此时 $\mathcal{H}$ 对 q 无差异，由市场出清定开采量。协态方程在零成本下尤其干净： $\partial \mathcal{H} / \partial S = 0$ （存量本身不进收益），故

$$\dot{m} = \rho m - \frac{\partial \mathcal{H}}{\partial S} = \rho m.$$

即 $m(t) = m_0 e^{\rho t}$ ：影子价格以折现率指数增长。结合 $p = m$ 得

Hotelling 规则：地下资源的价格按利率增长

$$\boxed{\frac{\dot{p}}{p} = \rho} \quad (\text{零开采成本}).$$

矿藏在地下是一项资产，其“回报”全部来自升值。无套利要求它的升值率等于资金的机会成本 ρ ——否则矿主要么今天全采了去买债券、要么屯着等涨价。于是资源的净价格（扣除开采成本后的“矿租”）必须以利率增长。这是协态方程 $\dot{m} = \rho m$ 的直接读数：当状态不进当期收益时，影子价格纯粹靠折现率自我增值。

把价格路径接回需求即可定出存量路径。设需求 $q = a - bp$ ，则 $p(t) = m_0 e^{\rho t}$ 给出 $q(t) = a - b m_0 e^{\rho t}$ ，开采量随价格上涨而递减；存量 $S(t) = S_0 - \int_0^t q \, ds$ 单调下降。初值 m_0 由“恰好在某有限时刻 T 把资源采尽、且此刻价格升到需求纵截距（ $q = 0$ ，即所谓窒息价格 a/b ）”这个横截条件钉死。图 37.2 把价格与存量的最优路径并排画出。

37.7 应用三：q 理论投资

第三个经典落点是带调整成本的最优投资，它给出了 Tobin 的 q 理论的微观基础。企业选择投资率 I 以最大化折现净现金流，资本按 $\dot{K} = I - \delta K$ 积累，但安装投资要




图 37.2: Hotelling 最优开采路径。(a) 资源净价格按利率指数上升, 直至 T 时刻触及窒息价格 $\bar{p}$ 、需求归零。(b) 地下存量从 S_0 单调耗减; 由于开采量随价格上涨而下降, 耗减先快后慢, 曲线凸减、末端 $\dot{S} = -q \rightarrow 0$ 切线水平, 到 T 恰好采尽 ($S(T) = 0$)。

付凸的调整成本 $C(I)$ ($C', C'' > 0$):

$$\max_{I(\cdot)} \int_0^\infty e^{-\rho t} [\pi(K) - I - C(I)] dt \quad \text{s.t.} \quad \dot{K} = I - \delta K,$$

$\pi(K)$ 为资本的营业利润流。当期值 Hamilton 量 $\mathcal{H} = \pi(K) - I - C(I) + m(I - \delta K)$ 。

例 (导出投资的 q 理论)。

写出 I 的最大值条件, 并解释为何协态 m 就是“边际 q ”。

解.

最大值条件:

$$\frac{\partial \mathcal{H}}{\partial I} = -1 - C'(I) + m = 0 \implies m = 1 + C'(I).$$

即投资到安装一单位资本的边际成本 (购置 1 加调整成本 C') 等于该单位资本的影子价格 m 。由于 $C'' > 0$, 可反解出 $I = C'^{-1}(m - 1)$, 投资是 m 的增函数: 影子价格越高、越值得投。协态方程:

$$\dot{m} = \rho m - \frac{\partial \mathcal{H}}{\partial K} = \rho m - (\pi'(K) - \delta m) = (\rho + \delta)m - \pi'(K).$$

这里的协态 m 正是 Tobin 的边际 q ——增加一单位安装好的资本给企业带来的边际价值。把协态方程写成资产定价式 $(\rho + \delta)m = \pi'(K) + \dot{m}$ 即一目了然: 持有一单位资本的要求回报 $(\rho + \delta)m$, 等于它的边际利润股息 $\pi'(K)$ 加上 q 的资本利得 $\dot{m}$ 。当 $q = m > 1$ (资本的市场估值高于其重置成本), 企业就该正投资; $q < 1$ 则该让资本折旧缩减。 q 理论把“企业该不该投资”这个问题, 干净地归结为“影子价格 m 是否超过 1”。

37.8 与动态规划的等价： λ 是值函数的梯度

最后把最优控制接回它的孪生工具——动态规划。两者解的是同一类问题，只是视角不同：最大值原理沿着最优路径走，追踪状态与协态这一对轨线；动态规划则站在状态空间里，为每个可能的状态求一个“从此刻起最优能拿到的价值”，即值函数 $V(x, t)$ 。二者由一个简洁的桥梁相连。

协态 = 值函数对状态的梯度

对同一个最优控制问题，沿最优路径有

$$\lambda(t) = \frac{\partial V}{\partial x}(x^*(t), t) \quad (\text{折现问题则 } m(t) = \partial V / \partial x).$$

协态变量就是值函数关于状态的偏导——这正坐实了“ λ 是状态的影子价格”这一说法：影子价格的标准定义本就是“最优值对约束（此处即状态存量）的边际”，而那恰是包络定理给出的 $\partial V / \partial x$ 。

这条等式不是巧合，而是包络定理（最优化部分）在动态情形的化身：影子价格永远等于最优值函数对资源的边际敏感度。从它出发，连续时间动态规划的 Hamilton–Jacobi–Bellman 方程

$$\rho V(x) = \max_u \left\{ f(x, u) + V'(x) g(x, u) \right\}$$

与最大值原理是一回事：右边花括号内正是把 $\lambda = V'(x)$ 代入后的 current-value Hamilton 量 $\mathcal{H}$ ，对 u 取 $\max$ 就是最大值条件；而对 HJB 两边关于 x 求导（用包络定理）便复现协态方程 $\rho m = \partial \mathcal{H} / \partial x + \dot{m}$ 。

两条路，一座山

最大值原理与动态规划是同一座山的两条上山路。最大值原理（本章）适合刻画路径的性质——增长率规则、相图、鞍点动态，连续时间、确定性问题里它往往最省力。动态规划（下一章）适合递归地刻画策略（控制作为状态的函数 $u = u(x)$ ），且能自然地推广到随机环境（随机动态规划）。知道 $\lambda = V'(x)$ 这座桥，就能在两种语言间自由翻译：路径上的协态，就是状态空间里值函数的斜率。

至此，本章的工具完成了它的使命：把“在时间上分配资源”这个宏观经济学的母题，化为一个 Hamilton 量、一条最大化条件、一条协态方程与一组横截条件。Ramsey 规则、Hotelling 规则、q 理论——这些看似分属增长、资源、投资三个领域的结果，骨子里都是同一条协态方程在不同收益与运动方程下的读数。而协态变量 λ 作为“状态的动态影子价格”，既是这套机器的核心，也是通往下一章动态规划的桥。

第三十八章 动态规划与 Bellman 方程

用到的前置工具：压缩映射与 Banach 不动点定理、Blackwell 充分条件（压缩映射一章）；值函数与包络定理、Benveniste-Scheinkman 公式（值函数与包络定理一章）；无约束最优化的一阶条件（最优化部分）；上确界范数与有界函数空间（分析与拓扑部分）。

宏观经济学里几乎每一个量化模型，骨子里都是同一道题：一个决策者在无穷长的时间里反复做选择，每期的选择既要顾及当期得失，又要顾及它把人推到什么样的未来。最优增长里社会计划者每期在消费与投资间分配产出；消费-储蓄模型里家庭每期决定花多少、存多少；求职模型里失业者每天决定是否接受手头的工价；厂商每期决定投资多少、要不要更换设备。这些问题的共同形状是**序贯决策**（sequential decision）：一长串环环相扣的选择，前一步的选择经由“状态”的演化约束了后一步的可能性。直接把它当成一个变量多到无穷的最优化问题来解，既无从下手，也看不出结构。

动态规划（dynamic programming）给出的，是一种以“少胜多”的视角转换：它不去一次性地解出整条最优路径，而是把整个无穷期问题压缩成一个关于单期的递归方程——Bellman 方程。一旦能写出 Bellman 方程，无穷维的最优化就塌缩成“在每个状态上做一次静态最优化”，而把这些静态问题串起来的，是一个定义在函数空间上的算子。本章先由序贯问题导出 Bellman 方程（最优性原理），再说明这个算子是压缩、于是值函数存在唯一、值迭代必收敛（直接接上压缩映射一章的结论），随后给出策略迭代这另一条求解路线，最后用包络定理对值函数求导、结合一阶条件导出 Euler 方程——把动态规划接回它在宏观、消费理论与结构估计里的全部去处。

38.1 序贯决策与序贯问题

先把要解的问题摆清楚。一个标准的无穷期、折现、确定性最优化问题，由四样东西刻画：**状态** $x \in X$ （描述“此刻处境”的变量，如资本存量、财富、是否在业），**行动** $a \in \Gamma(x)$ （在状态 x 下可选的决策，可行集 $\Gamma(x)$ 可能随状态而变），**当期收益** $u(x, a)$ （这一期的得失），以及**状态转移** $x' = \phi(x, a)$ （今天的状态与行动决定明天的状态）。再加一个**折现因子** $\beta \in [0, 1)$ ：未来的收益按 β 的幂次贴现回今天。

定义 38.1: 序贯问题

给定初始状态 $x_0 \in X$ ，序贯问题 (sequence problem, SP) 是在所有可行的行动序列上最大化折现收益之和：

$$W(x_0) = \sup_{\{a_t\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t u(x_t, a_t) \quad \text{s.t.} \quad a_t \in \Gamma(x_t), \quad x_{t+1} = \phi(x_t, a_t), \quad x_0 \text{ 给定.}$$

称 $W : X \rightarrow \mathbb{R}$ 为序贯问题的**值函数**：它是从每个可能的起点出发所能达到的最优折现总收益。

这里“选择”的对象是整条无穷长的行动序列 $\{a_t\}_{t=0}^{\infty}$ ——一个无穷维的最优化对象。直接对它做一阶条件，会得到一串首尾相连、无穷多个方程，难以驾驭。动态规划的全部出发点，是注意到这个问题有一种特殊的递归结构：它在时间上“自相似”。

为什么序贯问题适合递归处理

注意收益和与转移方程都是**平稳** (stationary) 且**可加的**：当期收益 $u(x, a)$ 只看当下的状态与行动（不显含时间 t ），转移 $\phi(x, a)$ 也是；而总收益是各期收益的折现求和。这两条合起来意味着：站在任意一期 t 回望，“从今往后”的问题与“从第 0 期起”的问题长得一模一样，只是起点状态从 x_0 换成了 x_t 。正是这种“未来是当下的缩影”让我们能把无穷期问题折叠进一个单期的递归方程。可加性保证今天的决策只通过一个渠道——它留给明天的状态 x' ——影响整个未来；折现 $\beta < 1$ 则保证那个未来的价值是有限的、可比较的。

38.2 最优性原理与 Bellman 方程

把上面的“自相似”说法形式化，就得到动态规划的奠基性观察——Bellman 的**最优性原理**。

最优性原理 (Principle of Optimality)

一条最优策略具有这样的性质：无论初始状态与初始决策为何，余下的决策相对于由初始决策所导致的新状态而言，必定也构成一条最优策略。换句话说：**最优路径的任意一段尾巴，本身也是从它的起点出发的最优路径。**

这句话听上去像绕口令，几何上却极朴素（图 38.1）。设想从 x_0 出发的一条最优路径，它第一步选了 a_0 、于是明天落在 $x_1 = \phi(x_0, a_0)$ 。把这条路径在 $t = 1$ 处“切一刀”，剩下从 x_1 往后的那段尾巴——如果它不是“从 x_1 出发的最优路径”，那我们就能用一条更好的尾巴替换它，从而改进整条路径的总收益；但这与原路径已是最优相矛盾。故那段尾巴必然最优。它的折现总收益，恰恰就是从 x_1 出发的值 $W(x_1)$ 。

有了这个洞见，导出 Bellman 方程只需把“切一刀”写成等式。从 x_0 出发的最优




图 38.1: 最优性原理。整条最优路径的折现总收益是 $W(x_0)$ ；在 $t=1$ 处“切一刀”，从 x_1 起的尾巴本身也最优，其折现值为 $\beta W(x_1)$ 。于是 $W(x_0)$ 拆成“当期收益 $u(x_0, a_0)$ ”加上“折现后的尾巴 $\beta W(x_1)$ ”——这正是 Bellman 方程的来源。

总收益，等于第一步的当期收益，加上从明天的状态起最优地走下去的折现值：

$$W(x_0) = \max_{a_0 \in \Gamma(x_0)} \left\{ u(x_0, a_0) + \beta W(\phi(x_0, a_0)) \right\}.$$

这里的关键一跳是：尾巴的最优值不必再展开成一串无穷和，最优性原理保证它就是 $W(\phi(x_0, a_0))$ 本身。由于问题平稳，起点 x_0 没有任何特殊之处，对每个状态 x 都成立同样的等式。去掉时间下标、把状态记为 x 、明天的状态记为 $x' = \phi(x, a)$ ，便得到本章的中心方程。

定义 38.2: Bellman 方程

Bellman 方程 (Bellman equation, 又称泛函方程) 是关于未知函数 $V: X \rightarrow \mathbb{R}$ 的方程

$$V(x) = \max_{a \in \Gamma(x)} \left\{ u(x, a) + \beta V(\phi(x, a)) \right\} \quad \text{对一切 } x \in X.$$

满足此方程的 V 称为该问题的**值函数** (value function)。达到右端最大值的行动 a (作为状态 x 的函数) 记

$$g(x) = \arg \max_{a \in \Gamma(x)} \left\{ u(x, a) + \beta V(\phi(x, a)) \right\},$$

称为**最优策略函数** (optimal policy function)。

请细看这个方程的“身份”：它不是一个关于数的方程，而是一个关于函数的方程——未知量 V 是整条函数，方程要求它在每一点都与“自己经过右端那套运算后”的结果相等。这正是泛函方程之名的由来，也预告了求解它需要在函数空间上做文章。

Bellman 方程把“无穷维”压成“单期 + 递归”

序贯问题 $W(x_0) = \sup \sum_t \beta^t u(x_t, a_t)$ 的选择对象是无穷长的行动序列；Bellman 方程把它替换成“在每个状态上做一次单期最大化” $\max_a \{u(x, a) + \beta V(x')\}$ 。两者通过最优性原理等价： W 满足 Bellman 方程，且 Bellman 方程的解就是

W （在适当条件下，见下节）。这是动态规划的核心交易——用一个定义在函数空间上的递归方程，换掉一个无穷维的序贯最优化。代价是要去函数空间里求解 V ；回报是结构空前清晰：当期收益 $u(x, a)$ 与“留给未来的状态价值” $\beta V(x')$ 之间的权衡，被孤立成一道每期都一样的静态题。

注（行动可以是“下一期状态”本身）。

许多模型里把“选明天的状态”当作决策更方便。例如最优增长中产出 $f(k)$ 一部分消费、一部分留作明天的资本 k' ，与其说“选投资 i ”不如直接说“选 k' ”。此时 Bellman 方程写成

$$V(k) = \max_{k' \in \Gamma(k)} \left\{ u(f(k) - k') + \beta V(k') \right\},$$

行动 $a = k'$ 、转移 $\phi(k, k') = k'$ 退化为恒等。这是宏观里最常见的写法，下文的 Euler 方程与例子都采用它。

38.3 Bellman 算子与值函数的存在唯一

要让上一节的全部论断站得住脚，必须回答两个问题：Bellman 方程有解吗？解唯一吗？这两问的答案，整个落在压缩映射一章已经备好的工具上。关键是把 Bellman 方程右端看成一个作用在函数上的算子。

定义 38.3: Bellman 算子

设 $B(X)$ 为 X 上的有界函数空间，配上确界范数 $\|f\|_\infty = \sup_{x \in X} |f(x)|$ 。Bellman 算子 $T: B(X) \rightarrow B(X)$ 把候选值函数 f 映成新函数 Tf ：

$$(Tf)(x) = \max_{a \in \Gamma(x)} \left\{ u(x, a) + \beta f(\phi(x, a)) \right\}.$$

在这套语言下，Bellman 方程 $V = TV$ 就是一句话：值函数是 Bellman 算子的不动点。于是“Bellman 方程有唯一解”等价于“ T 有唯一不动点”——而压缩映射一章的 Banach 不动点定理正是回答不动点存在唯一的利器。我们只需验证 T 是压缩。直接和上确界、绝对值缠斗并不轻松，所幸压缩映射一章给出的 Blackwell 两条充分条件专为这类算子量身定做：只要 T 保持单调、且对函数整体加常数有折现效应，它就自动是压缩。这两条对 Bellman 算子都一目了然。

假设 38.4: 标准假设

当期收益 u 有界 ($\sup_{x,a} |u(x, a)| < \infty$)、折现因子 $\beta \in [0, 1)$ 、可行集 $\Gamma(x)$ 非空。

有界性是为了让 T 把 $B(X)$ 映回 $B(X)$ 、并直接套用 sup-范数下的完备性；常见的无界收益（如对数效用、二次损失）需要换用带权范数或单调收敛的论证，结论形态不变，本章按工具性立场默认有界以突出主线。

定理 38.5: 值函数的存在唯一与值迭代收敛

在标准假设下, Bellman 算子 $T: B(X) \rightarrow B(X)$ 是 sup-范数下系数为 β 的压缩映射。从而:

- (存在唯一) Bellman 方程 $V = TV$ 有且仅有一个解 $V \in B(X)$;
- (值迭代收敛) 从任意初猜 $V_0 \in B(X)$ 出发, 迭代 $V_{n+1} = TV_n$ 都收敛到 V , 且

$$\|V_n - V\|_\infty \leq \frac{\beta^n}{1-\beta} \|V_1 - V_0\|_\infty,$$

即误差以 β^n 的几何速率衰减。

证明. $B(X)$ 配 sup-范数是完备度量空间 (一致收敛的极限仍有界), 故只需证 T 是压缩, 再援引 Banach 不动点定理。验 Blackwell 两条:

单调性。 设 $f \leq g$ 处处成立。因 $\beta \geq 0$, 对每个 x 与每个可行 a 都有 $u(x, a) + \beta f(\phi(x, a)) \leq u(x, a) + \beta g(\phi(x, a))$ 。逐点占优的两族数取最大值后仍占优, 故 $(Tf)(x) \leq (Tg)(x)$ 。

折现。 对任意常数 $c \geq 0$, 注意 βc 与被最大化的 a 无关、可提到 $\max$ 外:

$$(T(f+c))(x) = \max_a \{u(x, a) + \beta(f(\phi(x, a)) + c)\} = (Tf)(x) + \beta c.$$

两条 Blackwell 条件成立, 压缩系数恰为折现因子 $\beta < 1$, 故 T 压缩。其余三句结论 (存在、唯一、几何收敛与误差界) 由 Banach 不动点定理直接给出。□

动态规划的地基, 是“压缩”这一个条件

本节兑现了上一节悬而未决的承诺: Bellman 方程有唯一解 (“值函数”这个概念因此良定义、无歧义), 而且这个解可以算——从任意初猜 (哪怕 $V_0 \equiv 0$) 反复作用 T 必收敛到它, 连 “算几步够” 都由误差界 $\frac{\beta^n}{1-\beta} \|V_1 - V_0\|_\infty$ 回答。请记住这条因果链: 折现 $\beta < 1 \Rightarrow T$ 压缩 (系数 β) $\Rightarrow$ 值函数存在唯一 + 值迭代收敛。它也解释了一桩校准中天天遇到的朴素事实—— β 越接近 1 (决策者越有耐心), 压缩越弱、值迭代越慢。

38.4 值迭代

上节定理里那句 “ $V_{n+1} = TV_n$ 收敛” 本身就是一套算法, 叫**值迭代** (value function iteration, VFI), 是数值动态规划最基本的求解器。它把求解泛函方程变成一个机械的循环: 随便取一个初始值函数 V_0 (通常取 $V_0 \equiv 0$), 反复对它作用 Bellman 算子, 序列 $V_0 \rightarrow V_1 \rightarrow V_2 \rightarrow \cdots$ 单调而稳步地逼近真正的值函数 V^* 。每一步 $V_{n+1} = TV_n$ 都只是对每个状态 x 做一次静态最大化 $\max_a \{u(x, a) + \beta V_n(\phi(x, a))\}$ ——再无穷期的问题, 也被拆成了一连串单期最优化。

收敛的几何图像最直观 (图 38.2): 把每个 V_n 画成 X 上的一条曲线, 它们像一摞逐步抬升的水平线, 相邻两条之间的间隔按 β 的幂次缩小——这正是上确界范数下 $\|V_{n+1} - V_n\|_\infty \leq \beta \|V_n - V_{n-1}\|_\infty$ 的可视化, 与压缩映射一章里“相邻迭代步长几何衰减”是同一回事。




图 38.2: 值迭代的几何收敛。从任意初猜 V_0 出发, $V_{n+1} = TV_n$ 生成一摞逐步抬升的曲线, 逐点逼近不动点 V^* 。相邻两条曲线在 sup-范数下的间隔 $d_0, \beta d_0, \beta^2 d_0, \dots$ 按 β 的幂次几何收缩——这就是 T 为压缩 (系数 β) 的可视化。

例 (用值迭代验证最优增长的解析解)。

考虑对数效用、Cobb–Douglas 生产、资本完全折旧的最优增长模型, 决策对象取为下一期资本 k' :

$$V(k) = \max_{0 \leq k' \leq k^\alpha} \left\{ \ln(k^\alpha - k') + \beta V(k') \right\}, \quad \alpha \in (0, 1), \beta \in (0, 1).$$

(产出 k^α 一部分消费 $c = k^\alpha - k'$ 、一部分作明天的资本 k' 。) 用值迭代从 $V_0 \equiv 0$ 出发, 猜测极限的函数形式并验证它满足 Bellman 方程。

解.

先做一步值迭代看出形状。取 $V_0 \equiv 0$ 。则

$$V_1(k) = \max_{k'} \ln(k^\alpha - k') = \ln(k^\alpha) = \alpha \ln k$$

($\beta V_0 = 0$, 故全部产出当期消费、 $k' = 0$ 最优)。再迭代一步会得到形如 $A_2 + B_2 \ln k$ 的函数。这提示极限必是

$$V(k) = A + B \ln k$$

的形式（“猜函数形式再验证”的待定系数法，其合法性正源于值迭代收敛到唯一不动点：只要猜中的 $A + B \ln k$ 满足 Bellman 方程，它就是那个值函数）。

代入待定。把 $V(k') = A + B \ln k'$ 代入 Bellman 方程右端：

$$A + B \ln k = \max_{k'} \left\{ \ln(k^\alpha - k') + \beta(A + B \ln k') \right\}.$$

对 k' 求一阶条件 $-\frac{1}{k^\alpha - k'} + \frac{\beta B}{k'} = 0$ ，解得最优储蓄

$$k' = \frac{\beta B}{1 + \beta B} k^\alpha.$$

回代、比较两边 $\ln k$ 的系数：右端 $\ln(k^\alpha - k') + \beta B \ln k'$ 中含 $\ln k$ 的部分为 $\alpha(1 + \beta B) \ln k$ 嵌进对数后整理给出系数方程 $B = \alpha + \alpha \beta B$ ，故

$$B = \frac{\alpha}{1 - \alpha \beta}.$$

于是最优策略

$$k' = g(k) = \alpha \beta k^\alpha \quad \left(\text{因 } \frac{\beta B}{1 + \beta B} = \alpha \beta \right),$$

即每期把产出的固定比例 $\alpha \beta$ 储蓄下来、其余 $(1 - \alpha \beta)$ 比例消费。常数 A 由 $A = \frac{1}{1 - \beta} \left[\ln(1 - \alpha \beta) + \frac{\alpha \beta}{1 - \alpha \beta} \ln(\alpha \beta) \right]$ 给定（对收敛与策略无关紧要）。这个 $V = A + B \ln k$ 满足 Bellman 方程，由解的唯一性它就是值函数——而值迭代从 $V_0 \equiv 0$ 出发必收敛到它，第一步 $V_1 = \alpha \ln k$ 已显出 $\ln k$ 的雏形。

注（这就是图 38.3 里的政策函数）。

上例解出的最优策略 $k' = g(k) = \alpha \beta k^\alpha$ 是一条凹增曲线。它与 45° 线 $k' = k$ 的交点给出稳态资本 $k^* = (\alpha \beta)^{1/(1 - \alpha)}$ （令 $g(k^*) = k^*$ 解出）；从任意初始资本出发，按 $k_{t+1} = g(k_t)$ 迭代都单调收敛到 k^* 。下一节把策略函数与这种动态收敛画在一起。

38.5 最优策略函数

值迭代收敛后，我们手里有了值函数 V ；但模型的行为预测，藏在伴随而生的**最优策略函数** $g(x) = \arg \max_a \{u(x, a) + \beta V(\phi(x, a))\}$ 里——它直接回答“在每个状态该怎么做”。一旦有了 g ，整条最优路径只需从初始状态反复迭代 $x_{t+1} = \phi(x_t, g(x_t))$ 即可生成，无穷维的序贯问题至此被一条单变量映射的迭代完全取代。

策略函数也是连接动态规划与可观测数据的接口：消费-储蓄模型里 g 是消费函数，求职模型里 g 是“保留工资”规则，投资模型里 g 是投资政策。结构估计（下文）拟合的，正是 g （或由它生成的选择概率）与数据的吻合。

把上一节最优增长例子的策略函数 $g(k) = \alpha \beta k^\alpha$ 画出来，能一眼看清模型的长期行为（图 38.3）。策略曲线与 45° 线的交点是**稳态**（steady state） k^* ：在那里“明天的资本恰等于今天”，系统停驻。曲线在 k^* 处比 45° 线平缓（ $0 < g'(k^*) < 1$ ），于是从任意初始资本出发，沿 $k_{t+1} = g(k_t)$ 的“蛛网”迭代都单调收敛到 k^* ——这与压缩映射一章里收敛蛛网图是同一种几何，只不过这里迭代的是状态、那里迭代的是值函数。




图 38.3: 最优增长模型的策略函数 $k' = g(k) = \alpha\beta k^\alpha$ ($\alpha = 0.4$, $\beta = 0.95$)。它与 45° 线相交于稳态 $k^* = (\alpha\beta)^{1/(1-\alpha)} \approx 0.20$ 。因 $0 < g'(k^*) < 1$, 从任意 k_0 出发沿 $k_{t+1} = g(k_t)$ 迭代的“蛛网”都单调收敛到 k^* 。

38.6 策略迭代

值迭代每步只把值函数往前推一点点（收敛速率 β , β 接近 1 时奇慢）。策略迭代 (policy iteration, Howard 算法) 换一条思路：不去一点点改进值函数，而是一次性把一个固定策略评估到底，再据此改进策略，如此交替。它往往以超线性的速度、很少的几轮就收敛，是另一根求解动态规划的主梁。

策略迭代在两步之间循环。给定当前策略 g ：

第一步：策略评估 (policy evaluation)。假装今后永远照 g 行事，算出这套（次优）策略下的值函数 V_g 。它满足一个去掉了 $\max$ 的线性方程——因为行动已被 g 钉死，不再需要最大化：

$$V_g(x) = u(x, g(x)) + \beta V_g(\phi(x, g(x))) \quad \text{对一切 } x.$$

这是一个关于 V_g 的线性不动点方程（记右端算子为 T_g , 则 $V_g = T_g V_g$ ）；状态有限时它就是一个线性方程组，可直接求逆解出 $V_g = (\mathbf{I} - \beta \mathbf{P}_g)^{-1} \mathbf{u}_g$, 其中 $\mathbf{P}_g$ 是策略 g 诱导的状态转移矩阵、 $\mathbf{u}_g$ 是各状态当期收益向量。

第二步：策略改进 (policy improvement)。拿着评估出的 V_g , 在每个状态重新做一次单期最大化，看有没有比 $g(x)$ 更好的当期行动：

$$g^+(x) = \arg \max_{a \in \Gamma(x)} \left\{ u(x, a) + \beta V_g(\phi(x, a)) \right\}.$$

用 g^+ 替换 g , 回到第一步。如此往复，直到策略不再变化。

定理 38.6: 策略迭代单调改进且收敛

策略迭代生成的策略序列对应的值函数逐轮不减： $V_{g^+} \geq V_g$ （逐点）；且当策略不再改变时，对应的 V_g 满足 Bellman 方程，故 g 为最优策略、 $V_g = V$ 。在有限状态-有限行动下，策略迭代经有限轮终止于最优。

证明. 改进不变差。由 g^+ 的定义，它在每个状态取得的右端值不小于 g 所取得的，即

$$u(x, g^+(x)) + \beta V_g(\phi(x, g^+(x))) \geq u(x, g(x)) + \beta V_g(\phi(x, g(x))) = V_g(x).$$

左端正是 $(T_{g^+} V_g)(x)$ ，故 $T_{g^+} V_g \geq V_g$ 。 T_{g^+} 单调（与 Bellman 算子同理， $\beta \geq 0$ 加 $\max$ 退化求和仍保序），反复作用并取极限： $V_{g^+} = \lim_n T_{g^+}^n V_g \geq V_g$ 。即新策略处处不差于旧策略。

终止即最优。若某轮 $g^+ = g$ ，代入改进的定义即知 $V_g(x) = \max_a \{u(x, a) + \beta V_g(\phi(x, a))\}$ ，恰是 Bellman 方程；由解的唯一性 $V_g = V$ 、 g 为最优。有限状态-行动下策略只有有限多个、且值严格改进（除非已最优），故必有限轮终止。□

值迭代 vs. 策略迭代：同一地基，两种节奏

两套算法都根植于“ T 单调 + 折现”这副骨架（见压缩映射一章）。差别在节奏：**值迭代**每步只对值函数作用一次 T ，便宜但收敛慢（线性速率 β ）；**策略迭代**每轮先把当前策略彻底评估（解一个线性方程组，等价于把 T_g 迭代到收敛），再贪婪改进，轮数极少（常 $O(\log)$ 量级）但每轮更贵。实践中常用折中的“修正策略迭代”：评估步只迭代固定的几次而非解到底。无论哪种，正确性都由本章“ T 是压缩、解唯一”与策略改进的单调性共同担保。

38.7 包络定理与 Euler 方程

到此我们能求出值函数与策略函数，但还缺一件做解析分析时最常用的东西：**Euler 方程**——刻画相邻两期最优选择之间权衡的一阶必要条件。它是消费理论、资产定价、最优增长里做比较分析、推导利率-消费增长关系的标准入口。导出它需要对值函数求导，而 V 只是“由一个 $\max$ 隐式定义”的对象、没有显式表达式。这正是值函数与包络定理一章里 Benveniste-Scheinkman 公式大显身手之处。

以宏观最常用的“选下一期状态”写法为例：

$$V(k) = \max_{k'} \left\{ u(f(k) - k') + \beta V(k') \right\}.$$

内点最优 $k' = g(k)$ 满足对 k' 的一阶条件——当期多存一单位、少消费的边际损失，等于明天多一单位资本带来的折现边际值：

$$-u'(f(k) - k') + \beta V'(k') = 0 \iff u'(c) = \beta V'(k'), \quad c = f(k) - k'. \quad (38.1)$$

式 (38.1) 含一个我们尚不知道的对象 $V'(k')$ 。下一步用包络定理把它算出来。

用 Benveniste–Scheinkman 求 V' 。把状态 k 当参数、 k' 当选择变量，对值函数恒等式 $V(k) = u(f(k) - g(k)) + \beta V(g(k))$ 求 $\frac{d}{dk}$ 。链式法则给出对 k 的直接通道加上经由 $g(k)$ 的间接通道：

$$V'(k) = u'(c) f'(k) + \underbrace{[-u'(c) + \beta V'(k')]}_{=0 \text{ (对 } k' \text{ 的一阶条件 (38.1))}} g'(k).$$

方括号恰是一阶条件，间接项归零，余下

$$\boxed{V'(k) = u'(c) f'(k)}. \quad (38.2)$$

这就是 Benveniste–Scheinkman 公式在本模型的形态：边际值函数等于“当期消费的边际效用”乘以“资本的边际产出”——直观上，多一单位资本能多产出 $f'(k)$ 、换成消费值 $u'(c)f'(k)$ 。它对隐式值函数求导这件没把握的事，变成了一个一目了然的偏导。

合成 Euler 方程。式 (38.2) 对任意期都成立，故明天 $V'(k') = u'(c')f'(k')$ (c' 是明天的消费)。把它代回一阶条件 (38.1) $u'(c) = \beta V'(k')$ ，那个抽象的 V' 被彻底消去，只剩下相邻两期的消费与可观测的技术：

$$\boxed{u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1})} \quad (\text{Euler 方程}).$$

Euler 方程：跨期的“边际权衡相等”

Euler 方程是整个跨期最优化的中枢，读法是一句经济直觉：**今天少消费一单位的边际损失 $u'(c_t)$ ，恰好等于把它存下来、明天连本带利（边际产出 $f'(k_{t+1})$ ）地折现回来的边际收益 $\beta u'(c_{t+1})f'(k_{t+1})$ 。**最优路径上跨期的边际权衡处处相等，没有任何可改进的重新配置余地。它的导出严丝合缝地分两步：一阶条件给出“今天 vs. 明天”的权衡 $u'(c) = \beta V'(k')$ ，包络定理 (Benveniste–Scheinkman) 把无法直接观测的 V' 翻译成可观测的边际量 $u'(c')f'(k')$ 。这套“一阶条件 + 包络定理”的组合拳，是从任何递归问题里榨出 Euler 方程的通用配方。

注（与变分法的 Euler 方程是同一个东西）。

变分法部分用扰动法（对最优路径做微小偏移、令一阶变分为零）也能直接从序贯问题导出同一条 Euler 方程，不经过值函数。两条路殊途同归：变分法把它看成“无穷维最优化的一阶条件”，动态规划把它看成“递归一阶条件 + 包络定理”。动态规划这条路额外的好处是：它同时交付了全局的值函数与策略函数（不只是局部最优的必要条件），还自带了随机推广的现成框架（见下文）。

例（对数效用最优增长的 Euler 方程与稳态）。

仍取 $u(c) = \ln c$ 、 $f(k) = k^\alpha$ 、完全折旧。写出 Euler 方程，求稳态资本 k^* ，并与前文待定系数法解出的 $g(k) = \alpha\beta k^\alpha$ 对照。

解.

$u'(c) = 1/c$ 、 $f'(k) = \alpha k^{\alpha-1}$ ，代入 Euler 方程：

$$\frac{1}{c_t} = \beta \frac{1}{c_{t+1}} \alpha k_{t+1}^{\alpha-1} \iff \frac{c_{t+1}}{c_t} = \alpha \beta k_{t+1}^{\alpha-1}.$$

稳态处 $c_{t+1} = c_t$ 、 $k_{t+1} = k^*$ ，故 $1 = \alpha \beta (k^*)^{\alpha-1}$ ，解得

$$k^* = (\alpha \beta)^{1/(1-\alpha)},$$

与图 38.3 中策略函数同 45° 线交点的 k^* 完全一致。**对照策略函数**：由 $g(k) = \alpha \beta k^\alpha$ 与 $c = k^\alpha - g(k) = (1 - \alpha \beta)k^\alpha$ ，则 $c_{t+1}/c_t = (k_{t+1}/k_t)^\alpha$ 。（用 $k_{t+1} = \alpha \beta k_t^\alpha$ ）化简后正是 $\alpha \beta k_{t+1}^{\alpha-1}$ ，与 Euler 方程吻合。三条路线——值迭代待定系数、策略函数、Euler 方程——指向同一个解，互为印证。

38.8 它通向何处

动态规划是离散时间动态最优化的统治性框架，其去处几乎覆盖现代宏观与结构计量的全部：

- **宏观 DSGE 与最优增长、实际经济周期**。最优增长模型（本章贯穿的例子）是新古典宏观的内核；加入劳动-闲暇选择、技术冲击，就成了 RBC 与各类 DSGE 模型。它们的求解与分析，靠的正是本章的值/策略迭代（数值解）与 Euler 方程（解析刻画、对数线性化）。
- **消费-储蓄与永久收入假说**。家庭的跨期消费选择是 Bellman 方程的直接应用，Euler 方程 $u'(c_t) = \beta \mathbb{E}((1 + r_{t+1}) u'(c_{t+1}))$ （随机收益版）就是消费理论的核心方程；永久收入假说、预防性储蓄、流动性约束都在这套递归框架里展开。
- **动态离散选择与结构估计 (Rust 模型)**。当行动是离散的（换不换发动机、退不退出市场、上不上学），值函数定义在离散行动上，Bellman 方程成为“条件值函数”的递归。Rust 的嵌套不动点算法 (NFXP) 把“内层用值迭代解 Bellman、外层最大化似然”嵌套起来，是结构产业组织与劳动经济学估计动态模型的奠基方法。
- **随机动态规划与 Markov 决策过程**。把确定性转移 $x' = \phi(x, a)$ 换成随机转移核、把 $V(\phi(x, a))$ 换成条件期望 $\mathbb{E}(V(x') | x, a)$ ，本章的全部论证一字不改地成立 (Blackwell 两条仍满足、 T 仍压缩)——这就是下一章随机递归方法的主题，也是上面所有应用的真正工作形态（收入冲击、生产率冲击、价格不确定）。
- **强化学习**。机器学习里的 Q-学习、时序差分、策略梯度，骨架就是 Bellman 方程与值/策略迭代在“转移核未知、需从样本中学”情形下的随机近似版本。本章的压缩与不动点视角，是理解这些算法为何收敛的出发点。

把本章放回全书的脉络，它是数把工具的交汇点：**压缩映射**（压缩映射一章）担保值函数存在唯一、值迭代收敛；**包络定理**（值函数与包络定理一章）让我们能对隐式的值函数求导、生出 Euler 方程；**一阶条件**（最优化部分）给出每期的跨期权衡。三者合

流，把一个看似无从下手的无穷期最优化，化成“一个递归方程 + 一套迭代算法 + 一条 Euler 方程”。认准了 Bellman 方程这一个递归方程，就等于同时握住了现代宏观与动态结构估计的总钥匙。

第三十九章 随机动态规划与递归方法

用到的前置工具：上一章的（确定性）动态规划与 Bellman 方程；压缩映射与 Banach 不动点定理、Blackwell 充分条件（第十二章）；条件期望（概率与测度部分）；Markov 链与转移矩阵（随机过程部分）；用于一阶条件的包络定理（最优化部分）。

上一章的动态规划假设了一个其实并不存在的世界：明天会怎样，今天就已经板上钉钉。可现实经济的底色恰恰是不确定——技术冲击让产出忽高忽低，个人收入随就业、健康起落，资产回报更是天天在赌。一旦把随机性放进来，“状态”就分成两半：一半是决策者自己攒下来的、可由行动改变的**内生状态**（资本、财富），另一半是老天爷甩过来的、谁也左右不了的**外生冲击**。本章要做的，是把上一章那套递归方法升级到这个有冲击的世界，并说明一件令人安心的事：升级几乎不费力气——只要在“看向未来”的那一步把确定的值换成条件期望，确定性 DP 的整套机器（值函数存在唯一、值迭代收敛、Euler 方程）就原样接着转。能这么省事，根子在一个朴素的算子性质：取期望不会把函数之间的距离放大。本章先把随机 Bellman 方程立起来，再证期望保压缩、随机值迭代仍收敛，接着导出含 $\mathbb{E}_t$ 的随机 Euler 方程，最后落到现代宏观与金融最看重的三处去处——预防性储蓄、递归竞争均衡、资产定价的随机贴现因子。

39.1 从确定到随机：状态里多出一个冲击

回忆上一章那个标准的折现序贯问题：选一串行动使折现收益和最大。确定性版本里，今天的状态 x 加上今天的行动 a ，明天的状态 $x' = \phi(x, a)$ 就完全定下来了。现在往里掺入不确定性。最干净的做法是引入一个**外生状态** z （“冲击”），它本身按某个随机规律演化、不受决策者控制，但会影响当期收益或状态转移。于是系统由一对状态 (x, z) 描述：

- x 是**内生状态**（endogenous state）：资本存量、金融财富、库存——决策者通过行动 a 改变它， $x' = \phi(x, a, z)$ 。
- z 是**外生状态**（exogenous state）或**冲击**：全要素生产率、利率、个人收入扰动——它自行演化，决策者只能观察、不能干预。

对 z 的演化，最常用、也最便于递归处理的假设是它服从 **Markov 过程**：明天的冲击分布只取决于今天的冲击，与更早的历史无关。这个假设之所以是“天作之合”，是因为递归方法的全部威力都建立在“当前状态是对未来的充分概括”之上；只要 z 是 Markov 的， (x, z) 这一对就仍然是充分状态——记住今天的 (x, z) ，明天该怎么决策就一清二楚，无需翻历史账本。

假设 39.1: 外生冲击服从 Markov 过程

冲击 z_t 取值于状态空间 $\mathcal{Z}$, 其演化满足 Markov 性质: 对任意 t 与任意可测集 B ,

$$\mathbb{P}(z_{t+1} \in B | z_t, z_{t-1}, \dots, z_0) = \mathbb{P}(z_{t+1} \in B | z_t).$$

当 $\mathcal{Z} = \{z_1, \dots, z_N\}$ 有限时, 演化由转移矩阵 Π 完全刻画, 其元素

$$\Pi_{ij} = \mathbb{P}(z_{t+1} = z_j | z_t = z_i), \quad \sum_{j=1}^N \Pi_{ij} = 1.$$

本书一律把转移矩阵写作粗体的 Π (源码 `\vc\Pi`, 而非 `\mat\Pi`) —— 大写希腊字母的矩阵在本书字体下必须用 `\vc` 才能正常显示。它的第 i 行是“今天处在 z_i 、明天落到各 z_j ”的概率分布, 故每行非负且和为 1, 即 Π 是一个随机矩阵。它的性质 (平稳分布、遍历性) 留待随机过程部分细讲, 这里只把它当作刻画冲击演化的输入。

随机情形的关键观念: 把“冲击”纳入状态, 递归结构就保住了

不确定性看似破坏了“当前状态概括一切”的递归前提, 但只要冲击是 Markov 的, 把它并入状态向量 (从 x 升级到 (x, z)), 充分性就失而复得。代价仅仅是: 状态多了一维, 且“看向明天”时面对的不再是一个确定的明天, 而是一个分布——于是“最大化未来价值”自然变成“最大化未来价值的条件期望”。本章余下的一切, 都是这一句话的展开。

39.2 随机 Bellman 方程

把上一章的 Bellman 方程改写到 (x, z) 上。决策者在状态 (x, z) 下选行动 a , 得当期收益 $u(x, a, z)$; 行动连同当期冲击决定内生状态的转移 $x' = \phi(x, a, z)$; 而下期冲击 z' 按 Π 随机抽取。决策者在选 a 时已经知道今天的 (x, z) , 但还不知道明天的 z' ——他只能对 z' 的分布取期望。这就给出

定理 39.2: 随机 Bellman 方程

设当期收益 u 有界、折现因子 $\beta \in [0, 1)$ 、可行集 $a \in \Gamma(x, z)$ 、冲击 z 按 Markov 转移核演化。则值函数 $V(x, z)$ 满足

$$V(x, z) = \max_{a \in \Gamma(x, z)} \left\{ u(x, a, z) + \beta \mathbb{E}(V(x', z') | z) \right\}, \quad x' = \phi(x, a, z),$$

其中条件期望对下期冲击 z' 求取 (给定当期 z)。有限状态时它写成

$$V(x, z_i) = \max_{a \in \Gamma(x, z_i)} \left\{ u(x, a, z_i) + \beta \sum_{j=1}^N \Pi_{ij} V(\phi(x, a, z_i), z_j) \right\}.$$

和确定性版本逐字对照，唯一的改动是把那个确定的“下期值” $V(x')$ 换成了条件期望 $\mathbb{E}(V(x', z') | z)$ 。这正是“看向一个不确定的明天”该有的样子：明天的内生状态 x' 由今天的选择定下、是确定的，但明天的冲击 z' 还没揭晓，于是对 $V(x', z')$ 沿 z' 的条件分布求平均。条件期望这个对象——“给定今天信息、对明天的最好预测”——正是条件期望一章锻造出来的工具，在这里第一次进入动态规划的核心。

注（“给定 z ”而非“给定 (x, z) ”）。

期望里的条件信息只写了 z ，没写 x 。这是因为下期冲击 z' 的分布只由当期 z （经 Π ）决定，与 x, a 无关——这是“ z 外生”的精确含义。 x' 虽是随机量 z' 出现前就被 a 锁定的确定值，但 $V(x', z')$ 仍随 z' 而波动，故期望不可省。若模型里转移本身带噪声（如 $x' = \phi(x, a, z) + \varepsilon'$ ），则把 ε' 一并纳入冲击、对其分布一起取期望即可，下文论证一字不改。

相应的最优策略也带上冲击。解出 V 后，每个状态上取到最大值的那个行动定义策略函数

$$a = g(x, z) \in \arg \max_{a \in \Gamma(x, z)} \left\{ u(x, a, z) + \beta \mathbb{E}(V(x', z') | z) \right\}.$$

与确定性情形最醒目的不同是：策略现在是两个变量的函数。固定内生状态 x 、让冲击 z 取不同值，就得到一族策略曲线——冲击越有利，同样的 x 往往对应越高的最优行动（更多投资、更多储蓄或更多消费，视模型而定）。图 39.1 画的正是随机增长模型里的资本积累策略 $k' = g(k, z)$ ：三条曲线对应高、中、低三种生产率冲击，整体随 z 上移。这族曲线就是结构计量与数值宏观真正要计算、并拿去与数据匹配的对象。




图 39.1: 随机增长模型的资本积累策略族 $k' = g(k, z)$ 。冲击 z 越高（生产率越好），对同样的当期资本 k 选择越高的下期资本，整族曲线随 z 平移。冲击使“一条”策略变成“一族”策略。

下面那张图（图 39.2）则换个角度，画出状态本身在冲击驱动下如何随机演化：今天 x_t 是确定的一点，明天 x_{t+1} 随 z' 的三种实现分叉成三个可能值（各带转移概率 Π ），后天再各自展开——这就是随机递归问题在状态空间里铺开的“情景树”。期望算子做的，正是在每个分叉处按概率加权求平均。




图 39.2: 状态在冲击下的随机演化 (情景树)。当前 x_t 确定, 下期状态随冲击 z' 的实现分叉, 各支按转移概率 $\Pi_{z_t z_j}$ 加权; 其后每个节点继续展开。Bellman 方程里的条件期望, 就是在每个分叉处按这些概率求平均。

39.3 期望算子保压缩: 随机值迭代照样收敛

把随机 Bellman 方程写成算子形式: 定义**随机 Bellman 算子** T , 它把候选值函数 $f(x, z)$ 映成

$$(Tf)(x, z) = \max_{a \in \Gamma(x, z)} \left\{ u(x, a, z) + \beta \mathbb{E}(f(x', z') | z) \right\}.$$

我们要的还是老三样: 值函数 V (即 $V = TV$ 的解) 存在、唯一, 且从任意初猜做值迭代 $V_{n+1} = TV_n$ 都收敛到它。第十二章已经用 Blackwell 充分条件把确定性算子是压缩这件事办妥了, 那里还顺手写了一句“随机情形把 $f(\phi(x, a))$ 换成条件期望, 论证一字不改”。本节把这句承诺兑现: 之所以一字不改, 是因为条件期望算子本身不放大距离。

引理 39.3: 条件期望是非扩张的

对任意两个有界函数 f, g 与任意当期冲击 z ,

$$|\mathbb{E}(f(x', z') | z) - \mathbb{E}(g(x', z') | z)| \leq \mathbb{E}(|f(x', z') - g(x', z')| | z) \leq \|f - g\|_{\infty}.$$

证明. 第一个不等号是条件期望版的三角不等式: 期望的差等于差的期望 $\mathbb{E}(f - g | z)$ (线性), 而 $|\mathbb{E}(Y | z)| \leq \mathbb{E}(|Y| | z)$ (条件 Jensen, 或直接由积分的绝对值不超过绝对值的积分)。第二个不等号: 逐点有 $|f(x', z') - g(x', z')| \leq \sup_{x', z'} |f - g| = \|f - g\|_{\infty}$, 对一个不超过常数 $\|f - g\|_{\infty}$ 的非负量取条件期望, 结果仍不超过该常数 (期望保序、且常数的期望是自身)。两步合起来即得。□

这条引理说的是一件几何上很直白的事: 取 (条件) 期望是一种“加权平均”, 而平均一组数绝不会比这组数里最大的偏离更离谱——平均把差异抹平、只会缩小或持

平，永远不会放大。这正是“非扩张”（系数 1 的 Lipschitz）的含义。有了它，验证随机 Bellman 算子的两条 Blackwell 条件就毫无悬念。

定理 39.4: 随机 Bellman 算子是压缩

在上述设定下，随机 Bellman 算子 T 是有界函数空间 $B(\mathcal{X} \times \mathcal{Z})$ （配 sup-范数）上系数为 β 的压缩映射。从而 Bellman 方程 $V = TV$ 有唯一解 V ，且从任意初猜 V_0 做值迭代 $V_{n+1} = TV_n$ 都有

$$\|V_n - V\|_\infty \leq \frac{\beta^n}{1-\beta} \|V_1 - V_0\|_\infty \rightarrow 0.$$

证明. 验 Blackwell 两条（第十二章）， T 中唯一新增的成分是条件期望算子。

单调性：设 $f \leq g$ 处处成立。条件期望保序（对 $f \leq g$ 取条件期望得 $\mathbb{E}(f|z) \leq \mathbb{E}(g|z)$ ），故对任意 (x, z) 与可行 a ，

$$u(x, a, z) + \beta \mathbb{E}(f(x', z') | z) \leq u(x, a, z) + \beta \mathbb{E}(g(x', z') | z)$$

（用到 $\beta \geq 0$ ）。逐点占优的两族数取最大值后仍占优，故 $(Tf)(x, z) \leq (Tg)(x, z)$ 。

折现：对任意常数 $c \geq 0$ ，因 $\mathbb{E}(f + c | z) = \mathbb{E}(f | z) + c$ （条件期望对常数的处理与无条件期望相同），

$$(T(f + c))(x, z) = \max_a \left\{ u + \beta (\mathbb{E}(f(x', z') | z) + c) \right\} = (Tf)(x, z) + \beta c.$$

两条 Blackwell 条件都满足，故 T 是系数 β 的压缩。有界函数空间在 sup-范数下完备，Banach 不动点定理（第十二章）即交付存在唯一与值迭代的几何收敛；误差界来自该定理的先验估计。□

随机性几乎是“免费”的：期望不破坏压缩

这是本章在理论上最该记住的一句话。从确定性 DP 到随机 DP，整套“存在 + 唯一 + 值迭代收敛”的理论骨架原封不动，唯一新增的环节——对未来取条件期望——恰好是个非扩张算子，它嵌进 Bellman 算子里既不破坏单调性、也不破坏折现，于是压缩系数仍然就是折现因子 β ，收敛速率也仍是 β^n 。换句话说，不确定性没有给递归方法的合法性添任何麻烦；它只是把“算一个确定的下期值”换成“算一个期望”，多出来的全是计算的活（求积分、求和），不是理论的坎。

图 39.3 把这层结论画了出来：从初猜 $V_0 \equiv 0$ 出发，值迭代生成的函数列 $V_1, V_2, V_3, \dots$ 自下而上逐次逼近不动点 V ，相邻两次的最大偏差按 β^n 几何缩小——与确定性情形画出来一模一样，因为期望那一步没有改变收敛的快慢。




图 39.3: 随机值迭代的几何收敛。从初猜 $V_0 \equiv 0$ 起, 迭代列 $V_1, V_2, V_3, \dots$ 自下而上逼近不动点 $V = TV$, 相邻间距按 β^n 缩小。期望算子的非扩张性保证了这一收敛与确定性情形无异。

39.4 随机 Euler 方程

值迭代回答“怎么算”, Euler 方程回答“最优条件长什么样”——它是用解析手段刻画最优行为、并把模型接到数据上的主力。确定性 Euler 方程把“今天少消费一单位的边际代价”与“存起来、明天多消费的边际收益”相等; 随机版本只在“明天”那一侧多套一个 $\mathbb{E}_t$, 因为明天的回报与边际效用都还是随机的。

以最典型的随机消费-储蓄问题为例。消费者持有财富, 每期选消费 c_t 、把余下的存成资产、赚取随机毛回报 R_{t+1} (受冲击 z 驱动), 效用为 $\mathbb{E}_0 \sum_t \beta^t u(c_t)$, u 凹增。写成递归形式, 状态是“财富 x 、冲击 z ”, Bellman 方程为

$$V(x, z) = \max_c \left\{ u(c) + \beta \mathbb{E} (V(R'(x - c), z') | z) \right\},$$

其中 $x - c$ 是当期储蓄、 R' 是随机毛回报。这里下期财富 $x' = R'(x - c)$ 因含下期回报 R' 而也随 z' 波动——这正是“随机 Bellman 方程”一节那条注里“转移本身带噪声”的情形, 把 R' 一并纳入对 z' 的条件期望即可, 下面的推导一字不改。对内点最优 c 求一阶条件 (对 c 求导、令其为零):

$$u'(c) = \beta \mathbb{E} (R' V_x(R'(x - c), z') | z).$$

右边出现的是下期值函数对财富的偏导 V_x 。要把它换成可观测的边际效用, 调用**包络定理** (最优化部分): 在已按最优策略行事的包络上, 值函数对状态的偏导等于当期收益对状态的偏导, 这里给出 $V_x(x, z) = u'(c(x, z))$ (多得一单位财富, 全花在当期消费上的边际价值)。把这条包络关系代回, 便得

定理 39.5: 随机 Euler 方程 (消费-储蓄)

内点最优消费路径满足

$$u'(c_t) = \beta \mathbb{E}(R_{t+1} u'(c_{t+1}) | z_t),$$

等价地, 记 $\mathbb{E}_t(\cdot) := \mathbb{E}(\cdot | z_t)$ (给定 t 期信息的条件期望),

$$\mathbb{E}_t \left[\beta \frac{u'(c_{t+1})}{u'(c_t)} R_{t+1} \right] = 1.$$

这就是宏观与金融里出镜率最高的方程之一。左边那一大坨的期望等于 1, 是一切“跨期最优”的统一指纹。它的读法是: 把明天多消费一单位折算回今天的“主观现值” $\beta u'(c_{t+1})/u'(c_t)$, 乘上这一单位储蓄实际换来的物质回报 R_{t+1} , 再对未达成的不确定性取期望, 平均下来应当不赚不亏 (等于 1); 否则当前的消费-储蓄配置就还没榨干, 可以重新分配来变好。

注 (与确定性 Euler 方程的唯一区别就是那个 $\mathbb{E}_t$) .

若把所有随机性拿掉 (R_{t+1} 与 c_{t+1} 确定), 上式退化为确定性 Euler 方程 $u'(c_t) = \beta R u'(c_{t+1})$, 正是上一章的结论。随机化做的事仅有一件: 在明天那一侧罩上 $\mathbb{E}_t$ 。但这个“仅有一件”改变深远——因为期望里 R_{t+1} 与 $u'(c_{t+1})$ 同时随机、还可能相关, $\mathbb{E}_t[R_{t+1} u'(c_{t+1})] \neq \mathbb{E}_t[R_{t+1}] \cdot \mathbb{E}_t[u'(c_{t+1})]$, 那个协方差项正是下文资产风险溢价的来源。

$\mathbb{E}_t$ 是“在 t 期信息下”的条件期望, 本质上就是条件期望一章里以 σ -代数 $\mathcal{F}_t$ 为条件的 $\mathbb{E}(\cdot | \mathcal{F}_t)$; 在 Markov 设定下它退化为以当期冲击 z_t 为条件, 故写成 $\mathbb{E}(\cdot | z_t)$ 。理性预期假设说的就是: 经济主体在做决策时用的正是这个数学上“正确”的条件期望, 不多不少。

39.5 应用一: 随机增长与预防性储蓄

随机增长 (RBC 的核)。 把上面的资产换成生产性资本, 就是实际经济周期 (RBC) 模型的核心。社会计划者在状态 (k, z) (资本、生产率冲击) 下选当期消费 c 与下期资本 k' , 产出为 $zf(k)$, 资源约束 $c + k' = zf(k) + (1 - \delta)k$ 。Bellman 方程

$$V(k, z) = \max_{k'} \left\{ u(zf(k) + (1 - \delta)k - k') + \beta \mathbb{E}(V(k', z') | z) \right\},$$

其 Euler 方程为 $u'(c_t) = \beta \mathbb{E}_t[u'(c_{t+1})(z_{t+1}f'(k_{t+1}) + 1 - \delta)]$ ——这里随机毛回报就是“下期资本边际产品 + 不折旧的部分”。其策略函数 $k' = g(k, z)$ 正是图 39.1 那一族曲线: 生产率高时多积累、低时少积累, 资本与产出于是随冲击共同波动, 这便是 RBC 解释经济周期的机制。

预防性储蓄：风险本身就让人多存钱。 随机 Euler 方程还揭示了一个确定性世界里根本不存在的动机。比较两个消费者，面对相同的期望未来收入，但一个未来确定、另一个未来有风险。确定性 Euler 方程只关心 $u'(c_{t+1})$ ；而随机版本关心 $\mathbb{E}_t[u'(c_{t+1})]$ 。关键在于边际效用 u' 的形状：对常见效用（如 CRRA）， u' 是凸函数 ($u''' > 0$)。由 Jensen 不等式，对凸函数取期望大于在期望处取值：

$$\mathbb{E}_t[u'(c_{t+1})] > u'(\mathbb{E}_t[c_{t+1}]) \quad (\text{当 } u''' > 0).$$

也就是说，在期望消费相同的前提下，消费的不确定性抬高了期望边际效用。而 Euler 方程要求 $u'(c_t) = \beta R \mathbb{E}_t[u'(c_{t+1})]$ ，右边被风险抬高，要重新相等，左边 $u'(c_t)$ 也得抬高，即今天 c_t 要降低——消费者主动压低今天的消费、多存一点，以缓冲未来的风险。这就是**预防性储蓄** (precautionary saving)，其源头精确地是边际效用的凸性 $u''' > 0$ (图 39.4)。




图 39.4: 预防性储蓄的来源。边际效用 u' 凸时 ($u''' > 0$)，消费 c_L, c_H 的期望边际效用（红弦中点）高于在期望消费 $\bar{c}$ 处的边际效用（蓝点），即 $\mathbb{E}(u'(c')) > u'(\mathbb{E}(c'))$ 。风险抬高期望边际效用，迫使今天少消费、多储蓄。

注（二次效用为何“看不见”预防性储蓄）。

若 u 取二次型，则 u' 是线性的、 $u''' = 0$ ，Jensen 不等式退化成等号， $\mathbb{E}_t[u'(c_{t+1})] = u'(\mathbb{E}_t[c_{t+1}])$ ——风险被边际效用“漏掉”，预防性储蓄消失，模型回到“确定性等价”（只看期望、不看方差）。这正是早期用二次效用得到的随机游走消费假说看不到预防性动机的原因。要让风险真正影响储蓄，必须让边际效用弯曲 ($u''' > 0$)，这也是为何不完全市场宏观（下一应用）几乎都用 CRRA 而非二次效用。

通向不完全市场 (Aiyagari)。 预防性储蓄是不完全市场宏观模型的发动机。在 Aiyagari 型经济里，大量异质个体各自面对不可保险的收入冲击 z ，只能靠存一种无风险资产自我保险，每个人解的都是上面那个带 $\mathbb{E}_t$ 的消费-储蓄问题。预防性动机使他们持有正的缓冲储蓄，加总起来就是整个经济的资本供给——它取决于收入风险的大小，于是“风险”这个微观变量经由预防性储蓄，定量地决定了宏观的利率与财富分布。这类

模型的求解，本质上就是对每个个体跑本章的随机值迭代、再加一个总量市场出清，正是下一节“递归竞争均衡”的内容。

39.6 应用二：递归竞争均衡

到目前为止我们解的都是单个决策者的问题。把许多这样的决策者放进一个市场、让价格内生地把他们的选择协调到出清，就得到**均衡**。递归方法的威力在于：均衡本身也能写成递归的——这就是**递归竞争均衡**（recursive competitive equilibrium, RCE），现代宏观刻画动态经济的标准语言。

它的关键设计是把“个体状态”与“总体状态”分开。每个人有自己的内生状态（如个人资产 x ），但他做最优决策时还需要知道决定价格的总体状态——通常是外生冲击 z ，以及（在异质个体模型里）整个经济的财富分布 μ 。于是个体的 Bellman 方程里，价格被写成总体状态的函数，个体把它当作给定：

定义 39.6: 递归竞争均衡（要素）

一个 RCE 由以下对象构成，使彼此自洽：

- **价格函数** $p(z, \mu)$ ：把总体状态映成市场价格（利率、工资等）。
- **个体值函数与策略** $V(x; z, \mu)$ 、 $g(x; z, \mu)$ ：在给定价格函数下，解个体的随机 Bellman 方程

$$V(x; z, \mu) = \max_a \left\{ u(x, a; p(z, \mu)) + \beta \mathbb{E}(V(x'; z', \mu') | z) \right\}.$$

- **分布的演化律** $\mu' = \Phi(\mu, z, z')$ ：由所有个体的策略 g 与冲击实现，按“加总后的转移”把今天的分布推到明天。
- **市场出清**：在每个总体状态 (z, μ) 下，由 g 加总出的总需求与总供给相等，这正是 $p(z, \mu)$ 被定下来的条件。

RCE = “个体递归优化”与“总体一致性”的不动点

RCE 把均衡问题拆成两层，每层都是一个不动点：个体层给定价格函数解随机 Bellman 方程（一个值函数不动点，由本章前几节保证存在唯一）；总体层要求由个体最优策略加总出的价格，恰好就是个体当初拿来优化的那个价格函数（一个“预期自我实现”的不动点）。整个模型因此是“不动点套不动点”。这层结构正是它被数值求解的原因：外层迭代价格函数、内层值迭代解个体问题，交替直至两层都收敛。

在代表性个体模型（如基准 RBC）里，分布 μ 退化成一个点（人人相同），总体状态就只剩冲击 z ，RCE 大大简化——个体问题与社会计划者问题甚至常常重合（福利定理）。一旦个体异质且市场不完全（Aiyagari、以及带总量冲击的 Krusell-Smith），分布 μ 真正变成一个“无穷维状态”，如何在递归框架里处理它，是计算宏观的一大主

题。

39.7 应用三：资产定价与随机贴现因子

随机 Euler 方程换一副眼镜看，就是整个资产定价理论。前面那条消费-储蓄 Euler 方程 $\mathbb{E}_t[m_{t+1}R_{t+1}] = 1$ 里反复出现的“主观折现 $\times$ 边际效用比”

$$m_{t+1} = \beta \frac{u'(c_{t+1})}{u'(c_t)},$$

值得被单独命名：

定义 39.7: 随机贴现因子

随机贴现因子 (stochastic discount factor, SDF)，又称定价核，是随机变量

$$m_{t+1} := \beta \frac{u'(c_{t+1})}{u'(c_t)}.$$

它把“下一期、某个状态下的一块钱”折算成“今天的价值”，且这个折算率随未来状态（经消费）而变——故曰“随机”。

有了 m ，任何资产的定价被压缩成一行。对毛回报为 R_{t+1}^i 的资产 i ，随机 Euler 方程即

定理 39.8: 资产定价基本方程

任何资产 i 的毛回报 R_{t+1}^i 满足

$$\boxed{\mathbb{E}_t[m_{t+1} R_{t+1}^i] = 1}, \quad m_{t+1} = \beta \frac{u'(c_{t+1})}{u'(c_t)}.$$

等价地，资产的当期价格 p_t 等于其未来支付 x_{t+1} 的“ m -加权期望” $p_t = \mathbb{E}_t[m_{t+1}x_{t+1}]$ 。

一条式子、一个 m ，给所有资产定价——这是金融经济学的中心结论之一。它的力量在于“同一个 m ”：无论股票、债券还是期权，折现用的是同一个由消费决定的核 m_{t+1} ，资产之间的差别全在它们的支付 R_{t+1}^i 上。下面两个推论把它翻译成更熟悉的语言。

无风险利率与风险溢价。 对无风险资产 R_{t+1}^f (t 期已知)， $\mathbb{E}_t[m_{t+1}R_{t+1}^f] = 1$ 给出 $R_t^f = 1/\mathbb{E}_t[m_{t+1}]$ 。对一般风险资产，用 $\mathbb{E}_t[mR^i] = \mathbb{E}_t[m]\mathbb{E}_t[R^i] + \text{Cov}(m, R^i)$ (条件协方差，下标省略) 展开 $\mathbb{E}_t[mR^i] = 1$ ，再代入 $R^f = 1/\mathbb{E}_t[m]$ ，整理得

$$\mathbb{E}_t[R_{t+1}^i] - R_t^f = -R_t^f \text{Cov}(m_{t+1}, R_{t+1}^i).$$

这就是**风险溢价**的来源：一个资产要求多高的超额回报，取决于它的回报与定价核 m （即边际效用）怎么共动。 m 在消费低（边际效用高）时大；若某资产恰在那种“经济差”的时候回报也低（ $\text{Cov}(m, R^i) < 0$ ），它在你最需要钱时掉链子，故须用正的风险溢价补偿。反之，能在坏时候发钱的资产（保险性）允许负溢价。风险的价钱，量的是与边际效用的协方差，不是回报自身的方差——这是消费基础资产定价对“风险”的根本重新定义。

消费 CAPM。 进一步把 m 线性化（或取 CRRA 效用 $u'(c) = c^{-\gamma}$ ，则 $m_{t+1} = \beta(c_{t+1}/c_t)^{-\gamma}$ ），上式化为：资产的风险溢价正比于其回报与消费增长的协方差，比例系数是相对风险厌恶 γ 。这就是**消费资本资产定价模型**（Consumption CAPM）——它把经典 CAPM 里那个“市场组合”替换成了“总消费”，断言真正不可分散、必须被定价的风险，是与总消费同涨落的那部分。

资产定价 = 随机 Euler 方程换个名字

不要把资产定价当成独立的一套理论。它就是消费者跨期最优的一阶条件——随机 Euler 方程——的重新包装：把“主观折现 $\times$ 边际效用比”命名为定价核 m ，那条人人都在满足的最优条件 $\mathbb{E}_t[mR] = 1$ 立刻成了给一切资产定价的万能公式。这正是本书反复强调的“一具工具、多扇门”：同一个随机 Euler 方程，在宏观那一侧解释消费与储蓄，在金融这一侧就成了资产定价的地基。

注（ $\mathbb{E}_t[mR] = 1$ 直接就是一族矩条件——通向 GMM）。

资产定价基本方程在计量上是一座金矿。对任意 t 期已知的工具变量 w_t ，由全期望（塔性质）有 $\mathbb{E}((m_{t+1}R_{t+1}^i - 1)w_t) = 0$ ——这是一组矩条件，其中 $m_{t+1} = \beta(c_{t+1}/c_t)^{-\gamma}$ 含未知参数 (β, γ) 。用样本矩去匹配这些总体矩、求出 (β, γ) ，正是**广义矩估计**（GMM）的经典发源地（Hansen-Singleton）。换言之，理论给的 Euler 方程直接就是估计方程，不需要先解出整个模型——这条捷径是结构计量偏爱 Euler 方程的根本原因。GMM 作为极值估计统一框架的一员，其相合性与渐近正态见后文“极值估计”一章。

39.8 它通向何处

本章把递归方法从确定性世界推进到了不确定性世界，而代价之小（只多一个非扩张的期望算子）几乎令人意外。它的去处铺满了现代经济学的实证与理论前沿：

- **数值宏观**：随机值迭代、策略迭代，加上对连续状态的离散化或插值，是求解几乎一切动态随机模型的主力算法；本章的收敛理论就是它们能用的保证。
- **不完全市场与异质个体宏观**：从 Aiyagari 的预防性储蓄到 Krusell-Smith 的总量冲击，再到当下的 HANK（异质个体新凯恩斯），核心都是“大量个体各解一个随机 DP + 总体出清”的递归竞争均衡。
- **资产定价**：消费 CAPM、长期风险、灾难风险等模型，全部围绕同一个 $\mathbb{E}_t[mR] = 1$ 展开，区别只在如何刻画定价核 m 与消费过程。

- **动态结构估计**：从随机 Euler 方程读出矩条件交给 GMM (Hansen-Singleton)，或用嵌套不动点 (Rust) 直接估计离散选择的动态规划——结构计量的两大路线都以本章的递归问题为被估对象。这些估计量的大样本性质，统归后文**极值估计**一章的旗下。

把这一章和前一章并看，会看到一条清爽的逻辑线：压缩映射保证了 Bellman 算子有唯一不动点（第十二章），确定性 DP 据此把无限期最优化压缩成一个递归方程（上一章），而本章只是往“看向未来”那一步里塞进一个条件期望——一个碰巧不放大距离的算子——整套理论便毫发无伤地延拓到了随机世界。不确定性是现代经济学绕不开的底色，而递归方法正是驯服它的通用语言。

第八部分

随机过程

第四十章 Markov 链：平稳分布与遍历性

用到的前置工具：转移矩阵作为线性映射、矩阵幂与对角化、特征值 1 的左特征向量（特征值与对角化一章，线性代数部分）；条件概率与条件期望（概率与测度部分）；依概率收敛、几乎必然收敛与大数定律（渐近统计部分）；Perron–Frobenius 直觉（非负矩阵的主特征值，可借特征值一章）。

经济学里很多随机模型，状态空间是离散的、时间是一格一格走的，而且“下一步去哪”只取决于“此刻在哪”——就业还是失业、繁荣还是衰退、违约还是正常。这类过程的骨架就是 Markov 链：一台只看当前状态、按固定概率随机跳转的机器。它简单到可以完全写进一个矩阵里，却足以撑起一大片现代经济学——劳动市场的就业流转、商业周期的状态切换、随机增长、财富分布动态（Aiyagari）、贝叶斯计算里的 MCMC，乃至 Google 给网页排序的 PageRank，骨子里都是同一台机器在转。

本章的主线是两个长期问题。其一：让这台机器空转很久，它最终停在哪儿？答案是**平稳分布**——一个被转移矩阵原样保持的概率分布，正是“长期均衡分布”的数学形态。其二：我能不能只靠观测一条足够长的样本路径，就把这个长期分布估出来？答案是**遍历定理**——在适当条件下“时间平均等于空间平均”，这是时间序列版的大数定律、也是几乎所有动态计量推断默默依赖的前提。沿途我们会看到，这两个问题最终都化成线性代数里的一道特征值问题：平稳分布是转移矩阵特征值 1 的左特征向量，收敛快慢由第二特征值的模主宰。这正兑现了特征值一章末尾埋下的那句预告。

40.1 Markov 性：只记得现在

先把“无记忆”这件直觉的事钉成定义。设有一个取值于离散状态空间 $S = \{1, 2, \dots, m\}$ 的随机过程 $\{X_t\}_{t \geq 0}$ ， X_t 表示 t 时刻系统所处的状态。

定义 40.1: Markov 性与 (时齐) Markov 链

随机过程 $\{X_t\}$ 称为一条 **Markov 链**，若对一切 t 与一切状态序列，都有

$$\mathbb{P}(X_{t+1} = j | X_t = i, X_{t-1} = i_{t-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{t+1} = j | X_t = i).$$

即给定当前状态 X_t ，未来 X_{t+1} 与过去的历史条件独立。若右端这个一步转移概率还不依赖时间 t ，记

$$P_{ij} = \mathbb{P}(X_{t+1} = j | X_t = i),$$

则称该链是**时齐的** (time-homogeneous)。本章只讨论时齐链。

定义里那条等式，常被读成一句口诀：在已知现在的条件下，未来与过去无关。它不是说“过去无关紧要”，而是说过去的全部相关信息，已经被“当前状态”这一个量打包压缩干净了——只要你知道今天的状态，昨天怎么走到这里的，对预测明天不再添加任何信息。这正是 Markov 性的全部内容，也是它好用的根源：一个本可能极其复杂的历史依赖，被压成了“当前在哪”这一个充分统计量。

注 (Markov 性是一种“状态设计”)。

一个过程是不是 Markov，往往取决于你把“状态”定义成什么。原始变量若有记忆（比如今天的产出依赖过去两期），它本身不是一阶 Markov；但只要把状态扩维——令 $\tilde{X}_t = (Y_t, Y_{t-1})$ ——扩维后的过程通常就重获 Markov 性。这一招在宏观里无处不在：把“够用的历史”塞进状态向量，让递归方法（Bellman 方程、随机动态规划）得以施展。Markov 性与其说是世界的性质，不如说是一种建模选择：选对状态，复杂的历史依赖就坍缩成“只看现在”。

40.2 转移矩阵：把一条链装进一个矩阵

把所有一步转移概率 P_{ij} 码成一个 $m \times m$ 的方阵，就得到整条链的全部信息。

定义 40.2: 转移矩阵

时齐 Markov 链的**转移矩阵**是 $\mathbf{P} = [P_{ij}]_{m \times m}$ ，其中 $P_{ij} = \mathbb{P}(X_{t+1} = j | X_t = i)$ 是“从 i 到 j ”的一步概率。它是一个**随机矩阵** (stochastic matrix)：

$$P_{ij} \geq 0 \quad \text{对一切 } i, j; \quad \sum_{j=1}^m P_{ij} = 1 \quad \text{对一切 } i.$$

即每个元素非负、每一行加起来等于 1（从 i 出发，下一步总要落在某个状态）。

记号约定：本书把状态分布写成行向量、转移概率从行指标流向列指标（ P_{ij} 是 $i \rightarrow j$ ），于是分布的演化是“行向量右乘矩阵” $\mu \mapsto \mu \mathbf{P}$ 。这与计量、宏观文献的主流一致；少数书把分布写成列向量、用 $\mathbf{P}^T$ 作用，结论一样，只是左右乘的差别。

分布如何演化。 设 t 时刻系统状态的概率分布是行向量 $\mu_t = [\mu_t(1), \dots, \mu_t(m)]$, $\mu_t(i) = \mathbb{P}(X_t = i)$ 。由全概率公式, 下一期落在 j 的概率是

$$\mu_{t+1}(j) = \sum_i \mathbb{P}(X_t = i) \mathbb{P}(X_{t+1} = j | X_t = i) = \sum_i \mu_t(i) P_{ij}.$$

这恰是行向量乘矩阵的第 j 个分量。于是分布的演化律干净利落:

$$\mu_{t+1} = \mu_t \mathbf{P}.$$

这就是 Markov 链最实用的一句话——往前推一期, 就是右乘一次 $\mathbf{P}$ 。整条链的动力学, 被压缩成了一次矩阵乘法。




图 40.1: 两状态就业链的转移图。结点是状态, 有向箭头标注一步转移概率: 在业者以概率 s 失业、 $1-s$ 留任; 失业者以概率 f 找到工作、 $1-f$ 继续失业。从每个结点流出的概率之和为 1 (转移矩阵每行加总为 1)。

例 (两状态就业链) .

最经典的劳动市场玩具模型只有两个状态: 就业 E 与失业 U (图 40.1)。每期在业者以概率 s (分手率) 变为失业, 失业者以概率 f (找工率) 变为就业。写出转移矩阵, 并把状态排列为 (E, U) 。

解.

从 E 出发: 留在 E 的概率是 $1-s$, 去 U 的概率是 s ; 从 U 出发: 去 E 的概率是 f , 留在 U 的概率是 $1-f$ 。于是

$$\mathbf{P} = \begin{bmatrix} 1-s & s \\ f & 1-f \end{bmatrix}.$$

每一行加起来都是 1, 确是随机矩阵。这个 2×2 的小矩阵, 后面会一路陪我们走到平稳分布与遍历性——它的平稳分布将给出长期失业率。

40.3 n 步转移与 Chapman–Kolmogorov: 矩阵幂

一步转移已被 $\mathbf{P}$ 装好, 那 “ n 步之后从 i 到 j ” 的概率呢? 记

$$P_{ij}^{(n)} = \mathbb{P}(X_{t+n} = j | X_t = i).$$

把中途某个时点 k ($0 < k < n$) 的落脚状态拆出来，按全概率公式对它求和，再用 Markov 性把“前 k 步”与“后 $n-k$ 步”解耦：

定理 40.3: Chapman–Kolmogorov 方程

对任意 $0 < k < n$ 与任意状态 i, j ,

$$P_{ij}^{(n)} = \sum_{\ell \in S} P_{i\ell}^{(k)} P_{\ell j}^{(n-k)}.$$

写成矩阵就是 $\mathbf{P}^{(n)} = \mathbf{P}^{(k)} \mathbf{P}^{(n-k)}$ ；特别地， n 步转移矩阵就是一步转移矩阵的 n 次幂：

$$\boxed{\mathbf{P}^{(n)} = \mathbf{P}^n}.$$

证明. 分两步看。固定起点 i 、终点 j ，把第 k 期所处的中间状态 ℓ 拆出来：

$$\mathbb{P}(X_{t+n} = j | X_t = i) = \sum_{\ell} \mathbb{P}(X_{t+n} = j, X_{t+k} = \ell | X_t = i).$$

对联合事件用乘法公式、再用 Markov 性（给定 $X_{t+k} = \ell$ ，后段与起点 i 无关），且时齐性把“从 ℓ 再走 $n-k$ 步”写成 $P_{\ell j}^{(n-k)}$ ：

$$= \sum_{\ell} \underbrace{\mathbb{P}(X_{t+k} = \ell | X_t = i)}_{P_{i\ell}^{(k)}} \underbrace{\mathbb{P}(X_{t+n} = j | X_{t+k} = \ell)}_{P_{\ell j}^{(n-k)}} = \sum_{\ell} P_{i\ell}^{(k)} P_{\ell j}^{(n-k)}.$$

右端正是矩阵乘积 $\mathbf{P}^{(k)} \mathbf{P}^{(n-k)}$ 的 (i, j) 元。取 $k=1$ 归纳即得 $\mathbf{P}^{(n)} = \mathbf{P}^n$ 。□

这条结论把一个看似要追踪所有中间路径的概率问题，彻底交给了线性代数： n 步转移就是把转移矩阵自乘 n 次。而矩阵幂正是对角化最直接的红利（特征值一章）。若 $\mathbf{P}$ 可对角化为 $\mathbf{P} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^{-1}$ ($\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_m)$ 为特征值)，则

$$\mathbf{P}^n = \mathbf{V} \mathbf{\Lambda}^n \mathbf{V}^{-1}, \quad \mathbf{\Lambda}^n = \text{diag}(\lambda_1^n, \dots, \lambda_m^n).$$

长期行为 $n \rightarrow \infty$ 于是完全由特征值的幂主宰——这正是平稳分布与收敛速率的来源，下面就兑现。

长期行为 = 最大特征值的天下

随机矩阵 $\mathbf{P}$ 的特征值都满足 $|\lambda| \leq 1$ （每行加总为 1 决定了 $\mathbf{P}\mathbf{1} = \mathbf{1}$ ，故 1 必是特征值；Perron–Frobenius 进一步保证它是模最大的那个）。当链不可约且非周期时，1 是唯一模长等于 1 的特征值，于是 $\mathbf{P}^n$ 中除 $\lambda_1 = 1$ 对应的那一项外，其余模长严格小于 1 的 $\lambda_i^n \rightarrow 0$ （可约或周期链另有别的模 1 特征值——如周期 2 链的 $\lambda = -1$ ——其幂并不衰减，留待后面两节处理）。留下来主宰长期分布的，正是特征值 1 对应的特征向量；衰减最慢的那一项 $|\lambda_2|^n$ 则决定收敛有多快。把“链停在哪”与“停得多快”两个问题，化成了第一、第二特征值。

40.4 状态分类：常返、暂留与周期

并非每条链都会安顿到一个长期分布。决定命运的，是状态之间“能不能互相到达”以及“回访的节律”。先厘清几个分类概念，它们恰是后面遍历定理两个条件的来源。

定义 40.4: 可达、互通、不可约

状态 j 可达于 i (记 $i \rightarrow j$)，若存在某个 $n \geq 0$ 使 $P_{ij}^{(n)} > 0$ (从 i 出发有正概率在若干步后到 j)。若 $i \rightarrow j$ 且 $j \rightarrow i$ ，称 i, j 互通。若链中任意两个状态都互通，称该链不可约 (irreducible) —— 整个状态空间连成一块，没有“出去就回不来”的死角。

定义 40.5: 常返与暂留

从状态 i 出发，记首次返回 i 的概率为 $f_i = \mathbb{P}(\exists n \geq 1: X_n = i | X_0 = i)$ 。若 $f_i = 1$ ，称 i 常返 (recurrent) —— 迟早必定回来，从而被访问无穷多次；若 $f_i < 1$ ，称 i 暂留 (transient) —— 有正概率一去不返，长期看只被访问有限次。进一步，若常返且平均返回时间 $\mathbb{E}(T_i) < \infty$ ，称正常返 (positive recurrent)。

定义 40.6: 周期

状态 i 的周期是 $d(i) = \gcd \{n \geq 1: P_{ii}^{(n)} > 0\}$ ，即所有能回到 i 的步数的最大公约数。若 $d(i) = 1$ ，称 i 非周期 (aperiodic)；若 $d(i) > 1$ ，则回访只能发生在 $d(i)$ 的整数倍步，链的分布会在几组状态间周期性摆动而不收敛。

这三组概念各管一件事，缺一不可，下面的图给出一眼可辨的对照：不可约管“连不连通”，正常返管“回不回得来、回得快不快”，非周期管“回访有没有固定节拍”。

注（周期的典型与破除）。

取两状态链 $\mathbf{P} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ ：从 1 出发只能第 2, 4, 6, ... 步回到 1，周期 $d = 2$ 。分布 $(1, 0)$ 与 $(0, 1)$ 永远交替、绝不收敛——它有唯一平稳分布 $(\frac{1}{2}, \frac{1}{2})$ ，却收敛不上去。破除周期极其廉价：只要任一状态有正的自环 $P_{ii} > 0$ (比如经济里“有概率维持原状”几乎总成立)，gcd 里就混进了 1，整条不可约链立刻非周期。这解释了为何现实经济模型几乎从不真遇上周期病。

有限状态链的一条便利事实

在有限状态空间上，不可约 $\Rightarrow$ 所有状态都是正常返的（链跑不出去，又必然无穷次回访每个状态，平均返回时间自动有限）。于是对有限链，遍历性所需的条件浓缩成两句话：不可约 + 非周期。本章后面的主结论默认在有限状态上陈述，正是吃了这条便利；可数无穷或连续状态空间还需单独要求正常返（如收入、财富取值连续时）。




图 40.2: 状态分类对照。左：状态 3 只流出、流不回，是暂留态， $\{1, 2\}$ 构成一个“出不去”的吸收性闭集，全链可约。右：三个状态两两可达（不可约），且状态 1 带自环（有正概率原地停留），打破了纯三角环的周期性——这正是遍历定理要求的“不可约 + 非周期”。

40.5 平稳分布：被转移矩阵原样保持的分布

现在回到主问题。若分布 μ_t 演化到某一刻不再改变，这个分布就是链的“长期均衡”。

定义 40.7: 平稳分布

概率行向量 $\pi = [\pi_1, \dots, \pi_m]$ ($\pi_i \geq 0, \sum_i \pi_i = 1$) 称为链的**平稳分布** (stationary distribution)，若它被一步转移原样保持：

$$\pi \mathbf{P} = \pi, \quad \text{即} \quad \pi_j = \sum_i \pi_i P_{ij} \quad \text{对一切 } j.$$

等价地， π 是不动点：若 $\mu_t = \pi$ ，则 $\mu_{t+1} = \pi \mathbf{P} = \pi$ ，此后永远停在 π 。

这个定义把“长期均衡”说成了一个再清楚不过的代数条件，而它正是线性代数里的老熟人。把 $\pi \mathbf{P} = \pi$ 看作 $\pi(\mathbf{P} - \mathbf{I}) = \mathbf{0}$ ，它说的恰是：

平稳分布 = 转移矩阵特征值 1 的左特征向量

$\pi \mathbf{P} = \pi$ 意味着 π 是 $\mathbf{P}$ 关于特征值 $\lambda = 1$ 的左特征向量（再归一化为概率向量）。而 $\lambda = 1$ 一定是 $\mathbf{P}$ 的特征值——因为每行加总为 1 等价于 $\mathbf{P}\mathbf{1} = \mathbf{1}$ ($\mathbf{1}$ 是全 1 列向量)，即 1 是 $\mathbf{P}$ 的右特征值；左、右特征值集合相同，故 1 也是左特征值，对应的左特征向量就是 π 。求平稳分布 = 解一道特征值 1 的（左）特征向量问题。这把“长期均衡分布”彻底接进了特征值与对角化一章的对角化机器。

定理 40.8: 平稳分布的存在与唯一（有限链）

有限状态、不可约的 Markov 链存在唯一的平稳分布 π ，且 $\pi_i > 0$ 对一切 i 。

直觉. 存在性：随机矩阵 $\mathbf{P}\mathbf{1} = \mathbf{1}$ 保证 1 是特征值，相应必有左特征向量；Perron–Frobenius 定理（应用于非负、不可约矩阵）进一步保证该特征向量可取成各分量同号，归一化后即得一个概率向量 π ，且 $\pi_i > 0$ 。唯一性：不可约使主特征值 1 单重（几何重

数为 1)，故特征值 1 的特征向量空间一维，归一化后的概率向量唯一。把这条与有限链的“不可约 $\Rightarrow$ 正常返”合起来，还可给出概率意义上的显式公式 $\pi_i = 1/\mathbb{E}(T_i)$ ($\mathbb{E}(T_i)$ 为从 i 出发的平均返回时间)：长期停在某状态的比例，等于回访它的平均间隔的倒数。严格的 Perron–Frobenius 构造属纯线性代数，这里只取其结论与直觉。□

注（注意：平稳 $\neq$ 收敛）。

不可约只保证平稳分布存在且唯一，并不保证从任意初始分布出发都会收敛到它。上一节那条周期 2 的链是反例：它有唯一的 $\pi = (\frac{1}{2}, \frac{1}{2})$ ，但 $(1, 0)$ 出发的分布永远在 $(1, 0), (0, 1)$ 间跳，到不了 π 。要让“从哪儿出发都收敛过去”，还得补上非周期——这正是下一节遍历定理的内容。代数上看，周期会让 $\mathbf{P}$ 有别的模长为 1 的特征值（如 $\lambda = -1$ ），它们的幂不衰减、持续制造振荡。

例（两状态就业链的平稳分布 = 长期失业率）。

续图 40.1 的就业链 $\mathbf{P} = \begin{bmatrix} 1-s & s \\ f & 1-f \end{bmatrix}$ ($0 < s, f < 1$)。求平稳分布，并解读其经济含义。

解。

解 $\pi\mathbf{P} = \pi$ ，即 (π_E, π_U) 满足

$$\pi_E = (1-s)\pi_E + f\pi_U, \quad \pi_U = s\pi_E + (1-f)\pi_U.$$

两式等价（这是 $\pi(\mathbf{P} - \mathbf{I}) = \mathbf{0}$ 的两行必线性相关），取第一式得 $s\pi_E = f\pi_U$ ，配上归一化 $\pi_E + \pi_U = 1$ ：

$$\pi_U = \frac{s}{s+f}, \quad \pi_E = \frac{f}{s+f}.$$

$\pi_U = \frac{s}{s+f}$ 就是长期失业率——一个只由分手率 s 与找工率 f 决定的简洁比值。它正是劳动经济学里 Shimer 等人讨论的失业率稳态公式：分手越频繁 ($s \uparrow$) 失业率越高，找工越快 ($f \uparrow$) 失业率越低。注意这个长期值与初始就业状态无关——无论经济从充分就业还是大萧条出发，只要 s, f 不变，失业率终将收敛到同一个 $s/(s+f)$ 。这条“初值无关”正是下一节遍历性的预演。

40.6 遍历定理：收敛、且时间平均 = 空间平均

把前面的线索收束成本章的中心结论。“不可约”让长期均衡存在且唯一，“非周期”再排除掉周期性振荡——两者合起来，链就真正“忘掉初始条件”、收敛到那个唯一的平稳分布。

定理 40.9: 遍历定理 (有限状态)

设 $\{X_t\}$ 是有限状态、不可约且非周期的 Markov 链，平稳分布为 π 。则：

1. 分布收敛 (混合)：对任意初始分布 μ_0 ,

$$\mu_0 \mathbf{P}^n \xrightarrow{n \rightarrow \infty} \pi, \quad \text{即 } P_{ij}^{(n)} \rightarrow \pi_j \text{ 对一切 } i, j.$$

2. 时间平均收敛 (遍历)：对任意有界函数 $g: S \rightarrow \mathbb{R}$ ，以概率 1 (不论初始状态)，

$$\frac{1}{n} \sum_{t=1}^n g(X_t) \xrightarrow{\text{a.s.}} \sum_{i \in S} \pi_i g(i) = \mathbb{E}_{\pi}(g(X)).$$

第一部分是“空间”层面的收敛：让链空转足够久，不论从哪个状态出发， n 步后落在 j 的概率都趋于同一个 π_j 。 $\mathbf{P}^n$ 的每一行都趋于同一个行向量 π ——初始条件被彻底冲刷干净。它的代数机理上一节已点透：可对角化下 $\mathbf{P}^n = \sum_k \lambda_k^n (\cdots)$ ，唯一模长为 1 的特征值 $\lambda_1 = 1$ 的项存活、贡献出 π ，其余 $|\lambda_k| < 1$ 的项（非周期保证了再无别的模 1 特征值）以 $|\lambda_k|^n$ 的速率消失。第二大特征值的模 $|\lambda_2|$ 因而主宰收敛的快慢——它是那个**收敛因子**： $|\lambda_2|$ 越小，误差衰减越快、越早忘掉初始条件； $|\lambda_2|$ 越接近 1 则混得越慢。真正与收敛速率成正比的是它的补 $1 - |\lambda_2|$ ，下一段的谱隙。

注 (谱隙与混合时间)。

$1 - |\lambda_2|$ 称为谱隙 (spectral gap)。收敛误差大致按 $|\lambda_2|^n$ 衰减，故达到给定精度所需步数 (混合时间) 约正比于 $1/(1 - |\lambda_2|)$ 。这在 MCMC 里是性命攸关的量：谱隙大则采样器“混得快”、少量样本就近似独立于初值；谱隙小则链在状态空间里挪得慢，需要极长的 burn-in。设计一个好的 MCMC 采样器，本质就是把第二特征值往零里压。

第二部分才是经济计量真正吃重的那一半——它是**时间序列版的大数定律**。普通大数定律要求样本独立同分布；可一条 Markov 链的相邻取值显然相关 (X_{t+1} 依赖 X_t)。遍历定理告诉我们：只要链不可约、(正)常返，相依不要紧——沿单一一条样本路径做时间平均 $\frac{1}{n} \sum_t g(X_t)$ ，照样收敛到按平稳分布算的“空间平均” $\mathbb{E}_{\pi}(g(X))$ 。

遍历性：一条长路径 = 一整个总体

独立同分布下，大数定律让我们用“横截面的多个个体”逼近总体期望。可时间序列里我们往往只有一条历史轨迹（一个国家的 GDP 序列、一只股票的回报），样本点之间还彼此相关。遍历性正是这种处境的救命稻草：它许诺一条足够长的样本路径，能像反复独立抽样那样，把整个平稳分布“跑遍”一遍。于是“时间平均 = 空间平均”——用历史均值估长期均值、用样本自相关估总体自相关，都因此有了根据。几乎所有时间序列计量（平稳性、一致性、 $\sqrt{n}$ -渐近正态）默认的“遍历平稳”前提，源头就在这里；它也是蒙特卡洛与 MCMC 能用样本均值近似积分的理论保证。

第一部分（分布收敛）需要非周期，否则分布会周期振荡；但第二部分（时间平均）只需不可约 + 正常返、不要求非周期——哪怕分布在两组状态间永远跳，长程的时间平均仍把两组按 π 的比例正确加权。计量里“遍历”一词通常指的就是第二部分这种时间平均的收敛。

40.7 细致平衡：可逆链与一个验证平稳的捷径

求平稳分布要解线性方程组 $\pi \mathbf{P} = \pi$ ；状态一多就麻烦。有一类特殊的链，存在一条几乎免算的捷径——也正是这类链撑起了 MCMC。

定义 40.10: 细致平衡与可逆链

若概率向量 π 与转移矩阵 $\mathbf{P}$ 满足细致平衡条件 (detailed balance)

$$\pi_i P_{ij} = \pi_j P_{ji} \quad \text{对一切 } i, j,$$

则称该链关于 π 是可逆的 (reversible)。

细致平衡有一个透明的概率解读：把 $\pi_i P_{ij}$ 看作平稳态下“单位时间里从 i 流向 j 的概率质量”。条件说的是——每一对状态之间，正向流量恰好等于反向流量，逐边两两抵消（图 40.3）。这比平稳分布的要求强：平稳只需每个结点的总流入等于总流出（全局平衡），可逆则要求每条边上双向流量分别相等（局部平衡）。强条件自然蕴含弱条件：

命题 40.11: 细致平衡 $\Rightarrow$ 平稳

若 π 与 $\mathbf{P}$ 满足细致平衡 $\pi_i P_{ij} = \pi_j P_{ji}$ ，则 π 是平稳分布，即 $\pi \mathbf{P} = \pi$ 。

证明. 逐分量验证 $\pi \mathbf{P} = \pi$ 的第 j 个分量。把细致平衡代入再用 $\mathbf{P}$ 的行和为 1：

$$(\pi \mathbf{P})_j = \sum_i \pi_i P_{ij} \stackrel{\text{细致平衡}}{=} \sum_i \pi_j P_{ji} = \pi_j \sum_i P_{ji} = \pi_j \cdot 1 = \pi_j.$$

对每个 j 成立，故 $\pi \mathbf{P} = \pi$ 。 □

这条命题的妙处在于把“验证平稳”从“解方程组”降级为“逐边核对一个对称等式”。在很多模型里，人们先猜一个 π 、再核对细致平衡——成立就立刻断定它平稳，完全绕开了 $\pi \mathbf{P} = \pi$ 的联立求解。

例（出生-死亡链的平稳分布）。

设状态为 $\{0, 1, \dots, m\}$ （如某产品的库存、排队人数），只能在相邻状态间移动：在 i 处以概率 a_i 上行到 $i+1$ 、以概率 b_i 下行到 $i-1$ 、其余概率原地不动。这类“生死链” (birth-death chain) 必可逆。用细致平衡求其平稳分布。

解.

两个方向的“概率流”相等： $\pi_i P_{ij} = \pi_j P_{ji}$




图 40.3: 细致平衡 (可逆链)。平稳态下, $i \rightarrow j$ 与 $j \rightarrow i$ 两个方向的概率流量逐边相等: $\pi_i P_{ij} = \pi_j P_{ji}$ 。逐边相抵自然推出每个结点总流入等于总流出, 故 π 平稳——但反之不然, 平稳并不要求逐边相等。

相邻才有转移, 细致平衡只对相邻边给出非平凡条件: $\pi_i a_i = \pi_{i+1} b_{i+1}$, 即

$$\pi_{i+1} = \pi_i \frac{a_i}{b_{i+1}}.$$

从 π_0 出发层层相乘:

$$\pi_k = \pi_0 \prod_{i=0}^{k-1} \frac{a_i}{b_{i+1}}, \quad k = 0, 1, \dots, m,$$

再由 $\sum_k \pi_k = 1$ 定出 π_0 。一条线性链上, 整个平稳分布被“逐边比值”连乘出来, 根本不必解 $m+1$ 元方程组——这正是可逆性的红利。排队论里 $M/M/1$ 队列的几何型平稳分布、随机库存模型的长期分布, 都是这个公式的实例。

细致平衡是 MCMC 的设计原理

贝叶斯计量里, 后验分布 π 往往只知道形状、算不出归一化常数, 没法直接抽样。MCMC 的思路反过来: 先有目标 π , 再去设计一条以 π 为平稳分布的链, 让它跑起来、用样本路径近似 π (遍历定理保证可行)。怎么保证设计出的链恰好平稳于 π ? 正是用细致平衡来凑: Metropolis-Hastings 的接受概率 $\min\{1, \frac{\pi_j q_{ji}}{\pi_i q_{ij}}\}$ 就是精心设计来让 $\pi_i P_{ij} = \pi_j P_{ji}$ 成立的——而且这个比值里 π 的归一化常数恰好相消, 于是“算不出归一化常数”不再是障碍。一条本章的纯理论命题, 就这样成了现代贝叶斯计算的发动机。

40.8 去处：它把哪些门连了起来

Markov 链是“离散状态 + 离散时间 + 无记忆”这一最朴素随机结构的完整理论, 它的去处铺得很广:

- **随机动态规划的冲击过程** (随机动态规划一章)。递归宏观模型里, 外生冲击 (生产率、收入) 通常被设成一条有限状态 Markov 链, 转移矩阵 $\mathbf{P}$ 进入 Bellman 方程里那个条件期望 $\mathbb{E}(V(\cdot) | \text{今日冲击})$; 连续的 AR(1) 冲击也常用 Tauchen/Rouwenhorst

方法离散成 Markov 链来求解。

- **财富与收入分布动态** (Aiyagari、Bewley 模型)。异质个体面对收入 Markov 冲击各自最优储蓄，个体策略 + 收入链共同诱导出财富的转移核；其平稳分布就是模型预测的长期**财富分布**——平稳分布在这里直接等于宏观研究的核心对象。
- **贝叶斯计算 (MCMC)**。如上所述，Gibbs 采样、Metropolis-Hastings 都是“为目标后验造一条遍历链”，靠细致平衡保平稳、靠遍历定理保样本均值收敛；谱隙决定它跑得快不快。
- **时间序列的遍历平稳前提** (大数定律、渐近统计部分)。平稳遍历是几乎所有时间序列一致性与渐近正态结果的默认底座；本章第二部分的“时间平均 = 空间平均”，正是 ARMA、GMM、动态面板能用一条历史路径做推断的根据。
- **PageRank**。Google 早期把网页间的链接结构当成一条 Markov 链（随机冲浪者），网页的重要性排名就取它的平稳分布 π ；为保证不可约非周期、平稳分布唯一，算法人为加了“以小概率随机跳到任意页”的扰动——本章的存在唯一性条件被直接拿来当工程设计准则。

一条链，一个矩阵，两个特征值，串起了宏观的冲击过程、计量的遍历推断、贝叶斯的采样算法与搜索引擎的排序。这再次印证本书的主张：认清“平稳分布是特征值 1 的左特征向量、长期收敛由第二特征值主宰”这一条线性代数事实，就同时拿到了好几扇门的钥匙。下一章的鞅会从另一个角度刻画随机过程——不是问“长期停在哪”，而是问“下一步能不能被预测”。

第四十一章 鞅

用到的前置工具：条件期望及其塔性质（“条件期望”一章，作为投影理解）；概率空间、 σ -代数与可测性（概率与测度部分）； σ -代数作为“信息”的解读与后验信念的鞅性（“贝叶斯更新与信息”一章）。

经济学里反复出现一句口头禅：“有效市场上没有免费的午餐”、“理性预期下的误差无法预测”、“公平的赌局长期下来不赚不赔”。这三句话听起来像格言，其实背后是同一个精确的数学对象——鞅（martingale）。鞅是“公平博弈”的形式化：给定到此刻为止的全部信息，下一刻的最优预测就是当前值，既不系统性地上漂、也不系统性地下沉。一旦把“不可被系统性预测”这件直觉的事钉成定义，有效市场假说、理性预期、贝叶斯学习、无套利定价就都成了同一句话的不同方言。

本章按使用者的顺序展开。先把承载“信息随时间积累”的 filtration 讲清楚（它把上一部分的 σ -代数串成一条时间线）；再用条件期望写出鞅的定义，并分出上鞅、下鞅与鞅差分序列这几个亲戚；接着给两条撑起全部应用的大定理——可选停时定理（赌徒无法靠聪明的停手策略稳赚）与鞅收敛定理（鞅在温和条件下必收敛），证明以讲清直觉为主、极重的部分只陈述；最后把工具对准它的四个去处：有效市场与风险中性定价、理性预期的预测误差、时间序列的鞅中心极限定理、以及序贯检验。读完应当能看出：鞅不是随机过程里一个孤立的技术概念，而是“信息”与“期望”这两件旧工具在时间轴上的自然合体。

41.1 信息流：filtration

要谈“随时间到来的信息”，先得让“信息”有一个随时间变化的载体。上一部分我们已经学会用一个 σ -代数 $\mathcal{F}$ 表示“此刻能分辨的事件全体”。现在把时间放进来：在每个时刻 t ，我们掌握的信息对应一个 σ -代数 $\mathcal{F}_t$ ，而“信息只增不减”——昨天知道的今天仍然知道——就要求这列 σ -代数递增。

定义 41.1: Filtration（信息流）

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间，时间指标 $t = 0, 1, 2, \dots$ （或连续 $t \geq 0$ ）。一列子 σ -代数

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \dots \subseteq \mathcal{F}$$

若满足 $s \leq t \Rightarrow \mathcal{F}_s \subseteq \mathcal{F}_t$ ，则称为一个 **filtration**（信息流）。其中 $\mathcal{F}_t$ 解读为“截止到时刻 t 所能知道的一切信息”。

最常见的 filtration 是由一个随机过程自身的历史生成的：给定过程 $\{X_t\}$ ，令

$$\mathcal{F}_t = \sigma(X_0, X_1, \dots, X_t),$$

即“观察到截止 t 的全部取值”所携带的信息，称为该过程的自然 filtration。一个过程若在每个时刻 t 都是 $\mathcal{F}_t$ -可测的（即“到 t 为止的信息足以算出 X_t ”），就说它关于这个 filtration 是**适应的**（adapted）。直觉上，适应性排除了“偷看未来”： X_t 的取值只能依赖于 t 为止已经发生的事，不能依赖明天的随机性。

filtration 把“信息一章”搬上了时间轴

上一部分讲“信息越多 $\Rightarrow$ σ -代数越细”，那是静态的两个信息结构在比精粗。filtration 不过是把这件事动态化：让信息结构沿时间 t 一格一格地变细， $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots$ 就是“学习”在数学上的样子——每过一期，划分被进一步切碎、能分辨的事件变多。鞅、停时、布朗运动全都建在这条信息流上。每当你在宏观或金融模型里看到 $\mathbb{E}(\cdot | \mathcal{F}_t)$ （“给定 t 期信息取期望”），背后就是这一条 filtration。

有了 filtration，“给定到 t 为止的信息，对未来取期望”就有了精确写法： $\mathbb{E}(Y | \mathcal{F}_t)$ 。这正是上一章条件期望的运算，只不过条件化的对象是一个随时间增长的信息流。鞅的定义，就是对这个量提一个出奇简单的要求。

41.2 鞅、上鞅、下鞅

定义 41.2: 鞅、上鞅、下鞅

设 $\{\mathcal{F}_t\}$ 为 filtration，过程 $\{X_t\}$ 关于它适应且每个 X_t 可积（ $\mathbb{E}(|X_t|) < \infty$ ）。称 $\{X_t\}$ 为

- 鞅 (martingale)，若对一切 t ， $\mathbb{E}(X_{t+1} | \mathcal{F}_t) = X_t$ ；
- 下鞅 (submartingale)，若 $\mathbb{E}(X_{t+1} | \mathcal{F}_t) \geq X_t$ ；
- 上鞅 (supermartingale)，若 $\mathbb{E}(X_{t+1} | \mathcal{F}_t) \leq X_t$ 。

定义只有一行，却要逐字咀嚼。条件 $\mathbb{E}(X_{t+1} | \mathcal{F}_t) = X_t$ 说的是：站在今天、用今天的全部信息去预测明天，最优预测恰好就是今天的值。鞅既不预期上涨、也不预期下跌——它是“公平”的精确含义。下鞅有系统性的上漂（“对你有利的博弈”，财富在期望意义下增长），上鞅则有系统性的下沉（“对你不利的博弈”）。图 41.1 把鞅画了出来：已实现的过去是一条确定的折线，而站在当前时刻 t 往后看，所有可能的未来路径在条件期望的意义上恰好围绕着水平线 X_t 展开。

注（“给定当前信息”与“给定当前值”不是一回事）。

鞅定义里条件化的是整个信息流 $\mathcal{F}_t$ （直到 t 的全部历史），不是单个当前值 X_t 。若 $\mathbb{E}(X_{t+1} | X_t) = X_t$ （只用当前值）成立但 $\mathbb{E}(X_{t+1} | \mathcal{F}_t) = X_t$ （用全部历史）不成立，那它就不是鞅。这个区别在经济学里要紧：“价格是鞅”意味着任何基于公开历史信




图 41.1: 鞅的样本路径。蓝色折线是已实现的过去（在 $\mathcal{F}_t$ 下确定）；站在当前时刻 t 向后看，未来充满随机性（几条灰色路径），但它们的条件期望恰好持平于当前值 X_t （红色水平虚线）。“下一步往哪走”无法预测，“下一步的平均位置”就是脚下——这就是公平。

息的交易策略都无法系统性获利，而不只是“不能靠当前价格预测”。Markov 性（只看当前状态）与鞅性（条件期望持平）是两条独立的性质——一个过程可以是其一而非其二。

把定义里的 X_t 移到等号一侧，鞅的“增量”有一个极有用的名字。

定义 41.3: 鞅差分序列

设 $\{X_t\}$ 是关于 $\{\mathcal{F}_t\}$ 的鞅，记增量 $D_t := X_t - X_{t-1}$ 。则 $\{D_t\}$ 称为 **鞅差分序列** (martingale difference sequence, MDS)，它满足

$$\mathbb{E}(D_{t+1} | \mathcal{F}_t) = \mathbb{E}(X_{t+1} - X_t | \mathcal{F}_t) = X_t - X_t = 0.$$

即给定过去，每一步增量的条件期望为零。反过来， $X_t = X_0 + \sum_{s=1}^t D_s$ 把鞅写成“初值加一串鞅差分的累加”。

鞅差分是“不可预测的增量”的精确刻画。它比“独立同分布”弱、却往往够用：增量不必独立、不必同分布，只要“给定过去、当前增量的最优预测是零”。这一条性质有一个立竿见影的推论——**鞅差分两两不相关**：对 $s < t$,

$$\mathbb{E}(D_s D_t) = \mathbb{E}(\mathbb{E}(D_s D_t | \mathcal{F}_{t-1})) = \mathbb{E}(D_s \mathbb{E}(D_t | \mathcal{F}_{t-1})) = \mathbb{E}(D_s \cdot 0) = 0,$$

其中第二步用了“提出已知量”（ D_s 在 $\mathcal{F}_{t-1}$ 下已知，可提到条件期望外，因为 $s < t$ ）、第三步用了鞅差分性质。这条“不相关”正是后面鞅中心极限定理和理性预期检验的支点。

鞅差分序列：计量经济学里“扰动”的正确身份

本科计量常假设误差项 i.i.d.，但时间序列里这太强：今天的冲击常与昨天的波动相关。真正需要的、也几乎处处够用的，是把扰动设成鞅差分序列—— $\mathbb{E}(\varepsilon_{t+1} | \mathcal{F}_t) = 0$ 。它恰好等价于“用过去信息无法预测下一期扰动”，正是理性预期、有效市场、以及 GMM 矩条件 $\mathbb{E}(g(\cdot) | \mathcal{F}_t) = 0$ 想表达的东西。鞅差分两两不相关、却允许条件异方差（如 ARCH/GARCH 的波动聚集），这使它成为金融时间序列的默认扰动结构。

下鞅与上鞅则刻画“有方向的漂移”，图 41.2 把三者并排对照：从同一个当前值出发，下一期的条件期望或上移（下鞅）、或持平（鞅）、或下移（上鞅）。




图 41.2: 鞅、下鞅、上鞅的漂移方向。三者从同一当前值 X_t 出发，下一期条件期望分别上移（下鞅，对持有者有利）、持平（鞅，公平）、下移（上鞅，不利）。记忆口诀：“上鞅向下、下鞅向上”，名字来自其期望的极限性质（上鞅期望递减），与漂移方向恰好相反。

名字容易记反：上鞅的期望随时间递减、路径系统性下沉；下鞅则期望递增、向上漂。术语对的是“期望序列的单调性”（super 对应优越、势能递减），不是路径的方向，初学者务必当心。

由塔性质，鞅的无条件期望恒定，这是最常被用到的一条简单推论。

命题 41.4: 鞅的期望恒定

若 $\{X_t\}$ 是鞅，则 $\mathbb{E}(X_t) = \mathbb{E}(X_0)$ 对一切 t 成立。对下鞅 $\mathbb{E}(X_t)$ 关于 t 递增，对上鞅递减。

证明。对鞅，用塔性质把信息一层层抹掉：

$$\mathbb{E}(X_{t+1}) = \mathbb{E}(\mathbb{E}(X_{t+1} | \mathcal{F}_t)) = \mathbb{E}(X_t),$$

故 $\mathbb{E}(X_t)$ 不随 t 变，等于 $\mathbb{E}(X_0)$ 。下鞅情形把中间的等号换成 $\geq$ 得 $\mathbb{E}(X_{t+1}) \geq \mathbb{E}(X_t)$ （递增），上鞅换成 $\leq$ （递减）。□

41.3 典型例子

定义抽象，例子才让它活起来。下面三个例子分别对应“公平赌局”、“统计推断”、“资产价格”——后文的全部应用都从它们生长出来。

例（对称随机游走是鞅）。

设 $\{\xi_t\}$ 独立同分布， $\mathbb{P}(\xi_t = +1) = \mathbb{P}(\xi_t = -1) = \frac{1}{2}$ （公平的一步赌注）， $S_0 = 0$ ， $S_t = \sum_{s=1}^t \xi_s$ 。取自然 filtration $\mathcal{F}_t = \sigma(\xi_1, \dots, \xi_t)$ 。证明 $\{S_t\}$ 是鞅。

解。

S_t 是 $\xi_1, \dots, \xi_t$ 的函数，故 $\mathcal{F}_t$ -可测、适应； $|S_t| \leq t$ 故可积。验证鞅等式：

$$\mathbb{E}(S_{t+1} | \mathcal{F}_t) = \mathbb{E}(S_t + \xi_{t+1} | \mathcal{F}_t) = S_t + \mathbb{E}(\xi_{t+1} | \mathcal{F}_t) = S_t + \mathbb{E}(\xi_{t+1}) = S_t,$$

第二步用线性与“ S_t 在 $\mathcal{F}_t$ 下已知可提出”，第三步用 ξ_{t+1} 与 $\mathcal{F}_t$ 独立（故条件期望退化为无条件），末步因 $\mathbb{E}(\xi_{t+1}) = 0$ 。增量 ξ_t 正是鞅差分序列。若改成有偏赌局 $\mathbb{P}(\xi = 1) = p$ ，则 $\mathbb{E}(\xi) = 2p - 1$ ： $p > \frac{1}{2}$ 时 S_t 是下鞅（向上漂）， $p < \frac{1}{2}$ 时是上鞅——赌场的优势正是把玩家财富做成了上鞅。

例（似然比是鞅）。

设 $X_1, X_2, \dots$ 在真实密度 f_0 下独立同分布， f_1 是另一个备择密度（在 f_0 的支撑上 $f_0 > 0$ ）。定义累积似然比

$$L_t = \prod_{s=1}^t \frac{f_1(X_s)}{f_0(X_s)}, \quad L_0 = 1.$$

取 $\mathcal{F}_t = \sigma(X_1, \dots, X_t)$ 。证明在真实分布 f_0 下 $\{L_t\}$ 是鞅。

解。

L_t 适应、且 $\mathbb{E}(L_t) = 1 < \infty$ （下面顺带得到）。关键一步是算单步条件期望。 $L_{t+1} = L_t \cdot \frac{f_1(X_{t+1})}{f_0(X_{t+1})}$ ，其中 L_t 在 $\mathcal{F}_t$ 下已知， X_{t+1} 与 $\mathcal{F}_t$ 独立，故

$$\mathbb{E}_{f_0}(L_{t+1} | \mathcal{F}_t) = L_t \cdot \mathbb{E}_{f_0}\left(\frac{f_1(X_{t+1})}{f_0(X_{t+1})}\right).$$

而那个无条件期望（在真实密度 f_0 下积分）恰好为一：

$$\mathbb{E}_{f_0}\left(\frac{f_1(X)}{f_0(X)}\right) = \int \frac{f_1(x)}{f_0(x)} f_0(x) dx = \int f_1(x) dx = 1.$$

于是 $\mathbb{E}_{f_0}(L_{t+1} | \mathcal{F}_t) = L_t$ ， $\{L_t\}$ 是鞅，且 $\mathbb{E}(L_t) = \mathbb{E}(L_0) = 1$ 。这是序贯似然比检验（下一节“序贯检验”）与测度变换的引擎：似然比鞅在 f_0 下期望恒为 1，正是 Wald 序贯检验的边界概率得以控制、以及金融里“从客观测度换到风险中性测度”（Radon–Nikodym 导数过程）能成立的根本原因。

例 (Doob 鞅：对固定目标的逐步逼近) .

设 Y 是任一可积随机变量 (“终将揭晓的真相”，如某资产的清算价值、某参数的真值)， $\{\mathcal{F}_t\}$ 是 filtration。定义

$$M_t := \mathbb{E}(Y | \mathcal{F}_t).$$

则 $\{M_t\}$ 是鞅。

解.

M_t 按构造 $\mathcal{F}_t$ -可测、可积。用塔性质 ($\mathcal{F}_t \subseteq \mathcal{F}_{t+1}$ ，“粗投影吃掉细投影”)：

$$\mathbb{E}(M_{t+1} | \mathcal{F}_t) = \mathbb{E}(\mathbb{E}(Y | \mathcal{F}_{t+1}) | \mathcal{F}_t) = \mathbb{E}(Y | \mathcal{F}_t) = M_t.$$

故 $\{M_t\}$ 是鞅，称为 Y 关于该 filtration 的 Doob 鞅。

最后这个例子值得专门点出，因为它把上一章的“后验信念是鞅”一句话彻底解释清楚了。

后验信念是鞅——一个 Doob 鞅

设真相是参数 θ ，把待估的目标取成示性量 $Y = \mathbf{1}_{\{\theta=\theta^*\}}$ (“状态是否为 θ^*)”。则 $M_t = \mathbb{E}(Y | \mathcal{F}_t) = \mathbb{P}(\theta = \theta^* | \mathcal{F}_t)$ 正是 t 期的后验信念。由上例，它自动是鞅： $\mathbb{E}(M_{t+1} | \mathcal{F}_t) = M_t$ 。这正是上一章“你说服不了自己往哪边走”的精确来源——理性后验信念是对一个固定真相的 Doob 鞅，其期望恒等于当前信念，未来的信念变动事前无法预测。贝叶斯劝说里的 Bayes-plausibility 约束、宏观学习里“信念不可被系统性操纵”，都是这一条 Doob 鞅性的化身。

41.4 可选停时定理

鞅的“公平”在固定的确定时刻 t 上由 $\mathbb{E}(X_t) = \mathbb{E}(X_0)$ 表达。但赌徒真正想问的是：我能不能用一个聪明的停手策略打破公平——比如“只要赢了就收手、输了就接着赌”？停手的时刻本身是随机的、取决于已发生的牌局。要回答这个问题，先得给“依赖历史的随机停手时刻”一个干净的定义。

定义 41.5: 停时

关于 filtration $\{\mathcal{F}_t\}$ ，一个取值于 $\{0, 1, 2, \dots\} \cup \{\infty\}$ 的随机变量 τ 称为 **停时** (stopping time)，若对每个 t ，事件 $\{\tau = t\} \in \mathcal{F}_t$ 。

这个条件的含义朴素而关键：是否在时刻 t 停手，只能依据到 t 为止的信息来决定——你不许偷看未来再决定何时收手。“第一次财富触及 100 元就停”是停时（每天都能判断今天是否首次达标）；而“在财富即将下跌的前一刻停”不是停时（需要知道明天）。这正是把“可实施的交易/退出策略”与“事后诸葛”区分开的数学线。

定理 41.6: 可选停时定理 (Optional Stopping Theorem)

设 $\{X_t\}$ 是关于 $\{\mathcal{F}_t\}$ 的鞅, τ 是停时。若下列三条充分条件之一成立:

- (i) τ 有界 (存在常数 N 使 $\tau \leq N$ 几乎必然); 或
- (ii) $\tau < \infty$ 几乎必然, 且 $\{X_{t \wedge \tau}\}$ 一致有界 (存在 C 使 $|X_{t \wedge \tau}| \leq C$); 或
- (iii) $\mathbb{E}(\tau) < \infty$, 且增量一致有界 (存在 C 使 $|X_{t+1} - X_t| \leq C$);

则

$$\mathbb{E}(X_\tau) = \mathbb{E}(X_0).$$

对上鞅相应地有 $\mathbb{E}(X_\tau) \leq \mathbb{E}(X_0)$, 对下鞅 $\mathbb{E}(X_\tau) \geq \mathbb{E}(X_0)$ 。

注 (为什么需要那些技术条件: 能不能“无中生有”).

没有任何附加条件时定理会失效, 反例正是著名的倍注策略 (martingale betting, 术语的来源): 在对称随机游走里押注, 每输一次就把赌注翻倍, 直到第一次赢为止收手。令 τ 为首次赢的时刻——它几乎必然有限, 而停手时净赢利恒为 $+1$, 于是 $\mathbb{E}(X_\tau) = 1 \neq 0 = \mathbb{E}(X_0)$, 公平似乎被打破了! 破绽在于: 这个策略要求“无限的本金与无限的信用”——中途的亏损没有下界, $\{X_{t \wedge \tau}\}$ 不一致有界、 $\mathbb{E}(\tau)$ 也未必配上有限增量, 定理三条都不满足。现实中本金有限 (财富有下界 $-b$), 一旦撞到下界就被迫离场, 公平立刻恢复。定理的技术条件, 本质上是在排除“用无限资源套出确定收益”这种物理上不可能的事。

下面给定理在最干净的有界情形 (i) 下的证明——它只是塔性质的一次迭代, 把“公平在每个固定时刻成立”推广到“公平在有界的随机时刻也成立”。

有界停时情形 (i). 设 $\tau \leq N$ 。关键观察: 把鞅按“停或不停”分解, 停时之前每一步仍是公平的。具体地, 考虑停止过程 $X_{t \wedge \tau}$ (撞到 τ 后就冻结不动), 它仍是鞅——因为在 $\{\tau > t\}$ (尚未停) 上它走一步真正的鞅增量、条件期望持平, 在 $\{\tau \leq t\}$ (已停) 上它不动、条件期望也持平。形式地,

$$X_{(t+1) \wedge \tau} - X_{t \wedge \tau} = \mathbf{1}_{\{\tau > t\}} (X_{t+1} - X_t),$$

而 $\mathbf{1}_{\{\tau > t\}} = 1 - \mathbf{1}_{\{\tau \leq t\}}$ 是 $\mathcal{F}_t$ -可测的 (停时定义保证 $\{\tau \leq t\} \in \mathcal{F}_t$)。于是

$$\mathbb{E}(X_{(t+1) \wedge \tau} - X_{t \wedge \tau} | \mathcal{F}_t) = \mathbf{1}_{\{\tau > t\}} \mathbb{E}(X_{t+1} - X_t | \mathcal{F}_t) = \mathbf{1}_{\{\tau > t\}} \cdot 0 = 0,$$

即 $\{X_{t \wedge \tau}\}$ 是鞅。对它取无条件期望得 $\mathbb{E}(X_{t \wedge \tau}) = \mathbb{E}(X_0)$ 对一切 t 成立。取 $t = N$, 因 $\tau \leq N$ 故 $N \wedge \tau = \tau$, 于是 $\mathbb{E}(X_\tau) = \mathbb{E}(X_0)$ 。其余情形 (ii)(iii) 用控制收敛/一致可积把上式中的极限 $t \rightarrow \infty$ 取进期望即可, 技术细节本书从略。□

可选停时定理 = “没有稳赚的停手策略”

这是鞅最具经济学分量的一条。它说：面对一个公平博弈（鞅），任何在满足温和条件下的停手规则 τ 都不能改变期望收益—— $\mathbb{E}(X_\tau) = \mathbb{E}(X_0)$ ，赢面与输面恰好抵消。“低买高卖”听起来稳赚，但若价格是鞅、且你不能偷看未来（ τ 必须是停时），你就无法系统性地“总在高点卖出”。这把“有效市场上不存在稳赚的择时策略”翻译成了一行数学。它也是无套利的微观机制：若某停手策略能保证 $\mathbb{E}(X_\tau) > \mathbb{E}(X_0)$ ，那就是一台免费印钞机，理性市场会立刻把它套利掉、使价格回到鞅。

图 41.3 把这件事画在一个有上下界的公平赌局里：无论路径如何游走、无论你设定怎样的（合规的）停手规则，停时处取值的期望都钉在初值 X_0 上。




图 41.3: 可选停时定理的图像。公平赌局（鞅）从 X_0 出发，在触及上界 $+a$ 或下界 $-b$ 时停手（图中样本于 τ 处触上界被吸收）。尽管单条路径或赢或输，但停时取值的期望恒等于初值 X_0 （蓝色虚线）——任何合规的停手规则都无法系统性地改变它。

例（赌徒破产问题：用可选停时一步算出胜率）。

对称随机游走 S_t 从 $S_0 = k$ 出发（ $0 < k < n$ ），在触及 0（破产）或 n （达标）时停手，停时记 τ 。求最终达标（先到 n ）的概率 $p_k = \mathbb{P}(S_\tau = n)$ 。

解。

$\{S_t\}$ 是鞅，停时 τ 把过程限制在 $[0, n]$ 内、故 $\{S_{t \wedge \tau}\}$ 一致有界，且可证 $\tau < \infty$ 几乎必然——满足可选停时定理条件 (ii)。于是

$$\mathbb{E}(S_\tau) = \mathbb{E}(S_0) = k.$$

而 S_τ 只取两个值：以概率 p_k 取 n 、以概率 $1 - p_k$ 取 0。代入：

$$\mathbb{E}(S_\tau) = n p_k + 0 \cdot (1 - p_k) = n p_k = k \implies p_k = \frac{k}{n}.$$

达标概率正比于起点离破产线的距离——直觉完全合理（起点越靠近目标越容易先到），而我们没有解任何差分方程，只用了“公平博弈的期望守恒”。若把目标换成“求期望持续时间 $\mathbb{E}(\tau)$ ”，对称随机游走的另一个鞅 $S_t^2 - t$ （可验证它也是鞅）配可选停时定理，可一行得到 $\mathbb{E}(\tau) = k(n - k)$ 。鞅方法把这类边界问题统一成“找一个合适的鞅 + 套可选停时”。

41.5 鞅收敛定理

鞅不仅在每步保持公平，在温和条件下还必然收敛到一个极限随机变量。这条定理是“学习终将稳定”、“信念终将沉淀”这类断言的数学根据。其证明（Doob 的上穿不等式）较重，本书按惯例只陈述结论并给直觉。

定理 41.7: 鞅收敛定理 (Doob)

设 $\{X_t\}$ 是鞅（或下鞅、上鞅），且在 L^1 上一致有界：

$$\sup_t \mathbb{E}(|X_t|) < \infty.$$

则存在一个可积的随机变量 X_∞ ，使得 $X_t \xrightarrow{\text{a.s.}} X_\infty$ （几乎必然收敛）。特别地，非负上鞅总满足这一条件，故非负上鞅必几乎必然收敛。

直觉是这样的：鞅不能有系统性漂移（期望恒定），所以它要么逐渐安定下来、要么无界地剧烈摆动；而“ L^1 一致有界”恰好排除了“摆动幅度无限增大”这条出路。Doob 的证明把“不收敛”刻画为“无穷多次上穿任一给定区间 $[a, b]$ ”，再证明鞅的“上穿次数”期望有限（否则会与公平性矛盾），于是几乎必然只能上穿有限次——也就只能收敛。

鞅收敛 = “学习终将沉淀”

把这条定理用在 Doob 鞅 $M_t = \mathbb{E}(Y | \mathcal{F}_t)$ （后验信念 / 对真相的逐步逼近）上，威力立现。后验概率 $M_t \in [0, 1]$ 是有界鞅，故必几乎必然收敛到某个 M_∞ 。这说明：理性贝叶斯学习者的信念不会永远震荡，终将沉淀到一个极限信念。若信息流足够丰富（ $\mathcal{F}_\infty$ 能识别真相），则 M_∞ 收敛到真相本身——这就是贝叶斯一致性的鞅证明。在宏观学习、社会学习（信息瀑布）、重复博弈的信念演化里，“信念收敛”这一步几乎总是鞅收敛定理在背后兜底。

注（收敛了，期望就一定守得住吗：一致可积）。

几乎必然收敛 $X_t \rightarrow X_\infty$ 并不自动保证 $\mathbb{E}(X_\infty) = \mathbb{E}(X_0)$ （期望可能在极限处“漏掉”）。回到对称随机游走加吸收：它是鞅、有界停止后收敛，但若不设上界、只在触 0 时停，则 $S_\tau \equiv 0$ ， $\mathbb{E}(S_\tau) = 0 \neq k = \mathbb{E}(S_0)$ ——期望守恒失效。补上“一致可积”这条额外条件，才有 $\mathbb{E}(X_\infty) = \mathbb{E}(X_0)$ 且 $X_t \rightarrow X_\infty$ 在 L^1 中成立。直觉上一致可积排除了“质量逃向无穷”。这与可选停时定理需要技术条件是同一回事：极限/停时与期望交换，需要“不漏质量”的保证。

41.6 它通向何处

鞅是少数几个“一处学会、四处遇见”的工具。把本章接回经济学主干，四个去处尤为重要。

41.6.1 有效市场与风险中性定价

有效市场假说最锋利的数学形式就是一句话：**(贴现后的)资产价格是鞅**。若价格 P_t 关于公开信息流 $\mathcal{F}_t$ 满足 $\mathbb{E}(P_{t+1} | \mathcal{F}_t) = P_t$ (更准确地，是相对无风险利率贴现后的价格)，则由可选停时定理，任何基于公开信息的择时策略都无法系统性获利——“可预测的超额收益”不存在。这正是上一章“后验信念是鞅”在价格上的体现：价格作为对未来现金流的理性信念，其变动只能是不可预测的“意外”。

更深一层是无套利与风险中性定价。资产定价基本定理断言：市场无套利，当且仅当存在一个等价的“风险中性测度” $\mathbb{Q}$ ，使得每个资产的贴现价格在 $\mathbb{Q}$ 下是鞅：

$$\frac{P_t}{(1+r)^t} = \mathbb{E}_{\mathbb{Q}} \left(\frac{P_{t+1}}{(1+r)^{t+1}} \middle| \mathcal{F}_t \right).$$

于是任何衍生品的当期价格 = 其未来收益在风险中性测度下的贴现期望——定价就是对一个鞅取条件期望。从客观测度 $\mathbb{P}$ 换到风险中性测度 $\mathbb{Q}$ ，用的正是似然比鞅那样的 Radon-Nikodym 导数过程（见“似然比是鞅”例）。Black-Scholes 公式、二叉树定价、利率模型，骨架全是这一条鞅性质。

41.6.2 理性预期：预测误差是鞅差分

理性预期假设个体的主观预期等于真实的条件期望： $P_{t+1}^e = \mathbb{E}(P_{t+1} | \mathcal{F}_t)$ 。于是预测误差

$$e_{t+1} := P_{t+1} - \mathbb{E}(P_{t+1} | \mathcal{F}_t)$$

满足 $\mathbb{E}(e_{t+1} | \mathcal{F}_t) = 0$ ——它是一个**鞅差分序列**。这给出理性预期最可检验的推论：预测误差不可被任何 t 期信息预测，即 e_{t+1} 与一切 $\mathcal{F}_t$ -可测变量正交 ($\mathbb{E}(e_{t+1} Z_t) = 0$)。计量上这就是一组可检验的正交矩条件：若回归预测误差对任何已知信息（滞后变量、其它公开数据）得到显著系数，理性预期假设即被拒绝。宏观里对“预期是否理性”的检验、对 Fed 沟通效果的评估，做的都是这件事。

41.6.3 时间序列的鞅中心极限定理

经典中心极限定理要求独立同分布，时间序列里往往不成立。鞅差分序列提供了恰到好处的好处：只要 $\{D_t\}$ 是鞅差分 ($\mathbb{E}(D_{t+1} | \mathcal{F}_t) = 0$) 且满足温和的矩与稳定性条件，就有

$$\frac{1}{\sqrt{n}} \sum_{t=1}^n D_t \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

这就是**鞅中心极限定理**。它之所以是渐近计量的主力，是因为绝大多数估计量的“得分”（一阶条件的样本平均）在正确设定下天然就是鞅差分——回忆“条件期望”一章里 M-估

计量由样本一阶条件隐含定义，那个一阶条件正是鞅差分。于是 MLE、GMM、时间序列回归的渐近正态性，统统由鞅 CLT 而非 i.i.d. 的 CLT 来保证。鞅差分“两两不相关”（本章已证）正是让方差 σ^2 不出现协方差交叉项、CLT 得以干净成立的关键。

41.6.4 序贯检验与随机逼近

似然比鞅 ($\mathbb{E}(L_t) = 1$) 撑起序贯检验：Wald 的序贯概率比检验 (SPRT) 让样本量本身成为停时——边观察边累积证据，似然比一旦穿越上/下阈值就停手判决。可选停时定理保证了这种“适应性停手”不会暗中扭曲第一类/第二类错误率，从而能在期望意义下用最少的样本完成检验。这是 A/B 测试“偷看数据”之所以危险、而正确的序贯设计之所以安全的根本原因。鞅还是随机逼近 (Robbins–Monro, 随机梯度下降的祖先) 收敛性证明的核心工具：把迭代误差构造成一个上鞅，再用鞅收敛定理证明它几乎必然趋零——现代机器学习优化算法的收敛性分析，许多就走这条鞅路线。

一个由“条件期望持平”定义的简单对象，串起了金融、宏观、计量与统计推断。这再次印证全书的主线：鞅之所以能同时是“有效市场”、是“理性预期误差”、是“渐近正态的得分”、是“收敛的学习”，正因为它们共享同一个内核——给定信息，最优预测就是当下；变化只能是不可预测的意外。认清这把钥匙，许多扇看似无关的门便一起打开了。

第四十二章 布朗运动与 Itô 引理

用到的前置工具：正态分布与独立性（概率与测度部分）；中心极限定理（渐近统计部分，CLT 一章）；Taylor 二阶展开（多元微积分部分，Taylor 一章）；鞅与条件期望（随机过程部分，鞅一章）。

到本章为止，本书的随机对象大多是“一串”随机变量：样本 $X_1, \dots, X_n$ 、一条 Markov 链、一列鞅。但连续时间金融与宏观要处理的，是在每一个时刻都在抖动的量——股价分分秒秒在变、利率连续地游走、一个宏观冲击持续地敲打经济。要给这种“连续时间的随机扰动”一个数学载体，就需要布朗运动：它是随机游走在时间步长趋于零时的极限，是连续时间随机过程的“白噪声原材料”。有了它，资产价格可以写成一个随机微分方程，期权可以定价，最优消费—投资问题可以用 Hamilton–Jacobi–Bellman 方程求解。

可是布朗运动有一个让人措手不及的性质：它的路径连续，却处处不可微。这意味着普通微积分的链式法则、换元积分，统统不能照搬——对一个无处可导的对象， dX/dt 根本不存在。本章的主角 Itô 引理，正是为这种对象量身定做的“链式法则”。它与普通链式法则只差一项，却恰恰是这一项，撑起了整个连续时间金融的大厦。本章先把布朗运动讲清楚（它从哪来、为什么不可微），再讲清那个核心的“ $(dW)^2 = dt$ ”，然后推出 Itô 引理，最后用它解几何布朗运动、并指向 Black–Scholes 与随机控制。

42.1 从随机游走到布朗运动

最稳妥的理解方式，是把布朗运动看成一个我们已经熟悉的对象——简单随机游走——在时间被无限细分时的极限。这条路径不仅给出布朗运动的“出处”，还顺手解释了它为什么是高斯的、为什么方差随时间线性增长。

设时间步长为 Δt ，每一步独立地以等概率向上或向下跳一段 Δx ：令 $\xi_1, \xi_2, \dots$ 独立同分布、各取 ± 1 概率各半。走到时刻 $t = N\Delta t$ （即 $N = t/\Delta t$ 步）的位置是

$$S_N = \Delta x \sum_{k=1}^N \xi_k.$$

因为 $E(\xi_k) = 0$ 、 $\text{Var}(\xi_k) = 1$ ，有 $E(S_N) = 0$ 与 $\text{Var}(S_N) = (\Delta x)^2 N = (\Delta x)^2 t / \Delta t$ 。我们希望取极限 $\Delta t \rightarrow 0$ 后，到时刻 t 的位置有一个非平凡的方差（既不爆掉、也不塌成零）。这就逼着我们把空间步长与时间步长按一个特定比例绑定：

$$(\Delta x)^2 = \sigma^2 \Delta t \iff \Delta x = \sigma \sqrt{\Delta t}.$$

有了这个标度, $\text{Var}(S_N) = \sigma^2 t$ 与步长无关。再对 $S_N = \sigma\sqrt{\Delta t} \sum_{k=1}^N \xi_k = \sigma\sqrt{t} \cdot \frac{1}{\sqrt{N}} \sum_{k=1}^N \xi_k$ 用中心极限定理 (见渐近统计部分, CLT 一章): 当 $N \rightarrow \infty$ 时 $\frac{1}{\sqrt{N}} \sum \xi_k \xrightarrow{d} \mathcal{N}(0, 1)$, 于是

$$S_N \xrightarrow{d} \mathcal{N}(0, \sigma^2 t).$$

这个极限过程就是 (带波动率 σ 的) 布朗运动。

为什么是 $\Delta x \propto \sqrt{\Delta t}$, 而不是 $\propto \Delta t$

这一条标度关系是理解后文一切的钥匙。如果像普通光滑曲线那样让位移正比于时间 ($\Delta x \propto \Delta t$), 那么 N 步累计的方差是 $(\Delta x)^2 N \propto (\Delta t)^2 \cdot t/\Delta t = t \Delta t \rightarrow 0$ ——抖动会被磨平, 极限退化出一条不动的直线。要让随机性在连续极限下存活, 位移必须按 $\sqrt{\Delta t}$ 这个更“大”的量级走。正是 $\Delta x \sim \sqrt{\Delta t} \gg \Delta t$ 这件事, 日后会化为 $(dW)^2 = dt$, 也正是它让布朗运动不可微: 斜率 $\Delta x/\Delta t \sim 1/\sqrt{\Delta t} \rightarrow \infty$ 。

把这个极限对象的性质单独列出, 就是布朗运动的公理化定义。

定义 42.1: 标准布朗运动 (Wiener 过程)

随机过程 $\{W_t\}_{t \geq 0}$ 称为**标准布朗运动**, 若满足:

- (B1) $W_0 = 0$;
- (B2) **独立增量**: 对任意 $0 \leq t_0 < t_1 < \dots < t_n$, 增量 $W_{t_1} - W_{t_0}, \dots, W_{t_n} - W_{t_{n-1}}$ 相互独立;
- (B3) **高斯增量**: 对 $s < t$, 增量 $W_t - W_s \sim \mathcal{N}(0, t - s)$ ——均值为零, 方差等于时间长度;
- (B4) **路径连续**: 几乎必然地, $t \mapsto W_t$ 是连续函数。

带漂移 μ 、波动率 σ 的布朗运动定义为 $X_t = \mu t + \sigma W_t$ 。

注 (四条公理各管什么)。

(B2) 独立增量是“无记忆”的连续时间版本: 过去怎么走, 不影响未来怎么走——它使 W_t 同时是 Markov 过程, 也 (在 (B3) 之下) 使 W_t 成为鞅 (见鞅一章)。(B3) 高斯性是中心极限定理留下的“指纹”: 极限里出现正态, 是因为增量本身是大量独立微小跳动之和。方差恰等于时间长度 $t - s$, 正是上文 $(\Delta x)^2 = \sigma^2 \Delta t$ 标度的结果 (标准布朗运动取 $\sigma = 1$)。(B4) 连续性必须单独要求——它不是前三条的推论, 而是 Wiener 当年证明“这样的过程确实存在”时最吃力的部分。

注 (存在性是一个真正的定理)。

“满足 (B1)–(B4) 的过程真的存在”并非显然: 要在一个概率空间上同时安排不可数无穷多个随机变量 $\{W_t\}$, 还要它们的联合分布自洽、路径连续。Wiener (1923) 给出了第一个严格构造。本书按使用者的需要, 把存在性当作已知, 把重心放在如何

用布朗运动上；想看构造的读者可参阅随机分析教材（如 Karatzas-Shreve）。




图 42.1: 布朗运动的三条样本路径：连续但处处锯齿、不可微；典型幅度随时间按 $\sqrt{t}$ 张开，落在虚线包络 $\pm c\sqrt{t}$ 之间（这里 c 取若干倍标准差以含住大多数路径）。

42.2 处处连续，处处不可微

布朗运动最反直觉的性质，是它的路径连续却处处不可微。这不是数学家的怪癖，而是它作为“连续时间随机扰动”的本质，并且直接决定了为什么需要一套新的微积分。

直觉已经藏在标度关系里。考虑差商

$$\frac{W_{t+\Delta t} - W_t}{\Delta t}.$$

分子是一个 $\mathcal{N}(0, \Delta t)$ 的随机变量，典型大小是 $\sqrt{\Delta t}$ ；除以 Δt 后，典型大小是 $\sqrt{\Delta t}/\Delta t = 1/\sqrt{\Delta t}$ ，当 $\Delta t \rightarrow 0$ 时发散。差商不收敛到任何有限值，导数 dW/dt 不存在。从图 42.1 看，无论把路径放大到多小的尺度，它依旧是锯齿状的——放大并不会让它变得“像直线”，自相似的粗糙在每个尺度上重现。

为什么不可微逼出一套新微积分

普通微积分的两块基石都依赖可微性：链式法则要 $df/dt = f' dX/dt$ ，换元积分 $\int g dX = \int g X' dt$ 也要 X' 存在。布朗运动 W_t 处处没有导数，这两块基石同时垮掉。于是必须重建两样东西：(i) 一种新的积分 $\int_0^t H_s dW_s$ (Itô 积分)，它不靠 W 可导、而靠 W 的增量来定义；(ii) 一条新的链式法则 (Itô 引理)，它会比普通链式法则多出一项。这一整章其余部分，就是在搭这两样东西。

不可微性的“定量”来源，是下一节的二次变分——这也是 Itô 微积分与普通微积分分道扬镳的真正源头。

42.3 二次变分: $(dW)^2 = dt$

普通光滑函数 f 有一个不起眼的性质: 把 $[0, t]$ 切成 N 小段, 平方增量之和 $\sum_k [f(t_{k+1}) - f(t_k)]^2$ 在 $N \rightarrow \infty$ 时趋于零 (每个增量 $\sim \Delta t$, 平方 $\sim (\Delta t)^2$, 乘以 $N \sim 1/\Delta t$ 段还是 $\sim \Delta t \rightarrow 0$)。这就是为什么普通微积分里 $(dx)^2$ 可以当作高阶小量直接扔掉。布朗运动恰恰在这一点上不同。

定理 42.2: 布朗运动的二次变分

把 $[0, t]$ 等分为 N 段, $t_k = kt/N$, $\Delta W_k = W_{t_{k+1}} - W_{t_k}$ 。则平方增量之和

$$Q_N = \sum_{k=0}^{N-1} (\Delta W_k)^2 \xrightarrow{L^2} t \quad (N \rightarrow \infty).$$

即布朗运动在 $[0, t]$ 上的二次变分等于 t (确定值, 非随机)。

证明. 各 $\Delta W_k \sim \mathcal{N}(0, t/N)$ 且相互独立 (独立增量)。记 $h = t/N$ 。逐项算期望: $\mathbb{E}((\Delta W_k)^2) = \text{Var}(\Delta W_k) = h$, 故

$$\mathbb{E}(Q_N) = \sum_{k=0}^{N-1} h = N \cdot \frac{t}{N} = t.$$

均值已经对了, 再看它围绕 t 的波动。由独立性,

$$\text{Var}(Q_N) = \sum_{k=0}^{N-1} \text{Var}((\Delta W_k)^2).$$

对 $Z \sim \mathcal{N}(0, h)$, $(\Delta W_k)^2 \stackrel{d}{=} Z^2$, 而 $\text{Var}(Z^2) = \mathbb{E}(Z^4) - (\mathbb{E}(Z^2))^2 = 3h^2 - h^2 = 2h^2$ (用了高斯四阶矩 $\mathbb{E}(Z^4) = 3h^2$)。于是

$$\text{Var}(Q_N) = N \cdot 2h^2 = 2N \left(\frac{t}{N} \right)^2 = \frac{2t^2}{N} \xrightarrow{N \rightarrow \infty} 0.$$

均值恒为 t 、方差趋于零, 故 $Q_N \rightarrow t$ (依 L^2 , 从而依概率)。

□

这条定理是整套 Itô 微积分的发动机。它说: 布朗运动的平方增量之和不会像光滑函数那样塌成零, 反而坚定地收敛到确定值 t 。把它写成微分的助记形式, 就是那条著名的等式:

$$\boxed{(dW)^2 = dt}.$$

它的含义不是“某个随机量等于 dt ”, 而是: 在对 $[0, t]$ 求和 (积分) 的极限意义下, $\sum (\Delta W_k)^2$ 的行为与 $\sum \Delta t_k = t$ 完全一样。配套地, 由于 $\Delta W_k \cdot \Delta t_k \sim \sqrt{\Delta t} \cdot \Delta t = (\Delta t)^{3/2}$, $(\Delta t_k)^2 \sim (\Delta t)^2$ 求和后都趋于零, 我们还有 Itô 乘法表:

$$(dW)^2 = dt, \quad dW \, dt = 0, \quad (dt)^2 = 0.$$

$(dW)^2 = dt$ 是 Itô 微积分与普通微积分唯一的本质差别

普通微积分扔掉一切二阶项 $(dx)^2$ ；Itô 微积分扔掉 $dW dt$ 和 $(dt)^2$ ，却必须保留 $(dW)^2$ 并把它换成 dt 。后文 Itô 引理之所以比普通链式法则多出一项，根子全在这里：Taylor 展开的二阶项 $\frac{1}{2}f''(dX)^2$ 含一个 $(dW)^2$ ，在普通微积分里它是可忽略的高阶小量，在 Itô 微积分里它升格成了一个 dt 量级的、不可忽略的漂移项。记住这一条，Itô 引理就不再需要背。




图 42.2: 二次变分对照。左：布朗运动的平方增量之和 Q_N 随细分变细，方差收窄、稳定收敛到非零的确定值 t 。右：普通光滑路径的平方增量之和塌向 0。正是左图这条“不肯归零”的二阶量，逼出了 $(dW)^2 = dt$ 与 Itô 引理的多出项。

42.4 Itô 积分：为何不能照搬普通积分

在写下随机微分方程之前，必须先弄清 $\int_0^t H_s dW_s$ 这样一个“对布朗运动积分”的对象到底是什么意思。普通的 Riemann–Stieltjes 积分 $\int H dg$ 要求积分子 g 是有界变差的——而布朗运动不是（二次变分非零正意味着一阶总变差无穷）。所以这个积分必须重新定义。

定义的办法是回到黎曼和，但要在两处格外当心。设被积过程 H_s 是“适应”的（在时刻 s 只用到 s 之前的信息，不偷看未来），用左端点取值作和：

$$\int_0^t H_s dW_s := \lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} H_{t_k} [W_{t_{k+1}} - W_{t_k}] \quad (L^2 \text{ 极限}).$$

两个关键约定：

- **取左端点（这就是“Itô”的含义）。**普通积分里取区间内哪一点求值无所谓，极限都一样；但 W 的二次变分非零，使得“取左端 H_{t_k} ”与“取右端 $H_{t_{k+1}}$ ”给出不同的极限。Itô 积分一律取左端点——即用当前信息、不预见增量。正是这个选择让下面的鞅性质成立，也契合金融里“此刻持仓、随后承受下一段价格变动”的因果次序。
- **适应性。** H_{t_k} 必须只依赖 t_k 时刻及以前的信息，与未来的增量 $W_{t_{k+1}} - W_{t_k}$ 独立。这保证每一项 $H_{t_k} \Delta W_k$ 的条件期望为零。

命题 42.3: Itô 积分是鞅，且有等距

若 H 适应且 $\mathbb{E}\left(\int_0^t H_s^2 ds\right) < \infty$ ，则 $M_t = \int_0^t H_s dW_s$ 是（关于布朗运动自然信息流的）鞅， $\mathbb{E}(M_t) = 0$ ，并满足 **Itô 等距**

$$\mathbb{E}\left(\left(\int_0^t H_s dW_s\right)^2\right) = \mathbb{E}\left(\int_0^t H_s^2 ds\right).$$

证明. 鞅性。在黎曼和里，由适应性， H_{t_k} 与 ΔW_k 独立，且 $\mathbb{E}(\Delta W_k | \mathcal{F}_{t_k}) = 0$ （增量均值为零、与过去独立），故 $\mathbb{E}(H_{t_k} \Delta W_k | \mathcal{F}_{t_k}) = H_{t_k} \mathbb{E}(\Delta W_k | \mathcal{F}_{t_k}) = 0$ 。逐项条件期望为零，求和并取极限即得 $\mathbb{E}(M_t | \mathcal{F}_s) = M_s$ ，这正是鞅。

等距。把平方和展开：

$$\mathbb{E}\left(\left(\sum_k H_{t_k} \Delta W_k\right)^2\right) = \sum_{j,k} \mathbb{E}(H_{t_j} H_{t_k} \Delta W_j \Delta W_k).$$

交叉项 ($j \neq k$, 设 $j < k$) 中 ΔW_k 与 $H_{t_j} H_{t_k} \Delta W_j$ 独立且均值为零，故为零。对角项用 $\mathbb{E}((\Delta W_k)^2) = \Delta t_k$ 与独立性， $\mathbb{E}(H_{t_k}^2 (\Delta W_k)^2) = \mathbb{E}(H_{t_k}^2) \Delta t_k$ 。求和得 $\sum_k \mathbb{E}(H_{t_k}^2) \Delta t_k \rightarrow \mathbb{E}\left(\int_0^t H_s^2 ds\right)$ 。□

注 (Itô 等距：把对 dW 的积分换成对 dt 的积分)。

Itô 等距是 Itô 积分最实用的计算工具：要算一个随机积分的二阶矩（方差），不必直面 dW ，只需把被积函数平方、改对 dt 求普通积分。它本质上又是 $(dW)^2 = dt$ 的化身——平方让 $(dW)^2$ 现身，再换成 dt 。在资产定价里，它是计算组合收益方差、推导定价方程的家常便饭。

42.5 Itô 引理：随机演算的链式法则

现在搭本章的顶梁柱。问题是：若 X_t 由布朗运动驱动， f 是一个光滑函数，那么 $f(X_t)$ 随时间如何变化？普通链式法则会说 $df = f'(X) dX$ ；但我们已经知道，对布朗运动这是错的——会漏掉一项。

42.5.1 推导：Taylor 展开到二阶，再代入 $(dW)^2 = dt$

先建立记号。称 X_t 是一个 **Itô 过程**，若它满足随机微分方程 (SDE)

$$dX_t = \mu(X_t, t) dt + \sigma(X_t, t) dW_t,$$

其中 μ 是漂移（单位时间的确定性趋势）、 σ 是扩散（单位时间的随机波动幅度）。这是“ $X_t = X_0 + \int_0^t \mu ds + \int_0^t \sigma dW_s$ ”的微分速记，后一个积分按上一节的 Itô 积分理解。

要看 $f(X_t)$ 怎么变, 对 f 在 X_t 处做 Taylor 二阶展开 (见多元微积分部分, Taylor 一章)。关键的判断是: 展开保留到哪一阶。普通微积分留到一阶; 但因为 $(dX)^2$ 含 $(dW)^2 = dt$ 这个一阶量级的项, 二阶项不能扔。于是展开到二阶:

$$df = f'(X_t) dX_t + \frac{1}{2} f''(X_t) (dX_t)^2 + \underbrace{\cdots}_{\text{三阶及以上}}.$$

计算 $(dX_t)^2$, 用 Itô 乘法表 $(dW)^2 = dt$, $dW dt = 0$, $(dt)^2 = 0$:

$$(dX_t)^2 = (\mu dt + \sigma dW)^2 = \mu^2(dt)^2 + 2\mu\sigma dt dW + \sigma^2(dW)^2 = \sigma^2 dt.$$

(三项里前两项归零, 只剩 $\sigma^2(dW)^2 = \sigma^2 dt$ 。) 三阶及以上含 $(dt)^{3/2}$ 以上的因子, 求和后归零, 可弃。代回展开式, 并把 $dX_t = \mu dt + \sigma dW_t$ 也代入:

$$df = f'(\mu dt + \sigma dW_t) + \frac{1}{2} f'' \sigma^2 dt.$$

整理出漂移与扩散, 便是 Itô 引理。

定理 42.4: Itô 引理 (一维)

设 X_t 是 Itô 过程 $dX_t = \mu dt + \sigma dW_t$, $f(x, t)$ 对 x 二次连续可微、对 t 一次连续可微。则 $Y_t = f(X_t, t)$ 也是 Itô 过程, 且

$$df = \underbrace{\left(\frac{\partial f}{\partial t} + \mu \frac{\partial f}{\partial x} + \frac{1}{2} \sigma^2 \frac{\partial^2 f}{\partial x^2} \right)}_{\text{漂移}} dt + \underbrace{\sigma \frac{\partial f}{\partial x}}_{\text{扩散}} dW_t.$$

对仅依赖 x 的 $f(x)$, 简化为 $df = (\mu f' + \frac{1}{2} \sigma^2 f'') dt + \sigma f' dW_t$ 。

与普通链式法则只差一项——那一项是凸性修正

普通链式法则给 $df = f' dX = (\mu f') dt + \sigma f' dW$ 。Itô 引理在漂移里多出了 $\frac{1}{2} \sigma^2 f''$ 。这一项: (i) 正比于波动率平方 σ^2 ——波动越大, 修正越大; (ii) 正比于二阶导 f'' ——曲率越大, 修正越大; (iii) 符号随 f'' 走—— f 凸 ($f'' > 0$) 则正向抬高漂移, f 凹则压低。它就是下一小节要讲的“凸性修正”: 随机性叠加在弯曲的函数上, 会系统性地推动 f 的均值。把波动率设为零 ($\sigma = 0$), 多出项消失, Itô 引理退回普通链式法则——可见普通微积分只是“无噪声”的特例。

42.5.2 多出项的直觉: 凸性修正 (Jensen 在动)

为什么弯曲的函数会让随机扰动“有方向”? 这就是 Jensen 不等式: 对凸函数 f , $\mathbb{E}(f(X)) \geq f(\mathbb{E}(X))$ 。布朗运动每一小步是均值为零的对称抖动 ΔW ; 可一旦穿过一个凸函数 f , 向上的抖动被放大、向下的被压缩, 平均下来 f 被 net 抬高。抬高多少?

对 f 在中心做二阶展开取期望：

$$\mathbb{E}(f(X + \Delta W)) - f(X) \approx f'(X) \mathbb{E}(\Delta W) + \frac{1}{2} f''(X) \mathbb{E}((\Delta W)^2) = \frac{1}{2} f''(X) \sigma^2 \Delta t,$$

因为 $\mathbb{E}(\Delta W) = 0$ 、 $\mathbb{E}((\Delta W)^2) = \sigma^2 \Delta t$ 。一阶项被对称性抹平，留下的恰是 $\frac{1}{2} f'' \sigma^2 dt$ ——正是 Itô 引理多出的那一项（图 42.3）。这把 “ $(dW)^2 = dt$ ” 和 “Jensen 凸性” 缝到了一起：二者是同一件事的两副面孔。




图 42.3: Itô 多出项就是 Jensen 凸性间隙。X 做对称抖动 $\pm \sigma \sqrt{\Delta t}$ ，穿过凸函数 f 后两端被“撬”上去，平均高度 $\mathbb{E}(f(X))$ （弦中点）高于 $f(\mathbb{E}(X))$ （曲线上的点）。这段差距正是 $\frac{1}{2} f'' \sigma^2 dt$ ，即 Itô 引理在漂移里多出的一项。

42.6 几何布朗运动：资产价格的标准模型

Itô 引理的第一桩大用处，是解出连续时间金融里最基础的模型——几何布朗运动 (GBM)。它假设股价 S_t 的对数收益是布朗运动，即相对变化（而非绝对变化）服从恒定漂移加恒定波动：

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t \quad \Longleftrightarrow \quad dS_t = \mu S_t dt + \sigma S_t dW_t.$$

这样设定有两个经济上的好处：股价天然为正（不会跌成负数），且百分比波动不随价格水平变化（一只 \$10 的股票和一只 \$1000 的股票，日波动率可以相同）。

例（解几何布朗运动）。

对 $dS_t = \mu S_t dt + \sigma S_t dW_t$ ，求 S_t 的显式表达式。

解。

直觉上想“两边除以 S 再积分得 $\ln S$ ”——这正是普通微积分会做的，但对 Itô 过程必须用 Itô 引理校正。取变换 $f(S) = \ln S$ ，则 $f' = 1/S$ 、 $f'' = -1/S^2$ 。这里漂移 $\mu_S = \mu S$ 、扩散 $\sigma_S = \sigma S$ 。代入 Itô 引理 $df = (\mu_S f' + \frac{1}{2} \sigma_S^2 f'') dt + \sigma_S f' dW$ ：

$$d(\ln S_t) = \left(\mu S \cdot \frac{1}{S} + \frac{1}{2} \sigma^2 S^2 \cdot \left(-\frac{1}{S^2} \right) \right) dt + \sigma S \cdot \frac{1}{S} dW_t = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t.$$

右边漂移与扩散都成了常数，可以直接积分： $\ln S_t - \ln S_0 = (\mu - \frac{1}{2} \sigma^2) t + \sigma W_t$ ，于是

$$S_t = S_0 \exp \left[\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t \right].$$

由于 $W_t \sim \mathcal{N}(0, t)$ ， $\ln S_t$ 正态，故 S_t 服从**对数正态分布**。

注（那个 $-\frac{1}{2} \sigma^2$ 不是笔误，是 Itô 修正）。

若用普通微积分硬算，会得到 $S_t = S_0 \exp(\mu t + \sigma W_t)$ ，漂移里没有 $-\frac{1}{2} \sigma^2$ 。这一项正是 Itô 引理对 $\ln(\cdot)$ 这个凹函数（ $f'' = -1/S^2 < 0$ ）的修正，它把漂移往下压。它有实在的金融含义： μ 是“瞬时期望收益率”（ $\mathbb{E}(dS/S) = \mu dt$ ），但对数（连续复利）收益率的期望是 $\mu - \frac{1}{2} \sigma^2$ 。波动本身会侵蚀复利增长——同样的算术平均收益，波动越大，长期实现的几何增长越低。这就是“波动拖累”（volatility drag），无数实证与资产配置讨论的起点。由 $\mathbb{E}(S_t) = S_0 e^{\mu t}$ （对数正态的均值公式恰好补回那 $\frac{1}{2} \sigma^2$ ）可验证 μ 确为期望收益率。




图 42.4: 几何布朗运动的样本路径（ $\mu > 0$ ）。路径始终为正、呈乘性张开（对数正态因而右偏：向上的尾巴比向下的长）；虚线为期望轨道 $\mathbb{E}(S_t) = S_0 e^{\mu t}$ 。注意典型（中位）路径增长慢于期望路径，差距即来自 $-\frac{1}{2} \sigma^2$ 的波动拖累。

42.7 去处：从 Black-Scholes 到随机控制

布朗运动与 Itô 引理是连续时间经济学的通用语言。把本章工具接回主干，几条最重要的去处如下。

42.7.1 Black-Scholes 期权定价

设标的股价是 GBM, 欧式期权在到期日 T 的价值 $V(S, t)$ 待定。对 $V(S, t)$ 用 Itô 引理算出 dV , 再构造一个“持有期权、空头 $\partial V / \partial S$ 份股票”的对冲组合——巧妙之处在于这个组合的 dW 项恰好相消, 瞬时收益变成无风险的。无套利要求它只能赚无风险利率 r , 令两边相等, μ 神奇地消失, 得到 Black-Scholes 偏微分方程:

$$\frac{\partial V}{\partial t} + rS \frac{\partial V}{\partial S} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} = rV.$$

那个 $\frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2}$ 项, 正是 Itô 引理的多出项; 期权价值对波动率的依赖 (即“为什么波动率是期权的核心”) 全压在这一项上。

42.7.2 风险中性定价与鞅

Black-Scholes 推导里 μ 的消失不是巧合, 它指向更深的结构: 存在一个等价的“风险中性”概率测度, 在其下所有资产的折现价格都是鞅 (见鞅一章)。于是任何衍生品的价格都等于其折现收益在风险中性测度下的期望——定价问题被化为求期望。测度的更换 (Girsanov 定理) 本质上是给布朗运动换一个漂移, 而 Itô 引理保证换测度后过程仍是良定义的 Itô 过程。

42.7.3 随机最优控制与 HJB 方程

连续时间的最优消费—投资、最优停时 (实物期权)、最优增长等问题, 都是在一个由 SDE 驱动的状态上做动态规划。把离散时间的 Bellman 方程取连续极限 (见动态规划一章), 值函数 $V(x, t)$ 满足 Hamilton-Jacobi-Bellman 方程

$$\frac{\partial V}{\partial t} + \max_a \left\{ u(x, a) + \mu(x, a) \frac{\partial V}{\partial x} + \frac{1}{2}\sigma^2(x, a) \frac{\partial^2 V}{\partial x^2} \right\} = 0.$$

方括号里那串正是对 V 用 Itô 引理得到的漂移——HJB 方程就是“值函数的漂移加上瞬时收益等于零”。它把最优控制 (见最优控制一章, Pontryagin 原理) 与动态规划在连续时间随机环境下统一了起来。

42.7.4 利率与宏观金融模型

短期利率模型 (Vasicek、CIR) 把利率写成均值回复的 Itô 过程 $dr_t = \kappa(\theta - r_t) dt + \sigma(r_t) dW_t$; 债券定价、期限结构都建立在对它用 Itô 引理之上。连续时间宏观 (如 Brunnermeier-Sannikov 一类“宏观金融”模型) 更是把整个经济的状态变量写成 Itô 过程, 用 Itô 引理推演资产价格与杠杆的动态。

一条引理, 半个连续时间经济学

布朗运动给了我们“连续时间的随机扰动”这个原材料; Itô 引理给了我们在其上做微分的唯一正确法则。资产定价 (Black-Scholes、风险中性鞅)、随机控制 (HJB)、利率与宏观金融, 表面上是不同领域, 骨子里都是“写一个 SDE, 对感

兴趣的函数用 Itô 引理，再让无套利 / 最优性 / 平稳性收口成一个偏微分方程”。认清那个多出的 $\frac{1}{2}\sigma^2 f''$ 项——它既是 $(dW)^2 = dt$ ，又是 Jensen 凸性——就等于拿到了进入连续时间金融的钥匙。